SÍLABO DEL CURSO

Sistema de Inteligencia Causal

De la identificación a la producción local: estimar efectos, no solo predicciones, y vigilar señales que obligan a revisar su validez

Curso	ECO-490 / ECON-540 — edición 2026-II
Audiencia	Profesionales de datos, ML, producto, analítica, riesgo y operaciones
Modalidad	En línea, asíncrona, con checkpoints síncronos
Duración	16 semanas · 32 sesiones de 90 minutos · 48 horas cronológicas
Evaluación	Tres quizzes de 10 % cada uno · trabajo final único de 70 %
Entorno	El flujo técnico principal se ejecuta en el computador del estudiante; no requiere cuentas ni servicios de nube
Versión	Sílabo 2026-II. Los cambios se comunican en la plataforma del curso

Compromiso de trabajo. El curso distingue una predicción de un efecto de una intervención. Aprenderás a formular la pregunta causal, estimar el efecto con incertidumbre, documentar los supuestos y operar el resultado en local. La puerta y el monitor no prueban que el efecto sea verdadero: hacen visibles los problemas que el sistema sí puede detectar.

Monografía del curso (32 capítulos, Typst/PDF) · *Designing Machine Learning Systems* (Huyen) · *Causal Artificial Intelligence* (Bareinboim) · Monorepo: labs L01–L28, Series A y B, datos de benchmark

Contenido

1. Presentación y fundamentación iv
2. Enfoque pedagógico iv
2.1 Cuatro ideas que ordenan el curso iv
2.2 Tres clases de supuestos iv
2.3 Cómo leer una afirmación causal v
3. Objetivos de aprendizaje v
3.1 Objetivo general v
3.2 Objetivos específicos v
3.3 Qué evidencia acredita cada objetivo vi
4. Perfil de ingreso y requisitos técnicos vi
4.1 Rutas de ejecución vii
4.2 Semana 0: autodiagnóstico y nivelación vii
5. Estructura del curso vii
5.1 Evaluaciones oficiales viii
5.2 Si el calendario se acorta viii
6. Dinámica de cada sesión ix
6.1 La Bitácora Causal ix
6.2 Ausencias y ritmo x
7. Contenidos clase a clase x
Módulo 0 — Causalidad elemental y arranque x
Módulo 1 — Fundamentos y datos para sistemas causales xi
Módulo 2 — Estimación con ML y primer servicio local xiii
Checkpoint 1 — Integración xv
Módulo 3 — Repositorio, model cards y CI local xvi
Módulo 4 — Explicación, decisión, política y uplift xvii
Módulo 5 — Monitoreo, descubrimiento y frontera xix
Módulo 6 — Proyecto final xx
8. Puesta en producción local xxi
8.1 El recorrido de un efecto, de los datos al monitor xxi
8.2 Qué se hace con cada clase de supuesto xxii
8.3 Umbrales y regla de decisión xxiii
8.4 Cómo se ejecuta xxiii
8.5 Perfil opcional de contenedores xxiv
8.6 Límites de esta demostración xxiv
9. Evaluación xxiv
9.1 Qué se evalúa con una máquina y qué con una persona xxv
9.2 Evidencia de las evaluaciones xxv
9.3 Frontera entre prácticas y evaluación xxv
9.4 Fechas de evaluación xxvi
9.5 Integridad académica y uso de asistentes de IA xxvi
9.6 Datos del proyecto y confidencialidad xxvi
10. Materiales y herramientas xxvi
11. Guía operativa xxvii
11.1 Rutina semanal xxvii
11.2 Listas de verificación xxvii
11.3 Primera apertura xxviii
12. Referencias xxviii

12.1 Fuentes principales del curso xxviii
12.2 Fundamentos de inferencia causal xxviii
12.3 Estimación con ML y efectos heterogéneos xxviii
12.4 Diagnósticos, solapamiento y sensibilidad xxviii
12.5 Datos de referencia y validez externa xxix
12.6 Descubrimiento, explicación y equidad xxix
12.7 Producción, monitoreo y documentación xxix
12.8 Software y documentación técnica xxix

1. Presentación y fundamentación

Este curso está dirigido a **profesionales** que trabajan con datos o machine learning y necesitan decidir si una intervención merece continuar, ampliarse o detenerse. El nivel es aplicado: no exige desarrollar demostraciones de econometría teórica, pero sí explicar qué se estima, bajo qué supuestos y con qué evidencia. El material combina el marco de IA causal de Elias Bareinboim (*Causal Artificial Intelligence*), la monografía del curso *Sistema de Inteligencia Causal* (32 capítulos, en `02_monografia/`) y principios de ingeniería de sistemas de ML tomados de *Designing Machine Learning Systems* (Chip Huyen).

La diferencia que se enseña. Un modelo predictivo responde «¿quién tiene peor resultado?». Un sistema causal pregunta «¿a quién le cambia el resultado si actuamos?». La segunda pregunta puede cambiar el presupuesto, la priorización y la decisión de continuar o detener un programa. También puede mostrar que no hay evidencia suficiente para actuar. Cada sesión termina con una pregunta de decisión:

Si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?

Teoría y práctica en partes iguales. La teoría de identificación y estimación se apoya en la monografía y en Bareinboim. La práctica recorre el ciclo de vida de un sistema de ML —datos, covariables, evaluación, servicio y monitoreo— mediante los labs de sesión (L01–L28), los casos guiados y el prototipo de producción local. Los productos de cada módulo son prácticas formativas: una estimación auditada, un servicio de inferencia, una model card, un servicio de política o un monitor de supuestos. La única entrega calificada es el trabajo final del curso.

Numeración. La columna *Lectura* de este sílabo usa la numeración vigente del PDF de la monografía (32 capítulos).

2. Enfoque pedagógico

2.1 Cuatro ideas que ordenan el curso

Enfoque

- **Decisiones de diseño, no recetas.** Servicio o biblioteca, reentrenar o alertar, publicar o abstenerse: cada decisión se evalúa por su efecto sobre la validez del resultado.
- **Ciclo iterativo.** Identificar → estimar → servir → monitorear supuestos → actualizar.
- **Cuatro exigencias de producción, en versión causal:** confiabilidad del efecto, escalabilidad del pipeline, mantenibilidad de la identificación y adaptación ante cambios en los supuestos.
- **Lado humano.** Comunicar ATE y CATE a quien decide, redactar model cards honestas y declarar los límites de validez externa y la equidad.

2.2 Tres clases de supuestos

El eje del curso es distinguir qué se puede *medir* de qué solo se puede *declarar y acotar*. Esta distinción aparece desde la sesión 7 y gobierna la producción local (sección 8).

Clase	Qué ocurre	Ejemplos
Observables	Se miden con un estadístico, un umbral y una acción asociada.	Solapamiento, balance tras ponderar, calidad de los modelos auxiliares, deriva de covariables, estabilidad del efecto.

Clase	Qué ocurre	Ejemplos
Falsificables	Se contrastan por consecuencias que deberían cumplirse. Pasar la prueba no confirma el supuesto; fallarla sí obliga a revisar la explicación.	Placebo de tratamiento, control negativo, pre-tendencias.
No observables	No se observan directamente. Se declaran por escrito, se acotan con análisis de sensibilidad y, cuando el diseño lo permite, se contrastan con una referencia aleatorizada.	No confusión, ausencia de interferencia, validez externa, exclusión de un instrumento.

En la enseñanza usamos tres palabras para organizar la evidencia. El registro machine-readable usa dos clases: `observable` y `no_observable`. Un supuesto `falsificable` se registra según la clase del supuesto y conserva la prueba que podría refutarlo; no se crea una tercera clase que el esquema no pueda aceptar.

2.3 Cómo leer una afirmación causal

En cada tema conviene separar cinco preguntas. Esta separación evita que una métrica favorable se convierta, sin justificación, en una afirmación causal:

1. **¿Qué decisión se quiere tomar?** Por ejemplo, continuar un programa, asignar un presupuesto o abstenerse.
2. **¿Qué estimando responde a esa decisión?** Puede ser un ATE, un CATE, el valor de una política o ningún efecto todavía.
3. **¿Qué supuestos hacen posible la interpretación?** Se clasifican como observables, falsificables o no observables.
4. **¿Qué evidencia se obtuvo?** Se anotan el método, el intervalo, los diagnósticos y las pruebas que podrían contradecir el análisis.
5. **¿Qué queda fuera de lo que se sabe?** Una prueba que pasa no confirma todos los supuestos; una alerta no demuestra que el efecto sea nulo.

La bitácora, la model card y la puerta causal repiten esta estructura con distinto nivel de detalle. El estudiante no solo ejecuta un cálculo: deja escrita la razón para confiar en él, el alcance de esa confianza y la acción que corresponde.

3. Objetivos de aprendizaje

3.1 Objetivo general

Capacitar a profesionales para **formular, estimar y poner en producción local** sistemas de inferencia causal con machine learning. El logro esperado es construir y defender una decisión basada en un efecto documentado, su incertidumbre y sus supuestos; no se promete que todo caso sea identificable ni que un monitor pueda observar todos los sesgos.

3.2 Objetivos específicos

Al terminar el curso, el estudiante será capaz de:

1. Distinguir asociación, intervención y contrafactual, y reconocer cuándo **no** conviene estimar.
2. Diseñar pipelines de datos con roles de tratamiento, resultado y covariables, sin fuga causal.
3. Estimar ATE y CATE (DML, meta-learners y bosques causales), reportar su incertidumbre y evaluarlos fuera de muestra con Qini, placebos y análisis de sensibilidad.
4. Convertir un CATE en una **política** bajo presupuesto y compararla con alternativas no causales.

5. Servir un estimador de forma local, con contrato de API, model card validada por un esquema JSON y una puerta automática antes de publicar.
6. Monitorear en producción los supuestos observables y falsificables, y declarar, acotar y contrastar los no observables.
7. Comunicar resultados a audiencias de negocio con sus supuestos y límites explícitos.

3.3 Qué evidencia acredita cada objetivo

Obj.	Sesiones principales	Evidencia que lo acredita
1	S1–S3, S7	L03, L07 y Quiz online 1
2	S4, S6, S8	L04, L06 y L08
3	S5, S9–S14	L09–L14 y Quiz online 2
4	S21–S24	L21–L24
5	S12, S14, S17, S18	Prácticas de servicio, model card y puerta local
6	S7, S11, S25–S27	Prácticas de falsificación, sensibilidad y monitoreo
7	S19, S20, S28–S32	Preparación y defensa del trabajo final

4. Perfil de ingreso y requisitos técnicos

Requisito	Detalle
Programación	Python intermedio (pandas, scikit-learn) y Git básico.
Estadística	Estadística o econometría introductoria (regresión). Deseable: variables instrumentales o evaluación de impacto.
Despliegue	Experiencia con APIs deseable; se cubre en el curso.
Equipo	Un computador con Python 3.11 o superior. El camino principal no requiere GPU, contenedores ni conexión permanente. Los requisitos de memoria se publican con la guía de instalación; si el equipo no los cumple, se acuerda una ruta alternativa antes de la sesión 1.
Sistema operativo	Linux o macOS. En Windows se recomienda WSL 2, porque algunas librerías de estimación (EconML) pueden ser lentas o frágiles en Windows nativo.
Idioma de lectura	Los materiales del curso están en español. La documentación técnica de las librerías y buena parte de las referencias están en inglés.
Cuentas	Ninguna. No se necesita cuenta en plataformas de nube, repositorios públicos ni servicios de despliegue.
Plataforma institucional	El curso usa la plataforma institucional (aula virtual y videoconferencia) para comunicación, quizzes, entrega final y checkpoints. No forma parte del entorno técnico.
Teoría avanzada	No se exigen demostraciones. Los capítulos electivos del libro son opcionales.

4.1 Rutas de ejecución

Lo que importa es que cada estudiante pueda ejecutar los labs y preparar el trabajo final en un equipo suyo o de acceso garantizado. Hay tres rutas, y se acuerda cuál se usa en la semana 0.

Ruta	Cómo funciona
Estándar	Equipo personal con Linux, macOS o Windows con WSL 2. El estudiante instala el entorno fijado del curso con el paquete de estudiante y verifica con `python3 scripts/doctor_minimo.py`.
Equipo restringido	Equipo corporativo o sin permisos de instalación. El equipo docente indica un entorno preparado que se ejecuta sin privilegios de administrador. Se acuerda con el profesor antes de la sesión 1.
Equipo compartido	Si ninguna de las anteriores es posible, el estudiante usa un equipo de acceso garantizado (laboratorio institucional u otro equipo propio) con las mismas versiones.

4.2 Semana 0: autodiagnóstico y nivelación

Antes de la sesión 1 cada estudiante hace un autodiagnóstico de 30 a 45 minutos, sin nota: (1) ejecutar `python3 scripts/doctor_minimo.py` (2) hacer un commit en Git; (3) ajustar una regresión y leer sus coeficientes; (4) leer un fragmento de documentación en inglés. Si algún punto falla, registra el problema y usa la ruta de emergencia del curso; S1 no es una sesión de instalación. El profesor orienta una nivelación con lecturas y ejercicios de refuerzo de Python, Git y regresión. Quien ya domina estos temas puede pasar directamente a las lecturas ◇ de cada módulo.

5. Estructura del curso

El curso tiene siete módulos y un checkpoint, distribuidos en 16 semanas lectivas y 32 sesiones. El calendario académico ubica el cierre administrativo y el trabajo final en la semana 18, después del receso. Cada semana combina una lectura de la monografía con un lab de sesión. Los productos de las carpetas de casos y producción son prácticas guiadas; no son entregas calificadas.

Módulo	Semanas	Sesiones	Actividad principal
Semana 0 · Autodiagnóstico y nivelación	0	—	Preparación, sin nota
0 · Causalidad elemental y arranque	1	S1–S2	Prácticas guiadas
1 · Fundamentos y datos para sistemas causales	2–4	S3–S8	Prácticas guiadas + Quiz 1
2 · Estimación con ML y primer servicio local	5–7	S9–S14	Prácticas guiadas + Quiz 2
Checkpoint 1 · Integración	8	S15–S16	Revisión formativa, sin nota
3 · Repositorio, model cards y CI local	9	S17–S18	Prácticas guiadas + Quiz 3
4 · Explicación, decisión, política y uplift	10–12	S19–S24	Prácticas guiadas
5 · Monitoreo, descubrimiento y frontera	13–14	S25–S28	Prácticas guiadas

Módulo	Semanas	Sesiones	Actividad principal
6 · Trabajo final	15–16	S29–S32	Preparación, defensa y cierre

Las etiquetas internas de las carpetas —por ejemplo, Serie A, Serie B, A1 o B1— describen recorridos técnicos y no representan evaluaciones adicionales. El símbolo ◇ marca contenido de **extensión**: se presenta como contexto, pero no forma parte de la evaluación oficial.

Capítulos electivos (no bloquean el camino profesional): 5 (predicción frente a causalidad; solapa con el Cap. 1), 16 (PDS extendido), 17 (panel y DML-IV), 18 (mapa metodológico), 27 (deep causal) y 28 (SCM y matrix completion).

5.1 Evaluaciones oficiales

El cronograma distingue las actividades de aprendizaje de las evaluaciones. Antes del cierre solo hay tres quizzes online. El curso tiene una única entrega de trabajo: el trabajo final.

Semana	Evaluación	Peso	Fecha según grupo
3	**Quiz online 1**	10 %	G1, viernes 30 de octubre; G2, jueves 29 de octubre
6	**Quiz online 2**	10 %	G1, viernes 20 de noviembre; G2, jueves 19 de noviembre
9	**Quiz online 3**	10 %	G1, viernes 11 de diciembre; G2, jueves 10 de diciembre
18	**Trabajo final único**	70 %	G1, viernes 12 de febrero; G2, jueves 11 de febrero

No hay entregas intermedias calificadas. Los labs, la bitácora, los notebooks guiados, los servicios locales y las revisiones de avance sirven para aprender y preparar el trabajo final; por sí solos no agregan componentes a la nota.

La autoridad y las equivalencias de esta evaluación están en [`06_proyecto_final/ADENDA_CONTRATOS_EVALUACION.md`]. ATE, CATE y valor de política son opciones válidas cuando se declara la población y el objeto que cubre la incertidumbre. HTTP y CLI son transportes equivalentes. El Quiz 3 comprueba contratos de producción, model card, puerta, abstención y lectura de señales; no exige una biblioteca, ruta HTTP ni método de sensibilidad particular cuando el estimando requiere otro método compatible.

5.2 Si el calendario se acorta

Si se pierden sesiones (feriados, fallas técnicas o cambios del calendario institucional), se mantienen las fechas de los quizzes y del trabajo final. Lo que se ajusta son las prácticas internas, en este orden:

Sesiones perdidas	Qué se hace
1	S19 y S20 se fusionan en una sola sesión sobre explicación y equidad; L20 pasa a lectura guiada.
2	Además, S30 (revisión cruzada) se hace de forma asíncrona con la misma rúbrica.
3	Además, S32 se sustituye por la encuesta y una lectura de cierre.

6. Dinámica de cada sesión

Cada sesión dura 90 minutos y conserva una estructura estable. Cambia la pregunta causal y el producto del lab, no la secuencia de trabajo; así el estudiante puede concentrarse en el contenido sin tener que aprender de nuevo la dinámica.

El curso está diseñado para que el estudiante intente avanzar de forma autónoma con los materiales disponibles. El orden recomendado es: leer el capítulo indicado, abrir el `README` y el `lab.ipynb`, ejecutar las celdas paso a paso, revisar las comprobaciones y registrar el resultado en la bitácora. En particular, el lab es el recurso principal de práctica: algunos notebooks contienen funciones o celdas incompletas que forman parte del ejercicio y deben intentarse antes de consultar la solución. `solution.ipynb` es material de referencia para recuperarse de un bloqueo o comparar el procedimiento, no un sustituto del intento propio. Si el problema persiste, se registra una breve descripción y se continúa con la parte que sí pueda ejecutarse.

Bloque	Minutos	Qué ocurre	Protagonista
Pregunta	15	Se plantea la pregunta de negocio de la sesión y el concepto mínimo que hace falta para contestarla. Nada más.	Profesor
Lab	55	Todos ejecutan el mismo lab del monorepo, con el mismo conjunto de datos, hasta obtener un número o un artefacto. Las celdas de comprobación y el informe de ejecución indican qué quedó resuelto.	Estudiante
Bitácora	10	Cada estudiante añade su fila de la sesión y corre el validador.	Estudiante
Cierre	10	Se responde la pregunta del curso. En vivo, en voz alta; en modo autoguiado, en tres líneas escritas dentro de la fila.	Profesor y dos estudiantes

Este reparto sigue el formato orientativo del curso (concepto, práctica de 50 a 60 min y cierre de 10 a 20 min), con el concepto reducido a 15 minutos para reservar 10 a la bitácora. Las sesiones de proyecto (S29–S32) y el checkpoint (S16) adaptan el bloque central, como se indica en cada ficha.

6.1 La Bitácora Causal

Cada estudiante puede mantener un archivo, `bitacora_causal.md`, que crece una fila por sesión. La bitácora es una herramienta de aprendizaje y preparación del trabajo final; no es una entrega calificada. Una fila tiene seis campos obligatorios y no se añaden otros:

```
## S10 — DML sobre IHDP-medium
- Pregunta de negocio: ¿El programa mueve el resultado en promedio?
- Método: DML-PLR, 5 pliegues, gradient boosting como modelo auxiliar
- Estimando: ATE
- Número + IC: (valor) con su intervalo del 95 %
- Supuesto clave: observable · medido · ESS/n = (valor)
- Decisión: continuar / abstenerse / reestimar, con una línea de justificación
```

Supuesto clave tiene siempre la misma forma: `tipo (observable, falsificable o no observable) · cómo se trató (medido, contrastado, declarado y acotado) · resultado`. Estas tres etiquetas son didácticas; al registrar la ficha, `falsificable` conserva la prueba como evidencia dentro de `observable` o `no_observable`. **Decisión** usa el vocabulario del monitor de producción (continuar, alertar, abstenerse, revisar identificación, reentrenar). Si un lab no termina en los 55 minutos, la fila

se escribe igual con lo obtenido y la nota literal «lab incompleto». El estudiante puede copiar la fila anterior y cambiar solo el número/IC y la decisión.

El validador de bitácora, si existe, comprueba la forma de cada fila: los seis campos, que haya intervalo cuando la sesión produce un estimando, y que *Estimando* y *Decisión* salgan de listas cerradas. El profesor lee la sustancia especialmente en S07, S11, S16, S18, S25, S28 y S29–S32; el resto se considera hecho si pasa la forma. Una declaración de herramientas externas pertenece a las reglas de integridad del proyecto, no es un séptimo campo de la bitácora.

6.2 Ausencias y ritmo

Los labs no dependen de la asistencia. Quien falta a una sesión en vivo hace el lab por su cuenta con el mismo guion y completa su fila cuando pueda. Las fechas oficiales de los quizzes y del trabajo final son las del cronograma; cualquier ajuste se comunica por la plataforma institucional.

7. Contenidos clase a clase

Cómo leer cada ficha. La cabecera indica sesión, tema, capítulo de la monografía y lab. A la izquierda están el resultado de aprendizaje y los contenidos; a la derecha, la planificación de los 90 minutos: qué se hace en la pregunta inicial, qué produce la práctica, qué debe destacar la fila de la bitácora y con qué pregunta se cierra. Las actividades marcadas en cada ficha son formativas y no constituyen entregas adicionales.

Módulo 0 — Causalidad elemental y arranque

Semana 1

S1 Correlación no es causación — Cap. 1 · L01

AL TERMINAR

Distinguir una asociación de un efecto y explicar por qué observar un solo resultado por persona no basta para medirlo.

CONTENIDOS

- Asociación frente a efecto: casos espurios y paradoja de Simpson.
- Problema fundamental de la inferencia causal: de cada persona solo vemos un resultado potencial.
- Escalera de Pearl (adelanto): ver, hacer, imaginar.
- De la pregunta predictiva (¿quién tiene peor resultado?) a la pregunta de decisión (¿a quién le cambia si actuamos?).

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	Presentación del curso y dos ejemplos de scores que confunden correlación con impacto.
55′	**Lab**	Casos espurios y Simpson: tabla agregada frente a tabla por estratos, con la conclusión de cada una.
10′	**Bitácora**	Primera fila. Método descriptivo; estimando «ninguno»; supuesto clave: la asociación no se lee como efecto.
10′	**Cierre**	Con el score del caso Simpson, ¿a quién trataríamos? ¿Cambia al estratificar?

S2 Anatomía de un sistema de ML en producción — Cap. 2 · L02

AL TERMINAR

Nombrar las piezas de un sistema de ML en producción y lo que exige cada una cuando el objetivo es un efecto; dejar el entorno local listo.

CONTENIDOS

- Ciclo de vida: datos, covariables, evaluación, servicio y monitoreo.
- Qué cambia con un objetivo causal: confiabilidad del efecto, mantenibilidad de la identificación y adaptación ante cambios en los supuestos.
- Reproducibilidad: entorno, versiones y semilla fija (42).
- Mapa del monorepo y del flujo local de producción (sección 8).

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	Un sistema real en el que el efecto se pierde sin que ningún monitor técnico lo note.
55′	**Lab**	Lab 0: entorno Python, Git local y monorepo. El diagnóstico `python3 scripts/doctor_minimo.py` termina sin faltantes.
10′	**Bitácora**	Se crea `bitacora_causal.md` y se valida por primera vez. Fila de arranque, sin supuesto.
10′	**Cierre**	Primer commit y etiqueta local del repositorio del curso. No hace falta ninguna cuenta externa.

Módulo 1 — Fundamentos y datos para sistemas causales

Semanas 2–4 · prácticas + Quiz 1

S3 Modelos causales estructurales y la jerarquía de Pearl — Cap. 3 · L03

AL TERMINAR

Clasificar una pregunta de negocio como asociativa, de intervención o contrafactual y representarla con un modelo causal.

CONTENIDOS

- SCM y DAG: variables, mecanismos y ruido.
- Las tres capas: ver, hacer, imaginar.
- El operador do y por qué $P(Y \mid T) \neq P(Y \mid \mathrm{do}(T))$.
- El DAG es un supuesto del analista, no un resultado de los datos.

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	Tres preguntas de una misma empresa, una en cada capa de la jerarquía.
55′	**Lab**	Clasificar 10 preguntas en la jerarquía y justificar cada clasificación en una línea.
10′	**Bitácora**	Supuesto clave: no observable, declarado. El DAG propuesto. Estimando «ninguno».
10′	**Cierre**	¿Qué pregunta de tu organización es de nivel 2 y hoy se contesta con un análisis de nivel 1?

S4 Ingeniería de datos para un sistema causal — Cap. 4 · L04

AL TERMINAR

Asignar roles de tratamiento, resultado y covariables, y dejar trazabilidad de cada variable.

CONTENIDOS

- Roles T, Y y X, y el momento en que se mide cada variable.
- Variables posteriores al tratamiento: por qué no son covariables.
- Trazabilidad: origen, versión y hash del dataset.
- EDA causal: balance inicial entre tratados y controles (diferencia estandarizada de medias, SMD).

Actividad guiada del bloque · sin nota ni entrega separada

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	¿Qué es realmente el tratamiento y cuándo se mide? Ejemplo: un programa de empleo.
55′	**Lab**	Roles T/Y/X, análisis exploratorio y tabla de balance en Jobs.
10′	**Bitácora**	Supuesto clave: observable, medido. Balance inicial (SMD máximo). Estimando: diferencia en medias descriptiva.
10′	**Cierre**	Con la diferencia en medias bruta, ¿se aprobaría el programa? ¿Qué diría un score que solo predice el ingreso?

S5 Regularización y post-selección

Cap. 6 (+ 16 ◇) · L05

AL TERMINAR

Explicar por qué penalizar sin cuidado sesga el efecto y estimar el ATE con post-selección doble.

CONTENIDOS

- Alta dimensión: muchas covariables y pocas observaciones.
- Sesgo de regularización: el lasso puede eliminar justo un confusor.
- Post-double-selection (PDS): seleccionar para el resultado y para el tratamiento.
- Tres estimadores comparados: diferencia en medias, OLS y PDS.

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	Un lasso que «limpia» covariables, ¿puede borrar el confusor?
55′	**Lab**	ATE con IC por diferencia en medias, OLS y PDS en Jobs, frente a la referencia del benchmark.
10′	**Bitácora**	Estimando ATE con IC. Supuesto clave: no observable, declarado. No confusión condicional en lo medido.
10′	**Cierre**	Versionar el conjunto de datos de la práctica. ¿Cambia la decisión del programa entre diferencia en medias y PDS?

S6 Datos de entrenamiento, muestreo y solapamiento

Cap. 7 · L06

AL TERMINAR

Construir particiones sin fuga y comprobar si hay solapamiento suficiente para estimar el efecto.

CONTENIDOS

- Muestreo y etiquetas naturales: de dónde salen los tratados.
- Particiones de entrenamiento, validación y prueba sin fuga.
- Solapamiento (positividad): propensiones estrictamente interiores.
- Qué se hace si no hay solapamiento: recortar cambia el estimando.

Actividad guiada del bloque · sin nota ni entrega separada

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	Si nadie parecido a Ana recibió el programa, ¿qué sabemos de su efecto?
55′	**Lab**	Particiones con sus tamaños, propensiones y diagnóstico de solapamiento en Jobs. Cierre de la práctica de identificación.
10′	**Bitácora**	Supuesto clave: observable, medido. Proporción de propensiones interiores.
10′	**Cierre**	¿Es estimable o no? Decidir y justificar si conviene reportar un efecto o abstenerse.

S7 Operador do, puertas traseras y contrafactuales

Cap. 8 · L07

AL TERMINAR

Aplicar el criterio de puerta trasera, decidir cuándo abstenerse y acotar lo que no se puede medir.

CONTENIDOS

- Criterio de puerta trasera y conjuntos de ajuste válidos.
- Confusor latente: qué ocurre cuando falta una variable.
- Contrafactuales: qué pregunta responden.
- E-value: qué fuerza debe tener un confusor no medido para anular el efecto. Primer contacto con un supuesto no observable.

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	Si el confusor no está en los datos, ¿se puede decir algo del efecto?
55′	**Lab**	Puerta trasera frente a confusor latente en un escenario con verdad conocida; clasificación estimable o no, y E-value.
10′	**Bitácora**	Supuesto clave: no observable, declarado y acotado. E-value con su interpretación.
10′	**Cierre**	¿Qué tan fuerte debería ser el confusor para cambiar la decisión? ¿Es plausible en este dominio?

S8 Covariables sin fuga causal — Cap. 9 · L08

AL TERMINAR
Detectar y eliminar la fuga causal en las covariables antes de estimar.

CONTENIDOS
- Fuga causal frente a fuga predictiva: variables posteriores al tratamiento, mediadores y colisionadores.
- Auditoría de covariables (`auditar_features()`).
- Por qué una variable muy predictiva puede arruinar el efecto.
- El conjunto de datos limpio como artefacto versionado.

Actividad guiada del bloque · sin nota ni entrega separada

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	La mejor covariable del modelo, ¿es causa del tratamiento o consecuencia?
55′	**Lab**	Dos versiones de IHDP, limpia y con fuga, y la diferencia en el efecto estimado.
10′	**Bitácora**	Supuesto clave: observable, medido. Ninguna covariable es posterior al tratamiento (auditoría).
10′	**Cierre**	Versionar el conjunto de datos limpio. ¿Cuánto cambia la decisión cuando aparece fuga causal?

Módulo 2 — Estimación con ML y primer servicio local

Semanas 5–7 · prácticas + Quiz 2

S9 Ortogonalidad de Neyman, cross-fitting y score ortogonal — Cap. 10 · L09

AL TERMINAR
Explicar por qué el cross-fitting y un score ortogonal protegen la inferencia cuando los modelos auxiliares se estiman con ML.

CONTENIDOS
- Parámetro de interés y modelos auxiliares.
- Ortogonalidad de Neyman: insensibilidad de primer orden a errores de los modelos auxiliares.
- Cross-fitting: entrenar y predecir en pliegues distintos.
- Score ortogonal canónico: PLR, IRM, DR, R-learner y valor de política como instancias de una misma inferencia.

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	Si el modelo auxiliar se equivoca un poco, ¿cuánto se equivoca el efecto?
55′	**Lab**	Un fold de cross-fitting con pseudo-resultado fuera de muestra. El ATE final puede quedar para S10.
10′	**Bitácora**	Supuesto clave: observable, medido. Calidad de los modelos auxiliares (R^2 o log-loss por pliegue).
10′	**Cierre**	¿Qué ocurre con el IC si se usa la misma muestra para ajustar y para estimar?

S10 DML: PLR, IRM y soporte común — Cap. 11 · L10

AL TERMINAR
Estimar un ATE con DML, reportar su intervalo y diagnosticar el soporte común.

CONTENIDOS
- PLR (modelo parcialmente lineal) e IRM (modelo de regresión interactivo).
- Eficiencia semiparamétrica y error estándar.
- ESS relativo y recorte de propensiones ($\alpha \approx 0.1$, Crump et al., 2009).
- Del ATE a la decisión de seguir o detener el programa.

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	El programa sube el resultado en promedio. ¿Cuánto, y con qué incertidumbre?
55′	**Lab**	ATE con IC 95 % y artefacto DML guardado, o el número del solution marcado como referencia.
10′	**Bitácora**	Estimando ATE con IC. Supuesto clave: observable, medido. ESS/n.
10′	**Cierre**	Con este ATE y su IC, ¿se financia el programa? ¿Y con un score predictivo?

S11 Validación fuera de muestra: referencias base, Qini, placebo y sensibilidad

Cap. 14 · L11

AL TERMINAR

Someter un estimador a pruebas que pueden refutarlo y reportar su sensibilidad.

CONTENIDOS

- Referencias base (baselines) y RATE; curvas de uplift y Qini.
- Refutaciones: placebo de tratamiento y control negativo.
- Sensibilidad en tres niveles: E-value, R^2 parcial y cotas de Manski.
- ◇ BLP, BEST, CLAN e intervalos conformes.

Actividad guiada del bloque · sin nota ni entrega separada

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	Si el efecto desaparece al permutar el tratamiento, ¿qué aprendimos? ¿Y si no desaparece?
55′	**Lab**	Un placebo o control negativo y una frase sobre lo que no demuestra acerca del supuesto no observable.
10′	**Bitácora**	Supuesto clave: falsificable, contrastado. El control negativo no rechaza, y qué no demuestra eso.
10′	**Cierre**	Pasar el placebo, ¿prueba que no hay confusión? Escribe una frase sobre lo que no demuestra.

S12 Despliegue como servicio local

Cap. 15 · L12

AL TERMINAR

Exponer el estimador como un servicio con contrato claro y evitar el training–serving skew.

CONTENIDOS

- Servicio frente a biblioteca; separación entre la lógica de inferencia y la capa HTTP.
- Contrato de la API: `/health`, `/predict` y `/metadata`.
- `/metadata` legible por máquina y validado contra el JSON Schema (Ap. G.4).
- Latencia y desajuste entre entrenamiento y servicio (training–serving skew).

Actividad guiada del bloque · sin nota ni entrega separada

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	¿Qué debe responder un servicio que estima efectos: un número, o un número con su incertidumbre?
55′	**Lab**	GET /health responde y existe un caso de abstención fuera del soporte. Sin model card.
10′	**Bitácora**	Supuesto clave: observable, medido. Las 25 covariables del servicio coinciden con las del entrenamiento.
10′	**Cierre**	Si la entrada llega fuera del rango de entrenamiento, ¿el servicio responde o se abstiene?

S13 Meta-learners S, T, X, R y DR

Cap. 12 · L13

AL TERMINAR

Estimar efectos heterogéneos (CATE) con meta-learners y compararlos.

CONTENIDOS

- Del ATE al CATE: efecto por persona o por grupo.
- S-, T-, X-, R- y DR-learner: qué modela cada uno.
- PEHE, y por qué solo se calcula con verdad conocida.
- El DR-learner como instancia del score canónico del Cap. 10.

Actividad guiada del bloque · sin nota ni entrega separada

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	Dos personas con el mismo riesgo, ¿tienen el mismo efecto?
55′	**Lab**	T-learner en IHDP: CATE, PEHE y placebo.
10′	**Bitácora**	Estimando CATE. Supuesto clave: no observable, declarado. La no confusión vale también dentro de cada subgrupo.
10′	**Cierre**	Versionar el modelo DML (`.joblib` y `feature_list.json`) con etiqueta local. ¿El CATE cambia a quién tratar?

S14 Árboles y bosques causales

Cap. 13 · L14

AL TERMINAR

Usar bosques causales para detectar heterogeneidad y verificar un servicio con pruebas de humo.

CONTENIDOS

- Partición honesta y bosques causales.
- CATE con intervalo; qué hacer si no hay heterogeneidad detectable.
- Pruebas de humo del servicio: salud, efecto y metadata.
- Estabilidad del estimador frente a semillas y pliegues.

Actividad guiada del bloque · sin nota ni entrega separada

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	¿El efecto cambia entre grupos o estamos viendo ruido?
55′	**Lab**	Pruebas de humo del servicio local (`/health`, `/predict`, `/metadata`). La ruta de efecto devuelve una estimación o una abstención explícita.
10′	**Bitácora**	Supuesto clave: observable, medido. Estabilidad del estimador entre semillas y pliegues.
10′	**Cierre**	¿Qué evidencia necesitaría quien decide para creer en la heterogeneidad que muestra el bosque?

Checkpoint 1 — Integración

Semana 8 · revisión formativa

S15 Integración: identificación, estimación y primer servicio

Repaso Caps. 1–15 · L15

AL TERMINAR

Recorrer el sistema completo y detectar sus eslabones más débiles.

CONTENIDOS

- Cadena completa: identificar, estimar, servir.
- Checklist de sistema: roles, fuga, solapamiento, estimador, validación y contrato.
- Lectura crítica de la propia bitácora (S1–S14): ¿qué supuestos quedaron sin tratar?
- Preparación del checkpoint.

Actividad guiada del bloque · sin nota ni entrega separada

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	¿Qué supuesto de mi sistema está declarado, pero no medido ni contrastado?
55′	**Lab**	Checklist de integración sobre los artefactos y los datos de Jobs e IHDP.
10′	**Bitácora**	La fila resume la brecha más importante del sistema hasta hoy.
10′	**Cierre**	Ordenar los eslabones por riesgo y decidir cuál se refuerza antes del checkpoint.

S16 Checkpoint 1: defensa de avance

— · —

AL TERMINAR

Defender el avance con evidencia ordenada y recibir retroalimentación.

CONTENIDOS

- Defensa breve a partir de la bitácora: lectura de las filas S1–S15.
- Qué se estimó, bajo qué supuestos y con qué decisión.
- Retroalimentación sobre brechas.
- Plan de las semanas siguientes.

Actividad guiada del bloque · sin nota ni entrega separada

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	Reglas de la defensa y criterios de la retroalimentación.
55′	**Defensas**	Tres líneas en la bitácora: pregunta «¿debo hacer X para lograr Y?», estimando y razón por la que el caso no es guiado. Checkpoint formativo, sin nota.
10′	**Bitácora**	Fila de cierre: brechas detectadas y compromisos hasta la semana 12.
10′	**Cierre**	Retroalimentación general del grupo y del profesor.

Módulo 3 — Repositorio, model cards y CI local

Semana 9 · prácticas + Quiz 3

S17 Repositorio y model cards causales

Cap. 19 · Ap. G (G.4) · L17

AL TERMINAR

Documentar un modelo causal con supuestos que una máquina pueda verificar.

CONTENIDOS

- Qué debe decir una tarjeta causal: estimando, población, supuestos y límites.
- JSON Schema (Ap. G.4): campos obligatorios y validación automática del contrato.
- Supuestos observables y no observables dentro de la tarjeta: medidos, contrastados, declarados y acotados.
- Repositorio versionado en local: estructura y etiquetas.

Actividad guiada del bloque · sin nota ni entrega separada

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	¿Qué diferencia hay entre «documentamos los supuestos» y «la puerta rechaza una tarjeta que no los documenta»?
55′	**Lab**	Model card JSON que valida contra el schema, con los campos mínimos.
10′	**Bitácora**	La tarjeta es la bitácora ordenada: cada campo sale de una fila.
10′	**Cierre**	¿Qué supuesto no observable omitiría quien quiera presentar el modelo bajo su mejor luz?

S18 Integración continua local

Cap. 20 · L18

AL TERMINAR

Montar una puerta automática que impida publicar un modelo roto o mal documentado.

CONTENIDOS

- Pruebas unitarias, pruebas de humo y validación del schema antes de publicar.
- La auditoría local (`scripts/audit_repo.sh`) como puerta de integración.
- Qué se bloquea y qué solo se advierte.
- ◇ Plantilla de workflow de GitHub Actions como lectura; se practica con el equivalente local.

Actividad guiada del bloque · sin nota ni entrega separada

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	¿Qué debe bloquear la publicación y qué solo debe avisar al experto?
55′	**Lab**	Un hash SHA-256 y un estado de puerta; champion solo si la puerta pasa.
10′	**Bitácora**	Supuesto clave: observable, medido. La puerta falla ante una tarjeta sin supuestos no observables.
10′	**Cierre**	¿Dejarías que la puerta bloquee sola o prefieres que el experto decida? Justifica.

Módulo 4 — Explicación, decisión, política y uplift

Semanas 10–12 · prácticas

S19 Explicación causal frente a asociativa

Cap. 23 · L19

AL TERMINAR

Distinguir una explicación causal de una importancia asociativa.

CONTENIDOS

- Qué significa «explicar» una decisión.
- Asociación frente a efecto en las explicaciones.
- Afirmaciones causales: qué las respalda.
- Equidad: dónde entran las variables sensibles.

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	Una variable es «importante» en el modelo: ¿cambiarla cambia el resultado?
55′	**Lab**	Tabla de afirmaciones: cuáles son causales, cuáles asociativas y qué respalda cada una.
10′	**Bitácora**	Supuesto clave: no observable, declarado. Toda explicación causal depende del DAG asumido.
10′	**Cierre**	Reescribe una explicación del modelo sin palabras causales que no puedas respaldar.

S20 Interpretabilidad y equidad sobre estimadores causales

Cap. 24 · L20

AL TERMINAR

Auditar una importancia de variables sin atribuirle un significado causal que no tiene.

CONTENIDOS

- SHAP e importancias: qué miden y qué no.
- Sesgo y equidad en la estimación de efectos.
- Auditoría con advertencia obligatoria.
- Ética del uso de efectos estimados.

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	Un banco explica una decisión con SHAP: ¿está explicando el efecto de cambiar la variable?
55′	**Lab**	Auditoría de importancia asociativa sobre IHDP-medium con advertencia explícita.
10′	**Bitácora**	Supuesto clave: falsificable, contrastado. La importancia no coincide con el efecto estimado.
10′	**Cierre**	¿Qué advertencia mínima debe acompañar a cualquier gráfico de importancia?

S21 Decisiones estructurales bajo incertidumbre

Cap. 25 · L21

AL TERMINAR

Formalizar una decisión de negocio a partir de un efecto estimado y de su incertidumbre.

CONTENIDOS

- De efecto a decisión: utilidad, costo y presupuesto.
- Formalización de la decisión de negocio.
- Cómo entra la incertidumbre del efecto en la decisión.
- Seguir, detener o abstenerse.

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	Antes de optimizar una política, ¿qué decisión exacta se quiere tomar y con qué costo?
55′	**Lab**	Decisión de negocio formalizada (`DecisionProblem`) sobre IHDP.
10′	**Bitácora**	Estimando: valor de la decisión. Supuesto clave: no observable, declarado. Utilidad y costos supuestos.
10′	**Cierre**	¿A partir de qué intervalo cambia la decisión de tratar a un grupo?

S22 Policy learning y presupuesto

Cap. 21 · L22

AL TERMINAR

Construir una política bajo presupuesto y compararla con alternativas, con inferencia sobre la diferencia.

CONTENIDOS

- Política top-k con presupuesto del 20 %.
- Valor de la política y su estimación.
- Baselines: política aleatoria y política basada solo en el resultado.
- Inferencia sobre el valor de la política (función de influencia eficiente) para comparar dos políticas, no solo el punto.

Actividad guiada del bloque · sin nota ni entrega separada

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	Con capacidad para tratar al 20 %, ¿a quién se prioriza?
55′	**Lab**	Política top-k con presupuesto del 20 %, bienestar y comparación con el baseline, con IC de la diferencia.
10′	**Bitácora**	Estimando: valor de política con IC. Supuesto clave: observable, medido. Cumplimiento del presupuesto.
10′	**Cierre**	¿La política causal supera de verdad a la que solo predice el resultado?

S23 Uplift y targeting

Cap. 22 · L23

AL TERMINAR

Evaluar un uplift con curvas Qini y llevar la política a un servicio local que muestre su incertidumbre.

CONTENIDOS

- Uplift frente a riesgo; curva Qini.
- Targeting con restricciones.
- Servicio local de política: decisión, `uplift_score` y presupuesto.
- Mostrar el IC y los supuestos junto al punto estimado.

Actividad guiada del bloque · sin nota ni entrega separada

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	¿Qué ve quien decide cuando usa la herramienta: un ranking o un efecto con sus límites?
55′	**Lab**	Curva de uplift y Qini; tres casos de humo del servicio de política.
10′	**Bitácora**	Supuesto clave: observable, medido. Presupuesto y decisiones binarias del servicio.
10′	**Cierre**	¿Qué información mínima debe mostrar el servicio para no inducir a error?

S24 Transportabilidad entre dominios

Cap. 26 · L24

AL TERMINAR

Decidir si un efecto estimado en un dominio vale en otro y calibrarlo contra un grupo aleatorizado.

CONTENIDOS

- Validez externa: qué debe parecerse entre dominios.
- Diagnósticos de transporte y reponderación.
- Grupo aleatorizado de referencia: sesgo del estimador observacional medido contra el experimento.
- Cuándo abstenerse de transportar.

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	El efecto se estimó en otro mercado. ¿Vale en el mío?
55′	**Lab**	Diagnóstico de transporte y, si hay parte aleatorizada, sesgo del estimador frente al experimento.
10′	**Bitácora**	Supuesto clave: no observable, contrastado. Diferencia entre el estimador observacional y el experimental.
10′	**Cierre**	Si la discrepancia con el experimento supera el IC conjunto, ¿qué se revisa primero?

Módulo 5 — Monitoreo, descubrimiento y frontera

Semanas 13–14 · prácticas

S25 Monitoreo: deriva y estabilidad del efecto

Cap. 30 (+ 17 ◇) · L25

AL TERMINAR

Vigilar en producción los supuestos observables y entender por qué un sistema «saludable» puede dar un efecto inválido.

CONTENIDOS

- Deriva de covariables (KS y PSI).
- Solapamiento y balance en producción.
- Estabilidad del efecto en el tiempo.
- Una respuesta 200 OK no demuestra que el efecto siga siendo válido. ◇ Con PLIV: fuerza del instrumento (F y Anderson–Rubin).

Actividad guiada del bloque · sin nota ni entrega separada

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	El servicio responde sin errores, ¿sigue siendo válido su efecto?
55′	**Lab**	Una señal con umbral numérico y una acción del monitor. No se construye un dashboard.
10′	**Bitácora**	Supuesto clave: observable, medido. Deriva máxima por ventana y acción asociada.
10′	**Cierre**	¿Qué señal, además de la deriva, necesitarías para sospechar de un confusor nuevo?

S26 Descubrimiento de estructura

Cap. 29 · L26

AL TERMINAR

Usar un algoritmo de descubrimiento causal y tratar su resultado como hipótesis, no como verdad.

CONTENIDOS

- Qué puede y qué no puede recuperar un algoritmo de descubrimiento.
- Algoritmo PC: esqueleto y conjuntos separadores.
- ◇ NOTEARS: panorama.
- Del grafo descubierto a una hipótesis que hay que contrastar.

Actividad guiada del bloque · sin nota ni entrega separada

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	Si un algoritmo propone un grafo, ¿qué más hace falta para creerlo?
55′	**Lab**	Esqueleto PC sobre un grafo lineal gaussiano de 10 variables, con conjuntos separadores.
10′	**Bitácora**	Supuesto clave: no observable, declarado. Suficiencia causal y fidelidad.
10′	**Cierre**	¿Qué arista del grafo descubierto contrastarías primero, y con qué evidencia?

S27 Aprendizaje continuo: reentrenar o alertar

Cap. 31 · L27

AL TERMINAR

Aplicar una regla de decisión para cada tipo de señal y entender por qué reentrenar a ciegas puede ocultar un problema de identificación.

CONTENIDOS

- Cinco decisiones: continuar, alertar, abstenerse, revisar identificación y reentrenar.
- Regla con precedencia entre decisiones.
- Por qué reentrenar no arregla un confusor nuevo.
- ◇ Panorama de RL causal.

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	Hay drift en una covariable. ¿Se reentrena?
55′	**Lab**	Regla de decisión probada sobre series simuladas, con un caso para cada decisión.
10′	**Bitácora**	Decisión: usa el vocabulario completo del monitor. Supuesto clave: según la señal que disparó la regla.
10′	**Cierre**	¿Qué señal te haría revisar la identificación en lugar de reentrenar?

S28 Lado humano: comunicación y responsabilidad

Cap. 32 · L28

AL TERMINAR

Comunicar un efecto con sus supuestos y límites a quien decide, sin sobrevender ni ocultar la incertidumbre.

CONTENIDOS

- Comunicar ATE y CATE en tres capas: mensaje, evidencia y límites.
- Qué debe decir siempre un resumen de una página.
- Responsabilidad sobre decisiones basadas en efectos.
- Elección del caso del proyecto final.

Actividad guiada del bloque · sin nota ni entrega separada

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	¿Cómo se explica un intervalo a quien tiene que decidir hoy?
55′	**Lab**	Resumen de una página con ATE, IC y límites, escrito para quien decide.
10′	**Bitácora**	Supuesto clave: el que más pesa en la decisión, escrito en lenguaje no técnico.
10′	**Cierre**	¿Qué frase del resumen cambiarías para que nadie pueda leer más certeza de la que hay?

Módulo 6 — Proyecto final

Semanas 15–16

S29 Proyecto final: trabajo autónomo y mentoría

Ap. E, G (G.4), H · P1

AL TERMINAR

Dejar abiertos el repositorio, la identificación y la línea base del caso propio.

CONTENIDOS

- Integración del caso elegido en S16.
- Repositorio, identificación y línea base.
- Plan de monitoreo: qué supuestos se miden y cuáles se declaran.
- Mentoría individual.

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	Reglas del proyecto y criterios de la rúbrica.
55′	**Trabajo**	README con comando y demo del escenario sano. El caso ya fue elegido en S16.
10′	**Bitácora**	Filas del proyecto: mismos seis campos aplicados al caso propio.
10′	**Cierre**	¿Qué supuesto del caso es el más difícil de defender?

S30 Revisión cruzada estructurada

Rúbrica del curso · P2

AL TERMINAR

Evaluar con la rúbrica el trabajo de otros y mejorar el propio con sus comentarios.

CONTENIDOS

- Revisión estructurada de dos o tres proyectos con la rúbrica.
- Cómo dar retroalimentación específica y accionable.
- Qué hacer con los comentarios recibidos.
- Brechas frecuentes en identificación y monitoreo.

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	Qué es un buen comentario de revisión y qué no lo es.
55′	**Revisión**	Checklist de seis ítems: pregunta+estimando, puerta, abstención, card válida, condición de parada y cierre. No se depura código ajeno.
10′	**Bitácora**	Fila de revisión: el supuesto más débil que se encontró en un proyecto ajeno.
10′	**Cierre**	¿Qué cambio al proyecto propio es el más rentable antes de la defensa?

S31 Defensa del sistema causal — · P3

AL TERMINAR
Defender un sistema causal que se ejecuta de principio a fin en la máquina del estudiante.

CONTENIDOS
- Demostración local: del dato a la decisión, con evidencia reproducible.
- Comparación entre el ranking predictivo y la política causal.
- Supuestos observables y no observables: qué se midió, qué se declaró y cómo se vigila.
- Preguntas del tribunal.

Actividad guiada del bloque · sin nota ni entrega separada

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	Reglas de la defensa y criterio de la prueba de humo.
55′	**Defensa**	Defensa con ejecución local del sistema y paquete de evidencia.
10′	**Bitácora**	Fila final del proyecto: decisión recomendada y condiciones para retirarla.
10′	**Cierre**	¿Qué señal en producción te haría retirar la recomendación?

S32 Cierre y frontera — Caps. 27–28 (electivos) · P4

AL TERMINAR
Reconocer los límites de lo aprendido y las líneas de trabajo futuro.

CONTENIDOS
- ◇ Panorama de aprendizaje causal profundo y de RL causal.
- ◇ SCM y matrix completion (panorama).
- Límites de lo aprendido y trabajo futuro.
- Encuesta del curso.

PLANIFICACIÓN · 90 MIN

15′	**Pregunta**	Qué queda fuera del curso y por qué importa.
55′	**Cierre**	Cierre de cuatro campos: decisión, efecto+IC, supuesto y cuándo dejar de confiar. Solo formato, hashes, README y prosa; las cifras y decisiones están congeladas.
10′	**Bitácora**	Fila de cierre: lo que haría distinto con lo aprendido.
10′	**Cierre**	Si solo predijéramos, ¿a quién trataríamos? ¿Con el efecto cambió tu decisión a lo largo del curso?

8. Puesta en producción local

Poner un estimador de efectos en producción no es servir un score: el sistema decide qué publicar, qué responder y cuándo abstenerse. En este curso todo ocurre en el computador del estudiante, sin cuentas ni servicios de nube, con herramientas abiertas. La referencia es el ejemplo de MLOps local del curso (versión 3, en `docs/ejemplo_mlops_abierto/`), que el estudiante ejecuta, lee y adapta en las prácticas guiadas y en el trabajo final.

8.1 El recorrido de un efecto, de los datos al monitor

Datos › **Estimación** › **Diagnóstico y puerta** › **Model card** › **Registro y alias** › **Servicio** › **Monitor**

Etapa	Qué ocurre	Qué deja	Ses.
1 · Datos	Datos sintéticos o de benchmark, con efecto verdadero conocido. El estudiante nunca ve las columnas de verdad (`y0`,	CSV con hash SHA-256	S4, S8

Etapa	Qué ocurre	Qué deja	Ses.
	`y1`, `tau`); solo el evaluador las usa. Cada dataset se identifica por su hash.		
2 · Estimación	Estimador doblemente robusto con cross-fitting (DML/AIPW) y CATE lineal con intervalo. Semilla fija.	Estimación serializada (sin `pickle` en el ejemplo)	S9–S14
3 · Diagnóstico y puerta	Se miden los supuestos observables (solapamiento, balance, tamaño efectivo) y se contrasta el control negativo. La puerta devuelve un estado: pasa, alerta o falla.	Informe de diagnóstico	S6, S10, S11
4 · Model card	Una tarjeta en JSON se valida contra su esquema local-0.2. El esquema exige declarar los supuestos no observables, su estado de sensibilidad compatible o la limitación explícita; sin ello, la tarjeta no se registra.	Tarjeta validada	S17
5 · Registro y promoción	Cada versión se guarda con un manifiesto de hashes. El alias `champion` apunta a la versión vigente. Una versión en *falla* nunca se promueve; una en *alerta* exige aceptación explícita; se verifica la integridad antes de promover.	Versión inmutable y alias	S18
6 · Servicio	Carga la versión del alias al arrancar. Responde con el efecto y su intervalo, o **se abstiene** si la consulta cae fuera del soporte de entrenamiento (percentiles 1 a 99). Avisa si la puerta de esa versión quedó en alerta.	Respuesta con IC o abstención	S12, S14
7 · Monitor	Cada ventana de datos nuevos se resume en señales y una regla de decisión elige la acción (sección 8.3).	Tabla de ventanas y decisiones	S25–S28

8.2 Qué se hace con cada clase de supuesto

La puerta y el monitor solo pueden *medir* lo observable. Lo no observable no se monitorea: se declara, se acota y se compara contra un experimento.

Clase	Cómo se trata en producción	Dónde queda registrado
Observables	Estadístico con umbral y acción: propensiones extremas, tamaño efectivo relativo, balance ponderado (SMD), drift de covariables (PSI y KS), estabilidad del efecto.	Puerta y monitor
Falsificables	Control negativo: un resultado que el tratamiento no puede afectar debería dar efecto nulo. Si no lo da, hay confusión. Que lo dé no prueba su ausencia.	Informe de diagnóstico

Clase	Cómo se trata en producción	Dónde queda registrado
No observables	Se declaran con su formulación y evidencia indirecta; se acotan con E-value y valor de robustez; cuando existe un holdout aleatorizado, se compara con él. Esta referencia aporta evidencia, pero no prueba por sí sola la ausencia de confusión en toda la población.	Model card (campo obligatorio)

8.3 Umbrales y regla de decisión

Los umbrales son **convenciones de trabajo**, no leyes. Se recalibran por caso y se registran en la model card.

Señal de la puerta	Alerta	Falla
Propensiones fuera de 0,05 a 0,95 (proporción)	≥ 0,05	≥ 0,10
Tamaño efectivo relativo (el menor de los dos brazos)	≤ 0,30	≤ 0,15
Diferencia estandarizada de medias ponderada (máxima)	≥ 0,10	≥ 0,25
Control negativo, |z|	≥ 3	≥ 5

El monitor resume cada ventana con el PSI máximo de las covariables (cambio grande a partir de 0,25), la estabilidad del efecto frente a la referencia ($|z| \geq 3$) y el control negativo ($|z| \geq 3$). Cuando varias señales coinciden, gana la decisión de mayor precedencia:

№	Decisión	Cuándo
1	**Abstenerse**	El solapamiento o el balance están fuera de límite: el efecto no es fiable en la ventana.
2	**Revisar identificación**	El control negativo rechaza, o el efecto cambia sin deriva de covariables. Reentrenar no arregla un confusor nuevo.
3	**Reentrenar**	Hay deriva grande y el efecto re-estimado se aleja de la referencia.
4	**Alertar**	Deriva grande sin evidencia de cambio del efecto, o la puerta está en alerta.
5	**Continuar**	Sin señales.

> **Lección central**
>
> Un confusor nuevo no mueve necesariamente la distribución de las covariables medidas. Por eso los indicadores de deriva pueden seguir en verde mientras el efecto deja de ser válido. Se delata por señales de otra naturaleza: el control negativo, un efecto que cambia sin deriva o, cuando existe, el desacuerdo con el grupo aleatorizado. En la demostración del curso se simulan semanas sanas, con deriva de covariables, con confusor oculto y con solapamiento violado, y se comprueba qué señal detecta cada problema.

8.4 Cómo se ejecuta

Todo se ejecuta con `make` desde la carpeta del ejemplo. No hace falta red después de instalar las dependencias.

```
python3 scripts/doctor_minimo.py  # qué parte puede ejecutarse en tu equipo
make ci              # pruebas rápidas + demostración completa; sale con 0 si todo pasa
make demo            # casos PASA/FALLA: promoción, bloqueo, servicio y abstención
make monitor         # 12 semanas simuladas con drift, confusor oculto y solapamiento violado
make serve           # servicio HTTP local (requiere fastapi y uvicorn)
```

La demostración recorre tres escenarios con efecto conocido: uno **sano**, donde el intervalo cubre el efecto verdadero y la versión se promueve; uno con **solapamiento violado**, donde la puerta falla y la versión no se promueve; y uno con **confusor oculto**, donde el balance y el solapamiento observables pasan sin ver el problema y lo delatan el control negativo y el holdout aleatorizado. Después consulta la versión vigente: devuelve el efecto con su intervalo dentro del soporte y se abstiene fuera de él.

En el prototipo abierto la ruta que devuelve el efecto se llama `/efecto`. El adaptador docente B1 conserva la ruta `/predict` por compatibilidad con su contrato. En ambos casos la respuesta debe incluir la estimación, su incertidumbre y una abstención explícita cuando la entrada queda fuera del soporte.

Pieza	Qué construye el estudiante	Cómo corre
B1	Servicio de inferencia con `/health`, `/predict` y `/metadata`. La ruta de efecto devuelve estimación o abstención.	FastAPI en local
B2	Model card validada contra su JSON Schema y puerta de integración.	Pruebas y `scripts/audit_repo.sh`
B3	Servicio de política que muestra decisión, uplift, incertidumbre y supuestos.	`python service.py` en local
B4	Monitor de supuestos con regla de decisión y, cuando existe, comparación con el grupo aleatorizado.	`python scripts/run_monitor.py` en local

8.5 Perfil opcional de contenedores

Para quien quiera aislar el servicio o simular un equipo, el ejemplo incluye un perfil de contenedores. **No es necesario para aprobar** y no reemplaza el camino anterior. Una tarea de preparación ejecuta la demostración y la puerta; solo si pasa arranca el servicio, que lee los artefactos en modo de solo lectura y se publica únicamente en la propia máquina (127.0.0.1). Un segundo perfil añade un servidor de seguimiento de experimentos (MLflow con SQLite). No se usan almacenes de objetos ni bases de datos externas.

8.6 Límites de esta demostración

- Los datos son sintéticos y de un solo mecanismo de generación: la demostración enseña a pensar, no valida el método para otros contextos.
- Los umbrales son convenciones; la calibración de cada caso real es una decisión del equipo y debe quedar escrita.
- El E-value y el valor de robustez son aproximaciones y no identifican al confusor ni su prevalencia.
- Un monitor que no dispara no demuestra que los supuestos se cumplan.

9. Evaluación

La evaluación oficial tiene cuatro componentes: tres quizzes online y un trabajo final único. Las prácticas del curso preparan esas evaluaciones, pero no crean entregas adicionales ni requisitos de admisibilidad.

Evaluación	Peso	Qué se observa
Quiz online 1	10 %	Comprensión y aplicación de los fundamentos de causalidad, identificación y datos.
Quiz online 2	10 %	Comprensión y aplicación de estimación, incertidumbre y validación.
Quiz online 3	10 %	Comprensión y aplicación de producción local, documentación y monitoreo.
Trabajo final único	70 %	Sistema causal completo sobre un caso elegido: pregunta, identificación, estimación, política, puesta en producción local, monitoreo y defensa. Ver `06_proyecto_final/`.

Los labs L01–L28, los notebooks guiados, la bitácora, las prácticas de las Series A y B y el checkpoint son formativos y no tienen una nota separada. Su función es preparar el trabajo final y dar oportunidades de recibir retroalimentación.

9.1 Qué se evalúa con una máquina y qué con una persona

Verificación automática	Lectura del profesor
Resultados y respuestas del quiz \ Tiempo y estado de envío \ Integridad de los archivos del trabajo final \ Ejecución del sistema local \ Contrato de la API \ Presupuesto, soporte y alertas del monitor	Calidad de la pregunta y de la identificación \ Defensa de los supuestos \ Interpretación del efecto \ Validez externa \ Equidad y límites \ Calidad de la model card \ Claridad de la decisión

Los verificadores automáticos comprueban condiciones concretas. No sustituyen la rúbrica ni convierten un resultado técnico en una nota sin revisión del razonamiento. La elección entre HTTP y CLI no se califica como una preferencia de implementación.

9.2 Evidencia de las evaluaciones

Evaluación	Evidencia
Quizzes online	Tres actividades individuales realizadas en las fechas del cronograma. La plataforma registra las respuestas y el resultado de cada quiz.
Trabajo final único	Un paquete con notebook o informe ejecutado, sistema causal funcionando en local, model card, artefactos versionados, evidencia de la puerta y del monitor, y una defensa final. No se entregan trabajos separados para cada práctica intermedia.

9.3 Frontera entre prácticas y evaluación

Las prácticas preparan; no se entregan ni se califican por separado. La evaluación oficial se concentra en los tres quizzes online y en el trabajo final único.

Actividad	Función
Labs y notebooks guiados	Practicar conceptos, métodos y herramientas con datos y escenarios controlados.
Bitácora y revisión de avance	Hacer explícitos el método, el supuesto, la evidencia y la decisión. Sirven para recibir retroalimentación.
Quizzes online	Comprobar individualmente la comprensión de los bloques del curso.

Actividad	Función
Trabajo final	Integrar la cadena causal completa y defenderla. Es la única entrega de trabajo calificada.

9.4 Fechas de evaluación

Las fechas oficiales son las que aparecen en la sección 5.1 y en el calendario de `01_silabo/chronograma/`. Los tres quizzes se realizan durante el semestre y el trabajo final se entrega al cierre administrativo de la semana 18. Cualquier cambio se comunica por la plataforma institucional; las prácticas pueden reorganizarse sin crear nuevas evaluaciones.

9.5 Integridad académica y uso de asistentes de IA

El trabajo final es individual. Los labs y las prácticas pueden discutirse, pero cada estudiante debe ejecutar y comprender sus propios resultados. Los quizzes se resuelven individualmente según las reglas de la plataforma; cualquier ayuda permitida se indicará en el enunciado.

En las prácticas y en el trabajo final se pueden usar asistentes de IA y buscadores como apoyo, con tres condiciones:

1. **Se declara.** La línea *Ayudas* de la bitácora y la documentación final indican qué herramienta se usó y para qué.
2. **Se puede defender.** El estudiante explica y reproduce cada resultado. La revisión formativa y la defensa final permiten comprobarlo.
3. **Los resultados son propios.** Las cifras salen de artefactos que el estudiante ejecutó, y el paquete final incluye comandos, salidas y hashes cuando corresponda.

Copiar el trabajo de otro estudiante o compartir las columnas de verdad del benchmark (`y0`, `y1`, `tau`) es una falta de integridad.

9.6 Datos del proyecto y confidencialidad

El caso propio puede usar datos de la organización del estudiante solo si tiene autorización para ello. Los datos se quedan en su equipo: al curso se entregan el código, los hashes y resultados agregados, nunca registros individuales. Si no puede usar datos propios, elige un caso del benchmark documentado.

10. Materiales y herramientas

Componente	Ubicación en el monorepo	Rol
Monografía	`02_monografia/`	Lectura de los Caps. 1–32
Labs L01–L28	`05_labs_sesion/`	Práctica formativa por sesión (sin L16)
Casos guiados (Serie A)	`03_notebooks_caso_estudio/`	Prácticas de identificación, DML, CATE y política; sin calificación separada
Producción local (Serie B)	`04_produccion_causal/`	Prácticas de servicio, model card, puerta, política local y monitor; sin calificación separada

Componente	Ubicación en el monorepo	Rol
Paquete de estudiante	Se entrega al inicio	Datos, labs, librería y guía de instalación, sin el resto del repositorio
Datos	`data_benchmark_causal/`	Jobs, IHDP y escenarios sintéticos documentados
MLOps local	`docs/ejemplo_mlops_abierto/`	Ejemplo de referencia de la sección 8
Diapositivas	`07_diapositivas/capitulos/`	Un mazo por capítulo
Proyecto	`06_proyecto_final/`	Guía, rúbrica y checklist de humo
Planes	`PLAN_CURSO_COMPLETO.md`, `CHRONOGRAMA_SEMANAL.md`, `01_silabo/chronograma/`	Práctica y calendario oficial de evaluaciones

- ☐ Python 3.11 o superior; pandas, NumPy, scikit-learn y SciPy; utilidades de Serie A en `03_notebooks_caso_estudio/lib/` y componentes de producción en `04_produccion_causal/src/`.
  - ☐ EconML y DoubleML (recomendados; el monorepo trae alternativa con scikit-learn).
  - ☐ FastAPI y Uvicorn para el servicio; CLI y scripts reproducibles para policy y monitoreo.
  - ☐ `jsonschema` para validar la ficha causal contra `04_produccion_causal/esquemas/causal--model-card.local.schema.json` (`local-0.2`). El esquema v1 de `B2_model_card_ci/schemas/` es solo un ejemplo didáctico, no el contrato runtime.
  - ☐ Opcionales: MLflow y DVC en modo local; contenedores (sección 8.5).
  - ☐ Datos: solo los del benchmark documentado en `data_benchmark_causal/`.
  - ☐ Auditoría local: `bash scripts/audit_repo.sh`.

11. Guía operativa

11.1 Rutina semanal

Quién	Antes	Durante (90 min)	Después
Profesor	Leer el capítulo y el lab; preparar la pregunta de negocio de la sesión.	15′ pregunta · 55′ lab · 10′ bitácora · 10′ cierre.	Responder dudas; preparar los quizzes y el trabajo final sin añadir tareas calificadas.
Estudiante	Leer el capítulo del PDF y revisar el README y las instrucciones del lab.	Intentar primero el lab de forma autónoma, ejecutar sus comprobaciones, consultar `solution.ipynb` solo si hay un bloqueo y completar la fila de bitácora.	Terminar el lab o dejar registrado qué quedó pendiente; completar la fila y preparar el quiz o el trabajo final cuando corresponda.

11.2 Listas de verificación

Estudiante: (1) capítulo leído; (2) celdas de comprobación y salida del lab revisadas; (3) fila de bitácora validada; (4) preparación del quiz o del trabajo final, si corresponde; (5) tres líneas de «predictivo frente a efecto»; (6) ninguna columna de verdad fuera de la evaluación.

Profesor: (1) capítulo, lab y ejemplo de negocio de la cohorte; (2) numeración vigente del PDF; (3) cierre con la pregunta del curso; (4) horario de consulta para los quizzes y el trabajo final; (5) los capítulos electivos (◇) no entran al checkpoint.

11.3 Primera apertura

Estudiante: autodiagnóstico de la semana 0 → `01_silabo/silabo_final_vista_previa.pdf` → `01_silabo/chronograma/` → capítulo de la semana → `05_labs_sesion/Lxx-nombre/README.md` → `05_labs_sesion/Lxx-nombre/lab.ipynb` → intento autónomo y comprobaciones → consulta de `solution.ipynb` si hay bloqueo → bitácora → preparación del quiz o del trabajo final.

Profesor: `docs/NOTA_INSTRUCTORS.md` → sílabo y cronograma → `bash scripts/audit_repo.sh` → demostración de 10 minutos (L01 y el compromiso de trabajo).

12. Referencias

12.1 Fuentes principales del curso

- Curso ECO-490/ECON-540 (2026). *Sistema de Inteligencia Causal*. Monografía en Typst, 32 capítulos. `02_monografia/`.
- Bareinboim, E. (2025). *Causal Artificial Intelligence* (v0.27). Columbia CausalAI Lab.
- Huyen, C. (2022). *Designing Machine Learning Systems*. O'Reilly.
- Chen, C., Murphy, N. R., Parisa, K., Sculley, D. y Underwood, T. (2022). *Reliable Machine Learning*. O'Reilly.
- Kästner, C. *Machine Learning in Production*. Carnegie Mellon University.

12.2 Fundamentos de inferencia causal

- Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2.ª ed.). Cambridge University Press.
- Pearl, J. y Mackenzie, D. (2018). *The Book of Why*. Basic Books.
- Hernán, M. A. y Robins, J. M. (2020). *Causal Inference: What If*. Chapman & Hall/CRC.
- Imbens, G. W. y Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press.
- Rosenbaum, P. R. y Rubin, D. B. (1983). The central role of the propensity score in observational studies for causal effects. *Biometrika*, 70(1), 41–55.

12.3 Estimación con ML y efectos heterogéneos

- Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W. y Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68.
- Bang, H. y Robins, J. M. (2005). Doubly robust estimation in missing data and causal inference models. *Biometrics*, 61(4), 962–973.
- Künzel, S. R., Sekhon, J. S., Bickel, P. J. y Yu, B. (2019). Metalearners for estimating heterogeneous treatment effects using machine learning. *PNAS*, 116(10), 4156–4165.
- Wager, S. y Athey, S. (2018). Estimation and inference of heterogeneous treatment effects using random forests. *Journal of the American Statistical Association*, 113(523), 1228–1242.
- Athey, S., Tibshirani, J. y Wager, S. (2019). Generalized random forests. *The Annals of Statistics*, 47(2), 1148–1178.
- Kennedy, E. H. (2023). Towards optimal doubly robust estimation of heterogeneous causal effects. *Electronic Journal of Statistics*, 17(2), 3008–3049.
- Nie, X. y Wager, S. (2021). Quasi-oracle estimation of heterogeneous treatment effects. *Biometrika*, 108(2), 299–319. (datos bibliográficos por verificar)
- Athey, S. y Wager, S. (2021). Policy learning with observational data. *Econometrica*, 89(1), 133–161. (datos bibliográficos por verificar)

12.4 Diagnósticos, solapamiento y sensibilidad

- Crump, R. K., Hotz, V. J., Imbens, G. W. y Mitnik, O. A. (2009). Dealing with limited overlap in estimation of average treatment effects. *Biometrika*, 96(1), 187–199.

- Austin, P. C. (2011). An introduction to propensity score methods for reducing the effects of confounding in observational studies. *Multivariate Behavioral Research*, 46(3), 399–424.
- VanderWeele, T. J. y Ding, P. (2017). Sensitivity analysis in observational research: introducing the E--value. *Annals of Internal Medicine*, 167(4), 268–274.
- Cinelli, C. y Hazlett, C. (2020). Making sense of sensitivity: extending omitted variable bias. *Journal of the Royal Statistical Society: Series B*, 82(1), 39–67.
- Chernozhukov, V., Cinelli, C., Newey, W., Sharma, A. y Syrgkanis, V. (2022). *Long story short: omitted variable bias in causal machine learning*. NBER Working Paper 30302.
- Lipsitch, M., Tchetgen Tchetgen, E. y Cohen, T. (2010). Negative controls: a tool for detecting confounding and bias in observational studies. *Epidemiology*, 21(3), 383–388.

12.5 Datos de referencia y validez externa

- LaLonde, R. J. (1986). Evaluating the econometric evaluations of training programs with experimental data. *The American Economic Review*, 76(4), 604–620.
- Dehejia, R. H. y Wahba, S. (1999). Causal effects in nonexperimental studies: reevaluating the evaluation of training programs. *Journal of the American Statistical Association*, 94(448), 1053–1062.
- Hill, J. L. (2011). Bayesian nonparametric modeling for causal inference. *Journal of Computational and Graphical Statistics*, 20(1), 217–240.
- Dorie, V., Hill, J., Shalit, U., Scott, M. y Cervone, D. (2019). Automated versus do-it-yourself methods for causal inference: lessons learned from a data analysis competition. *Statistical Science*, 34(1), 43–68.
- Pearl, J. y Bareinboim, E. (2014). External validity: from do-calculus to transportability across populations. *Statistical Science*, 29(4), 579–595.
- Bareinboim, E. y Pearl, J. (2016). Causal inference and the data-fusion problem. *PNAS*, 113(27), 7345–7352.

12.6 Descubrimiento, explicación y equidad

- Spirtes, P., Glymour, C. y Scheines, R. (2000). *Causation, Prediction, and Search* (2.ª ed.). MIT Press.
- Zheng, X., Aragam, B., Ravikumar, P. y Xing, E. P. (2018). DAGs with NO TEARS: continuous optimization for structure learning. *Advances in Neural Information Processing Systems*, 31.
- Lundberg, S. M. y Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.
- Kusner, M. J., Loftus, J., Russell, C. y Silva, R. (2017). Counterfactual fairness. *Advances in Neural Information Processing Systems*, 30.

12.7 Producción, monitoreo y documentación

- Sculley, D. et al. (2015). Hidden technical debt in machine learning systems. *Advances in Neural Information Processing Systems*, 28.
- Breck, E., Cai, S., Nielsen, E., Salib, M. y Sculley, D. (2017). The ML test score: a rubric for ML production readiness and technical debt reduction. *IEEE International Conference on Big Data*.
- Gama, J., Žliobaitė, I., Bifet, A., Pechenizkiy, M. y Bouchachia, A. (2014). A survey on concept drift adaptation. *ACM Computing Surveys*, 46(4), 44.
- Rabanser, S., Günnemann, S. y Lipton, Z. C. (2019). Failing loudly: an empirical study of methods for detecting dataset shift. *Advances in Neural Information Processing Systems*, 32.
- Mitchell, M. et al. (2019). Model cards for model reporting. *Proceedings of the Conference on Fairness, Accountability, and Transparency (FAT*)*, 220–229.

12.8 Software y documentación técnica

- Bach, P., Chernozhukov, V., Kurz, M. S. y Spindler, M. (2022). DoubleML: an object-oriented implementation of double machine learning in Python. *Journal of Machine Learning Research*, 23(53), 1–6.
- Sharma, A. y Kiciman, E. (2020). *DoWhy: an end-to-end library for causal inference*. arXiv:2011.04216.
- EconML (PyWhy). Biblioteca de estimación de efectos heterogéneos. github.com/py-why/EconML
- FastAPI. *Lifespan events*. fastapi.tiangolo.com/advanced/events
- MLflow. *Tracking server*. mlflow.org/docs/latest/self-hosting/architecture/tracking-server
- Docker. *Control startup order in Compose*. docs.docker.com/compose/how-tos/startup-order
- Docker. *docker compose up*. docs.docker.com/reference/cli/docker/compose/up