MONOGRAFÍA DEL CURSO

Sistema de Inteligencia Causal

*De la identificación al despliegue: estimar **efectos**, no solo predicciones,*
y poner políticas causales en producción local

Curso ECO-490 / ECON-540

Profesionales y posgrado aplicado (data / ML / product / analytics)

Modalidad online/asíncrona · 32 sesiones · 33 capítulos

Edición 2026

Promesa. Deja de priorizar con scores que confunden correlación con impacto. Estima efectos, documenta supuestos y despliega localmente, con monitoreo de cuándo el efecto deja de ser válido.

Monorepo del curso: labs L01–L28 · Serie A (casos) · Serie B (local) · benchmark de datos
Stack: `econml` / `sklearn` · `FastAPI` · `Streamlit` · `Docker`

Sistema de Inteligencia Causal

Monografía del Curso ECO-490 / ECON-540

Edición 2026

© 2026 Curso ECO-490 / ECON-540
Todos los derechos reservados.

ISBN: TODO: ISBN por asignar

Primera edición, 2026.

Queda prohibida la reproducción total o parcial de esta obra por cualquier medio o procedimiento (incluidos la reprografía, el tratamiento informático y la distribución de ejemplares mediante alquiler o préstamo públicos) sin la autorización previa y por escrito del titular de los derechos.

Compuesto con Typst 0.15.1.
Tipografía: New Computer Modern (serif), Inter (sans-serif), DejaVu Sans Mono (monoespaciada).

Marcas de terceros. PyTorch, scikit-learn, FastAPI, Docker, `econml`, `DoubleML`, `causalml` y `dowhy` son marcas (registradas o no) de sus respectivos titulares. Su mención en esta obra es meramente descriptiva y no implica patrocinio, respaldo ni afiliación alguna.

Implementación de referencia en el monorepo del curso (`data_benchmark_causal`, Serie A/B).
Stack Python: `econml`, `DoubleML`, `causalml`, `dowhy`, `PyTorch`.

Esta monografía es material de referencia para uso docente.
La reproducción total o parcial requiere citación adecuada.

Prefacio

Este libro está pensado, en primer lugar, para **profesionales**: analistas de datos, ingenieros de ML, product analytics, riesgo, operaciones y perfiles afines, que ya usan modelos predictivos y deben **decidir o priorizar intervenciones**. También sirve a posgrado aplicado y a economistas de último año con base cuantitativa. Está escrito para leerse y consultarse de forma autónoma. No es un tratado para investigadores básicos: el recorrido prioriza los **casos de estudio**, la **estimación de efectos accionables** y la **puesta en producción**.

Se asume familiaridad con regresión, evaluación de modelos y, de forma deseable, nociones de evaluación de impacto (resultados potenciales, confusión). Quien ya conozca la causalidad aplicada (experimentos, emparejamiento y ponderación, variables instrumentales, diferencias en diferencias) avanzará más rápido; quien no, puede apoyarse en los Caps. 1 a 3. El libro **extiende** ese bagaje al régimen de alta dimensionalidad y de heterogeneidad de efectos, y sobre todo a la ingeniería de sistemas que hace falta para **operar** esos métodos.

El eje conceptual combina tres tesis.

Primera: el aprendizaje automático no identifica causalidad por sí solo. Los supuestos de identificación siguen siendo del dominio y deben justificarse. Lo que el ML aporta es flexibilidad para estimar los componentes auxiliares (*nuisance*: propensión, modelos de resultado) sin perder inferencia válida, gracias a la **ortogonalización de Neyman**, el **cross-fitting** y la **honestidad** de los árboles.

Segunda: un estimador causal validado no es todavía un sistema. Documentarlo, servirlo, versionarlo y monitorearlo es trabajo de ingeniería (Huyen, 2022), y en un sistema causal tiene una dificultad adicional: los supuestos que lo justifican no se ven en los datos y pueden dejar de valer sin que ninguna métrica lo anuncie. Por eso gran parte de la ingeniería de este libro consiste en dejar por escrito esos supuestos y en vigilar lo que sí se puede vigilar.

Tercera, la que vertebra el libro: priorizar por puntaje predictivo no es lo mismo que priorizar por efecto. Un buen predictor responde «quién tiene el peor resultado». Un sistema causal responde «a quién **cambia** el resultado si actuamos». Esa diferencia reordena presupuestos, *targeting* y riesgo reputacional, y es la que justifica el costo de todo lo demás. Cada bloque del libro cierra con la misma pregunta: **si solo predijéramos, ¿a quién trataríamos? Con el efecto, ¿cambia la decisión?**

Cómo está organizado

El libro se escribe en cuatro capas: teoría, pseudocódigo, principios con casos canónicos, e implementación. Las tres primeras duran, y la cuarta se renueva con las herramientas. La sección *Cómo usar este libro* explica las capas y los dos tipos de capítulo, los de método y los de ingeniería. Los capítulos de método responden «cómo se estima esto correctamente», y los de ingeniería, «cómo se lleva esto a producción de forma responsable». Los Caps. 17, 27 y 28 (panel con DML y variables instrumentales, *deep learning* causal y *matrix completion*) son **profundización electiva**: no hacen falta para cubrir el núcleo, aunque amplían de forma considerable el repertorio de métodos.

Convenciones. La notación sigue el estándar de la literatura: $Y(d)$ denota el resultado potencial bajo el tratamiento $d \in \{0, 1\}$, D es la asignación observada y X son las covariables previas al tratamiento. El estimando central es el CATE $\tau(x) = E[Y(1) - Y(0) \mid X = x]$, cuyo promedio $\theta = E[\tau(X)]$ es el ATE. Los algoritmos se presentan en pseudocódigo de complejidad similar a la de los artículos originales. En el texto corrido los decimales se escriben con coma, y dentro de las fórmulas con punto. La tabla completa de notación está en la sección siguiente.

Código, datos y material del curso. La implementación de referencia (laboratorios L01 a L28, notebooks de las series A y B, datos de benchmark y autograders) vive junto a este libro en el repositorio del curso. La tabla sesión ↔ capítulo ↔ laboratorio ↔ entrega y el posicionamiento profesional se detallan en el sílabo y se reproducen en el Apéndice J. Cuando un listado de código del libro use un diseño idealizado (por ejemplo, Parquet con `CausalSchema`), el monorepo documenta el **equivalente operativo** (CSV con `metadata.json` y `lib.data_io`).

Agradecimientos. Esta obra se apoya en tres fuentes de ingeniería y teoría: *Designing Machine Learning Systems* (Huyen), *Causal Artificial Intelligence* (Bareinboim) y *Machine Learning in Production* (CMU), y en el ecosistema de benchmarks que acompaña al libro (`data_benchmark_causal`). Agradecemos a los autores de los trabajos metodológicos citados a lo largo del texto.

Cómo usar este libro

Este libro presenta los métodos de aprendizaje automático causal, los principios para llevarlos a producción y la razón por la que la teoría causal hace que esa producción tenga efecto real. Tiene nueve partes y treinta y tres capítulos, y está escrito en capas para que cada lector entre por el nivel que necesita.

Las capas de un capítulo

Todo capítulo se construye con las mismas capas, de la más estable a la más cambiante.

- **Capa 0, teoría.** Definiciones, supuestos, proposiciones y demostraciones o bosquejos. Responde la pregunta «¿qué se puede afirmar, y bajo qué supuestos?».
- **Capa 1, pseudocódigo.** Algoritmos numerados, escritos sin referencia a ningún lenguaje. Responde «¿qué pasos hay que dar?».
- **Capa 2, principios y casos canónicos.** Las ideas que sobreviven al cambio de herramientas, y casos pequeños con números verificados por simulación. Un caso canónico sirve de prueba de aceptación: cualquier implementación del método, con la herramienta que sea, debe reproducir su orden de magnitud. Responde «¿cómo sé que lo hice bien?».
- **Capa 3, implementación.** Listados, configuración y guías de herramientas. Responde «¿cómo lo hago hoy, con estas piezas?». Es la capa que más rápido envejece.

Esta es la **edición de curso**: contiene las cuatro capas, los laboratorios y el material docente de los apéndices. Las capas 0 a 2 son idénticas a las de las otras ediciones del libro; lo que cambia es la capa 3 y el aparato de curso.

Dos tipos de capítulo

Capítulos de método (todos los que no son de ingeniería). Siguen este orden: problema, estimando e identificación; teoría, supuestos y garantías; procedimientos, con su pseudocódigo; casos canónicos y validación; implementación; riesgos, límites y sensibilidad; y ejercicios con notas bibliográficas. Responden «¿cómo se estima esto correctamente?».

Capítulos de ingeniería (Caps. 2, 4, 7, 9, 15, 19, 20 y 30 a 33). Siguen la filosofía de *Designing Machine Learning Systems* (Huyen, 2022): no entregan recetas únicas sino decisiones de diseño con costos y beneficios explícitos. Sus pasos son: el problema de diseño; las opciones y sus compromisos, con al menos dos alternativas reales; la decisión de referencia; el contrato de la pieza y su implementación de referencia; la aplicación al sistema causal de referencia; las

señales de alerta con su checklist operativo; y los ejercicios. Responden «¿cómo se lleva esto a producción de forma responsable?».

Los dos tipos comparten el cuadro resumen del inicio (el **cuadro sinóptico** en los de método y el **cuadro de decisión** en los de ingeniería), el sistema de referencias cruzadas y la numeración de figuras, tablas y algoritmos.

Partes del libro

Parte	Contenido	Caps.
0	Introducción: causalidad elemental y anatomía de un sistema de ML en producción.	1–2
I	Fundamentos estructurales y de datos: SCM, Jerarquía Causal de Pearl, regularización, criterio de puerta trasera, ingeniería de datos y **features** sin fuga causal.	3–9
II	Estimación causal flexible y primer despliegue: ortogonalidad, DML, meta-learners, bosques causales, validación y el primer servicio causal desplegado.	10–15
III	Diseños de identificación con ML: Post-Double-Selection, panel e instrumentos, mapa de decisión metodológica.	16–18
IV	Registro y operación en producción: **model cards** causales e integración continua.	19–20
V	Heterogeneidad, políticas y **targeting**: **policy learning** y **uplift modeling**.	21–22
VI	Explicación, equidad y decisión estructural: descomposición causal de la equidad, interpretabilidad, decisiones bajo incertidumbre y transportabilidad.	23–26
VII	Métodos avanzados: **deep learning** causal, control sintético y **matrix completion**.	27–28
VIII	Estructura, monitoreo y frontera: descubrimiento de grafos, monitoreo en producción, aprendizaje continuo, panorama de RL causal, comunicación de resultados y supuestos no observables en operación.	29–33

Elementos del libro

Algunos elementos se repiten en todos los capítulos.

- **Cuadro sinóptico o de decisión:** el resumen ejecutivo del capítulo, al comienzo.
- **Algoritmos:** pseudocódigo numerado, independiente del lenguaje.
- **Casos canónicos:** recuadros con un experimento pequeño y sus números, que sirven de prueba de aceptación.

- **Intuición y notas técnicas:** la primera explica una idea sin fórmulas; las segundas desarrollan un detalle matemático opcional o enlazan capítulos.
- **Tablas de riesgos:** riesgos, consecuencias, diagnósticos y mitigaciones.
- **Checklists:** listas de verificación de validación o de señales de alerta operativas.
- **Apéndices:** fundamentos matemáticos (Apéndice A), guía de herramientas y entorno (Apéndice B), datos y procesos generadores (Apéndice C), glosario (Apéndice D), plantilla de proyecto y rúbrica (Apéndice E), checklists por método (Apéndice F), plantilla de **model card** causal (Apéndice G), checklist de arquitectura de despliegue (Apéndice H) y contratos numerados de ingeniería (Apéndice I), más la guía para instructores y equipos de curso (Apéndice J).

Audiencia profesional y camino crítico

El camino crítico para profesionales (★) prioriza: identificación y datos (Caps. 1–4, 6–9), luego DML y validación (10–11, 14), el primer servicio (15), CATE y políticas (12–13, 21–22), el registro y las pruebas de despliegue (19–20), la explicación y la decisión (23–26), y por último el monitoreo, la comunicación y los supuestos no observables (29–33). Los Caps. **16–18** y **27–28** son profundización electiva (◇): útiles, pero no bloquean la puesta en producción de un sistema.

Este libro se lee junto al **monorepo del curso**: laboratorios, notebooks de las series A/B, datos de benchmark y proyecto final. El detalle de esa organización, y su correspondencia con cada capítulo, está en el Apéndice J.

Pregunta de valor (se repite en cada bloque). Si solo predijéramos el resultado, ¿a quién trataríamos? Si estimamos el efecto, ¿cambia el ranking, el presupuesto o el riesgo?

Cómo leer un capítulo de ingeniería

1. Cuadro de decisión, con los compromisos principales.
2. Problema de diseño **propio de un sistema causal**.
3. Opciones reales, no una sola receta.
4. Decisión de referencia del curso.
5. Contrato de la pieza e implementación de referencia, con el código en un recuadro propio.
6. Checklist operativo y señales de alerta.
7. Ejercicios y actividades prácticas.

Notación y convenciones

La siguiente tabla resume los símbolos principales utilizados a lo largo de la monografía.

Símbolo	Significado	Uso
$Y_i(d)$	Resultado potencial bajo tratamiento d	Capítulos 1, 5
D_i	Tratamiento observado	Todo el libro
X_i	Covariables pre-tratamiento	Todo el libro
$\tau(x)$	CATE: $E[Y(1) - Y(0) \mid X = x]$	5, 10–14, 21–22, 25, 27
θ_0	Parámetro causal verdadero	Capítulos 6, 10–11, 16–17
ATE o θ_{ATE}	ATE: $E[\tau(X)]$	Todo el libro
$\mu_d(x)$	Outcome condicional: $E[Y \mid X = x, D = d]$	Capítulos 5, 10–14, 21, 27
$g_0(x)$	Componente estructural PLR	Capítulos 10–11, 17
$l_0(x)$	Outcome regression PLR: $E[Y \mid X = x]$	Capítulos 10–11
$e_0(x)$	Propensity score: $E[D \mid X = x]$	Capítulos 5, 10–14, 21–22
$m_0(x)$	Tratamiento condicional: $E[D \mid X = x]$	Capítulos 10–11
$\psi(W, \theta, \eta)$	Score ortogonal	Capítulos 10–11, 17
η	Nuisance parameter	Capítulos 10–11
$W_i = (Y_i, D_i, X_i)$	Observación i-ésima	Todo el libro
Z, Z_i	Instrumento (en el Cap. 8, conjunto de ajuste de puerta trasera)	Capítulos 3, 8, 16–17
$Y_i^\star$	*Transformed outcome*	Capítulos 14, 24
$\boldsymbol{W}$	Matriz de adyacencia (NOTEARS)	Capítulo 29
$\boldsymbol{w}$	Pesos del control sintético	Capítulo 28
$\omega_i(x)$	Pesos locales (GRF)	Capítulo 13
$\mathcal{V}$	Varianza asintótica	Capítulos 10–11
$V(\pi)$	Valor de la política	Capítulos 21–22

Símbolo	Significado	Uso
A	Atributo protegido	Capítulo 23
α_i	Efecto fijo de unidad	Capítulo 17
$\mathcal{L}_m$	Hoja m-ésima del árbol	Capítulo 13
u_i	Residuo Robinson (outcome)	Capítulos 10–11
v_i	Residuo Robinson (tratamiento)	Capítulos 10–11
λ	Penalización / multipl. presupuestario	Capítulos 6, 16, 21–22, 28
n, N, T	Obs. i.i.d. / unidades / periodos	Todo el libro

Símbolos y convenciones de notación.

Índice general

Prefacio ... iii
Cómo está organizado ... iv
Cómo usar este libro ... v
Las capas de un capítulo ... v
Dos tipos de capítulo ... v
Partes del libro ... vi
Elementos del libro ... vi
Audiencia profesional y camino crítico ... vii
Cómo leer un capítulo de ingeniería ... vii
Notación y convenciones ... viii
1 Causalidad elemental y el problema fundamental de la inferencia causal ... 35
1.1 Dos preguntas que parecen la misma ... 35
1.2 Correlación no es causalidad: tres escenas clásicas ... 36
1.3 El problema fundamental de la inferencia causal ... 37
1.4 Un adelanto de la escalera de la causalidad ... 38
1.5 Por qué el aprendizaje automático no es causal por defecto ... 39
1.6 Ejercicios y notas bibliográficas ... 39
1.6.1 Ejercicios conceptuales ... 39
1.6.2 Notas bibliográficas ... 40
2 Anatomía de un sistema de ML en producción ... 41
2.1 El problema de diseño ... 41
2.2 Opciones y trade-offs ... 42
2.3 Decisión de referencia para el curso ... 43
2.4 El sistema desplegado es una intervención ... 43
2.5 Las cinco acciones del sistema ... 45
2.6 Implementación de referencia: el esqueleto del proyecto del curso ... 46
2.7 Aplicación al sistema causal del curso ... 46
2.8 Señales de alerta y checklist operativo ... 47
2.9 Ejercicios y notas bibliográficas ... 47
2.9.1 Ejercicios conceptuales ... 47
2.9.2 Ejercicio de infraestructura (Lab 0) ... 48
2.9.3 Notas bibliográficas ... 48
3 Modelos Causales Estructurales y la Jerarquía Causal de Pearl ... 51
3.1 El problema: formalizar «causa» matemáticamente ... 51

3.2 Teoría: SCM y la Jerarquía Causal de Pearl . . . 52
3.2.1 Modelos Causales Estructurales . . . 52
3.2.2 Los tres niveles de la Jerarquía Causal de Pearl . . . 52
3.3 De la ecuación a los números: un caso canónico . . . 54
3.4 Consistencia del grafo supuesto con los datos . . . 55
3.5 Qué cambia en un sistema desplegado . . . 57
3.6 Riesgos, límites y sensibilidad . . . 58
3.7 Ejercicios y notas bibliográficas . . . 58
3.7.1 Ejercicios teóricos . . . 58
3.7.2 Ejercicios computacionales . . . 59
3.7.3 Notas bibliográficas . . . 59
4 Ingeniería de datos para sistemas causales . . . 60
4.1 El problema de diseño . . . 61
4.2 Opciones y trade-offs . . . 61
4.3 Decisión de referencia para el curso . . . 61
4.4 El contrato del esquema de roles . . . 62
4.5 Implementación de referencia . . . 64
4.6 Aplicación al sistema causal del curso . . . 66
4.7 Señales de alerta y checklist operativo . . . 67
4.8 Ejercicios y notas bibliográficas . . . 67
4.8.1 Ejercicios conceptuales . . . 67
4.8.2 Ejercicio de infraestructura . . . 67
4.8.3 Notas bibliográficas . . . 67
5 Predicción y causalidad: por qué el ML no es causal por defecto . . . 69
5.1 Problema causal, estimando e identificación . . . 69
5.2 Teoría, supuestos y garantías . . . 71
5.2.1 Supuestos . . . 71
5.2.2 Estimandos e identificación . . . 72
5.2.3 Sesgo de primer orden del estimador por sustitución . . . 72
5.3 Procedimiento: simulación con verdad conocida . . . 73
5.4 Casos canónicos y validación . . . 73
5.4.1 Interpretación económica . . . 75
5.5 Implementación en Python . . . 76
5.6 Riesgos, límites y sensibilidad . . . 78
5.7 Ejercicios y notas bibliográficas . . . 79
5.7.1 Ejercicios teóricos . . . 79
5.7.2 Ejercicios computacionales . . . 80
5.7.3 Ejercicios aplicados . . . 80
5.7.4 Notas bibliográficas . . . 80
6 Regularización, selección de variables y sesgo post-selección . . . 81
6.1 Problema causal, estimando e identificación . . . 81
6.2 Teoría, supuestos y garantías . . . 82

6.2.1 Supuestos . . . 82
6.2.2 Estimadores penalizados . . . 82
6.2.3 Garantías de estimación . . . 83
6.2.4 Recuperar el soporte exige mucho más que recuperar el vector . . . 83
6.2.5 El problema de Leeb y Pötscher . . . 84
6.2.6 Por qué la doble selección corrige el problema . . . 85
6.2.7 Dos familias de respuestas . . . 85
6.3 Algoritmo . . . 86
6.4 Casos canónicos y validación . . . 87
6.5 Implementación en Python . . . 88
6.6 Riesgos, límites y sensibilidad . . . 91
6.7 Ejercicios y notas bibliográficas . . . 92
6.7.1 Ejercicios teóricos . . . 92
6.7.2 Ejercicios computacionales . . . 92
6.7.3 Notas bibliográficas . . . 92
7 Datos de entrenamiento en sistemas causales . . . 93
7.1 El problema de diseño . . . 93
7.2 Opciones y trade-offs . . . 94
7.3 Decisión de referencia para el curso . . . 94
7.4 El chequeo de balance . . . 95
7.5 El contrato de la comparación de poblaciones . . . 96
7.6 Implementación de referencia . . . 98
7.7 Aplicación al sistema causal del curso . . . 99
7.8 Señales de alerta y checklist operativo . . . 99
7.9 Ejercicios y notas bibliográficas . . . 100
7.9.1 Ejercicios conceptuales . . . 100
7.9.2 Ejercicio computacional . . . 100
7.9.3 Notas bibliográficas . . . 100
8 Razonamiento intervencional y contrafactual . . . 102
8.1 Problema causal, estimando e identificación . . . 102
8.2 Teoría, supuestos y garantías . . . 103
8.2.1 El criterio de puerta trasera . . . 103
8.2.2 Buenos y malos controles . . . 103
8.2.3 Las tres reglas del cálculo-do . . . 105
8.2.4 Cuando la puerta trasera falla: el criterio de puerta delantera . . . 106
8.2.5 Cómputo contrafactual: abducción, acción, predicción . . . 107
8.3 Algoritmo e implementación . . . 108
8.4 Caso aplicado: el grafo de educación y salario . . . 108
8.5 Riesgos, límites y sensibilidad . . . 109
8.6 Ejercicios y notas bibliográficas . . . 109
8.6.1 Ejercicios teóricos . . . 109
8.6.2 Ejercicios computacionales . . . 110

8.6.3 Notas bibliográficas ... 110
9 Ingeniería de *features* sin fuga causal ... 111
9.1 El problema de diseño ... 112
9.2 Opciones y trade-offs ... 112
9.3 Decisión de referencia para el curso ... 112
9.4 El contrato de la auditoría de *features* ... 114
9.5 Implementación de referencia ... 116
9.6 Aplicación al sistema causal del curso ... 118
9.7 Señales de alerta y checklist operativo ... 118
9.8 Ejercicios y notas bibliográficas ... 118
9.8.1 Ejercicios conceptuales ... 118
9.8.2 Ejercicio computacional ... 119
9.8.3 Notas bibliográficas ... 119
10 Ortogonalidad de Neyman, cross-fitting e influence functions ... 122
10.1 Problema causal, estimando e identificación ... 122
10.2 Teoría, supuestos y garantías ... 123
10.2.1 El problema del doble sesgo ... 123
10.2.2 Ortogonalidad de Neyman ... 124
10.2.3 Construcción del score ortogonal para PLR ... 124
10.2.4 Teorema central de DML ... 126
10.3 Procedimientos ... 127
10.3.1 El rol del cross-fitting ... 127
10.4 Casos canónicos y validación ... 128
10.5 Implementación en Python ... 129
10.6 Riesgos, límites y sensibilidad ... 131
10.7 Ejercicios y notas bibliográficas ... 131
10.7.1 Ejercicios teóricos ... 131
10.7.2 Ejercicios computacionales ... 132
10.7.3 Notas bibliográficas ... 132
11 Double/Debiased Machine Learning ... 133
11.1 Problema causal, estimando e identificación ... 133
11.2 Teoría, supuestos y garantías ... 134
11.2.1 Supuestos ... 134
11.2.2 Estimador y score ... 134
11.2.3 Garantías ... 135
11.2.4 Diagnósticos cuantitativos de soporte común ... 136
11.3 Algoritmo e implementación ... 137
11.3.1 DML con DoubleML para PLR ... 138
11.3.2 DML con econml para CATE bajo PLR/etapa final lineal ... 138
11.3.3 Comparación de learners ... 139
11.3.4 Verificación de leakage ... 140
11.4 Caso empírico y validación ... 141

11.5 Riesgos, límites y sensibilidad ... 142
11.6 Ejercicios y notas bibliográficas ... 143
11.6.1 Ejercicios teóricos ... 143
11.6.2 Ejercicios computacionales ... 144
12 Meta-learners para efectos de tratamiento heterogéneos ... 145
12.1 Problema causal, estimando e identificación ... 145
12.2 Teoría, supuestos y garantías ... 146
12.2.1 El S-learner ... 146
12.2.2 El T-learner ... 146
12.2.3 El X-learner ... 146
12.2.4 R-learner: Estimador y score ... 147
12.2.5 El DR-learner ... 147
12.2.6 Comparación de propiedades ... 148
12.3 Algoritmos e implementación ... 150
12.3.1 Pseudocódigo ... 150
12.3.2 Implementación en Python ... 151
12.3.3 Análisis de sesgo y varianza por subgrupo ... 152
12.4 Caso empírico y validación ... 152
12.5 Riesgos, límites y sensibilidad ... 153
12.6 Ejercicios y notas bibliográficas ... 154
12.6.1 Ejercicios teóricos ... 154
12.6.2 Ejercicios computacionales ... 154
13 Árboles y bosques causales ... 156
13.1 Motivación aplicada ... 156
13.2 Teoría, supuestos y garantías ... 157
13.2.1 Árboles causales honestos ... 157
13.2.2 El criterio de partición ... 158
13.3 Estimador y score ... 159
13.3.1 Del árbol al bosque: pesos de vecindad ... 159
13.3.2 Comparación con meta-learners ... 162
13.4 Validación y lectura de la heterogeneidad ... 162
13.4.1 Calibrar antes de interpretar ... 162
13.4.2 Importancia de variables y *policy trees* ... 163
13.5 Implementación en Python ... 164
13.5.1 Estimación con `CausalForestDML` ... 164
13.5.2 Comparación con un X-learner ... 165
13.5.3 Importancia de variables ... 166
13.5.4 Réplica sobre el programa NSW ... 166
13.6 Riesgos, límites y sensibilidad ... 167
13.6.1 Tabla de riesgos ... 167
13.6.2 Límites ... 167
13.7 Ejercicios propuestos ... 168

13.7.1 Ejercicios teóricos ... 168
13.7.2 Ejercicios computacionales ... 168
13.8 Lecturas complementarias ... 169
14 Validación, refutación y sensibilidad ... 170
14.1 Motivación aplicada ... 170
14.2 Teoría, supuestos y garantías ... 171
14.2.1 El problema fundamental ... 171
14.2.2 Curva Qini (versión acumulada) ... 171
14.2.3 Curva uplift y transformed outcome ... 172
14.2.4 Placebo tests ... 173
14.2.5 Sensibilidad a confusión no observada: protocolo de tres niveles ... 174
14.2.6 Validación con datos sintéticos ... 175
14.2.7 Tests formales de heterogeneidad: BLP, BEST y CLAN ... 175
14.2.8 Intervalos conformes para efectos individuales ... 176
14.3 Implementación en Python ... 176
14.3.1 Curva Qini sobre datos sintéticos ... 176
14.3.2 Placebo test ... 178
14.4 Caso empírico y validación ... 179
14.4.1 Suite de refutación ... 179
14.4.2 Curva Qini comparativa ... 180
14.5 Riesgos, límites y sensibilidad ... 182
14.5.1 Tabla de riesgos ... 182
14.5.2 Límites ... 183
14.6 Evaluación offline en el ciclo de vida del sistema ... 183
14.6.1 *Baselines* obligatorios ... 183
14.6.2 Selección formal de estimadores de CATE: RATE ... 184
14.6.3 Versionado del proceso de evaluación ... 184
14.7 Ejercicios y notas bibliográficas ... 185
14.7.1 Ejercicios propuestos ... 185
14.7.2 Lecturas complementarias ... 185
15 Despliegue de un estimador causal como servicio ... 186
15.1 El problema de diseño ... 186
15.2 Opciones y trade-offs ... 187
15.3 Decisión de referencia para el curso ... 187
15.4 El contrato del servicio ... 188
15.4.1 La prueba de aceptación necesita datos con verdad conocida ... 190
15.5 Aplicación al sistema causal del curso ... 190
15.6 Implementación de referencia ... 191
15.7 Señales de alerta y checklist operativo ... 193
15.8 Ejercicios y notas bibliográficas ... 194
15.8.1 Ejercicios conceptuales ... 194
15.8.2 Ejercicio de infraestructura (Lab, Notebook B1) ... 194

15.8.3 Notas bibliográficas ... 195
16 Post-Double-Selection LASSO ... 198
16.1 Motivación aplicada ... 198
16.2 Teoría, supuestos y garantías ... 199
16.2.1 Modelo de alta dimensión con efecto causal ... 199
16.2.2 Post-Double-Selection (PDS) ... 199
16.2.3 Pseudocódigo: Post-Double-Selection ... 200
16.2.4 La elección de λ no es un detalle de implementación ... 200
16.2.5 Por qué la doble selección funciona ... 201
16.2.6 Comparación con DML ... 202
16.2.7 Confusión densa ... 203
16.3 Sensibilidad y validación ... 204
16.3.1 Sensibilidad a la elección de λ ... 204
16.3.2 Una limitación del PDS estándar ... 205
16.4 Implementación en Python ... 205
16.4.1 Implementación de PDS ... 205
16.4.2 Comparación PDS frente a DML y a la selección manual ... 206
16.4.3 Réplica sobre NHEFS ... 207
16.4.4 Sensibilidad al hiperparámetro lambda ... 208
16.5 Riesgos, límites y sensibilidad ... 209
16.6 Ejercicios propuestos ... 210
16.6.1 Ejercicios teóricos ... 210
16.6.2 Ejercicios computacionales ... 211
16.7 Lecturas complementarias ... 211
17 Machine learning causal en datos de panel ... 212
17.1 Problema causal, estimando e identificación ... 213
17.2 Teoría, supuestos y garantías ... 213
17.2.1 Modelo de panel con efectos fijos ... 213
17.2.2 Supuestos ... 214
17.2.3 DML para panel ... 214
17.2.4 Garantías ... 215
17.2.5 Variables instrumentales: DML-PLIV ... 215
17.2.6 Adopción escalonada: el límite de la transformación within ... 216
17.3 Casos canónicos y validación ... 217
17.4 Implementación en Python ... 219
17.5 Riesgos, límites y sensibilidad ... 221
17.6 Ejercicios propuestos ... 221
17.6.1 Ejercicios teóricos ... 221
17.6.2 Ejercicios computacionales ... 222
17.7 Lecturas complementarias ... 222
18 Diseño de investigación y selección de método ... 223
18.1 Motivación aplicada ... 223

18.2 Problema causal, estimando e identificación ... 224
18.2.1 Dimensiones del problema causal ... 224
18.2.2 Estimando e identificación ... 224
18.3 Teoría, supuestos y garantías ... 225
18.3.1 Mapa de decisión metodológica ... 225
18.3.2 Identificación jerárquica de diseños ... 226
18.3.3 Un procedimiento de decisión en el orden correcto ... 226
18.3.4 Criterios adicionales de selección ... 226
18.4 Casos resueltos ... 228
18.4.1 Validación de la elección metodológica ... 228
18.5 Implementación en Python ... 229
18.6 Errores comunes y límites ... 230
18.7 Ejercicios propuestos ... 230
18.8 Lecturas complementarias ... 231
19 *Model cards* causales y registro local de artefactos ... 234
19.1 El problema de diseño ... 234
19.2 Opciones y trade-offs ... 235
19.3 Decisión de referencia para el curso ... 235
19.4 El contrato de la ficha ... 236
19.5 Implementación de referencia ... 237
19.6 Aplicación al sistema causal del curso ... 239
19.7 Señales de alerta y checklist operativo ... 240
19.8 Ejercicios y notas bibliográficas ... 240
19.8.1 Ejercicios conceptuales ... 240
19.8.2 Ejercicio de infraestructura ... 241
19.8.3 Notas bibliográficas ... 241
20 CI/CD para modelos causales ... 242
20.1 El problema de diseño ... 242
20.2 Opciones y trade-offs ... 243
20.3 Decisión de referencia para el curso ... 243
20.4 El contrato de la compuerta de registro ... 244
20.4.1 Qué mira cada prueba ... 245
20.4.2 Los umbrales se calibran con la tasa medida ... 246
20.5 Implementación de referencia ... 248
20.6 Aplicación al sistema causal del curso ... 251
20.7 Señales de alerta y checklist operativo ... 251
20.8 Ejercicios y notas bibliográficas ... 252
20.8.1 Ejercicios conceptuales ... 252
20.8.2 Ejercicio de infraestructura (cierra el Notebook B2) ... 252
20.8.3 Notas bibliográficas ... 252
21 Aprendizaje de políticas óptimas ... 255
21.1 Motivación aplicada ... 255

21.2 Teoría, supuestos y garantías ... 256
21.2.1 Valor de una política y *welfare regret* ... 256
21.2.2 Estimación del valor de la política ... 256
21.2.3 Garantías de aprendizaje ... 257
21.2.4 Evaluación de políticas con datos históricos ... 258
21.2.5 Restricciones presupuestarias ... 259
21.3 Algoritmo: árbol de política con presupuesto ... 260
21.4 Implementación en Python ... 262
21.4.1 Policy learning con econml ... 262
21.4.2 Restricción presupuestaria ... 264
21.5 Riesgos, límites y sensibilidad ... 265
21.6 Ejercicios propuestos ... 265
21.6.1 Ejercicios teóricos ... 265
21.6.2 Ejercicios computacionales ... 266
21.7 Lecturas complementarias ... 266
22 Uplift modeling y targeting económico ... 267
22.1 Motivación aplicada ... 267
22.2 Marco teórico formal ... 268
22.2.1 Uplift y CATE ... 268
22.2.2 Qini y AUUC: teoría, supuestos y garantías ... 268
22.2.3 Multi-treatment uplift ... 270
22.3 Algoritmo: asignación por net score con presupuesto ... 271
22.4 Aplicación con Python ... 274
22.4.1 Uplift modeling con causalml ... 274
22.4.2 Costo-efectividad: tres estrategias ... 276
22.5 Riesgos, límites y mitigación ... 277
22.6 Ejercicios propuestos ... 278
22.6.1 Ejercicios teóricos ... 278
22.6.2 Ejercicios computacionales ... 279
22.7 Lecturas complementarias ... 279
23 Explicación causal y equidad algorítmica ... 282
23.1 Problema causal, estimando e identificación ... 282
23.2 Teoría, supuestos y garantías ... 283
23.2.1 Efectos directos, indirectos y espurios ... 283
23.2.2 Equidad contrafactual ... 284
23.3 Procedimiento: auditoría causal de equidad ... 284
23.4 Casos canónicos y validación ... 285
23.5 Implementación en Python ... 286
23.6 Riesgos, límites y sensibilidad ... 287
23.7 Ejercicios y notas bibliográficas ... 287
23.7.1 Ejercicios teóricos ... 287
23.7.2 Ejercicio computacional ... 288

23.7.3 Notas bibliográficas ... 288
24 Ética, interpretabilidad y comunicación de resultados ... 289
24.1 Motivación aplicada ... 290
24.2 Teoría, supuestos y garantías ... 290
24.2.1 Equidad causal ... 290
24.2.2 Del criterio observacional al criterio causal ... 291
24.2.3 Interpretabilidad ... 292
24.2.4 Comunicación de incertidumbre ... 293
24.3 Algoritmos e implementación ... 294
24.3.1 Atribución sobre un sustituto del efecto ... 294
24.3.2 Brecha entre grupos con incertidumbre ... 294
24.3.3 Interpretabilidad con SHAP ... 295
24.3.4 Tabla de resultados para policymakers ... 296
24.3.5 Análisis de equidad ... 297
24.4 Caso empírico y validación ... 298
24.4.1 Auditoría de equidad en focalización de transferencias ... 298
24.5 Riesgos, límites y sensibilidad ... 299
24.5.1 Tabla de riesgos ... 299
24.5.2 Cuándo no usar este método ... 301
24.6 Ejercicios propuestos ... 301
24.6.1 Ejercicios teóricos ... 301
24.6.2 Ejercicios computacionales ... 302
24.7 Lecturas complementarias ... 302
25 Decisiones estructurales bajo incertidumbre ... 303
25.1 Problema causal, estimando e identificación ... 303
25.2 Teoría, supuestos y garantías ... 304
25.2.1 La decisión como maximización de utilidad esperada ... 304
25.2.2 Criterios de decisión cuando el efecto no está identificado con precisión . 305
25.2.3 El valor de la información ... 306
25.2.4 Identificación y soporte de cada acción ... 306
25.3 Procedimiento: decidir entre acciones con incertidumbre ... 307
25.4 Casos canónicos y validación ... 307
25.5 Implementación en Python ... 309
25.6 Riesgos, límites y sensibilidad ... 311
25.7 Ejercicios y notas bibliográficas ... 311
25.7.1 Ejercicios teóricos ... 311
25.7.2 Ejercicios computacionales ... 312
25.7.3 Notas bibliográficas ... 312
26 Generalización y transportabilidad entre dominios ... 313
26.1 Problema causal, estimando e identificación ... 313
26.2 Teoría, supuestos y garantías ... 314
26.2.1 Diagramas de selección ... 314

26.2.2 Qué puede decirse del efecto en el destino . . . 314
26.2.3 Por qué esto no es lo mismo que reestimar con más datos . . . 316
26.3 Procedimiento: evaluar la transportabilidad de un efecto . . . 316
26.4 Casos canónicos y validación . . . 316
26.5 Implementación en Python . . . 318
26.6 Riesgos, límites y sensibilidad . . . 319
26.7 Ejercicios y notas bibliográficas . . . 320
26.7.1 Ejercicios teóricos . . . 320
26.7.2 Ejercicio computacional . . . 320
26.7.3 Notas bibliográficas . . . 320
27 Deep learning para inferencia causal . . . 323
27.1 Motivación aplicada . . . 323
27.2 Teoría, supuestos y garantías . . . 324
27.2.1 TARNet: representación compartida . . . 324
27.2.2 CFRNet: balance con una métrica integral de probabilidad . . . 324
27.2.3 DeepIV . . . 325
27.3 Algoritmos de entrenamiento . . . 325
27.4 Implementación en Python . . . 326
27.4.1 CFRNet con penalización MMD . . . 327
27.5 Arquitectura de TARNet/CFRNet . . . 328
27.6 Caso empírico y validación . . . 329
27.7 Límites y errores comunes . . . 330
27.7.1 ¿Balancear la representación ayuda realmente? . . . 331
27.7.2 Redes como estimadores de *nuisance* e inferencia válida . . . 332
27.8 Ejercicios propuestos . . . 333
27.8.1 Ejercicios teóricos . . . 333
27.8.2 Ejercicios computacionales . . . 333
27.9 Lecturas complementarias . . . 333
28 Control sintético y matrix completion . . . 335
28.1 Problema causal, estimando e identificación . . . 336
28.2 Teoría, supuestos y garantías . . . 336
28.2.1 Control sintético . . . 336
28.2.2 Matrix completion . . . 337
28.2.3 Elegir λ o r: el hiperparámetro que fija el contrafactual . . . 337
28.2.4 Comparación entre ambos métodos . . . 338
28.2.5 Inferencia con una sola unidad tratada . . . 338
28.3 Procedimientos . . . 340
28.4 Casos canónicos y validación . . . 340
28.5 Implementación en Python . . . 342
28.6 Riesgos, límites y mitigación . . . 344
28.7 Ejercicios y notas bibliográficas . . . 344
28.7.1 Ejercicios teóricos . . . 344

28.7.2 Ejercicios computacionales ... 345
28.7.3 Notas bibliográficas ... 345
29 Descubrimiento causal y grafos ... 348
29.1 Motivación aplicada ... 348
29.2 Marco teórico formal ... 349
29.2.1 DAGs y el criterio de puerta trasera ... 349
29.2.2 Algoritmo PC ... 349
29.2.3 Pseudocódigo: PC skeleton ... 350
29.2.4 NOTEARS ... 351
29.2.5 Límites: causal sufficiency ... 352
29.3 Implementación en Python ... 352
29.3.1 Construcción de DAGs con dowhy ... 352
29.3.2 PC con causal-learn y NOTEARS con la implementación de referencia . 353
29.4 Caso empírico y validación ... 354
29.4.1 Evaluación de grafos estimados ... 354
29.4.2 Caso de estudio: DAGs y descubrimiento causal ... 355
29.5 Riesgos, límites y sensibilidad ... 357
29.5.1 Tabla de riesgos ... 357
29.5.2 Límites del descubrimiento causal ... 358
29.6 Ejercicios propuestos ... 359
29.6.1 Ejercicios teóricos ... 359
29.6.2 Ejercicios computacionales ... 359
29.7 Lecturas complementarias ... 359
30 Monitoreo de supuestos causales en producción ... 361
30.1 El problema de diseño ... 361
30.2 Opciones y trade-offs ... 362
30.3 Decisión de referencia para el curso ... 362
30.4 El contrato del monitoreo causal ... 364
30.5 Implementación de referencia ... 367
30.6 Aplicación al sistema causal del curso ... 370
30.7 De la señal a la acción ... 370
30.8 Señales de alerta y checklist operativo ... 371
30.9 Ejercicios y notas bibliográficas ... 372
30.9.1 Ejercicios conceptuales ... 372
30.9.2 Ejercicio de infraestructura (Lab, arranca Notebook B4) ... 372
30.9.3 Notas bibliográficas ... 372
31 Aprendizaje continuo y panorama de *Reinforcement Learning* causal ... 374
31.1 Aprendizaje continuo para sistemas causales ... 374
31.1.1 El problema de diseño ... 374
31.1.2 Opciones y trade-offs ... 375
31.1.3 Decisión de referencia para el curso ... 375
31.2 Implementación de referencia ... 378

31.2.1 Señales de alerta . . . 379
31.3 Panorama de *Reinforcement Learning* causal . . . 380
31.3.1 De decisiones únicas a decisiones secuenciales . . . 380
31.3.2 Bandits causales: el caso introductorio más simple . . . 380
31.3.3 Por qué el libro se detiene aquí . . . 381
31.4 Ejercicios y notas bibliográficas . . . 381
31.4.1 Ejercicios conceptuales . . . 381
31.4.2 Ejercicio de infraestructura . . . 382
31.4.3 Notas bibliográficas . . . 382
32 El lado humano de los sistemas causales . . . 383
32.1 El problema de diseño . . . 383
32.2 Opciones y trade-offs . . . 384
32.3 Decisión de referencia para el curso . . . 385
32.4 La plantilla de comunicación . . . 385
32.5 Aplicación al sistema causal del curso: cierre . . . 386
32.6 Señales de alerta y checklist operativo . . . 386
32.7 Ejercicios y notas bibliográficas . . . 387
32.7.1 Ejercicios conceptuales . . . 387
32.7.2 Ejercicio de cierre (proyecto final) . . . 387
32.7.3 Notas bibliográficas . . . 387
33 Supuestos no observables en operación . . . 388
33.1 El problema de diseño . . . 388
33.2 Opciones y trade-offs . . . 389
33.3 Decisión de referencia para el curso . . . 390
33.4 El contrato de la sensibilidad . . . 393
33.5 Implementación de referencia . . . 394
33.6 Aplicación al sistema causal del curso . . . 397
33.7 Señales de alerta y checklist operativo . . . 397
33.8 Ejercicios y notas bibliográficas . . . 398
33.8.1 Ejercicios conceptuales . . . 398
33.8.2 Ejercicios computacionales . . . 398
33.8.3 Notas bibliográficas . . . 398
A Notación, convenciones y fundamentos matemáticos . . . 400
A.1 Notación general . . . 400
A.2 Modos de convergencia . . . 401
A.3 Teoremas límite fundamentales . . . 401
A.4 Teoría asintótica semiparamétrica . . . 402
A.4.1 Espacios tangentes . . . 402
A.4.2 Estimación semiparamétrica eficiente . . . 402
A.5 Ortogonalidad de Neyman . . . 402
A.6 Cross-fitting y sample splitting . . . 403
A.7 Honesty en árboles causales . . . 403

A.8 Norma nuclear y matrix completion . . . 403
A.9 Modelos causales estructurales . . . 403
A.10 Influence functions . . . 403
A.11 Regresión Discontinua (RDD) . . . 404
A.12 Transportabilidad . . . 404
B Guía de librerías y entorno reproducible . . . 405
B.1 Entorno reproducible . . . 405
B.2 econml (Microsoft Research) . . . 405
B.3 DoubleML . . . 406
B.4 causalml (Uber) . . . 406
B.5 dowhy (PyWhy) . . . 407
B.6 PyTorch . . . 407
B.7 scikit-learn . . . 407
B.8 networkx . . . 408
B.9 statsmodels . . . 408
B.10 Tabla comparativa . . . 408
B.11 Instalación recomendada . . . 408
B.11.1 Librerías complementarias . . . 409
C Datos, DGP y benchmarks . . . 410
C.1 Conjuntos reales . . . 410
C.2 Procesos generadores sintéticos . . . 411
C.3 Recomendaciones de uso por capítulo . . . 413
C.4 Datos complementarios sugeridos . . . 413
C.5 Verdad conocida e integridad . . . 414
C.6 Estructura de archivos . . . 414
D Glosario de estimandos, supuestos y métodos . . . 415
D.1 Estimandos . . . 415
D.2 Supuestos . . . 416
D.3 Métodos . . . 417
D.4 Garantías . . . 419
D.5 Diagnósticos . . . 419
E Plantilla de proyecto final y rúbrica . . . 421
E.1 Estructura del informe . . . 421
E.2 Capa causal de la pregunta . . . 422
E.3 DAG o supuesto estructural . . . 422
E.4 Identificación . . . 422
E.5 Estimación . . . 422
E.6 Validación y refutación . . . 422
E.7 Análisis de sensibilidad . . . 423
E.8 Transportabilidad . . . 423
E.9 Ética y comunicación . . . 423
E.10 Criterios de evaluación . . . 423

E.11 Entregables ... 424
E.12 Ejemplos de problemas aplicados ... 424
E.13 Plazos sugeridos ... 424
F Checklists por método ... 425
F.1 Checklist DML ... 425
F.2 Checklist meta-learners ... 425
F.3 Checklist causal forest ... 425
F.4 Checklist PDS ... 426
F.5 Checklist panel/DMLIV ... 426
F.6 Checklist policy learning ... 426
F.7 Checklist uplift ... 426
F.8 Checklist SCM/matrix completion ... 427
F.9 Checklist causal discovery ... 427
G Plantilla de *model card* causal ... 428
G.1 Campos obligatorios y su propósito ... 428
G.2 Plantilla completa ... 429
G.3 Checklist antes de registrar ... 430
G.4 Esquema legible por máquinas ... 430
H Checklist de arquitectura de despliegue ... 435
H.1 Elegir el patrón de *serving* ... 435
H.2 Checklist de la función de inferencia ... 435
H.3 Checklist de CI/CD ... 436
H.4 Checklist de monitoreo en producción ... 436
H.5 Checklist de comunicación ... 436
I Contratos numerados del libro ... 437
I.1 Cómo se lee un contrato ... 437
I.2 Los ocho contratos de un vistazo ... 438
I.3 Una prueba de aceptación por contrato ... 438
I.4 Declaración de conformidad ... 440
I.5 Cuándo cambia un contrato ... 440
I.6 Un orden razonable para adoptarlos ... 440
I.7 Checklist de conformidad ... 441
J Guía para instructores y equipos de curso ... 442
J.1 Mapa sesión → capítulo → lab → entrega (resumen) ... 442
J.2 Nivel de madurez del material (NMM) ... 443
J.3 Práctica del curso: laboratorios, series de notebooks y proyecto ... 443
J.4 Nota sobre las dos ediciones ... 444
Bibliografía ... 445

Índice de figuras

Figura 11.1 Sensibilidad de la estimación DML-PLIV del retorno a la educación al número de folds K del cross-fitting. Las barras indican IC al 95%. La línea punteada es la estimación OLS con controles (HC1). Dataset: `close_college` (Card, 1995), $n = 3\,003$. La sensibilidad a K bajo se mitiga con *repeated cross-fitting* (Nota técnica 10.2.4). 141

Figura 14.1 Curva Qini en una muestra de evaluación de 1 200 unidades: ranking por CATE estimado (T-learner), regla de riesgo sin causalidad, orden perfecto y azar. Datos sintéticos con $\tau(x) = 2 + 3x_1 - x_2^2$ y $n = 3\,000$; semillas 42 (datos), 0 (partición) y 42 (*boosting*). 180

Figura 16.1 Sensibilidad de la estimación PDS al hiperparámetro λ de LASSO. Las barras indican IC al 95% (HC1). La línea verde punteada marca el λ óptimo por validación cruzada. Dataset: `nhefs`, $n = 1\,566$, $p = 51$ controles. Sin generador reproducible en esta edición. 207

Figura 21.1 Valor de la política frente al presupuesto en el caso canónico. Verde discontinua: orden perfecto con piso en cero. Azul: orden por CATE estimado (T-learner), con banda de una desviación típica entre 20 repeticiones. Gris punteada: tratamiento al azar de la misma fracción. Roja punteada: tratar a todos. La línea vertical marca el presupuesto del 30 %. El script que genera la figura está en el material de verificación. 259

Figura 22.1 Izquierda: uplift verdadero acumulado al tratar primero a los clientes de mayor uplift estimado (línea continua) frente a tratar al azar (línea punteada), para SMS y llamada. Derecha: uplift verdadero total de las estrategias A, B y C según el presupuesto; la línea vertical marca el presupuesto del caso canónico (4 000). Datos sintéticos con semilla fija ($n = 5\,000$, *hold-out* de 2 000 clientes, T-learner con *gradient boosting*). El script que genera la figura está en el material de verificación. 273

Figura 27.1 Arquitectura de TARNet / CFRNet (Shalit, Johansson & Sontag, 2017). La capa de representación compartida Φ es seguida por dos cabezas separadas h_0, h_1 para $D = 0$ y $D = 1$. CFRNet añade una penalización IPM (Wasserstein o MMD) que fuerza el balance entre las distribuciones de $\Phi(X)$ condicionales al tratamiento. 329

Figura 28.1 (a) y (b): trayectoria de la unidad tratada, control sintético y matrix completion en una realización, con la unidad tratada dentro y fuera de la envolvente convexa de los donantes; la línea vertical marca el inicio del tratamiento. (c):

raíz del error cuadrático medio del efecto estimado por matrix completion frente a λ, en 200 repeticiones. Efecto verdadero 2,5. 341
Figura 29.1 Izquierda: DAG supuesto para el retorno a la educación (Card, 1995); U denota un confusor no observado. Derecha: DAG ponderado estimado por NOTEARS sobre datos sintéticos con estructura conocida ($X_0 \to X_1$, $X_1 \to X_2$, $X_3 \to X_2$, y X_4 aislada); las etiquetas en las aristas son los pesos estimados. 355

Índice de tablas

Símbolos y convenciones de notación. viii
Tabla 5.1 Régimen predictivo y régimen causal. 70
Tabla 5.2 Riesgos al confundir predicción con causalidad. 78
Tabla 6.1 Riesgos de la selección de variables en problemas causales. 91
Tabla 10.1 Instancias del score ortogonal canónico a lo largo del libro. 125
Tabla 10.2 Errores comunes en la implementación de DML para el PLR. 131
Tabla 11.1 Learners comunes para nuisance en DML. 136
Tabla 11.2 Riesgos comunes en DML 142
Tabla 12.1 Comparación de meta-learners. 148
Tabla 12.2 CATE estimado por subgrupo en NSW (CausalForestDML). Réplica propia, sin intervalos por subgrupo. 153
Tabla 12.3 Riesgos comunes en meta-learners 153
Tabla 13.1 Bosque causal frente a meta-learners. 162
Tabla 13.2 Riesgos al usar árboles y bosques causales. 167
Tabla 14.1 Suite de refutación para modelos causales. 179
Tabla 14.2 Riesgos en la validación de modelos causales sin ground truth. 182
Tabla 16.1 PDS frente a DML. 202
Tabla 16.2 Riesgos al aplicar PDS LASSO. 209
Tabla 17.1 Riesgos comunes en DML con panel e instrumentos. 221
Tabla 18.1 Mapa de decisión metodológica. 225
Tabla 18.2 Identificación jerárquica de diseños causales (credibilidad típica del supuesto clave). 226
Tabla 18.3 Riesgos comunes en la elección metodológica. 230
Tabla 21.1 Riesgos comunes en policy learning. 265
Tabla 22.1 Riesgos comunes en uplift modeling y targeting. 278
Tabla 23.1 Riesgos en el análisis causal de equidad. 287
Tabla 24.1 Riesgos en ética, interpretabilidad y comunicación de ML causal 300
Tabla 25.1 Riesgos en la decisión entre acciones bajo incertidumbre. 311
Tabla 26.1 Riesgos al transportar un efecto entre dominios. 319
Tabla 27.1 Riesgos comunes en deep causal learning 330
Tabla 28.1 Control sintético y matrix completion. 338
Tabla 28.2 Riesgos en control sintético y matrix completion. 344
Tabla 29.1 Riesgos en descubrimiento causal y grafos 357
Tabla 30.1 Orden de las preguntas de monitoreo y la acción que dispara cada una. 370

Tabla 33.1 Clase de cada supuesto y lo que el sistema hace con él. 389
Tabla A.1 Símbolos y convenciones notacionales. 400
Tabla B.1 Comparación de librerías y versiones vigentes (PyPI, 5 de octubre de 2026). . 408
Tabla B.2 Librerías complementarias. 409
Tabla C.1 Conjuntos de datos reales de referencia y capítulos donde se usan. 410
Tabla C.2 Procesos generadores sintéticos con efecto verdadero conocido. 412
Tabla C.3 Datos complementarios sugeridos. 413
Tabla E.1 Rúbrica de evaluación del proyecto final. 423

Índice de algoritmos

Algoritmo 1. Simulación con verdad conocida 73
Algoritmo 2. Post-LASSO OLS (selección ingenua) 86
Algoritmo 3. Verificación del criterio de puerta trasera 108
Algoritmo 4. Double Machine Learning con cross-fitting (K pliegues) 128
Algoritmo 5. DML manual con cross-fitting para PLR 128
Algoritmo 6. DML con cross-fitting 137
Algoritmo 7. X-learner 150
Algoritmo 8. DR-learner con cross-fitting 150
Algoritmo 9. Causal tree honesto 158
Algoritmo 10. Causal forest (GRF), esquema 161
Algoritmo 11. Post-Double-Selection (PDS) 200
Algoritmo 12. DML-panel con transformación within 214
Algoritmo 13. Selección de diseño y método 226
Algoritmo 14. Árbol de política con restricción presupuestaria 261
Algoritmo 15. Asignación por net score con presupuesto 271
Algoritmo 16. Auditoría causal de equidad 284
Algoritmo 17. Atribución de importancia sobre un sustituto del CATE 294
Algoritmo 18. Brecha de efecto entre dos grupos con incertidumbre 294
Algoritmo 19. Decisión entre acciones con incertidumbre 307
Algoritmo 20. Evaluación de la transportabilidad 316
Algoritmo 21. Entrenamiento TARNet/CFRNet 326
Algoritmo 22. DeepIV en dos etapas 326
Algoritmo 23. Control sintético clásico 340
Algoritmo 24. Matrix completion con λ por validación cruzada de bloque 340
Algoritmo 25. PC skeleton: esqueleto del grafo causal 350

Índice de listados

Listado 3.1 SCM simulado: divergencia entre asociación e intervención. 54
Listado 3.2 Contraste de independencia condicional con correlación parcial, aplicado a una cadena con y sin confusión no observada. 56
Listado 4.1 Esquema de roles causales como estructura de datos explícita (contrato C-01). 64
Listado 4.2 Uso del esquema sobre datos sintéticos: validar, escribir y volver a leer. 66
Listado 5.1 Caso 1: contraste predictivo, OLS y residualización con *cross-fitting* sobre un proceso con efecto conocido. 76
Listado 5.2 Caso 3: asociación creada al condicionar en un *collider* y sesgo al controlar por él. 78
Listado 6.1 Sesgo post-selección: Post-LASSO ingenuo, doble selección y oráculo con efecto conocido. 88
Listado 6.2 Partialling-out manual con LASSO. 90
Listado 7.1 Chequeo de balance: SMD, razón de varianzas y p-valores con corrección de Holm. 98
Listado 8.1 Verificación del criterio de puerta trasera con `networkx`. 108
Listado 9.1 Auditoría de *features* por marca de tiempo y por rol declarado. 116
Listado 10.1 Implementación manual de DML para PLR con cross-fitting. 129
Listado 10.2 DML aplicado a los datos del NSW (Lalonde). 130
Listado 11.1 DML con librería DoubleML sobre NSW. 138
Listado 12.1 Comparación de meta-learners sobre dataset sintético. 151
Listado 12.2 Sesgo del S-learner bajo regularización fuerte. 152
Listado 13.1 Causal Forest sobre NSW con mapas de heterogeneidad. 164
Listado 13.2 Causal Forest vs. X-learner en datos sintéticos. 165
Listado 13.3 Importancia de variables en causal forest. 166
Listado 14.1 Curva Qini en una muestra de evaluación, con tres rankings y el azar como referencia. 176
Listado 14.2 Placebo temporal sobre un panel sintético, con y sin confusor no observado. 178
Listado 15.1 Función de inferencia pura, desacoplada del framework web. Implementa *estimar* del contrato C-04. 191
Listado 15.2 Servicio FastAPI que envuelve la función de inferencia. Una abstención responde con código 200: es una respuesta válida, no un error. 192

Listado 15.3 Metadatos del modelo, servidos desde el mismo archivo que alimenta la inferencia. Implementa *metadatos* del contrato C-04. 193
Listado 15.4 `Dockerfile` opcional para empaquetar el servicio. 193
Listado 16.1 Post-Double-Selection LASSO sobre NHEFS. 205
Listado 16.2 Comparación PDS vs. DML vs. selección manual. 206
Listado 16.3 Sensibilidad al hiperparametro lambda. 208
Listado 17.1 DML-panel manual: transformación *within*, atributos de trayectoria y *cross-fitting* por unidad. 219
Listado 17.2 DML-PLIV manual con *cross-fitting* y diagnóstico del F de primera etapa. .220
Listado 18.1 Función de decisión metodológica (heurística de primer descarte). 229
Listado 19.1 Plantilla mínima de *model card* causal en Markdown (valores ilustrativos). . 237
Listado 19.2 Construcción de `model_card.json` (esquema `causal-model-card-v2`, Ap. G.4). El soporte, la huella y el veredicto de los supuestos observables salen de los datos. 238
Listado 19.3 Registro local del modelo y su *model card*. 239
Listado 20.1 CI local con pruebas de software y estadísticas en etapas separadas. 248
Listado 20.2 Validación de `model_card.json` en el CI local (Ap. G.4): esquema, supuestos observables y huella de los datos. 248
Listado 20.3 Prueba estadística de humo: reestimar con el tratamiento permutado no debe dar un efecto significativo. 249
Listado 20.4 Prueba de estabilidad: el efecto reestimado no se aleja del registrado más de la tolerancia, en errores estándar. 250
Listado 21.1 Policy learning con evaluación hold-out sobre un DGP sintético (covariables reales de `gov_transfers`, tratamiento y resultado simulados). 262
Listado 21.2 Policy learning con restricción presupuestaria. 264
Listado 22.1 Uplift modeling multi-tratamiento con `causalml`: un estimador por acción. . 274
Listado 22.2 Análisis costo-efectividad: tres estrategias sobre el *hold-out* y las columnas de uplift estimadas en el listado 22.1. 276
Listado 23.1 Descomposición de efectos con un modelo estructural lineal simulado. 286
Listado 24.1 SHAP para Causal Forest. 295
Listado 24.2 Tabla de resultados para comunicación a tomadores de decisión. 296
Listado 24.3 Análisis de equidad en policy learning. 297
Listado 25.1 Criterios de decisión y valor de la información para tres políticas candidatas. 309
Listado 26.1 Efecto transportado por reponderación de estratos, con cobertura del destino. 318
Listado 27.1 Implementación de TARNet en PyTorch. 326
Listado 27.2 CFRNet con penalización MMD. 327
Listado 28.1 Control sintético y matrix completion sobre un panel de factores simulado. 342
Listado 28.2 Elección de λ por validación cruzada de bloque. 343
Listado 29.1 Identificación con DAGs en dowhy. 352

Listado 29.2 PC con causal-learn y NOTEARS con la implementación de referencia. . . . 353
Listado 30.1 Las cuatro métricas de monitoreo causal sobre una ventana reciente de datos. . . . 367
Listado 31.1 Regla de promoción: compara la población del *champion* con los datos nuevos y devuelve una de las cinco acciones. . . . 378
Listado 32.1 Plantilla de tres capas para comunicar un resultado causal. . . . 386
Listado 33.1 Sensibilidad de un supuesto no observable: valor crítico de la decisión, escala de referencia, control negativo y motivos de revisión. . . . 394
Listado B.1 Ejemplo canónico de uso de `econml` (`LinearDML`). . . . 406
Listado B.2 Red de representación para TARNet/CFRNet en PyTorch. . . . 407
Listado B.3 Instalación del stack base de librerías de ML causal. . . . 408
Listado B.4 Instalación de librerías complementarias. . . . 409
Listado C.1 Verificación de integridad de un conjunto con sumas SHA-256. . . . 414
Listado G.1 Plantilla completa de *model card* causal, para copiar y guardar junto al artefacto local. . . . 429
Listado G.2 Esquema JSON versionado de la *model card* causal (`causal-model-card-v2`). . . . 431
Listado G.3 Ejemplo de ficha JSON válida contra el esquema anterior (valores ilustrativos). . . . 433

PARTE 0

Introducción

Esta parte abre el libro con dos capítulos sin prerrequisitos: la distinción elemental entre correlación y causalidad, y la anatomía de un sistema de machine learning en producción. Juntos establecen los dos hilos, el causal y el de ingeniería de sistemas, que el resto del libro desarrolla en paralelo.

CAPÍTULO 1

Causalidad elemental y el problema fundamental de la inferencia causal

Cuadro sinóptico del capítulo

Problema:	Distinguir una pregunta asociativa de una pregunta causal
Idea central:	El problema fundamental de la inferencia causal (Holland, 1986)
Herramienta:	Resultados potenciales $Y(1), Y(0)$; un adelanto de la escalera de Pearl
Ejemplos:	Correlaciones espurias, paradoja de Simpson
Aplicación:	Por qué un modelo que predice bien puede decidir mal cuando opera dentro de un sistema
Sin laboratorio:	Sesión conceptual; el primer notebook llega en el Módulo 1
Prepara:	Capítulo 3 (SCM y PCH) y Capítulo 5 (ML no es causal por defecto)

1.1 Dos preguntas que parecen la misma

Suponga dos preguntas sobre un programa de becas universitarias. La primera: *¿los estudiantes becados tienen, en promedio, mejores calificaciones que los no becados?* La segunda: *¿dar una beca a un estudiante mejora sus calificaciones?* Ambas preguntas se responden, en apariencia, con el mismo tipo de dato, una tabla de estudiantes, si recibieron beca, y sus calificaciones, y sin embargo son preguntas radicalmente distintas. La primera es una pregunta **asociativa**: describe un patrón en los datos tal como existen. La segunda es una pregunta **causal**: describe qué pasaría si *interviniéramos* sobre el mundo, otorgando una beca que de otro modo no se habría otorgado.

La confusión entre ambas preguntas no es un error ingenuo. Es, de hecho, el error más común y más costoso en la aplicación de *machine learning* a la toma de decisiones. Un modelo predictivo entrenado sobre $(\text{beca}, \text{calificación})$ puede alcanzar una precisión excelente respon-

diendo la primera pregunta y, sin embargo, ofrecer una respuesta completamente equivocada si se lo usa para decidir a quién becar, porque los estudiantes que hoy reciben becas no son una muestra aleatoria de la población: probablemente ya tenían mejores calificaciones, mejor preparación, o mayor motivación **antes** de recibir la beca. La asociación observada mezcla el efecto de la beca con estas diferencias preexistentes.

El costo de esa confusión cambia de naturaleza cuando el modelo deja de describir y pasa a decidir. Suponga que el programa usa el modelo para repartir los cupos de beca entre quienes tienen mayor calificación esperada. El sistema parecerá funcionar: el error de predicción es bajo, la métrica no se mueve, el tablero está en verde. Pero estará entregando las becas a quienes habrían obtenido buenas notas de todos modos, y el efecto que el programa buscaba producir se perderá sin que ninguna métrica predictiva lo registre. Un modelo que predice bien y decide mal es el fallo más difícil de ver en producción, justamente porque las señales que se vigilan habitualmente son las que él cumple. De ahí la pregunta que organiza este libro, y que un ajuste excelente no responde: *¿cuánto mejor es el resultado para las personas afectadas con este sistema operando que sin él?*

Este curso completo puede resumirse en una sola tesis, que retomaremos una y otra vez bajo distintas formas técnicas: **ningún volumen de datos, por sí solo, convierte una pregunta asociativa en una pregunta causal**. Convertir una en otra requiere supuestos explícitos sobre cómo se generaron los datos, supuestos que provienen del conocimiento del dominio, no del algoritmo. El aporte del *machine learning* moderno, que ocupará el resto del curso, es permitir que esos supuestos se combinen con métodos flexibles y de alta dimensión sin perder validez estadística. Pero el primer paso, el de este capítulo, es aprender a **reconocer** cuándo una pregunta es causal, y por qué los datos nunca la responden solos.

1.2 Correlación no es causalidad: tres escenas clásicas

La distinción anterior suele aceptarse en principio y olvidarse en la práctica. Tres ejemplos clásicos ayudan a que la intuición se vuelva difícil de desactivar.

Escena 1: cigüeñas y nacimientos. En varios países europeos, los conteos anuales de parejas de cigüeñas y de nacimientos humanos están positivamente correlacionados a nivel regional. Nadie propone que las cigüeñas traen bebés; ambas variables responden a una tercera, el tamaño y la ruralidad de la región, que las mueve en la misma dirección sin que exista ningún vínculo causal directo entre ellas.

Escena 2: el tamaño del pie y la capacidad de lectura. En una muestra de niños entre 2 y 12 años, el tamaño del pie predice con notable precisión el puntaje en una prueba de lectura. Un modelo de *machine learning* entrenado sobre estos datos «aprendería» esta relación con alta confianza. La variable omitida es, por supuesto, la edad: los niños mayores tienen pies más grandes y leen mejor, sin que agrandar artificialmente el pie de un niño mejore su lectura. En el lenguaje que formalizaremos en el próximo capítulo, la edad es un *confusor* (*confounder*): afecta tanto a la variable explicativa como al resultado, y genera una asociación que no representa ningún mecanismo causal entre ellas.

Ejemplo 1.1 ***(El problema fundamental)***

La paradoja de Simpson. Un hospital evalúa dos tratamientos, A y B, para una misma condición. Tomando todos los pacientes en conjunto, el tratamiento A tiene una tasa de éxito mayor que B. Sin embargo, al separar a los pacientes por gravedad del caso (leve/grave), el tratamiento B resulta superior tanto en el grupo leve como en el grupo grave. La reversión ocurre porque el tratamiento A se administró desproporcionadamente a los casos leves, que se recuperan más fácilmente por sí solos, mientras que B se reservó para los casos graves. La gravedad es, otra vez, un confusor: determina tanto qué tratamiento recibe el paciente como su probabilidad de recuperación. La paradoja de Simpson (1951 el fenómeno ya había sido descrito por Yule (1903)) es la demostración más nítida de que una asociación puede invertir su signo por completo según qué variables se incluyan en el análisis. Tampoco existe una respuesta puramente estadística sobre cuál desagregación es la «correcta»: se requiere una teoría causal (¿la gravedad afecta a la asignación del tratamiento?) para saberlo.

Estas tres escenas comparten una estructura: una variable no observada, o no correctamente condicionada, genera una asociación que desaparece o se revierte en cuanto se controla por ella. La pregunta que este curso enseña a hacer sistemáticamente es: *¿qué tendría que ser cierto sobre cómo se generaron estos datos para que la asociación observada refleje el efecto causal que me interesa?*

1.3 El problema fundamental de la inferencia causal

Formalicemos la intuición anterior con la herramienta que usaremos durante todo el curso: el marco de **resultados potenciales** (Neyman, 1923 Rubin, 1974). Para cada unidad i (una persona, un hogar, una empresa) y un tratamiento binario $D_i \in \{0, 1\}$, definimos dos resultados **potenciales**: $Y_i(1)$, el resultado que se observaría si la unidad recibiera el tratamiento, y $Y_i(0)$, el resultado que se observaría si no lo recibiera. El efecto causal individual del tratamiento sobre la unidad i es, por definición, la diferencia $Y_i(1) - Y_i(0)$.

Definición 1.2

El problema fundamental de la inferencia causal (Holland 1986): para cualquier unidad i, solo se observa uno de los dos resultados potenciales, el correspondiente al tratamiento efectivamente recibido, y nunca ambos. Si i recibió el tratamiento, observamos $Y_i(1)$ pero $Y_i(0)$ permanece contrafactual, es decir, no observado y no observable. Si no lo recibió, ocurre lo simétrico.

Esta afirmación, aunque elemental, tiene una consecuencia que estructura todo el campo: el efecto causal individual $Y_i(1) - Y_i(0)$ **nunca** puede calcularse directamente para ninguna unidad, sin importar cuántos datos se recolecten sobre ella. Lo que sí puede estimarse, bajo supuestos adecuados, es un efecto **poblacional** o **promedio** (por ejemplo, el efecto promedio del tratamiento, ATE, $\theta = E[Y(1) - Y(0)]$) comparando grupos de unidades distintas que recibieron y no recibieron el tratamiento.

Conviene ver, ya en este capítulo introductorio, exactamente **dónde** entra el supuesto que hace legítima esa comparación, porque es la misma estructura lógica que reaparecerá, con

aparato técnico creciente, en todos los métodos del curso. Lo que los datos entregan directamente es la **diferencia de medias observada**, $\Delta = E[Y \mid D = 1] - E[Y \mid D = 0]$. Aplicando la restricción de consistencia $Y = DY(1) + (1 - D)Y(0)$, esta diferencia se reescribe como

$$\Delta = \underbrace{E[Y(1) - Y(0) \mid D = 1]}_{\text{efecto causal sobre los tratados (ATT)}} + \underbrace{E[Y(0) \mid D = 1] - E[Y(0) \mid D = 0]}_{\text{sesgo de selección}}. \tag{1.1}$$

El segundo término compara el resultado que tratados y no tratados habrían tenido **en ausencia de tratamiento**: es cero solo si ambos grupos eran comparables de partida, y no hay ningún dato que permita calcularlo, porque $E[Y(0) \mid D = 1]$ involucra el resultado potencial no observado de los tratados. Las tres escenas de la sección anterior son, todas, casos donde ese segundo término no es cero y domina la comparación.

Los experimentos aleatorizados lo anulan **por diseño**: si D se asigna independientemente de $(Y(0), Y(1))$, entonces $E[Y(0) \mid D = 1] = E[Y(0) \mid D = 0]$ y $\Delta = \theta$. La aleatorización no «descubre» nada en los datos; impone, mediante el procedimiento de asignación, una condición que ningún volumen de datos observacionales garantiza. Gran parte de este curso está dedicada precisamente a los métodos que permiten **aproximar** esa condición cuando no hubo aleatorización, haciéndola plausible condicional en un conjunto de covariables observadas, usando herramientas de *machine learning* para manejar un número grande de ellas sin perder validez estadística.

1.4 Un adelanto de la escalera de la causalidad

Judea Pearl propuso organizar todas las preguntas causales en tres niveles jerárquicos, popularizados como la «escalera de la causalidad» (Pearl y Mackenzie 2018) y formalizados como la Jerarquía Causal de Pearl (PCH) en el trabajo que retomaremos en detalle en el Capítulo 3. Como adelanto:

- **Nivel 1: Asociación** («ver»): ¿qué relación existe entre las variables tal como se observan? *¿Los estudiantes becados tienen mejores notas?*
- **Nivel 2: Intervención** («hacer»): ¿qué pasaría si actuáramos sobre el sistema? *¿Qué pasaría con las notas si diéramos una beca a un estudiante que hoy no la tiene?*
- **Nivel 3: Contrafactual** («imaginar»): ¿qué habría pasado en un mundo alternativo, dado lo que efectivamente observamos? *¿Habría aprobado María si le hubieran dado la beca, sabiendo que en los hechos no se la dieron y no aprobó?*

Cada nivel requiere información y supuestos estrictamente más fuertes que el anterior: los datos observacionales puros solo permiten responder preguntas de Nivel 1 sin más; responder Nivel 2 requiere supuestos de identificación (como los que exploraremos con Post-Double-Selection y Double Machine Learning); responder Nivel 3 requiere, además, un modelo estructural completo. La pregunta con la que abrimos este capítulo, ¿dar una beca mejora las calificaciones?, es una pregunta de Nivel 2, y es precisamente el tipo de pregunta que un modelo de *machine learning* estándar, entrenado para predecir bien, **no** está diseñado para responder.

1.5 Por qué el aprendizaje automático no es causal por defecto

Vale la pena anticipar, en términos simples, por qué esto importa específicamente para este curso y no solo para la estadística clásica. Los algoritmos de *machine learning*, regresión regularizada, bosques aleatorios, *gradient boosting*, redes neuronales, están diseñados y evaluados para minimizar el error de predicción fuera de muestra. Esa optimización no distingue, ni tiene por qué distinguir, entre la parte de la relación $D \to Y$ que es causal y la parte que refleja confusión, como en las tres escenas de la Sección 1.2. Un modelo que predice el tamaño del pie a partir de la capacidad de lectura (o viceversa) con gran precisión está haciendo exactamente lo que se le pidió: predecir bien. El error no está en el algoritmo, sino en usar sus resultados para responder una pregunta, la pregunta causal, que nunca se le planteó.

Este curso dedica su primera mitad a mostrar cómo, bajo supuestos de identificación explícitos, es posible usar la misma flexibilidad de alta dimensión que hace poderoso al *machine learning* predictivo, sin heredar su ceguera ante la confusión, y su segunda mitad a mostrar cómo llevar esos modelos, ya validados, a un sistema que opera de forma confiable en producción. El Capítulo 5 retoma esta discusión con el aparato formal completo (resultados potenciales en alta dimensión, sesgo de regularización, el estimando CATE); el Capítulo 3 formaliza la escalera de causalidad con modelos causales estructurales. Este capítulo solo pretende dejar instalada, de forma intuitiva y memorable, la pregunta que todo el curso responde: *¿es esto una pregunta de asociación, o una pregunta causal?*

1.6 Ejercicios y notas bibliográficas

1.6.1 Ejercicios conceptuales

1. Para cada una de las siguientes preguntas, indique si es de Nivel 1 (asociación), Nivel 2 (intervención) o Nivel 3 (contrafactual), y justifique en una oración: (a) ¿Los países con más médicos per cápita tienen menor mortalidad infantil? (b) ¿Contratar más médicos reduciría la mortalidad infantil en un país específico? (c) ¿Habría sobrevivido este paciente si el hospital hubiera tenido un médico más?
2. Proponga un ejemplo propio (distinto a los del capítulo) de una correlación espuria generada por una variable confusora. Identifique explícitamente la variable confusora y explique por qué genera la asociación observada.
3. Explique con sus propias palabras por qué el problema fundamental de la inferencia causal (Holland, 1986) implica que ningún algoritmo, por sofisticado que sea, puede calcular el efecto causal individual $Y_i(1) - Y_i(0)$ para una unidad específica a partir de datos observacionales de esa unidad.
4. Un equipo de datos entrena un modelo de *gradient boosting* para predecir ventas a partir de si un producto tuvo o no una promoción, alcanzando un R^2 de 0.95. El equipo concluye que «la promoción explica el 95% de las ventas» y recomienda aplicarla a todos

los productos. ¿Qué está mal en este razonamiento, en términos de los niveles de la escalera de causalidad?

1.6.2 Notas bibliográficas

El marco de resultados potenciales se origina en (Neyman 1923) para experimentos agrícolas aleatorizados y se extiende a estudios observacionales en (Rubin 1974); Holland (1986) formaliza el problema fundamental de la inferencia causal y sigue siendo la referencia estándar para esa formulación. La descomposición de la diferencia de medias en ATT más sesgo de selección de la Sección 1.3 es estándar; su tratamiento completo, incluida la discusión de cuándo el ATT y el ATE coinciden, está en (Imbens y Rubin 2015), Capítulo 1. Pearl y Mackenzie (2018) ofrece la exposición más accesible de la escalera de causalidad para un público no especializado; el tratamiento técnico completo de la Jerarquía Causal de Pearl se encuentra en (Bareinboim et al. 2022), la formalización canónica del resultado, que el Capítulo 3 retoma con precisión, y, de forma integrada con el resto del programa de IA causal, en (Bareinboim 2025) y (Pearl 2009). Simpson (1951) es la referencia original de la paradoja que lleva su nombre, aunque el fenómeno había sido descrito antes en (Yule 1903). Para una introducción contemporánea y aplicada al marco contrafactual, véase (Hernán y Robins 2020), ya citado en capítulos posteriores.

CAPÍTULO 2

Anatomía de un sistema de ML en producción

Cuadro de decisión del capítulo

Decisión:	Tratar el modelo como un componente de un sistema, no como el sistema entero
Alternativas:	Enfoque centrado en el modelo (*model-centric*) vs. enfoque centrado en el sistema (*system-centric*, DMLS)
Trade-off clave:	Velocidad de iteración académica vs. confiabilidad operativa
Stack:	Python y Git (Lab 0 de este capítulo) Docker es opcional
Riesgo principal:	Confundir "el modelo entrena bien" con "el sistema está listo para producción"

2.1 El problema de diseño

Un equipo de análisis de datos entrena un estimador de efectos causales (digamos, un modelo DML del tipo que se construirá en la Parte II de este curso) y obtiene un intervalo de confianza razonable, diagnósticos de identificación satisfactorios y una historia convincente sobre el mecanismo económico. El equipo concluye, con toda razón desde el punto de vista estadístico, que «el modelo funciona». Y sin embargo, si ese modelo se entrega tal cual a un equipo de producto para que decida a quién ofrecer un subsidio, casi con certeza algo saldrá mal en cuestión de semanas: la función que calcula las covariables en el entorno de producción no coincide exactamente con la que se usó para entrenar; nadie sabe qué hacer cuando llegan datos con un valor faltante; no existe forma de saber, tres meses después, si la población a la que se le sigue aplicando el modelo todavía se parece a la población de entrenamiento; y si el modelo empieza a fallar, nadie recibe una alerta hasta que un usuario se queja.

El problema de diseño de este capítulo es reconocer, antes de escribir una sola línea de código de estimación, que **un modelo entrenado y un sistema en producción son dos**

objetos distintos, y que la distancia entre ambos no se cierra con más precisión estadística sino con decisiones de ingeniería. Como señala (Huyen 2022), cuando la mayoría de las personas piensan en «un sistema de machine learning» piensan únicamente en el algoritmo; sin embargo, el algoritmo es apenas un componente de un sistema que también incluye la interfaz con la que interactúan usuarios y desarrolladores, el stack de datos que alimenta al modelo, el *backend* de cómputo sobre el que corre, y la infraestructura que permite desarrollarlo, desplegarlo, monitorearlo y actualizarlo. Este curso dedica su segunda mitad a esos componentes no-algorítmicos, precisamente porque suelen ser el motivo real por el que un proyecto de ciencia de datos técnicamente correcto fracasa en producción.

2.2 Opciones y trade-offs

Existen, en la práctica, dos filosofías de desarrollo que compiten por el tiempo y la atención de un equipo de datos.

Opción 1. Enfoque centrado en el modelo (*model-centric*). El foco está en mejorar la especificación, el algoritmo o la arquitectura, manteniendo los datos y el entorno de despliegue relativamente fijos. Es el modo de trabajo dominante en la academia y en competencias como Kaggle: se compite por una décima de mejora en una métrica sobre un dataset fijo. Su ventaja es la velocidad de iteración sobre la pregunta metodológica; su límite es que ignora, por construcción, todo lo que ocurre antes de tener el dataset y después de tener el modelo entrenado.

Opción 2. Enfoque centrado en el sistema (*system-centric*, DMLS). El foco se reparte deliberadamente entre datos, modelo e infraestructura, entendiendo que mejorar cualquiera de los tres puede mejorar el desempeño observado del sistema. Requiere invertir tiempo en aspectos que no son estadísticamente «interesantes» (formato de almacenamiento, **feature stores**, **logging**, **tests**) y por eso suele sentirse, al principio, como una desviación del trabajo «real». Su ventaja es que es, empíricamente, el único enfoque que sobrevive el contacto con datos reales que cambian con el tiempo y con usuarios reales que dependen del sistema.

Un segundo trade-off, ortogonal al anterior, es el del **proceso** de desarrollo:

Dimensión	Proceso lineal («waterfall»)	Proceso iterativo (DMLS)
Estructura	Recolectar datos → entrenar → desplegar → fin	Ciclo continuo: diseño → datos → desarrollo → despliegue → monitoreo → vuelve a diseño
Supuesto implícito	El mundo (los datos, los usuarios) no cambia después del despliegue	El mundo cambia; el sistema debe detectarlo y adaptarse
Cuándo falla	En cualquier entorno de producción real, tarde o temprano	Requiere infraestructura de monitoreo que el proceso lineal no contempla

El proceso lineal no es una decisión de diseño defendible en 2026 para un sistema que opera de forma continua; se incluye en la tabla porque sigue siendo, de hecho, cómo se enseña y se ejecuta gran parte de los proyectos de ciencia de datos aplicada, y reconocerlo como la opción por defecto, y como opción inadecuada, es el primer paso para adoptar deliberadamente la alternativa.

2.3 Decisión de referencia para el curso

Este curso adopta explícitamente el **enfoque centrado en el sistema** y el **proceso iterativo** de DMLS como su filosofía de trabajo. Los formaliza en cuatro requisitos que todo sistema descrito aquí debe satisfacer, reinterpretados para el caso en que el objetivo del sistema es estimar un efecto causal y no solo predecir:

Opciones y trade-offs

- **Confiabilidad**: el sistema sigue produciendo el comportamiento correcto incluso en presencia de errores de datos o de infraestructura. Para un sistema causal, esto incluye algo que un sistema puramente predictivo no necesita: que el efecto estimado siga siendo **válido bajo los supuestos de identificación declarados**, no solo que el servicio esté «arriba».
- **Escalabilidad**: el sistema puede crecer en volumen de datos, de tratamientos o de usuarios sin un rediseño completo. Para un sistema causal, incluye poder re-estimar el efecto sobre subpoblaciones nuevas sin invalidar el pipeline de identificación existente.
- **Mantenibilidad**: otra persona del equipo, y no quien lo construyó, puede entender, auditar y modificar el sistema. Para un sistema causal, esto exige que los supuestos de identificación estén **documentados y sean auditables**, no solo el código.
- **Adaptabilidad**: el sistema puede ajustarse a cambios en el entorno (nuevos datos, nuevas poblaciones, nuevas políticas). Para un sistema causal, incluye poder **detectar** cuándo un supuesto causal (no confusión, soporte común, fuerza del instrumento) dejó de sostenerse, tema que retomaremos en el Módulo 5.

Estos cuatro requisitos, y no la precisión del estimador considerada de forma aislada, son el criterio con el que se evalúa cada notebook de producción (Serie B) del curso.

2.4 El sistema desplegado es una intervención

Hasta aquí hemos tratado al sistema como algo que mira el mundo y responde. Esa imagen es cómoda y es falsa. En cuanto el sistema decide a quién se le ofrece el subsidio, a quién se le llama o a quién se le concede el crédito, deja de ser un observador: sus decisiones son una intervención sobre el mundo que mide, y esas decisiones se convierten en los datos con los que se entrenará su próxima versión.

El bucle es corto. El modelo de la semana t recomienda una acción para cada persona, la recomendación se aplica o se anula, el resultado se observa y se registra, y ese registro alimenta al modelo de la semana $t+1$:

$$\text{datos}_t \to \text{modelo}_t \to \text{decisión}_t \to \text{mundo}_{t+1} \to \text{datos}_{t+1} \to \text{modelo}_{t+1}. \tag{2.1}$$

Dibujado como un grafo causal, la decisión pasada aparece como causa del dato futuro. De ahí salen tres consecuencias que ningún diagnóstico de predicción detecta, y que organizan buena parte de lo que sigue.

Primera: la asignación del tratamiento pasa a ser la política del propio modelo. Si el sistema recomienda siempre la misma acción a las personas con las mismas covariables, la probabilidad de recibir el tratamiento dado X es 0 o 1 en los datos nuevos. Sin variación en quién recibe qué para un mismo perfil no hay con quién comparar, y el efecto deja de estar identificado por los datos que el sistema mismo produce. Es la condición de soporte común del Capítulo 5, que aquí se rompe por construcción y no por mala suerte.

Segunda: solo se observa el resultado de quienes recibieron la acción. El crédito que no se concedió no deja registro de si habría sido pagado, y el cliente a quien no se llamó no dice si habría renovado. El modelo nuevo aprende entonces de una muestra que el modelo viejo seleccionó. Es el problema de las *etiquetas selectivas*, y su efecto es acumulativo: el sesgo de la versión de ayer entra en los datos de hoy y puede amplificarse con cada reentrenamiento (Sculley et al. 2015).

Tercera: lo que se quiere medir puede cambiar con la política. Un modelo de riesgo que dispara una intervención preventiva consigue que muchos de los casos que marcó no ocurran, y con eso su precisión aparente empeora: los aciertos se ven como falsas alarmas. Cuando la predicción influye en el resultado que pretende predecir se habla de predicción *performativa* (Perdomo et al. 2020), y la pregunta correcta deja de ser qué tan bien acertó el modelo para pasar a ser qué habría ocurrido sin él.

La salida no es dejar de decidir con modelos. Es diseñar el sistema para que siga siendo identificable mientras opera. Tres prácticas lo logran. La primera es reservar de forma permanente un grupo pequeño, asignado al azar, que el modelo no gobierna (un *holdout* permanente). La segunda es registrar con qué probabilidad se asignó cada acción a cada persona, porque sin ese registro no se puede corregir después por la forma en que se decidió. La tercera es mantener un piso de exploración, una fracción mínima de asignación aleatoria dentro de cada perfil para que ninguno quede sin comparación. Las tres cuestan algo de valor de corto plazo, porque una parte de las personas recibe una acción que el modelo no habría elegido, y compran la posibilidad de seguir midiendo el efecto del sistema. Este capítulo solo instala la idea; los Capítulos 30 y 31 tratan cómo vigilar un sistema que decide y cómo reentrenarlo sin perder la identificación.

2.5 Las cinco acciones del sistema

Un sistema que opera necesita un vocabulario cerrado para lo que hace frente a lo que observa. Este libro usa cinco acciones, siempre con el mismo sentido, de modo que «alertar» o «abstenerse» signifiquen lo mismo en el servicio, en la ficha del modelo, en las pruebas automáticas, en el monitoreo y en el aprendizaje continuo. La tabla las ordena de la más restrictiva a la menos restrictiva.

Acción	**Qué significa**	**Quién actúa**
Abstenerse	El sistema no devuelve un número: responde «sin respuesta» a esa consulta, o a todas, porque no puede sostener el efecto (por ejemplo, la consulta está fuera de la población de soporte).	El sistema
Revisar identificación	Un supuesto de identificación dejó de sostenerse o dejó de poder comprobarse. No se promueve ninguna versión nueva hasta que alguien revise el diseño, el grafo y los supuestos.	Una persona
Alertar	Una señal superó su umbral de aviso. El sistema sigue respondiendo y una persona recibe la señal junto con su evidencia.	Una persona
Reentrenar	El estimador se ajusta de nuevo con datos nuevos, sin cambiar el estimando ni la población declarados.	El sistema, bajo una regla de promoción
Continuar	Ninguna señal supera su umbral. El sistema sigue respondiendo con la versión vigente.	El sistema

Cuando varias acciones aplican a la vez, prevalece la más restrictiva. El orden tiene una razón en cada peldaño. Abstenerse va primero porque un número sin sustento es peor que ningún número. Revisar la identificación va antes que alertar porque un supuesto roto no se arregla con un aviso. Y reentrenar queda por debajo de alertar a propósito: ante un cambio en los datos, lo primero es preguntar qué cambió (el Capítulo 26 desarrolla esa pregunta), y reentrenar solo es la respuesta cuando cambió la distribución de las covariables y el efecto sigue siendo el mismo. Si el cambio altera quién recibe el tratamiento o cómo se mide el resultado, reentrenar produce un modelo nuevo para un problema distinto.

Qué señal dispara cada acción y con qué umbral lo decide cada capítulo de producción, y esos umbrales son valores de partida que se calibran con datos propios. Aquí solo se fija el vocabulario.

2.6 Implementación de referencia: el esqueleto del proyecto del curso

Un sistema causal en producción, con la tecnología que sea, tiene seis piezas. Los **datos**, versionados y con el papel de cada columna declarado (tratamiento, resultado, covariables, identificadores, marcas de tiempo). Una **preparación de variables** única, que es la misma función en entrenamiento y en servicio. El **estimador** con su procedimiento de ajuste, de modo que las semillas y la versión de los datos queden registradas. Un **servicio de estimación** que responde con efecto, intervalo y población, o se abstiene. Las **pruebas**, que separan lo determinista (el servicio hace lo que dice) de lo estadístico (el efecto sigue siendo válido). Y una **ficha del modelo** que viaja con el artefacto y declara el estimando, la población y los supuestos. Los capítulos siguientes describen cada pieza como un contrato: qué entra, qué sale, qué debe cumplirse siempre y cómo falla.

Todo el trabajo práctico del curso (Serie A y Serie B de notebooks, y el proyecto final) se organiza sobre un mismo esqueleto de repositorio, que se establece en este capítulo y no vuelve a discutirse:

```
proyecto-causal/
├── data/                 # datos crudos y procesados (no versionados en git
salvo muestras pequeñas)
├── notebooks/
│   ├── serie_a_caso_estudio/     # A1–A4: identificación y estimación
│   └── serie_b_produccion/       # B1–B4: despliegue local
├── src/
│   ├── identification/   # DAGs, diagnósticos de no confusión y soporte común
│   ├── estimation/        # DML, meta-learners, bosques causales
│   └── service/            # función de inferencia, app FastAPI
├── tests/                # pruebas de humo y de sanidad estadística
├── scripts/               # CI local (se detalla en el Capítulo 20)
├── Dockerfile            # opcional: empaquetado del servicio
└── model_card.md          # plantilla del Apéndice G
```

Lab 0 de esta sesión consiste en dejar este esqueleto funcionando localmente: entorno de Python con las librerías del Apéndice B, repositorio Git inicializado y una prueba de humo que se ejecuta con un solo comando. Docker no es necesario para este laboratorio; si más adelante empaqueta el servicio en un contenedor (Capítulos 15 y 20), instálelo entonces. No se estima ningún efecto causal todavía; el objetivo es puramente de infraestructura.

2.7 Aplicación al sistema causal del curso

Vale la pena ser explícitos sobre qué cambia, en esta anatomía de sistema, cuando el «modelo» no predice sino que estima un efecto. Primero, **el artefacto que se sirve no es solo un objeto entrenado**: es un estimador más un conjunto de supuestos de identificación que deben viajar junto con él. De nada sirve servir los coeficientes de un DML sin la documentación de

qué variables se controlaron y bajo qué DAG supuesto, porque sin eso nadie puede saber si el efecto sigue siendo válido para una nueva observación. Segundo, **la interfaz con el usuario debe comunicar algo más que un número**: un sistema predictivo puede mostrar una predicción puntual; un sistema causal responsable debe comunicar el intervalo de confianza y, cuando sea posible, la población para la cual el efecto fue estimado, para evitar que se use fuera de su dominio de validez. Y a veces la respuesta correcta es no comunicar ningún número: si la consulta cae fuera de esa población, el sistema se abstiene. Tercero, **reentrenar no es inocuo**: en un sistema predictivo, reentrenar con datos nuevos casi siempre es deseable si mejora la métrica de error. En un sistema causal, incorporar datos nuevos puede cambiar silenciosamente la población para la que el efecto estimado es representativo, un problema de validez externa y no solo de varianza. Este libro vuelve sobre esto en el Capítulo 31 (aprendizaje continuo).

2.8 Señales de alerta y checklist operativo

- ☐ La estimación no tiene asociada ninguna versión de los datos ni del código (no hay forma de reproducir el resultado).
- ☐ La función que calcula las covariables en el entrenamiento y la que las calculará en producción no son literalmente la misma función (riesgo de **training-serving skew**).
- ☐ No existe un libro de supuestos: ningún documento, ni siquiera informal, que enumere cada supuesto de identificación, de qué tipo es (observable, falsable o no observable) y cómo se vigila o se trata.
- ☐ Nadie en el equipo, aparte de quien entrenó el modelo, podría explicar bajo qué población es válido el efecto estimado.
- ☐ No hay ningún mecanismo, ni manual, para detectar si las covariables que llegan en producción se parecen a las de entrenamiento.
- ☐ El sistema siempre responde, incluso cuando la consulta cae fuera de la población donde se estimó el efecto: no existe ninguna condición en la que devuelva «sin respuesta».
- ☐ Todas las personas reciben la acción que el modelo recomienda. No hay un grupo, por pequeño que sea, al que el sistema no gobierne, ni registro de con qué probabilidad se asignó cada acción.

Si dos o más de estas señales están presentes, el sistema, por preciso que sea el estimador, no está listo para producción según los criterios de este curso.

2.9 Ejercicios y notas bibliográficas

2.9.1 Ejercicios conceptuales

1. Enumere los componentes de un sistema de ML según (Huyen 2022) (más allá del algoritmo) y, para cada uno, dé un ejemplo concreto de cómo fallaría específicamente si el sistema estima un efecto causal en lugar de predecir.

2. Explique, con sus propias palabras, por qué «reentrenar con datos nuevos» es una decisión más delicada en un sistema causal que en uno puramente predictivo.
3. Revise los cuatro requisitos de la Sección 2.3 (confiabilidad, escalabilidad, mantenibilidad, adaptabilidad) y ordénelos según cuál cree que es más fácil de descuidar en un proyecto real. Justifique.
4. Un banco usa un modelo para decidir a quién ofrecer un crédito y cada mes lo reentrena con los créditos que otorgó y su desempeño. Dibuje el bucle y explique qué información sobre los solicitantes a quienes el modelo no ofreció crédito llega al modelo del mes siguiente. ¿Qué cambiaría si el banco otorgara crédito al azar al 2 % de los solicitantes, sin importar su puntaje?
5. Para cada situación indique cuál de las cinco acciones de la Sección 2.5 corresponde y por qué. Si más de una aplica, diga cuál prevalece. (a) La distribución de una covariable se desplazó, la señal superó su umbral de aviso, el soporte común se sigue cumpliendo y los diagnósticos de identificación no empeoraron. (b) Llega una consulta con una covariable fuera del rango de la población donde se estimó el efecto. (c) Un cambio de política interna hace que los clientes de ingreso alto ya no reciban nunca la oferta. (d) Ninguna señal supera su umbral.

2.9.2 Ejercicio de infraestructura (Lab 0)

1. Complete el Lab 0: cree el esqueleto de repositorio de la Sección 2.6, inicialice Git y deje una prueba de humo que se ejecute con un solo comando. Entregue la salida de ese comando.

2.9.3 Notas bibliográficas

Huyen (2022) es la fuente principal de este capítulo y del enfoque pedagógico de todo el curso; sus Capítulos 1 y 2 («Overview of Machine Learning Systems» e «Introduction to Machine Learning Systems Design») desarrollan en detalle la distinción entre modelo y sistema, y los cuatro requisitos aquí adaptados al caso causal. Sculley et al. (2015) es el artículo seminal que documentó por primera vez, de forma sistemática, cómo el código del modelo de aprendizaje automático suele ser una fracción pequeña del sistema real, y cómo la «deuda técnica» se acumula en el resto de los componentes. Breck et al. (2017) ofrece una rúbrica operativa, el «ML Test Score», que puede usarse como complemento al checklist de la Sección 2.8 para auditar la preparación de un sistema para producción. Paleyes et al. (2022) complementa a ambos con evidencia empírica: una revisión sistemática de casos documentados de despliegue que clasifica los puntos de fallo a lo largo del ciclo de vida completo (gestión de datos, desarrollo del modelo, despliegue, monitoreo) y confirma que la fracción de fallos atribuible al algoritmo mismo es minoritaria, el argumento central de este capítulo contrastado contra la práctica industrial en lugar de solo argumentado. Sobre el bucle de la Sección 2.4, Sculley et al. (2015) describe los bucles de retroalimentación ocultos, en los que un modelo influye en los datos con los que se reentrena, como una fuente de deuda técnica, y Perdomo et al. (2020) formalizan la predicción performativa, el caso en que la predicción cambia el resultado que predice.

PARTE I

Fundamentos estructurales y de datos

Esta parte formaliza el problema causal con Modelos Causales Estructurales y la Jerarquía Causal de Pearl, desarrolla el aparato de regularización y post-selección en alta dimensión, y establece el criterio de puerta trasera para distinguir controles legítimos de controles que sesgan la estimación. En paralelo, construye la capa de datos e ingeniería de features de un sistema causal en producción, sin la cual ningún resultado de identificación sobrevive el paso a un pipeline real.

CAPÍTULO 3

Modelos Causales Estructurales y la Jerarquía Causal de Pearl

Cuadro sinóptico del capítulo

Problema:	Formalizar matemáticamente qué significa «causa» y qué pregunta responde cada nivel de causalidad
Estimando:	Distribuciones $P(v)$, $P(y \mid \text{do}(x))$ y $P(y_x \mid \text{evidencia})$
Identificación:	Un Modelo Causal Estructural (SCM) más su grafo asociado
Método:	Do-calculus (adelanto; formalización completa en el Capítulo 8)
Garantía:	Cada nivel de la PCH requiere estrictamente más supuestos que el anterior
Librerías:	`networkx`, `dowhy`, `causal-learn`
Validación:	Contraste de las independencias condicionales que el grafo supuesto implica

3.1 El problema: formalizar «causa» matemáticamente

El Capítulo 1 introdujo, de forma intuitiva, la distinción entre preguntas de asociación, de intervención y de contrafactual, junto con el marco de **resultados potenciales**. Este capítulo formaliza esa distinción con una segunda herramienta, el marco de **Modelos Causales Estructurales** (SCM) de Judea Pearl, que Elias Bareinboim y su escuela extienden hasta la **Jerarquía Causal de Pearl** (PCH). Los dos marcos son equivalentes para el uso que les da este libro, pero difieren en lo que hacen explícito. Los resultados potenciales son más naturales para razonar sobre un tratamiento y un resultado. Los SCM lo son para razonar sobre sistemas con muchas variables relacionadas entre sí, que es justo el tipo de sistema que aparece en un pipeline de datos de producción, y por eso son el lenguaje de la segunda mitad del libro cuando se habla de arquitectura de datos y de despliegue.

La pregunta que este capítulo responde es doble: **(i)** ¿qué objeto matemático representa por completo un sistema causal?, y **(ii)** dado ese objeto, ¿qué tres tipos de pregunta, y solo tres, se le pueden hacer, y qué información mínima requiere responder cada una?

3.2 Teoría: SCM y la Jerarquía Causal de Pearl

3.2.1 Modelos Causales Estructurales

Definición 3.1 ***(SCM)***

Un **Modelo Causal Estructural** (SCM) es una tupla $M = \langle U, V, F, P(u) \rangle$ donde: U es un conjunto de variables exógenas (no modeladas, «de fondo»); $V = \{V_1, ..., V_n\}$ es un conjunto de variables endógenas (las que el modelo explica); $F = \{f_1, ..., f_n\}$ es un conjunto de funciones estructurales tales que cada $V_i = f_i(\text{pa}_i, U_i)$, donde $\text{pa}_i \subseteq V \setminus \{V_i\}$ son los «padres» de V_i (sus causas directas dentro del modelo) y $U_i \subseteq U$; y $P(u)$ es una distribución de probabilidad sobre las variables exógenas.

Cada SCM induce un **grafo causal** G: un nodo por cada variable en V y una flecha $V_j \to V_i$ si $V_j \in \text{pa}_i$. Este grafo, el mismo objeto que el Capítulo 1 usó de manera informal para hablar de confusores, no es una descripción estadística sino una afirmación sobre **mecanismos**: cada ecuación $V_i = f_i(\text{pa}_i, U_i)$ representa un proceso físico, biológico, económico o social real, y no una relación estadística ajustada a los datos. Esta es la diferencia esencial entre un modelo causal y un modelo predictivo. Un modelo predictivo puede ajustar Y en función de X sin comprometerse con ninguna afirmación sobre mecanismos; un SCM afirma que si se **intervinieran** las causas de Y, Y cambiaría exactamente según su ecuación estructural.

La conexión con el marco de resultados potenciales del Capítulo 1 es directa. Dado un SCM con variable de tratamiento D y resultado $Y = f_Y(D, X, U_Y)$, el resultado potencial $Y(d)$ se define como el valor que toma la ecuación estructural de Y al fijar $D = d$: $Y(d) := f_Y(d, X, U_Y)$. Bajo esta correspondencia, los dos marcos son dos lenguajes para el mismo objeto.

3.2.2 Los tres niveles de la Jerarquía Causal de Pearl

Cada SCM M induce tres distribuciones de probabilidad distintas, que corresponden exactamente a los tres niveles adelantados en el Capítulo 1:

Nivel (PCH)	Distribución inducida	Se calcula con
$\mathcal{L}_1$: Asociación	$P(v)$: la distribución observacional conjunta de V	Los datos observados, sin modificar M
$\mathcal{L}_2$: Intervención	$P(y \mid \text{do}(x))$: la distribución de Y tras *reemplazar* la ecuación de X por la constante x	El SCM «quirúrgicamente modificado» M_x (se borra f_X y se fija $X = x$)
$\mathcal{L}_3$: Contrafactual	$P(y_x \mid e)$: la distribución de «Y hubiera sido y si X hubiera sido x», dada la evidencia e efectivamente observada	Un procedimiento de tres pasos: abducción, acción, predicción (ver más abajo)

El operador $\text{do}(x)$ formaliza qué significa «intervenir». No es lo mismo **observar** que $X = x$, lo que simplemente selecciona el subconjunto de unidades con $X = x$ y por tanto puede estar contaminado por confusión, como en las tres escenas del Capítulo 1, que **forzar** $X = x$ mediante una intervención externa que anula el mecanismo natural por el que X se determinaba. Formalmente, $P(y \mid \text{do}(x)) \neq P(y \mid X = x)$ en general. Las dos coinciden cuando no hay confusión entre X e Y, la condición que el resto del libro dedica tanto esfuerzo a verificar o inducir; con confusión pueden coincidir solo por una cancelación fortuita.

Ejemplo 3.2

Los tres niveles sobre el mismo SCM. Considere el SCM simplificado $D = f_D(U_D)$, $Y = f_Y(D, X, U_Y)$, $X = f_X(U_X)$, con U_D y U_Y correlacionados (confusión no observada entre D e Y). En $\mathcal{L}_1$, $P(y \mid D = d)$ mezcla el efecto de D sobre Y con la correlación espuria inducida por U_D y U_Y compartidos. En $\mathcal{L}_2$, $P(y \mid \text{do}(D = d))$ se calcula sobre el modelo modificado donde f_D se reemplaza por la constante d, lo que corta el vínculo entre U_D y D y elimina así exactamente la confusión. En $\mathcal{L}_3$, dado que se observó a un individuo específico con $D = 0, Y = y_0$, la pregunta «¿qué Y habría tenido si D hubiera sido 1?» requiere primero **inferir** la distribución de U_D, U_Y compatible con lo observado (abducción), luego **forzar** $D = 1$ en el modelo (acción) y finalmente **propagar** para predecir Y (predicción). De ahí el nombre del procedimiento de tres pasos de Pearl para el cómputo contrafactual.

Hay aquí un punto que suele perderse en presentaciones más elementales de esta jerarquía: la separación entre niveles no es una limitación práctica de los métodos disponibles, sino un resultado formal.

Teorema 3.3 ***(Teorema de la Jerarquía Causal)***

Sea Ω el espacio de SCM sobre un conjunto de variables V, equipado con una medida de probabilidad natural sobre las funciones estructurales y las distribuciones exógenas. El conjunto de SCM para los cuales las distribuciones de nivel $\mathcal{L}_{k+1}$ quedan **determinadas** por las de nivel $\mathcal{L}_k$ tiene medida cero en Ω, para $k = 1, 2$.

En términos operativos, salvo en un conjunto excepcional de casos (de medida nula), dos SCM distintos pueden inducir exactamente la misma distribución observacional $P(v)$ y, sin

embargo, distintas distribuciones interventivas $P(y \mid \text{do}(x))$, y análogamente entre $\mathcal{L}_2$ y $\mathcal{L}_3$. Por eso ningún procedimiento que opere únicamente sobre $P(v)$ puede, sin supuestos adicionales, recuperar $P(y \mid \text{do}(x))$: la información no está ahí. El **Teorema de la Jerarquía Causal** (Bareinboim et al. (2022)) establece que, casi siempre, los tres niveles de la escalera causal están estrictamente separados. Este resultado, presentado de forma integrada con el resto del programa de IA causal en (Bareinboim 2025), es la razón formal, y no solo intuitiva, de la tesis del Capítulo 1: los datos observacionales solos no responden preguntas causales.

Dos consecuencias prácticas se siguen de inmediato, y estructuran el resto del libro. Primera: todo método de estimación causal a partir de datos observacionales (DML, PDS, meta-learners, bosques causales) debe importar información externa a los datos, y esa información es siempre un supuesto de identificación, típicamente la afirmación de que las covariables observadas cierran todas las rutas de puerta trasera (Capítulo 8). Segunda: ese supuesto no se puede validar con los datos que se están usando, porque su función es suplir justamente lo que los datos no contienen. A lo sumo puede **refutarse** si genera implicaciones observacionales que los datos contradicen (Sección 3.4), o someterse a análisis de sensibilidad (Capítulo 14). Ninguna cantidad de datos ni ningún algoritmo cambia esta situación.

3.3 De la ecuación a los números: un caso canónico

Simular una intervención sobre un SCM conocido es un procedimiento corto. Se conservan las ecuaciones de todas las variables salvo la de D, se sustituye la de D por la constante d, se generan las demás variables con las mismas exógenas y se calcula la cantidad de interés. Lo que se obtiene es $P(y \mid \text{do}(D = d))$, que se compara con $P(y \mid D = d)$ calculada sobre los datos sin intervenir.

Caso canónico · Becas y motivación no observada

Una versión estilizada del ejemplo de becas y calificaciones del Capítulo 1. La motivación U es normal estándar y no se observa. Una persona pide la beca ($D = 1$) cuando $U + \varepsilon_D > 0.3$, con ε_D normal estándar, de modo que las más motivadas piden más becas. La calificación es $Y = 0.4D + 0.9U + \varepsilon_Y$, con ε_Y de desviación 0,5, y el efecto causal verdadero de la beca vale 0,4 por construcción.

Con 50 000 unidades, la diferencia de medias entre quienes recibieron la beca y quienes no es 1,43, es decir, 3,6 veces el efecto verdadero. Al simular $\text{do}(D = 1)$ y $\text{do}(D = 0)$ sobre toda la población, la diferencia es 0,40. La diferencia asociativa está inflada por la confusión a través de U; el efecto interventivo recupera el 0,4 porque do() anula el mecanismo que generaba D a partir de U.

El listado construye ese SCM y calcula las dos cantidades.

```
import numpy as np
import pandas as pd
```

```
rng = np.random.default_rng(7)
n = 50_000

# U: motivación no observada (confusor de D y de Y)
U = rng.normal(size=n)

# D (beca): depende de U -- estudiantes mas motivados piden mas becas
D_obs = (U + rng.normal(size=n) > 0.3).astype(int)

# Y (calificacion): depende de D (efecto causal verdadero = 0.4) y de U
Y_obs = 0.4 * D_obs + 0.9 * U + rng.normal(scale=0.5, size=n)

df = pd.DataFrame({"U": U, "D": D_obs, "Y": Y_obs})

# Nivel 1 (asociacion): P(Y | D=1) observacional
assoc = df.loc[df["D"] == 1, "Y"].mean() - df.loc[df["D"] == 0, "Y"].mean()

# Nivel 2 (intervencion): simular do(D=1) para TODA la poblacion,
# reemplazando la ecuacion estructural de D por la constante 1
Y_do1 = 0.4 * 1 + 0.9 * U + rng.normal(scale=0.5, size=n)
Y_do0 = 0.4 * 0 + 0.9 * U + rng.normal(scale=0.5, size=n)
intervencion = Y_do1.mean() - Y_do0.mean()

print(f"Diferencia asociativa  P(Y|D=1)-P(Y|D=0):  {assoc:.3f}")
print(f"Efecto interventivo    P(Y|do(D=1))-do(0): {intervencion:.3f}")
print(f"Efecto causal verdadero (por construccion): 0.400")
# La diferencia asociativa esta inflada por la confusion via U;
# el efecto interventivo recupera el 0.4 verdadero porque do()
# anula el mecanismo que generaba D a partir de U.
```

Listado 3.1: SCM simulado: divergencia entre asociación e intervención.

En la práctica no se observa U ni se puede «reemplazar la ecuación de D», porque la simulación conoce el SCM verdadero. El problema aplicado de identificación, que el resto del libro desarrolla, es cómo estimar $P(y \mid \mathrm{do}(x))$ **sin** conocer el SCM completo, usando solo datos observacionales más supuestos sobre el grafo (por ejemplo, con Post-Double-Selection o DML, si se asume no confusión condicional en las covariables observadas).

3.4 Consistencia del grafo supuesto con los datos

Antes de estimar un efecto conviene comprobar que el grafo supuesto sea **consistente** con los datos. Todo grafo implica, por d-separación, ciertas independencias condicionales entre las variables observadas (la definición se da en el Capítulo 29), y esas sí se pueden contrastar. El chequeo es **necesario pero no suficiente**, y el Teorema de la Jerarquía Causal explica por qué. Varios grafos distintos inducen exactamente el mismo conjunto de independencias condicionales: son observacionalmente equivalentes y forman lo que el Capítulo 29 llamará su

clase de equivalencia de Markov, de modo que pasar el contraste no los distingue. Lo que el contraste sí puede hacer es **refutar**: si el grafo implica una independencia que los datos rechazan, alguno de sus supuestos es falso.

Hay dos precauciones, y la segunda es la que más se olvida. La primera es que el contraste refuta el conjunto de supuestos y no dice cuál de ellos falla. La segunda es que **la independencia hay que derivarla del grafo antes de contrastarla**: condicionar en la variable equivocada puede destruirla, y un grafo correcto sale entonces «refutado» por una prueba que nunca debió aplicarse.

Caso canónico · Una cadena con y sin confusión no observada

Tres variables continuas: Z (por ejemplo, la cercanía a una universidad), D (educación) e Y (salario). En el primer mundo, $D = 0.8Z + \varepsilon_D$ e $Y = 0.5D + \varepsilon_Y$. La cadena $Z \to D \to Y$, sin confusión entre D e Y, implica $Z \perp\!\!\!\perp Y \mid D$. En el segundo mundo se añade una variable U no observada que entra con coeficiente 1 en D y en Y, el tipo de confusión que justifica usar Z como instrumento.

Con 2 000 unidades y 300 repeticiones, la correlación parcial de Z e Y dado D vale en promedio $-0{,}001$ en el primer mundo, y el contraste de Fisher rechaza al 5 % en el 4,7 % de las repeticiones, el nivel nominal. En el segundo, la correlación parcial vale en promedio $-0{,}27$ y el contraste rechaza en el 100 % de las repeticiones.

El grafo del segundo mundo es el correcto, y el contraste lo rechaza igual. Condicionar en D, que es un collider en el camino $Z \to D \leftarrow U \to Y$, abre ese camino y crea una asociación que el grafo nunca declaró como independencia. De hecho, el modelo de variable instrumental con confusión no observada no implica ninguna independencia condicional entre las tres variables observadas: no hay nada que contrastar.

La lección tiene dos caras. Cuando el analista afirma que no hay confusión no observada entre D e Y (la no confusión condicional que usan los métodos del libro) y dispone de una variable Z que, según el grafo, solo afecta a Y a través de D, la independencia $Z \perp\!\!\!\perp Y \mid D$ es una implicación contrastable de esa afirmación, y rechazarla es un motivo serio para dudar de ella. Cuando en cambio el diseño admite confusión no observada, como en un instrumento, esa misma independencia no existe y la prueba carece de sentido.

El segundo listado implementa el contraste gaussiano (correlación parcial por residuos de mínimos cuadrados y la transformación z de Fisher) y lo aplica a los dos mundos del caso canónico. Las bibliotecas de descubrimiento causal del Apéndice B ofrecen este mismo contraste y otros que no suponen normalidad.

```
import numpy as np
from scipy import stats


def correlacion_parcial(a, b, c):
```

```
    """Correlacion parcial de a y b dado c (matriz n x k), por residuos de
minimos cuadrados."""
    C = np.c_[np.ones(len(a)), c]
    ra = a - C @ np.linalg.lstsq(C, a, rcond=None)[0]
    rb = b - C @ np.linalg.lstsq(C, b, rcond=None)[0]
    return np.corrcoef(ra, rb)[0, 1]


def contraste_fisher(a, b, c):
    """Contraste de independencia condicional (gaussiano): z de Fisher de la
correlacion parcial."""
    c = np.asarray(c).reshape(len(a), -1)
    r = correlacion_parcial(a, b, c)
    z = np.sqrt(len(a) - c.shape[1] - 3) * np.arctanh(r)
    return r, 2 * (1 - stats.norm.cdf(abs(z)))


def mundo(n, semilla, con_confusion, efecto_directo=0.0):
    """Cadena Z -> D -> Y; con_confusion agrega U no observada en D e Y;
efecto_directo agrega Z -> Y."""
    g = np.random.default_rng(semilla)
    z = lambda: g.normal(size=n)
    Z = z()
    U = z() if con_confusion else np.zeros(n)
    D = 0.8 * Z + U + z()
    Y = 0.5 * D + U + efecto_directo * Z + z()
    return Z, D, Y


for con in (False, True):
    Z, D, Y = mundo(2000, 0, con)
    r, p = contraste_fisher(Z, Y, D)
    print(f"confusion no observada: {con!s:5}  correlacion parcial {r:+.3f}  p
= {p:.3g}")
```

Listado 3.2: Contraste de independencia condicional con correlación parcial, aplicado a una cadena con y sin confusión no observada.

3.5 Qué cambia en un sistema desplegado

Los tres niveles no son solo una clasificación teórica. Cada salida de un sistema en producción responde a uno de ellos, y el sistema tiene que saber a cuál. Un puntaje predictivo vive en $\mathcal{L}_1$. Un efecto de política (qué pasa si se asigna el tratamiento a esta población) vive en $\mathcal{L}_2$. Una explicación para un caso individual (qué habría pasado con esta persona si…) vive en $\mathcal{L}_3$ y exige supuestos sobre las ecuaciones estructurales que ni siquiera un experimento puede comprobar. El nivel que una salida responde forma parte, por eso, de su contrato con quien la

consume: la ficha del modelo (Capítulo 19) lo declara en el campo del estimando, y el servicio (Capítulo 15) devuelve un efecto con su intervalo y no un puntaje.

Hay además un segundo efecto, que el Capítulo 2 desarrolla en la Sección 2.4. Al desplegarse, el sistema sustituye en el mundo la ecuación estructural por la que se asignaba el tratamiento por una regla de decisión propia. Es el operador do() aplicado al mundo real, y por eso los datos que el sistema produce después ya no provienen del SCM con que se entrenó.

3.6 Riesgos, límites y sensibilidad

Riesgos, límites y mitigación

- **Confundir $P(y \mid X = x)$ con $P(y \mid \mathrm{do}(x))$.** Es, con diferencia, el error más frecuente entre practicantes de *machine learning* que se acercan por primera vez a la inferencia causal: tratar un filtro de la tabla como si fuera una intervención. Son el mismo objeto solo si no hay confusión.
- **Asumir que el grafo es «el verdadero».** Un SCM formaliza supuestos, no los verifica. Ningún test estadístico puede confirmar que un grafo causal es correcto; solo puede refutarlo si es inconsistente con los datos. La responsabilidad de argumentar el grafo es del analista, no del algoritmo.
- **Contrastar una independencia que el grafo no implica.** Condicionar en un collider, o en un descendiente suyo, crea la asociación que se pretendía descartar. Antes de usar un contraste para refutar un grafo hay que derivar la independencia con la regla de d-separación.
- **Tratar $\mathcal{L}_3$ como si fuera $\mathcal{L}_2$.** Una pregunta contrafactual («¿habría aprobado María si…?») no se responde con el mismo procedimiento que una pregunta interventiva poblacional («¿qué pasaría si becáramos a todos?»). Colapsar ambas, algo muy común en la comunicación de resultados a audiencias no técnicas, puede llevar a promesas que el modelo no puede respaldar.

3.7 Ejercicios y notas bibliográficas

3.7.1 Ejercicios teóricos

1. Escriba el SCM (variables, ecuaciones estructurales, grafo) para el ejemplo de la paradoja de Simpson del Capítulo 1 (tratamiento, gravedad del caso, recuperación). Indique cuál nodo es el confusor.
2. Para el SCM del ejercicio anterior, escriba explícitamente el modelo modificado $M_{\{\mathrm{do}(D=1)\}}$ y explique, en términos del grafo, qué arista(s) desaparece(n).

3. Explique por qué, en general, $P(y \mid \text{do}(x))$ no puede calcularse a partir de $P(v)$ sin supuestos adicionales sobre el grafo (Teorema de la Jerarquía Causal). Dé un ejemplo de dos SCM distintos que induzcan la misma $P(v)$ pero distinta $P(y \mid \text{do}(x))$.
4. Para el grafo con $Z \to D$, $D \to Y$, $U \to D$ y $U \to Y$, donde U no se observa, liste las independencias condicionales que implica entre Z, D e Y. ¿Cuántas hay? Relacione la respuesta con el caso canónico de la Sección 3.4.

3.7.2 Ejercicios computacionales

1. Modifique el listado 3.1 para que el efecto causal verdadero de D sobre Y sea 0 (sin efecto), manteniendo la confusión vía U. Verifique que la diferencia asociativa sigue siendo distinta de cero mientras que el efecto interventivo converge a 0.
2. Con las funciones del listado 3.2, agregue al mundo sin confusión un camino directo $Z \to Y$ de coeficiente 0,3 (parámetro `efecto_directo`). ¿Qué hace el contraste? ¿Puede decir si el rechazo se debe al camino directo o a una confusión no observada? Explique.

3.7.3 Notas bibliográficas

La referencia canónica del Teorema de la Jerarquía Causal, incluida la construcción precisa de la medida sobre el espacio de SCM que da sentido a la expresión «medida cero», es Bareinboim et al. (2022) su enunciado aquí es deliberadamente informal en ese punto. El capítulo sigue por lo demás la formalización de (Bareinboim 2025), fuente principal de contenido teórico-causal del libro, y la exposición clásica de (Pearl 2009), que introduce el operador do(), el procedimiento de tres pasos para el cómputo contrafactual y el cálculo-do que se enuncia formalmente en el Capítulo 8. Imbens y Rubin (2015) discute en detalle la equivalencia formal entre el marco de resultados potenciales y el de SCM. Para una introducción visual y menos técnica a la jerarquía, véase de nuevo (Pearl y Mackenzie 2018), ya citado en el Capítulo 1. El conjunto de datos de Card (1995), que los capítulos de estimación usan como ejemplo, es el contexto en que la cercanía a una universidad se propone como instrumento de la educación.

CAPÍTULO 4

Ingeniería de datos para sistemas causales

Cuadro de decisión del capítulo

Decisión:	Declarar los roles causales de cada columna en un esquema único que viaja con los datos, y no repetirlos en cada análisis
Alternativas:	Tabla ancha sin metadatos vs. esquema con roles etiquetados (tratamiento, resultado, covariable, instrumento)
Trade-off clave:	Velocidad de prototipado vs. prevención sistemática de errores de identificación
Contrato:	C-01, esquema de roles causales (Sección 4.4)
Stack:	pandas
Riesgo principal:	Que dos análisis definan X de forma distinta, o que una variable posterior al tratamiento entre como covariable sin que nada lo señale

Implementación en el monorepo del curso (2026)

En el monorepo del curso (2026) los datos de práctica viven en `data_benchmark_causal/…/datasets/` como **CSV** + `metadata.json` (no Parquet obligatorio). Los roles de variables se resuelven con `lib.data_io.load_scenario` y el puente `lib.schema.CausalSchema.from_scenario(«real/jobs»)`, que construye el esquema de este capítulo a partir de los metadatos del escenario. Labs: `L04`–`L06`. Entrega: **Notebook A1** (Jobs). Stack: `03_notebooks_caso_estudio/lib/`.

4.1 El problema de diseño

La ingeniería de datos genérica, la que enseña Huyen (2022) en su Capítulo 3, se pregunta qué formato de almacenamiento usar, qué modelo de datos es apropiado (relacional, documento, grafo) y cómo pasar datos entre procesos. Todas esas preguntas siguen vigentes en un sistema causal, pero hay una más, específica, que un pipeline puramente predictivo nunca tiene que responder: **¿qué rol estructural juega cada columna del conjunto de datos?** En predicción, las columnas de entrada son en principio intercambiables, porque el modelo usa todas las que ayuden a reducir el error. En un problema causal no lo son. Una es el **tratamiento** D, otra es el **resultado** Y, algunas son **covariables** X que pueden controlarse legítimamente y, lo más delicado, algunas que **parecen** covariables razonables son variables posteriores al tratamiento: están en la ruta causal entre D e Y, o son efecto común de ambos, y controlarlas sesga la estimación. El Capítulo 8 desarrolla esta distinción con el nombre de «buenos y malos controles».

Si el pipeline no distingue esos roles desde el origen, si todo llega como una tabla ancha sin metadatos, la tarea de no confundirlos recae en la memoria de quien escribe cada análisis. Eso falla de forma predecible a medida que el sistema crece y más personas lo tocan.

4.2 Opciones y trade-offs

Opciones y trade-offs

- **Tabla ancha sin metadatos.** Cada análisis decide, con nombres de columna escritos en su propio código, cuál es D, cuál es Y y cuáles son X. Es la opción más rápida para un estudio único y exploratorio, y la que domina en la práctica académica. Su costo aparece cuando el mismo conjunto de datos se reutiliza en varios análisis o cuando el sistema en producción tiene que reconstruir las mismas columnas: nada impide que dos análisis definan X de forma sutilmente distinta, uno con una variable posterior al tratamiento y otro sin ella, y produzcan estimaciones no comparables sin que nadie lo note. El caso canónico de más abajo muestra cuánto pueden diferir.
- **Esquema con roles etiquetados.** Se declara en un único lugar qué columna es el tratamiento, cuál el resultado, cuáles son covariables que pueden controlarse y cuáles instrumentos, si los hay. Todo análisis y todo servicio consume ese esquema en lugar de escribir nombres de columna. El costo es la fricción inicial de definirlo antes de poder «simplemente correr una regresión».

4.3 Decisión de referencia para el curso

El libro adopta un **esquema de roles causales** explícito para todo conjunto de datos que alimente una estimación. El esquema mínimo declara cuatro cosas: el tratamiento, el resultado,

las covariables y, cuando aplica, los instrumentos. Ninguna función de estimación del sistema acepta una tabla sola. Todas reciben la tabla junto con su esquema, de modo que sea imposible, por ejemplo, pasar el tratamiento como covariable por accidente.

Lo que la decisión fija es que **el esquema exista y sea la única fuente de verdad sobre los roles**, no el formato en que se guarda. Conviene que viaje con los datos, como metadato del propio archivo o como un archivo vecino versionado junto a ellos, porque el riesgo que se previene no es de eficiencia de lectura sino de **deriva semántica**: que dos partes del sistema discrepen sobre qué columna es el tratamiento o cuáles son las covariables. Ese riesgo se cierra con la unicidad del esquema, no con el formato.

Conviene también ser explícito sobre lo que el esquema declara. Etiquetar una columna como covariable no es una afirmación sobre su tipo de dato ni sobre su utilidad predictiva. Es una afirmación **causal**: que esa variable puede controlarse legítimamente, es decir, que pertenece a un conjunto que satisface el criterio de puerta trasera (Capítulo 8). Por eso el esquema es un artefacto de identificación además de uno de ingeniería, y por eso el Capítulo 9 le añade una auditoría explícita en vez de dar por buena la lista de covariables. El esquema puede comprobar que los roles no se contradicen y que las columnas existen. No puede comprobar que lo declarado sea cierto.

4.4 El contrato del esquema de roles

Este es el primero de los contratos numerados del libro. Cada contrato describe una pieza de ingeniería sin atarla a una tecnología: qué operaciones ofrece, qué recibe, qué devuelve, qué debe cumplirse siempre, cómo falla y cómo se comprueba. Cualquier implementación lo cumple si pasa su prueba de aceptación.

Contrato C-01 · Esquema de roles causales

Operaciones	*declarar*: construye el esquema a partir de los nombres del tratamiento, el resultado, las covariables y los instrumentos. *validar*: comprueba el esquema contra una tabla de datos. *proyectar*: devuelve de la tabla la matriz de covariables, el tratamiento y el resultado, en el orden declarado. *escribir* y *leer*: pasan el esquema a un texto legible por personas y por máquinas, y de vuelta.
Entrada	Los nombres de las columnas de cada rol (un tratamiento, un resultado, al menos una covariable, cero o más instrumentos) y la tabla de datos a la que el esquema se aplica.
Salida	La matriz de covariables, el tratamiento y el resultado. El texto del esquema, con los mismos campos que el apartado de roles de la ficha del modelo (contrato C-05 del Capítulo 19).
Invariantes	(1) Cada columna tiene un solo rol: ninguna aparece dos veces en el esquema. (2) Hay al menos una covariable. (3) Una tabla

	solo valida si contiene todas las columnas declaradas y si el tratamiento toma al menos dos valores distintos. (4) El orden de las covariables es parte del esquema y las proyecciones lo respetan. (5) Escribir y volver a leer devuelve un esquema igual al original. (6) El esquema no se modifica una vez creado: cambiar los roles produce otro esquema y deja intacto el que ya usan otras piezas. (7) Declarar una covariable es una afirmación causal que este contrato no verifica; la verifica la auditoría del C-03 (Capítulo 9).
Modos de fallo	Una columna declarada que ya no está en los datos, porque cambió de nombre en el origen. El tratamiento o el resultado repetidos entre las covariables, o un instrumento incluido entre ellas. Un tratamiento constante en la muestra recibida, porque un filtro dejó una sola rama. Un esquema que se desincroniza de los datos porque viaja por separado. Una covariable posterior al tratamiento que pasa todas las comprobaciones, porque el contrato solo ve nombres.
Prueba de aceptación	(a) Cada fallo estructural de la lista se provoca a propósito y la operación correspondiente lo rechaza con un mensaje que nombra la columna. (b) Escribir y leer devuelve un esquema igual, y el texto escrito valida contra el apartado de roles del esquema de la ficha del modelo. (c) Dos análisis que consumen el mismo esquema reciben la misma matriz de covariables y obtienen la misma estimación sobre el caso canónico de más abajo. (d) Una covariable posterior al tratamiento pasa la validación; el contrato no pretende detectarla y la prueba lo deja a la vista.

Caso canónico · Dos análisis, dos definiciones de X

Un conjunto de datos laborales estilizado, con efecto conocido. La educación de los padres P y la edad E son normales estándar independientes. La escolaridad depende de los padres, $D = 0.5P + \varepsilon_D$, y el salario es $Y = D + 0.8P + 0.5E + \varepsilon_Y$, de modo que el efecto de un año más de escolaridad vale exactamente 1. La tabla incluye además una columna de experiencia potencial, $S = E - D$, construida a partir de la edad y de la escolaridad. Es una práctica habitual en datos laborales: en el conjunto de datos de Card (1995), tal como se distribuye públicamente, la experiencia se calcula como edad menos escolaridad menos seis.

Dos análisis leen la misma tabla. El primero controla por $\{P, E\}$ y el segundo por $\{P, S\}$. Los nombres de ambos conjuntos existen en los datos, ninguno repite el tratamiento y los dos pasan cualquier validación estructural. Con 5 000 unidades y 200

repeticiones, el primero estima 1,00 y el segundo 1,50, con una desviación entre repeticiones de alrededor de 0,02 en los dos.

La diferencia de 0,50 no es ruido. Como S contiene a D, controlarla abre el camino $D \to S \leftarrow E \to Y$, y el coeficiente de D absorbe el efecto de la edad: sustituyendo $E = S + D$ en el salario queda $Y = 1.5D + 0.8P + 0.5S + \varepsilon_Y$. Con un esquema único no hay dos definiciones de X que comparar, y la discusión sobre si S pertenece a ella ocurre en un solo lugar y queda registrada. Lo que el esquema no decide es cuál de las dos definiciones es la correcta: eso lo hace la auditoría del Capítulo 9, que deja S fuera porque se calcula con el tratamiento.

Cada decisión del contrato responde a un fallo concreto.

Un solo rol por columna. Un instrumento incluido también como covariable es un error distinto al de repetir el tratamiento, pero igual de silencioso: el estimador corre y devuelve un número. Con la regla de que una columna ocupa un solo lugar, el esquema rechaza la contradicción antes de que haya un número que mirar.

Validar contra los datos, no solo contra sí mismo. Un esquema consistente consigo mismo puede describir una tabla que ya no existe. La comprobación contra la tabla recibida atrapa el cambio de nombre en el origen y el filtro que dejó sin variación al tratamiento, que de otro modo aparecen como una estimación con error estándar enorme o como un fallo lejano en el código del estimador.

Viajar con los datos. Un esquema que vive en la cabeza de alguien, o en un cuaderno de trabajo, se desincroniza. Escribirlo en un texto con los mismos campos que la ficha del modelo permite que el esquema con que se entrenó sea, sin traducción, el que registra la ficha y el que el servicio exige a cada consulta.

Declarar no es verificar. El contrato rechaza lo que puede decidir con nombres y tablas, y deja explícito lo que no puede. Una variable posterior al tratamiento pasa todas sus comprobaciones. Si el contrato pareciera garantizar lo contrario, un equipo daría por revisada la identificación cuando solo revisó la ortografía de las columnas.

4.5 Implementación de referencia

El primer listado implementa el contrato C-01 con una clase de datos inmutable. La construcción rechaza las columnas con dos roles, la validación comprueba el esquema contra una tabla, y la escritura y la lectura usan los mismos campos que el apartado de roles de la ficha del modelo (Ap. G).

```
import json
from dataclasses import dataclass
import pandas as pd
```

```
@dataclass(frozen=True)
class CausalSchema:
    treatment: str
    outcome: str
    covariates: tuple
    instruments: tuple = ()

    def __post_init__(self):
        object.__setattr__(self, "covariates", tuple(self.covariates))
        object.__setattr__(self, "instruments", tuple(self.instruments))
        if not self.covariates:
            raise ValueError("Se necesita al menos una covariable")
        cols = self.columns()
        dobles = sorted({c for c in cols if cols.count(c) > 1})
        if dobles:
            raise ValueError(f"Columnas con dos roles: {dobles}")

    def columns(self) -> list:
        return [self.treatment, self.outcome, *self.covariates,
*self.instruments]

    def validate(self, df: pd.DataFrame) -> None:
        ausentes = sorted(set(self.columns()) - set(df.columns))
        if ausentes:
            raise ValueError(f"Columnas ausentes en los datos: {ausentes}")
        if df[self.treatment].nunique() < 2:
            raise ValueError("El tratamiento no varía en estos datos")

    def X(self, df): return df[list(self.covariates)]
    def D(self, df): return df[self.treatment]
    def Y(self, df): return df[self.outcome]

    def to_json(self) -> str:
        return json.dumps({"tratamiento": self.treatment, "resultado":
self.outcome,
                           "covariables": list(self.covariates),
                           "instrumentos": list(self.instruments)},
ensure_ascii=False)

    @classmethod
    def from_json(cls, texto: str):
        r = json.loads(texto)
        return cls(r["tratamiento"], r["resultado"], r["covariables"],
r.get("instrumentos", []))
```

Listado 4.1: Esquema de roles causales como estructura de datos explícita (contrato C-01).

El esquema es un objeto que no cambia tras crearse: quien necesite otra lista de covariables construye otro esquema, y el anterior sigue siendo el que describe a los modelos ya entrenados con él. La clase no intenta detectar variables posteriores al tratamiento, y lo declara en el contrato. Ese trabajo es de la auditoría del Capítulo 9. El segundo listado la usa sobre datos sintéticos.

```
import numpy as np

# Los nombres de columna recuerdan a un estudio de retornos a la educación.
g = np.random.default_rng(4)
datos = pd.DataFrame({"padres_educ": g.normal(size=200), "edad":
g.normal(size=200),
                      "cerca_universidad": g.integers(0, 2, size=200)})
datos["educ"] = 0.5 * datos["padres_educ"] + g.normal(size=200)
datos["salario"] = datos["educ"] + 0.8 * datos["padres_educ"] + 0.5 *
datos["edad"] + g.normal(size=200)

esquema = CausalSchema(treatment="educ", outcome="salario",
                       covariates=("padres_educ", "edad"),
instruments=("cerca_universidad",))
esquema.validate(datos)   # lanza ValueError si falta una columna o si el
tratamiento no varía
assert CausalSchema.from_json(esquema.to_json()) == esquema
print(esquema.to_json())
```

Listado 4.2: Uso del esquema sobre datos sintéticos: validar, escribir y volver a leer.

Formato de almacenamiento. Un segundo trade-off, heredado de Huyen (2022), es el del formato en que se guardan los datos. Los formatos orientados a fila (CSV, JSON) son más simples de inspeccionar a mano, pero más lentos cuando solo se necesita un subconjunto de columnas, que es justo lo que un pipeline de estimación causal hace una y otra vez: leer Y, D y una parte de X sin cargar el resto. Los formatos orientados a columna (Parquet) son más eficientes para ese patrón y permiten adjuntar el esquema como metadato dentro del propio archivo. Un CSV acompañado de un archivo de esquema versionado a su lado cumple el mismo contrato, y es la forma que adopta el benchmark del curso (véase el recuadro de implementación al comienzo del capítulo).

4.6 Aplicación al sistema causal del curso

El esquema se declara antes de correr ninguna estimación. Eso obliga a que la pregunta de identificación (Capítulo 1, Capítulo 3) se convierta en un paso de ingeniería concreto y comprobable, en vez de quedar implícita en la cabeza de quien analiza los datos. Después el mismo esquema reaparece, sin cambios, a lo largo de todo el sistema: la ficha de procedencia del Capítulo 7 lo extiende con el mecanismo de asignación, la auditoría del Capítulo 9 lo contrasta con el tiempo y el grafo, la ficha del modelo lo registra como su apartado de roles (Capítulo 19) y el servicio lo usa para saber qué columnas debe traer cada consulta (Capítulo

15). Así se cierra el círculo entre el entrenamiento y el servicio desplegado. El Notebook de caso de estudio A1 (Módulo 1 del curso) exige construirlo para el conjunto de datos elegido antes de estimar nada, y el Notebook de producción B1 (Capítulo 15) lo reutiliza sin cambios.

4.7 Señales de alerta y checklist operativo

- ☐ El nombre de la columna de tratamiento está escrito a mano en más de un análisis o servicio, con riesgo de que diverja.
- ☐ Ninguna función de carga de datos valida que el tratamiento, el resultado y los instrumentos no figuren también entre las covariables.
- ☐ No hay forma de saber, sin leer el código que genera las variables, si alguna covariable fue medida o calculada **después** del tratamiento.
- ☐ El esquema de roles no viaja junto con los datos y puede desincronizarse sin que nadie lo note.
- ☐ Dos análisis del mismo conjunto de datos reportan efectos distintos y nadie ha comparado sus listas de covariables.
- ☐ El formato de almacenamiento obliga a cargar todas las columnas para leer solo tres, y esa carga se repite en cada corrida.

4.8 Ejercicios y notas bibliográficas

4.8.1 Ejercicios conceptuales

1. Para el conjunto de datos de becas del Capítulo 1, proponga tres covariables legítimas para X y una variable que, aunque esté correlacionada con el resultado, sería incorrecto incluir en X por ser posterior al tratamiento. Justifique.
2. Explique por qué un esquema de roles causales explícito importa más en un sistema con varios análisis y varios colaboradores que en un estudio individual de una sola vez.
3. En el caso canónico, suponga que la edad deja de afectar al salario (el coeficiente 0,5 pasa a 0). Dibuje el grafo, diga qué estima el segundo análisis y explique por qué el sesgo desaparece. ¿Qué dos arcos hacen falta para que controlar S sesgue?

4.8.2 Ejercicio de infraestructura

1. Extienda la clase `CausalSchema` del listado 4.1 con un método `summary()` que imprima, para cada rol, el número de valores faltantes y el tipo de dato de las columnas correspondientes. Aplíquelo al conjunto de datos que elija para el Notebook A1.

4.8.3 Notas bibliográficas

Huyen (2022), Capítulo 3, desarrolla en profundidad los formatos y modelos de datos genéricos que este capítulo adapta al caso causal. La distinción entre controles legítimos y variables posteriores al tratamiento se formaliza en el Capítulo 8 con el lenguaje de grafos causales;

véase también la discusión de «buenos y malos controles» en (Bareinboim 2025). Sculley et al. (2015) documentan cómo las dependencias de datos y la configuración sin declarar acumulan deuda técnica en los sistemas de aprendizaje automático, que es el costo de dejar los roles de las variables repartidos en el código de cada análisis. El conjunto de datos de Card (1995) sobre retornos a la educación se usa como ejemplo en los capítulos de estimación.

CAPÍTULO 5

Predicción y causalidad: por qué el ML no es causal por defecto

Cuadro sinóptico del capítulo

Problema:	Distinguir una respuesta predictiva de una respuesta causal
Estimando:	ATE, ATT, CATE(x), valor de una política
Identificación:	No confusión condicional, soporte común, SUTVA
Método:	Contraste predictivo frente a contraste causal, con verdad conocida
Nuisance:	$\mu_d(x)$, $e(x)$
Garantía:	Identificación bajo supuestos; sesgo de primer orden del estimador por sustitución
Librerías:	scikit-learn, numpy
Validación:	Simulación con efecto conocido, cobertura de intervalos, placebos

Nota técnica

Este capítulo retoma la distinción entre asociación y causalidad presentada de forma intuitiva en el Capítulo 1 y formalizada con modelos estructurales y la Jerarquía Causal de Pearl en el Capítulo 3. Aquí el foco pasa de «¿qué pregunta estoy haciendo?» a «¿cómo la respondo con datos de alta dimensión?», la pregunta que estructura toda la Parte II.

5.1 Problema causal, estimando e identificación

Un economista del Ministerio de Desarrollo Social debe decidir a qué hogares beneficiar con un programa de transferencias condicionadas. El presupuesto solo alcanza para el 30 % de la población elegible. Dispone de cien variables socioeconómicas por hogar (ingresos, composición familiar, escolaridad, empleo, vivienda, salud) y de un registro histórico de hogares que recibieron o no el programa, con el ingreso posterior observado. La pregunta relevante

es *causal*: ¿qué hogares verían el mayor aumento de ingresos si recibieran el programa? La pregunta *predictiva*, qué hogares tendrán mayores ingresos en el futuro con independencia del programa, es distinta y, para focalizar, a menudo equivocada.

La distinción importa porque los algoritmos corrientes de *machine learning* (regresión ridge, bosques aleatorios, *gradient boosting*, redes neuronales) se optimizan para predecir, no para estimar efectos. Un bosque que predice con alta precisión el ingreso futuro de un hogar puede dar una estimación sesgada del efecto del programa, por dos razones estructurales. Primero, un modelo predictivo no distingue la variación de Y asociada a D porque D la causa de la que se asocia porque D comparte causas con Y: esa distinción la aporta el supuesto de identificación, no el algoritmo. Segundo, la regularización que mejora la predicción fuera de muestra contrae justamente el coeficiente que interesa, un fenómeno que se llama sesgo inducido por la regularización.

El capítulo sostiene que la inferencia causal descansa en supuestos de identificación económicos, no estadísticos, y que el aporte del ML consiste en flexibilizar la estimación de los componentes auxiliares (*nuisance*) sin vulnerar esos supuestos. Fija la notación de resultados potenciales en alta dimensión, define los estimandos centrales del libro (ATE, ATT, CATE y valor de una política) y muestra con tres simulaciones de efecto conocido tres maneras distintas de equivocarse: un predictor excelente que estima mal el efecto, un sesgo que no desaparece con más datos y un control que crea el sesgo que pretendía evitar.

Conviene evitar también la conclusión simétrica y equivocada de que la predicción sea siempre el instrumento inadecuado. Kleinberg et al. (2015) identifican una clase entera de problemas de política, los *prediction policy problems*, en los que la decisión depende de un pronóstico y no de un efecto causal. Su ejemplo es la prótesis de cadera o rodilla: el beneficio de operar crece con los años de vida que le quedan al paciente, de modo que lo que falta saber para decidir es cuánto vivirá, una pregunta predictiva. El criterio para distinguir ambos regímenes es preciso: **si la decisión cambia la variable sobre la que se razona, la pregunta es causal; si solo depende de un estado del mundo que ocurriría de todos modos, la pregunta es predictiva**. Focalizar un subsidio por «quién se beneficiaría más» es causal, porque asignarlo cambia el ingreso. Focalizarlo por «quién es más pobre» pide predecir la pobreza basal, que se realiza con o sin el programa, y equivale a focalizar por beneficio solo si se supone que el efecto crece con la pobreza o si el objetivo es de equidad y no de eficiencia. Muchos sistemas de *targeting* en producción mezclan ambos criterios sin declararlo, y la tabla 5.1 existe para forzar esa declaración.

Dimensión	**Predicción**	**Causalidad**
Objetivo	Minimizar el error fuera de muestra	Estimar $\tau(x)$ con intervalo válido
Estimando	$E[Y \mid X]$	$E[Y(1) - Y(0) \mid X]$
Métrica de éxito	RMSE, exactitud, AUC	Sesgo, cobertura, RMSE de $\hat{\tau}$
Datos requeridos	Solo Y, X observados	Requiere $Y(0), Y(1)$, que no se observan a la vez

Dimensión	Predicción	Causalidad
Supuestos clave	Datos i.i.d., estacionariedad	No confusión, soporte común, SUTVA
Regularización	Bienvenida (mejora la generalización)	Peligrosa si recae sobre el efecto (introduce sesgo en τ)
Validación	Validación cruzada estándar	Placebos, curvas Qini, *benchmarks* y simulación con verdad conocida

Tabla 5.1: Régimen predictivo y régimen causal.

5.2 Teoría, supuestos y garantías

5.2.1 Supuestos

Se adopta el marco de (Neyman 1923) y (Rubin 1974). Cada unidad i tiene dos resultados potenciales: $Y_i(1)$ si recibe el tratamiento e $Y_i(0)$ si no lo recibe. La asignación observada es $D_i \in \{0,1\}$ y el resultado observado cumple la restricción de consistencia $Y_i = D_i Y_i(1) + (1 - D_i)Y_i(0)$. Las covariables pretratamiento $X_i \in \mathbb{R}^p$ forman un vector cuya dimensión p puede ser grande (decenas o cientos) e incluso crecer con n. Tres supuestos permiten identificar $\tau(x)$ con datos observacionales.

Supuesto 5.1 ***(No confusión condicional)***

$Y(0), Y(1) \perp\!\!\!\perp D \mid X$.

Supuesto 5.2 ***(Soporte común)***

Existe $\underline{e} > 0$ tal que $\underline{e} < P(D = 1 \mid X = x) < 1 - \underline{e}$ para todo x en el soporte de X.

Supuesto 5.3 ***(SUTVA: no interferencia y versión única)***

El resultado potencial de la unidad i depende solo de su propio tratamiento, $Y_i(d_1, ..., d_n) = Y_i(d_i)$, y el tratamiento no tiene versiones ocultas que cambien el resultado.

Estos supuestos son *económicos*: su validez depende del contexto sustantivo y no de la cantidad de datos. La no confusión exige haber observado todas las variables que afectan a la vez la asignación y el resultado. El soporte común exige que haya unidades tratadas y no tratadas en cada región del espacio de covariables. SUTVA prohíbe efectos cruzados entre unidades y versiones distintas del tratamiento bajo un mismo nombre. Solo el soporte común puede diagnosticarse con los datos (mirando la distribución del propensity score). La no confusión no se contrasta con datos observados, porque involucra $Y(0)$ e $Y(1)$ de las mismas unidades, que nunca se observan juntas; SUTVA depende del diseño del programa. La responsabilidad de justificarlos recae en el economista y no en el algoritmo.

5.2.2 Estimandos e identificación

Definición 5.4 ***(Estimandos causales centrales)***

Bajo SUTVA, los estimandos de interés son

$$\begin{aligned} \text{ATE}: &\quad \theta = E[Y(1) - Y(0)], \\ \text{ATT}: &\quad \theta_{\text{ATT}} = E[Y(1) - Y(0) \mid D = 1], \\ \text{CATE}: &\quad \tau(x) = E[Y(1) - Y(0) \mid X = x], \\ \text{Valor de una política}: &\quad V(\pi) = E[Y(\pi(X))], \end{aligned} \tag{5.1}$$

donde $\pi : \mathbb{R}^p \to \{0, 1\}$ es una regla de asignación del tratamiento.

El libro se centra en $\tau(x)$ y $V(\pi)$, porque son los estimandos que el ML permite abordar de una manera genuinamente nueva: la heterogeneidad del efecto y la optimización de políticas que se apoyan en ella (Capítulo 12 y Capítulo 21).

Proposición 5.5 ***(Identificación del CATE)***

Bajo consistencia y los supuestos de no confusión condicional y soporte común, para todo x del soporte,

$$\mu_d(x) = E[Y \mid X = x, D = d] = E[Y(d) \mid X = x], \quad \tau(x) = \mu_1(x) - \mu_0(x), \tag{5.2}$$

y por tanto $\theta = E[\tau(X)]$, $\theta_{\text{ATT}} = E[\tau(X) \mid D = 1]$ y $V(\pi) = E[\mu_0(X) + \pi(X)\tau(X)]$.

Demostración. Por consistencia, $E[Y \mid X = x, D = d] = E[Y(d) \mid X = x, D = d]$. Por no confusión condicional, $E[Y(d) \mid X = x, D = d] = E[Y(d) \mid X = x]$. El soporte común garantiza que el evento $D = d$ tiene probabilidad positiva dado $X = x$, de modo que el condicionamiento está bien definido. Los demás estimandos siguen de la ley de las esperanzas iteradas. □

La proposición contiene una lección que el resto del capítulo precisa. Bajo no confusión condicional, el contraste predictivo $E[Y \mid X, D = 1] - E[Y \mid X, D = 0]$ **coincide** con el efecto causal. Un modelo predictivo no está equivocado por naturaleza al leerse en clave causal. Falla por dos razones concretas y separables: porque el supuesto de identificación no se cumple (hay confusión no observada, el caso 2 más abajo), o porque la función μ_d se estima mal justamente en la dirección que importa (el caso 1). Por eso la respuesta correcta a «¿puedo leer este modelo como causal?» nunca es un sí o un no genérico, sino una revisión de los dos supuestos de arriba y de la calidad de la estimación.

5.2.3 Sesgo de primer orden del estimador por sustitución

Si se estiman $\hat{\mu}_0$ y $\hat{\mu}_1$ con un método de ML y se calcula $\hat{\tau}(x) = \hat{\mu}_1(x) - \hat{\mu}_0(x)$, se obtiene el *T-learner* del Capítulo 12, y su promedio $\hat{\theta} = (1/n) \sum_i \hat{\tau}(X_i)$ es el estimador por sustitución del ATE. La pregunta es bajo qué condiciones $\hat{\theta}$ admite inferencia en alta dimensión. La respuesta es negativa, y se explica con una descomposición exacta.

Proposición 5.6 ***(Sesgo de primer orden del estimador por sustitución)***

Sean $\hat{\mu}_0, \hat{\mu}_1$ estimados en una muestra independiente de la que se usa para promediar, y sea $\hat{\tau} = \hat{\mu}_1 - \hat{\mu}_0$. Entonces

$$\hat{\theta} - \theta = \underbrace{b_n}_{\text{sesgo}} + \underbrace{(P_n - P)(\hat{\tau})}_{O_p(n^{-1/2})}, \quad b_n = E[\hat{\tau}(X) - \tau(X) \mid \hat{\mu}], \tag{5.3}$$

y $|b_n| \le \|\hat{\mu}_1 - \mu_1\|_{L^2} + \|\hat{\mu}_0 - \mu_0\|_{L^2}$. El sesgo b_n es de primer orden en el error de los *nuisance*. Si ese error converge a una tasa a_n con $\sqrt{n}a_n \to \infty$, como ocurre con los estimadores flexibles en dimensión alta, entonces $\sqrt{n}\big(\hat{\theta} - \theta\big)$ no es asintóticamente normal centrada en cero.

Demostración (esquema). Se suma y resta $P\hat{\tau}$, con P la esperanza bajo la distribución verdadera y P_n el promedio muestral: $\hat{\theta} - \theta = (P_n - P)\hat{\tau} + P(\hat{\tau} - \tau)$. El primer término tiene varianza $\mathrm{Var}(\hat{\tau}(X))/n$ condicional en $\hat{\mu}$, porque $\hat{\tau}$ es independiente de la muestra de promediado, y es por tanto $O_p\big(n^{-1/2}\big)$ si $\hat{\tau}$ está acotada en L^2. El segundo es b_n, y la desigualdad sigue de Cauchy-Schwarz y de la desigualdad triangular. □

Dos consecuencias operacionales. Primera, b_n no se puede estimar sin conocer μ_d, de modo que ningún error estándar calculado con los datos lo corrige: un intervalo $\hat{\theta} \pm 1.96\widehat{\mathrm{SE}}$ queda centrado en el lugar equivocado. Segunda, la regularización hace que b_n sea sistemático y no solo ruido: contrae $\hat{\mu}_d$ hacia una función más simple, y el sesgo resultante no desaparece al aumentar n a la velocidad que exigiría la inferencia. Recuperar la $\sqrt{n}$-consistencia requiere cambiar el estimador de modo que el error de los *nuisance* entre solo a segundo orden. Eso es la ortogonalización de Neyman combinada con *cross-fitting* (Capítulo 10 y Capítulo 11), y es la razón de ser de la Parte II.

5.3 Procedimiento: simulación con verdad conocida

Ninguna de las dos fuentes de error anteriores se ve en los datos reales, donde el efecto verdadero se desconoce. Se ven en un experimento controlado: se genera un conjunto de datos a partir de un proceso conocido con efecto θ_0 fijo, se aplica el estimador y se compara con θ_0. Este procedimiento es la herramienta de validación más barata del libro y se usa en casi todos los capítulos.

La salida admite una lectura en tres filas. Un sesgo cercano a cero con cobertura nominal valida el estimador **bajo ese proceso**. Un R^2 predictivo alto con sesgo grande muestra que la calidad predictiva no certifica el efecto. Un sesgo constante en n con cobertura que se hunde al crecer n señala un problema de identificación, no de estimación.

5.4 Casos canónicos y validación

Los tres casos usan el procedimiento anterior. Las cifras están promediadas sobre las repeticiones que se indican. Salen de `herramientas/verificaciones/verif_cap05.py`.

Algoritmo

Entrada: Proceso generador G con efecto causal conocido θ_0, tamaño muestral n, estimador $\hat{\theta}(\cdot)$, número de repeticiones R.
Salida: Sesgo, desviación típica, cobertura del intervalo y, si procede, R^2 predictivo.
for r = 1 **to** R **do**

Generar (Y, D, X) de G con semilla r y también una muestra independiente (Y', D', X').
Calcular $\hat{\theta}_r$ y su intervalo de confianza con la muestra (Y, D, X).
Calcular el R^2 predictivo del modelo ajustado sobre (Y', D', X').

end for
Sesgo $= (1/R)\sum_r \hat{\theta}_r - \theta_0$; cobertura $= (1/R)\sum_r \mathbf{1}\{\theta_0 \in \mathrm{IC}_r\}$.
return Sesgo, desviación típica de $\left(\hat{\theta}_r\right)$, cobertura, R^2 medio.

Algoritmo 1. Simulación con verdad conocida

Caso canónico · Un bosque que predice bien y estima mal

Diez covariables normales estándar, D binaria con $P(D = 1 \mid X) = \mathrm{sigm}(0.8X_0 + 0.8X_1)$ y $Y = D + 2X_0 + X_1 + 0.5X_2 + \varepsilon$, de modo que el efecto verdadero es $\theta_0 = 1$ y la confusión es solo por variables observadas. Con $n = 2\sim000$ y 30 repeticiones:

Estimador	Media	Desv. típica	Sesgo
Contraste de un bosque con (D, X)	0,815	0,133	−0,185
OLS con los controles	1,003	0,048	0,003
Residualización con bosques y *cross-fitting*	1,020	0,047	0,020

El bosque, entrenado para predecir Y con (D, X), alcanza un R^2 fuera de muestra de 0,84 y, sin embargo, subestima el efecto en casi un 19 %. La razón es de regularización: D aporta una fracción pequeña de la varianza de Y (unos 0,25 frente a los 5,25 de la señal de X), los árboles tienden a dedicar sus divisiones a X_0 y X_1, y la dependencia de Y respecto de D queda contraída. OLS acierta porque el modelo está bien especificado, y la residualización con bosques (adelanto del Capítulo 10) lo recupera sin exigir linealidad.

Caso canónico · El sesgo que no se va con más datos

Se añade una variable U no observada que afecta a la asignación y al resultado: $D = \mathbf{1}\{0.8U + 0.5X_0 + \varepsilon_D > 0\}$, $Y = D + 1.5U + X_0 + \varepsilon$, efecto verdadero $\theta_0 = 1$. Se estima por OLS con los controles observados, con errores estándar robustos y 200 repeticiones por tamaño:

n	Media	Sesgo	Desv. típica	Cobertura IC 95 %
500	2,518	1,518	0,151	0,00
2 000	2,524	1,524	0,083	0,00
8 000	2,521	1,521	0,039	0,00
32 000	2,521	1,521	0,020	0,00

La desviación típica se reduce a la mitad cada vez que n se cuadruplica, y el sesgo no se mueve. Con más datos la estimación es más precisa y sigue igual de equivocada, y el intervalo, cada vez más estrecho, nunca contiene el valor verdadero. Un bosque con (D, X) da lo mismo (sesgo de 1,60, 1,55 y 1,53 con $n = 500$, 2 000 y 8 000, sobre 10 repeticiones): ningún algoritmo recupera una variable que no está en X.

Caso canónico · Controlar por todo lo disponible

A y B son normales estándar independientes, $D = A + \varepsilon_D$, $Y = D + B + \varepsilon_Y$ y $C = A + B + \varepsilon_C$ es una variable que ambos causan (un *collider*). El efecto de D sobre Y es 1 y no hay confusión: A y B no se asocian. Con 200 000 observaciones, el coeficiente de D es 0,999 sin controlar por C y 0,798 al controlar por C, que coincide con el valor exacto 4/5 del Ejercicio 3; con $n = 10 \sim 000$ y 200 repeticiones, la media al controlar por C es 0,802 (desviación típica de 0,010). En esa muestra grande, la correlación entre A y B es −0,003 y, al condicionar en el 20 % superior de C, pasa a ser −0,293.

El tercer caso es el mecanismo inverso al de la confusión: allí condicionar **elimina** una asociación espuria; aquí la **crea**, y explica por qué «controlar por todo lo disponible» no es una estrategia conservadora sino una fuente activa de sesgo. Elwert y Winship (2014) llaman a este fenómeno sesgo de selección endógena: dos variables independientes se vuelven dependientes al condicionar en una causa común o en un descendiente de ella. El Capítulo 8 formaliza cuándo ocurre cada caso mediante el criterio de puerta trasera; aquí basta con dejar instalada la intuición numérica. Hay una variante más cotidiana del mismo error: usar como control una variable posterior al tratamiento. La experiencia potencial de un trabajador, definida como edad menos escolaridad menos seis, es función exacta de la escolaridad y no puede incluirse como control en una regresión del salario sobre los años de estudio.

5.4.1 Interpretación económica

Intuición

Caja de profundización: tres tipos de preguntas causales

Objetivo. Distinguir las preguntas que solo observan, las que intervienen y las que imaginan escenarios alternativos.

Ejemplo económico. Un gerente de banco quiere saber:

1. ¿Los clientes con más ingresos piden más crédito? (se observa)
2. ¿Qué pasa si se baja la tasa de interés? (se interviene)
3. ¿Este cliente habría pedido crédito si no se le hubiera subido la tasa? (se imagina)

Los tres niveles de Pearl. En general, las cantidades

$$P(Y \mid X = x), \quad P(Y \mid \mathrm{do}(X = x)), \quad P(Y_x \mid X = x', Y = y') \tag{5.4}$$

son tres objetos distintos.

- **Nivel 1, asociación («ver»):** $P(Y \mid X)$. Ejemplo: «los clientes con más ingresos piden más crédito».
- **Nivel 2, intervención («hacer»):** $P(Y \mid \mathrm{do}(X))$. Ejemplo: «si se baja la tasa, ¿cuánto aumenta el crédito?»
- **Nivel 3, contrafactual («imaginar»):** $P(Y_x \mid X = x', Y = y')$. Ejemplo: «Juan no pidió crédito con la tasa alta; ¿lo habría pedido con la tasa baja?»

Importante. Un modelo de ML entrenado con datos observacionales aprende el nivel 1. Para decidir una política (nivel 2) hacen falta supuestos causales adicionales, y para responsabilizar a un caso individual (nivel 3) hace falta además un modelo del mecanismo.

5.5 Implementación en Python

Los listados reproducen los casos 1 y 3 con una versión autocontenida del procedimiento (solo `numpy` y `scikit-learn`). El caso 2 cambia el generador del caso 1 por el que describe el recuadro correspondiente y repite la estimación OLS para cada n.

```
import numpy as np
from sklearn.ensemble import RandomForestRegressor
from sklearn.model_selection import KFold


def generar(n, rng, p=10, theta=1.0):
    X = rng.standard_normal((n, p))
    e = 1.0 / (1.0 + np.exp(-(0.8 * X[:, 0] + 0.8 * X[:, 1])))
    D = rng.binomial(1, e)
    Y = theta * D + 2.0 * X[:, 0] + X[:, 1] + 0.5 * X[:, 2] +
rng.standard_normal(n)
    return X, D, Y


def ols(D, X, Y):
    Z = np.column_stack([np.ones(len(Y)), D, X])
    return np.linalg.lstsq(Z, Y, rcond=None)[0][1]
```

```
def contraste_bosque(X, D, Y, seed):
    # Predictivo: ajusta E[Y | D, X] y deriva respecto de D. No es un estimador
causal por diseño.
    rf = RandomForestRegressor(n_estimators=200, min_samples_leaf=5,
random_state=seed, n_jobs=-1)
    rf.fit(np.column_stack([D, X]), Y)
    uno = np.column_stack([np.ones(len(Y)), X])
    cero = np.column_stack([np.zeros(len(Y)), X])
    return (rf.predict(uno) - rf.predict(cero)).mean(), rf


def residualizacion(X, D, Y, seed, k=5):
    # Residual sobre residual con nuisance ajustados fuera del fold (adelanto
del Cap. 10).
    ry, rd = np.zeros(len(Y)), np.zeros(len(Y))
    for tr, te in KFold(k, shuffle=True, random_state=seed).split(X):
        my = RandomForestRegressor(n_estimators=100, min_samples_leaf=5,
random_state=seed, n_jobs=-1).fit(X[tr], Y[tr])
        md = RandomForestRegressor(n_estimators=100, min_samples_leaf=5,
random_state=seed, n_jobs=-1).fit(X[tr], D[tr])
        ry[te], rd[te] = Y[te] - my.predict(X[te]), D[te] - md.predict(X[te])
    return (rd * ry).sum() / (rd * rd).sum()


def simular(reps=30, n=2000):
    est = {"bosque": [], "ols": [], "residualizacion": []}
    for r in range(reps):
        X, D, Y = generar(n, np.random.default_rng(1000 + r))
        est["bosque"].append(contraste_bosque(X, D, Y, r)[0])
        est["ols"].append(ols(D, X, Y))
        est["residualizacion"].append(residualizacion(X, D, Y, r))
    for nombre, v in est.items():
        v = np.array(v)
        print(f"{nombre:16s} media={v.mean():.3f}  sd={v.std(ddof=1):.3f}
sesgo={v.mean() - 1.0:+.3f}")


if __name__ == "__main__":
    # Prueba de coherencia: con el efecto verdadero 1.0, OLS debe quedar cerca
de 1.
    X, D, Y = generar(2000, np.random.default_rng(0))
    assert abs(ols(D, X, Y) - 1.0) < 0.25
    simular()
```

Listado 5.1: Caso 1: contraste predictivo, OLS y residualización con *cross-fitting* sobre un proceso con efecto conocido.

```
import numpy as np

rng = np.random.default_rng(42)
n = 200_000
A, B = rng.standard_normal(n), rng.standard_normal(n)
C = 0.8 * A + 0.8 * B + rng.standard_normal(n)        # A -> C <- B

alto = C > np.quantile(C, 0.8)
print("Corr(A,B):", np.corrcoef(A, B)[0, 1])
print("Corr(A,B | C en el 20% superior):", np.corrcoef(A[alto], B[alto])[0, 1])

# Efecto de D sobre Y sin confusión: A causa D, B causa Y, ambos causan C2.
D = A + rng.standard_normal(n)
Y = 1.0 * D + B + rng.standard_normal(n)
C2 = A + B + rng.standard_normal(n)
sin = np.linalg.lstsq(np.column_stack([np.ones(n), D]), Y, rcond=None)[0][1]
con = np.linalg.lstsq(np.column_stack([np.ones(n), D, C2]), Y, rcond=None)[0]
[1]
print(f"Efecto de D (verdadero 1.0): sin C = {sin:.3f}, controlando C =
{con:.3f}")
assert abs(sin - 1.0) < 0.05 and abs(con - 0.8) < 0.05   # coherencia con el
valor exacto 4/5
```

Listado 5.2: Caso 3: asociación creada al condicionar en un *collider* y sesgo al controlar por él.

El primer listado ilustra con un efecto conocido lo que con datos reales no puede verse: el bosque tiene un R^2 fuera de muestra alto y estima mal el efecto. Con datos reales solo se dispone de uno de los dos lados de esa comparación.

5.6 Riesgos, límites y sensibilidad

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Confundir predicción con causalidad	Política errónea basada en un contraste predictivo	Comparar el contraste $E[Y \mid X, D=1] - E[Y \mid X, D=0]$ con una referencia de efecto conocido	Definir $Y(1), Y(0)$ y el estimando antes de estimar. La derivada de un predictor respecto de D solo es causal si se cumple la identificación y μ_d se estima bien en esa dirección (caso 1)
Omitir confusores	Sesgo que no se corrige con más datos (caso 2)	Construir un DAG, buscar placebos y analizar la sensibilidad a un confusor no observado	Justificar la no confusión con teoría económica o usar un diseño alternativo. Si un confusor no está en X, ningún algoritmo lo recupera

Riesgo	Consecuencia	Diagnóstico	Mitigación
Controlar por un *collider* o por una variable posterior al tratamiento	Se crea una asociación espuria o se bloquea parte del efecto (caso 3)	Revisar el orden temporal de cada control y su lugar en el DAG	Controlar solo por variables previas al tratamiento o por causas de D e Y que el DAG justifique
Interpretar la importancia de variables (valores de Shapley) como causal	Sobreinterpretar lo que es una descripción del predictor	Preguntarse qué intervención justificaría la lectura	Reportar la importancia como descriptiva y estimar el efecto de intervenir con el estimando causal
Reportar el RMSE como evidencia de calidad causal	Falsa confianza en un efecto sesgado	Comparar métricas predictivas con métricas causales (Qini, cobertura)	Validar con placebos, Qini y verdad sintética. En el caso 1 un R^2 de 0,84 convive con un sesgo de casi 19 %

Tabla 5.2: Riesgos al confundir predicción con causalidad.

Límites del marco. El marco de resultados potenciales supone no interferencia. En contextos con efectos cruzados (epidemias, redes sociales, externalidades) este supuesto se vulnera y se requieren métodos específicos, como la inferencia bajo interferencia o los diseños con aleatorización por conglomerados; quedan fuera del alcance de este volumen, y (Aronow y Miller 2017) es una referencia. El checklist completo de validación de métodos causales está en el apéndice F.

5.7 Ejercicios y notas bibliográficas

5.7.1 Ejercicios teóricos

1. Clasifique cada pregunta como asociación, intervención o contrafactual: (a) ¿los alumnos con mejores notas tienen mejor salario?, (b) ¿sirve dar becas para mejorar notas?, (c) ¿María habría entrado a la universidad si le hubieran dado la beca?
2. Demuestre que, bajo no confusión condicional, $E[Y \mid D=1] - E[Y \mid D=0]$ difiere en general del ATE, y exprese la diferencia en términos de $\mu_0(x)$ y de la distribución de X en cada grupo. ¿Qué papel juega el soporte común?
3. En el tercer caso canónico, con $D = A + \varepsilon_D$, $Y = D + B + \varepsilon_Y$ y $C = A + B + \varepsilon_C$ (todas las perturbaciones normales estándar independientes), muestre que el coeficiente de D en la regresión de Y sobre D y C vale $4/5$. Sugerencia: aplique el teorema de Frisch-Waugh-Lovell y calcule $\mathrm{Cov}(B, D - C/3)$.
4. Justifique con la proposición de la Sección 5.2.3 por qué un intervalo $\hat{\theta} \pm 1.96\widehat{\mathrm{SE}}$ del estimador por sustitución puede tener cobertura muy por debajo de 95 % aunque $\hat{\mu}_d$ sea un buen predictor. ¿Qué condición sobre a_n lo evita?
5. La experiencia potencial es $\text{exper} = \text{edad} - \text{educ} - 6$. Muestre que, al incluirla como control en una regresión del salario sobre educ, el coeficiente de educ compara personas con distinta escolaridad **y distinta edad** (la misma experiencia potencial), de modo

que ya no mide el efecto de un año más de estudio a igual edad. ¿Qué comparación representa entonces?

5.7.2 Ejercicios computacionales

1. Reemplace `RandomForestRegressor` por `GradientBoostingRegressor` en el listado 5.1. ¿Aumenta o disminuye el sesgo del contraste predictivo? ¿Por qué?
2. Modifique el generador para que el efecto de D sea 2 en lugar de 1 y verifique si el sesgo relativo del bosque cambia. Relacione el resultado con el argumento de la fracción de varianza explicada por D.
3. Construya un conjunto sintético con una variable U no observada y verifique que el sesgo de OLS y de un bosque no disminuye al aumentar n (caso 2).
4. Ejecute el listado 5.2 y explique por qué aparece una correlación entre A y B al condicionar en C.

5.7.3 Ejercicios aplicados

1. Sobre el conjunto `close_college`, estime el retorno a la educación con (a) OLS sin controles y (b) OLS con `black`, `smsa`, `south` y `married`. No use `exper` como control: es función de la escolaridad. Compare los dos coeficientes.
2. Sobre `nsw_mixtape` (LaLonde), calcule la diferencia de medias de `re78` entre tratados y controles. Luego estime el ATE por OLS con `age`, `educ`, `black`, `hisp`, `marr`, `nodegree`, `re74` y `re75`. ¿Cuánto cambia la estimación y qué dice eso del balance observacional?

5.7.4 Notas bibliográficas

Athey (2017) ofrece la motivación conceptual del campo. Imbens y Rubin (2015) es la referencia canónica sobre resultados potenciales. Hernán y Robins (2020) presenta de forma accesible el marco contrafactual. Mullainathan y Spiess (2017) discute las diferencias prácticas entre predicción y estimación causal en políticas públicas, y Kleinberg et al. (2015) es la referencia obligada para el argumento simétrico: cuándo la pregunta de política es genuinamente predictiva, que el capítulo desarrolla en la Sección 5.1. Elwert y Winship (2014) es el tratamiento de referencia del sesgo por *collider* del tercer caso canónico. Para una revisión técnica reciente, véanse (Athey y Imbens 2019) y (Chernozhukov et al. 2018a). (Pearl 2009), disponible en español como *Causalidad*, expone en profundidad la jerarquía causal y los modelos estructurales que subyacen a la distinción entre asociación, intervención y contrafactual. Sobre el ejemplo clásico de retornos a la educación con proximidad a una universidad como instrumento, véase (Card 1995) y su tratamiento en el Capítulo 4.

CAPÍTULO 6

Regularización, selección de variables y sesgo post-selección

Cuadro sinóptico del capítulo

Problema:	Sesgo post-selección al inferir después de seleccionar variables
Estimando:	θ_0 en regresión de alta dimensión
Identificación:	No confusión condicional y esparsidad aproximada
Método:	LASSO, Ridge, Elastic Net, Post-LASSO OLS
Nuisance:	Selección de variables
Garantía:	Tasa ℓ_2 bajo *restricted eigenvalue* ((Bickel et al. 2009)); consistencia de **selección** solo bajo irrepresentabilidad ((Zhao y Yu 2006)), una condición mucho más fuerte
Librerías:	scikit-learn, numpy
Validación:	Monte Carlo con efecto conocido, sensibilidad a λ

Nota técnica

El Capítulo 5 estableció que responder una pregunta causal en alta dimensión exige seleccionar controles sin sesgar la inferencia. Este capítulo formaliza ese problema, la selección de variables y el sesgo post-selección que induce, y es, junto con el capítulo anterior, el prerrequisito técnico de Double Machine Learning (Capítulo 11, Parte II).

6.1 Problema causal, estimando e identificación

Una economista laboral quiere estimar el efecto de un programa de capacitación sobre el salario posterior. Dispone de un panel con 80 variables de control potenciales: características demográficas, historial laboral, sector, región, características del empleador, expectativas subjetivas y un conjunto de variables administrativas. No sabe cuáles de ellas son confusoras

(asociadas a la vez con la asignación al programa y con el salario) y cuáles son irrelevantes. La intuición clásica sugiere incluirlas todas, pero con 80 controles y $n = 1 \sim 000$ observaciones OLS tiene una varianza alta y poca potencia.

La salida aparentemente natural es seleccionar variables con LASSO y luego correr OLS con las seleccionadas. Es una idea peligrosa: la selección induce un sesgo en la inferencia posterior que se conoce como *post-selection inference* o inferencia selectiva. (Leeb y Pötscher 2006) y (Pötscher y Leeb 2009) mostraron que los intervalos construidos después de una selección consistente pueden tener una cobertura muy inferior a la nominal, y que el problema no desaparece con muestras grandes.

El capítulo desarrolla tres ideas. Primero, presenta LASSO, Ridge y Elastic Net como métodos de regularización con propiedades estadísticas distintas. Segundo, formaliza el sesgo post-selección y muestra por qué la inferencia ingenua puede fallar y por qué a veces no falla: la diferencia depende de qué tan fuertes sean las confusoras. Tercero, anticipa la solución, la doble selección de Belloni, Chernozhukov y Hansen (Capítulo 16), como ejemplo de cómo el ML puede integrarse con inferencia válida cuando el procedimiento respeta la estructura del problema causal.

6.2 Teoría, supuestos y garantías

6.2.1 Supuestos

Para que LASSO sea consistente en alta dimensión se requiere esparsidad: solo unas pocas componentes de β son distintas de cero. Para leer el coeficiente de D como un efecto causal se requiere además la no confusión condicional del Capítulo 5, con los controles X como conjunto de ajuste.

Supuesto 6.1 ***(Esparsidad)***

El vector verdadero β_0 tiene a lo más $s \ll n$ componentes no nulas, con $s \log p = o(n)$.

6.2.2 Estimadores penalizados

Sea el modelo lineal de alta dimensión $\boldsymbol{Y} = \boldsymbol{X}\beta + \varepsilon$, con $\boldsymbol{X} \in \mathbb{R}^{n \times p}$ y $\beta \in \mathbb{R}^p$. Cuando p es comparable a n o mayor, OLS tiene una varianza alta o ni siquiera está definido ($p > n$). Los estimadores penalizados resuelven el problema contrayendo los coeficientes hacia cero.

Definición 6.2 ***(LASSO)***

El estimador LASSO (Tibshirani 1996) resuelve

$$\hat{\beta}_{\text{LASSO}} = \underset{\beta \in \mathbb{R}^p}{\operatorname{argmin}} \left\{ \left(\frac{1}{2n} \right) \|Y - X\beta\|_2^2 + \lambda \|\beta\|_1 \right\}, \tag{6.1}$$

donde $\|\beta\|_1 = \sum_j |\beta_j|$ es la norma ℓ_1 y $\lambda \geq 0$ el hiperparámetro de penalización.

Definición 6.3 ***(Ridge)***

El estimador Ridge (Hoerl y Kennard 1970) usa la penalización ℓ_2:

$$\hat{\beta}_{\text{Ridge}} = \underset{\beta}{\operatorname{argmin}} \left\{ \left(\frac{1}{2n}\right) \|Y - X\beta\|_2^2 + \lambda \|\beta\|_2^2 \right\}. \tag{6.2}$$

Definición 6.4 ***(Elastic Net)***

Elastic Net (Zou y Hastie 2005) combina ambas penalizaciones:

$$\hat{\beta}_{\text{EN}} = \underset{\beta}{\operatorname{argmin}} \left\{ \left(\frac{1}{2n}\right) \|Y - X\beta\|_2^2 + \lambda [\alpha \|\beta\|_1 + (1-\alpha)\|\beta\|_2^2] \right\}, \tag{6.3}$$

con $\alpha \in [0,1]$ que mezcla las dos penalizaciones.

La diferencia clave es que LASSO produce *selección de variables* (algunos $\hat{\beta}_j$ son exactamente cero), mientras que Ridge solo contrae los coeficientes sin seleccionar. Elastic Net combina ambos comportamientos y es preferible cuando hay grupos de variables muy correlacionadas.

6.2.3 Garantías de estimación

Teorema 6.5 ***(Tasa de convergencia del LASSO)***

Bajo esparsidad y la *restricted eigenvalue condition* de (Bickel et al. 2009) con constante $\kappa > 0$, si $\lambda \asymp \sqrt{\log p / n}$, entonces con probabilidad alta

$$\left\| \hat{\beta}_{\text{LASSO}} - \beta_0 \right\|_1 = O_p\left(s\sqrt{\log p / n} \right), \quad \left\| \hat{\beta}_{\text{LASSO}} - \beta_0 \right\|_2 = O_p\left(\sqrt{s \log p / n} \right). \tag{6.4}$$

La tasa $\sqrt{s \log p / n}$ es óptima en el sentido minimax, salvo constantes y factores logarítmicos. Pero el teorema garantiza consistencia en norma ℓ_2, no componente a componente y menos aún del **conjunto seleccionado**. Aunque $\hat{\beta}_{\text{LASSO}}$ se acerque a β_0 en norma global, cada componente puede tener un sesgo apreciable, sobre todo las que el LASSO contrae o selecciona mal.

6.2.4 Recuperar el soporte exige mucho más que recuperar el vector

Conviene separar dos garantías que suelen confundirse, porque su diferencia motiva el resto del capítulo. El teorema anterior acota el error de **estimación** bajo la *restricted eigenvalue condition*, una condición relativamente débil. Recuperar el **soporte** $S_0 = \{j : \beta_{0,j} \neq 0\}$, es decir, que $\hat{S} = S_0$ con probabilidad tendiente a uno, requiere una condición estrictamente más fuerte sobre la correlación entre variables dentro y fuera del soporte.

Supuesto 6.6 ***(Condición de irrepresentabilidad)***

Sea X_{S_0} la submatriz de columnas activas y $X_{S_0^c}$ la de las inactivas. Existe $\eta \in (0,1]$ tal que

$$\left\| X_{S_0^c}^T X_{S_0} \left(X_{S_0}^T X_{S_0} \right)^{-1} \operatorname{sign}\left(\beta_{0,S_0} \right) \right\|_\infty \leq 1 - \eta. \tag{6.5}$$

Teorema 6.7 ***(Consistencia de selección del LASSO)***

Bajo la condición de irrepresentabilidad, condiciones de regularidad sobre el ruido y un λ apropiado, el LASSO es *sign-consistent*: $P\left(\operatorname{sign}\left(\hat{\beta}_{\text{LASSO}}\right) = \operatorname{sign}(\beta_0)\right) \to 1$. Recíprocamente, si la norma anterior es mayor que 1 en el límite, el LASSO no recupera los signos verdaderos con probabilidad tendiente a uno, para ningún valor de λ.

Este resultado, de Zhao y Yu (2006), es una mala noticia disfrazada de teorema. La condición de irrepresentabilidad no es verificable en la práctica (depende de S_0, lo desconocido) y falla justamente en el escenario que más importa para la inferencia causal: cuando una variable irrelevante está muy correlacionada con las confusoras verdaderas. La parte recíproca es la clave: no se trata de que el LASSO necesite más datos, sino de que hay diseños donde ninguna elección de λ recupera el soporte. La lección operativa es que **el conjunto seleccionado por LASSO nunca debe leerse como «las variables que verdaderamente importan»**, y que ningún procedimiento causal debería depender de que la selección sea exactamente correcta. La doble selección del Capítulo 16 se diseña bajo esa premisa: no necesita $\hat{S} = S_0$, solo que $\hat{S}$ contenga las confusoras relevantes con alta probabilidad.

6.2.5 El problema de Leeb y Pötscher

Leeb y Pötscher (2006) demostraron un resultado perturbador. Si se selecciona un subconjunto $\hat{S}$ de variables y luego se corre OLS sobre $\hat{S}$ y se reporta el intervalo habitual al 95 %, la cobertura real puede ser muy inferior.

Teorema 6.8 ***(Leeb y Pötscher: no uniformidad (esquema))***

Sea un procedimiento de selección de modelo consistente. La distribución del estimador post--selección no puede estimarse de manera uniformemente consistente respecto del parámetro, y el ínfimo, sobre el espacio de parámetros, de la cobertura del intervalo ingenuo (el que ignora la selección) puede quedar muy por debajo del nivel nominal, incluso cerca de cero, a lo largo de secuencias de coeficientes de orden $n^{-1/2}$.

Intuición

Imagine que el verdadero β_j es positivo pero muy pequeño. LASSO lo selecciona solo si la estimación preliminar de β_j es suficientemente grande. Condicionado a haber sido seleccionado, $\hat{\beta}_j$ tiende a ser mayor que β_j, un sesgo de selección análogo al sesgo de publicación. El intervalo post-selección, que no condiciona en ese hecho, queda centrado en un valor sesgado. Y lo preocupante son los coeficientes «localmente pequeños», del orden de $n^{-1/2}$: no son tan grandes como para ser seleccionados con certeza ni tan pequeños como para no importar.

6.2.6 Por qué la doble selección corrige el problema

La razón de fondo del problema, y de su solución, se ve en una descomposición del sesgo por omitir variables. Sea el modelo $Y = \theta D + \sum_j \gamma_j X_j + \varepsilon$ y sea S el conjunto de controles que se incluyen en el OLS final.

Proposición 6.9 ***(Sesgo por omisión de controles)***

Si el OLS final de Y sobre D y X_S deja fuera el conjunto S^c, el límite en probabilidad del coeficiente de D es

$$\theta + \sum_{j \in S^c} \gamma_j \delta_j, \quad \delta_j = \frac{\mathrm{Cov}(\tilde{D}_S, X_j)}{\mathrm{Var}(\tilde{D}_S)}, \tag{6.6}$$

donde $\tilde{D}_S$ es el residuo de proyectar D sobre X_S (y la constante), y δ_j es el coeficiente de $\tilde{D}_S$ en la regresión de X_j. En consecuencia, $|\text{sesgo}| \leq \sum_{j \in S^c} |\gamma_j| \; |\delta_j|$.

Demostración (esquema). Por el teorema de Frisch-Waugh-Lovell, el coeficiente de D es $\mathrm{Cov}(\tilde{D}_S, Y)/\ \mathrm{Var}(\tilde{D}_S)$. Se sustituye $Y = \theta D + \sum_{j \in S} \gamma_j X_j + \sum_{j \in S^c} \gamma_j X_j + \varepsilon$; el residuo $\tilde{D}_S$ es ortogonal a X_S y a ε, y $\mathrm{Cov}(\tilde{D}_S, D) = \mathrm{Var}(\tilde{D}_S)$. □

El sesgo es una suma de **productos**: un coeficiente de la ecuación de Y (γ_j) por una medida de cuánto se asocia X_j con D (δ_j). La selección ingenua, que mira solo la ecuación de Y, omite las variables con γ_j pequeño, sin importar cuán grande sea δ_j. Y un γ_j pequeño con un δ_j grande es justamente lo que no se puede dejar fuera. La doble selección añade la ecuación de D: una variable solo queda fuera si **ambos** coeficientes son pequeños, y entonces su producto es de segundo orden. Es la misma estructura de producto que sostiene la ortogonalidad del Capítulo 10.

6.2.7 Dos familias de respuestas

La literatura posterior a Leeb y Pötscher desarrolló dos estrategias frente al problema.

La primera es la **inferencia selectiva condicional**: aceptar que la selección ocurrió y hacer inferencia sobre la distribución de $\hat{\beta}_j$ condicionada al evento de selección. Lee et al. (2016) muestran que, para el LASSO con λ fijo, ese evento es un politopo en el espacio de Y, lo que permite construir intervalos con cobertura condicional exacta mediante una normal truncada. Es elegante, pero condiciona en un evento aleatorio y puede producir intervalos muy anchos.

La segunda es la **desregularización** (*de-biasing*): corregir de forma explícita el sesgo que la penalización introduce en la componente de interés y construir un estimador asintóticamente normal y centrado. Zhang y Zhang (2014) y Geer et al. (2014) desarrollan esta vía, que da inferencia no condicional y uniformemente válida sobre el parámetro de interés.

La segunda familia es la relevante para este libro, por una razón conceptual y no solo técnica: en un problema causal no interesa la inferencia sobre «las variables que el LASSO seleccionó», sino sobre un parámetro estructural fijado antes de mirar los datos, el efecto de D sobre Y. La doble selección (Capítulo 16) y Double Machine Learning (Capítulo 11) comparten la lógica

Algoritmo

Entrada: Datos $\{(Y_i, D_i, X_i)\}_{i=1}^n$, penalización $\lambda \geq 0$.
Salida: Estimador $\hat{\theta}$ y error estándar robusto $\hat{\sigma}$.
Ejecutar LASSO de Y sobre (D, X) con penalización λ.
Identificar $\hat{S} = \left\{j : \hat{\beta}_j \neq 0\right\}$ entre las columnas de X (la columna de D se fuerza a permanecer).
Estimar por OLS Y sobre una constante, D y $X_{\hat{S}}$.
Calcular errores estándar robustos a heterocedasticidad (HC1).
return $\hat{\theta}_{\text{OLS}}, \hat{\sigma}_{\text{HC1}}$.

Algoritmo 2. Post-LASSO OLS (selección ingenua)

de la ortogonalidad: construyen un momento insensible al error de selección o de estimación de los *nuisance*. Ninguno intenta que el LASSO seleccione bien; ambos construyen procedimientos cuya validez no depende de que lo haga.

Belloni et al. (2014) propusieron la solución para el caso causal: seleccionar dos veces, una para predecir Y con X y otra para predecir D con X, y correr OLS de Y sobre D y la unión de las variables seleccionadas.

Teorema 6.10 ***(Doble selección con LASSO (esquema))***

Bajo esparsidad aproximada, una penalización apropiada, regularidad estándar y un número de controles relevantes s con $s^2 \log^2(\max(p, n))/n \to 0$, el estimador de doble selección es asintóticamente normal con la misma varianza que un estimador que conociera el conjunto verdadero de controles (el estimador oráculo), y la inferencia con errores estándar robustos es válida. El enunciado completo, con la penalización y las condiciones, está en el Capítulo 16.

6.3 Algoritmo

El procedimiento Post-LASSO ingenuo es la práctica común que induce sesgo post-selección, y sirve de referencia para contrastar con la doble selección del Capítulo 16.

Intuición

Caja de profundización: partialling-out y doble LASSO

Objetivo. Entender dos herramientas para limpiar el efecto de las covariables antes de estimar el efecto causal.

Partialling-out. Para estimar el efecto de D sobre Y se «limpian» ambas variables de la influencia de X:

$$\tilde{Y} = Y - E[Y \mid X], \quad \tilde{D} = D - E[D \mid X]. \tag{6.7}$$

Luego se estima θ con la regresión de $\tilde{Y}$ sobre $\tilde{D}$ sin intercepto (teorema de Frisch-Waugh-Lovell).

Doble LASSO. En alta dimensión hay que seleccionar las variables relevantes:

1. LASSO de Y sobre X da S_Y, las variables que predicen Y.

2. LASSO de D sobre X da S_D, las que predicen D.
3. Unión: $S = S_Y \cup S_D$.
4. OLS de Y sobre D y los controles de S.

¿Por qué funciona? Una confusora afecta a Y y a D. Si se selecciona lo que afecta a cada uno, se capturan todas las confusoras relevantes, como muestra la proposición de la Sección 6.2.6. Esa es la base de la doble selección del Capítulo 16.

6.4 Casos canónicos y validación

Los dos casos usan un proceso generador con $\theta_0 = 1$, $n = 500$, $p = 100$ y cinco confusoras $X_0, ..., X_4$ (el resto es ruido). $D = \mathbf{1}\{X\beta_D + \varepsilon_D > 0\}$ e $Y = D + X\gamma + \varepsilon$, con ruidos normales estándar. Las cifras se calculan con 300 repeticiones, LASSO por validación cruzada de cinco pliegues y errores estándar HC1. El script es `herramientas/verificaciones/verif_cap06.py`. Las columnas son el sesgo medio, la desviación típica y la cobertura del intervalo al 95 %.

Caso canónico · Confusoras fuertes: la selección ingenua casi no sesga

Cada confusora pesa 0,7 en Y y 0,5 en D. Con $n = 500$ el LASSO las encuentra siempre (las cinco entran en las 300 repeticiones), y el procedimiento ingenuo funciona.

Procedimiento	Sesgo	Desv. típica	Cobertura
Post-LASSO ingenuo (validación cruzada)	−0,007	0,119	0,937
Doble selección (validación cruzada)	−0,025	0,116	0,943
Doble selección con λ teórico	0,002	0,112	0,953
Oráculo (OLS con las cinco confusoras)	0,002	0,112	0,953

Ningún procedimiento se equivoca de manera relevante. Es un caso útil precisamente porque desmiente la idea de que seleccionar siempre invalida la inferencia: el problema aparece cuando la señal de alguna confusora es débil.

Caso canónico · Confusoras débiles en Y y fuertes en D: el caso de Leeb y Pötscher

Cada confusora pesa 0,1 en Y (unas 2,2 veces $n^{-1/2}$, el rango de los coeficientes «localmente pequeños») y 1,0 en D. La penalización teórica sigue la fórmula de Belloni et al. (2014) del Sección 16.2.4 con $c = 1,1$.

Procedimiento	Sesgo	Desv. típica	Cobertura	Confusoras incluidas (de 5)
Post-LASSO ingenuo (validación cruzada)	0,012	0,144	0,883	4,16
Doble selección (validación cruzada)	−0,035	0,130	0,953	5,00
Post-LASSO ingenuo con λ teórico	0,206	0,135	0,453	1,49
Doble selección con λ teórico	−0,003	0,130	0,953	5,00
Oráculo	−0,003	0,130	0,953	5,00

Con λ de validación cruzada, que selecciona de forma generosa, el daño es moderado (cobertura de 0,88, con una confusora perdida en promedio). Con la penalización teórica, más estricta, el procedimiento ingenuo pierde casi todas las confusoras (incluye 1,49 de 5), el sesgo es de 0,21 y el intervalo del 95 % cubre el valor verdadero solo el 45 % de las veces. La doble selección conserva las cinco confusoras gracias a la ecuación de D y se comporta como el oráculo.

Los dos casos juntos son la lección del capítulo: la inferencia ingenua no **siempre** falla, pero no hay forma de saber desde los datos si se está en el primer caso o en el segundo, porque lo que distingue ambos es el tamaño de coeficientes desconocidos. Un procedimiento cuya validez no depende de esa distinción es lo que se necesita.

6.5 Implementación en Python

El listado reproduce el segundo caso canónico con `numpy` y `scikit-learn`, sin depender de `statsmodels`: los errores estándar HC1 se calculan a mano.

```
import numpy as np
from scipy.stats import norm
from sklearn.linear_model import Lasso, LassoCV


def generar(n=500, p=100, gamma=0.1, beta_d=1.0, k=5, seed=0):
    """theta = 1; las k primeras variables son confusoras; el resto es
ruido."""
    rng = np.random.default_rng(seed)
    X = rng.standard_normal((n, p))
    bd = np.zeros(p); bd[:k] = beta_d
    gy = np.zeros(p); gy[:k] = gamma
    D = (X @ bd + rng.standard_normal(n) > 0).astype(float)
```

```
    Y = 1.0 * D + X @ gy + rng.standard_normal(n)
    return Y, D, X


def ols_hc1(Y, D, Xs):
    """Coeficiente de D y su error estándar HC1 en OLS de Y sobre constante, D
y Xs."""
    n = len(Y)
    Z = np.column_stack([np.ones(n), D, Xs])
    b = np.linalg.lstsq(Z, Y, rcond=None)[0]
    e = Y - Z @ b
    ZtZi = np.linalg.inv(Z.T @ Z)
    meat = (Z * e[:, None]).T @ (Z * e[:, None])
    V = ZtZi @ meat @ ZtZi * n / (n - Z.shape[1])
    return b[1], np.sqrt(V[1, 1])


def alfa_teorico(y, n, p, c=1.1):
    """Penalización tipo Belloni-Chernozhukov-Hansen en la escala de
sklearn."""
    gamma = 0.1 / np.log(max(n, p))
    return c * y.std() * norm.ppf(1 - gamma / (2 * p)) / np.sqrt(n)


def seleccionar(modelo, X, y):
    return np.abs(modelo.fit(X, y).coef_) > 1e-8


def post_lasso_ingenuo(Y, D, X, alfa=None):
    """LASSO de Y sobre [D, X]; OLS final con D forzada y las columnas
seleccionadas."""
    n, p = X.shape
    modelo = LassoCV(cv=5) if alfa is None else Lasso(alpha=alfa,
max_iter=5000)
    sel = seleccionar(modelo, np.column_stack([D, X]), Y)[1:]
    return ols_hc1(Y, D, X[:, sel])


def doble_seleccion(Y, D, X, alfa_y=None, alfa_d=None):
    """Unión de lo que predice Y y lo que predice D."""
    m_y = LassoCV(cv=5) if alfa_y is None else Lasso(alpha=alfa_y,
max_iter=5000)
    m_d = LassoCV(cv=5) if alfa_d is None else Lasso(alpha=alfa_d,
max_iter=5000)
    sel = seleccionar(m_y, X, Y) | seleccionar(m_d, X, D)
    return ols_hc1(Y, D, X[:, sel])
```

```
def monte_carlo(reps=300, **dgp):
    filas = {"ingenuo (CV)": [], "ingenuo (teórico)": [], "doble selección
(teórico)": [], "oráculo": []}
    for r in range(reps):
        Y, D, X = generar(seed=r, **dgp)
        n, p = X.shape
        a = alfa_teorico(Y, n, p)
        filas["ingenuo (CV)"].append(post_lasso_ingenuo(Y, D, X))
        filas["ingenuo (teórico)"].append(post_lasso_ingenuo(Y, D, X,
alfa=alfa_teorico(Y, n, p + 1)))
        filas["doble selección (teórico)"].append(doble_seleccion(Y, D, X,
alfa_teorico(Y, n, p), alfa_teorico(D, n, p)))
        filas["oráculo"].append(ols_hc1(Y, D, X[:, :5]))
    for nombre, v in filas.items():
        b, se = np.array(v).T
        print(f"{nombre:28s} sesgo={b.mean() - 1:+.3f}  sd={b.std(ddof=1):.3f}
cobertura={np.mean(np.abs(b - 1) <= 1.96 * se):.3f}")


if __name__ == "__main__":
    # Prueba de coherencia: el oráculo debe quedar cerca de 1 en una sola
réplica.
    Y, D, X = generar(seed=0)
    assert abs(ols_hc1(Y, D, X[:, :5])[0] - 1.0) < 0.5
    monte_carlo()
```

Listado 6.1: Sesgo post-selección: Post-LASSO ingenuo, doble selección y oráculo con efecto conocido.

La cobertura se calcula con el error estándar estimado en cada réplica, no con la dispersión de los $\hat{\theta}$ entre réplicas. Con $\gamma = 0.7$ y $\beta_D = 0.5$ el mismo código reproduce el primer caso canónico.

```
import numpy as np
from sklearn.linear_model import LassoCV


def partialling_out_theta(Y, D, X):
    """Estima theta limpiando Y y D de la influencia de X con LASSO (sin cross-
fitting)."""
    y_res = Y - LassoCV(cv=5).fit(X, Y).predict(X)
    d_res = D - LassoCV(cv=5).fit(X, D).predict(X)
    return np.mean(d_res * y_res) / np.mean(d_res * d_res)
```

Listado 6.2: Partialling-out manual con LASSO.

Este partialling-out ajusta y evalúa en la misma muestra. Es una ilustración del mecanismo: la versión con *cross-fitting* es la del Capítulo 10.

6.6 Riesgos, límites y sensibilidad

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Inferir después de seleccionar con una sola ecuación	Confusoras débiles en Y quedan fuera; cobertura inválida (45 % en el segundo caso canónico)	Monte Carlo bajo un proceso plausible; comparar la selección con la de la ecuación de D	Doble selección o ortogonalización (Capítulo 16, Capítulo 11)
Leer el conjunto seleccionado como «las variables importantes»	Interpretación causal de la selección	Estabilidad de la selección con submuestreo	Reportar el efecto de D, no la lista de variables
Interpretar un coeficiente de LASSO como causal	Sesgo de contracción	Comparar con Post-LASSO y con OLS completo si $p < n$	Post-LASSO o Double Machine Learning
λ inestable	Selección frágil	Resultados para varios valores de λ	Reportar la penalización de validación cruzada y la teórica

Tabla 6.1: Riesgos de la selección de variables en problemas causales.

Límites del enfoque. La doble selección asume esparsidad aproximada: pocas variables son realmente confusoras. Si la confusión es densa (muchas variables pequeñas que importan colectivamente), la selección con penalización teórica puede fallar y se prefiere Double Machine Learning (Capítulo 11), que no exige esparsidad estricta; el Sección 16.2.7 lo muestra con cifras. Además, la doble selección es un método de regresión lineal: para heterogeneidad estructurada en X se usan bosques causales (Capítulo 13) o meta-learners (Capítulo 12).

- ☐ **Verificar la cobertura empírica:** ejecutar un Monte Carlo bajo el proceso generador supuesto y confirmar que los intervalos post-selección alcanzan la cobertura nominal.
- ☐ **Sensibilidad a λ:** reportar resultados para varios valores de λ (por ejemplo, el de validación cruzada y el teórico) y verificar que la selección y el coeficiente de D no cambian de manera drástica.
- ☐ **Estabilidad de la selección:** usar *bootstrap* o submuestreo para ver qué fracción de las veces entra cada variable.
- ☐ **Comparar con OLS completo:** si $p < n$, contrastar el Post-LASSO con OLS sin selección para medir el costo de la regularización.
- ☐ **Reportar ambos:** presentar siempre el Post-LASSO ingenuo junto con la doble selección, para transparentar el efecto de la ecuación de D.

6.7 Ejercicios y notas bibliográficas

6.7.1 Ejercicios teóricos

1. Demuestre que Ridge no hace selección de variables: muestre que $\hat{\beta}_{\text{Ridge}}$ tiene todas sus componentes distintas de cero en general. ¿Por qué es preferible a LASSO cuando hay grupos de variables muy correlacionadas?
2. Con dos regresores X_1, X_2 de varianza 1 y correlación ρ, y $\beta_0 = (1, 0)$, calcule el lado izquierdo de la condición de irrepresentabilidad y encuentre para qué valores de ρ se cumple.
3. Complete la demostración de la proposición de la Sección 6.2.6 y calcule, para el segundo caso canónico, el sesgo de omitir las cinco confusoras. Compare con 0,206, el sesgo observado del procedimiento ingenuo con λ teórico, que incluye 1,49 de ellas en promedio.
4. Explique con la proposición de la Sección 6.2.6 por qué una confusora con γ_j pequeño y δ_j grande es omitida por la selección ingenua pero incluida por la doble selección, y por qué una con ambos pequeños puede omitirse sin consecuencias de primer orden.

6.7.2 Ejercicios computacionales

1. Replique el listado 6.1 variando $p \in \{20, 50, 100, 200\}$. ¿Cómo cambian el sesgo y la cobertura con la dimensión?
2. Con el mismo proceso, barra γ en $\{0.05, 0.1, 0.3, 0.7\}$ y trace la cobertura del procedimiento ingenuo con λ teórico. ¿A partir de qué γ deja de ser un problema?
3. Implemente la función `partialling_out_theta` del listado 6.2 y verifique que recupera θ en un proceso lineal. ¿Qué pasa si X contiene variables de ruido puro?
4. Sobre el conjunto `nhefs`, compare (a) OLS con cinco controles elegidos a mano, (b) LASSO ingenuo y (c) doble selección. Compare los tres estimadores y sus errores estándar.

6.7.3 Notas bibliográficas

Tibshirani (1996) y Hoerl y Kennard (1970) son las referencias originales. Hastie et al. (2015) ofrece un tratamiento moderno de la regularización en alta dimensión. Bickel et al. (2009) establece la tasa ℓ_2 bajo *restricted eigenvalue* y Zhao y Yu (2006) la condición de irrepresentabilidad y su recíproca para la consistencia de selección; leerlos en secuencia es la forma más económica de internalizar por qué «el LASSO funciona» significa cosas muy distintas según lo que se le pida. Leeb y Pötscher (2006) y Pötscher y Leeb (2009) son las referencias obligadas sobre el problema de la inferencia post-selección; Lee et al. (2016) desarrolla la vía de la inferencia selectiva condicional, y Zhang y Zhang (2014) junto con Geer et al. (2014) la de *de-biasing*, que es la que este libro sigue. Belloni et al. (2014) introduce la doble selección. Para una revisión pedagógica, véase (Chernozhukov et al. 2018a).

CAPÍTULO 7

Datos de entrenamiento en sistemas causales

Cuadro de decisión del capítulo

Decisión:	Tratar la asignación del tratamiento como parte del proceso de muestreo a auditar, no como un dato dado
Alternativas:	Usar los datos «tal como llegan» vs. auditar explícitamente el mecanismo de asignación
Trade-off clave:	Velocidad de arranque vs. riesgo de sesgo de selección no detectado
Stack:	pandas, `pandera`, tests de balance
Riesgo principal:	Confundir «faltante al azar» con «faltante por selección relacionada al tratamiento»

7.1 El problema de diseño

Huyen (2022) dedica su Capítulo 4 a una idea que la comunidad de *machine learning* tarda en internalizar: los datos de entrenamiento casi nunca son una muestra aleatoria simple del universo sobre el que luego se aplicará el modelo, y cómo se generaron (el proceso de muestreo, cómo se etiquetó, qué faltó y por qué) determina la validez de cualquier cosa que se entrene sobre ellos. En un sistema **causal** este problema no es solo una amenaza a la precisión predictiva: es una amenaza directa a la **identificación**. Si la asignación del tratamiento en los datos históricos está relacionada con variables no observadas, ningún ajuste posterior por covariables observadas, por sofisticado que sea el estimador, corrige el problema. El problema de diseño de este capítulo es entonces: ¿cómo se estructuran la recolección y el muestreo de los datos de entrenamiento para que las amenazas a la identificación queden documentadas y, cuando sea posible, mitigadas, en lugar de descubrirse después de haber estimado el efecto?

No es un problema que se resuelva una sola vez. Un sistema desplegado genera él mismo la asignación de los datos futuros (Capítulo 2), de modo que cada reentrenamiento hereda una asignación que condicionó el sistema anterior. La auditoría de este capítulo se repite en cada reentrenamiento y se reutiliza como señal de monitoreo (Capítulo 30).

7.2 Opciones y trade-offs

Opciones y trade-offs

- **Usar los datos «tal como llegan».** Se toma el conjunto de datos disponible y se procede directamente a la estimación. Es la opción más rápida y, en la práctica, la más común. El riesgo es que el mecanismo de asignación del tratamiento (quién decidió, con qué información, a quién tratar) quede completamente implícito, y que cualquier sesgo de selección relacionado con variables no observadas nunca se detecte porque nadie lo buscó explícitamente.
- **Auditar el mecanismo de asignación antes de estimar.** Se documenta explícitamente, para el conjunto de datos en cuestión: ¿la asignación fue aleatorizada, cuasi-aleatorizada (por ejemplo, un umbral administrativo) u observacional pura? ¿Qué información tenía quien decidió asignar el tratamiento, y coincide con las covariables observadas en los datos? Este paso no reemplaza el análisis de identificación de los capítulos anteriores: lo **precede**, y a menudo revela qué covariables son plausiblemente suficientes para el criterio de puerta trasera antes de intentar ajustar ningún modelo.

Un segundo trade-off, heredado de la discusión de Huyen (2022) sobre «etiquetas naturales», es específico de los sistemas causales. En muchos casos el «tratamiento» es una decisión que ya ocurrió en el pasado dentro de un proceso administrativo o de negocio (a quién se le otorgó un crédito, a quién se le dio un descuento). Estas asignaciones pasadas tienen la ventaja de estar disponibles a bajo costo, pero la desventaja de que la regla de decisión histórica, a menudo no documentada, es exactamente la fuente potencial de confusión que el análisis de identificación debe descubrir.

7.3 Decisión de referencia para el curso

El libro exige que todo conjunto de datos usado para estimar vaya acompañado de una **ficha de procedencia del tratamiento**, una extensión del esquema de datos del Capítulo 4 que documenta, como mínimo: el mecanismo de asignación (aleatorizado, cuasi-experimental u observacional), la relación temporal entre la asignación y la medición del resultado, y cualquier regla de elegibilidad conocida. Completar la ficha es un requisito previo a cualquier estimación, y es parte de la entrega del Notebook de caso de estudio A1 (Capítulo 4). Es la versión operacional del «problema causal, estimando e identificación» que abre cada capítulo de Plantilla A.

La ficha de procedencia no se queda en un cuaderno de trabajo. El mecanismo de asignación es el tipo de diseño de identificación que declara la ficha del modelo (Capítulo 19), y la fuente de los datos es lo que esa ficha registra junto con su huella. Cuando la ficha de procedencia cambia (otra regla de elegibilidad, otro canal de asignación), el modelo entrenado con los datos anteriores deja de tener una procedencia válida, aunque su código no haya cambiado.

7.4 El chequeo de balance

La herramienta mínima para auditar el mecanismo de asignación es el **chequeo de balance**: comparar la distribución de cada covariable entre tratados y controles. Aquí conviene ser preciso sobre qué estadístico usar, porque la elección por defecto, un t-test por covariable, es la equivocada por dos razones independientes.

Primero, el t-test responde la pregunta incorrecta. Su p-valor mezcla el tamaño de la diferencia con el tamaño de la muestra: con n grande, diferencias irrelevantes resultan «significativas»; con n pequeño, desbalances severos pasan el test. Pero lo que amenaza la identificación es la **magnitud** del desbalance (cuánta extrapolación tendrá que hacer el estimador) y no si esa magnitud es distinguible de cero. El estadístico apropiado es por tanto una medida de tamaño de efecto, la **diferencia media estandarizada** (SMD, también llamada *standardized bias*):

$$\mathrm{SMD}_j = \frac{\overline{X}_{j,1} - \overline{X}_{j,0}}{\sqrt{\left(s_{j,1}^2 + s_{j,0}^2\right)/2}}, \tag{7.1}$$

que es invariante a las unidades de medida y no crece con n. Rubin (2001) propone dos criterios operativos que se han vuelto convencionales: $|\mathrm{SMD}_j| < 0.25$ (por convención, más exigente, < 0.1) y una razón de varianzas $s_{j,1}^2 / s_{j,0}^2$ dentro de $[0.5, 2]$. El segundo criterio importa y suele olvidarse: dos grupos pueden tener la misma media y distribuciones tan distintas en dispersión que el soporte común sea escaso en las colas, lo que compromete el supuesto de solapamiento antes que el de no confusión.

Segundo, si aun así se reportan p-valores (y hay una razón legítima para hacerlo cuando la asignación **debería** haber sido aleatoria, como en la submuestra experimental de un RCT), evaluar p covariables al 5 % produce por construcción $\approx 0.05p$ rechazos espurios. Con 40 covariables, esperar dos «desbalances significativos» bajo aleatorización perfecta es lo normal, no una anomalía. Cualquier lectura del chequeo debe corregir por comparaciones múltiples (Holm o Benjamini–Hochberg) o, mejor, apoyarse en la distribución completa de las SMD.

Caso canónico · Cuarenta covariables y dos mecanismos de asignación

Cuarenta covariables independientes, normales estándar. En el primer mecanismo el tratamiento se asigna con una moneda justa. Se simulan 200 experimentos de 500 unidades y en cada uno se cuenta cuántas covariables rechaza el t-test al 5 %. En el segundo, 2 000 unidades reciben el tratamiento con probabilidad $\sigma(1.2X_0)$, es decir, la asignación depende solo de X_0.

Bajo aleatorización perfecta, el p-valor crudo rechazó en 1,98 covariables por experimento en promedio, y con la corrección de Holm en 0,05. Con asignación que depende de X_0, la SMD de esa covariable fue 1,12, la bandera del criterio de 0,25 se activó solo para ella y ninguna de las otras 39 la activó.

Un número alto de covariables desbalanceadas no invalida por sí solo el análisis observacional (es, de hecho, la situación esperada cuando la asignación no fue aleatoria) y, sobre todo, **no es el chequeo el que identifica el efecto**: el balance en las covariables observadas no dice nada sobre las no observadas, que son las que rompen la no confusión. Lo que el chequeo aporta es más modesto y más útil: cuantifica cuánta corrección tendrá que hacer el estimador, y por tanto cuánto de la estimación final descansará en extrapolación del modelo en vez de en comparaciones respaldadas por datos. Una SMD de 1,5 en una covariable relevante advierte que el estimador comparará poblaciones con poco solapamiento efectivo, mucho antes de que un diagnóstico de *propensity score* lo revele en el Capítulo 11.

Dos lecturas específicas del reporte merecen atención. Si covariables que **deberían** ser irrelevantes para la asignación (por ejemplo, una característica administrativa sin relación aparente con el criterio de elegibilidad) resultan fuertemente desbalanceadas, es señal de que el mecanismo de asignación real difiere del documentado, y amerita revisar el DAG propuesto antes de proceder. Y si el porcentaje de faltantes difiere sistemáticamente entre tratados y controles, el problema ya no es de balance sino de selección sobre quién aparece en los datos. Si la ausencia depende de variables observadas, se puede corregir reponderando. Si depende del propio resultado no observado, el faltante es no aleatorio en el sentido de Rubin (1976) y ningún ajuste por covariables observadas lo corrige.

El mismo chequeo se reutiliza más adelante con otro propósito. Aplicado a datos de entrenamiento contra una ventana reciente, es la primera señal del monitoreo (Capítulo 30). Aplicado a los datos de un modelo reentrenado contra los de la versión vigente, es la comparación de poblaciones de la regla de promoción (Capítulo 31). En los dos casos el umbral se calibra con muestras de la misma población y no se hereda de la convención.

7.5 El contrato de la comparación de poblaciones

El chequeo de balance no sirve solo para este capítulo. El libro lo usa con tres pares de poblaciones: tratados y controles (aquí), datos de entrenamiento y ventana reciente (Capítulo 30) y versión vigente y datos de un candidato (Capítulo 31). Lo que se fija es la comparación

de poblaciones, con el formato del C-01 (Sección 4.4), de modo que los tres usos compartan sus reglas.

Contrato C-02 · Comparación de poblaciones

Operaciones	*comparar*: recibe dos poblaciones de unidades, descritas por las covariables del esquema (C-01), y devuelve para cada covariable la diferencia media estandarizada, la razón de varianzas y una bandera por cada criterio.
Entrada	Las dos poblaciones, con las covariables del esquema. Los criterios: el umbral de la diferencia estandarizada y el intervalo admitido para la razón de varianzas, escritos antes de mirar los datos y calibrados para el tamaño de las muestras (regla del Sección 30.3).
Salida	Una fila por covariable con la diferencia estandarizada (con signo), la razón de varianzas y las dos banderas. Si se piden p--valores, se corrigen por comparaciones múltiples y se rotulan como secundarios.
Invariantes	(1) El estadístico principal mide tamaño de efecto y no crece con el número de unidades; ningún p-valor decide por sí solo. (2) Intercambiar las poblaciones cambia el signo de la diferencia, invierte la razón de varianzas y deja las banderas igual. (3) Con las mismas poblaciones el resultado es idéntico. (4) El umbral se calibra con muestras de una misma población y se fija antes de comparar; no se hereda de la convención. (5) Los valores faltantes no entran en el cálculo, así que una diferencia en la proporción de faltantes entre las poblaciones no aparece en la comparación y se mide aparte. (6) La comparación habla solo de covariables observadas.
Modos de fallo	Una muestra pequeña con el umbral de la convención: la bandera se enciende con ruido. Un umbral relajado después de ver el resultado. Un p-valor no significativo leído como ausencia de desbalance. Un faltante diferencial que la comparación no ve. Un balance perfecto en lo observado leído como prueba de que no hay confusión.
Prueba de aceptación	(a) Se reproduce el caso canónico de este capítulo: con la moneda justa los rechazos crudos rondan el 5 % de las covariables y los de Holm casi no aparecen, y con asignación que depende de X_0 se activa la bandera de X_0 y ninguna otra. (b) Intercambiar las poblaciones cumple el invariante (2). (c) Con dos muestras de una misma población, la frecuencia de banderas se mide y se compara con la que dio la calibración; con una muestra pequeña

> y el umbral de la convención, supera a la calibrada. (d) Con un faltante diferencial inyectado y sin diferencias en lo observado, la comparación no señala nada y la medida aparte sí.

Tamaño de efecto y no p-valor. Lo que amenaza la identificación es cuánta extrapolación tendrá que hacer el estimador, no si esa magnitud se distingue de cero. Un estadístico que crece con n cambia de veredicto cuando cambia el tamaño de la muestra, y las tres comparaciones del libro se hacen con muestras de tamaños muy distintos.

El umbral se calibra y se fija antes. El valor de 0,25 es un punto de partida razonable para decidir qué desbalance importaría, pero con pocas unidades la diferencia entre dos muestras de la misma población ya lo supera con frecuencia. Medir esa frecuencia, y escribir el umbral antes de comparar, evita relajarlo hasta que el resultado sea el esperado.

Solo lo observado. El contrato dice con todas las letras que no cubre las covariables que nadie midió ni la selección sobre quién aparece en los datos. Si no lo dijera, un chequeo limpio se leería como una garantía de identificación.

7.6 Implementación de referencia

El listado calcula, para cada covariable, la SMD, la razón de varianzas, el p-valor crudo y el ajustado por Holm, y las dos banderas de los criterios anteriores.

```
import numpy as np
import pandas as pd
from scipy.stats import ttest_ind


def chequeo_balance(df, tratamiento, covariables, smd_max=0.25, razon_var=(0.5,
2.0)):
    """Balance entre tratados y controles. Devuelve una fila por covariable con
la
    diferencia media estandarizada (SMD), la razon de varianzas, el p-valor
crudo
    y el p-valor ajustado por Holm, mas las dos banderas de los criterios de
Rubin."""
    T, C = df[df[tratamiento] == 1], df[df[tratamiento] == 0]
    filas = []
    for c in covariables:
        v_t, v_c = T[c].var(), C[c].var()
        filas.append({
            "covariable": c,
            "smd": (T[c].mean() - C[c].mean()) / np.sqrt((v_t + v_c) / 2),
            "razon_var": v_t / v_c,
            "p_crudo": ttest_ind(T[c], C[c], equal_var=False).pvalue,
        })
```

```
    r = pd.DataFrame(filas).set_index("covariable")
    # Holm: p ordenados, cada uno por (m - rango), forzando monotonia y
truncando a 1
    orden = r["p_crudo"].sort_values()
    m = len(orden)
    holm = np.minimum(1.0, np.maximum.accumulate(orden.to_numpy() * (m -
np.arange(m))))
    r["p_holm"] = pd.Series(holm, index=orden.index)
    r["viola_smd"] = r["smd"].abs() > smd_max
    r["viola_razon_var"] = ~r["razon_var"].between(*razon_var)
    return r

# Uso: resumen = chequeo_balance(df, esquema.treatment, esquema.covariates)
(esquema: C-01, Cap. 4)
#      print(resumen.round(3)); print(resumen[["viola_smd",
"viola_razon_var"]].sum())
```

Listado 7.1: Chequeo de balance: SMD, razón de varianzas y p-valores con corrección de Holm.

El ajuste de Holm del listado coincide con una implementación independiente, y las cifras del caso canónico salen de una simulación con semilla declarada que ejecuta este mismo listado. Está en `herramientas/verificaciones/verif_cap07.py`.

7.7 Aplicación al sistema causal del curso

LaLonde (1986) comparó las estimaciones de métodos econométricos observacionales contra el *benchmark* experimental del programa NSW y encontró que diferían sustancialmente, el resultado que fundó la literatura moderna de evaluación de programas. Dehejia y Wahba (1999) reexaminaron el mismo caso construyendo la extensión observacional (submuestras de CPS y PSID como controles) que sigue siendo el banco de pruebas estándar del campo.

Su utilidad pedagógica aquí es que ofrece los dos regímenes con el mismo tratamiento y el mismo resultado. La submuestra experimental tiene asignación aleatorizada por diseño, y el chequeo de balance debería mostrar SMD pequeñas. La extensión observacional no la tiene, y las tablas descriptivas de Dehejia y Wahba (1999) muestran grupos de comparación muy distintos de los tratados, de modo que el mismo chequeo debería mostrar SMD grandes en varias covariables. Aplicar el chequeo a ambas versiones y comparar las dos distribuciones de SMD es la forma más directa de ver, en números y no en abstracto, qué significa que un conjunto de datos sea o no «como aleatorizado». El Notebook A1 usa este caso por esa razón.

7.8 Señales de alerta y checklist operativo

- ☐ Nadie en el equipo puede explicar, en una oración, cómo se decidió históricamente quién recibía el tratamiento.
- ☐ No se ejecutó ningún chequeo de balance de covariables antes de estimar el efecto, o no se repite en cada reentrenamiento.

- ☐ Existen valores faltantes en el resultado Y que están sistemáticamente relacionados con el tratamiento (posible sesgo de selección en el seguimiento, no solo en la asignación).
- ☐ La ficha de procedencia del tratamiento no distingue si la asignación fue anterior o posterior a la medición de alguna covariable «de control».
- ☐ La ficha de procedencia no se actualizó cuando cambió la regla de asignación, y el modelo vigente sigue declarando la procedencia anterior.
- ☐ Se reporta el p-valor del t-test por covariable sin corrección por comparaciones múltiples, o se lee un desbalance «no significativo» en una muestra pequeña como ausencia de desbalance.

7.9 Ejercicios y notas bibliográficas

7.9.1 Ejercicios conceptuales

1. Para el conjunto de datos de becas del Capítulo 1, redacte una ficha de procedencia del tratamiento hipotética, incluyendo el mecanismo de asignación más plausible.
2. Explique por qué un desbalance fuerte en una covariable **administrativa, sin relación aparente con el criterio de elegibilidad** es una señal de alerta más seria que un desbalance en una covariable directamente relacionada con dicho criterio.
3. Un sistema reentrena cada mes con los datos del mes anterior, en los que la asignación la decidió el modelo vigente. Explique qué esperaría ver en el chequeo de balance de esos datos y qué le diría sobre la identificación; piense en el solapamiento si la regla del modelo vigente es determinista.

7.9.2 Ejercicio computacional

1. Aplique el listado 7.1 a las dos versiones del conjunto de datos de Lalonde (experimental y observacional). Reporte, para cada una, la distribución de SMD y cuántas covariables violan cada criterio de Rubin, y relacione el resultado con el mecanismo de asignación de cada submuestra.
2. Sobre la submuestra **experimental** (donde la asignación fue aleatoria por diseño), compare cuántas covariables resultan «significativas» con p crudo al 5 % frente a cuántas lo son con la corrección de Holm. Explique por qué el primer número no es evidencia de que la aleatorización haya fallado.

7.9.3 Notas bibliográficas

Huyen (2022), Capítulo 4, desarrolla en detalle el rol del muestreo y las «etiquetas naturales» en sistemas de ML generales. La lógica del chequeo de balance como diagnóstico de identificación es estándar en la literatura de evaluación de programas: Imbens y Rubin (2015) ofrece su tratamiento formal completo, y Rubin (2001) es la fuente de los criterios operativos (SMD y razón de varianzas), en el contexto de diseño de estudios observacionales sin mirar el resultado.

Rosenbaum y Rubin (1983) es la referencia fundacional del *propensity score*, que el Capítulo 11 usará como componente *nuisance* y que ofrece la versión resumida de este mismo diagnóstico en una sola dimensión. LaLonde (1986) y Dehejia y Wahba (1999) son las referencias del caso NSW usado en el Notebook A1. Sobre datos faltantes y la distinción MCAR/MAR/MNAR que subyace al diagnóstico de faltantes diferenciales, la referencia canónica es Rubin (1976).

CAPÍTULO 8

Razonamiento intervencional y contrafactual

Cuadro sinóptico del capítulo

Problema:	Decidir, a partir de un grafo causal, qué controles identifican el efecto y cuáles lo sesgan
Estimando:	$P(y \mid \mathrm{do}(x))$ y $P(y_x \mid e)$
Identificación:	Criterio de puerta trasera (*backdoor*); las tres reglas del cálculo-do; puerta delantera (*front-door*)
Método:	Ajuste por puerta trasera; abducción-acción-predicción para contrafactuales
Garantía:	Si el criterio de puerta trasera se satisface, $P(y \mid \mathrm{do}(x)) = \sum_z P(y \mid x, z)P(z)$. El cálculo-do es completo: si sus reglas no identifican el efecto, ningún método lo hace con ese grafo
Librerías:	`dowhy`, `networkx`
Validación:	Verificación algorítmica del criterio sobre el grafo propuesto

8.1 Problema causal, estimando e identificación

El Capítulo 3 dejó pendiente una pregunta operativa: dado un grafo causal y un conjunto de variables observadas, ¿cómo se determina **qué controles incluir** para que un ajuste estadístico (una regresión, un *matching*, un DML) recupere $P(y \mid \mathrm{do}(x))$ en lugar de $P(y \mid x)$? La intuición de «controlar por todo lo que se pueda medir» es, como muestra este capítulo, no solo insuficiente sino activamente peligrosa: hay variables que, al controlarlas, **introducen** sesgo donde no lo había. Este capítulo formaliza el criterio que resuelve la pregunta, el criterio de puerta trasera, y extiende el procedimiento de cómputo contrafactual que adelantó el Capítulo 3.

8.2 Teoría, supuestos y garantías

8.2.1 El criterio de puerta trasera

Definición 8.1 ***(Criterio de puerta trasera)***

Un conjunto de variables Z satisface el **criterio de puerta trasera** relativo a un par ordenado (X, Y) en un grafo G si: **(i)** ningún nodo de Z es descendiente de X, y **(ii)** Z bloquea todo camino entre X e Y que contenga una flecha **hacia** X (un «camino de puerta trasera»).

Teorema 8.2 ***(Fórmula de ajuste de puerta trasera)***

Si Z satisface el criterio de puerta trasera relativo a (X, Y), entonces el efecto causal de X sobre Y es identificable y está dado por la **fórmula de ajuste**:

$$P(y \mid \mathrm{do}(x)) = \sum_{z} P(y \mid x, z)\, P(z) \tag{8.1}$$

Demostración (esquema). La condición **(i)** garantiza que condicionar en Z no bloquea el efecto de X sobre Y a través de las rutas causales (no se controla por un mediador) ni abre rutas espurias a través de un descendiente de X. La condición **(ii)** garantiza que Z bloquea toda ruta espuria, es decir, toda confusión, entre X e Y. Bajo ambas, condicionar en Z dentro de cada estrato hace que X esté «como aleatorizado», y promediar sobre la distribución de Z recupera la distribución interventiva poblacional. □

El supuesto de «no confusión condicional» (*unconfoundedness*) que los capítulos anteriores usaron sin más formalidad, y que sustenta a DML, a los meta-learners y a los bosques causales de la Parte II, tiene en el criterio de puerta trasera su versión gráfica: si las covariables observadas X satisfacen el criterio relativo al tratamiento y al resultado, la no confusión condicional se cumple. El criterio es una condición suficiente que se lee directamente sobre el grafo. Este capítulo no cambia ningún método de estimación posterior; cambia **cómo se justifica**, con un grafo explícito, la elección de qué controlar.

8.2.2 Buenos y malos controles

El criterio de puerta trasera implica una clasificación de variables candidatas a control que conviene memorizar, porque en la práctica aplicada el error de incluir un mal control es más frecuente que el de omitir un confusor:

Tipo de variable	**Rol en el grafo**	**¿Controlar?**
Confusor	Causa común de X e Y (afecta a ambos)	**Sí**, es necesario para la puerta trasera
Mediador	Está en la ruta causal $X \to M \to Y$	**No**: bloquea parte del efecto que se quiere medir

Tipo de variable	Rol en el grafo	¿Controlar?
Collider	Es afectado tanto por X como por Y (o por sus causas)	**No**: condicionar en él **crea** una asociación espuria (ver Sección 1.2)
Instrumento	Afecta a Y solo a través de X y no comparte causa con Y	**No** como control directo: se usa de otro modo (Parte III, DML-IV) y, si queda confusión no observada, controlarlo amplifica el sesgo
Variable post-tratamiento	Medida después de X, potencialmente afectada por él	**No**: riesgo de ser mediador o collider sin que el analista lo note

La fila de mediadores explica formalmente algo que el Capítulo 4 mencionó sin desarrollar: por qué una variable «post-tratamiento» es peligrosa como control, aunque parezca un predictor razonable de Y. Con probabilidad no trivial es un mediador (se controla por parte del efecto que se busca medir) o un collider (se introduce sesgo de selección). La fila de colliders es la que más sorprende a quien viene del *machine learning* predictivo, porque contradice el reflejo de «controlar por todo». Elwert y Winship (2014) documentan cómo este **sesgo de selección endógena** aparece de forma encubierta en la práctica aplicada, y no solo al añadir un control explícito: aparece cada vez que la muestra misma se define condicionando en una variable afectada por el tratamiento (restringir el análisis a quienes completaron el programa, a quienes siguen siendo clientes, a quienes respondieron la encuesta de seguimiento). Su tratamiento formal está en esa misma referencia.

En un sistema en producción, esta tabla es la regla que aplica la auditoría de *features* (contrato C-03 del Capítulo 9): el rol declarado de cada candidata decide si entra o no en la matriz de covariables.

Caso canónico · Cuatro controles con verdad conocida

Primer mundo, sin confusión no observada. La covariable C es un confusor observado: $X = 0.8C + \varepsilon_X$. El mediador es $M = 0.5X + \varepsilon_M$ y el resultado es $Y = 0.7X + 0.6M + C + \varepsilon_Y$, de modo que el efecto total de X vale $0.7 + 0.6 \times 0.5 = 1$. Una cuarta variable, $K = 0.6X + 0.6Y + \varepsilon_K$, es un collider. Con 5 000 unidades y 200 repeticiones, la regresión de Y sobre X y cada conjunto de controles estima:

Controles	Efecto estimado
Ninguno	1,49
C (el confusor)	1,00
C y M (más el mediador)	0,70
C y K (más el collider)	0,34

La desviación entre repeticiones es de alrededor de 0,02. Controlar por el confusor recupera el efecto; añadir el mediador lo reduce a su parte directa, y añadir el collider lo destruye.

Segundo mundo, con confusión no observada y sin mediador ni collider: $X = 0.8C + Z + U + \varepsilon_X$ e $Y = X + C + U + \varepsilon_Y$, donde U no se observa y Z es un instrumento, porque solo llega a Y a través de X. El efecto de X vale 1. Controlar por C deja un sesgo de 0,33 (estima 1,33), y controlar además por Z lo amplía a 0,50 (estima 1,50). Es la amplificación de sesgo que describe Pearl (2010): el instrumento explica parte de la variación de X que no tiene relación con U, y al condicionar en él la variación restante de X está más cargada de U.

8.2.3 Las tres reglas del cálculo-do

Este capítulo formaliza el **criterio de puerta trasera** con su prueba. Las tres reglas del **cálculo-do** (**do-calculus**, (Pearl 2009)) proporcionan un sistema para determinar la identificabilidad causal en grafos arbitrarios.

El criterio de puerta trasera resuelve el caso más frecuente, pero no es la herramienta general. Hay grafos donde ningún conjunto observado satisface el criterio y, sin embargo, el efecto **sí** es identificable por otra vía. La herramienta completa es el **cálculo-do**: tres reglas de reescritura que transforman una expresión con el operador do() en otra equivalente, con el objetivo de eliminar todos los do y quedar con una fórmula puramente observacional, es decir, estimable con los datos.

La notación requiere dos operaciones de «cirugía» sobre el grafo G. Escribimos $G_{\overline{X}}$ para el grafo que resulta de **borrar todas las flechas que entran** a los nodos de X (el grafo bajo la intervención do(x), donde X deja de responder a sus causas) y $G_{\underline{Z}}$ para el que resulta de **borrar todas las flechas que salen** de los nodos de Z. Ambas operaciones pueden combinarse. La relación $(A \perp\!\!\!\perp B \mid C)_G$ denota d-separación de A y B dado C en el grafo G.

Teorema 8.3 ***(Cálculo-do)***

Sea G el grafo causal de un SCM y sean X, Y, Z, W conjuntos disjuntos de nodos. Las tres igualdades siguientes son válidas siempre que se cumpla la condición gráfica indicada a la derecha.

Regla 1 (inserción/eliminación de observaciones). Permite descartar una variable observada que es irrelevante bajo la intervención:

$$P(y \mid \mathrm{do}(x), z, w) = P(y \mid \mathrm{do}(x), w) \quad \text{si} \quad (Y \perp\!\!\!\perp Z \mid X, W)_{G_{\overline{X}}}. \tag{8.2}$$

Regla 2 (intercambio de acción por observación). Permite reemplazar un do por un condicionamiento ordinario, el paso que convierte una cantidad no estimable en una estimable:

$$P(y \mid \mathrm{do}(x), \mathrm{do}(z), w) = P(y \mid \mathrm{do}(x), z, w) \quad \text{si} \quad (Y \perp\!\!\!\perp Z \mid X, W)_{G_{\overline{X}\underline{Z}}}. \tag{8.3}$$

Regla 3 (inserción/eliminación de acciones). Permite descartar una intervención que no afecta al resultado:

$$P(y \mid \mathrm{do}(x), \mathrm{do}(z), w) = P(y \mid \mathrm{do}(x), w) \quad \text{si} \quad (Y \perp\!\!\!\perp Z \mid X, W)_{G_{\overline{X}\underline{Z(W)}}}, \tag{8.4}$$

donde $Z(W)$ es el subconjunto de nodos de Z que no son ancestros de ningún nodo de W en $G_{\overline{X}}$.

Las tres reglas son **válidas** (todo lo que derivan es correcto) y, además, **completas**: si un efecto es identificable a partir del grafo y de la distribución observacional, existe una secuencia finita de aplicaciones de estas tres reglas que produce su fórmula; y si no existe tal secuencia, el efecto no es identificable, y ningún método, por sofisticado que sea, puede recuperarlo con esos datos y ese grafo. La completitud la demostraron Shpitser y Pearl (2006) y Huang y Valtorta (2006), de forma independiente, junto con algoritmos que deciden la identificabilidad. Esta completitud es lo que convierte al cálculo-do en un procedimiento de decisión y no solo en un conjunto de trucos: cuando un algoritmo de identificación responde que un efecto no es identificable, esa respuesta es una afirmación matemática y no una limitación del software.

La fórmula de ajuste de puerta trasera es, desde este punto de vista, un corolario. Por probabilidad total, $P(y \mid \mathrm{do}(x)) = \sum_z P(y \mid \mathrm{do}(x), z) P(z \mid \mathrm{do}(x))$. Si Z satisface el criterio, la Regla 2 justifica reemplazar $P(y \mid \mathrm{do}(x), z)$ por $P(y \mid x, z)$, porque condicionar en Z bloquea todas las rutas de puerta trasera y deja por tanto a Y y X d-separados en $G_{\underline{X}}$. La Regla 3 justifica que $P(z \mid \mathrm{do}(x)) = P(z)$, porque ningún nodo de Z es descendiente de X. Sustituyendo ambos queda $P(y \mid \mathrm{do}(x)) = \sum_z P(y \mid x, z) P(z)$.

8.2.4 Cuando la puerta trasera falla: el criterio de puerta delantera

El valor práctico del cálculo-do se aprecia mejor en un caso donde la puerta trasera **no** sirve. Suponga el grafo $X \to M \to Y$ con un confusor no observado U que afecta a X y a Y pero no a M salvo a través de X. No existe ningún conjunto observado que bloquee la ruta $X \leftarrow U \to Y$, porque U no se observa, y por tanto ningún ajuste por covariables identifica el efecto. Sin embargo, el mediador M ofrece una vía alternativa. El efecto de X sobre M es identificable (no hay confusión entre ellos), el efecto de M sobre Y es identificable ajustando por X (que bloquea la ruta $M \leftarrow X \leftarrow U \to Y$), y encadenando ambos se recupera el efecto total:

$$P(y \mid \mathrm{do}(x)) = \sum_{m} P(m \mid x) \sum_{x'} P(y \mid m, x') P(x'). \tag{8.5}$$

Esta es la **fórmula de puerta delantera** (*front-door*), derivable por aplicación sucesiva de las tres reglas. El punto conceptual, y la razón de incluirla en un libro orientado a la práctica, es doble. Primero, la identificación no se reduce a «encontrar los controles correctos»: el conocimiento sobre **mecanismos** (saber que todo el efecto de X sobre Y pasa por M) es una fuente de identificación tan legítima como el conocimiento sobre confusores, y a veces la única disponible. Segundo, como advertencia, el supuesto de que **ninguna** ruta directa $X \to Y$ escapa a M es fuerte y raramente defendible en datos económicos, razón por la cual la puerta trasera, y no la delantera, sigue siendo el caballo de batalla de los métodos de la Parte II.

Algoritmo

Entrada: Grafo dirigido acíclico G, tratamiento X, resultado Y y conjunto candidato Z.
Salida: Aceptar o rechazar Z, con el motivo.
Si algún nodo de Z es descendiente de X en G, rechazar (falla la condición **(i)**).
Construir G' borrando de G todas las flechas que salen de X; lo que queda entre X e Y son sus caminos de puerta trasera.
Tomar el subgrafo ancestral de X, Y y Z en G' y **moralizarlo**: unir con una arista a cada par de padres de un mismo nodo y quitar la dirección de las flechas.
Borrar los nodos de Z del grafo moral.
Si en el grafo resultante hay un camino entre X e Y, rechazar (falla la condición **(ii)**); en otro caso, aceptar.
return aceptar o rechazar

Algoritmo 3. Verificación del criterio de puerta trasera

Caso canónico · Una puerta delantera con confusor no observado

Cuatro variables binarias. U no se observa y vale 1 con probabilidad 0,5. El tratamiento vale 1 con probabilidad $0.2 + 0.6U$, el mediador con probabilidad $0.2 + 0.6X$ y el resultado con probabilidad $0.1 + 0.5M + 0.3U$. Por la fórmula de puerta delantera el efecto de X sobre $P(Y = 1)$ vale exactamente $0.5 \times 0.6 = 0.30$.

Con 200 000 unidades, la diferencia de medias entre tratados y no tratados es 0,48, inflada por U, y la fórmula de puerta delantera aplicada a los datos observados estima 0,30. Ninguna regresión sobre las variables observadas habría dado ese número, porque U no se observa.

8.2.5 Cómputo contrafactual: abducción, acción, predicción

El Capítulo 3 adelantó el procedimiento de tres pasos para responder preguntas de $\mathcal{L}_3$. Formalizado: dado un SCM M y evidencia observada e sobre una unidad específica, calcular $P(y_x \mid e)$ requiere:

1. **Abducción**: actualizar $P(u)$ a $P(u \mid e)$, es decir, inferir a partir de lo observado qué configuración de variables exógenas es consistente con la evidencia.
2. **Acción**: construir el modelo modificado M_x, reemplazando la ecuación de X por la constante x (idéntico al paso interventivo del Capítulo 3).
3. **Predicción**: calcular Y en M_x usando la distribución actualizada $P(u \mid e)$ del paso de abducción, en lugar de la $P(u)$ original.

La diferencia crucial con el cómputo interventivo puro es el paso de abducción: una pregunta contrafactual siempre está condicionada por lo que efectivamente se observó de esa unidad específica, mientras que una pregunta interventiva pura pregunta por el efecto promedio poblacional sin condicionar en ninguna observación particular.

8.3 Algoritmo e implementación

El algoritmo 3 comprueba un conjunto candidato contra el criterio de puerta trasera con un procedimiento corto, que se apoya en la prueba de d-separación por moralización del subgrafo ancestral.

El listado implementa el mismo procedimiento con la prueba de d-separación de `networkx` (versión 3.3 o posterior).

```
import networkx as nx

# Grafo: educ (X) -> wage (Y); ability (confusor) -> educ, wage;
# test_score (mediador) : educ -> test_score -> wage
G = nx.DiGraph([
    ("ability", "educ"), ("ability", "wage"),
    ("educ", "wage"),
    ("educ", "test_score"), ("test_score", "wage"),
])

def satisface_puerta_trasera(G, X, Y, Z):
    G_sin_salientes_X = G.copy()
    G_sin_salientes_X.remove_edges_from(list(G.out_edges(X)))
    # (i) ningun nodo de Z es descendiente de X
    descendientes_X = nx.descendants(G, X)
    if any(z in descendientes_X for z in Z):
        return False, "Z contiene un descendiente de X (posible mediador)"
    # (ii) Z separa X de Y en el grafo sin las aristas salientes de X
    if not nx.is_d_separator(G_sin_salientes_X, {X}, {Y}, set(Z)):
        return False, "Z no bloquea todos los caminos de puerta trasera"
    return True, "Z satisface el criterio de puerta trasera"

print(satisface_puerta_trasera(G, "educ", "wage", {"ability"}))
print(satisface_puerta_trasera(G, "educ", "wage", {"ability", "test_score"}))
# El segundo caso debe fallar: test_score es un mediador (descendiente de X)
```

Listado 8.1: Verificación del criterio de puerta trasera con `networkx`.

En la práctica, `dowhy` automatiza esta verificación y además identifica conjuntos de puerta trasera válidos dado un grafo declarado por el usuario, con la función `identify_effect()`; el Apéndice B documenta su uso. Esa misma función busca estimandos por puerta delantera (Sección 8.2.4) y por variable instrumental cuando la puerta trasera falla, de modo que su salida «no identificable» debe leerse con el peso que le da la completitud del cálculo: no es que la librería no sepa cómo, es que con ese grafo y esos datos no se puede.

8.4 Caso aplicado: el grafo de educación y salario

Considere un grafo con cuatro variables: la habilidad afecta a la educación y al salario, la educación afecta al salario directamente y a través de una prueba de competencias adquiridas

en la escuela, y esa prueba afecta al salario. Si el analista incluyera la prueba de competencias (una variable medida **después** de completar los años de educación) como control en la regresión del salario sobre la educación, estaría, según la clasificación de la Sección 8.2.2, controlando por un mediador: parte del efecto de la educación sobre el salario opera precisamente a través de las competencias que la prueba mide. El coeficiente de la educación quedaría sesgado hacia abajo, como el 0,70 del primer mundo del caso canónico de más arriba. El algoritmo de verificación llega a la misma conclusión: el conjunto formado por la habilidad y la prueba falla la condición **(i)**, mientras que la habilidad sola satisface las dos (listado 8.1).

8.5 Riesgos, límites y sensibilidad

Riesgos, límites y mitigación

- **«Más controles siempre es más seguro».** Es falso en general: agregar un mediador o un collider puede introducir sesgo donde una especificación más parca no lo tenía. El criterio de puerta trasera formaliza exactamente cuándo agregar un control ayuda y cuándo perjudica.
- **Confundir un instrumento con un confusor.** Un instrumento válido no debe controlarse directamente como si fuera una covariable de puerta trasera; su rol es distinto y se explota con métodos específicos (DML-IV, Parte III). Si queda confusión no observada, incluirlo como control amplifica el sesgo de esa confusión (Pearl (2010)), como muestra el segundo mundo del caso canónico.
- **El grafo es siempre una hipótesis.** Todo lo desarrollado en este capítulo presupone que el grafo declarado es correcto. Ningún algoritmo puede generar el grafo desde los datos solos sin supuestos adicionales (el Capítulo 29, más adelante en el libro, aborda qué tan lejos se puede llegar con descubrimiento automatizado, y sus límites).

8.6 Ejercicios y notas bibliográficas

8.6.1 Ejercicios teóricos

1. Para el grafo de la Sección 8.4, con habilidad, educación, prueba de competencias y salario, agregue una variable «vecindario» que sea causa común de la habilidad y del salario (pero no de la educación). ¿Sigue la habilidad, sola, satisfaciendo el criterio de puerta trasera? Justifique con el grafo modificado.
2. Explique, en el lenguaje de este capítulo, por qué condicionar en un collider crea una correlación espuria (retome el ejemplo del tamaño del pie y la capacidad de lectura del Capítulo 1, agregando explícitamente un collider).
3. Aplique el procedimiento de abducción-acción-predicción a un ejemplo numérico simple: un SCM lineal $Y = 2X + U$, $X = U + \varepsilon$, con $U \sim N(0,1)$ y $\varepsilon \sim N(0,1)$ independientes.

Dado que se observó $X = 1, Y = 3$, calcule el valor contrafactual de Y si X hubiera sido 2.

4. Derive la fórmula de ajuste de puerta trasera a partir de las tres reglas del cálculo-do de la Sección 8.2.3, indicando explícitamente qué regla justifica cada paso y qué condición de d-separación se invoca en cada caso.
5. Para el grafo de puerta delantera de la Sección 8.2.4 ($X \to M \to Y$ con U no observado afectando a X e Y), añada una flecha directa $X \to Y$. Explique por qué la fórmula de puerta delantera deja de ser válida y qué supuesto sustantivo se estaría violando.
6. En el segundo mundo del caso canónico de los cuatro controles, ¿qué estimaría la regresión si se controlara por Z y no por C? Explique con el grafo por qué ninguna de las especificaciones identifica el efecto.

8.6.2 Ejercicios computacionales

1. Instale `dowhy` (Apéndice B) y reproduzca la verificación del listado 8.1 usando `identify_effect()` en lugar de la función manual. Compare el conjunto de ajuste que identifica automáticamente con el usado en el capítulo.
2. Simule el primer mundo del caso canónico de los cuatro controles y reproduzca la tabla con mínimos cuadrados. Repita con 500 unidades en lugar de 5 000 y compare la desviación entre repeticiones.

8.6.3 Notas bibliográficas

El criterio de puerta trasera, las tres reglas del cálculo-do, su completitud y la fórmula de puerta delantera se presentan en (Pearl 2009), Capítulo 3, que es la referencia canónica para todo el aparato de identificación gráfica de este capítulo; la clasificación de buenos y malos controles sigue la sistematización de (Bareinboim 2025). La completitud del cálculo la establecen Shpitser y Pearl (2006) y Huang y Valtorta (2006). Elwert y Winship (2014) es el tratamiento de referencia del sesgo por *collider* y de sus formas encubiertas (selección muestral, atrición, condicionamiento en supervivencia), y es la lectura más útil para quien deba auditar un pipeline de datos ya construido; la amplificación de sesgo por instrumentos la describe Pearl (2010). Para una implementación aplicada, Sharma y Kiciman (2020) documenta una biblioteca de referencia, cubierta en el Apéndice B de este libro.

CAPÍTULO 9

Ingeniería de *features* sin fuga causal

Cuadro de decisión del capítulo

Decisión:	Auditar cada *feature* candidata contra el grafo causal y contra el momento en que se mide antes de incluirla, no solo contra su poder predictivo
Alternativas:	Selección de *features* por importancia predictiva vs. selección por rol causal
Trade-off clave:	Una *feature* que mejora el ajuste predictivo puede empeorar la estimación causal
Insumo:	Los roles causales declarados en el esquema de datos del Capítulo 4
Stack:	pandas
Riesgo principal:	*Fuga* (*leakage*) de información post-tratamiento disfrazada de covariable

Implementación en el monorepo del curso (2026)

Lab `L08` planta fugas deliberadas (outcome, tratamiento, interacciones) y las detecta antes de estimar. La Serie A2 (DML) y el escenario `ihdp_medium` asumen covariables solo pre-tratamiento. No usar columnas de ground truth (`y0`, `y1`, `tau`) fuera de celdas de evaluación. Rutas: `05_labs_sesion/L08_leakage_ihdp/` y notebook A2 en `03_notebooks_caso_estudio/notebooks/`.

9.1 El problema de diseño

La ingeniería de *features* estándar, la de Huyen (2022) (Capítulo 5), evalúa una *feature* candidata con un solo criterio: ¿mejora el desempeño predictivo fuera de muestra? Con ese criterio, cualquier variable disponible al entrenar que esté correlacionada con Y es bienvenida. El Capítulo 8 mostró por qué ese criterio es **insuficiente y a veces contraproducente** en un sistema causal: una *feature* puede reducir el error de predicción y, a la vez, ser un mediador o un collider que sesga la estimación del efecto. El problema de diseño de este capítulo es construir un proceso que audite cada variable candidata contra su **rol en el grafo causal** y contra el **momento en que se mide**, no solo contra su poder predictivo. Es la versión operacional, en la preparación de variables, de la clasificación de controles del capítulo anterior.

En un sistema que opera, el momento importa dos veces. Al entrenar, una variable medida después del tratamiento filtra información del resultado. Al servir, la preparación de variables solo dispone de lo que se sabe en el instante de decidir: una *feature* calculada en un lote nocturno con datos posteriores a la decisión funciona en el entrenamiento retrospectivo y, en servicio, no existe o existe con otro valor. Por eso la regla temporal se formula respecto del momento de la decisión, y por eso la preparación de variables debe ser una sola función para entrenamiento y servicio, una de las seis piezas del Sección 2.6.

9.2 Opciones y trade-offs

Opciones y trade-offs

- **Selección por importancia predictiva.** Se agregan *features* mientras mejoren una métrica de validación cruzada (RMSE, AUC). Es el flujo de trabajo estándar en *machine learning* aplicado y el más rápido de ejecutar. Su riesgo específico en un contexto causal ya se discutió en el Capítulo 5: un modelo puede predecir excelente y estimar el efecto causal con sesgo severo, precisamente porque la importancia predictiva no distingue entre variación causal y variación espuria.
- **Selección por rol causal, informada por el grafo.** Cada *feature* candidata se clasifica primero según la Sección 8.2.2 del capítulo anterior (confusor, mediador, collider, post-tratamiento) y solo después se evalúa su aporte predictivo **dentro** de la categoría de controles legítimos. Requiere tener, aunque sea de forma preliminar, un DAG propuesto, lo cual no siempre es cómodo en la fase exploratoria de un proyecto, pero previene sistemáticamente la clase de error más costosa de este curso.

9.3 Decisión de referencia para el curso

El libro adopta una etapa de **auditoría de features**, obligatoria antes de construir cualquier matriz de covariables X. Cada columna candidata se anota con su rol supuesto (confusor,

mediador, collider, post-tratamiento o desconocido) y con la columna que registra cuándo se midió, y la auditoría produce no una sino **dos** especificaciones de X:

- X_{base}, con las variables anotadas como **confusor** y medidas antes del tratamiento. Es la especificación sobre la que se reporta la estimación principal.
- $X_{\text{ampliada}} = X_{\text{base}} \cup \{\text{desconocido}\}$, que añade las candidatas cuyo rol el analista no pudo determinar, siempre que sean pre-tratamiento. Es la especificación sobre la que se reporta el **análisis de sensibilidad**.

Momento de medida	**Rol declarado**	$\boldsymbol{X}_{\textbf{base}}$	$\boldsymbol{X}_{\textbf{ampliada}}$
Antes del tratamiento	Confusor	Sí	Sí
Antes del tratamiento	Desconocido	No	Sí
Antes del tratamiento	Mediador, collider o post--tratamiento	No	No
Después del tratamiento, en alguna unidad	Cualquiera	No	No
Sin marca de tiempo, o con valores faltantes en ella	Cualquiera	No	No

La última fila es la regla conservadora que el listado de referencia hace cumplir: lo que no se puede verificar como anterior al tratamiento no entra. Las reglas valen para el efecto total. Si el estimando fuera un efecto directo o un efecto mediado, el mediador entraría por diseño y el grafo sería otro; es un problema de identificación distinto.

La razón de exigir dos especificaciones en lugar de una regla única es que las dos decisiones posibles sobre una variable de rol desconocido tienen riesgos opuestos y no comparables: excluirla arriesga sesgo por confusión omitida, incluirla arriesga sesgo por mal control. Ningún criterio automático resuelve esa disyuntiva, pero reportar ambas estimaciones convierte la duda en información. Si el efecto es estable entre X_{base} y X_{ampliada}, la ambigüedad de rol no era material. Si no lo es, la identificación tiene que revisarse antes de registrar el modelo, que es la acción *revisar identificación* del Sección 2.5. La condición temporal se aplica a **ambas** especificaciones: ninguna cantidad de análisis de sensibilidad rescata a una covariable medida después del tratamiento.

Qué queda registrado. El resultado de la auditoría no es un paso desechable. La lista de covariables con que se estima el efecto principal es el campo de roles de la ficha del modelo (Capítulo 19), y es lo que el servicio exige a cada consulta (Capítulo 15). Una ficha sin roles no pasa la compuerta de registro (Capítulo 20). Cuando las estimaciones con X_{base} y X_{ampliada} difieren de forma material, se registran las dos.

Caso canónico · Cuatro tipos de feature y una verdad conocida

Seis variables continuas generadas con ruido normal. C y U son confusores observados y se miden antes del tratamiento. A_1 y A_2 no se observan: A_1 afecta solo al tratamiento y A_2 solo al resultado. $B = 0.8A_1 + 0.8A_2 + \varepsilon_B$ es un collider medido antes del tratamiento. El tratamiento es $D = 0.8C + 0.8U + 0.8A_1 + \varepsilon_D$ y el mediador, $M = 0.5D + \varepsilon_M$, se mide después. El resultado es $Y = 0.7D + 0.6M + C + U + 0.8A_2 + \varepsilon_Y$, de modo que el efecto total de D es $0.7 + 0.6 \times 0.5 = 1$. Dos variables más se miden después: $K = 0.6D + 0.6Y + \varepsilon_K$, un collider, y $P = Y + 0.3\varepsilon_P$, una medición tardía del propio resultado. El analista declara C como confusor, U como desconocido, B y K como collider, M como mediador y P como post-tratamiento. Con 5 000 unidades y 200 repeticiones, la regresión lineal de Y sobre D y cada especificación da lo siguiente (la desviación entre repeticiones es de 0,02 o menos en todas las filas):

Controles	Efecto estimado	R^2 fuera de muestra
Ninguno	1,55	0,69
X_{base} (C)	1,35	0,73
X_{ampliada} (C, U)	1,00	0,80
X_{ampliada} y B (collider previo)	0,88	0,82
X_{ampliada} y M (mediador)	0,70	0,84
Todas las variables	0,00	0,99

Pasar de X_{ampliada} a la selección por ajuste predictivo mejora el R^2 de 0,80 a 0,99 y empeora el efecto de 1,00 a 0,00. La última fila usa K y P, que contienen información del resultado y vacían el coeficiente del tratamiento. En este mundo U es un confusor y la especificación correcta es X_{ampliada}. Si en cambio U fuera un collider previo, como B, la correcta sería X_{base} (que daría 1,00) y X_{ampliada} estimaría 0,91. La discrepancia entre las dos especificaciones es de 0,35 en un mundo y de 0,09 en el otro, y ambas superan con holgura la desviación de 0,02. Los datos solos no dicen en cuál de los dos mundos se está: eso lo decide el grafo.

9.4 El contrato de la auditoría de *features*

La regla de la sección anterior se convierte en una pieza de ingeniería con el formato del C-01 (Sección 4.4). Cualquier implementación que cumpla este contrato sirve, sea una función, un paso de un pipeline o una revisión asistida.

Contrato C-03 · Auditoría de *features*

Operaciones *auditar*: recibe las candidatas con el rol que el analista les asigna y con la columna que dice cuándo se midió cada una, junto

	con la columna que dice cuándo se asignó el tratamiento, y devuelve una fila por candidata con una decisión de inclusión para cada especificación. *extraer*: devuelve la lista de covariables de una especificación, que pasa a ser el campo de covariables del esquema (C-01) y de la ficha del modelo.
Entrada	Las candidatas con su rol (confusor, mediador, collider, post--tratamiento o desconocido) y su marca de tiempo por unidad, y la marca de tiempo del tratamiento por unidad. El estimando es el efecto total; para otro estimando cambia la tabla de decisión (el mediador entraría en un efecto directo, por ejemplo).
Salida	Una fila por candidata con su rol, la fracción de unidades en que se midió después del tratamiento, si su marca de tiempo es verificable y las decisiones de inclusión en X_{base} y en X_{ampliada}. Una advertencia por cada candidata con riesgo temporal o de rol ambiguo.
Invariantes	(1) Ninguna candidata se omite en silencio: toda la que aparezca en los roles o en las marcas de tiempo aparece en la salida. (2) Lo que no puede verificarse como anterior al tratamiento, por falta de marca o por faltantes en ella, no entra en ninguna especificación. (3) Una candidata medida después del tratamiento en alguna unidad no entra en ninguna. (4) Mediador, collider y post-tratamiento no entran en ninguna. (5) X_{base} contiene solo confusores y está incluida en X_{ampliada}, que añade los de rol desconocido. (6) Una candidata sin rol declarado es de rol desconocido. (7) Con los mismos datos y los mismos roles, la salida es idéntica.
Modos de fallo	Un rol mal declarado: la auditoría confía en lo que se declara, y un confusor que en realidad es un collider entra en las dos especificaciones. Una marca de tiempo que registra cuándo se cargó el dato y no cuándo se midió: la condición temporal se cumple en el papel. Un rol desconocido que se resuelve por conveniencia en vez de por el grafo. Una sola especificación reportada cuando las dos difieren. Una candidata derivada cuya fórmula usa datos posteriores al tratamiento.
Prueba de aceptación	(a) Casos de borde, uno por cada caso de la tabla de decisión, más la candidata que solo aparece en los roles y la que tiene faltantes en su marca: cada una cae en la fila que le corresponde. (b) En el caso canónico, la auditoría deja $X_{\text{base}} = \{C\}$ y $X_{\text{ampliada}} = \{C, U\}$, y B, K, M y P quedan fuera de las dos. (c) Las seis estimaciones del caso canónico se reproducen, y la

> diferencia entre las dos especificaciones supera con holgura la desviación entre repeticiones.

Nada se omite en silencio. Una auditoría que solo recorre las candidatas con marca de tiempo deja pasar justo las que nadie sabe cuándo se midieron. Con el invariante (1) esas candidatas aparecen, marcadas como no verificables, y el analista ve la lista de lo que quedó fuera y por qué.

Lo no verificable queda fuera. Entre incluir una variable cuyo momento de medida se ignora y excluirla, el contrato elige excluirla y reportarlo. El riesgo de la exclusión (una confusión omitida) se ve en la comparación de las dos especificaciones. El de la inclusión (una fuga) no se ve en ningún lado.

La auditoría confía en el rol declarado. El contrato comprueba el tiempo y aplica la tabla, pero no puede saber si el rol es el correcto. Esa es la parte que depende del grafo y de quien lo dibuja, y por eso el contrato exige que la decisión sobre los roles dudosos quede registrada en la ficha del modelo.

9.5 Implementación de referencia

El listado implementa la tabla de la sección anterior. Recorre las *features* que aparezcan en cualquiera de los dos diccionarios, de modo que una *feature* sin marca de tiempo se marca como no verificable en lugar de omitirse en silencio, y trata como no verificable una marca con valores faltantes.

```
import pandas as pd

# Roles que NUNCA entran en X cuando el estimando es el efecto total:
# su inclusion bloquea una parte del efecto o abre un camino espurio.
ROLES_PROHIBIDOS = {"mediador", "collider", "post_tratamiento"}

def auditar_features(df: pd.DataFrame, treatment_time_col: str,
                     feature_time_cols: dict[str, str],
                     roles_declarados: dict[str, str]) -> pd.DataFrame:
    """Marca cada feature con su riesgo de fuga temporal y con su rol causal
    declarado. Recorre todas las features que aparezcan en cualquiera de los
    dos diccionarios: una feature sin marca de tiempo no se omite, se marca
    como no verificable y queda fuera de ambas especificaciones.

    Devuelve dos indicadores de inclusion, no uno:
      - incluir_en_X_base:     especificacion principal (solo confusores)
      - incluir_en_X_ampliada: especificacion de sensibilidad (base + rol
                               desconocido, siempre verificablemente pre-
tratamiento)
    """
    filas = []
```

```
    for feature in sorted(set(feature_time_cols) | set(roles_declarados)):
        rol = roles_declarados.get(feature, "desconocido")
        tiempo_col = feature_time_cols.get(feature)
        if tiempo_col is None:
            verificable, posterior = False, float("nan")
        else:
            t_feature, t_trat = df[tiempo_col], df[treatment_time_col]
            verificable = bool(t_feature.notna().all() and
t_trat.notna().all())
            posterior = float((t_feature > t_trat).mean())
        pre_tratamiento = verificable and posterior == 0.0
        filas.append({
            "feature": feature,
            "rol_declarado": rol,
            "pct_medida_despues_del_tratamiento": posterior,
            "marca_de_tiempo_verificable": verificable,
            "riesgo_temporal": not pre_tratamiento,
            "incluir_en_X_base": pre_tratamiento and rol == "confusor",
            "incluir_en_X_ampliada": pre_tratamiento and rol not in
ROLES_PROHIBIDOS,
        })
    resultado = pd.DataFrame(filas)

    riesgosas = resultado[resultado["riesgo_temporal"]
                          | (resultado["rol_declarado"] == "desconocido")]
    if len(riesgosas) > 0:
        print("ADVERTENCIA: features con riesgo de fuga o sin rol
determinado:")
        print(riesgosas[["feature", "rol_declarado",
                         "pct_medida_despues_del_tratamiento",
                         "marca_de_tiempo_verificable"]])
    n_amb = (resultado["rol_declarado"] == "desconocido").sum()
    if n_amb:
        print(f"{n_amb} feature(s) de rol ambiguo -> reportar la estimacion "
              "con X_base y con X_ampliada, y comparar.")
    return resultado


def columnas_X(resultado: pd.DataFrame, especificacion: str = "base") ->
list[str]:
    """Extrae la lista de covariables de una de las dos especificaciones."""
    col = f"incluir_en_X_{especificacion}"
    return resultado.loc[resultado[col], "feature"].tolist()
```

Listado 9.1: Auditoría de *features* por marca de tiempo y por rol declarado.

La función no decide por el analista cuál de las dos especificaciones es la correcta: esa decisión sigue siendo suya, informada por el grafo. Lo que hace es imposible dos cosas: que una variable

post-tratamiento, o una sin marca de tiempo verificable, entre a X en silencio, y que una variable de rol ambiguo desaparezca sin dejar rastro. Aparece en la especificación ampliada y obliga a reportar la comparación. Las cifras del caso canónico salen de una simulación con semilla declarada que ejecuta este mismo listado y están en `herramientas/verificaciones/verif_listados_cap09.py`.

9.6 Aplicación al sistema causal del curso

La auditoría se ejecuta sobre la matriz de covariables **antes** de estimar el modelo PLR/IRM del Capítulo 11 (en el Notebook de caso de estudio A2, Módulo 2). Esto conecta con un punto que ese capítulo asume resuelto: la validez de la ortogonalidad de Neyman depende de que X contenga controles legítimos, no mediadores ni colliders disfrazados de covariables predictivas.

9.7 Señales de alerta y checklist operativo

- ☐ Una *feature* mejora sustancialmente el ajuste predictivo del modelo de resultado sin que exista una razón causal clara para incluirla.
- ☐ Ninguna columna del dataset tiene una marca de tiempo que permita verificar si fue medida antes o después del tratamiento, o esa marca tiene valores faltantes.
- ☐ El equipo agregó una *feature* «porque funcionaba mejor en las pruebas» sin volver a evaluar el DAG.
- ☐ Existen *features* derivadas cuya fórmula usa, aunque sea indirectamente, el resultado medido después del tratamiento.
- ☐ La preparación de variables de servicio es una función distinta de la de entrenamiento, o calcula alguna *feature* con datos posteriores al momento de decidir.
- ☐ Las estimaciones con X_{base} y X_{ampliada} difieren de forma material y solo se registró una.

9.8 Ejercicios y notas bibliográficas

9.8.1 Ejercicios conceptuales

1. Para el dataset de retornos a la educación, clasifique las siguientes variables candidatas a `covariates` según la tabla de la Sección 8.2.2: habilidad cognitiva medida antes de ingresar a la escuela; puntaje de un examen de egreso universitario; cercanía geográfica a una universidad; ingreso de los padres.
2. Un promedio móvil del resultado de las últimas 4 semanas puede ser un control legítimo o una fuente de fuga. Explique de qué depende, qué rol le asignaría en cada caso y qué marca de tiempo debe tener para que la auditoría lo deje pasar.
3. En el caso canónico, la especificación con todas las variables tiene $R^2 = 0.99$ y estima un efecto de 0,00. Explique, con el grafo, por qué K y P vacían el coeficiente del tratamiento aunque el modelo prediga casi perfectamente.

9.8.2 Ejercicio computacional

1. Aplique el listado 9.1 al conjunto de datos que eligió para el Notebook A1, declarando roles causales para al menos 6 covariables candidatas, de las cuales al menos una debe quedar como `desconocido` y al menos una debe carecer de marca de tiempo. Reporte cuántas quedan excluidas de X_{base} y por qué motivo cada una, y compare X_{base} con X_{ampliada}.
2. Estime el efecto con ambas especificaciones (X_{base} y X_{ampliada}) y compare los dos intervalos de confianza. Si la diferencia es pequeña frente al ancho de los intervalos, ¿qué concluye sobre la variable de rol ambiguo? ¿Y si es grande? Explique por qué, en el segundo caso, **ninguna** de las dos estimaciones es defendible sin resolver antes la pregunta de identificación.

9.8.3 Notas bibliográficas

Huyen (2022), Capítulo 5, cubre la ingeniería de *features* genérica y la fuga de datos (*data leakage*) en su sentido predictivo estándar (por ejemplo, escalar antes de separar entrenamiento y prueba); este capítulo extiende esa discusión al tipo de fuga específico de sistemas causales. La clasificación de controles retomada aquí se desarrolla en (Bareinboim 2025) y (Pearl 2009), ya citados en el Capítulo 8.

PARTE II

Estimación causal flexible y primer despliegue

Esta parte desarrolla los estimadores centrales del libro: ortogonalidad de Neyman y cross-fitting, Double Machine Learning, meta-learners, árboles y bosques causales, y validación sin ground truth, entendida como un proceso de evaluación offline del sistema y no solo como un chequeo estadístico puntual. Cierra con el primer despliegue local del libro: el estimador DML servido como un servicio con contrato explícito.

CAPÍTULO 10

Ortogonalidad de Neyman, cross-fitting e influence functions

Cuadro sinóptico del capítulo

Problema:	Estimar un efecto con *learners* de ML sin que su sesgo contamine la inferencia
Estimando:	θ_0 en el modelo parcialmente lineal (PLR)
Identificación:	No confusión condicional y ortogonalidad de Neyman del score
Método:	Score ortogonal y *cross-fitting*
Nuisance:	$l_0(X) = E[Y \mid X]$ y $m_0(X) = E[D \mid X]$, o bien $g_0(X)$ y $m_0(X)$
Garantía:	$\sqrt{n}\left(\hat{\theta} - \theta_0\right) \Rightarrow N(0, \sigma^2)$ si el error de los *nuisance* cumple $\sqrt{n}a_n^2 \to 0$
Librerías:	`scikit-learn` (implementación manual del score); `DoubleML` y `econml` en el Capítulo 11
Validación:	Perturbación de los *nuisance* y Monte Carlo de sesgo y cobertura con y sin *cross-fitting*

Nota técnica

Con el criterio de puerta trasera (Capítulo 8) y la auditoría de *features* (Capítulo 9) resueltos, la Parte I dejó pendiente una pregunta puramente estadística: ¿cómo combinar *learners* de ML flexibles para estimar un efecto causal sin que el sesgo de esos *learners* contamine la inferencia? Este capítulo, que abre la Parte II, responde esa pregunta.

10.1 Problema causal, estimando e identificación

Una consultora evalúa el efecto de una reforma tributaria sobre la inversión empresarial con un panel de 5 000 firmas y 200 covariables (financieras, sectoriales, de propiedad y de

gobernanza). La asignación de la reforma no fue aleatoria: las firmas grandes y rentables fueron más propensas a ser tratadas. El estimador ideal (i) usa ML para modelar con flexibilidad la asignación al tratamiento, (ii) usa ML para modelar la relación entre covariables e inversión, y (iii) combina ambas estimaciones en un estimador del efecto con inferencia válida.

El problema es que enchufar el ML en un estimador construido para funciones conocidas no da, en general, inferencia válida. El estimador por ajuste de regresión $\hat{\theta} = n^{-1}\sum_i[\hat{\mu}_1(X_i) - \hat{\mu}_0(X_i)]$, por ejemplo, hereda directamente el error de estimación de $\hat{\mu}_d$, y ese error, producto de regularizar un modelo de alta dimensión, no desaparece con la rapidez que exige la inferencia. La salida no es abandonar el ML sino cambiar la función de momento con la que se estima el efecto, de modo que los errores de los *nuisance* solo entren en segundo orden. Eso es la **ortogonalidad de Neyman**. Combinada con *cross-fitting*, permite estimadores $\sqrt{n}$ -consistentes y asintóticamente normales aun cuando los *nuisance* se estimen con ML a tasas más lentas que $\sqrt{n}$.

10.2 Teoría, supuestos y garantías

10.2.1 El problema del doble sesgo

Considérese el modelo parcialmente lineal (PLR, *partial linear model*):

$$Y = D\theta_0 + g_0(X) + \varepsilon, \quad D = m_0(X) + v, \tag{10.1}$$

donde Y es el resultado, D el tratamiento, X las covariables, g_0 la regresión del resultado y m_0 la función de tratamiento, que no tiene por qué ser una probabilidad. Se supone $E[\varepsilon \mid D, X] = 0$ y $E[v \mid X] = 0$. Para D binario, $m_0(x) = e_0(x) = P(D = 1 \mid X = x)$. Se definen además $l_0(X) = E[Y \mid X] = g_0(X) + \theta_0 m_0(X)$ y los residuos de Robinson $v = D - m_0(X)$ y $u = Y - l_0(X)$, que cumplen $u = \theta_0 v + \varepsilon$.

El parámetro de interés es θ_0. La pregunta es cómo estimarlo cuando g_0 y m_0 son funciones desconocidas de alta dimensión.

Primer enfoque ingenuo: ML para g_0 y OLS para θ_0. Si g_0 fuera conocida, θ_0 se estimaría con la regresión de $Y - g_0(X)$ sobre D. Como se estima, se sustituye por $\hat{g}$ obtenida con ML:

$$\tilde{\theta} = \left(\sum_i D_i^2\right)^{-1} \sum_i D_i(Y_i - \hat{g}(X_i)). \tag{10.2}$$

El error de $\hat{g}$ es $O_p(a_n)$ y, con ML en alta dimensión, $a_n \gg n^{-\frac{1}{2}}$. Ese error de primer orden contamina a $\tilde{\theta}$:

$$\tilde{\theta} - \theta_0 = \underbrace{\left(\sum D_i^2\right)^{-1} \sum D_i \varepsilon_i}_{\text{ruido } O_p\left(n^{-\frac{1}{2}}\right)} + \underbrace{\left(\sum D_i^2\right)^{-1} \sum D_i(g_0(X_i) - \hat{g}(X_i))}_{\text{sesgo } O_p(a_n)}. \tag{10.3}$$

Como $a_n \gg n^{-\frac{1}{2}}$, el sesgo domina la varianza asintótica y la inferencia normal queda invalidada. Para fijar ideas sobre a_n: con una función de dos derivadas en una sola dimensión, la tasa

óptima de un estimador no paramétrico es del orden de $n^{-\frac{2}{5}}$; con muchas covariables y sin estructura (esparsidad, aditividad), la tasa óptima es aún más lenta.

Segundo enfoque ingenuo: ML para m_0 y regresión sobre el residuo del tratamiento. Con $\hat{v}_i = D_i - \hat{m}(X_i)$ y $\tilde{\theta}' = \left(\sum \hat{v}_i^2\right)^{-1} \sum \hat{v}_i Y_i$, el mismo problema aparece: el error $\hat{m} - m_0$ entra en primer orden, porque Y contiene a $g_0(X)$ y el residuo $\hat{v}$ conserva la parte de m_0 que el modelo no captó.

10.2.2 Ortogonalidad de Neyman

La solución es construir un score $\psi(W, \theta, \eta)$, con $W = (Y, D, X)$ y η los parámetros *nuisance*, que sea insensible en primer orden a errores en η.

Definición 10.1 ***(Score ortogonal de Neyman)***

Un score $\psi(W, \theta, \eta)$ con $E[\psi(W, \theta_0, \eta_0)] = 0$ es *ortogonal de Neyman* respecto de η en (θ_0, η_0) si la derivada de Gateaux de la esperanza respecto de η se anula:

$$\partial_\eta E[\psi(W, \theta_0, \eta)] \mid_{\eta=\eta_0} [r] = 0 \quad \text{para toda dirección admisible } \; r. \tag{10.4}$$

Con un desarrollo de Taylor de $E[\psi(W, \theta_0, \hat{\eta})]$ alrededor de η_0, el término de primer orden desaparece y queda un resto de segundo orden, del tamaño del producto de los errores de los *nuisance*. Eso permite que $\hat{\eta}$ converja más despacio que $n^{-\frac{1}{2}}$ sin que su error contamine a $\hat{\theta}$ en el orden que importa. La idea es de Neyman (1959), que la usó en su test $C(\alpha)$ para parámetros de estorbo.

10.2.3 Construcción del score ortogonal para PLR

Del modelo se obtiene $Y - g_0(X) - \theta_0 D = \varepsilon$ y $D - m_0(X) = v$, con $E[\varepsilon \mid D, X] = 0$ y $E[v \mid X] = 0$. Multiplicar la primera igualdad por v y tomar esperanza da $E[(D - m_0(X))(Y - g_0(X) - \theta_0 D)] = E[v\varepsilon] = 0$, y de ahí se despeja

$$\theta_0 = \frac{E[(D - m_0(X))(Y - g_0(X))]}{E[(D - m_0(X))D]}. \tag{10.5}$$

Hay dos parametrizaciones de los *nuisance* que conviene no mezclar, y ambas dan un score ortogonal:

1. **Forma estructural**, con $\eta = (g, m)$ y $g_0(X) = E[Y - \theta_0 D \mid X]$: $\psi = (D - m(X))(Y - g(X) - \theta D)$.
2. **Forma de Robinson**, con $\eta = (l, m)$ y $l_0(X) = E[Y \mid X]$, que es la que usa el DML estándar:

$$\psi(W, \theta, \eta) = (D - m(X))\{Y - l(X) - \theta(D - m(X))\}. \tag{10.6}$$

Mezclar las dos, por ejemplo usar $(D - m)(Y - l - \theta D)$ cuando $l = E[Y \mid X]$, rompe la ortogonalidad respecto de m. No debe confundirse tampoco g_0 con $\mu_{d(x)} = E[Y \mid X = x, D = d]$ de los Capítulo 5, Capítulo 12 y Capítulo 13: bajo el PLR, $\mu_{d(x)} = g_0(x) + \theta_0 d$, de modo que $\mu_1 - \mu_0 = \theta_0$.

Robinson (1988) introdujo la transformación de la segunda forma, que consiste en proyectar Y y D sobre X y regresar residuo contra residuo, para el PLR con g_0 estimada de forma no paramétrica, y demostró que el estimador resultante es $\sqrt{n}$-consistente pese a que las regresiones auxiliares convergen más despacio. Es el antecedente directo del score PLR de DML. Lo que Chernozhukov et al. (2018b) añaden es el **cross-fitting**, que permite reemplazar los estimadores de núcleo de Robinson por *learners* de ML arbitrarios sin pagar el sesgo de sobreajuste de estimar y evaluar en la misma muestra. El mismo score reaparece en el Capítulo 12 como la pérdida del R-learner; la «R» es por Robinson.

Teorema 10.2 ***(Ortogonalidad del score PLR)***

Los dos scores anteriores son ortogonales de Neyman respecto de su η en (θ_0, η_0).

Demostración. Para la forma estructural, la derivada de Gateaux en la dirección (r_g, r_m) es

$$\partial_\eta E[\psi]\,[r_g, r_m] = \partial_\alpha E\big[(D - (m_0 + \alpha r_m))\big(Y - (g_0 + \alpha r_g) - \theta_0 D\big)\big]\,|_{\alpha=0} = -E[r_m \varepsilon] - E\big[v r_g(X)\big] = 0,$$

porque $E[\varepsilon \mid D, X] = 0$ implica $E[r_m(X)\varepsilon] = 0$ y $E[v \mid X] = 0$ implica $E\big[v r_g(X)\big] = 0$. Para la forma de Robinson, la derivada en la dirección (r_l, r_m) es $-E[v r_l] - E[r_m(u - \theta_0 v)] + \theta_0 E[v r_m]$, que se anula por el mismo motivo, ya que $u - \theta_0 v = \varepsilon$. □

Un contraste que aclara qué pide la ortogonalidad: el score no ortogonal $D(Y - g(X) - \theta D)$ del primer enfoque ingenuo tiene derivada $-E\big[D r_g(X)\big]$, que en general no es cero porque D está correlacionado con X. El primer caso canónico de más abajo mide esa diferencia.

Nota técnica

Forma canónica del score ortogonal. Todos los scores que el libro deriva en capítulos distintos son instancias de un único objeto: un funcional $\psi(W, \theta, \eta)$ con $E[\psi(W, \theta_0, \eta_0)] = 0$ y derivada de Gateaux nula respecto de η en (θ_0, η_0) (Sección 10.2.2). La tabla reúne las instancias.

Estimando	$\boldsymbol{\psi(W, \theta, \eta)}$	$\boldsymbol{\eta}$
PLR, efecto constante (Capítulo 11)	$(D - m(X))(Y - l(X) - \theta(D - m(X)))$	(l, m)
ATE bajo IRM (Capítulo 11)	$\mu(1, X) - \mu(0, X) + \frac{D(Y - \mu(1,X))}{e(X)} - \frac{(1-D)(Y-\mu(0,X))}{1-e(X)} - \theta$	(μ, e)
CATE, DR-learner (Capítulo 12)	Γ_i = score IRM antes de promediar	(μ, e)
CATE, R-learner (Capítulo 12)	Pérdida $[(Y - m_Y(X)) - \tau(X)(D - e(X))]^2$, cuyo gradiente es ortogonal	(m_Y, e)
PLIV (Capítulo 17)	$(Z - r(X))(Y - g(X) - \theta D)$	(g, r, m)
Valor de una política (Capítulo 21)	$\mu_{\pi(X)}(X) + \frac{\mathbf{1}\{D = \pi(X)\}}{e_{\pi(X)}(X)} \cdot \big(Y - \mu_{\pi(X)}(X)\big) - V(\pi)$	(μ, e)

Tabla 10.1: Instancias del score ortogonal canónico a lo largo del libro.

Consecuencia operativa. El *cross-fitting*, la condición de tasa $\sqrt{n}a_n^2 \to 0$ y el error estándar por función de influencia (algoritmo de la Sección 10.3.1) son idénticos en todas las filas de la tabla. Cuando el libro presenta un estimador nuevo (Capítulo 11, Capítulo 12, Capítulo 17, Capítulo 21), lo que cambia es ψ y el estimando, no el aparato de inferencia. Es la perspectiva de funcionales de Riesz que el Capítulo 27 retoma: el score ortogonal de cada fila es el representador de Riesz de su funcional.

10.2.4 Teorema central de DML

El teorema central de (Chernozhukov et al. 2018b) combina ortogonalidad con *cross-fitting*.

Teorema 10.3 ***(DML, versión simplificada)***

Sea $\hat{\eta}$ un estimador de η_0 obtenido en una muestra auxiliar independiente de la muestra principal, con $\|\hat{\eta} - \eta_0\|_{L^2} = O_p(a_n)$ y $\sqrt{n}a_n^2 \to 0$. Sea $\hat{\theta}$ la solución de

$$\left(\frac{1}{n}\right)\sum_{i=1}^{n}\psi\left(W_i, \hat{\theta}, \hat{\eta}\right) = 0. \tag{10.8}$$

Entonces, bajo regularidad estándar y la ortogonalidad (10.4),

$$\sqrt{n}\left(\hat{\theta} - \theta_0\right) \xrightarrow{d} N(0, \sigma^2), \quad \sigma^2 = \frac{E\left[\psi(W, \theta_0, \eta_0)^2\right]}{\left(E[\partial_\theta \psi]\right)^2}. \tag{10.9}$$

Demostración (esquema). La ortogonalidad deja el resto de segundo orden $O_p(a_n^2)$, que es $o_p\left(n^{-\frac{1}{2}}\right)$ por la condición de tasa. Con la muestra auxiliar independiente, el término empírico $(P_n - P)(\psi(\hat{\eta}) - \psi(\eta_0))$ tiene media cero y varianza $o(n^{-1})$ condicional en $\hat{\eta}$. Queda el término lineal $n^{-1}\sum_i \psi(W_i, \theta_0, \eta_0)$, al que se aplica el teorema central del límite. La prueba formal está en (Chernozhukov et al. 2018b), Sección 3. ■ □

Intuición

La condición $\sqrt{n}a_n^2 \to 0$ es la clave. Con $a_n = n^{-\frac{2}{5}}$, la tasa óptima con dos derivadas en una dimensión, $\sqrt{n}a_n^2 = n^{-\frac{3}{10}} \to 0$. Para LASSO bajo esparsidad, $a_n = \sqrt{s\log p/n}$ y $\sqrt{n}a_n^2 = s\log p/\sqrt{n} \to 0$ si $s\log p = o(\sqrt{n})$. La virtud de la ortogonalidad es que **no hace falta** estimar η a tasa $\sqrt{n}$: basta una tasa más lenta, con error cuadrático $o\left(n^{-\frac{1}{2}}\right)$. En el PLR el resto es en realidad un **producto** de los errores de $\hat{m}$ y $\hat{l}$, de modo que basta que el producto sea $o\left(n^{-\frac{1}{2}}\right)$, con lo que un *nuisance* muy bien estimado compensa a otro más pobre.

Nota técnica

Condiciones completas y variantes DML1 y DML2. El teorema anterior está simplificado. Las condiciones completas ((Chernozhukov et al. 2018b), Teorema 3.1) son: (C1) ortogonalidad de Neyman del score; (C2) identificabilidad local, $|E[\partial_\theta \psi(W, \theta, \eta_0)]| \geq$

Algoritmo

Entrada: Datos $\{(Y_i, D_i, X_i)\}_{i=1}^{n}$, score ortogonal ψ, número de pliegues K, *learners* para los *nuisance*.
Salida: Estimador $\hat{\theta}$ y error estándar.
Dividir $\{1, ..., n\}$ en K pliegues $I_1, ..., I_K$.
for k = 1 **to** K **do**

Entrenar $\hat{\eta}_{-k}$ en $\{i : i \notin I_k\}$.
Predecir los *nuisance* en X_i para $i \in I_k$.

end for
Resolver $\hat{\theta}$ tal que $\left(\frac{1}{n}\right)\sum_i \psi\left(W_i, \hat{\theta}, \hat{\eta}_{-k(i)}\right) = 0$.
Estimar $\hat{\sigma}^2 = \hat{E}[\psi^2]/\hat{E}[\partial_\theta \psi]^2$.
return $\left(\hat{\theta}, \hat{\sigma}/\sqrt{n}\right)$

Algoritmo 4. Double Machine Learning con cross-fitting (K pliegues)

$c > 0$ en una vecindad de θ_0; (C3) tasas de los *nuisance*, $\|\hat{\eta} - \eta_0\|^2 = o_p\left(n^{-\frac{1}{2}}\right)$; y (C4) momentos acotados, $E[\psi^2] < \infty$ y $E\left[|\partial_\theta \psi|^2\right]$ acotado en una vecindad de θ_0.

Hay dos formas de agregar los pliegues, y el libro las distingue. **DML1** resuelve el score en cada pliegue k, obtiene $\hat{\theta}_k$ y promedia los K estimadores. **DML2** resuelve una sola ecuación de momento con todas las observaciones, usando para cada una el *nuisance* de su pliegue. La recomendación de (Chernozhukov et al. 2018b) es DML2, por su mejor comportamiento en muestras finitas. Para reducir la variabilidad que introduce la partición aleatoria se recomienda además el *cross-fitting* repetido: repetir la partición varias veces y agregar las estimaciones, con la mediana como agregador habitual.

Nota técnica

La expansión por función de influencia permite escribir $\hat{\theta} - \theta_0 = n^{-1}\sum_i \psi(W_i, \theta_0, \eta_0)/J_0 + o_p\left(n^{-\frac{1}{2}}\right)$, con $J_0 = -E[\partial_\theta \psi]$. De ahí sale el error estándar: $\hat{\sigma}^2$ es la varianza muestral de la función de influencia estimada.

10.3 Procedimientos

10.3.1 El rol del cross-fitting

El teorema asume que $\hat{\eta}$ se estima en una muestra independiente de la principal. Sin *cross-fitting* habría que pedir, en cambio, que $\hat{\eta}$ pertenezca a una clase de funciones de complejidad limitada (una condición de tipo Donsker), que los *learners* de ML flexibles y de alta dimensión no cumplen en general; de ahí el riesgo de sobreajuste al estimar y evaluar sobre los mismos datos. La solución que no desperdicia datos es dividir la muestra en K pliegues; para cada pliegue k, estimar $\hat{\eta}_{-k}$ con los otros $K - 1$ y evaluar el score en el pliegue k. Así $\hat{\eta}$ es independiente de los datos donde se evalúa, y todas las observaciones se usan en ambos papeles.

Algoritmo

Entrada: Datos $\{(Y_i, D_i, X_i)\}_{i=1}^{n}$, número de pliegues K, *learners* para $\hat{l}$ y $\hat{m}$.
Salida: Estimador $\hat{\theta}$ y error estándar.
Dividir $\{1, ..., n\}$ en K pliegues $I_1, ..., I_K$.
for k = 1 **to** K **do**

Entrenar $\hat{l}_{-k}$ para $E[Y \mid X]$ y $\hat{m}_{-k}$ para $E[D \mid X]$ en $\{i : i \notin I_k\}$.
Predecir $\hat{l}_{-k}(X_i)$ y $\hat{m}_{-k}(X_i)$ para $i \in I_k$.

end for
Residuos: $\hat{v}_i = D_i - \hat{m}_{-k(i)}(X_i)$ y $\hat{u}_i = Y_i - \hat{l}_{-k(i)}(X_i)$.
Estimar $\hat{\theta} = \left(\sum_i \hat{v}_i \hat{u}_i\right) / \left(\sum_i \hat{v}_i^2\right)$.
Calcular $\hat{\sigma}^2 = \left(\frac{1}{n}\right) \sum_i \left[\hat{v}_i \left(\hat{u}_i - \hat{\theta}\hat{v}_i\right) / \left(\left(\frac{1}{n}\right) \sum_j \hat{v}_j^2\right)\right]^2$.
return $\left(\hat{\theta}, \hat{\sigma}/\sqrt{n}\right)$

Algoritmo 5. DML manual con cross-fitting para PLR

Para el PLR con el score de Robinson el algoritmo se reduce a regresiones de residuos.

Intuición

Funciones de influencia. Una función de influencia dice cuánto cambiaría el estimado al agregar o quitar una observación, y sirve para calcular errores estándar sin *bootstrap*. Para el PLR, $\psi_i = v_i(u_i - \theta v_i)$ con $v_i = D_i - \hat{m}(X_i)$ y $u_i = Y_i - \hat{l}(X_i)$, y el error estándar es $\sqrt{n^{-1} \sum_i \psi_i^2}$ dividido por la media de $\hat{v}^2$ y por $\sqrt{n}$. La ortogonalidad es lo que permite leerlo así: los errores de $\hat{m}$ y $\hat{l}$ solo entran en segundo orden, de modo que el ML puede ser imperfecto sin romper la inferencia sobre θ.

10.4 Casos canónicos y validación

Los casos usan el proceso del experimento de Chernozhukov et al. (2018b): $\theta_0 = 0.5$, $n = 500$ y 20 covariables normales; $m_0 = X_1 + 0.25\, e(X_3)$ y $g_0 = e(X_1) + 0.25 X_3$, con $e(z) = \exp(z)/(1 + \exp(z))$; $D = m_0 + N(0, 1)$ e $Y = \theta_0 D + g_0 + N(0, 1)$. El script es `herramientas/verificaciones/verif_cap10.py`.

Caso canónico · Primer orden frente a segundo orden

Se entregan al estimador los *nuisance* verdaderos más una perturbación $\delta h(X)$ con $h = m_0$, con muestras de 200 000 observaciones. El score no ortogonal $D(Y - g - \theta D)$ tiene un sesgo que cambia en proporción a δ: $-0{,}203$ con $\delta = 0.4$, $-0{,}102$ con 0,2, $-0{,}051$ con 0,1 y $-0{,}026$ con 0,05, lo que coincide con el valor teórico $-\delta E[Dh]/E[D^2] \approx -0.50\delta$. El score ortogonal tiene un sesgo que cambia en proporción a δ^2: $+0{,}069$, $+0{,}018$, $+0{,}004$ y 0,000, en línea con $\delta^2(1 - \theta)E[h^2]/(1 + \delta^2 E[h^2])$. Al reducir a la mitad el error de los *nuisance*, el sesgo ingenuo se reduce a la mitad y el ortogonal a la cuarta parte.

Caso canónico · El sobreajuste y el cross-fitting

Con el mismo proceso se comparan, en 40 a 60 muestras independientes, la regresión lineal con las 20 covariables, DML sin *cross-fitting* (los *nuisance* se ajustan y se evalúan en la misma muestra) y DML con cinco pliegues. Con bosques aleatorios de 100 árboles y hojas de al menos cinco observaciones, el sesgo es −0,017 sin *cross-fitting* y −0,006 con él, y la cobertura del intervalo al 95 % es 96,7 % y 98,3 %. Con hojas de una observación, el sesgo pasa a −0,019 y −0,008, y la cobertura a 92,5 % y 95,0 %. Con *boosting* profundo (300 iteraciones, profundidad 4), que sobreajusta mucho más, el efecto es grande: sin *cross-fitting* el sesgo es −0,115, el error estándar declarado (0,058) es la mitad de la dispersión real (0,096) y la cobertura cae a 55 %; con *cross-fitting* el sesgo baja a −0,040 y la cobertura sube a 87,5 %. El *cross-fitting* mejora siempre y su ganancia crece con el sobreajuste del aprendiz, pero no lo corrige todo: un aprendiz que predice mal sigue dejando sesgo de segundo orden. La regresión lineal queda sin sesgo (−0,002) porque en este proceso la parte no lineal de los *nuisance* es suave. El ejemplo no dice que DML supere a la regresión lineal aquí, sino que, con ML flexible, el *cross-fitting* y un aprendiz razonable son parte del método.

El retorno al programa de capacitación del NSW es el caso real de referencia del curso: el contraste experimental simple de medias entre tratados y controles da cerca de 1 800 USD en 1978 (Dehejia y Wahba (1999) reportan 1 794 para la muestra experimental), con un error estándar de unos 650 a 700 USD. Un estimador DML con covariables debe quedar cerca de ese valor con un intervalo comparable. No prueba la identificación, pero es una comprobación de plausibilidad con un resultado experimental conocido. La comprobación con datos reales es un ejercicio computacional de este capítulo.

10.5 Implementación en Python

```
import numpy as np
from sklearn.ensemble import RandomForestRegressor
from sklearn.model_selection import KFold


def dml_plr_manual(Y, D, X, n_folds=5, learner=None, seed=0):
    """DML para el modelo parcialmente lineal con cross-fitting K-fold y score
de Robinson.

    Nuisance: l(X) = E[Y|X] y m(X) = E[D|X]. Residuos v = D - m(X), u = Y -
l(X).
    theta = sum(v u) / sum(v^2); funcion de influencia psi = v (u - theta v) /
E[v^2].
    """
    if learner is None:
```

```
        learner = lambda: RandomForestRegressor(n_estimators=100,
min_samples_leaf=5,
                                                random_state=seed, n_jobs=-1)
    n = len(Y)
    l_hat, m_hat = np.zeros(n), np.zeros(n)
    for tr, te in KFold(n_splits=n_folds, shuffle=True,
random_state=seed).split(X):
        l_hat[te] = learner().fit(X[tr], Y[tr]).predict(X[te])
        m_hat[te] = learner().fit(X[tr], D[tr]).predict(X[te])
    v, u = D - m_hat, Y - l_hat
    den = np.mean(v * v)
    theta = np.mean(v * u) / den
    psi = v * (u - theta * v) / den
    return theta, np.sqrt(np.mean(psi ** 2) / n)


# Proceso del caso canonico: theta = 0.5, n = 500, p = 20
rng = np.random.default_rng(0)
n, p, theta0 = 500, 20, 0.5
logistica = lambda z: 1 / (1 + np.exp(-z))
X = rng.standard_normal((n, p))
D = X[:, 0] + 0.25 * logistica(X[:, 2]) + rng.standard_normal(n)
Y = theta0 * D + logistica(X[:, 0]) + 0.25 * X[:, 2] + rng.standard_normal(n)

theta, se = dml_plr_manual(Y, D, X)
print(f"theta = {theta:.3f}  se = {se:.3f}  IC 95% = [{theta - 1.96 * se:.3f},
{theta + 1.96 * se:.3f}]")
assert abs(theta - theta0) < 5 * se and 0.01 < se < 0.2     # coherencia
```

Listado 10.1: Implementación manual de DML para PLR con cross-fitting.

```
import pandas as pd
from sklearn.ensemble import GradientBoostingRegressor

df = pd.read_csv("../data/datasets/real/public_causaldata/nsw_mixtape/
data.csv")
Y = df["re78"].values
D = df["treat"].values
X = df[["age", "educ", "black", "hisp", "marr", "nodegree", "re74",
"re75"]].values

theta, se = dml_plr_manual(Y, D, X, learner=lambda: GradientBoostingRegressor(
    n_estimators=200, max_depth=3, random_state=42))
print(f"ATE estimado: {theta:.0f}  (SE: {se:.0f})")
print(f"IC 95%: [{theta - 1.96 * se:.0f}, {theta + 1.96 * se:.0f}]")
```

Listado 10.2: DML aplicado a los datos del NSW (Lalonde).

El segundo listado usa la función del primero y sobre los datos reales no lleva comprobación automática: su resultado debe compararse con el contraste experimental de referencia del texto.

10.6 Riesgos, límites y sensibilidad

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Omitir *cross-fitting*	Sesgo de sobreajuste (caso 2)	Comparar con y sin él	Pliegues siempre; K de 4 a 5
Una sola división simple	Se pierde información y sube la varianza	Variabilidad entre particiones	Repetir y agregar
Learners sin revisar su tasa	Se incumple $\sqrt{n}a_n^2 \to 0$	Curvas de aprendizaje fuera de muestra	Elegir por validación; ensamblar
Score incorrecto para l_0	Se rompe la ortogonalidad	Qué *nuisance* se estima (g o l)	Forma de Robinson con $l_0 = E[Y \mid X]$
Ortogonalidad tomada por identificación	No corrige la confusión no observada	Revisar la no confusión (Capítulo 8)	Sensibilidad a confusores

Tabla 10.2: Errores comunes en la implementación de DML para el PLR.

Límites. El PLR supone un efecto constante de D. Si el efecto es heterogéneo en X, se requiere el modelo interactivo del Capítulo 11. Y la ortogonalidad no resuelve problemas de identificación: si el supuesto de no confusión se vulnera, ningún score ortogonal lo corrige.

10.7 Ejercicios y notas bibliográficas

10.7.1 Ejercicios teóricos

1. Calcule la derivada de Gateaux del score no ortogonal $D(Y - g(X) - \theta D)$ respecto de g y muestre que vale $-E\big[Dr_g(X)\big]$. ¿En qué caso se anula?
2. Con $\theta_0 = 0.5$ y $h = m_0$, deduzca los sesgos teóricos del primer caso canónico, $-\delta E[Dh]/E[D^2]$ para el score no ortogonal y $\delta^2(1-\theta)E[h^2]/(1+\delta^2 E[h^2])$ para el ortogonal, y compárelos con las cifras del caso.
3. Con $a_n = n^{-\frac{1}{4}}$, ¿se cumple $\sqrt{n}a_n^2 \to 0$? Dé la tasa mínima para cada *nuisance* si solo se exige que el producto de los errores sea $o\big(n^{-\frac{1}{2}}\big)$.
4. Explique por qué, sin *cross-fitting*, la condición de tasa no basta y hace falta una condición de complejidad sobre $\hat{\eta}$.

10.7.2 Ejercicios computacionales

1. Replique la comparación del segundo caso canónico con el listado 10.1: DML con y sin *cross-fitting* (misma muestra para *nuisance* y score). ¿En cuánto cambian el sesgo y la cobertura con un bosque de hojas pequeñas, y con boosting profundo?
2. Modifique el proceso para que g_0 sea lineal y compare DML con OLS. ¿En qué caso son equivalentes?
3. Sobre el conjunto `close_college`, aplique DML-PLR al retorno a la educación con `GradientBoostingRegressor` para los dos *nuisance* y compare con OLS.
4. Construya un proceso donde $\hat{g}$ tenga tasa $a_n = n^{-\frac{1}{4}}$ y verifique que la cobertura se degrada, ya que $\sqrt{n}a_n^2$ no tiende a cero.

10.7.3 Notas bibliográficas

Neyman (1959) es la referencia original sobre ortogonalidad; la condición (10.4) se conoce como ortogonalidad de Neyman por su test $C(\alpha)$, construido con la misma idea de insensibilidad de primer orden a los parámetros de estorbo. Robinson (1988) es la referencia canónica del score de residuo contra residuo que el capítulo usa en el modelo parcialmente lineal y que reaparece en el Capítulo 12 (R-learner) y en el Capítulo 17 (panel); suele darse por sabida sin citarse, y conviene leerla para ver que la idea de ortogonalizar antecede en tres décadas al uso del ML. Chernozhukov et al. (2018b) es el artículo fundacional de DML y contiene el desarrollo completo del teorema y de las variantes DML1 y DML2. Chernozhukov et al. (2016) extiende el marco a estimandos más complejos. Newey (1994) y Robins y Rotnitzky (1995) son precursores por la vía de la eficiencia semiparamétrica, y Bickel et al. (1993) es el tratamiento de referencia de esa teoría. Para una revisión pedagógica accesible, (Chernozhukov et al. 2018a).

CAPÍTULO 11

Double/Debiased Machine Learning

Cuadro sinóptico del capítulo

Problema:	Estimar retorno a la educación con controles de alta dimensión
Estimando:	θ_0, efecto parcial en PLR
Identificación:	No confusión condicional
Método:	DML-PLR / DML-IRM
Nuisance:	$\hat{m}(X) = E[D \mid X]$, $\hat{\ell}(X) = E[Y \mid X]$
Garantía:	$\sqrt{n}\left(\hat{\theta} - \theta_0\right) \xrightarrow{p} N(0, \mathcal{V})$
Condición clave:	$\sqrt{n}a_n^2 \to 0$
Librerías:	DoubleML, econml
Validación:	Placebos, sensibilidad a learners, cross-fitting

Nota técnica

Este capítulo aplica la ortogonalidad de Neyman y el *cross-fitting* del Capítulo 10 al caso más estándar: los modelos PLR e IRM de Double Machine Learning, el estimador que el servicio del Capítulo 15 pone en producción (el primer notebook de producción del curso, B1).

11.1 Problema causal, estimando e identificación

El Ministerio de Educación desea estimar el efecto causal de una beca sobre el rendimiento académico de estudiantes de secundaria. Dispone de un panel con 60 covariables por estudiante (características familiares, rendimiento previo, características de la escuela, contexto barrial, expectativas subjetivas). La asignación de la beca no fue aleatoria: se priorizó a estudiantes con bajo rendimiento previo, pero también influyeron variables familiares y de contexto. La pregunta de política es: ¿cuál es el efecto promedio de la beca sobre el rendimiento?

En el capítulo 10 demostramos que el score ortogonal de Neyman permite estimar θ_0 con inferencia válida cuando g_0 y m_0 se estiman con ML. Este capítulo desarrolla el procedimiento completo, cubriendo los dos modelos centrales de la literatura: el modelo parcialmente lineal (PLR) y el modelo interactivo (IRM), con la librería `DoubleML` (Bach, Chernozhukov, Kurz y Spindler, 2021) y con `econml.dml`. Discutimos la elección de *learners* de *nuisance*, la selección de hiperparámetros, la verificación de *leakage* en *cross-fitting* y la sensibilidad de los resultados a estas elecciones.

11.2 Teoría, supuestos y garantías

11.2.1 Supuestos

Los supuestos de identificación para DML son los mismos del capítulo 5. En particular, se requiere:

- **No confusión condicional:** $Y(0), Y(1) \perp\!\!\!\perp D \mid X$.
- **Soporte común:** $0 < P(D = 1 \mid X) < 1$ c.s.
- **Consistencia:** $Y = Y(D)$.

Bajo estos supuestos, el ATE se identifica como $\theta_0 = E[E[Y \mid D = 1, X] - E[Y \mid D = 0, X]]$.

11.2.2 Estimador y score

Modelo parcialmente lineal (PLR)

Reproducimos el modelo PLR del capítulo 10:

$$Y = D\theta_0 + g_0(X) + \varepsilon, \quad D = m_0(X) + v, \tag{11.1}$$

con $E[\varepsilon \mid D, X] = 0$ y $E[v \mid X] = 0$. El score ortogonal es:

$$\psi_{t\ \mathrm{PLR}}(W, \theta, \eta) = (D - m(X))(Y - g(X) - \theta D). \tag{11.2}$$

Si en lugar de g_0 se estima $\ell_0(X) = E[Y \mid X]$, el score ortogonal equivalente es el de Robinson, $(D - m(X))\{Y - \ell(X) - \theta(D - m(X))\}$, que es el que usa el algoritmo de esta sección.

Modelo interactivo (IRM)

El PLR asume que el efecto de D es constante. Cuando sospechamos heterogeneidad en X, el modelo interactivo (IRM) es más apropiado. En el IRM, las *outcome regressions* se modelan separadamente para $D = 0$ y $D = 1$:

$$Y = \mu(D, X) + \varepsilon, \quad D \sim \mathrm{Bernoulli}(e_0(X)), \tag{11.3}$$

donde $\mu(d, x) = E[Y \mid D = d, X = x]$ y $\mu_d(x) \equiv \mu(d, x)$.

Bajo los supuestos de identificación de no confusión condicional y soporte común del capítulo 5, el ATE se identifica como:

$$\theta_0 = E[\mu(1, X) - \mu(0, X)]. \tag{11.4}$$

El score ortogonal correspondiente, derivado por (Chernozhukov et al. 2018b), es:

$$\psi_{t\ \mathrm{IRM}}(W,\theta,\eta) = \mu(1,X) - \mu(0,X) + \frac{D(Y-\mu(1,X))}{e(X)} - \frac{(1-D)(Y-\mu(0,X))}{1-e(X)} - \theta, \tag{11.5}$$

donde $\eta = (\mu, e)$. Este score es la combinación clásica *doubly robust* de (Robins et al. 1994) ajustada para satisfacer ortogonalidad de Neyman. El score (11.5) es la instancia IRM de la forma canónica de la Nota técnica 10.2.4 la instancia sin promediar reaparece como Γ_i del DR--learner (Sección 12.2.5) y como EIF del *policy value* (Sección 21.2.2).

Teorema 11.1 ***(Doble robustez + ortogonalidad)***

El score (11.5) es ortogonal de Neyman respecto a $\eta = (\mu, e)$. Adicionalmente, es *double robust*: si $\hat{\mu}$ o $\hat{e}$ es consistente (no necesariamente ambos), $\hat{\theta}$ es consistente.

Teorema 11.2 ***(Eficiencia semiparamétrica del estimador DML-IRM)***

Bajo no confusión, soporte común y Y acotado, la *efficient influence function* (EIF) del funcional $\theta_0 = E[\mu(1,X) - \mu(0,X)]$ en el modelo IRM es exactamente el integrando del score (11.5):

$$\psi^*(W) = \mu_1(X) - \mu_0(X) + \frac{D(Y-\mu_1(X))}{e(X)} - \frac{(1-D)(Y-\mu_0(X))}{1-e(X)} - \theta_0. \tag{11.6}$$

Por la cota de Cramér-Rao semiparamétrica (Ap. A, Sección A.4.2), el estimador DML-IRM es asintóticamente eficiente: ningún estimador regular puede tener varianza asintótica menor que

$$V_{\text{eff}} = E\left[(\tau(X) - \theta_0)^2 + \frac{\sigma_1^2(X)}{e(X)} + \frac{\sigma_0^2(X)}{1-e(X)}\right], \tag{11.7}$$

con $\sigma_d^2(x) = \mathrm{Var}(Y \mid X = x, D = d)$. La doble robustez (teorema de la Sección 11.2.2) y la eficiencia son propiedades complementarias: la primera protege contra mala especificación de un *nuisance*; la segunda certifica que, cuando ambos *nuisance* convergen, no se puede hacer mejor. Los ejemplos de IF del Ap. A (Sección A.10) son las instancias de este resultado para IRM y PLR.

11.2.3 Garantías

Bajo condiciones de regularidad y tasas de convergencia de los *learners* nuisance, el estimador DML satisface:

$$\sqrt{n}\left(\hat{\theta} - \theta_0\right) \xrightarrow{p} N(0, \mathcal{V}), \tag{11.8}$$

donde $\mathcal{V}$ es la varianza asintótica. La condición clave para que el error de los *learners* nuisance no afecte la distribución asintótica es:

$$\sqrt{n}\, a_n^2 \to 0, \tag{11.9}$$

donde a_n es la tasa de convergencia del *learner* nuisance más lento.

La tabla 11.1 resume las opciones más usadas para estimar $\hat{g}, \hat{m}, \hat{\mu}, \hat{e}$, con sus tasas de convergencia típicas.

Learner	Cuándo usar	Tasa a_n típica	Notas
Bosque aleatorio	No lineal, interactivo	$n^{-\frac{2}{5}}$	Robusto, fácil de ajustar
Boosting de gradiente	No lineal, alta dimensión	$n^{-\frac{2}{5}}$	Suele competir con el bosque en alta dimensión; más hiperparámetros
LASSO con validación cruzada	Lineal, esparso, $p \gg n$	$\sqrt{s \log \frac{p}{n}}$	Requiere esparsidad
Ridge	Lineal, denso	$n^{-\frac{1}{2}}$ si p fijo	No hace selección
Boosting de histogramas	No lineal, $n > 10^5$	$n^{-\frac{2}{5}}$	Escalable
Red neuronal	No lineal complejo	depende	Sensible a hiperparámetros

Tabla 11.1: Learners comunes para nuisance en DML.

La condición $\sqrt{n}a_n^2 \to 0$ se satisface para $a_n = n^{-\frac{2}{5}}$ (bosques, boosting) porque $\sqrt{n} \cdot n^{-\frac{4}{5}} = n^{-\frac{3}{10}} \to 0$. Para LASSO bajo esparsidad, la condición es $s \log p = o(\sqrt{n})$. Las tasas de la tabla valen bajo supuestos de suavidad, esparsidad o dimensión baja; en un problema concreto la condición se **supone** y se vigila de forma indirecta (con el R^2 fuera de muestra de los *nuisance* y con la sensibilidad del resultado a la elección del *learner*), no se verifica.

Los hiperparámetros de los *learners* (profundidad de árboles, *learning rate*, λ de LASSO) se seleccionan típicamente por *cross-validation* dentro de cada *fold* de *cross-fitting*. Esto significa que el costo computacional es $K \times$ (CV interno). Una buena práctica es reportar la sensibilidad de los resultados a la elección de *learner* y de hiperparámetros.

11.2.4 Diagnósticos cuantitativos de soporte común

La alerta «$\hat{e}$ cerca de 0 o 1» (Tabla 11.2) se vuelve operativa con dos cantidades medibles.

ESS de Kish. Para la componente IPW del estimador, el tamaño efectivo de muestra es

$$\mathrm{ESS} = \frac{\left(\sum_i w_i\right)^2}{\sum_i w_i^2}, \quad w_i = \frac{D_i}{\hat{e}}(X_i). \tag{11.10}$$

$\frac{\mathrm{ESS}}{n} \ll 1$ señala que pocas unidades con $\hat{e}$ extremo dominan la estimación: el soporte común es formalmente escaso aunque el histograma de $\hat{e}$ «se vea bien» ((Kish 1965)).

Trimming óptimo. Crump et al. (2009) derivan la regla de recorte simétrico $\hat{e}(X) \notin [\alpha, 1-\alpha]$ que minimiza la varianza asintótica del ATE; el α^* óptimo resuelve una condición de punto fijo sobre la varianza condicional y, en general, no tiene forma cerrada simple. Como regla práctica, que en su artículo funciona bien en un amplio rango de distribuciones del propensity score, proponen $\alpha \approx 0.1$, es decir, descartar $\hat{e}(X) \notin [0.1, 0.9]$. **Atención al estimando:** tras

Algoritmo

Entrada: $(Y_i, D_i, X_i)_{i=1}^n$, learner L, folds K
Salida: $\hat{\theta}$, (SE)
Partir los índices en K folds.
for k = 1 **to** K **do**

Estimar $\hat{\ell}_{-k}(x) = E[Y \mid X = x]$ con los datos fuera del fold k y predecir dentro del fold k
Estimar $\hat{m}_{-k}(x) = E[D \mid X = x]$ con los datos fuera del fold k y predecir dentro del fold k

end for
Calcular residuos con las predicciones fuera de muestra: $u_i = Y_i - \hat{\ell}(X_i)$, $v_i = D_i - \hat{m}(X_i)$
$\hat{\theta} = \frac{\sum_i v_i u_i}{\sum_i v_i^2}$
Calcular la influence function $\psi_i = v_i\big(u_i - \hat{\theta} v_i\big)$ y (SE) $= \frac{\sqrt{\sum_i \psi_i^2}}{\sum_i v_i^2}$

Algoritmo 6. DML con cross-fitting

el *trimming*, el efecto identificado es el ATE sobre la población con *overlap*, no el ATE poblacional, y declararlo en la *model card* (Capítulo 19) es obligatorio.

Regla operativa: reportar $\frac{\text{ESS}}{n}$ y el rango de $\hat{e}$ en todo resultado DML; si $\hat{e} \notin [0.05, 0.95]$ para más del 5 % de la muestra, reestimar con *trimming* y reportar ambas cifras. El mismo diagnóstico se hereda en el DR-learner (Sección 12.2.5) y en el *net score* del Capítulo 22.

11.3 Algoritmo e implementación

La verificación de que el *cross-fitting* se hizo bien se reduce a cuatro invariantes sobre las particiones y los modelos:

1. Las particiones de prueba cubren cada observación exactamente una vez, y ninguna observación está a la vez en el entrenamiento y la prueba de un mismo fold.
2. Los modelos de *nuisance* que predicen la unidad i no se entrenaron con la unidad i.
3. Todo preprocesamiento (escalado, selección de variables, imputación) se ajusta solo con los datos de entrenamiento de cada fold.
4. Con particiones y semilla fijas la estimación es reproducible; al repetir el *cross-fitting* con otras particiones, la dispersión entre repeticiones es pequeña frente al error estándar, o se reporta.

Caso canónico · Con y sin cross-fitting

Cinco covariables independientes y uniformes en $[-1, 1]$. Una función no lineal $h(X) = \sin(3x_0) + x_1^2$ confunde la relación: el tratamiento es $D = h(X) + \varepsilon_D$ y el resultado es $Y = 1 \cdot D + 2h(X) + \varepsilon_Y$, con ruido normal estándar. El efecto verdadero es $\theta_0 = 1$. Con 2 000 unidades y 20 repeticiones, los tres estimadores dan:

Estimador	Media	Desv. típica
OLS con las cinco covariables lineales	1,41	0,025

Estimador	Media	Desv. típica
DML con boosting, sin *cross-fitting*	0,86	0,042
DML con boosting, con *cross-fitting* ($K = 5$)	0,95	0,021

El OLS sufre un sesgo grande y estable, de unos 0,4 (la confusión no lineal no se captura con controles lineales). El DML sin *cross-fitting* usa un *learner* flexible para ajustar y para predecir sobre los mismos datos: los residuos quedan subestimados y el estimador pierde parte del efecto, con un sesgo de unos 0,14 hacia abajo. Con *cross-fitting* el sesgo cae a unos 0,05. El sesgo que queda es el del error de estimación de los *nuisance* con este tamaño muestral, que se reduce con más datos o con un *learner* mejor ajustado.

11.3.1 DML con DoubleML para PLR

```
import doubleml as dml
from sklearn.ensemble import RandomForestRegressor, RandomForestClassifier
from sklearn.linear_model import LassoCV, LogisticRegressionCV
import pandas as pd

df = pd.read_csv("../data/datasets/real/public_causaldata/nsw_mixtape/
data.csv")
Y = df["re78"].values
D = df["treat"].values
X = df[["age","educ","black","hisp","marr","nodegree","re74","re75"]].values

# PLR con Random Forest
obj_dml = dml.DoubleMLPLR(
    dml.DoubleMLData.from_arrays(X, Y, D),
    ml_l=RandomForestRegressor(n_estimators=200, min_samples_leaf=20,
random_state=42),
    ml_m=RandomForestRegressor(n_estimators=200, min_samples_leaf=20,
random_state=42),
    n_folds=5,
)
obj_dml.fit()
print(obj_dml.summary)
```

Listado 11.1: DML con librería DoubleML sobre NSW.

11.3.2 DML con econml para CATE bajo PLR/etapa final lineal

```
from econml.dml import LinearDML, CausalForestDML
from sklearn.ensemble import GradientBoostingRegressor,
GradientBoostingClassifier

# LinearDML: asume CATE lineal en X
```

```
est = LinearDML(
    model_y=GradientBoostingRegressor(n_estimators=200, max_depth=4,
random_state=42),
    model_t=GradientBoostingClassifier(n_estimators=200, max_depth=4,
random_state=42),
    discrete_treatment=True,
    cv=5,
    random_state=42,
)
est.fit(Y, D, X=X)
# ATE
ate = est.ate(X=X)
ate_lb, ate_ub = est.ate_interval(X=X, alpha=0.05)
print(f"ATE: {ate:.2f}  IC 95%: [{ate_lb:.2f}, {ate_ub:.2f}]")

# CATE para los primeros 5 individuos
cate = est.effect(X[:5], T0=0, T1=1)
print(f"CATE (5 primeros): {cate}")
```

`LinearDML` implementa un modelo parcialmente lineal con etapa final lineal en X. No es una implementación general del score IRM no paramétrico para CATE.

11.3.3 Comparación de learners

Una práctica recomendada es comparar varios *learners* para verificar robustez:

```
from sklearn.linear_model import LassoCV, LogisticRegressionCV
from sklearn.ensemble import RandomForestRegressor

learners = {
    "Lasso": (LassoCV(cv=5), LogisticRegressionCV(cv=5, max_iter=1000)),
    "RF":    (RandomForestRegressor(n_estimators=200, min_samples_leaf=20,
random_state=42),
              RandomForestClassifier(n_estimators=200, min_samples_leaf=20,
random_state=42)),
    "GBM":   (GradientBoostingRegressor(n_estimators=200, max_depth=3,
random_state=42),
              GradientBoostingClassifier(n_estimators=200, max_depth=3,
random_state=42)),
}

for name, (ml_y, ml_t) in learners.items():
    est = LinearDML(model_y=ml_y, model_t=ml_t, discrete_treatment=True,
                    cv=5, random_state=42).fit(Y, D, X=X)
    ate = est.ate(X=X); lb, ub = est.ate_interval(X=X, alpha=0.05)
    print(f"{name:>8}: ATE={ate:7.2f}  IC=[{lb:7.2f}, {ub:7.2f}]")
```

11.3.4 Verificación de leakage

El *leakage* entre *folds* de *cross-fitting* invalida la inferencia. `DoubleML` y `econml` manejan esto internamente, pero los invariantes 1 y 2 de la sección anterior se pueden comprobar sobre las particiones:

```
import numpy as np
from sklearn.model_selection import KFold

def verificar_cross_fitting(n, n_folds=5, seed=42):
    """Comprueba los invariantes 1 y 2 sobre las particiones de cross-
fitting."""
    kf = KFold(n_splits=n_folds, shuffle=True, random_state=seed)
    veces_en_prueba = np.zeros(n, dtype=int)
    for entrenamiento, prueba in kf.split(np.arange(n)):
        assert np.intersect1d(entrenamiento, prueba).size == 0, \
            "una unidad esta en el entrenamiento y en la prueba del mismo fold"
        veces_en_prueba[prueba] += 1
    assert (veces_en_prueba == 1).all(), \
        "alguna unidad no esta en exactamente un fold de prueba"
    return True

print(verificar_cross_fitting(len(Y)))
```

Si D es binario, puede usarse un clasificador con `predict_proba` para el propensity, pero para el score de Robinson basta con estimar $E[D \mid X]$.

Intuición

Caja de profundización: Refutación y diagnósticos de robustez

Objetivo. Aprender a poner a prueba un estimador DML antes de confiar en sus resultados.

Pruebas de refutación («¿y si...?»).

- **Placebo treatment:** reemplazar D por una variable aleatoria. El ATE debería ser cero. Si no lo es, algo anda mal.
- **Random common cause:** agregar una variable aleatoria como confusora. El ATE no debería cambiar sustancialmente.
- **Subset validation:** estimar en la mitad de los datos y verificar que el resultado es similar.

Diagnósticos de nuisance.

- Distribución de $\hat{e}(X)$: si hay valores muy cercanos a 0 o 1, el estimador puede ser inestable.
- Comparar learners: si LASSO, bosques aleatorios y boosting dan ATE similares, hay más confianza.

11.4 Caso empírico y validación

El diseño de referencia para esta parte del capítulo es el de (Card 1995), que instrumenta los años de educación con la proximidad geográfica a una universidad de cuatro años, bajo el argumento de que vivir cerca de una universidad reduce el costo de asistir sin afectar directamente el salario. (Conviene no confundirlo con el otro diseño IV clásico de la literatura de retornos a la educación, el de (Angrist y Krueger 1991), que usa el trimestre de nacimiento interactuado con las leyes de escolaridad obligatoria.) Chernozhukov et al. (2018b) desarrollan la extensión de DML a este tipo de diseño. El modelo es *partial linear IV*:

$$Y = D\theta_0 + g_0(X) + \varepsilon, \quad Z = r_0(X) + \zeta, \quad D = m_0(Z, X) + v, \tag{11.11}$$

donde Z es el instrumento. `DoubleML` ofrece el método `DoubleMLPLIV` para este caso.

Réplica propia sobre el dataset del repositorio. Hemos replicado el ejercicio sobre `close_college` (Card 1995) con $n = 3\,003$ observaciones y controles `black, smsa, south, married, exper`. Los resultados obtenidos son:

- OLS con controles (HC1): coeficiente de `educ` $= 0.071$, IC 95% $[0.064, 0.078]$.
- IV 2SLS clásico (`nearc4` como instrumento): coeficiente $= 0.124$, IC 95% $[0.028, 0.221]$.
- DML-PLIV con `GradientBoostingRegressor` para nuisance: coeficiente $= 0.145$, IC 95% $[0.052, 0.237]$.

Estos números constituyen una *réplica propia* sobre el dataset del repositorio y *no* corresponden a las cifras originales del *paper* de (Chernozhukov et al. 2018b), que utiliza una muestra distinta. **Aviso:** la réplica incluye `exper` entre los controles. Como se advirtió en el Capítulo 4, la experiencia potencial es función de la educación (edad menos educación menos seis), de modo que es una variable posterior al tratamiento y debe excluirse; estas cifras deben recalcularse sin ella antes de citarse.

La figura 11.1 muestra que el estimador DML es estable entre $K = 2$ y $K = 10$, con una varianza moderadamente creciente a K bajos. Esto respalda la recomendación operacional de usar $K \in \{4, 5\}$ como compromiso entre sesgo (favorece K alto) y varianza (favorece K bajo).

Conviene leer la comparación entre estimadores con cuidado y no como «IV corrige el sesgo de OLS y DML lo corrige mejor». Los tres estimadores de este diseño (OLS con controles, 2SLS y DML con instrumento) estiman objetos distintos. El coeficiente OLS es un efecto parcial bajo no confusión condicional en los controles observados, un supuesto que casi nadie defiende para la educación, por la habilidad no observada. Los dos estimadores IV recuperan, bajo monotonicidad y exclusión, un efecto promedio ponderado sobre los individuos cuya decisión educativa efectivamente respondió a vivir cerca de una universidad (un **LATE**), un subgrupo que no es la población general y que plausiblemente enfrentaba restricciones de crédito más severas. Que la estimación IV sea mayor que la de OLS, como suele ocurrir en esta literatura, es consistente con al menos dos explicaciones sustantivas distintas, la heterogeneidad del efecto concentrada en los *compliers* o el error de medición en la educación que atenúa el OLS, y la evidencia de un solo estudio no las separa. El intervalo IV es mucho más ancho que el de OLS, y esa amplitud tiene una lectura mecánica: es el precio de identificar con la variación limitada

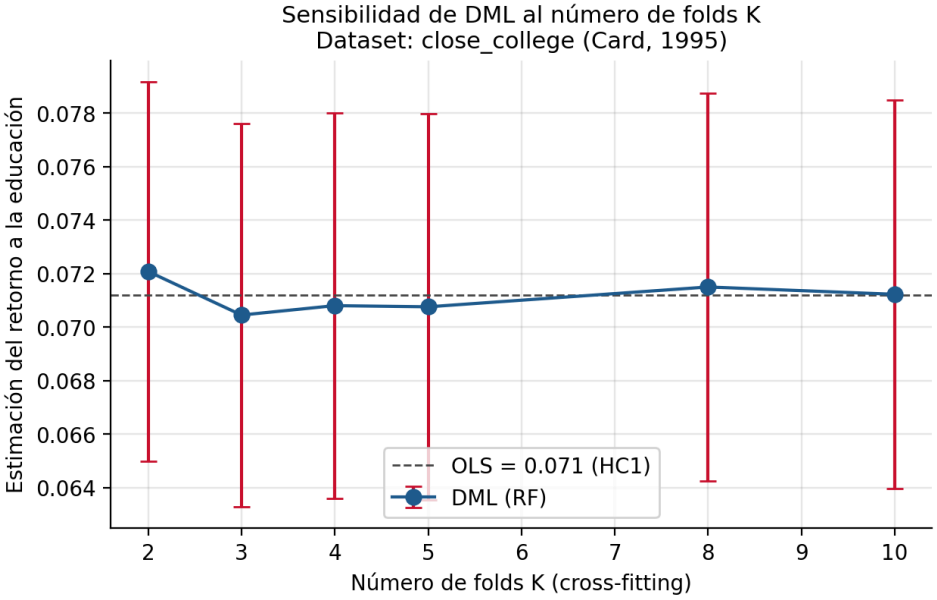


Figura 11.1: Sensibilidad de la estimación DML-PLIV del retorno a la educación al número de folds K del cross-fitting. Las barras indican IC al 95%. La línea punteada es la estimación OLS con controles (HC1). Dataset: `close_college` (Card, 1995), $n = 3\,003$. La sensibilidad a K bajo se mitiga con *repeated cross-fitting* (Nota técnica 10.2.4).

que induce un instrumento de fuerza moderada, y anticipa la discusión de instrumentos débiles del Capítulo 17.

11.5 Riesgos, límites y sensibilidad

Riesgo	Descripción
Learner único	Reportar un único *learner* sin análisis de sensibilidad. Siempre comparar al menos dos *learners* (lineal + no lineal). Divergencias grandes señalan problemas de especificación.
Folds insuficientes	Usar $K = 2$ *folds*. Con $K = 2$, la varianza del estimador aumenta sustancialmente. Recomendado: $K = 4$ o $K = 5$, con *repeated cross-fitting* ($R \geq 5$) si la varianza entre particiones es material (Nota técnica 10.2.4).
Soporte común ignorado	Si $\hat{e}(X)$ está muy cerca de 0 o 1, las ponderaciones IPW explotan. Reportar $\frac{\text{ESS}}{n}$ y rango de $\hat{e}$; *trimming* con $\alpha \approx 0.1$ ((Crump et al. 2009), Sección 11.2.4).
Confusión no observada	Asumir que DML «resuelve» la confusión no observada. DML requiere el supuesto de no confusión condicional. Si hay variables confusoras no observadas, DML es tan sesgado como OLS.

Riesgo	Descripción
Fuga entre *folds*	Predecir una unidad con un modelo entrenado con ella, o ajustar el preprocesamiento con todos los datos: los residuos quedan subestimados y la inferencia deja de ser válida. Comprobar los cuatro invariantes del *cross-fitting*.

Tabla 11.2: Riesgos comunes en DML

Límites del PLR. El PLR asume efecto constante de D. Si el efecto es heterogéneo, θ_0 se interpreta como un promedio ponderado que puede diferir del ATE. Para heterogeneidad explícita, usar IRM o bosques causales (capítulo 13). Un modelo parcialmente lineal con etapa final lineal en X estima un efecto lineal en las covariables; para un CATE no paramétrico bajo la estructura IRM hay que recurrir al DR-learner, a bosques causales o a scores localizados (Capítulo 12 y Capítulo 13).

Límites del IRM. El IRM permite heterogeneidad pero asume *unconfoundedness*. Si el tratamiento es endógeno por variables no observadas, se requiere DML con instrumentos (DMLIV).

Diagnósticos recomendados

Diagnóstico	Qué evaluar	Señal de alerta
Overlap	Histograma de $\hat{m}(X)$	Valores cerca de 0 o 1
Nuisance	R^2 fuera de muestra	R^2 bajo
Leakage	Invariantes del *cross-fitting*	Alguna unidad predicha con un modelo que la vio
Estabilidad	Cambio de learner	ATE cambia mucho

11.6 Ejercicios y notas bibliográficas

11.6.1 Ejercicios teóricos

1. Demuestre que el score IRM de la (11.5) tiene esperanza cero en θ_0 cuando μ y e son los verdaderos, y que sigue teniéndola si solo uno de los dos es correcto.
2. Explique por qué estimar los *nuisance* y calcular los residuos sobre las mismas observaciones sesga el estimador cuando el *learner* es flexible, y por qué el *cross-fitting* lo evita.
3. En una muestra, el propensity estimado toma el valor 0,5 en 90 unidades tratadas y el valor 0,02 en 10 unidades tratadas. Calcule el ESS de Kish de la componente IPW y compárelo con el número de unidades tratadas. ¿Qué indica?

11.6.2 Ejercicios computacionales

1. Replique el listado 11.1 variando $K \in \{2, 3, 5, 10\}$. ¿Cómo cambia el error estándar con K?
2. Sobre el dataset `cps_mixtape`, estime el efecto de la educación sobre el salario con DML-PLR y compare con OLS. ¿En qué dirección cambia el estimado al usar DML?
3. Sobre `nhefs`, estime el efecto de dejar de fumar sobre el cambio de peso con: (a) OLS con controles manuales, (b) DML-PLR con GBM, (c) DML-IRM con GBM. Compare.
4. Verifique empíricamente la doble robustez: reemplace $\hat{\mu}$ por una constante (modelo mal especificado) y observe que el ATE sigue siendo consistente si $\hat{e}$ es consistente.

Chernozhukov et al. (2018b) es el *paper* fundacional. Foster y Syrgkanis (2019) extiende el marco a casos más generales. Para una revisión pedagógica, (Chernozhukov et al. 2018a). Bach et al. (2022) documenta la librería `DoubleML` y Battocchi et al. (2019) documenta `econml`.

CAPÍTULO 12

Meta-learners para efectos de tratamiento heterogéneos

Cuadro sinóptico del capítulo

Problema:	Estimar CATE sin asumir forma funcional
Estimando:	$\tau(x) = E[Y(1) - Y(0) \mid X = x]$
Identificación:	No confusión, soporte común, SUTVA
Método:	S-learner, T-learner, X-learner, R-learner, DR-learner
Nuisance:	$\mu_1(x), \mu_0(x), e(x)$
Garantía:	Cuasi-oracle (R-learner); tasa oracle bajo producto de tasas (DR--learner); bootstrap (T, X)
Condición clave:	Ortogonalidad + cross-fitting (R-learner)
Librerías:	causalml, econml
Validación:	Calibración de CATE, placebos, Qini

Nota técnica

El Capítulo 11 estimó un efecto promedio (ATE); este capítulo da el primer paso hacia la heterogeneidad, estimando el efecto condicional $\tau(x) = E[Y(1) - Y(0) \mid X = x]$ mediante cinco estrategias de meta-aprendizaje que reutilizan directamente los *learners* ya vistos.

12.1 Problema causal, estimando e identificación

Una organización no gubernamental debe decidir a cuál de dos variantes de un programa de microcrédito ofrecer a cada cliente. La variante A tiene tasas de interés más bajas pero requiere reuniones grupales semanales; la variante B tiene tasas más altas pero es individual. El efecto sobre el repago difiere según características del cliente (experiencia previa, red social, sector

económico). La pregunta de política no es «¿cuál es el efecto promedio de A vs B?», sino «¿a qué clientes conviene asignar A y a cuáles B?».

Para responder a esta pregunta se necesita estimar el *CATE* $\tau(x) = E[Y(1) - Y(0) \mid X = x]$ como función de X, no solo el ATE. Los *meta-learners* (S-learner, T-learner, X-learner, R--learner y DR-learner) son estrategias para construir un estimador de $\tau(x)$ a partir de cualquier algoritmo supervisado de ML. Fueron formalizados por (Künzel et al. 2019) (S, T, X), (Nie y Wager 2021) (R-learner) y (Kennedy 2023) (DR-learner).

Este capítulo presenta los cinco *meta-learners*, sus propiedades estadísticas (sesgo, varianza, tasa de convergencia) y una comparación sobre un caso sintético con CATE conocido. Mostramos que ningún *meta-learner* es uniformemente dominante: el S-learner sufre de *regularization bias*, el T-learner sufre de alta varianza cuando un grupo es pequeño, el X-learner mitiga ambos pero requiere estimación de propensity score, y el R-learner y el DR-learner tienen las mejores garantías asintóticas pero dependen de un propensity bien estimado y de una regresión final que absorba el ruido del pseudo-resultado.

12.2 Teoría, supuestos y garantías

12.2.1 El S-learner

El S-learner (*single-learner*) entrena un único modelo predictivo $\hat{\mu}(D, X)$ que toma D como una covariable más. La estimación del CATE es:

$$\hat{\tau}_S(x) = \hat{\mu}(1, x) - \hat{\mu}(0, x). \tag{12.1}$$

Ventajas. Usa toda la muestra para entrenar; aprovecha cualquier algoritmo supervisado.

Problema. El algoritmo puede *ignorar* D si D tiene poco poder predictivo sobre Y comparado con X, especialmente bajo regularización. En el extremo, $\hat{\mu}(1, x) = \hat{\mu}(0, x)$ y $\hat{\tau}_S(x) = 0$ para todo x.

12.2.2 El T-learner

El T-learner (*two-learner*) entrena dos modelos separados:

$$\hat{\mu}_1(x) = \mathrm{ML}(Y \mid X, D = 1), \quad \hat{\mu}_0(x) = \mathrm{ML}(Y \mid X, D = 0), \tag{12.2}$$

y estima $\hat{\tau}_T(x) = \hat{\mu}_1(x) - \hat{\mu}_0(x)$.

Ventajas. Garantiza que D afecta la predicción (no puede ser ignorado).

Problema. Cada modelo se entrena solo con la submuestra correspondiente. Si un grupo es pequeño (p. ej., 10 % tratados), $\hat{\mu}_1$ tiene alta varianza.

12.2.3 El X-learner

El X-learner (Künzel et al. 2019) usa tres etapas:

1. Entrenar $\hat{\mu}_1$ y $\hat{\mu}_0$ como en el T-learner.

2. Para las unidades tratadas, computar $\tilde{\tau}_1^i = Y_i - \hat{\mu}_0(X_i)$; entrenar un modelo $\hat{\tau}_1(x) = \text{ML}(\tilde{\tau}_1 \mid X, D = 1)$.
   Para las unidades control, computar $\tilde{\tau}_0^i = \hat{\mu}_1(X_i) - Y_i$; entrenar $\hat{\tau}_0(x) = \text{ML}(\tilde{\tau}_0 \mid X, D = 0)$.
3. Combinar: $\hat{\tau}_X(x) = \hat{e}(x)\hat{\tau}_0(x) + (1 - \hat{e}(x))\hat{\tau}_1(x)$, donde $\hat{e}(x)$ es el *propensity score* estimado.

Intuición

El paso 2 imputa efectos individuales usando el modelo del grupo opuesto: para una unidad tratada, el contrafactual sin tratamiento sale de $\hat{\mu}_0$, estimado con los controles. Cuando hay pocos tratados, $\hat{\mu}_0$ se estima bien (hay muchos controles) y $\hat{\tau}_1$ se apoya en una imputación precisa, mientras que $\hat{\tau}_0$ depende de $\hat{\mu}_1$, estimado con pocos datos. Con la ponderación $\hat{e}(x)$ la combinación da más peso a $\hat{\tau}_1$ justo cuando los tratados son pocos, que es lo que esa lógica recomienda. Es una convención común, no la única: la ponderación óptima depende de las varianzas de $\hat{\tau}_0$ y $\hat{\tau}_1$.

12.2.4 R-learner: Estimador y score

El R-learner (Nie y Wager 2021) optimiza directamente una *loss* que aísla el CATE usando el score ortogonal de Robinson. La forma del score del R-learner deriva del **score de Robinson** ((Robinson 1988)), el mismo que el Capítulo 10 usó para estimar un efecto constante, ahora con θ reemplazado por una función $\tau(\cdot)$ que se optimiza sobre una clase de funciones:

$$\hat{\tau}_R = \text{argmin}_\tau \left\{ \frac{1}{n} \sum_i \left[(Y_i - \hat{m}_Y(X_i)) - \tau(X_i)(D_i - \hat{e}(X_i)) \right]^2 + \Lambda(\tau) \right\}, \tag{12.3}$$

donde $\hat{m}_Y(X)$ es la *outcome regression* de Y sobre X, $\hat{e}(X)$ es el *propensity score*, y $\Lambda(\tau)$ es un regularizador.

Teorema 12.1 ***(Nie y Wager, 2021)***

Bajo no confusión, soporte común, y tasas de convergencia $\|\hat{m}_Y - m_Y\|_{L^2} = O_p(a_n)$ y $\|\hat{e} - e\|_{L^2} = O_p(a_n)$ con $\sqrt{n}a_n^2 \to 0$, el R-learner alcanza tasas cuasi-oracle para $\tau(\cdot)$ bajo condiciones de ortogonalidad, cross-fitting y tasas de convergencia apropiadas para los nuisance. La consistencia $\sqrt{n}$ y la eficiencia semiparamétrica aplican a funcionales de dimensión finita, como el ATE, o a clases paramétricas de $\tau(x)$. Para el CATE no paramétrico punto a punto, la tasa depende de la suavidad local, la dimensión de X y el learner utilizado.

El R-learner es preferible cuando se dispone de suficiente muestra para estimar $\hat{m}_Y, \hat{e}$ con precisión, y cuando se quiere inferencia asintótica válida sobre $\tau(x)$.

12.2.5 El DR-learner

Los tres primeros meta-learners (S, T y X) comparten un límite: el error de los *nuisance* se propaga al CATE a primer orden. El R-learner lo evita con la ortogonalidad de Robinson, a

costa de optimizar una pérdida con residuos. El **DR-learner** ((Kennedy 2023)) ofrece otra salida, más sencilla de implementar, aplicando al CATE la misma lógica que DML aplicó al ATE: construir un pseudo-resultado cuyo valor esperado condicional **es** el CATE, y luego regresarlo sobre X con cualquier método supervisado.

El procedimiento tiene tres etapas, todas con cross-fitting:

1. Estimar los *nuisance* $\hat{\mu}_0, \hat{\mu}_1, \hat{e}$ en particiones ajenas.
2. Construir, para cada observación, el **pseudo-resultado doblemente robusto**

$$\Gamma_i = \hat{\mu}_1(X_i) - \hat{\mu}_0(X_i) + \frac{D_i(Y_i - \hat{\mu}_1(X_i))}{\hat{e}}(X_i) - \frac{(1 - D_i)(Y_i - \hat{\mu}_0(X_i))}{1 - \hat{e}(X_i)}. \quad (12.4)$$

3. Estimar $\hat{\tau}_{\text{DR}}(x) = \hat{E}[\Gamma \mid X = x]$ mediante una regresión ordinaria de Γ sobre X.

La observación clave es que Γ_i es el integrando del score IRM del Capítulo 11 **antes** de promediar (sin restar θ): promediarlo sobre toda la muestra da el ATE; regresarlo sobre X da el CATE. La doble robustez se hereda punto a punto: $E[\Gamma \mid X = x] = \tau(x)$ si $\hat{\mu}_d$ **o** $\hat{e}$ es correcto, no necesariamente ambos, caso particular de la forma canónica de la Nota técnica 10.2.4.

Teorema 12.2 ***(Kennedy, 2023: tasa oracle del DR-learner)***

Bajo no confusión, soporte común y cross-fitting, el error del DR-learner se acota por la suma de dos términos: el error que tendría un **oracle** que observara los verdaderos pseudo-resultados Γ_i^* (construidos con μ_d y e verdaderos), más un término de segundo orden proporcional al **producto** de los errores de $\hat{\mu}_d$ y $\hat{e}$. En particular, si ambos *nuisance* convergen a tasa a_n con a_n^2 menor que la tasa oracle de la regresión final, el DR-learner alcanza esa tasa oracle.

La estructura de **producto** de errores es lo que distingue al DR-learner del T- y el X-learner, cuyos errores dependen de los *nuisance* de forma aditiva y de primer orden. En la práctica esto significa que el DR-learner tolera *nuisance* mediocres siempre que no fallen los dos a la vez, y es la razón por la que es el meta-learner por defecto cuando se quiere una garantía y no solo un estimador razonable. Su costo es la inestabilidad heredada del término IPW: cuando $\hat{e}(x)$ se acerca a 0 o 1, Γ_i explota, y sin *trimming* o recorte de pesos el estimador puede tener varianza inaceptable. El mismo diagnóstico de soporte común que el Capítulo 11 exige antes de reportar un ATE se vuelve aquí obligatorio antes de reportar un CATE (Sección 11.2.4 para el protocolo cuantitativo). En `econml`, la implementación es `DRLearner` (y sus variantes `LinearDRLearner` y `ForestDRLearner` según el regresor de la tercera etapa); en `causalml`, `BaseDRRegressor`.

12.2.6 Comparación de propiedades

Propiedad	S-learner	T-learner	X-learner	R-learner	DR-learner
Sesgo	Alto (regularización)	Medio	Bajo	Bajo	Bajo
Varianza	Bajo	Alto (grupo pequeño)	Medio	Medio	Alta si $\hat{e}$ extremo

Propiedad	S-learner	T-learner	X-learner	R-learner	DR-learner
Requiere $\hat{e}$	No	No	Sí	Sí	Sí
Dependencia de los *nuisance*	1.er orden	1.er orden	1.er orden	2.º orden	2.º orden (producto)
Inferencia válida	No	Bootstrap	Bootstrap	Asintótica local bajo condiciones	Asintótica local; oracle bajo tasas
Tasa $\tau(x)$	a_n	a_n	a_n	cuasi-oracle/local; $\sqrt{n}$ solo para ATE/funcionales	oracle de la regresión final si a_n^2 es despreciable
Implementación	Trivial	Simple	Media	Compleja	Media

Tabla 12.1: Comparación de meta-learners.

La fila decisiva es la de **dependencia de los nuisance**. S, T y X heredan el error de $\hat{\mu}_d$ (y de $\hat{e}$, en el caso de X) de forma aditiva: si los *learners* auxiliares convergen a tasa a_n, el CATE estimado también, y no mejor. R y DR lo heredan a segundo orden (el producto de los errores en el caso del DR-learner), que es la misma propiedad que hace funcionar a DML y la razón por la que son los únicos dos de la familia con garantías del tipo «el ML puede ser mediocre y el estimador causal seguir siendo bueno». Son garantías **asintóticas**: la tabla de propiedades no dice qué estimador gana con una muestra moderada, y el caso canónico que sigue es un recordatorio de ello.

Intuición

Caja de profundización: calibración de efectos y ETT

Objetivo. Verificar si los efectos estimados tienen sentido, y distinguir el estimando poblacional del estimando sobre los tratados.

Calibración de CATE. Una forma simple de verificar si los CATE tienen sentido:

1. Ordenar individuos por $\hat{\tau}(x)$ de menor a mayor.
2. Dividir en 10 grupos (decilas).
3. Calcular el uplift promedio observado en cada decila.
4. Graficar: si el modelo es bueno, el uplift observado debe aumentar con las decilas.

ETT (Effect on the Treated). No solo importa el ATE. A veces queremos saber: ¿cuánto afectó el tratamiento a quienes realmente lo recibieron?

$$\text{ETT} = E[Y(1) - Y(0) \mid D = 1] \tag{12.5}$$

Algoritmo

Entrada: Datos $(Y_i, D_i, X_i)_{i=1}^n$, modelos ML para $\hat{\mu}_1, \hat{\mu}_0, \hat{\tau}_1, \hat{\tau}_0$, estimador de propensity $\hat{e}$.
Salida: Estimación $\hat{\tau}_X(x)$ del CATE.
Entrenar $\hat{\mu}_1(x)$ con (X_i, Y_i) para $D_i = 1$.
Entrenar $\hat{\mu}_0(x)$ con (X_i, Y_i) para $D_i = 0$.
Para cada $i : D_i = 1$: $\tilde{\tau}_1^i \leftarrow Y_i - \hat{\mu}_0(X_i)$.
Para cada $i : D_i = 0$: $\tilde{\tau}_0^i \leftarrow \hat{\mu}_1(X_i) - Y_i$.
Entrenar $\hat{\tau}_1(x)$ con $(\tilde{\tau}_1^i, X_i)$ para $D_i = 1$.
Entrenar $\hat{\tau}_0(x)$ con $(\tilde{\tau}_0^i, X_i)$ para $D_i = 0$.
Estimar $\hat{e}(x)$ con todos los datos.
return $\hat{\tau}_X(x) = \hat{e}(x)\hat{\tau}_0(x) + (1 - \hat{e}(x))\hat{\tau}_1(x)$.

Algoritmo 7. X-learner

Algoritmo

Entrada: Datos $(Y_i, D_i, X_i)_{i=1}^n$, folds K, modelos ML para $\hat{\mu}_1, \hat{\mu}_0, \hat{e}$ y para la regresión final.
Salida: Estimación $\hat{\tau}_{\mathrm{DR}}(x)$ del CATE.
Partir los índices en K folds.
for k = 1 **to** K **do**

Entrenar $\hat{\mu}_1$, $\hat{\mu}_0$ y $\hat{e}$ con los datos fuera del fold k y predecir dentro del fold k

end for
Calcular $\Gamma_i = \hat{\mu}_1(X_i) - \hat{\mu}_0(X_i) + D_i \frac{Y_i - \hat{\mu}_1(X_i)}{\hat{e}}(X_i) - (1 - D_i)\frac{Y_i - \hat{\mu}_0(X_i)}{1 - \hat{e}(X_i)}$, recortando $\hat{e}$ lejos de 0 y 1.
Entrenar la regresión final de Γ sobre X.
return $\hat{\tau}_{\mathrm{DR}}(x)$ = predicción de la regresión final

Algoritmo 8. DR-learner con cross-fitting

12.3 Algoritmos e implementación

12.3.1 Pseudocódigo

Caso canónico · Cinco meta-learners con CATE conocido

Diez covariables independientes y uniformes en $[-1, 1]$. El efecto es $\tau(x) = 2 + 3x_0 - x_1^2$, el resultado sin tratamiento es $x_2 + 0.5x_3$, el ruido es normal con desviación 0,5 y el tratamiento se asigna con probabilidad $\frac{1}{1+e^{-a-0.5x_0}}$. Con 2 000 unidades, aprendices de boosting de gradiente poco profundos, cross-fitting con cinco folds para los *nuisance* y 20 repeticiones, el error cuadrático medio de $\hat{\tau}(x)$ respecto de $\tau(x)$ (menos es mejor) es:

Escenario	S	T	X	DR	R
50 % de tratados	0,31	0,28	0,19	0,35	0,37
10 % de tratados	0,47	0,40	0,31	1,92	1,38

El X-learner es el mejor en los dos escenarios de este DGP suave, y el T-learner mejora al S-learner. El DR-learner y el R-learner, cuyas garantías son asintóticas y de segundo

orden, quedan por detrás con 50 % de tratados (0,35 y 0,37) y se degradan con 10 %, con errores de 1,92 y 1,38 y una dispersión grande entre repeticiones (desviaciones de 0,58 y 0,21), porque el pseudo-resultado divide por un propensity cercano a 0,1 y la regresión final recibe un objetivo muy ruidoso (con recorte de $\hat{e}$ en 0,01). Con 10 % de tratados, el T-learner, pese a su varianza, supera con holgura a ambos. No es un argumento contra las garantías asintóticas sino una advertencia sobre su alcance: con una muestra moderada y un propensity bajo, un estimador sesgado pero de baja varianza puede ganar. El orden exacto depende del DGP, de los *learners* y del recorte, y por eso se compara siempre sobre un caso con verdad conocida.

12.3.2 Implementación en Python

```
import numpy as np
import pandas as pd
from sklearn.ensemble import RandomForestRegressor, GradientBoostingRegressor
from sklearn.linear_model import LogisticRegressionCV
from econml.metalearners import XLearner, TLearner, SLearner
from econml.dml import CausalForestDML

def make_dgp(n=2000, p=10, seed=0):
    """CATE verdadero: tau(x) = 2 + 3*x1 - x2^2."""
    rng = np.random.default_rng(seed)
    X = rng.uniform(-1, 1, (n, p))
    e = 1 / (1 + np.exp(-1.0 - 0.5*X[:, 0]))  # propensity score
    D = (rng.uniform(size=n) < e).astype(int)
    tau = 2 + 3*X[:, 0] - X[:, 1]**2
    mu0 = X[:, 2] + 0.5 * X[:, 3]
    Y = mu0 + D * tau + rng.standard_normal(n) * 0.5
    return Y, D, X, tau

# Datos
Y, D, X, tau_true = make_dgp(n=2000, seed=42)

# Learners
ml = lambda: GradientBoostingRegressor(n_estimators=200, max_depth=4,
random_state=42)
e_model = LogisticRegressionCV(cv=5)

# S-learner
s = SLearner(overall_model=ml()).fit(Y, D, X)
tau_s = s.effect(X)

# T-learner
t = TLearner(models=ml()).fit(Y, D, X)
tau_t = t.effect(X)
```

```
# X-learner
x = XLearner(models=ml(), propensity_model=e_model).fit(Y, D, X)
tau_x = x.effect(X)

# R-learner via CausalForestDML (proxy)
r = CausalForestDML(model_y=ml(), model_t=e_model, discrete_treatment=True,
                    n_estimators=200, random_state=42).fit(Y, D, X=X)
tau_r = r.effect(X)

# Evaluacion: RMSE respecto a CATE verdadero
for name, tau_hat in [("S", tau_s), ("T", tau_t), ("X", tau_x), ("R", tau_r)]:
    rmse = np.sqrt(np.mean((tau_hat - tau_true)**2))
    bias = np.mean(tau_hat - tau_true)
    print(f"{name}-learner: RMSE={rmse:.4f}  Bias={bias:.4f}")
```

Listado 12.1: Comparación de meta-learners sobre dataset sintético.

12.3.3 Análisis de sesgo y varianza por subgrupo

```
# Forzar regularizacion fuerte (alpha grande en Lasso)
from sklearn.linear_model import Lasso
ml_strong_reg = lambda: Lasso(alpha=0.5, max_iter=5000)

s_strong = SLearner(overall_model=ml_strong_reg()).fit(Y, D, X)
tau_s_strong = s_strong.effect(X)
print(f"S-learner (regularizado): RMSE={np.sqrt(np.mean((tau_s_strong -
tau_true)**2)):.4f}")
print(f"  Fraccion de CATEs estimados en 0: {(np.abs(tau_s_strong) <
0.01).mean():.3f}")
```

Listado 12.2: Sesgo del S-learner bajo regularización fuerte.

El *output* típico muestra que el S-learner con regularización fuerte colapsa los CATEs hacia cero (fracción cercana a 1 en cero), ilustrando el sesgo de regularización. En la simulación de verificación del caso canónico con `scikit-learn` (`herramientas/verificaciones/verif_cap12.py`) un Lasso con $\alpha = 0.5$ dejó en cero el 95 % de los CATE estimados con 50 % de tratados y el 100 % con 10 % de tratados.

12.4 Caso empírico y validación

Un CATE por subgrupo sin intervalos no autoriza una regla de focalización. Las diferencias entre las medias de dos subgrupos deben compararse con el error de estimación, y ese error suele ser grande cuando ya el ATE tiene un intervalo ancho: si el intervalo del efecto promedio abarca desde un valor cercano a cero hasta el doble de la estimación, diferencias de unos cientos de dólares entre subgrupos no se distinguen del ruido. Antes de actuar sobre una heterogeneidad estimada hay que calibrarla (la caja de profundización de este capítulo), construir intervalos

por subgrupo con un *bootstrap* del procedimiento completo o con un estimador que los provea, y contrastarla con un placebo.

Sobre el dataset `nsw_mixtape` ($n = 445$), estimamos el CATE del programa de capacitación sobre ingresos con `CausalForestDML`. Réplica propia: el ATE estimado es \$2,226 (IC 95% [\$14, \$4,438]). La tabla 12.2 reporta CATE promedio por subgrupo, calculado sobre los CATEs individuales estimados.

Subgrupo	CATE medio (USD)	n
Educación $<$ 10 años	1 549	116
Educación $\geq$ 10 años	2 638	329
Ingreso 1974 $= 0$	2 387	334
Ingreso 1974 > 0	1 963	111
Edad $<$ 25	2 269	131
Edad $\geq$ 25	2 205	314

Tabla 12.2: CATE estimado por subgrupo en NSW (CausalForestDML). Réplica propia, sin intervalos por subgrupo.

La tabla ilustra el riesgo «subgrupos sin IC» más que un hallazgo: las diferencias entre subgrupos (por ejemplo, 1 549 frente a 2 638 dólares según la educación) son del orden del error de estimación del ATE, cuyo intervalo ya abarca desde 14 hasta 4 438 dólares, y la tabla no trae intervalos propios. Con estas cifras no se puede concluir que el programa sea más efectivo para quienes tienen más educación ni justificar una focalización por educación; hacerlo exigiría intervalos por subgrupo y una réplica.

12.5 Riesgos, límites y sensibilidad

Riesgo	**Consecuencia**	**Diagnóstico**	**Mitigación**
S-learner regularizado	CATE colapsa a cero	Fracción de CATE cero	T/X/R-learner
Propensity extremo	Varianza alta	Histograma	Trimming
Subgrupos sin IC	Falsos hallazgos	Intervalos	Bootstrap/forest

Tabla 12.3: Riesgos comunes en meta-learners

Límites. Los meta-learners asumen no confusión. Si hay variables confusoras no observadas, los CATEs estimados son sesgados. Adicionalmente, los meta-learners S, T, X no tienen garantía de $\sqrt{n}$-consistencia para CATE no paramétrico. El R-learner tiene garantía cuasi-oracle y el DR-learner alcanza la tasa oracle de su regresión final bajo la condición de producto de tasas; en ambos casos, la consistencia $\sqrt{n}$ y la eficiencia aplican a funcionales como el ATE o a clases paramétricas de $\tau(x)$, no al CATE punto a punto sin condiciones adicionales. Para inferencia rigurosa sobre CATE, preferir Causal Forest (capítulo 13), R-learner o DR-learner.

Cómo elegir en la práctica. Una regla de trabajo defendible, en orden: (i) si el soporte común es bueno y hay muestra suficiente, DR-learner o R-learner, por sus garantías de segundo orden, y comparándolos siempre con un X-learner, que en muestras moderadas puede ganar en error como en el caso canónico; (ii) si $\hat{e}$ tiene masa cerca de 0 o 1, evitar DR-learner sin *trimming* y preferir un bosque causal, que no divide explícitamente por el *propensity*, o un X-learner; (iii) el T-learner como *baseline* obligatorio de comparación, porque es simple y su fallo es diagnóstico (si el DR-learner no lo supera, la heterogeneidad modelada probablemente sea ruido); (iv) el S-learner solo con *learners* poco regularizados y nunca como única especificación, por el colapso a cero con regularización fuerte documentado en el listado 12.2.

12.6 Ejercicios y notas bibliográficas

12.6.1 Ejercicios teóricos

1. Muestre que $E[\Gamma_i \mid X_i = x] = \tau(x)$ si $\hat{\mu}_0, \hat{\mu}_1$ son correctos aunque $\hat{e}$ no lo sea, y también si $\hat{e}$ es correcto aunque $\hat{\mu}_0, \hat{\mu}_1$ no lo sean.
2. Explique por qué un S-learner con regularización fuerte tiende a devolver un CATE constante y por qué el T-learner no tiene ese problema pero sí el de varianza cuando un grupo es pequeño.
3. En el X-learner con ponderación $\hat{e}(x)$, ¿qué peso recibe $\hat{\tau}_1$ cuando casi todas las unidades son controles ($\hat{e}$ cercano a 0)? Justifíquelo con la fuente de cada imputación.
4. Con $\hat{e}(x) \in [0.05, 0.15]$, ¿cuánto pueden valer los términos IPW de Γ_i y por qué eso degrada al DR-learner y al R-learner?

12.6.2 Ejercicios computacionales

1. Replique el listado 12.1 variando el tamaño muestral $n \in \{500, 1000, 2000, 5000\}$. ¿Cómo cambia el ranking de meta-learners?
2. Modifique el DGP para que el propensity score sea extremo ($e(x) \in [0.05, 0.15]$). ¿Qué meta-learner se degrada más?
3. Sobre el dataset `gov_transfers`, estime el CATE de las transferencias gubernamentales sobre el consumo. ¿Qué subgrupos muestran efectos mayores, y con qué intervalos?
4. Implemente el R-learner «a mano» (sin `econml`) usando `scikit-learn` para $\hat{m}_Y, \hat{e}$ y un `RandomForestRegressor` para $\hat{\tau}$. Compare con la implementación de `econml`. Use cross-fitting ($K = 5$) para estimar $\hat{m}_Y$ y $\hat{e}$ fuera de muestra antes de optimizar $\hat{\tau}$.

Künzel et al. (2019) es la referencia original para S/T/X-learners. Nie y Wager (2021) introduce el R-learner, construido sobre el score de (Robinson 1988). Kennedy (2023) es la referencia canónica del DR-learner y de la tasa oracle de la Sección 12.2.5; su lectura es especialmente recomendable porque sitúa a todos los meta-learners de este capítulo dentro de un marco común de pseudo-resultados. Foster y Syrgkanis (2019) generaliza el principio subyacente a los dos anteriores (*orthogonal statistical learning*) a problemas de aprendizaje con parámetros

de estorbo arbitrarios, y es la referencia teórica que explica **por qué** la familia R/DR tiene dependencia de segundo orden. Para una revisión comparativa, (Athey y Imbens 2019).

CAPÍTULO 13

13 Árboles y bosques causales

Cuadro sinóptico del capítulo

Problema:	Identificar subgrupos con efectos heterogéneos
Estimando:	CATE(x)
Identificación:	No confusión, soporte común, SUTVA
Método:	Árboles causales honestos, bosques causales, *Generalized Random Forests* (GRF)
Nuisance:	$m(x) = E[Y \mid X = x]$, $e(x)$
Garantía:	Normalidad asintótica puntual, con partición honesta y submuestreo
Librerías:	econml, grf (R)
Validación:	Calibración, importancia de variables con cautela, *policy trees*

Nota técnica

Los meta-learners del Capítulo 12 reutilizan *learners* genéricos de fuera de la caja; este capítulo presenta una familia diseñada específicamente para el CATE, los árboles y bosques causales con partición *honesta*, que ofrece una teoría de inferencia propia a costa de mayor especialización.

13.1 Motivación aplicada

Un organismo público quiere saber en qué subgrupos de hogares un programa de transferencias condicionadas aumenta más la asistencia escolar. Supongamos, a modo de ilustración, que el efecto promedio es de 3 puntos porcentuales pero que en algunos subgrupos es nulo y en otros supera los 10. Identificar esos subgrupos permitiría focalizar el programa y mejorar su costo-efectividad, y equivocarse al identificarlos tiene un costo simétrico: se deja fuera a quienes sí se benefician o se gasta en quienes no.

Los *causal trees* (Athey y Imbens 2016) y los *causal forests* (Wager y Athey 2018), junto con su generalización, los *Generalized Random Forests* (Athey et al. 2019), son métodos diseñados para estimar CATEs con intervalos de confianza asintóticamente válidos. La idea que lo hace posible es la *honestidad*: la muestra que decide la partición del árbol no es la que estima el efecto dentro de cada hoja. Eso evita el sobreajuste estructural de los árboles estándar, que eligen justamente las divisiones donde el ruido favorece una diferencia grande.

Conviene ubicar la contribución con precisión, porque el nombre «bosque causal» sugiere una analogía con el bosque aleatorio predictivo que es engañosa. Un bosque aleatorio predice promediando predicciones. La versión original de Wager y Athey (2018) promedia las estimaciones de hoja de cada árbol; la formulación de GRF, que es la que sigue la literatura posterior, hace algo distinto: usa los árboles para inducir **pesos de vecindad** $\omega_i(x)$ (cuán a menudo la observación i cae en la misma hoja que el punto de consulta x) y resuelve con ellos una ecuación de momento local. El bosque es, entonces, un procedimiento adaptativo para elegir **qué vecinos son relevantes** para estimar el efecto en x, y la estimación propiamente dicha la hace el score causal. Esta distinción, que la Sección 13.3.1 desarrolla con un ejemplo numérico, explica por qué el método admite intervalos de confianza mientras que un T-learner con bosques aleatorios no.

Este capítulo desarrolla la teoría de árboles y bosques causales, muestra con dos casos de resultado conocido qué aporta la honestidad y en qué se diferencian los dos estimadores, y discute cuándo el método es apropiado frente a los meta-learners o al DML con efecto constante.

13.2 Teoría, supuestos y garantías

13.2.1 Árboles causales honestos

Un *causal tree* es un árbol de decisión que particiona el espacio de covariables X en hojas $\mathcal{L}_1, ..., \mathcal{L}_M$. Dentro de cada hoja $\mathcal{L}_m$, el CATE se estima como la diferencia de medias entre tratados y controles:

$$\hat{\tau}(\mathcal{L}_m) = \frac{1}{n_{1,m}} \sum_{i \in \mathcal{L}_m, D_i=1} Y_i - \frac{1}{n_{0,m}} \sum_{i \in \mathcal{L}_m, D_i=0} Y_i. \tag{13.1}$$

Esta estimación es válida como efecto de la hoja si dentro de ella la asignación es aleatoria o ignorable dado X; con datos observacionales, la diferencia de medias dentro de la hoja solo es razonable si las hojas son lo bastante finas para que la no confusión condicional se sostenga. Por eso las versiones con *nuisance* de las secciones siguientes reemplazan la diferencia de medias por un score ortogonalizado.

La *honestidad* exige que la muestra usada para decidir las divisiones (*splitting subsample*) sea distinta de la usada para estimar $\hat{\tau}$ (*estimation subsample*). Se logra dividiendo la muestra de entrenamiento en dos mitades antes de construir el árbol.

Algoritmo

Entrada: Muestra $\{(Y_i, D_i, X_i)\}_{i=1}^{n}$, tamaño mínimo de hoja $n_{\min}$, mínimo de tratados por hoja $n_{1,\min}$, mínimo de controles por hoja $n_{0,\min}$.
Salida: Árbol $\mathcal{T}$ con hojas $\mathcal{L}_1, \ldots, \mathcal{L}_M$ y estimaciones $\hat{\tau}(\mathcal{L}_m)$.
Dividir la muestra en S_{split} (partición) y S_{est} (estimación).
Inicializar $\mathcal{T}$ con una sola hoja (raíz) que contiene S_{split}.
while haya hojas factibles sin dividir:
    Seleccionar una hoja $\mathcal{L}$ de $\mathcal{T}$.
    for cada posible división binaria $X_j \le c$:
        Calcular el criterio Q de (13.2) con la división, usando S_{split}.
    Elegir la división que maximiza Q.
    Si ambas hojas hijas cumplen $n_{\min}, n_{1,\min}, n_{0,\min}$ tanto en S_{split} como en S_{est}, aplicarla.
for cada hoja $\mathcal{L}_m$ del árbol final:
    Estimar $\hat{\tau}(\mathcal{L}_m)$ usando solo S_{est} según (13.1).
return $\mathcal{T}$ con $\hat{\tau}(\mathcal{L}_m)$ por hoja.

Algoritmo 9. Causal tree honesto

Definición 13.1 ***(Honestidad)***

Un árbol causal es *honesto* si las decisiones de partición son independientes de los resultados que se usan para estimar $\hat{\tau}$ dentro de cada hoja. Formalmente, existe una partición de la muestra de entrenamiento $S = S_{\text{split}} \cup S_{\text{est}}$, con $S_{\text{split}} \cap S_{\text{est}} = \varnothing$, tal que el árbol se construye usando S_{split} y los efectos se estiman usando S_{est}.

Por qué importa la honestidad. Sin ella, el árbol elige las divisiones que maximizan la diferencia de medias *observada* entre tratados y controles, y eso introduce un sesgo de selección (la *maldición del ganador*): los CATEs estimados en las hojas elegidas tienden a ser mayores, en valor absoluto, que los verdaderos. Con honestidad, las divisiones se eligen con una muestra y se evalúan con otra, de modo que, dada la partición, la estimación de cada hoja es una diferencia de medias común y sin sesgo de selección. El caso canónico de más abajo lo cuantifica.

Las restricciones de tamaño deben cumplirse también en S_{est}, porque es allí donde se estima: una hoja que en la muestra de estimación no tenga ningún control queda sin estimación, y una con uno o dos tiene un error de estimación que ningún criterio sobre S_{split} anticipa.

13.2.2 El criterio de partición

El criterio habitual de un árbol predictivo es la reducción de varianza del resultado. Para un árbol causal, (Athey y Imbens 2016) proponen un criterio con dos términos, que en su forma honesta es

$$Q(\Pi) = \frac{1}{N_{\text{split}}} \sum_{i \in S_{\text{split}}} \hat{\tau}(X_i; \Pi)^2 - \left(\frac{1}{N_{\text{split}}} + \frac{1}{N_{\text{est}}} \right) \sum_{l \in \Pi} \left(\frac{\hat{\sigma}^2_{1,l}}{p} + \frac{\hat{\sigma}^2_{0,l}}{1-p} \right), \tag{13.2}$$

donde Π es la partición, $\hat{\tau}(X_i; \Pi)$ es la estimación de la hoja de X_i calculada en S_{split}, p es la fracción de tratados y $\hat{\sigma}^2_{d,l}$ es la varianza muestral del resultado entre las unidades con $D = d$ de la hoja l. El primer término premia las particiones cuyas hojas tienen efectos estimados distintos entre sí (como el promedio de los $\hat{\tau}$ casi no cambia de una partición a otra, maximizarlo

equivale a maximizar la dispersión de los CATE estimados). El segundo castiga las hojas donde la estimación será ruidosa, y por eso aparece N_{est}: la penalización anticipa la varianza con la que se estimará en la muestra honesta. Los factores exactos varían entre versiones del criterio; lo que importa es la estructura, heterogeneidad premiada y varianza de hoja penalizada.

En los *Generalized Random Forests* el criterio no se evalúa exhaustivamente sino que se aproxima con pseudo-resultados basados en el gradiente de la ecuación de momento, de modo que cada división cuesta lo mismo que una división de un árbol de regresión estándar.

Caso canónico · Honestidad y falsos descubrimientos

Mil unidades, diez covariables independientes y uniformes en $[0, 1]$, tratamiento aleatorio con probabilidad $1/2$ y resultado $Y = D\tau(X) + \varepsilon$ con $\varepsilon \sim N(0, 1)$. El «árbol» tiene una sola división: entre las diez covariables, se elige la que, partida en su mediana, da la mayor diferencia $|\hat{\Delta}|$ entre los efectos estimados de las dos hojas. Se compara el procedimiento **adaptativo** (elegir y estimar con las mismas mil unidades) con el **honesto** (elegir con 500 y estimar con las otras 500). Con 4 000 repeticiones:

Medida	Adaptativo	Honesto
Sin efecto ($\tau = 0$): muestras con diferencia «significativa» al 5 %	41 %	5 %
Sin efecto: $\lvert\hat{\Delta}\rvert$ medio entre hojas	0,24	0,15
Efecto 0,2 solo si $X_0 > 0.5$: la división elegida usa X_0	41 %	25 %

Si la división se hubiera fijado de antemano, $|\hat{\Delta}|$ medio sería 0,10 con las mil unidades y 0,14 con 500: la selección multiplica por 2,4 la heterogeneidad aparente del procedimiento adaptativo, mientras que el honesto solo refleja el ruido de la mitad de la muestra. El adaptativo «descubre» una diferencia significativa en el 41 % de las muestras donde no hay ninguna, casi exactamente $1 - 0.95^{10} \approx 0.40$: con diez divisiones candidatas, la mejor cruza el umbral por azar la mayor parte de las veces. El honesto mantiene la tasa nominal del 5 %. El precio está en la última fila: con heterogeneidad real, el procedimiento honesto elige la covariable correcta solo el 25 % de las veces, frente al 41 % del adaptativo, porque dispone de la mitad de la muestra para decidir. La salida a ese dilema son los bosques: cada árbol es honesto, pero con submuestras distintas, de modo que una misma observación sirve para dividir en unos árboles y para estimar en otros.

13.3 Estimador y score

13.3.1 Del árbol al bosque: pesos de vecindad

Un *causal forest* es un conjunto de B árboles causales honestos, cada uno construido sobre una submuestra de tamaño $s < n$ extraída **sin reemplazo**; el submuestreo, y no un *bootstrap*

de tamaño n, es lo que sustenta la teoría asintótica. La versión original (Wager y Athey 2018) estima el CATE como el promedio de las estimaciones de hoja:

$$\hat{\tau}_{\mathrm{CF}}(x) = \frac{1}{B}\sum_{b=1}^{B} \hat{\tau}_b(x), \tag{13.3}$$

donde $\hat{\tau}_b(x)$ es la (13.1) de la hoja del árbol b que contiene a x.

La formulación de GRF (Athey et al. 2019) reescribe el bosque como un generador de pesos. Con $\mathcal{L}_b(x)$ la hoja del árbol b que contiene a x y $S_{\mathrm{est},b}$ su muestra de estimación, el peso de la observación i es

$$\omega_i(x) = \frac{1}{B}\sum_{b=1}^{B} \frac{\mathbf{1}\{X_i \in \mathcal{L}_b(x), i \in S_{\mathrm{est},b}\}}{|\{j \in S_{\mathrm{est},b} : X_j \in \mathcal{L}_b(x)\}|}, \tag{13.4}$$

que suma 1 y es grande cuando i cae a menudo en la misma hoja que x. El parámetro local $\hat{\theta}(x)$ se obtiene resolviendo una ecuación de momento ponderada, $\sum_i \omega_i(x)\psi_{\hat{\theta}(x)}(O_i) = 0$. Para el CATE con tratamiento ortogonalizado, el score es el del R-learner (Capítulo 12) y la solución tiene forma cerrada:

$$\hat{\tau}(x) = \frac{\sum_i \omega_i(x)(Y_i - \hat{m}(X_i))(D_i - \hat{e}(X_i))}{\sum_i \omega_i(x)(D_i - \hat{e}(X_i))^2}, \tag{13.5}$$

una regresión de residuos sobre residuos, pero local, con pesos que el bosque elige adaptativamente. Los *nuisance* $\hat{m}$ y $\hat{e}$ se estiman con *cross-fitting* o con predicciones fuera de bolsa, por el mismo motivo de ortogonalidad del Capítulo 10. Si el tratamiento es binario y los *nuisance* se toman constantes en la vecindad de x, la (13.5) es la pendiente de una regresión ponderada de Y sobre D, es decir, la diferencia ponderada de medias entre tratados y controles.

Caso canónico · Mismo bosque, dos estimadores

Un bosque de dos árboles y seis observaciones. Para el punto de consulta x, la hoja del árbol 1 contiene a las observaciones 1 a 4 y la del árbol 2, a las observaciones 3 a 6.

i	1	2	3	4	5	6
D_i	1	0	1	0	1	1
Y_i	5	1	4	2	9	5
Hoja árbol 1	sí	sí	sí	sí	no	no
Hoja árbol 2	no	no	sí	sí	sí	sí
$\omega_i(x)$	1/8	1/8	1/4	1/4	1/8	1/8

En la hoja 1, los tratados valen en promedio 4,5 y los controles 1,5, de modo que $\hat{\tau}_1 = 3.0$. En la hoja 2, hay tres tratados (promedio 6) y un solo control (valor 2), de modo que $\hat{\tau}_2 = 4.0$. El promedio de árboles de la (13.3) es $\frac{3.0+4.0}{2} = 3.50$. Con los pesos de la (13.4), los tratados (1, 3, 5, 6) suman peso 5/8 y su media ponderada es 5,40, y los controles

Algoritmo

Entrada: Muestra $\{(Y_i, D_i, X_i)\}_{i=1}^{n}$, número de árboles B, tamaño de submuestra $s < n$, punto de consulta x.
Salida: $\hat{\tau}(x)$ y una estimación de su varianza.
Estimar $\hat{m}(X_i)$ y $\hat{e}(X_i)$ con *cross-fitting* o predicciones fuera de bolsa.
Calcular los residuos $\tilde{Y}_i = Y_i - \hat{m}(X_i)$ y $\tilde{D}_i = D_i - \hat{e}(X_i)$.
for $b = 1, ..., B$:
    Extraer una submuestra S_b de tamaño s sin reemplazo y dividirla en S_b^{split} y S_b^{est}.
    Construir un árbol honesto sobre S_b^{split} dividiendo según heterogeneidad de $\tilde{Y}$ y $\tilde{D}$.
Calcular los pesos $\omega_i(x)$ de (13.4) sobre las muestras de estimación.
Calcular $\hat{\tau}(x)$ con (13.5).
Estimar la varianza con un *jackknife infinitesimal* por grupos de árboles.
return $\hat{\tau}(x)$ y su varianza estimada.

Algoritmo 10. Causal forest (GRF), esquema

(2, 4) suman 3/8 y su media ponderada es 1,67, de modo que el estimador ponderado da $5.40 - 1.67 = 3.73$.

Los dos estimadores no coinciden, y la razón es estructural. El promedio de árboles trata las dos hojas como igual de informativas aunque la segunda estime el nivel de los controles con una sola observación. El estimador ponderado reúne todas las observaciones vecinas y da más peso a las que aparecen cerca de x en ambos árboles (las observaciones 3 y 4). No es un detalle de implementación: es la razón por la que GRF permite una teoría de varianza para la ecuación de momento completa y no solo para cada hoja.

Intuición

El bosque no estima el efecto; decide a quién se parece x. Cada árbol propone una vecindad de x construida con la información de S_{split}, el bosque promedia esas vecindades en pesos $\omega_i(x)$, y el efecto sale de comparar tratados y controles ponderados por esos pesos. Por eso el bosque puede ser flexible en la forma en que τ depende de X sin que la estimación deje de ser una comparación de tratados y controles entre unidades parecidas.

Teorema 13.2 ***(Normalidad asintótica puntual del bosque causal)***

Sean los datos i.i.d. con no confusión condicional y solape, $\mu_0(x)$ y $\mu_1(x)$ Lipschitz en x y covariables con soporte acotado. Sea $\hat{\tau}(x)$ un bosque cuyos árboles son honestos, regulares, de divisiones con aleatoriedad y simétricos, entrenados sobre submuestras sin reemplazo de tamaño $s \sim n^{\beta}$, con β en un intervalo $(\beta_{\min}, 1)$ que depende de la dimensión de X y de la regularidad de los árboles. Entonces existe una varianza estimable $\hat{V}(x)$ tal que

$$\frac{\hat{\tau}(x) - \tau(x)}{\sqrt{\hat{V}(x)}} \xrightarrow{d} N(0, 1), \tag{13.6}$$

y el estimador de varianza por *jackknife infinitesimal* es consistente.

Wager y Athey (2018) demuestran este resultado para el estimador de la (13.3), y la extensión a los scores de GRF sigue el mismo argumento. Cuatro precisiones evitan que se lea más de lo que dice. Primera, la tasa de convergencia es local, depende de la probabilidad de caer en hojas cercanas a x, y no es una normalización $\sqrt{n}$ universal; empeora con la dimensión de X, y $\beta_{\min}$ se acerca a 1 cuando X tiene muchas covariables relevantes. Segunda, el resultado es **puntual**: cubre $\tau(x)$ para un x fijo y no a toda la función a la vez. Tercera, es una cobertura para el efecto condicional promedio $\tau(x)$, no para el efecto individual $Y_i(1) - Y_i(0)$, que incluye un ruido que la varianza del estimador no captura (el Capítulo 14 trata los intervalos individuales). Cuarta, la garantía es asintótica y en muestras finitas el error de cobertura lo domina el sesgo, no la varianza: con muestras pequeñas o con τ muy irregular, los intervalos son optimistas.

13.3.2 Comparación con meta-learners

Dimensión	Bosque causal (GRF)	Meta-learners (S, T, X, DR, R)
Inferencia sobre $\tau(x)$	Intervalos puntuales con teoría asintótica y varianza por *jackknife* en grupos de árboles	Con regresión final genérica, solo *bootstrap* sin garantía de cobertura; con regresión final de series o de polinomios locales, el DR-learner sí la tiene (Kennedy 2023)
Flexibilidad	Alta; la elige la partición adaptativa	Alta; la elige el *learner* base
Honestidad	Parte del diseño	Opcional, solo si el *learner* base la incorpora
Lectura del resultado	Pesos de vecindad inspeccionables; importancia de variables heurística	Depende del *learner* base
Alta dimensión	La tasa de inferencia se deteriora con la dimensión efectiva	Depende del *learner* base
Caso ideal	Se quieren intervalos puntuales sin especificar la forma de τ	Se prioriza el error de estimación, o hay estructura conocida

Tabla 13.1: Bosque causal frente a meta-learners.

13.4 Validación y lectura de la heterogeneidad

13.4.1 Calibrar antes de interpretar

Un bosque produce un $\hat{\tau}(x)$ para cada unidad, y un mapa de esos valores siempre parece mostrar heterogeneidad, incluso cuando se ajusta sobre ruido (el caso canónico de la Sección 13.2.2 ya mostró cuán fácil es que la selección la fabrique). Antes de leer el mapa hay que

comprobar que contiene señal. La prueba de calibración regresa el resultado residualizado sobre dos términos, la predicción media y la desviación de cada predicción respecto de la media, ambos multiplicados por el tratamiento residualizado. Un coeficiente de la desviación cercano a 1 indica que el bosque capta heterogeneidad real y con la escala correcta; cercano a 0, que las diferencias entre predicciones son ruido; el de la predicción media debe rondar 1 si el nivel promedio está bien. La Sección 14.2.7 desarrolla este protocolo con BLP, BEST y CLAN y fija la regla de reporte: un mapa de heterogeneidad sin ese contraste es exploratorio.

13.4.2 Importancia de variables y *policy trees*

Intuición

Caja de profundización: importancia de variables y *policy trees*

Objetivo. Interpretar un bosque causal más allá del CATE promedio sin sobreinterpretarlo.

¿Qué variables explican la heterogeneidad? La importancia de variables de un bosque causal mide con qué frecuencia, y a qué profundidad, se usa cada variable para dividir. Es una pista de dónde mirar, no una medida de cuánto modifica el efecto cada variable: dos covariables muy correlacionadas se reparten la importancia, y una variable puede ser elegida por ruido. Sirve para decidir qué cortes explorar con un test, nunca como resultado por sí sola.

***Policy trees*: reglas simples para decidir.** Un *policy tree* es un árbol de decisión de poca profundidad (2 o 3 niveles) que asigna el tratamiento. A diferencia de un árbol ajustado a los CATE estimados, se entrena maximizando el valor estimado de la política, la suma de los scores doblemente robustos Γ_i del Capítulo 12 sobre las unidades que la regla manda a tratar. Produce reglas como «si edad > 30 y educación > 12, tratar; si no, no tratar».

Athey y Wager (2021) formalizan este objeto: la clase de árboles de profundidad acotada tiene dimensión VC finita, lo que permite acotar el *regret* de la política aprendida respecto de la mejor política **dentro de esa clase**. El Capítulo 21 desarrolla el resultado; aquí basta retener que la interpretabilidad del *policy tree* no es solo una concesión a la comunicación, sino la fuente misma de su garantía estadística: restringir la clase de políticas es lo que evita sobreajustar la regla de decisión al ruido del CATE estimado.

Cuidado con buscar subgrupos «a ojo». Si se miran los datos para encontrar subgrupos con efectos grandes, aparecen incluso cuando no existen. Un *policy tree* con honestidad y validación reduce el problema, y la pre-especificación de los subgrupos de interés lo evita casi por completo.

13.5 Implementación en Python

13.5.1 Estimación con `CausalForestDML`

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from econml.dml import CausalForestDML
from sklearn.ensemble import GradientBoostingRegressor,
GradientBoostingClassifier

df = pd.read_csv("../data/datasets/real/public_causaldata/nsw_mixtape/
data.csv")
Y = df["re78"].values
D = df["treat"].values
X = df[["age", "educ", "black", "hisp", "marr", "nodegree", "re74",
"re75"]].values

cf = CausalForestDML(
    model_y=GradientBoostingRegressor(n_estimators=200, max_depth=4,
random_state=42),
    model_t=GradientBoostingClassifier(n_estimators=200, max_depth=4,
random_state=42),
    discrete_treatment=True,
    n_estimators=400,
    min_samples_leaf=20,
    max_depth=8,
    cv=5,
    random_state=42,
)
cf.fit(Y, D, X=X)

# ATE
ate = cf.ate(X=X); lb, ub = cf.ate_interval(X=X, alpha=0.05)
print(f"ATE: {ate:.2f}  IC 95%: [{lb:.2f}, {ub:.2f}]")

# CATE
cate = cf.effect(X)
cate_lb, cate_ub = cf.effect_interval(X, alpha=0.05)
# cate_lb y cate_ub pueden usarse para graficar intervalos de confianza
# en mapas de heterogeneidad (no mostrado aquí).

# Mapa de heterogeneidad: CATE vs edad y educacion
fig, axes = plt.subplots(1, 2, figsize=(12, 5))
axes[0].scatter(df["age"], cate, c=cate, cmap="viridis", alpha=0.6)
axes[0].set_xlabel("Edad"); axes[0].set_ylabel("CATE estimado")
axes[0].set_title("Heterogeneidad por edad")
```

```
axes[1].scatter(df["educ"], cate, c=cate, cmap="viridis", alpha=0.6)
axes[1].set_xlabel("Educacion"); axes[1].set_ylabel("CATE estimado")
axes[1].set_title("Heterogeneidad por educacion")
plt.tight_layout()
plt.savefig("figuras/cf_heterogeneity_nsw.png", dpi=120, bbox_inches="tight")
plt.show()
```

Listado 13.1: Causal Forest sobre NSW con mapas de heterogeneidad.

13.5.2 Comparación con un X-learner

```
import numpy as np
from econml.dml import CausalForestDML
from econml.metalearners import XLearner
from sklearn.ensemble import GradientBoostingClassifier,
GradientBoostingRegressor
# DGP con heterogeneidad estructurada
def make_heterogeneous_dgp(n=2000, seed=0):
    rng = np.random.default_rng(seed)
    X = rng.uniform(-1, 1, (n, 5))
    tau = 2 * X[:, 0] + X[:, 1] * X[:, 2]
    e = 0.5 + 0.3 * np.tanh(X[:, 3])
    D = (rng.uniform(size=n) < e).astype(int)
    Y = X[:, 4] + D * tau + rng.standard_normal(n) * 0.5
    return Y, D, X, tau

Y, D, X, tau_true = make_heterogeneous_dgp(2000, seed=42)
# Causal Forest
cf = CausalForestDML(n_estimators=400, min_samples_leaf=20, random_state=42,
                     model_y=GradientBoostingRegressor(),
                     model_t=GradientBoostingClassifier(),
                     discrete_treatment=True).fit(Y, D, X=X)
tau_cf = cf.effect(X)
# X-learner
xl = XLearner(models=GradientBoostingRegressor(),
              propensity_model=GradientBoostingClassifier()).fit(Y, D, X)
tau_xl = xl.effect(X)

print(f"CF RMSE: {np.sqrt(np.mean((tau_cf - tau_true)**2)):.4f}")
print(f"XL RMSE: {np.sqrt(np.mean((tau_xl - tau_true)**2)):.4f}")
```

Listado 13.2: Causal Forest vs. X-learner en datos sintéticos.

El resultado depende del DGP, del tamaño de muestra y de los *learners* base; este listado es para repetir la comparación con otras semillas y tamaños, no para extraer un ranking.

13.5.3 Importancia de variables

```
# Según la versión de econml, es una propiedad (cf.feature_importances_)
# o un método (cf.feature_importances()). Comprobar en la versión instalada.
importances = cf.feature_importances_
features = ["age", "educ", "black", "hisp", "marr", "nodegree", "re74", "re75"]
order = np.argsort(importances)[::-1]
for i in order:
    print(f"{features[i]:>12}: {importances[i]:.4f}")
```

Listado 13.3: Importancia de variables en causal forest.

13.5.4 Réplica sobre el programa NSW

Réplica propia con `CausalForestDML` sobre `nsw_mixtape` (Lalonde, 1986), $n = 445$ (185 tratados, 260 controles) y 8 controles observables. Las cifras vienen de la edición anterior y no se recalcularon en esta, porque la biblioteca no estaba instalada en el entorno de revisión; conviene repetir el listado 13.1 en local antes de citarlas.

- ATE estimado: \$2,226, IC 95% [\$14, \$4,438].
- CATE: media \$2,226, desviación estándar \$1,035, rango [\$780, \$4,078].
- Variables más importantes: `age` (0.43), `educ` (0.24), `re75` (0.22), `re74` (0.08).
- CATE medio por nivel educativo: \$1,174 con 7 años y \$3,515 con 14.

La lectura honesta de estas cifras es más cautelosa que la de un hallazgo. El intervalo del ATE casi toca el cero y mide más de 4 000 dólares de ancho, así que una dispersión de 1 035 dólares entre los CATE estimados no es evidencia de heterogeneidad: un bosque ajustado sobre ruido también produce CATE dispersos, como mostró el caso canónico de la Sección 13.2.2. Los CATE medios por educación se calcularon sin intervalos propios, y con 445 observaciones y 8 covariables el bosque está en el régimen en que los intervalos asintóticos son menos fiables. Lo que estas cifras justifican es el protocolo de calibración de la Sección 13.4.1 antes de interpretar el mapa, no una focalización por edad o educación.

13.6 Riesgos, límites y sensibilidad

13.6.1 Tabla de riesgos

La tabla 13.2 resume los riesgos principales al usar árboles y bosques causales, junto con sus consecuencias, diagnósticos y estrategias de mitigación.

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Árbol sin honestidad	Sesgo de selección: los CATEs estimados en hojas tienden a ser mayores que los verdaderos	Comparar estimaciones con y sin honestidad sobre la misma muestra, como en el caso canónico	Partición explícita $S_{\text{split}} \cup S_{\text{est}}$; que las restricciones de tamaño valgan también en S_{est}
Mapa de heterogeneidad sin calibrar	Se interpreta como señal una dispersión que puede ser ruido	Coeficiente de calibración de la desviación cercano a 0 o con intervalo que incluye el cero	Reportar como exploratorio todo mapa sin ese contraste (Sección 14.2.7)
Búsqueda de subgrupos y comparaciones múltiples	Falsos descubrimientos: efectos grandes donde no existen, e inflación del error tipo I al comparar muchos subgrupos	Pre-registrar los subgrupos de interés; reportar todos los evaluados y el número de comparaciones	Validación fuera de muestra con placebos y Qini; Bonferroni o FDR (*False Discovery Rate*); *policy trees* con honestidad y validación
Importancia de variables leída como causal	Se atribuye a una variable un efecto que es de otra correlacionada, o ruido	Repetir con otra semilla y con grupos de variables correlacionadas	Usarla solo para elegir qué cortes contrastar con un test, no como resultado
CATE fuera del soporte común	El CATE no es identificable en regiones sin tratados o sin controles	Reportar $\hat{e}(x)$ para cada observación e inspeccionar su distribución	Restringir el análisis al soporte común; no extrapolar a regiones sin solapamiento
Muestra pequeña o τ muy irregular	Intervalos anchos o optimistas; inestabilidad del árbol; cobertura dominada por el sesgo	Ancho promedio del IC y sensibilidad a la semilla del submuestreo	Agrupar subgrupos, aumentar $n_{\min}$ o usar métodos paramétricos más parsimoniosos

Tabla 13.2: Riesgos al usar árboles y bosques causales.

13.6.2 Límites

El bosque causal estándar identifica con no confusión condicional y solape; los confusores no observados sesgan el CATE y ningún intervalo lo corrige. Para tratamientos con instrumento, GRF ofrece una variante cuya ecuación de momento es la del diseño de variables instrumentales (un *bosque instrumental*), y el capítulo 17 desarrolla el caso con instrumentos. Con datos agrupados o de panel, las submuestras y la honestidad deben formarse por grupo, no por observación: si observaciones de un mismo grupo caen en S_{split} y en S_{est}, la dependencia dentro

del grupo rompe la independencia que la honestidad supone y los intervalos resultan optimistas. Los efectos dinámicos en el tiempo requieren extensiones específicas.

13.7 Ejercicios propuestos

13.7.1 Ejercicios teóricos

1. Con una división fija, el estimador de la diferencia entre dos hojas tiene error estándar $\sigma\sqrt{\frac{8}{n_{\text{hoja}}}}$ si cada hoja tiene n_{hoja} unidades y la mitad tratadas. Muestre que, con p divisiones candidatas independientes y ningún efecto, la probabilidad de que la mejor cruce $|z| > 1.96$ es $1 - 0.95^p$, y compárela con la tasa de 41 % del caso canónico para $p = 10$. ¿Por qué la coincidencia es solo aproximada?
2. En el caso canónico «Mismo bosque, dos estimadores», elimine la observación 6 (la hoja 2 pasa a tener las observaciones 3, 4 y 5) y recalcule el promedio de árboles y el estimador ponderado. ¿Cuál de los dos cambia más y por qué?
3. Explique por qué un T-learner con bosques aleatorios como *learners* base no admite los intervalos del teorema de normalidad asintótica puntual de la Sección 13.3.1, aunque use los mismos árboles. Nombre al menos tres ingredientes que el bosque causal añade.
4. Muestre que, con tratamiento binario y $\hat{m}$ y $\hat{e}$ constantes en la vecindad de x, la (13.5) es la pendiente de una regresión ponderada de Y sobre D con pesos $\omega_i(x)$ y que esa pendiente es la diferencia ponderada de medias.
5. Con datos de M escuelas y varios estudiantes por escuela, argumente por qué la honestidad debe aplicarse por escuela. ¿Qué se rompe si la división se hace por estudiante?

13.7.2 Ejercicios computacionales

1. Replique el listado 13.1 variando `min_samples_leaf` en $\{5, 10, 20, 50\}$. ¿Cómo cambia la heterogeneidad estimada? Acompañe cada variante de la prueba de calibración.
2. Compare el bosque causal con el R-learner sobre el dataset `cps_mixtape`. ¿Qué método identifica más heterogeneidad, y con qué intervalos?
3. Use un bosque causal para estimar la heterogeneidad del efecto de primera etapa de `nearc4` sobre `educ` en el dataset `close_college`. ¿Qué subgrupos muestran mayor efecto del instrumento sobre la educación? Esto no es el CATE de `educ` sobre `lwage`, sino la heterogeneidad en la primera etapa del diseño IV.
4. Implemente un árbol causal honesto «a mano» (sin `econml`) dividiendo la muestra en S_{split} y S_{est}. Compare con la implementación de `econml` y con una versión adaptativa que estime en la misma muestra en que parte. Repita el caso canónico de la Sección 13.2.2.

13.8 Lecturas complementarias

Athey y Imbens (2016) es el *paper* fundacional de los árboles causales y del criterio de partición honesto. Wager y Athey (2018) establece la consistencia y la normalidad asintótica puntual de los bosques causales, con la estimación de varianza por *jackknife infinitesimal* que hace posibles los intervalos de la Sección 13.3.1. Athey et al. (2019) generaliza el marco a GRF, reinterpretando el bosque como generador de pesos adaptativos para una ecuación de momento local (la lectura que este capítulo adopta). Athey y Wager (2021) es la referencia de los *policy trees* mencionados en la caja de profundización y se desarrolla en el Capítulo 21. Oprescu et al. (2023) documenta la implementación en `econml` la implementación de referencia en R es el paquete `grf` de los propios autores.

CAPÍTULO 14

Validación, refutación y sensibilidad

Cuadro sinóptico del capítulo

Problema:	Validar modelos causales sin ground truth
Estimando:	CATE, ranking por efecto
Identificación:	No confusión, placebos, refutación
Método:	Curvas Qini y AUUC, transformed outcome, placebos, E-value
Nuisance:	$\hat{e}(X), \hat{\mu}_d(X)$
Garantía:	Detección de fallos gruesos bajo refutación; cota de sensibilidad a confusión no observada (E-value)
Librerías:	econml, scikit-learn, causalml
Validación:	Suite de refutación, placebos, sensibilidad

Nota técnica

Los tres capítulos anteriores (Capítulo 10, Capítulo 11, Capítulo 12, Capítulo 13) presentaron estimadores; este capítulo cierra el bloque de estimación preguntando cómo saber si un estimador de CATE, en ausencia de *ground truth*, es confiable, y extiende la pregunta, en su última sección, a cómo organizar ese proceso de evaluación como parte de un sistema versionado y no solo como un chequeo puntual.

14.1 Motivación aplicada

Un banco ha entrenado un modelo de uplift para decidir a qué clientes ofrecer una línea de crédito pre-aprobada. El modelo produce un CATE estimado para cada cliente. Antes de desplegarlo, el equipo de riesgo debe validar que el modelo realmente distingue clientes con alto uplift de clientes con bajo uplift. El problema fundamental: **no se observa el CATE verdadero** para ningún cliente, porque cada cliente recibe solo un tratamiento (no ambos resultados potenciales).

Esta es la situación estándar en aplicaciones reales de ML causal: el estimando de interés (CATE, policy value) no es observable, lo que hace inválida la validación cruzada estándar de ML supervisado. Este capítulo desarrolla estrategias de validación indirecta: curvas Qini, curvas uplift, transformed outcomes, validación con placebos, y comparación con benchmarks clásicos. Para datasets sintéticos con ground truth, también discutimos métricas directas de error (RMSE en τ, cobertura del IC).

14.2 Teoría, supuestos y garantías

14.2.1 El problema fundamental

En ML supervisado estándar, la validación se basa en comparar predicciones $\hat{Y}$ con observaciones Y. Para estimadores de CATE, el análogo sería comparar $\hat{\tau}(x)$ con $\tau(x)$, pero $\tau(x)$ no se observa. La única excepción son los datos sintéticos con DGP conocido, donde $\tau(x)$ se computa analíticamente.

Proposición 14.1 ***(Imposibilidad de validación directa)***

Para cualquier estimador $\hat{\tau}$ y cualquier dataset real (Y, D, X), no existe función de los datos que permita estimar el error $\|\hat{\tau} - \tau\|$ sin supuestos adicionales.

La solución es recurrir a *proxy metrics* y a *placebo tests* que, aunque no miden el error directamente, sí detectan fallos gruesos del estimador.

14.2.2 Curva Qini (versión acumulada)

La curva Qini evalúa el ranking por $\hat{\tau}$. Una versión acumulada ordena las unidades por $\hat{\tau}$ descendente y compara el uplift acumulado contra una asignación aleatoria:

$$Q_{\text{cum}}(q) = \sum_{i \in T(q)} Y_i - \frac{|T(q)|}{|C(q)|} \sum_{i \in C(q)} Y_i, \tag{14.1}$$

cuando $|C(q)| > 0$. Si $|C(q)| = 0$, la cantidad no está definida y debe regularizarse o excluirse del gráfico.

También puede definirse un uplift promedio top-q:

$$Q_{\text{avg}}(q) = \frac{1}{|T(q)|} \sum_{i \in T(q)} Y_i - \frac{1}{|C(q)|} \sum_{i \in C(q)} Y_i. \tag{14.2}$$

Supuestos. La curva Qini no requiere conocer $\tau(x)$, pero su validez como proxy de ranking supone que los residuos $\varepsilon_i = Y_i - \mu_{D_i}(X_i)$ son intercambiables entre tratados y controles. No garantiza ausencia de sesgo en la magnitud de $\hat{\tau}$, solo calidad de ranking.

Garantías. Bajo no confusión y soporte común, si $\hat{\tau}$ es monótono respecto a τ, la curva Qini es creciente y domina al baseline aleatorio. La pendiente inicial alta indica concentración de unidades con alto efecto en el top del ranking.

Interpretación:

- Si $\hat{\tau}$ es informativo, la curva acumulada debe ubicarse por encima del baseline aleatorio, con pendiente inicial alta.
- El uplift promedio top-q no tiene por qué crecer con q; si el ranking es correcto, suele decrecer a medida que se incorporan unidades con menor efecto.
- Una curva Qini creciente en términos acumulados indica buen ranking, pero no garantiza ausencia de sesgo en la magnitud de $\hat{\tau}$.

Resumen escalar: AUUC y coeficiente Qini. Comparar dos curvas visualmente no escala cuando hay que evaluar muchos modelos o automatizar la decisión en un pipeline de CI (Capítulo 20). Se usan por eso dos resúmenes escalares, que conviene no confundir. El **AUUC** (*Area Under the Uplift Curve*) es simplemente el área bajo la curva de uplift acumulado; depende de la escala de Y y del tamaño muestral, por lo que solo tiene sentido comparar AUUC entre modelos evaluados sobre exactamente la misma muestra. El **coeficiente Qini** normaliza esa área restando el *baseline* aleatorio y dividiendo por el área del modelo perfecto, produciendo un número comparable entre datasets, análogo al coeficiente de Gini del que toma el nombre.

Dos advertencias operativas. Primera: ambos son métricas de **ranking**, no de calibración: un modelo que multiplique todos sus $\hat{\tau}$ por 10 tiene exactamente el mismo AUUC y produciría un presupuesto de campaña diez veces mal dimensionado. Segunda: ambos son estadísticos muestrales con varianza no despreciable, especialmente en las colas del ranking donde $|C(q)|$ es pequeño; reportar un AUUC sin banda de confianza por *bootstrap* invita a declarar ganador a un modelo que no lo es. El Capítulo 22 retoma estas métricas como criterio de evaluación de la política y no solo del estimador.

14.2.3 Curva uplift y transformed outcome

La *uplift curve* normaliza por el tamaño total:

$$U(q) = \frac{1}{n}\sum_{i \in T(q)} Y_i - \frac{1}{n}\sum_{i \in C(q)} Y_i \cdot \frac{|T(q)|}{|C(q)|}. \tag{14.3}$$

El *transformed outcome* (Athey y Wager 2019) construye una variable $Y^\star$ cuya esperanza es $\tau(X)$:

$$Y_i^\star = Y_i \cdot \frac{D_i - \hat{e}(X_i)}{\hat{e}(X_i)(1-\hat{e}(X_i))}. \tag{14.4}$$

Proposición 14.2

Si $\hat{e} = e_0$, entonces $E[Y^\star \mid X] = \tau(X)$.

Supuestos. La validez de $Y^\star$ como proxy requiere que $\hat{e}$ sea consistente para el verdadero propensity score e_0. Si $\hat{e}$ está mal especificado, $E[Y^\star \mid X] \neq \tau(X)$.

Garantías. $Y^\star$ permite usar métricas de ML supervisado (RMSE, correlación) sobre $\hat{\tau}$. La desventaja: $Y^\star$ tiene alta varianza, especialmente cuando $\hat{e}$ es cercano a 0 o 1. Con $\sigma_1^2(X), \sigma_0^2(X)$

las varianzas condicionales de Y bajo tratamiento y control, la varianza de $Y^\star$ condicional en X es:

$$\mathrm{Var}(Y^\star \mid X) = \frac{\sigma_1^2(X) + \mu_1(X)^2}{e_0}(X) + \frac{\sigma_0^2(X) + \mu_0(X)^2}{1 - e_0(X)} - \tau(X)^2, \tag{14.5}$$

que explota cuando $e_0(X) \to 0$ o $e_0(X) \to 1$: el término dominante en cada límite es, respectivamente, $1/e_0(X)$ o $1/(1 - e_0(X))$, independientemente del resto de la expresión.

14.2.4 Placebo tests

Un *placebo test* estima el efecto causal en un contexto donde debería ser cero. La lógica es simple: si el estimador produce un efecto no nulo donde sabemos que no debería haberlo, el estimador está sesgado.

Supuestos. El placebo test requiere que en el contexto placebo se cumplan los mismos supuestos de identificación que en el contexto real. Si no, un resultado no nulo podría deberse a violación de supuestos en el placebo y no a un problema del estimador.

Garantías. Bajo la hipótesis nula de efecto nulo y correcta especificación, el estimador debe producir un efecto indistinguible de cero. Un resultado significativo en un placebo es evidencia de mala especificación.

Tres variantes comunes:

- **Placebo temporal:** estimar el efecto en un periodo pre-tratamiento. Si el estimador es válido, el efecto debe ser cercano a cero.
- **Placebo por subgrupo:** estimar el efecto en un subgrupo que no debería responder al tratamiento (p. ej., efecto de un programa escolar sobre jubilados).
- **Placebo por outcome:** estimar el efecto sobre un outcome que no debería responder (p. ej., efecto de becas sobre altura).

Caso canónico · Placebo temporal con confusor no observado

Se simulan $n = 1\,500$ unidades observadas en dos periodos. Una covariable observada $X \sim N(0,1)$ y un confusor no observado $U \sim N(0,1)$ afectan al resultado en ambos periodos, $Y_t = 1 + 0.5X + sU + \varepsilon_t$ con $\varepsilon_t \sim N(0,1)$, y quien recibe el programa depende de ambos, $P(D = 1) = \sigma(0.8X + sU)$. El programa llega en el periodo 1 y su efecto verdadero es 0.3. El parámetro s gobierna la confusión no observada: con $s = 0$ no hay ninguna, y con $s = 1$ es fuerte.

En una corrida con semilla fija, el placebo del periodo 0 (cuando el programa aún no existe) da, con $s = 0$, un efecto de 0,06 cuyo intervalo de 95 % contiene el cero, y el efecto real del periodo 1 se estima en 0,40 con un intervalo que cubre 0,3. Con $s = 1$ el placebo da 0,86 con un intervalo que excluye el cero con holgura, y el efecto real se estima en 1,02, más de tres veces la verdad. El placebo no corrigió nada, pero avisó que la estimación del periodo 1 no se podía creer. Y lo hizo sin conocer U: le bastó observar un efecto donde no podía haberlo.

14.2.5 Sensibilidad a confusión no observada: protocolo de tres niveles

Los placebos detectan mala especificación, pero no responden la pregunta que más importa y que ningún test puede responder con los datos disponibles: **¿cuán fuerte tendría que ser un confusor no observado para anular el resultado?** La literatura de análisis de sensibilidad la convierte en una pregunta cuantitativa y reportable. La formulación más difundida hoy es el **E-value** de VanderWeele y Ding (2017).

Definición 14.3 ***(E-value)***

Para una razón de riesgos estimada $\mathrm{RR} > 1$, el **E-value** es

$$\mathrm{E} = \mathrm{RR} + \sqrt{\mathrm{RR}\ (\mathrm{RR} - 1)}, \tag{14.6}$$

y se interpreta así: un confusor no observado tendría que estar asociado **tanto** al tratamiento **como** al resultado por un factor de riesgo de al menos E (cada uno, y por encima de los confusores ya medidos) para explicar completamente la asociación observada. Para el límite del intervalo de confianza más cercano a la nulidad se calcula un segundo E-value, que indica la fuerza necesaria para volver el resultado estadísticamente no significativo.

La virtud del E-value es que traduce la amenaza a la identificación a una escala que un experto de dominio puede juzgar. Decir «el resultado es sensible a confusión no observada» no es accionable; decir «haría falta un confusor no medido asociado al tratamiento y al resultado con $\mathrm{RR} \geq 3.2$, cuando el confusor observado más fuerte de que disponemos tiene $\mathrm{RR} = 1.6$» invita a una discusión sustantiva concreta: ¿existe una variable plausible de esa magnitud que no hayamos medido?

Sus límites deben declararse con la misma claridad. El E-value es una condición **necesaria** mínima, no suficiente: describe el confusor único más débil capaz de explicar el resultado, y varios confusores moderados pueden combinarse para lograr lo mismo. No incorpora información sobre qué confusores son plausibles en el dominio (es una cota, no una probabilidad). Y su formulación estándar está definida sobre razones de riesgo; aplicarlo a un efecto en diferencias requiere transformar primero la escala, paso que se omite con frecuencia y que invalida el número reportado.

Nivel 2: sensibilidad en escala R^2. Para estimaciones tipo PLR (DML-PLR, PDS), la pregunta equivalente es: ¿qué R^2 parcial con D y con Y tendría que tener un confusor no observado U para anular el efecto? Si $r^2_{Y\cdot U \mid X,D}$ y $r^2_{D\cdot U \mid X}$ denotan las fracciones de varianza residual explicadas por U, el efecto deja de ser significativo cuando ambas superan un umbral derivable del t-estadístico observado (Cinelli y Hazlett (2020) la formulación en escala R^2 se remonta a Imbens (2003)). La ventaja sobre el E-value: se reporta contra *benchmarks* observados (el R^2 parcial del confusor medido más fuerte) en la misma escala del modelo estimado, sin cambio de escala a razones de riesgo.

Nivel 3: identificación parcial. Cuando el supuesto puede fallar parcialmente, el reporte correcto es un intervalo de *bounds*. Con $Y \in [0, 1]$ y sin ningún supuesto de no confusión, Manski (1990) muestra que, con $a = E[Y \mid D = 1]P(D = 1) - E[Y \mid D = 0]P(D = 0)$ (la diferencia de medias ponderada por la proporción de cada grupo),

$$\theta = E[Y(1) - Y(0)] \in [a - P(D=1), a + P(D=0)], \tag{14.7}$$

de ancho exactamente 1. Los *bounds* solo se estrechan si se está dispuesto a acotar la fuerza de la confusión no observada, que es la pregunta que plantean los Niveles 1 y 2.

Regla de reporte. Todo resultado observacional que alimente una decisión (en el proyecto final, Sección E.7) reporta el Nivel 1 (E-value) siempre, el Nivel 2 (R^2 de Imbens y de Cinelli–Hazlett) cuando el estimador sea de tipo PLR, y el Nivel 3 cuando el *outcome* esté acotado y el resultado sea próximo a cero. Si el E-value del límite del intervalo más cercano a la nulidad no supera la fuerza del confusor medido más fuerte, el resultado se reporta como «no robusto» y no se despliega.

14.2.6 Validación con datos sintéticos

Para datasets sintéticos con $\tau(x)$ conocido, se reportan:

- **Sesgo:** $E[\hat{\tau}(X) - \tau(X)]$.
- **RMSE:** $\sqrt{E[(\hat{\tau}(X) - \tau(X))^2]}$.
- **Cobertura del IC:** fracción de x tales que $\tau(x) \in [\hat{\tau}(x) \pm 1.96\hat{\sigma}(x)]$.
- **Policy regret:** diferencia entre $V(\pi^*)$ y $V(\hat{\pi})$ donde π^* es la política óptima y $\hat{\pi}$ se deriva de $\hat{\tau}$.

14.2.7 Tests formales de heterogeneidad: BLP, BEST y CLAN

La curva Qini evalúa *ranking*; no responde si la heterogeneidad detectada es estadísticamente distinguible de cero. Chernozhukov et al. (2020) proveen tests con control de tipo I, sin *ground truth*, mediante *sample-splitting* (la misma lógica del *cross-fitting* del Capítulo 10).

BLP (Best Linear Predictor). Sea $\hat{T}(X)$ un score de prioridad (p. ej. $\hat{\tau}$ de un *causal forest*). En la muestra de evaluación, con el *transformed outcome* $Y^\star$ (Ec. (14.4)):

$$Y_i^\star = \beta_1 + \beta_2\left(\hat{T}_i - \overline{T}\right) + \varepsilon_i. \tag{14.8}$$

El test $H_0 : \beta_2 = 0$ es un test válido de «no hay heterogeneidad linealmente detectable por $\hat{T}$». El coeficiente β_1 estima el efecto promedio, y β_2 mide cuánto del efecto covaría con el puntaje: vale 1 si $\hat{T}$ coincide con τ y 0 si no aporta nada.

BEST (Best subgroup Treatment Effect). Particionar por la mediana de $\hat{T}$ en los dos grupos de mayor/menor score estimado y testear la diferencia de sus efectos medios, con IC construidos sobre la muestra de evaluación separada.

CLAN (Classification Analysis). Efectos medios por cuantiles de $\hat{T}$ con IC simultáneos (corrección de Bonferroni o *bootstrap* multiplicador), para perfilar la forma de la heterogeneidad sin compromiso paramétrico.

Las bibliotecas de CATE traen implementaciones parciales de estos tests. EconML las ofrece en su módulo de validación (clase `DRTester`); conviene comprobar en la versión instalada cuáles de las tres cubre.

Regla de reporte. Ningún informe que reporte heterogeneidad se publica sin el BLP; si β_2 no es significativo, la heterogeneidad reportada se declara exploratoria.

14.2.8 Intervalos conformes para efectos individuales

El problema. El teorema de cobertura del CATE del Capítulo 13 da cobertura para $\tau(x)$, no para el efecto individual $Y_i(1) - Y_i(0)$: la varianza del efecto individual incluye el ruido ε_i, que la varianza del estimador no captura. Las decisiones individuales del servicio del Capítulo 15 requieren lo segundo.

Procedimiento (split conformal sobre transformed outcome). Bajo asignación aleatorizada o *propensity* conocido, $Y_i^\star$ (Ec. (14.4)) satisface $E[Y^\star \mid X] = \tau(X)$:

1. Particionar en entrenamiento $\mathcal{D}_1$ y calibración $\mathcal{D}_2$.
2. Entrenar $\hat{\tau}$ en $\mathcal{D}_1$.
3. En $\mathcal{D}_2$ calcular residuos no conformes $R_i = |Y_i^\star - \hat{\tau}(X_i)|$.
4. $\hat{C}(x) = [\hat{\tau}(x) - \hat{q}, \hat{\tau}(x) + \hat{q}]$, con $\hat{q}$ el cuantil $\frac{\lceil (m+1)(1-\alpha) \rceil}{m}$ de $\{R_i\}$.

Proposición 14.4 ***(Cobertura conforme)***

Si las observaciones son intercambiables, $P\left(Y^\star_{\text{nuevo}} \in \hat{C}(X_{\text{nuevo}})\right) \geq 1 - \alpha$, sin supuestos distribucionales sobre (Y, D, X).

Dos advertencias. Primera: la cobertura es para el *transformed outcome* (un proxy insesgado del efecto), no para $Y_i(1) - Y_i(0)$ literal (Lei y Candès (2021) tratan la versión con contrafactuales imputados). Segunda: con *propensity* estimado se requiere *conformal* ponderado (Tibshirani et al. (2019)); la versión sin ponderar es válida solo si $\hat{e} \approx e_0$. Para la base de predicción conforme libre de distribución, ver Lei et al. (2018), y Romano et al. (2019) para la variante de regresión cuantílica conforme.

Integración en producción: el servicio de estimación (Sección 15.4) puede añadir un intervalo individual cuando exista calibración conforme. La *model card* (Capítulo 19) debe declarar qué garantiza cada intervalo: el intervalo del efecto condicional promedio es cobertura del estimando poblacional; el individual es cobertura marginal no paramétrica.

14.3 Implementación en Python

14.3.1 Curva Qini sobre datos sintéticos

El listado entrena en una parte de los datos y evalúa en otra, y compara tres rankings sobre la misma muestra de evaluación: el del CATE estimado, el de una regla de riesgo que ignora la causalidad y el orden perfecto, que solo existe porque los datos son sintéticos. Para usar un estimador de EconML basta sustituir la función `t_learner` por el ajuste de un `CausalForestDML` en la muestra de entrenamiento y devolver su `effect` sobre la de evaluación.

```
import numpy as np
import matplotlib.pyplot as plt
```

```
from sklearn.ensemble import GradientBoostingRegressor
from sklearn.model_selection import train_test_split

# DGP con CATE conocido (solo posible con datos sinteticos)
def make_dgp(n=3000, seed=0):
    rng = np.random.default_rng(seed)
    X = rng.uniform(-1, 1, (n, 5))
    e = 1 / (1 + np.exp(-0.5 - 0.3 * X[:, 0]))
    D = (rng.uniform(size=n) < e).astype(int)
    tau = 2 + 3 * X[:, 0] - X[:, 1] ** 2
    mu0 = X[:, 2] + X[:, 3]
    Y = mu0 + D * tau + rng.standard_normal(n) * 0.5
    return Y, D, X, tau

def gbm():
    return GradientBoostingRegressor(n_estimators=200, max_depth=3,
random_state=42)

def t_learner(Y, D, X, X_nuevo):
    """CATE estimado y riesgo basal (resultado esperado sin tratamiento)."""
    m1 = gbm().fit(X[D == 1], Y[D == 1])
    m0 = gbm().fit(X[D == 0], Y[D == 0])
    return m1.predict(X_nuevo) - m0.predict(X_nuevo), m0.predict(X_nuevo)

def qini_curve(Y, D, score):
    """Qini acumulada: ordena por score descendente (no es el uplift promedio
top-q)."""
    o = np.argsort(-score)
    y, d = Y[o], D[o]
    cum_T = np.cumsum(y * d)
    cum_C = np.cumsum(y * (1 - d))
    n_C = np.cumsum(1 - d)
    n_T = np.cumsum(d)
    qini = cum_T - cum_C * n_T / np.clip(n_C, 1, None)
    return np.arange(1, len(y) + 1) / len(y), qini

# Particion: se entrena en una parte y se evalua en otra (hold-out)
Y, D, X, tau = make_dgp(3000, seed=42)
tr, te = train_test_split(np.arange(len(Y)), test_size=0.4, random_state=0)
tau_hat, riesgo = t_learner(Y[tr], D[tr], X[tr], X[te])

# Metricas directas (solo posibles con ground truth)
rmse = np.sqrt(np.mean((tau_hat - tau[te]) ** 2))
bias = np.mean(tau_hat - tau[te])
print(f"RMSE: {rmse:.3f}  Bias: {bias:.3f}")

def area(q, x):
```

```
    return np.sum((q[1:] + q[:-1]) * np.diff(x)) / 2     # regla del trapecio

# Rankings comparados sobre el mismo hold-out
rankings = {"T-learner (por CATE estimado)": tau_hat,
            "Regla de riesgo (sin causalidad)": riesgo,
            "Orden perfecto (CATE verdadero)": tau[te]}
curvas = {k: qini_curve(Y[te], D[te], s) for k, s in rankings.items()}
frac, q_perfecto = curvas["Orden perfecto (CATE verdadero)"]
azar = q_perfecto[-1] * frac                         # linea recta: tratar al
azar
for k, (_, q) in curvas.items():
    coef = (area(q, frac) - area(azar, frac)) / (area(q_perfecto, frac) -
area(azar, frac))
    print(f"{k:34s} coeficiente Qini = {coef:.3f}")

plt.figure(figsize=(8, 5))
for k, (f, q) in curvas.items():
    plt.plot(f, q, label=k, lw=2)
plt.plot(frac, azar, label="Azar", lw=2, ls="--", color="gray")
plt.xlabel("Fracción de la muestra de evaluación (mayor puntaje primero)")
plt.ylabel("Uplift acumulado (Qini)")
plt.legend()
plt.title("Curva Qini en hold-out: validación del ranking por CATE")
plt.tight_layout()
plt.savefig("qini_curve.png", dpi=120, bbox_inches="tight")
```

Listado 14.1: Curva Qini en una muestra de evaluación, con tres rankings y el azar como referencia.

14.3.2 Placebo test

El listado genera un panel de dos periodos y aplica el placebo temporal dos veces: sin confusor no observado y con uno. En el segundo caso el programa llega a quienes ya estaban mejor, y el placebo debe delatarlo.

```
import numpy as np
import pandas as pd
from econml.dml import LinearDML
from sklearn.ensemble import RandomForestRegressor, RandomForestClassifier

# Panel sintetico de dos periodos: el programa llega en t = 1
def make_panel(n=1500, seed=0, sesgo=0.0):
    rng = np.random.default_rng(seed)
    x = rng.normal(size=n)                           # covariable observada
    u = rng.normal(size=n)                           # confusor NO observado
    p = 1 / (1 + np.exp(-0.8 * x - sesgo * u))       # quien se trata depende de
x y de u
```

```
    treated = (rng.uniform(size=n) < p).astype(int)
    y0 = 1 + 0.5 * x + sesgo * u + rng.normal(size=n)                    # antes
del programa
    y1 = 1 + 0.5 * x + sesgo * u + 0.3 * treated + rng.normal(size=n)   #
despues
    return pd.DataFrame({"x": x, "treated_group": treated, "y_t0": y0, "y_t1":
y1})

def efecto(df, y):
    est = LinearDML(model_y=RandomForestRegressor(n_estimators=100,
random_state=42),
                    model_t=RandomForestClassifier(n_estimators=100,
random_state=42),
                    discrete_treatment=True, cv=3, random_state=42)
    X = df[["x"]].to_numpy()
    est.fit(df[y].to_numpy(), df["treated_group"].to_numpy(), X=X)
    return est.ate(X=X), *est.ate_interval(X=X, alpha=0.05)

for sesgo in (0.0, 1.0):
    df = make_panel(sesgo=sesgo)
    # Placebo temporal: efecto del programa sobre el outcome ANTERIOR al
programa
    pl, lb, ub = efecto(df, "y_t0")
    print(f"sesgo={sesgo}: ATE placebo {pl:.3f}  IC [{lb:.3f}, {ub:.3f}]
contiene 0: {lb <= 0 <= ub}")
    ef, lb, ub = efecto(df, "y_t1")
    print(f"         ATE real    {ef:.3f}  IC [{lb:.3f}, {ub:.3f}]  (verdad
0.3)")
```

Listado 14.2: Placebo temporal sobre un panel sintético, con y sin confusor no observado.

14.4 Caso empírico y validación

14.4.1 Suite de refutación

La tabla 14.1 resume las pruebas de refutación estándar para validar modelos causales sin ground truth. Estas pruebas no garantizan que el modelo sea correcto, pero detectan fallos gruesos de especificación.

Prueba	Qué hace	Interpretación
Placebo treatment	Reemplaza D por variable aleatoria	El efecto estimado debe caer a cero; si no, el modelo detecta señal espuria

Prueba	Qué hace	Interpretación
Random common cause	Agrega una covariable ruido independiente de Y y D	El efecto estimado debe ser estable; un cambio grande indica sensibilidad a ruido
Subset validation	Remuestrea los datos (bootstrap) y reestima	La distribución bootstrap del efecto debe ser estable; varianza alta sugiere sobreajuste
Transformed outcome	Construye $Y^\star$ y evalúa $\hat{\tau}$ con métricas supervisadas	$E[Y^\star \mid X] = \tau(X)$ bajo $\hat{e}$ correcto; permite RMSE y correlación
BLP/BEST	Test de heterogeneidad sobre $\hat{T}$	β_2 no significativo $\Rightarrow$ la heterogeneidad no supera el ruido (Sección 14.2.7)

Tabla 14.1: Suite de refutación para modelos causales.

14.4.2 Curva Qini comparativa

Caso canónico · Qini con CATE conocido

Se simulan $n = 3\,000$ unidades con cinco covariables independientes $X_1, \ldots, X_5 \sim U(-1, 1)$. El tratamiento depende débilmente de la primera, $D \sim \text{Bernoulli}(\sigma(0.5 + 0.3X_1))$, el efecto es $\tau(X) = 2 + 3X_1 - X_2^2$ y el resultado es $Y = X_3 + X_4 + D\tau(X) + \varepsilon$ con $\varepsilon \sim N(0, 0.5^2)$. El efecto varía entre unidades y es negativo en el 22 % de la población. El resultado sin tratamiento, $X_3 + X_4$, no tiene relación con el efecto: quién tiene más riesgo y a quién le sirve más el tratamiento son preguntas distintas. El 60 % de las unidades entrena el estimador y el 40 % restante, que el estimador no vio, evalúa.

La figura 14.1 compara, sobre esa muestra de evaluación, tres rankings: el del CATE estimado por un T-learner con *gradient boosting*, el de una regla de riesgo que ordena por el resultado esperado sin tratamiento, y el orden perfecto, que usa el CATE verdadero y solo existe con datos sintéticos. El azar es la recta que une el origen con el uplift total.

Interpretación. El ranking por CATE estimado sigue de cerca al orden perfecto: su coeficiente Qini es 0,999. Al tratar al 20 % con mayor puntaje acumula un uplift de 651 (en unidades de Y), frente a los 277 que daría el azar. La regla de riesgo, en cambio, ordena como el azar: su coeficiente es -0.05. Es el error que el Capítulo 1 advierte, visible aquí en una cifra. Las curvas de los dos rankings informativos alcanzan su máximo antes del final (con el 82 % de la muestra la del T-learner y con el 86 % la del orden perfecto) y luego bajan, porque el 21 % de las unidades de evaluación tiene efecto negativo y tratarlas resta. Esa caída es lo que un promedio global oculta y una curva Qini deja ver. El generador es deliberadamente favorable, con heterogeneidad fuerte y suave, y un coeficiente tan alto no debe esperarse con datos reales. Las métricas directas (RMSE de 0,33 y sesgo de 0,013 sobre τ) existen solo porque los datos son sintéticos.

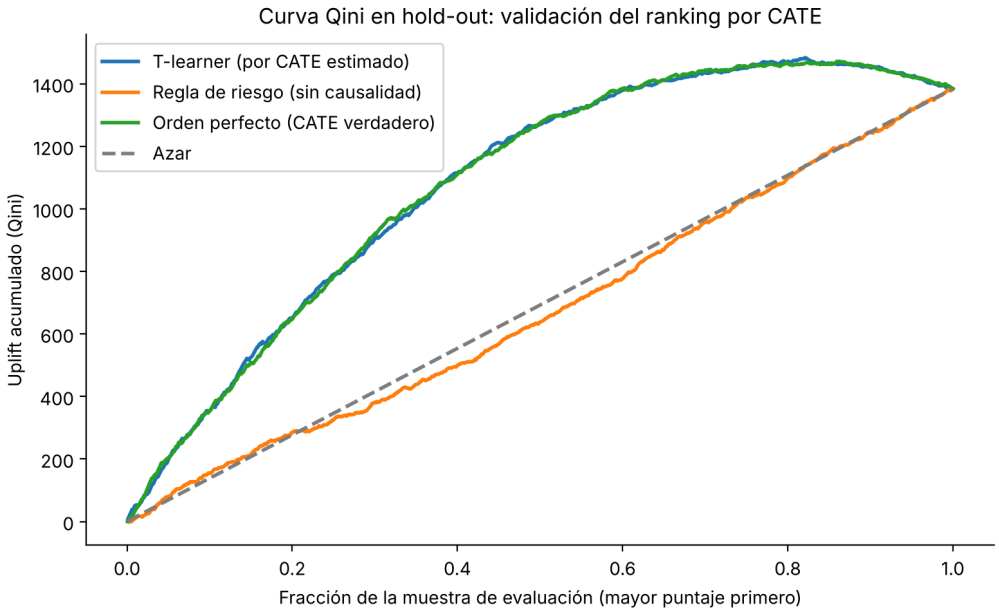


Figura 14.1: Curva Qini en una muestra de evaluación de 1 200 unidades: ranking por CATE estimado (T-learner), regla de riesgo sin causalidad, orden perfecto y azar. Datos sintéticos con $\tau(x) = 2 + 3x_1 - x_2^2$ y $n = 3\,000$; semillas 42 (datos), 0 (partición) y 42 (*boosting*).

El experimento de Thornton (2008) (dataset `thornton_hiv`) evalúa el efecto de incentivos monetarios sobre la demanda de resultados de test de VIH en Malaui. Su valor para este capítulo es que el tratamiento fue **aleatorizado**, de modo que la identificación no está en discusión y toda desviación detectada por la suite de refutación es atribuible al estimador y no al diseño. Es la situación de control que permite calibrar qué tan informativas son las métricas indirectas antes de aplicarlas a datos observacionales, donde ambas fuentes de error se confunden.

Intuición

Caja de profundización: Pruebas de refutación y análisis de sensibilidad

Objetivo. Aprender a poner a prueba un modelo causal cuando no tenemos el efecto verdadero.

Pruebas de placebo.

- **Placebo treatment:** asignar el tratamiento aleatoriamente y reestimar. El ATE debería ser cero.
- **Placebo outcome:** usar una variable que sabemos que no es afectada por el tratamiento como si fuera Y.
- **Placebo temporal:** en datos de panel, aplicar el método a un período prepolíticas donde no debería haber efecto.

¿Qué tan sensible es mi resultado a un confusor no observado? Incluso si controlamos por muchos confusores observados, siempre puede haber uno no observado.

El **E-value** (Sección 14.2.5) responde: ¿qué tan fuerte tendría que ser ese confusor para explicar mi resultado? Un E-value grande sugiere robustez, pero «grande» solo tiene sentido **comparado con la fuerza de los confusores que sí se midieron**, no contra un umbral universal.

Bootstrap para curvas Qini. Podemos remuestrear los datos muchas veces y recalcular la curva Qini cada vez. Esto nos da bandas de confianza alrededor de la curva y permite comparar modelos formalmente.

14.5 Riesgos, límites y sensibilidad

14.5.1 Tabla de riesgos

La tabla 14.2 resume los principales riesgos al validar modelos causales sin ground truth, junto con sus consecuencias, diagnóstico y mitigación.

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Validar con R^2 de Y	Falsa confianza en estimaciones sesgadas	Comparar R^2 predictivo con métricas causales (Qini, placebos)	Usar placebos, Qini y ground truth sintético. El R^2 predictivo de Y no correlaciona con la calidad de la estimación causal. Un modelo puede predecir Y perfectamente y producir CATEs totalmente sesgados
Omitir placebo tests en datos reales	No detectar mala especificación del estimador	Verificar que se aplicaron placebos antes de desplegar	Sin ground truth, los placebos son la única validación de especificación. Son obligatorios
Sobreinterpretar la curva Qini	Creer que un ranking informativo implica CATE insesgado	Comparar magnitud de $\hat{\tau}$ con benchmarks o transformed outcome	Una curva Qini creciente indica que el ranking es informativo, pero no que el CATE estimado sea insesgado. Puede haber sesgo uniforme que preserve el ranking

Tabla 14.2: Riesgos en la validación de modelos causales sin ground truth.

14.5.2 Límites

Las métricas indirectas (Qini, uplift, transformed outcome) solo detectan fallos gruesos. No garantizan ausencia de sesgo. La validación definitiva requiere replicación en experimentos controlados o datasets sintéticos con ground truth.

¿Cuándo no usar este enfoque? La validación indirecta no reemplaza un diseño de identificación creíble. Si el supuesto de no confusión es cuestionable, ninguna suite de refutación lo rescata. En esos casos, priorizar diseños cuasi-experimentales (RDD, DID, IV) sobre la validación post-hoc.

14.6 Evaluación offline en el ciclo de vida del sistema

Las secciones anteriores de este capítulo responden una pregunta estadística: ¿el estimador de CATE es razonable? Esta sección, que extiende el capítulo con una perspectiva de ingeniería de sistemas siguiendo a (Huyen 2022) (Capítulo 6, «Model Development and Offline Evaluation»), responde una pregunta distinta y complementaria: **¿cómo se organiza el proceso de evaluación offline para que sea comparable a través del tiempo y de distintas versiones del modelo?**

14.6.1 *Baselines* obligatorios

Huyen (2022) insiste en que ningún modelo se evalúa en el vacío: siempre debe compararse contra al menos un *baseline* simple. Para un sistema de estimación causal, se recomiendan tres *baselines* mínimos antes de aceptar cualquier estimador de CATE como el de producción:

Baseline	**Qué revela**
Efecto constante (ATE vía DML, Capítulo 11)	Si el CATE estimado no supera a un efecto constante en la curva Qini, la heterogeneidad modelada no aporta valor accionable.
Regla aleatoria	Piso de referencia: cualquier estimador debe superar claramente a targetear al azar.
Regla basada en riesgo (sin causalidad)	Detecta si el «efecto heterogéneo» estimado es, en realidad, una reformulación de quién tiene mayor Y esperado sin tratamiento, un error de confusión entre pronóstico de riesgo y efecto causal ya discutido en el Capítulo 1. En el caso canónico de la figura 14.1, esta regla obtiene un coeficiente Qini de -0.05.
RATE del estimador candidato vs. efecto constante	Si RATE no supera al efecto constante, la heterogeneidad no aporta valor (consistente con la advertencia de la Figura 21.1).

14.6.2 Selección formal de estimadores de CATE: RATE

El Capítulo 12 compara meta-learners por RMSE sobre τ, métrica disponible solo con *ground truth* sintético. En datos reales, el criterio formal es RATE (*Rank-Weighted Average Treatment Effect*, Yadlowsky et al. (2021)). Se parte de la curva TOC (*Targeting Operator Characteristic*), que para cada fracción q mide cuánto más gana el top-q del ranking respecto del efecto promedio:

$$\mathrm{TOC}(q) = E\big[\tau(X) \mid X \in \mathrm{top}_q(\hat{\tau})\big] - E[\tau(X)], \quad \mathrm{RATE} = \int_0^1 w(q)\ \mathrm{TOC}(q)\,\mathrm{d}q, \quad (14.9)$$

con $w(q) = 1$ (el AUTOC, que pesa igual todo el ranking) o $w(q) = q$ (el análogo de Qini, que pesa más el tramo donde se trata a más gente). Un RATE positivo indica que el ranking concentra efecto en su cabeza; uno cercano a cero, que no distingue mejor que el azar. En el caso canónico de la figura 14.1, calculado con el CATE verdadero sobre la muestra de evaluación, el AUTOC vale 1,49 para el ranking del T-learner y -0.004 para el de la regla de riesgo.

El RATE se estima con puntajes doblemente robustos sobre una muestra de evaluación y admite inferencia (Yadlowsky et al. (2021)). Para elegir entre dos estimadores conviene reportar la diferencia de sus RATE con un intervalo calculado sobre la misma muestra, por ejemplo con *bootstrap*, de modo que la diferencia no se confunda con ruido.

El `RScorer` de EconML (`econml.score.RScorer`) puntúa estimadores con la pérdida R de Nie y Wager (2021), un criterio distinto de RATE y complementario. Para RATE, el paquete `grf` de R trae una implementación.

Regla de decisión. La elección entre meta-learners y *causal forest* en datos reales se documenta con la diferencia de RATE y su intervalo, no con la inspección visual de la curva Qini. Qini sigue siendo la métrica de reporte para audiencias de negocio (Capítulo 22); RATE es la métrica de decisión interna.

14.6.3 Versionado del proceso de evaluación

Un segundo punto que DMLS enfatiza y que la literatura puramente estadística de validación causal rara vez menciona: el **proceso** de evaluación offline (qué *baselines*, qué partición de datos, qué semilla aleatoria) debe versionarse junto con el modelo, no solo el modelo mismo. Sin esto, comparar «la nueva versión del estimador es mejor que la anterior» es una afirmación no verificable: dos evaluaciones hechas con particiones distintas de los datos no son comparables, sin importar cuán rigurosa sea cada una por separado. La pieza de pruebas del Capítulo 2 existe exactamente para fijar este proceso una vez y reutilizarlo.

Esta perspectiva de sistema es la que conecta este capítulo con el siguiente: una vez que el proceso de evaluación offline está versionado y es reproducible, la pregunta natural es cómo llevar el estimador que pasó esa evaluación a un servicio que otros puedan consultar, el tema del Capítulo 15.

14.7 Ejercicios y notas bibliográficas

14.7.1 Ejercicios propuestos

1. Compare tres estimadores de CATE (por ejemplo un bosque causal, un X-learner y un T-learner) sobre la misma muestra de evaluación del caso canónico de la Sección 14.4.2. ¿Cuál obtiene el coeficiente Qini más alto, y cuánta incertidumbre tiene esa diferencia? (Parta del listado 14.1.)
2. Construya un DGP donde el CATE sea constante ($\tau(x) = \tau$ para todo x). Verifique que la curva Qini es plana, y explique por qué el coeficiente Qini, que divide por el área del orden perfecto, deja de ser informativo en ese caso.
3. En el caso canónico, la regla de riesgo ordena como el azar porque el resultado sin tratamiento no se relaciona con el efecto. Construya un DGP donde ambos estén positivamente correlacionados y otro donde lo estén negativamente. Prediga el signo del coeficiente Qini de la regla de riesgo en cada uno y verifíquelo. ¿Qué implica para una campaña que se dirige a «los clientes con más riesgo»?
4. Sobre un conjunto observacional con varios periodos previos al tratamiento (por ejemplo `cps_mixtape`), estime el CATE con un bosque causal y aplique un placebo temporal. Si el placebo rechaza, ¿qué supuesto se está violando y qué diseño lo corrige?
5. Implemente el *transformed outcome* $Y_i^\star$ de la ecuación (14.4) y calcule la correlación entre $Y_i^\star$ y $\hat{\tau}$. ¿Es alta? En el caso canónico vale 0,53 aunque el ranking es casi perfecto. Explique por qué la correlación no se acerca a 1 y qué dice eso sobre usar $Y^\star$ como métrica. Pista: compare la varianza de $Y^\star$ con la de τ (10,1 frente a 3,1).

14.7.2 Lecturas complementarias

Gutierrez y Gérardy (2017) revisa la literatura de uplift e introduce el *transformed outcome* usado en la Sección 14.2.3. Athey y Wager (2019) formaliza la validación causal aplicada. Schuler et al. (2018) compara sistemáticamente estrategias de selección de modelo para CATE y es la referencia empírica más útil para decidir con qué métrica quedarse. Para Qini, (Radcliffe 2007). VanderWeele y Ding (2017) es la referencia del E-value (Sección 14.2.5) y contiene las tablas de conversión de escala necesarias para aplicarlo fuera de razones de riesgo. Thornton (2008) documenta el experimento aleatorizado usado como banco de pruebas con identificación no discutida. Sobre el versionado del proceso de evaluación de la Sección 14.6, véase (Huyen 2022), Capítulo 6.

CAPÍTULO 15

Despliegue de un estimador causal como servicio

Cuadro de decisión del capítulo

Decisión:	Servir el estimador como un servicio síncrono que puede abstenerse, no como biblioteca embebida ni como *batch*
Alternativas:	Biblioteca embebida vs. servicio de red vs. estimaciones *batch* precomputadas
Trade-off clave:	Latencia y simplicidad de biblioteca vs. desacoplamiento y reutilización de un servicio
Stack:	FastAPI y `joblib`; Docker es opcional
Riesgo principal:	*Training-serving skew*, y un servicio que responde siempre, también donde el efecto no está identificado

Implementación en el monorepo del curso (2026)

Implementación de referencia: `04_notebooks_produccion_streamlit/B1_fastapi_dml/` (FastAPI, `inference.py` pura; Docker es opcional). Artefacto de entrada: `artifacts/A2/dml_estimator.joblib` + `model_card.json` (la ficha del modelo, con el esquema de roles del C-01: covariables, tratamiento y resultado). Labs: `L12`, `L14`. Humo: `autograder/grade_b1.py`. El endpoint local expone `/health`, `/metadata` y `/predict`.

15.1 El problema de diseño

El Capítulo 11 produjo un estimador DML entrenado y validado según los criterios del Capítulo 14. El problema de este capítulo, que cierra la Parte II, es distinto: ¿cómo se pone ese estimador a disposición de alguien, sea un compañero de equipo, otro servicio o una aplicación, que necesita una estimación sin tener que reabrir el entrenamiento? La respuesta no es única.

Huyen (2022) (Capítulo 7) y Kästner et al. (2024) (Capítulo 10) describen varios patrones de *serving* con costos y beneficios distintos, y elegir entre ellos es una decisión de diseño y no un detalle de implementación.

Para un estimador causal hay además una pregunta que un modelo predictivo no tiene. Un clasificador puede responder a cualquier entrada, y su error crece de forma gradual a medida que la entrada se aleja de lo que vio al entrenar. Un efecto causal estimado, en cambio, solo está identificado donde los datos de entrenamiento tenían variación en el tratamiento. Fuera de esa población el servicio puede devolver un número perfectamente formado, con su intervalo, y el número no significa nada. Un servicio causal responsable necesita por eso una tercera posibilidad además de acertar y de equivocarse: negarse a responder.

15.2 Opciones y trade-offs

Opciones y trade-offs

- **Biblioteca embebida.** El modelo serializado se distribuye como un paquete que cualquier proceso importa directamente. Es la opción de menor latencia, porque no hay llamada de red, y la más simple de depurar. Su costo: cada consumidor necesita el mismo entorno con las mismas versiones de dependencias, y actualizar el modelo exige redistribuir el paquete a todos los consumidores.
- **Servicio de red.** El modelo vive detrás de una interfaz de red. Los consumidores envían covariables y reciben una estimación, sin necesidad de tener instaladas las dependencias del modelo. Permite actualizar el modelo en un solo lugar y servir a consumidores escritos en cualquier lenguaje. Su costo es la latencia de red y la necesidad de operar un servicio (disponibilidad, escalado, versionado de la interfaz).
- ***Batch* precomputado.** Las estimaciones se calculan por adelantado para toda la población conocida y se guardan en una tabla que se consulta por clave. Es la opción de menor latencia de consulta y la más simple de auditar, porque todas las estimaciones existen antes de cualquier consulta. No sirve para unidades nuevas que no estaban al momento del cómputo, y el efecto estimado puede quedar desactualizado si las covariables de una unidad cambian entre el cómputo y la consulta.

Un segundo trade-off es la función de inferencia misma. Kästner et al. (2024) enfatiza que debe ser **pura**, sin efectos secundarios ni estado mutable entre llamadas, para que el mismo código se ejecute de forma idéntica en el entrenamiento y en el servicio y se evite el *training--serving skew* ya anticipado en el Capítulo 2.

15.3 Decisión de referencia para el curso

El curso adopta un **servicio síncrono detrás de una interfaz de red local** como patrón de referencia para todos los notebooks de producción de la Serie B, con una regla que lo distingue de un servicio de predicción: puede abstenerse. Se prefiere sobre la biblioteca embebida porque

permite consultar y actualizar el estimador sin replicar el entorno en cada consumidor, y sobre el *batch* precomputado porque los casos de uso del curso (Notebooks A2 y A4) requieren estimar el efecto para unidades nuevas y no solo para una población fija conocida de antemano.

Frontera · 2026

En 2026 lo habitual es exponer el servicio como una interfaz HTTP con mensajes JSON, y recurrir a gRPC cuando importa la latencia entre servicios. Empaquetar el servicio en un contenedor es frecuente pero no necesario. El contrato de la sección siguiente no depende del transporte ni del empaquetado, de modo que un cambio en estas costumbres no obliga a reescribir el capítulo.

15.4 El contrato del servicio

Este libro no fija una tecnología para el servicio: fija un contrato. Cualquier implementación lo cumple, sea un servicio web, una biblioteca o una tarea programada que llena una tabla, si pasa su prueba de aceptación. Los contratos del libro se numeran (C-01 a C-07) y comparten el formato que introdujo el C-01 (Sección 4.4) y que usa la caja que sigue: qué operaciones ofrece, qué recibe, qué devuelve, qué debe cumplirse siempre, cómo falla y cómo se comprueba.

Contrato C-04 · Servicio de estimación

Operaciones	*estimar*: recibe las covariables de una unidad y responde con un efecto y su intervalo, o se abstiene. *metadatos*: devuelve la ficha causal del modelo que está respondiendo, legible por máquina. *salud*: indica que el servicio está vivo, y nada más; no dice nada sobre la validez del efecto.
Entrada	Para *estimar*, las covariables de una unidad, con los nombres y tipos declarados en los roles causales del modelo (Capítulo 4). Las otras dos operaciones no reciben datos.
Salida	Para *estimar*, el estado (*responde* o *abstiene*) y la versión del modelo. Si responde, el efecto estimado y su intervalo de confianza. Si se abstiene, el motivo y las covariables que quedaron fuera de la población, y ningún número. La población de soporte y los supuestos se consultan con *metadatos*.
Invariantes	(1) Nunca devuelve un número sin su intervalo y sin su estado. (2) Con la misma versión del modelo y la misma entrada, la salida es idéntica. (3) Fuera de la población declarada, se abstiene. (4) Ninguna operación modifica el modelo ni la ficha. (5) La ficha de *metadatos* es la del artefacto que responde a *estimar*.

Modos de fallo	Una covariable ausente o de tipo inválido se rechaza como entrada inválida: ni se imputa ni se abstiene. Un valor faltante en una covariable que delimita la población cuenta como fuera de la población. Si el modelo o la ficha no se pueden cargar, el servicio no arranca, porque es preferible no responder a responder con un artefacto desconocido.
Prueba de aceptación	(a) Sobre datos con efecto conocido, la cobertura del intervalo no baja del piso calibrado más abajo. (b) Una consulta fuera de la población devuelve el estado *abstiene* y ningún número. (c) Dos llamadas idénticas devuelven salidas idénticas. (d) Una entrada inválida se rechaza. (e) La ficha de *metadatos* valida contra el esquema versionado del Apéndice G.

Cada decisión de diseño del contrato responde a un fallo concreto.

La abstención es una respuesta, no un error. El estado viaja dentro de la respuesta y no en un código de falla. Un consumidor que recibe un error lo trata como un problema técnico, reintenta o salta a un valor por defecto. Un consumidor que recibe *abstiene* sabe que el servicio funciona y que el efecto no está disponible para esa unidad, y tiene que decidir qué hace sin él. Obligarlo a esa decisión es el propósito.

La regla de soporte es explícita y viaja con el modelo. La regla más barata de comprobar es que cada covariable esté dentro del rango observado al entrenar. Es una condición necesaria y no suficiente: una combinación de covariables puede no haberse visto nunca aunque cada valor por separado sí. Reglas más finas, como abstenerse donde la propensión estimada se acerca a 0 o a 1 (Capítulo 11) o donde el tamaño efectivo de muestra local es bajo, cumplen el mismo contrato siempre que la ficha del modelo las declare. Lo que el contrato exige es que la regla exista, sea explícita y la calcule el proceso de registro a partir de los datos de entrenamiento, no una persona a mano.

El intervalo es el del efecto condicional promedio. Cubre el efecto medio entre las personas con esas covariables, no el efecto sobre una persona concreta. Para decisiones individuales hace falta calibración conforme (Capítulo 14), que es otro contrato.

Las operaciones se comprueban en un orden deliberado. La prueba de humo verifica primero *salud*, que el proceso vive; luego *metadatos*, que el artefacto cargado es el esperado (versión y huella de los datos); y solo entonces *estimar*, que la estimación es razonable. Un fallo en la segunda con éxito en la primera es el escenario silencioso que este capítulo busca hacer visible: el servicio responde, pero está sirviendo un modelo distinto del que el equipo cree.

15.4.1 La prueba de aceptación necesita datos con verdad conocida

Caso canónico · Datos con efecto conocido

Se simulan n unidades con cuatro covariables independientes $X_1, \ldots, X_4 \sim N(0,1)$. El tratamiento depende de la primera, $D \sim \text{Bernoulli}(\sigma(0.5X_1))$, y el resultado es $Y = \tau D + \sin(X_1) + 0.5X_2 + \varepsilon$ con $\varepsilon \sim N(0,1)$ y $\tau = 0.5$ constante. La primera covariable es un confusor: afecta al tratamiento y al resultado, de modo que una comparación ingenua de medias no recupera τ y un estimador ortogonalizado sí. Como el efecto es el mismo en toda la población, el intervalo que devuelva el servicio para cualquier unidad dentro de la población debe cubrir 0,5.

La prueba reajusta el estimador sobre R réplicas independientes de estos datos y cuenta en cuántas el intervalo cubre 0,5. Falta decidir qué cobertura mínima se acepta, y esa cifra no puede ser una constante elegida a ojo. Si el intervalo cubre de verdad el 95 %, la cobertura observada en R réplicas es una proporción con error estándar $\sqrt{0.95 \cdot 0.05/R}$. La regla del libro acepta una cobertura observada no inferior a

$$0.95 - 3\sqrt{0.95 \cdot \frac{0.05}{R}}, \tag{15.1}$$

que con $R = 200$ es 0,904. Se usan tres errores estándar porque una prueba que falla por azar una de cada veinte ejecuciones acaba ignorándose. Con $R = 200$, un servicio cuyo intervalo cubre de verdad el 95 % falla esta prueba en el 0,3 % de las ejecuciones (una de cada 370), y uno que cubre solo el 85 % la falla en el 98,5 %. Un intervalo que cubre el 90 % es más difícil de detectar: la prueba lo rechaza el 53 % de las veces, de modo que para detectar desviaciones pequeñas hay que aumentar R. En la simulación de verificación ($R = 200$, $n = 1\,000$, semilla fija) el estimador ortogonalizado cubrió el 96 % de las veces y pasó la prueba. La comparación ingenua de medias, que ignora el confusor, cubrió el 4,5 % y fue rechazada, que es lo que la prueba existe para lograr.

15.5 Aplicación al sistema causal del curso

La respuesta del servicio no es solo el efecto puntual: incluye el estado, el intervalo y la versión del modelo, y la población de soporte se consulta en los metadatos. Esto no es una decisión estética. El Capítulo 2 comprometió que la interfaz debe comunicar algo más que un número, y que a veces la respuesta correcta es no dar ninguno. Aquí queda concreto: ningún consumidor puede usar el efecto estimado como válido para una población distinta de la de entrenamiento sin saberlo, porque el propio servicio se lo advierte o se niega a responder.

El servicio hace cumplir el soporte en cada consulta, pero desde una sola consulta no puede ver lo que el monitoreo sí ve en conjunto. El Capítulo 30 vigila la proporción de consultas que terminan en abstención: si crece, la población que consulta se está alejando de la de entrenamiento, y es una de las señales que activan las acciones del vocabulario del Capítulo 2.

La operación de metadatos no es decorativa ni redundante con la *model card* del Capítulo 19. La *model card* es documentación para personas y vive en el repositorio. Los metadatos son el mismo contrato expuesto en tiempo de ejecución y de forma legible por máquina, de modo que un consumidor automatizado puede verificar qué versión del modelo responde y bajo qué supuestos sin depender de que alguien haya leído un documento.

15.6 Implementación de referencia

La función de inferencia se separa del servicio web. Lee dos cosas empaquetadas con el modelo: el estimador serializado y la ficha del modelo en JSON (Capítulo 19). La ficha trae los roles causales del Capítulo 4, es decir, el `CausalSchema` guardado como datos, y la regla de soporte. Guardar el esquema como datos y no como un objeto serializado evita un fallo clásico: un objeto de una clase definida en un notebook solo se puede cargar donde esa clase exista con el mismo nombre de módulo, y el servicio es otro proceso.

```
# inference.py -- funcion pura, sin dependencias de FastAPI
import copy
import json
import joblib
import pandas as pd

_modelo = joblib.load("model/dml_estimator.joblib")
with open("model/model_card.json", encoding="utf-8") as f:
    _card = json.load(f)                  # contrato causal del artefacto

_COVARIABLES = _card["roles"]["covariables"]
_SOPORTE = _card["poblacion"]["soporte"]
assert _SOPORTE["regla"] == "rango_por_covariable", "regla de soporte no
implementada"
assert set(_SOPORTE["rangos"]) <= set(_COVARIABLES)
_VERSION = _card["version"]["modelo"]


def estimar_efecto(covariables: dict) -> dict:
    """Funcion pura: la misma version y la misma entrada dan siempre la misma
salida.
    Devuelve estado "responde" (efecto e intervalo) o "abstiene" (ningun
numero)."""
    faltantes = set(_COVARIABLES) - set(covariables)
    if faltantes:
        raise ValueError(f"Faltan covariables requeridas: {sorted(faltantes)}")
    # not (lo <= v <= hi) y no (v < lo or v > hi): un valor faltante (NaN)
tambien abstiene
    fuera = sorted(c for c, (lo, hi) in _SOPORTE["rangos"].items()
                   if not (lo <= covariables[c] <= hi))
    if fuera:
```

```
        return {"estado": "abstiene", "motivo": "fuera_de_poblacion",
                "covariables_fuera_de_rango": fuera, "version_modelo":
_VERSION}
    X = pd.DataFrame([covariables])[_COVARIABLES]
    efecto = _modelo.effect(X)[0]
    ic_inf, ic_sup = _modelo.effect_interval(X, alpha=0.05)
    return {
        "estado": "responde",
        "efecto_estimado": float(efecto),
        "ic_95_inferior": float(ic_inf[0]),
        "ic_95_superior": float(ic_sup[0]),
        "version_modelo": _VERSION,
        # El intervalo es el del efecto condicional promedio en estas
covariables.
        # Para decisiones sobre una persona hace falta calibracion conforme.
    }
```

Listado 15.1: Función de inferencia pura, desacoplada del framework web. Implementa *estimar* del contrato C-04.

```
# app.py
from fastapi import FastAPI, HTTPException
from pydantic import BaseModel
from inference import estimar_efecto, metadatos_modelo

app = FastAPI(title="Servicio de estimacion causal")

class Covariables(BaseModel):
    exper: float
    black: int
    south: int
    married: int

@app.post("/predict")
def predict(cov: Covariables):
    try:
        return estimar_efecto(cov.model_dump())
    except ValueError as e:
        raise HTTPException(status_code=422, detail=str(e))

@app.get("/health")
def health():
    """Liveness: el proceso responde. No dice nada sobre validez causal."""
    return {"status": "ok"}

@app.get("/metadata")
def metadata():
```

```
    """Ficha causal del modelo servido: estimando, supuestos, poblacion y
version.
    Permite a un consumidor decidir si el efecto es aplicable a su caso ANTES
    de llamar a /predict."""
    return metadatos_modelo()
```

Listado 15.2: Servicio FastAPI que envuelve la función de inferencia. Una abstención responde con código 200: es una respuesta válida, no un error.

Los metadatos salen del mismo artefacto que la inferencia, de modo que lo que se declara y lo que responde no pueden divergir:

```
# inference.py (continuacion del listado anterior)
def metadatos_modelo() -> dict:
    """Ficha causal legible por maquina del artefacto servido. Es el contenido
de
    model_card.json, que valida contra causal-model-card-v2 (Ap. G.4); el CI lo
    verifica antes de registrar el modelo."""
    return copy.deepcopy(_card)           # copia: el llamador no puede alterar
la ficha
```

Listado 15.3: Metadatos del modelo, servidos desde el mismo archivo que alimenta la inferencia. Implementa *metadatos* del contrato C-04.

El empaquetado en un contenedor es opcional. Si se usa, conviene fijar las versiones de las dependencias, porque un contenedor construido con versiones libres se comporta distinto según el día en que se construya:

```
FROM python:3.11-slim
WORKDIR /app
COPY requirements.txt .
RUN pip install --no-cache-dir -r requirements.txt
COPY inference.py app.py ./
COPY model/ ./model/
EXPOSE 8000
CMD ["uvicorn", "app:app", "--host", "0.0.0.0", "--port", "8000"]
```

Listado 15.4: `Dockerfile` opcional para empaquetar el servicio.

En esta implementación, la prueba de humo pide primero `/health`, luego `/metadata` y por último `/predict`, el orden que fija el contrato.

15.7 Señales de alerta y checklist operativo

- ☐ La función de inferencia calcula las covariables con código distinto del usado durante el entrenamiento (riesgo directo de *training-serving skew*).
- ☐ La respuesta devuelve solo el efecto puntual, sin intervalo y sin estado.

- ☐ El servicio responde siempre un número, incluso con entradas fuera de la población de entrenamiento: no existe ninguna condición en la que se abstenga.
- ☐ No existe una operación de salud verificable independientemente de la estimación.
- ☐ No hay forma de saber, consultando el servicio, qué versión del modelo está respondiendo ni sobre qué datos se entrenó (metadatos ausentes, o sin versión y huella de los datos).
- ☐ La regla de soporte la escribió una persona a mano en lugar de calcularla de los datos de entrenamiento, o no está en la ficha del modelo.
- ☐ Las dependencias del servicio no están fijadas a versiones exactas, de modo que el servicio se comporta distinto según cuándo se construya.

15.8 Ejercicios y notas bibliográficas

15.8.1 Ejercicios conceptuales

1. Para el caso de la política de *targeting* del Capítulo 21, ¿cuál de las tres opciones de la Sección 15.2 sería más apropiada si el número de clientes a evaluar es fijo y conocido cada mes? Justifique.
2. Explique con sus propias palabras por qué separar la función de estimación de la interfaz de red facilita probar la lógica de inferencia sin necesidad de levantar el servicio. (Listados 15.1 y 15.2.)
3. Un consumidor del servicio recibe *abstiene* para el 12 % de sus consultas y pide que «el servicio devuelva la mejor estimación posible» en esos casos. ¿Qué responde usted? Distinga lo que el servicio puede ofrecer (por ejemplo, el rango de la población que sí conoce) de lo que no debe ofrecer, y explique qué decisión le toca tomar al consumidor.
4. La regla de soporte por rango de cada covariable es necesaria y no suficiente. Construya un ejemplo con dos covariables en el que una unidad cae dentro del rango de ambas y aun así el efecto no está identificado para ella. Proponga una regla más fina y diga qué costo tiene (por ejemplo, abstenerse en unidades donde el efecto sí estaba bien estimado).
5. Con $R = 100$ réplicas, calcule el piso de cobertura que fija la regla de la Sección 15.4.1. ¿Qué pasa con la capacidad de la prueba para detectar un intervalo que cubre el 90 % cuando R baja de 200 a 100? ¿Qué haría para recuperar potencia sin subir el costo de la prueba?

15.8.2 Ejercicio de infraestructura (Lab, Notebook B1)

1. Complete el Notebook de producción B1: serialice el estimador DML entrenado, genere la ficha `model_card.json` con el listado del Capítulo 19, adapte los listados 15.1 y 15.2 a su dataset y verifique con `curl` o el cliente HTTP de su elección que `/health` y `/metadata` responden, que `/predict` responde con una unidad de la población y que se

abstiene con una unidad fuera de ella. Si lo desea, construya además la imagen con el listado 15.4.

15.8.3 Notas bibliográficas

Huyen (2022), Capítulo 7 («Model Deployment and Prediction Service»), y Kästner et al. (2024), Capítulo 10 («Deploying a Model»), son las dos referencias principales de este capítulo. El segundo desarrolla en particular la discusión de *features* dentro y fuera del servicio y el *training-serving skew* retomada en la Sección 15.5. La idea de que un sistema de decisión debe poder negarse a responder cuando no hay identificación se sigue de la condición de soporte común del Capítulo 5 y de la discusión de validez externa del Capítulo 26.

PARTE III

Diseños de identificación con ML

Esta parte conecta el ML causal con diseños econométricos clásicos de identificación: selección de controles en alta dimensión con Post-Double-Selection, datos de panel e instrumentos con DML-IV, y un mapa de decisión que sintetiza cuándo usar cada diseño de los cubiertos hasta aquí.

CAPÍTULO 16

Post-Double-Selection LASSO

Cuadro sinóptico del capítulo

Problema:	Selección de confusores en alta dimensión para estimación causal
Estimando:	θ_0 en el modelo $Y = D\theta_0 + X^T\gamma_0 + \varepsilon$
Identificación:	No confusión condicional, esparsidad aproximada, condición de autovalores restringidos
Método:	PDS LASSO: doble selección (LASSO de Y y de D) y OLS final
Nuisance:	Conjuntos de controles seleccionados para Y y para D
Garantía:	$\sqrt{n}\left(\hat{\theta}_{\text{PDS}} - \theta_0\right) \xrightarrow{d} \mathcal{N}(0, \mathcal{V})$, uniforme sobre una clase de modelos
Librerías:	scikit-learn, statsmodels
Validación:	Sensibilidad a λ, comparación con DML

Nota técnica

Este capítulo abre la Parte III del libro, dedicada a diseños de identificación completos. El Capítulo 8 formalizó el criterio de puerta trasera de forma general; Post-Double-Selection es el procedimiento concreto para aplicarlo cuando el conjunto de controles candidatos es de alta dimensión y no se sabe, a priori, cuáles son verdaderamente confusores.

16.1 Motivación aplicada

Una economista de la salud quiere estimar el efecto de dejar de fumar sobre el cambio de peso a lo largo de once años, con los datos de seguimiento de una cohorte nacional (el estudio NHEFS que Hernán y Robins usan como ejemplo canónico). Hay medio centenar de covariables medidas antes del tratamiento: demográficas, de hábitos, de salud y socioeconómicas. No todas son confusoras: algunas no afectan ni al tratamiento ni al resultado, otras afectan solo al resultado. La pregunta metodológica es cómo seleccionar automáticamente las confusoras relevantes sin inducir el sesgo post-selección del capítulo 6.

Belloni et al. (2014) proponen el Post-Double-Selection (PDS) LASSO como solución. Las confusoras son las variables que predicen *tanto* al tratamiento *como* al resultado, y un LASSO que mira solo una de las dos ecuaciones puede dejar fuera una confusora que importa en la otra. Seleccionando por separado cada conjunto y tomando la unión, las confusoras relevantes quedan dentro con alta probabilidad, y las que se escapan lo hacen con un sesgo de segundo orden. El capítulo desarrolla PDS formalmente, lo contrasta con DML (capítulo 11), que no requiere esparsidad explícita, y muestra con dos casos de resultado conocido dónde funciona y dónde no.

16.2 Teoría, supuestos y garantías

16.2.1 Modelo de alta dimensión con efecto causal

Consideramos el modelo

$$Y = D\theta_0 + X^T\gamma_0 + \varepsilon, \quad D = X^T\beta_0 + v, \tag{16.1}$$

donde $X \in R^p$ con p potencialmente mayor que n, γ_0 y β_0 son *sparse* (con pocas componentes no nulas, o bien aproximables por pocas) y θ_0 es el parámetro causal de interés. Suponemos $E[\varepsilon \mid D, X] = 0$ y $E[v \mid X] = 0$. La primera condición es la no confusión condicional: dados los controles, el tratamiento es ignorable.

Sustituyendo D en la primera ecuación se obtiene la *forma reducida* $Y = X^T(\gamma_0 + \theta_0\beta_0) + (\varepsilon + \theta_0 v)$, que también es esparsa si lo son γ_0 y β_0. Esto explica por qué el LASSO de Y sobre X sin incluir D es un paso legítimo del procedimiento.

16.2.2 Post-Double-Selection (PDS)

El procedimiento consiste en tres pasos:

1. **Selección de controles para D:** LASSO de D sobre X, con conjunto seleccionado S_D.
2. **Selección de controles para Y:** LASSO de Y sobre X (sin D), con conjunto seleccionado S_Y.
3. **OLS final:** regresión de Y sobre D y las variables de $S = S_Y \cup S_D$, sin penalización. Los intervalos de confianza usan errores estándar robustos a heterocedasticidad y cuantiles de la normal (o de la t, que es asintóticamente equivalente).

El OLS final, llamado *post-LASSO*, elimina el sesgo de contracción que el LASSO induce en los coeficientes seleccionados, y por eso es el estimador que se reporta, no los coeficientes del LASSO.

Algoritmo

Entrada: Datos $\{(Y_i, D_i, X_i)\}_{i=1}^{n}$, penalización λ (teórica o por validación cruzada).
Salida: Estimador $\hat{\theta}_{\text{PDS}}$ y error estándar robusto $\hat{\sigma}_{\text{HC}}$.
Estandarizar las columnas de X (media 0, varianza 1).
Ejecutar LASSO de D sobre X con penalización λ e identificar $S_D = \left\{j : \hat{\beta}_{D,j} \neq 0\right\}$.
Ejecutar LASSO de Y sobre X con penalización λ e identificar $S_Y = \left\{j : \hat{\beta}_{Y,j} \neq 0\right\}$.
Unión: $S = S_Y \cup S_D$.
Estimar por OLS Y sobre una constante, D y X_S.
Calcular errores estándar robustos a heterocedasticidad.
return $\hat{\theta}_{\text{PDS}}, \hat{\sigma}_{\text{HC}}$.

Algoritmo 11. Post-Double-Selection (PDS)

Teorema 16.1 ***(Belloni, Chernozhukov y Hansen, 2014)***

Bajo esparsidad aproximada de γ_0 y β_0 con índice de esparsidad s tal que $s^2 \log^2 \frac{\max(p,n)}{n} \to 0$, condiciones de autovalores restringidos y regularidad de los momentos, y con la penalización del LASSO elegida como la Sección 16.2.4 describe, el estimador PDS cumple

$$\sqrt{n}\left(\hat{\theta}_{\text{PDS}} - \theta_0\right) \xrightarrow{d} \mathcal{N}(0, \mathcal{V}), \tag{16.2}$$

donde $\mathcal{V} = \frac{E[v^2\varepsilon^2]}{E[v^2]^2}$, y la convergencia es uniforme sobre una clase de modelos que no exige que el LASSO seleccione exactamente el soporte verdadero. La inferencia con errores estándar robustos es válida.

La uniformidad es lo que distingue a PDS de la inferencia ingenua tras una selección: el resultado vale aunque el LASSO omita coeficientes pequeños, porque los errores de selección que importan son de segundo orden, como el esquema de la Sección 16.2.5 muestra.

16.2.3 Pseudocódigo: Post-Double-Selection

16.2.4 La elección de λ no es un detalle de implementación

El teorema se enuncia «para un λ apropiadamente elegido», y conviene detenerse en esa cláusula porque es donde la práctica se aparta con más frecuencia de la teoría que la respalda.

La validación cruzada elige λ minimizando el error de **predicción** fuera de muestra. Es el criterio correcto si el objetivo es predecir, pero no es el criterio bajo el cual se demuestra el teorema. El λ óptimo para predicción tiende a ser más pequeño que el teóricamente justificado, porque incluir variables ligeramente informativas reduce el error cuadrático aunque introduzca sesgo en los coeficientes individuales; el resultado es un $\hat{S}$ más grande de lo necesario y, en muestras pequeñas, un OLS final con demasiados regresores.

Belloni et al. (2014) derivan en cambio un nivel de penalización **teóricamente justificado**. Para columnas estandarizadas y una pérdida promedio, es de la forma

$$\lambda = \frac{c \cdot \sigma}{\sqrt{n}} \cdot \Phi^{-1}(1 - \gamma/(2p)), \tag{16.3}$$

con $c \approx 1.1$ y $\gamma = 0.1/\log(\max(p, n))$. La fórmula tiene una lectura directa: la penalización se calibra para dominar el «ruido máximo» entre las p variables candidatas, de ahí el cuantil de la normal evaluado en una cola corregida por el número de comparaciones (un ajuste de Bonferroni), de modo que ninguna variable irrelevante entre por azar con probabilidad no despreciable. Como σ es desconocida, se estima iterativamente, o se usa la variante **rigurosa**, con una penalización distinta por variable que además corrige la heterocedasticidad.

La consecuencia práctica es una advertencia de doble filo. Con la penalización teórica, el conjunto seleccionado es pequeño y el procedimiento es conservador: protege contra falsos positivos, pero deja fuera las variables cuyo efecto no supera el umbral, y eso es inocuo solo si el sesgo que su omisión induce es de segundo orden. La recomendación operativa es reportar ambas versiones, la estimación con λ_{CV} y la estimación con λ_{BCH}. Si coinciden, que es lo frecuente cuando n es cómodo y la señal es clara, la elección era inmaterial y conviene decirlo. Si difieren, la discrepancia es información: señala que el resultado depende de cuántos controles se admitan, y ninguna de las dos cifras debería reportarse sola. La Sección 16.3 desarrolla esta comparación como análisis de sensibilidad estándar.

16.2.5 Por qué la doble selección funciona

El sesgo post-selección del capítulo 6 surge porque el LASSO puede *omitir* una confusora relevante cuando su coeficiente en la ecuación que se mira es pequeño. Un LASSO sobre la ecuación del resultado, con D incluido, omite una variable X_j cuyo efecto $\gamma_{0,j}$ es chico, aunque esa variable determine fuertemente a D. Si se la omite en el OLS final, el sesgo sobre $\hat{\theta}$ es proporcional al **producto** $\gamma_{0,j}\beta_{0,j}$: lo que X_j aporta a Y por lo que X_j aporta a D. Con una sola variable omitida y $E[v^2]$ la varianza de lo que de D no explican los controles incluidos, el sesgo límite es $\gamma_{0,j}\beta_{0,j}/\left(\beta_{0,j}^2 + E[v^2]\right)$.

La doble selección usa el hecho de que un producto es pequeño solo si al menos uno de sus factores lo es. Una variable que queda fuera de $S = S_Y \cup S_D$ no superó el umbral en ninguna de las dos ecuaciones: tanto su efecto en la forma reducida de Y como su efecto en D son del orden de $\lambda \sim \sqrt{\log p/n}$. Su contribución al sesgo es entonces del orden de $\log p/n$ por variable, y sumada sobre a lo sumo s variables relevantes omitidas es $O(s \log p/n)$, que es $o(1/\sqrt{n})$ precisamente cuando s es pequeño frente a $\sqrt{n}/\log p$. Esa es la condición de esparsidad del teorema, y este es el mismo argumento de producto que hace ortogonal al score de DML (Capítulo 10): el error de estimar los *nuisance* entra al sesgo multiplicado, no sumado. El argumento es un esquema; la demostración requiere controlar además el error de estimación de los coeficientes seleccionados.

Esto precisa dos matices que el lenguaje habitual de «las confusoras son las que afectan a ambos» no recoge. Primero, la unión captura variables que predicen solo D y no afectan a Y, que no son confusoras. Incluirlas no sesga bajo no confusión condicional, pero cuesta varianza, y con confusión no observada amplifica el sesgo (el Capítulo 8 muestra por qué). Segundo, las variables que predicen solo Y son inocuas y reducen la varianza del estimador final.

Caso canónico · Selección simple frente a doble selección

Cien observaciones y 200 covariables correlacionadas ($\Sigma_{ij} = 0.5^{|i-j|}$), con $\theta_0 = 0.5$ y ruidos normales estándar. Los coeficientes decrecen con el índice, $\beta_{0,j} = 4/j^2$ para D y $\gamma_{0,j} = 0.6/j^2$ para Y, de modo que X_1 es una confusora fuerte para el tratamiento ($\beta_{0,1} = 4$) y débil para el resultado ($\gamma_{0,1} = 0.6$, bajo el umbral de la penalización teórica con $n = 100$). La *selección simple* es un LASSO de Y sobre D y X con D sin penalizar, seguido de OLS. Con 500 repeticiones y la penalización teórica en todos los LASSO:

Método	Sesgo	Desv. est.	Cobertura IC 95 %
Sin controles	+0,145	0,020	0,00
Selección simple	+0,145	0,020	0,00
Doble selección (PDS)	+0,032	0,094	0,92
Oráculo (X_1 a X_5)	+0,016	0,099	0,94

La selección simple no selecciona nada (en promedio 0,002 variables) y coincide exactamente con la estimación sin controles: el sesgo de 0,145 es el de omitir a X_1, y como la desviación estándar es de apenas 0,02, el intervalo es estrecho y falla en todas las repeticiones. La doble selección elige en promedio 2,9 variables, entre ellas casi siempre X_1, que entra por la ecuación de D, y recupera una cobertura de 0,92 con un sesgo cercano al del oráculo. El precio es la varianza: la desviación estándar pasa de 0,02 a 0,09, porque con $n = 100$ el control X_1 y sus vecinas correlacionadas absorben variación del tratamiento. Un intervalo estrecho y equivocado no es mejor que uno ancho y correcto, y la selección simple solo parece más precisa.

16.2.6 Comparación con DML

PDS y DML atacan el mismo problema, la estimación causal con muchos controles, con estrategias distintas:

Dimensión	PDS LASSO	DML
Supuesto estructural	Esparsidad aproximada de las dos ecuaciones y linealidad en X	Que los *nuisance* se estimen a una tasa de producto $o(n^{-1/2})$; no exige esparsidad en sí
Forma funcional	Lineal en X, ampliable con un diccionario de transformaciones	Cualquier aprendiz para los *nuisance*
Efecto estimado	Constante	Constante (modelo parcialmente lineal) o heterogéneo (IRM, CATE)

Dimensión	PDS LASSO	DML
Inferencia	Normal asintótica con errores robustos, uniforme sobre la clase de modelos	Normal asintótica por la función de influencia del score ortogonal
Implementación	`scikit-learn` más OLS	`DoubleML`, `econml`
Cuándo conviene	Pocos controles relevantes, relación lineal, muestra pequeña	Relaciones no lineales, muchas señales pequeñas, muestra moderada o grande

Tabla 16.1: PDS frente a DML.

Intuición

Caja de profundización: PDS con instrumentos y cuándo preferir PDS frente a DML

Objetivo. Extender PDS a variables instrumentales y entender cuándo preferir PDS sobre DML.

PDS con instrumentos. Con un instrumento Z y controles de alta dimensión, el mismo argumento de producto pide quitar el efecto de los controles de las tres variables que intervienen en el diseño. Una variante estándar selecciona, por separado, los controles que predicen Y, D y Z sobre X, y estima por mínimos cuadrados en dos etapas con la unión como controles. Cuando hay además muchos instrumentos, la selección de instrumentos es un problema aparte, que Belloni et al. (2012) tratan.

¿Cuándo usar cada uno?

- **PDS:** mejor con muestra pequeña, modelo lineal y esparsidad fuerte (pocos controles relevantes).
- **DML:** mejor con no linealidades, dudas sobre la forma funcional o muchas variables con efectos pequeños.
- **Regla práctica:** sin convicción sobre la linealidad y la esparsidad, DML; con ella y una muestra pequeña, PDS.

Límite de PDS. Si hay **confusión densa** (muchas variables con efectos pequeños que en conjunto importan), la selección omite variables que juntas sesgan el resultado. La Sección 16.2.7 lo cuantifica.

16.2.7 Confusión densa

La esparsidad es un supuesto sobre la estructura del problema, y la selección con penalización teórica es conservadora. Cuando muchas variables tienen cada una un efecto pequeño sobre D y sobre Y, ninguna supera individualmente el umbral y todas se omiten, pero el sesgo total es la suma de muchos productos pequeños.

Caso canónico · Confusión densa

Mil observaciones, 100 covariables independientes y $\theta_0 = 1$. Cada covariable entra con coeficiente 0.1 tanto en $D = 0.1\sum_j X_j + v$ como en $Y = D + 0.1\sum_j X_j + \varepsilon$, con ruidos normales estándar. Sin controles, el límite de $\hat{\theta}$ es $1 + 100 \cdot 0.1^2/(100 \cdot 0.1^2 + 1) = 1.5$: un sesgo de 0,5. Con 150 repeticiones:

Método	Sesgo	Desv. est.	Cobertura IC 95 %
Sin controles	+0,499	0,030	0,00
PDS con penalización teórica	+0,457	0,030	0,00
PDS con λ por validación cruzada	0,000	0,033	0,94
DML con LASSO (validación cruzada)	+0,001	0,036	0,89
DML con ridge (validación cruzada)	+0,008	0,035	0,89

La penalización teórica selecciona en promedio 6 de las 100 covariables, las que por azar muestral superan el umbral, y deja casi todo el sesgo (+0,457): el estimador es preciso (desviación estándar de 0,03) y su intervalo falla en todas las repeticiones. Lo que falla es la combinación de una penalización conservadora con confusión densa, no el LASSO en sí. Con λ por validación cruzada, el procedimiento selecciona las 100 covariables, es decir, se reduce a un OLS con todos los controles, y la cobertura es 0,94. Eso funciona aquí porque $p = 100$ es pequeño frente a $n = 1000$; con $p > n$ no existe el OLS completo, y en ese terreno la confusión densa no tiene salida dentro de PDS. DML con aprendices de *nuisance* elegidos por validación cruzada (LASSO o ridge) también recupera el efecto, con una cobertura de 0,89 algo baja que con 150 repeticiones no se distingue del error de simulación, porque su validez no depende de que la selección sea esparsa. El diagnóstico práctico es este: si PDS con penalización teórica selecciona pocas variables y PDS con λ_{CV} selecciona muchas y además mueve la estimación, hay señales de confusión densa, y la discrepancia entre λ_{BCH} y λ_{CV} que la Sección 16.2.4 pide reportar es la alarma.

16.3 Sensibilidad y validación

16.3.1 Sensibilidad a la elección de λ

El resultado de PDS es una función de λ, y trazar esa función es parte del análisis. Se calcula $\hat{\theta}(\lambda)$ con su intervalo sobre una malla de valores y se lee la forma de la curva. Una **meseta amplia** alrededor del λ elegido indica que el resultado no depende de cuántos controles se admitan, y es la situación en que reportar una sola cifra es defendible. Una curva con pendiente pronunciada en el entorno del λ elegido indica lo contrario, que el efecto estimado es función de una decisión de hiperparámetro, y obliga a reportar el rango completo en lugar de un punto. Para λ muy grande el conjunto seleccionado se vacía y la curva converge a la estimación sin

controles, de modo que el tramo donde la curva se despega de la meseta señala qué controles sostienen el resultado. Por eso el gráfico de sensibilidad no es un apéndice opcional sino parte del resultado, junto con la comparación λ_{CV} frente a λ_{BCH} de la Sección 16.2.4.

16.3.2 Una limitación del PDS estándar

A diferencia de DML, el procedimiento PDS tal como se presenta aquí no usa *cross-fitting*: las dos selecciones LASSO y el OLS final se calculan sobre la misma muestra. La teoría no lo necesita, porque la estructura lineal y la penalización controlan el sobreajuste por otra vía: el argumento descansa en la esparsidad y en cotas uniformes, no en independencia entre etapas. La contrapartida es que esa garantía es exactamente tan fuerte como los supuestos de linealidad y esparsidad: si alguno falla, PDS no tiene la red de seguridad que el *cross-fitting* da a DML. Es una razón adicional, junto con la confusión densa, para preferir DML cuando no se tiene una convicción sustantiva sobre la forma funcional.

16.4 Implementación en Python

16.4.1 Implementación de PDS

```
import pandas as pd
import numpy as np
from sklearn.linear_model import LassoCV
import statsmodels.api as sm

df = pd.read_csv("../data/datasets/real/public_causaldata/nhefs/data.csv")
# Outcome: cambio de peso. Treatment: qsmk (quit smoking)
# Seleccionar columnas numericas como controles
Y_col = "wt82_71"   # cambio de peso
D_col = "qsmk"      # dejo de fumar
# Excluir identificadores, muerte y variables medidas en 1982 (post-
tratamiento)
POST = ["seqn", "id", "death", "yrdth", "modth", "dadth", "censored", "wt82",
        "sbp", "dbp", "smkintensity82_71", "hightax82", "price82", "tax82",
        "price71_82", "tax71_82"]
X_cols = [c for c in df.columns if c not in [Y_col, D_col] + POST]
# Limpiar (solo outcome y tratamiento; NA en controles -> 0 abajo)
df_clean = df.dropna(subset=[Y_col, D_col]).reset_index(drop=True)
Y = df_clean[Y_col].values
D = df_clean[D_col].values.astype(float)
X = df_clean[X_cols].select_dtypes(include=[np.number]).fillna(0).values
# Estandarizar: el LASSO penaliza por igual todas las columnas, y su escala
importa
X = (X - X.mean(axis=0)) / np.where(X.std(axis=0) > 0, X.std(axis=0), 1.0)

def pds_lasso(Y, D, X, cv=5):
```

```
    """Post-Double-Selection LASSO."""
    # Paso 1: LASSO Y ~ X
    lasso_Y = LassoCV(cv=cv, max_iter=10000, random_state=42).fit(X, Y)
    S_Y = np.where(np.abs(lasso_Y.coef_) > 1e-8)[0]
    # Paso 2: LASSO D ~ X
    lasso_D = LassoCV(cv=cv, max_iter=10000, random_state=42).fit(X, D)
    S_D = np.where(np.abs(lasso_D.coef_) > 1e-8)[0]
    # Union
    S = sorted(set(S_Y) | set(S_D))
    print(f"Seleccionadas: {len(S)} variables (de {X.shape[1]})")
    # Paso 3: OLS Y ~ D + X_S
    if len(S) == 0:
        X_final = sm.add_constant(D)
    else:
        X_final = sm.add_constant(np.column_stack([D, X[:, S]]))
    ols = sm.OLS(Y, X_final).fit(cov_type="HC1")
    theta = ols.params[1]
    se = ols.bse[1]
    return theta, se, S

theta_pds, se_pds, S = pds_lasso(Y, D, X)
print(f"PDS: theta={theta_pds:.4f}  SE={se_pds:.4f}
IC=[{theta_pds-1.96*se_pds:.4f}, {theta_pds+1.96*se_pds:.4f}]")
```

Listado 16.1: Post-Double-Selection LASSO sobre NHEFS.

Nota técnica

Tres advertencias sobre este listado. Primera, no forzar la inclusión de una covariable arbitraria: PDS usa la unión de las variables seleccionadas en los pasos de Y y D, y la constante se agrega por separado con `add_constant` forzar una columna puede introducir ruido, colisionadores o variables post-tratamiento. Segunda, el listado usa `LassoCV`, es decir λ_{CV} y no la penalización teórica; para esta última, el paquete `hdmpy` implementa la penalización rigurosa de Belloni et al. (2014), y con `scikit-learn` puede construirse a mano fijando `alpha` en lugar de usar `LassoCV`. Tercera, los valores faltantes de los controles se reemplazan por cero, que es una imputación arbitraria (un nivel educativo faltante no es un nivel educativo cero); para un análisis real conviene imputar con un criterio explícito o añadir indicadores de faltante.

16.4.2 Comparación PDS frente a DML y a la selección manual

```
from econml.dml import LinearDML
from sklearn.ensemble import GradientBoostingRegressor,
GradientBoostingClassifier
```

```
# DML con GBM
est = LinearDML(model_y=GradientBoostingRegressor(n_estimators=200,
random_state=42),
                model_t=GradientBoostingClassifier(n_estimators=200,
random_state=42),
                discrete_treatment=True, cv=5, random_state=42).fit(Y, D, X=X)
ate_dml = est.ate(X=X)
lb, ub = est.ate_interval(X=X, alpha=0.05)
print(f"DML:  theta={ate_dml:.4f}  IC=[{lb:.4f}, {ub:.4f}]")

# Seleccion manual (5 controles obvios)
manual_cols = ["age", "sex", "race", "smokeintensity", "smokeyrs"]
X_manual = df_clean[manual_cols].fillna(0).values
X_final_m = sm.add_constant(np.column_stack([D, X_manual]))
ols_m = sm.OLS(Y, X_final_m).fit(cov_type="HC1")
print(f"Manual: theta={ols_m.params[1]:.4f}  SE={ols_m.bse[1]:.4f}")
```

Listado 16.2: Comparación PDS vs. DML vs. selección manual.

16.4.3 Réplica sobre NHEFS

NHEFS es el ejemplo canónico de Hernán y Robins (2020) para el efecto de dejar de fumar sobre el peso; aquí aplicamos PDS, propuesto por Belloni et al. (2014), al mismo dataset. Réplica propia sobre `nhefs` con $n = 1\,566$ observaciones y 51 controles potenciales (excluidas las variables post-tratamiento y de fecha). Las cifras vienen de la edición anterior y no se recalcularon en esta, porque el dataset no estaba disponible en el entorno de revisión; conviene repetir el listado 16.1 en local antes de citarlas:

- OLS sin controles: $\theta = 2.54$ kg, IC 95% $[1.59, 3.50]$.
- OLS con 5 controles manuales (`age, sex, race, smokeintensity, smokeyrs`): $\theta = 3.20$ kg, IC 95% $[2.26, 4.14]$.
- LASSO ingenuo y OLS: $\theta = 3.21$ kg, IC 95% $[2.28, 4.13]$ (18 variables seleccionadas).
- PDS LASSO: $\theta = 3.22$ kg, IC 95% $[2.29, 4.14]$ (18 variables seleccionadas).
- DML con GBM: $\theta = 3.13$ kg, IC 95% $[2.16, 4.10]$.

La lectura correcta es más modesta que «PDS corrige a la selección manual». La diferencia relevante es entre los controles y la ausencia de ellos, de 2.54 a un valor entre 3.13 y 3.22 kg, y entre los métodos con controles no hay diferencia material: cinco controles elegidos a mano ya recuperan el valor (3.20), y PDS y el LASSO ingenuo seleccionan el mismo número de variables y dan prácticamente la misma cifra. Que los cuatro métodos con controles coincidan indica que el resultado es estable frente a la elección del conjunto de controles; no valida la no confusión condicional, que ninguno de ellos puede comprobar.

La figura 16.1 muestra una meseta: la estimación PDS se mantiene entre 3.15 y 3.25 kg a lo largo de tres órdenes de magnitud de λ, hasta las cercanías del λ óptimo por validación cruzada, con intervalos prácticamente idénticos. En el rango explorado no hay señal del colapso hacia el estimador sin controles que predice la teoría para λ muy grande, porque la malla no

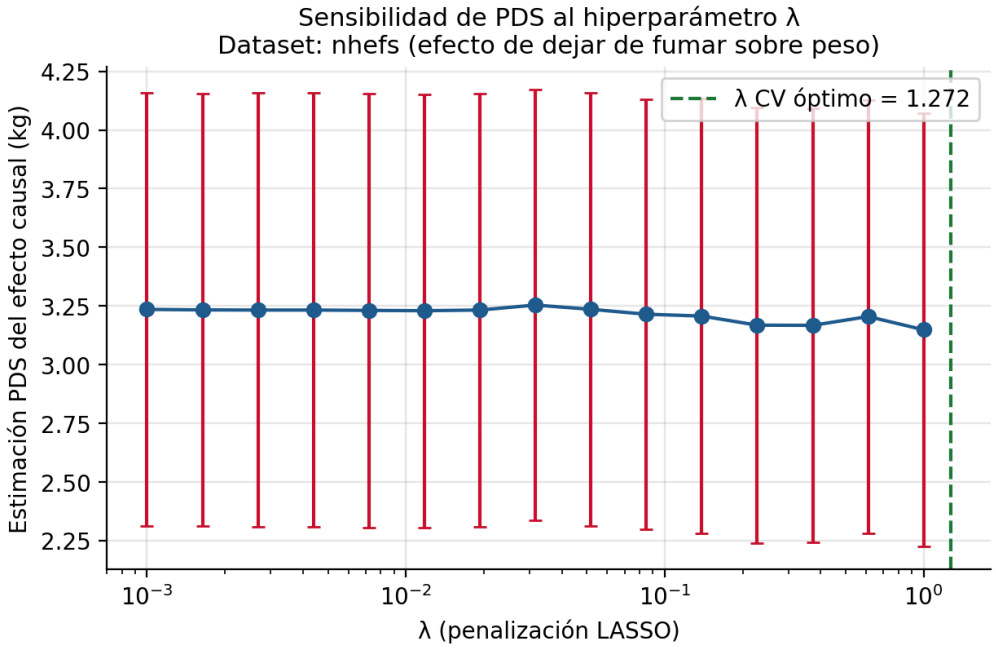


Figura 16.1: Sensibilidad de la estimación PDS al hiperparámetro λ de LASSO. Las barras indican IC al 95% (HC1). La línea verde punteada marca el λ óptimo por validación cruzada. Dataset: `nhefs`, $n = 1\,566$, $p = 51$ controles. Sin generador reproducible en esta edición.

llega más allá de $\lambda \approx 1$; para ver ese tramo habría que extenderla. Esta es la situación en la que reportar una sola cifra es defendible.

16.4.4 Sensibilidad al hiperparámetro lambda

```
import matplotlib.pyplot as plt
from sklearn.linear_model import Lasso

lasso_Y_cv = LassoCV(cv=5, max_iter=10000).fit(X, Y)
lambda_cv = lasso_Y_cv.alpha_

lambdas = np.logspace(
    -3,
    max(0, np.log10(lambda_cv * 1.5)),
    30
)
thetas = []
for lam in lambdas:
    lY = Lasso(alpha=lam, max_iter=10000).fit(X, Y)
    lD = Lasso(alpha=lam, max_iter=10000).fit(X, D)
    S = sorted(set(np.where(np.abs(lY.coef_) > 1e-8)[0]) |
               set(np.where(np.abs(lD.coef_) > 1e-8)[0]))
    if len(S) == 0:
        continue
```

```
    X_f = sm.add_constant(np.column_stack([D, X[:, S]]))
    ols = sm.OLS(Y, X_f).fit(cov_type="HC1")
    thetas.append((lam, ols.params[1], ols.bse[1]))

thetas = np.array(thetas)
plt.figure(figsize=(8, 5))
plt.errorbar(thetas[:, 0], thetas[:, 1], yerr=1.96*thetas[:, 2], fmt="o-")
if lambdas.min() <= lambda_cv <= lambdas.max():
    plt.axvline(lambda_cv, color="green", ls="--", label=r"$\lambda_{CV}$")
plt.xscale("log")
plt.xlabel("Lambda (penalizacion LASSO)")
plt.ylabel("Estimacion PDS del efecto causal")
plt.title("Sensibilidad de PDS a la eleccion de $\\lambda$")
plt.legend()
plt.tight_layout()
plt.savefig("figuras/pds_sensitivity.png", dpi=120, bbox_inches="tight")
plt.show()
```

Listado 16.3: Sensibilidad al hiperparametro lambda.

El listado salta los valores de λ para los que el conjunto seleccionado queda vacío (la instrucción `continue`), de modo que la curva que produce no llega al estimador sin controles aunque la malla lo permita; para trazar ese tramo hay que calcular el OLS sin controles en esos puntos.

16.5 Riesgos, límites y sensibilidad

La tabla 16.2 resume los principales riesgos al aplicar PDS, junto con sus consecuencias, diagnósticos y estrategias de mitigación.

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Confusión densa	Selección incompleta de confusoras relevantes y sesgo que no desaparece al crecer n	Simulación con un DGP de confusión densa, como el caso canónico	DML con un aprendiz que no dependa de la esparsidad, o PDS con una penalización menor, reportada como sensibilidad
λ inestable	Resultados frágiles que cambian con λ	Curva de $\hat{\theta}(\lambda)$: meseta frente a pendiente en el entorno del λ elegido	Reportar el rango completo y contrastar λ_{CV} con λ_{BCH} (Sección 16.2.4)

Riesgo	Consecuencia	Diagnóstico	Mitigación
Controles post-tratamiento	Sesgo por condicionar en variables afectadas por el tratamiento	Construir un DAG del problema y fechar cada covariable respecto del tratamiento	Excluir variables posteriores al tratamiento
Variables que solo predicen el tratamiento	Pérdida de eficiencia y, con confusión no observada, amplificación del sesgo	Comparar el ancho del intervalo con y sin las variables de S_D ausentes de S_Y	Revisar $S_D \setminus S_Y$ con criterio sustantivo; contrastar con el DAG (Capítulo 8)
Forma funcional lineal mal especificada	Sesgo si la confusión es no lineal y el diccionario no la recoge	Residuos de las dos ecuaciones frente a transformaciones de las covariables principales	Ampliar el diccionario con polinomios e interacciones, o usar DML

Tabla 16.2: Riesgos al aplicar PDS LASSO.

16.6 Ejercicios propuestos

16.6.1 Ejercicios teóricos

1. Con $Y = \theta D + \gamma X + \varepsilon$, $D = \beta X + v$ y $\mathrm{Var}(X) = 1$, muestre que omitir X en la regresión de Y sobre D da el límite $\theta + \gamma\beta/(\beta^2 + \sigma_v^2)$. Para $\beta = 2$, $\gamma = 0.5$ y $\sigma_v^2 = 1$, calcule el sesgo y explique por qué la selección simple puede omitir a X mientras que la doble selección no.
2. Muestre, con el teorema de Frisch-Waugh-Lovell, que el $\hat{\theta}$ del OLS final es la pendiente de regresar el residuo de Y sobre X_S contra el residuo de D sobre X_S, y relacione esa forma con el score ortogonal del Capítulo 10.
3. En el caso canónico de confusión densa, con m variables de coeficiente c en las dos ecuaciones y una varianza del error de D igual a 1, muestre que el sesgo de omitirlas todas es $mc^2/(mc^2 + 1)$ y compruebe el valor 0,5 del caso canónico. ¿Cuántas variables habría que incluir para reducir el sesgo a la mitad?
4. Explique por qué, bajo confusión no observada, incluir una variable que solo predice a D puede aumentar el sesgo de $\hat{\theta}$, y qué parte de S lo permitiría.
5. Con la penalización teórica y $n = 100$, $p = 200$, calcule el umbral λ de la Sección 16.2.4 para $\sigma = 1$, $c = 1.1$ y $\gamma = 0.1/\log(200)$, y exprésela en errores estándar de un coeficiente marginal ($\sigma/\sqrt{n}$). ¿Por qué es mucho más exigente que el 1,96 habitual?

16.6.2 Ejercicios computacionales

1. Replique el listado 16.1 sobre el dataset `close_college` (educación sobre salario, IV = `nearc4`). ¿Cambia el estimado IV al usar PDS para seleccionar controles?
2. Modifique el DGP del capítulo 6 para tener 20 confusoras y 80 variables irrelevantes. Compare PDS con selección simple en términos de cobertura.
3. Sobre el dataset `cps_mixtape`, estime el retorno a la educación con PDS y compare con DML.
4. Repita el caso canónico de confusión densa. Verifique que PDS con penalización teórica queda sesgado, que PDS con λ_{CV} y DML con ridge no, y estudie qué ocurre con DML cuando el aprendiz de los *nuisance* es un LASSO con penalización teórica.
5. Implemente la penalización teórica de Belloni et al. (2014) descrita en la Sección 16.2.4 y compare, sobre `nhefs`, el λ_{BCH} resultante con el λ_{CV} del listado 16.1. ¿Cuántas variables selecciona cada uno? ¿Cambia el efecto estimado o solo el tamaño del conjunto seleccionado?

16.7 Lecturas complementarias

Belloni et al. (2014) es el *paper* fundacional. Belloni et al. (2012) extiende la selección a instrumentos. Chernozhukov et al. (2018b) (capítulo 11) presenta el enfoque alternativo, y Chernozhukov et al. (2018a) ofrece un tratamiento pedagógico.

CAPÍTULO 17

Machine learning causal en datos de panel

Cuadro sinóptico del capítulo

Problema:	Estimar un efecto causal en panel con controles de alta dimensión, o con un instrumento
Estimando:	θ_0, efecto parcial en un modelo lineal parcial de panel con efectos fijos
Identificación:	Exogeneidad estricta condicional en efectos fijos y covariables; o exclusión y relevancia del instrumento
Método:	DML-panel (within, *cross-fitting* por unidad) y DML-PLIV
Nuisance:	g, m y r sobre las covariables y un resumen de la trayectoria de la unidad
Garantía:	$\sqrt{N}$-normalidad con N unidades y errores estándar por conglomerado
Condición clave:	Efecto constante; tasa de producto de los *nuisance*; instrumento fuerte
Librerías:	scikit-learn, DoubleML (opcional)
Validación:	Simulación con verdad conocida, *event study*, F de primera etapa e intervalo de Anderson-Rubin

Nota técnica

Con la doble selección (Capítulo 16) como primer diseño de identificación completo, este capítulo extiende el mismo espíritu, controlar con rigor la confusión en alta dimensión, a dos estructuras de datos que rompen el supuesto de observaciones independientes de Double Machine Learning (Capítulo 11): los datos de panel con efectos fijos y las variables

instrumentales. También advierte sobre el límite de todo el enfoque cuando la adopción del tratamiento es escalonada.

17.1 Problema causal, estimando e identificación

Una consultora evalúa el efecto de una reforma laboral sobre el empleo formal en 32 regiones observadas durante 10 años. La reforma se adoptó en distintas regiones en distintos años, lo que produce un panel con *adopción escalonada* (*staggered adoption*). La pregunta de política es cuál es el efecto de la reforma sobre el empleo formal.

Los métodos clásicos (efectos fijos, diferencias en diferencias, control sintético) funcionan bien con pocos controles y relaciones lineales. Si hay muchas características regionales (sectoriales, demográficas, macroeconómicas) que afectan a la vez la adopción y el empleo, y su efecto no es lineal, los efectos fijos lineales pueden no bastar. Chernozhukov et al. (2018b) extienden Double Machine Learning a paneles combinando la transformación *within* con *cross-fitting* por unidad.

El capítulo desarrolla tres cosas. Primero, DML para paneles: la transformación *within* que elimina los efectos fijos, el *cross-fitting* por unidad que preserva la inferencia válida y la salvedad que impone una función de controles no lineal. Segundo, la extensión a instrumentos, con el diagnóstico de instrumentos débiles que la acompaña. Tercero, el límite del enfoque: con adopción escalonada y efectos heterogéneos, la transformación *within* es un estimador de efectos fijos bidireccionales y hereda sus problemas, que ningún *learner* flexible corrige.

17.2 Teoría, supuestos y garantías

17.2.1 Modelo de panel con efectos fijos

Sea un panel balanceado con N unidades observadas durante T periodos y $n = NT$ observaciones. El modelo es

$$Y_{it} = \theta_0 D_{it} + g_0(X_{it}) + \alpha_i + \delta_t + \varepsilon_{it}, \tag{17.1}$$

donde α_i es el efecto fijo de la unidad, δ_t el del periodo, g_0 una función desconocida de las covariables que varían en el tiempo y ε_{it} el error. El parámetro causal es θ_0. La transformación *within* bidireccional elimina ambos efectos fijos:

$$\tilde{Y}_{it} = Y_{it} - \overline{Y}_{i\cdot} - \overline{Y}_{\cdot t} + \overline{Y}_{\cdot\cdot}, \tag{17.2}$$

donde $\overline{Y}_{i\cdot}$ es el promedio temporal de la unidad i, $\overline{Y}_{\cdot t}$ el promedio transversal del periodo t y $\overline{Y}_{\cdot\cdot}$ la gran media. Aplicada a la (17.1) y a D resulta

$$\tilde{Y}_{it} = \theta_0 \tilde{D}_{it} + \tilde{g}_{it} + \tilde{\varepsilon}_{it}, \quad \tilde{g}_{it} = g_0(X_{it}) - \overline{g}_{i\cdot} - \overline{g}_{\cdot t} + \overline{g}_{\cdot\cdot}, \tag{17.3}$$

con $\overline{g}_{i\cdot} = T^{-1} \sum_t g_0(X_{it})$ y los demás promedios definidos de la misma manera.

Esta forma requiere una advertencia que el tratamiento habitual omite. Si g_0 es lineal, $\tilde{g}_{it} = \beta' \tilde{X}_{it}$ y basta con transformar también las covariables. Si g_0 no es lineal, la transformación *within* **no conmuta** con g_0: el término $\tilde{g}_{it}$ depende de toda la trayectoria de covariables de la unidad (a través de $\overline{g}_{i\cdot}$), no solo de $\tilde{X}_{it}$. Por eso los *learners* deben recibir como atributos X_{it}, un resumen de la trayectoria de la unidad (por ejemplo, su media $\overline{X}_{i\cdot}$, como en los modelos de efectos aleatorios correlacionados de Mundlak) y el periodo t. La aproximación es buena cuando $\overline{g}_{i\cdot}$ se parece a una función de esos resúmenes; el segundo caso canónico mide qué tan buena es.

17.2.2 Supuestos

Supuesto 17.1 ***(Exogeneidad estricta)***

$E[\varepsilon_{it} \mid D_{i1}, ..., D_{iT}, X_{i1}, ..., X_{iT}, \alpha_i] = 0$ para todo i, t.

Es la versión de panel de la no confusión condicional: una vez que se controla por los efectos fijos de unidad y periodo y por las covariables observadas, la asignación del tratamiento es tan buena como aleatoria. Excluye la retroalimentación del resultado pasado hacia el tratamiento futuro, lo que descarta efectos dinámicos del tipo $Y_{i,t-1} \to D_{it}$.

Supuesto 17.2 ***(Efecto constante)***

El efecto causal del tratamiento es constante: θ_0 no varía entre unidades ni periodos.

Este supuesto es necesario para la formulación lineal parcial, y el resto del capítulo muestra que es más exigente de lo que parece cuando la adopción es escalonada.

Supuesto 17.3 ***(Condición de producto)***

Los *nuisance* estimados cumplen $\sqrt{n} a_n^2 \to 0$, donde a_n es el máximo de los errores en L^2 de $\hat{g}$ y $\hat{m}$.

Es la condición de producto del Capítulo 10: el error de los *nuisance* debe converger más rápido que $n^{-1/4}$ para que el sesgo de regularización sea de segundo orden.

17.2.3 DML para panel

Con las variables transformadas, el modelo es lineal parcial y se aplica el score ortogonal de Neyman,

$$\psi(W, \theta, \eta) = \big(\tilde{D} - m(F)\big)\big(\tilde{Y} - \ell(F) - \theta\big(\tilde{D} - m(F)\big)\big), \quad \eta = (\ell, m), \tag{17.4}$$

donde $F_{it} = \big(X_{it}, \overline{X}_{i\cdot}, t\big)$ son los atributos descritos arriba, $\ell(F) = E\big[\tilde{Y} \mid F\big]$ y $m(F) = E\big[\tilde{D} \mid F\big]$. La ortogonalidad hace que el error de $\hat{g}$ y de $\hat{m}$ no contamine la estimación de θ_0 en primer orden, y el *cross-fitting* se hace por unidad, no por observación, porque las observaciones de una misma unidad están correlacionadas.

El error estándar suma el score dentro de cada unidad antes de elevarlo al cuadrado, y eso captura la correlación intra-unidad que un error estándar *i.i.d.* ignora.

Algoritmo

Entrada: Panel $\{(Y_{it}, D_{it}, X_{it})\}$, K *folds*, *learners* para ℓ y m.
Salida: $\hat{\theta}$ y error estándar por conglomerado.
Calcular $\tilde{Y}$ y $\tilde{D}$ con la (17.2) y los atributos $F_{it} = \left(X_{it}, \overline{X}_{i\cdot}, t\right)$.
Dividir las N unidades en K *folds* (*cross-fitting* por conglomerado).
for k = 1 **to** K **do**

Ajustar $\hat{\ell}^{-k}$ y $\hat{m}^{-k}$ con las unidades fuera del *fold* k.
Para las unidades del *fold* k: $\hat{u}_{it} = \tilde{Y}_{it} - \hat{\ell}^{-k}(F_{it})$ y $\hat{v}_{it} = \tilde{D}_{it} - \hat{m}^{-k}(F_{it})$.

end for
$\hat{\theta} = \left(\sum_{i,t} \hat{v}_{it}\hat{u}_{it}\right) / \left(\sum_{i,t} \hat{v}_{it}^2\right)$.
$\hat{\psi}_{it} = \hat{v}_{it}\left(\hat{u}_{it} - \hat{\theta}\hat{v}_{it}\right)$, $\hat{J} = n^{-1}\sum_{i,t} \hat{v}_{it}^2$.
$\hat{\mathrm{se}}\left(\hat{\theta}\right) = \sqrt{\sum_i \left(\sum_t \hat{\psi}_{it}\right)^2} / \left(n\,|\hat{J}|\right)$.
return $\hat{\theta}$, $\hat{\mathrm{se}}\left(\hat{\theta}\right)$.

Algoritmo 12. DML-panel con transformación within

17.2.4 Garantías

Bajo los supuestos anteriores y con $N \to \infty$ y T fijo, $\sqrt{N}\left(\hat{\theta} - \theta_0\right)$ converge a una normal, con una varianza que el error estándar por conglomerado estima de forma consistente. La transformación *within* elimina α_i y δ_t sin estimarlos, lo que sería inviable con ML y paneles largos. Esas garantías valen para el modelo con efecto constante; la advertencia sobre $\tilde{g}$ del apartado anterior es una condición adicional, no un detalle: el error de aproximar la trayectoria de la unidad con un resumen entra como error de *nuisance*, y debe converger a la tasa que pide el supuesto de producto.

17.2.5 Variables instrumentales: DML-PLIV

Si D es endógeno y se dispone de un instrumento Z, el modelo es

$$Y = \theta_0 D + g_0(X) + \varepsilon, \quad E[\varepsilon \mid X, Z] = 0, \tag{17.5}$$

con los tres *nuisance* $\ell(X) = E[Y \mid X]$, $m(X) = E[D \mid X]$ y $r(X) = E[Z \mid X]$, de modo que $g_0(X) = \ell(X) - \theta_0 m(X)$. El score ortogonal de (Chernozhukov et al. 2018b) es

$$\psi(W, \theta, \eta) = (Z - r(X))(Y - g(X) - \theta D), \quad \hat{\theta} = \frac{\sum_i (Z_i - \hat{r}(X_i))\left(Y_i - \hat{\ell}(X_i)\right)}{\sum_i (Z_i - \hat{r}(X_i))(D_i - \hat{m}(X_i))}. \tag{17.6}$$

Teorema 17.4 ***(DML-PLIV)***

Bajo exclusión $E[\varepsilon \mid X, Z] = 0$, relevancia $E[(D - m(X))(Z - r(X))] \neq 0$ y tasas de producto para $\hat{\ell}, \hat{m}, \hat{r}$ con *cross-fitting*, el estimador $\hat{\theta}$ es $\sqrt{n}$-consistente y asintóticamente normal, con varianza $E[\psi^2]/J^2$ y $J = E[(D - m(X))(Z - r(X))]$.

La relevancia no es un supuesto binario. El teorema pide $J \neq 0$, pero la aproximación normal que lo respalda se degrada de forma continua a medida que J se acerca a cero. Con un instrumento débil el estimador IV tiene un sesgo hacia el de OLS, su distribución deja de

ser aproximadamente normal y los intervalos convencionales sub-cubren; el problema es de la aproximación asintótica misma, no del tamaño de muestra. El diagnóstico habitual es el estadístico F de la primera etapa sobre los instrumentos excluidos, con la regla práctica $F > 10$. Stock y Yogo (2005) tabulan valores críticos más precisos según el criterio que se adopte; por ejemplo, con un instrumento y un regresor endógeno, para que el test de Wald del 5 % no tenga un tamaño real superior al 10 % se necesita un F de alrededor de 16. Reportar el F es obligatorio en cualquier diseño IV del libro, y el Capítulo 30 lo convierte en una métrica de monitoreo continuo, porque la fuerza de un instrumento puede erosionarse con el tiempo sin que ninguna otra señal lo advierta.

El complemento del diagnóstico es la **inferencia robusta a instrumentos débiles**. El intervalo de **Anderson-Rubin** invierte tests: es el conjunto de valores θ_0 para los que no se rechaza $H_0 : \theta = \theta_0$, y tiene la cobertura nominal cualquiera sea la fuerza del instrumento, a costa de poder ser un conjunto no acotado cuando la identificación es débil. Con muchos instrumentos, estadísticos robustos como el de Kleibergen y Paap y los valores críticos de Stock y Yogo (Stock et al. (2002); Andrews et al. (2019)) reemplazan al F de un solo instrumento; con instrumentos generados por ML, Belloni et al. (2012) tratan la selección óptima con LASSO, y el F calculado sobre residuos ortogonalizados con ML no es el F de una primera etapa lineal, de modo que no hereda las tablas de Stock y Yogo y conviene reportar ambos.

Regla operativa del libro: si $F \leq 10$, el reporte de un diseño IV incluye el intervalo de Anderson-Rubin junto con el de Wald; si difieren de forma material, la estimación se declara sensible a la fuerza del instrumento y el Capítulo 30 la monitorea con doble umbral.

17.2.6 Adopción escalonada: el límite de la transformación within

Cuando distintas unidades reciben el tratamiento en distintos periodos, el estimador de efectos fijos bidireccionales (TWFE) no estima el efecto promedio sobre los tratados, sino un promedio ponderado de comparaciones 2×2. Goodman-Bacon (2021) lo descompone de forma exacta y muestra que incluye comparaciones «prohibidas»: unidades recién tratadas contra unidades **ya tratadas antes**, que actúan como controles pese a estar bajo tratamiento. Chaisemartin y D'Haultfœuille (2020) demuestran que, con efectos heterogéneos en el tiempo, algunos de esos pesos son **negativos**: el coeficiente TWFE puede tener signo opuesto al efecto verdadero aunque el efecto sea positivo para todas las unidades y periodos. No es un problema de precisión que más datos resuelvan, sino de que el estimando implícito no es el que se quiere.

La transformación *within* de la Sección 17.2.1 es TWFE, y por tanto **hereda el problema completo** si la adopción es escalonada y los efectos heterogéneos. El supuesto de efecto constante no es una simplificación menor: sostiene la validez del procedimiento. Flexibilizar los *nuisance* con ML no repara un estimando mal definido, y ninguna cantidad de *gradient boosting* en $\hat{g}$ y $\hat{m}$ corrige un peso negativo.

Intuición

Caja de profundización: diferencias en diferencias moderno

Objetivo. Saber qué hacer cuando la adopción es escalonada.

Estimadores robustos.

- ***Event study*:** graficar el efecto en cada periodo alrededor del tratamiento. Permite ver tendencias previas y la dinámica posterior. Es el punto de partida obligatorio.
- **Callaway y Sant'Anna (2021):** estimar $\text{ATT}(g,t)$ para cada cohorte de adopción g y periodo t usando solo controles nunca tratados o aún no tratados, y agregar con pesos explícitos y declarados.
- **Sun y Abraham (2021):** corrección análoga para especificaciones de *event study*, con interacciones cohorte por periodo.
- **Borusyak et al. (2024):** imputación: se estima el contrafactual con las observaciones no tratadas y se imputa; es eficiente bajo errores homocedásticos y sin anticipación.

Recomendación. Comenzar siempre con un *event study*. Con adopción escalonada, no usar TWFE (ni DML-panel sobre datos transformados) sin verificar antes la descomposición de Goodman-Bacon; si hay pesos negativos materiales, cambiar de estimador antes de preocuparse por la flexibilidad de los controles.

17.3 Casos canónicos y validación

Las cifras de los tres casos provienen de simulaciones con semilla declarada. El script es `herramientas/verificaciones/verif_cap17.py`.

Caso canónico · Adopción escalonada con efecto creciente

Tres grupos de 20 unidades observados durante 12 periodos: tratados desde el periodo 4, tratados desde el 7 y nunca tratados. El efecto es 0.5 × (periodos de exposición), de modo que crece con el tiempo en tratamiento; el promedio verdadero sobre las celdas tratadas es 2,200. Con 200 repeticiones:

Estimador	Media	Desv. típica
Verdad (promedio sobre celdas tratadas)	2,200	no aplica
TWFE (*within* bidireccional)	1,455	0,146
Imputación (efectos fijos con celdas no tratadas)	2,200	0,154

TWFE subestima el efecto en 0,745, un 34 %, porque usa al grupo tratado desde el periodo 4 como control del grupo tratado desde el 7, cuando el primero ya está en plena dinámica de efecto. El estimador de imputación recupera el valor verdadero. Con esta forma de efecto, la transformación *within* de este capítulo comete el mismo error que TWFE.

Caso canónico · Un panel con controles no lineales

200 unidades, 8 periodos, una covariable $X_{it} = \xi_i + 0.7\nu_{it}$ cuya media por unidad se asocia con el efecto fijo, $g_0(X) = 2\sin X + 0.5X^2$ y asignación $P(D=1) = \text{sigm}(1.5\sin X + 0.5\xi_i)$, con efecto verdadero $\theta_0 = 1$. Con 30 repeticiones:

Estimador	Media	Desv. típica	Sesgo
TWFE con X lineal	1,325	0,115	0,325
DML sin transformación *within*	1,170	0,080	0,170
DML-panel (*within* y atributos de trayectoria)	1,027	0,065	0,027

El DML-panel reduce el sesgo de 0,325 a 0,027, y el intervalo del 95 % con error estándar por unidad cubre en 0,97 de las repeticiones (con 30 repeticiones la cifra tiene un margen de error de varios puntos y no se distingue de 0,95). Prescindir de la transformación *within* es peor que aplicarla (sesgo de 0,170), porque los efectos fijos confunden. El sesgo residual de 0,027 puede atribuirse en parte a que el resumen de trayectoria (la media de X de la unidad) no reproduce exactamente la media de $g_0(X)$, como anticipa la advertencia sobre $\tilde{g}$.

Caso canónico · Un instrumento débil

$Y = D + \varepsilon$, $D = \pi Z + v$, con correlación 0,8 entre ε y v (confusión fuerte), $n = 200$ y 400 repeticiones. Se compara el intervalo de Wald con el de Anderson-Rubin sobre la rejilla $[-6, 8]$:

π	F medio	Mediana de $\hat{\theta}$	Cobertura Wald	Cobertura AR	AR no acotado
0,05	1,4	1,48	0,87	0,95	0,92
0,10	2,9	1,09	0,89	0,95	0,77
0,30	18,9	0,99	0,93	0,95	0,05
1,00	201,4	1,00	0,93	0,95	0,00

El intervalo de Anderson-Rubin tiene la cobertura nominal en los cuatro casos, a costa de ser no acotado en 92 % y 77 % de las muestras cuando el instrumento es muy débil. El intervalo de Wald sub-cubre (0,87 y 0,89) y es siempre acotado, es decir, parece informativo cuando no lo es: un intervalo de Wald angosto con F cercano a 1 es una señal de alarma, no de precisión.

17.4 Implementación en Python

Los dos listados son manuales y no dependen de la versión de ninguna biblioteca de DML; usan `numpy` y `scikit-learn`. La implementación de referencia en Python, con *cross-fitting* por conglomerado y varias extensiones, es `DoubleML` (Bach et al. 2022), y para el DiD con adopción escalonada están los paquetes `did` (Callaway y Sant'Anna) y `fixest` (Sun y Abraham), ambos de R.

```
import numpy as np
from sklearn.ensemble import RandomForestRegressor
from sklearn.model_selection import GroupKFold


def doble_dem(v, N, T):
    """Y_it - Y_i. - Y_.t + Y_.. para un panel balanceado ordenado por unidad y
luego por tiempo."""
    M = v.reshape(N, T)
    return (M - M.mean(1, keepdims=True) - M.mean(0, keepdims=True) +
M.mean()).ravel()


def dml_panel(Y, D, X, unidad, t, N, T, K=5, seed=0):
    """Devuelve theta y el error estándar por unidad. X es un vector (n,) con
una covariable."""
    Yt, Dt = doble_dem(Y, N, T), doble_dem(D, N, T)
    # Atributos: X_it, media de X de la unidad (trayectoria) y periodo.
    Xbar = np.array([X[unidad == i].mean() for i in range(N)])[unidad]
    F = np.column_stack([X, Xbar, t])
    u, v = np.zeros(len(Y)), np.zeros(len(Y))
    for tr, te in GroupKFold(K).split(F, groups=unidad):
        g = RandomForestRegressor(100, min_samples_leaf=10, random_state=seed,
n_jobs=-1).fit(F[tr], Yt[tr])
        m = RandomForestRegressor(100, min_samples_leaf=10, random_state=seed,
n_jobs=-1).fit(F[tr], Dt[tr])
        u[te], v[te] = Yt[te] - g.predict(F[te]), Dt[te] - m.predict(F[te])
    theta = (v * u).sum() / (v * v).sum()
    psi = v * (u - theta * v)
    J = (v * v).mean()
    por_unidad = np.array([psi[unidad == i].sum() for i in range(N)])
    se = np.sqrt((por_unidad ** 2).sum()) / (len(Y) * abs(J))
    return theta, se


if __name__ == "__main__":
    # Prueba de coherencia con un proceso lineal sencillo: el efecto verdadero
es 1.
    rng = np.random.default_rng(0)
```

```
    N, T = 100, 6
    unidad = np.repeat(np.arange(N), T); t = np.tile(np.arange(T), N)
    X = rng.standard_normal(N * T)
    D = (X + rng.standard_normal(N * T) > 0).astype(float)
    Y = D + X + rng.standard_normal(N)[unidad] + 0.2 * t +
rng.standard_normal(N * T)
    theta, se = dml_panel(Y, D, X, unidad, t, N, T)
    print(f"theta = {theta:.3f} (se {se:.3f}); verdadero = 1.0")
    assert abs(theta - 1.0) < 0.5
```

Listado 17.1: DML-panel manual: transformación *within*, atributos de trayectoria y *cross-fitting* por unidad.

El divisor del error estándar usa $\hat{J} = n^{-1}\sum \hat{v}^2$, que coincide con el denominador de $\hat{\theta}$; si se cambia el estimador, el error estándar debe recalcularse con el score correspondiente.

```
import numpy as np
from sklearn.ensemble import GradientBoostingRegressor
from sklearn.model_selection import KFold


def dml_pliv(Y, D, Z, X, K=5, seed=0):
    """theta = sum (Z - r)(Y - l) / sum (Z - r)(D - m), con l, m, r ajustados
fuera del fold."""
    n = len(Y)
    ry, rd, rz = np.zeros(n), np.zeros(n), np.zeros(n)
    for tr, te in KFold(K, shuffle=True, random_state=seed).split(X):
        for objetivo, res in ((Y, ry), (D, rd), (Z, rz)):
            mod = GradientBoostingRegressor(n_estimators=200,
random_state=seed).fit(X[tr], objetivo[tr])
            res[te] = objetivo[te] - mod.predict(X[te])
    theta = (rz * ry).sum() / (rz * rd).sum()
    psi = rz * (ry - theta * rd)
    J = (rz * rd).mean()
    se = psi.std(ddof=1) / (abs(J) * np.sqrt(n))
    # F de primera etapa sobre residuos ortogonalizados (no es el F lineal de
Stock y Yogo)
    b = (rz * rd).sum() / (rz * rz).sum()
    F = b ** 2 * (rz * rz).sum() / (((rd - b * rz) ** 2).sum() / (n - 1))
    return theta, se, F
```

Listado 17.2: DML-PLIV manual con *cross-fitting* y diagnóstico del F de primera etapa.

Sobre el conjunto `close_college`, los controles son `black`, `smsa`, `south` y `married` no se incluye `exper` porque es función de la escolaridad (Capítulo 4). Un intervalo de Anderson-Rubin se obtiene con la rejilla de valores de θ y el estadístico de la Sección 17.2.5.

17.5 Riesgos, límites y sensibilidad

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
No transformar *within*	Sesgo por α_i no observado (caso 2)	Comparar DML con y sin la transformación	Aplicarla siempre, o incluir efectos fijos explícitos
Transformar solo X con g no lineal	Error de aproximación en $\tilde{g}$ que no desaparece	Comparar el sesgo con y sin resumen de trayectoria en los atributos	Atributos $\left(X_{it}, \overline{X}_{i\cdot}, t\right)$ o un modelo de efectos aleatorios correlacionados
Cross-fitting por observación en lugar de por unidad	Errores estándar subestimados	Verificar que los *folds* agrupan unidades	Validación cruzada agrupada por unidad
Adopción escalonada con efectos heterogéneos	Estimando mal definido: pesos negativos; el coeficiente puede tener signo opuesto (caso 1)	*Event study* con adelantos y rezagos; descomposición de Goodman-Bacon	Cambiar de estimador, no de *learner*: Callaway y Sant'Anna, Sun y Abraham, Borusyak et al.
Instrumento débil	Sesgo hacia OLS, distribución no normal, intervalos que sub-cubren (caso 3)	F de primera etapa; compararlo con el umbral de Stock y Yogo	Reportar el F; intervalo de Anderson-Rubin junto con el de Wald si $F \leq 10$
Varianza *i.i.d.* con correlación intra-unidad	Inferencia inválida por errores estándar subestimados	Comparar el error estándar por unidad con el *i.i.d.*	Sumar el score por unidad antes de elevarlo al cuadrado

Tabla 17.1: Riesgos comunes en DML con panel e instrumentos.

Límites. Las garantías del capítulo valen con efecto constante, exogeneidad estricta y N grande con T fijo. La exogeneidad estricta excluye la retroalimentación del resultado hacia el tratamiento; con efectos dinámicos hay que modelarlos de manera explícita. Y con instrumentos, la exclusión no se puede contrastar con los datos: la relevancia sí.

17.6 Ejercicios propuestos

17.6.1 Ejercicios teóricos

1. Demuestre que la transformación *within* bidireccional de la (17.2) elimina α_i y δ_t en un panel balanceado. ¿Qué falla si el panel no es balanceado?
2. Muestre que, si g_0 es lineal, $\tilde{g}_{it} = \beta' \tilde{X}_{it}$, y que si $g_0(x) = x^2$ el término $\tilde{g}_{it}$ depende de la varianza temporal de $X_{i\cdot}$, no solo de $\tilde{X}_{it}$.
3. Verifique que el score (17.6) es ortogonal respecto de (ℓ, m, r) bajo $E[\varepsilon \mid X, Z] = 0$.

4. Con dos cohortes A (tratada en $t = 2$) y B (tratada en $t = 4$) y un efecto que crece con la exposición, calcule los pesos del TWFE sobre las comparaciones 2×2 y encuentre una configuración donde alguno sea negativo.
5. Para el tercer caso canónico, aproxime la esperanza de F para $\pi = 0.05$ y $n = 200$ (con Z y v normales estándar, F es del orden de $1 + n\pi^2$) y explique por qué un intervalo de Wald angosto con F cercano a 1 no es informativo.

17.6.2 Ejercicios computacionales

1. Reemplace `RandomForestRegressor` por `GradientBoostingRegressor` en el listado 17.1 y compare el sesgo y la cobertura sobre el proceso del segundo caso canónico.
2. Construya un panel con tendencias previas no paralelas y muestre que el DML-panel produce un estimado sesgado.
3. Aplique el listado 17.2 a un proceso con un instrumento débil y verifique que el F calculado alerta antes de que el intervalo de Wald sea engañoso.
4. Sobre un panel con adopción escalonada, estime el efecto con TWFE y con un estimador de imputación, y compare con el efecto verdadero (primer caso canónico).

17.7 Lecturas complementarias

Chernozhukov et al. (2018b) cubre DML-PLIV. Sobre instrumentos débiles, Stock y Yogo (2005) es la referencia de los valores críticos y Belloni et al. (2012) la del caso con muchos instrumentos seleccionados por LASSO.

La literatura de DiD con adopción escalonada es donde más ha cambiado el estado del arte en los últimos años, y conviene leerla en orden: Goodman-Bacon (2021) descompone el estimador TWFE y muestra de dónde vienen las comparaciones problemáticas; Chaisemartin y D'Haultfœuille (2020) establecen el resultado de pesos negativos que vuelve inservible al TWFE bajo heterogeneidad; y las tres propuestas correctivas principales son Callaway y Sant'Anna (2021) (agregación explícita de $\mathrm{ATT}(g, t)$), Sun y Abraham (2021) (*event study* con interacciones cohorte por periodo) y Borusyak et al. (2024) (imputación del contrafactual). Para el diagnóstico de tendencias previas en diseños de *event study*, véase (Freyaldenhoven et al. 2019). El Capítulo 28 retoma esta familia de problemas desde el control sintético y la *matrix completion*.

CAPÍTULO 18

Diseño de investigación y selección de método

Cuadro sinóptico del capítulo

Problema:	Elegir el diseño causal apropiado según las características del problema
Estimando:	ATE, ATT, CATE, LATE, valor de una política
Identificación:	No confusión, validez de instrumentos, continuidad local, tendencias paralelas, combinación convexa
Método:	Mapa de decisión basado en el estimando, el diseño y los supuestos
Nuisance:	Dimensión (p frente a n), heterogeneidad, endogeneidad, estructura temporal
Garantía:	Identificación bajo los supuestos propios de cada diseño; orden por credibilidad típica del supuesto
Librerías:	DoubleML, econml, causalml, statsmodels
Validación:	Placebos, sensibilidad a supuestos, diseño preregistrado

Nota técnica

Este capítulo cierra la Parte III sintetizando los tres diseños de identificación completos del libro (la doble selección del Capítulo 16, el DML de panel e instrumental del Capítulo 17 y el DML no estructurado de la Parte II, Capítulo 11) en un único mapa de decisión, y anticipa los diseños de heterogeneidad y *targeting* de la Parte V.

18.1 Motivación aplicada

Un analista del Banco Central recibe un encargo: estimar el efecto causal de una política monetaria sobre la inflación. Dispone de datos mensuales de diez años y de 30 covariables

macroeconómicas, y la política se implementó en distintos momentos en distintos países. ¿Qué método usar? ¿DML? ¿Diferencias en diferencias? ¿Control sintético? ¿Bosques causales? ¿Alguno de ellos?

La elección metodológica es la decisión más importante de la inferencia causal aplicada. Un método inadecuado produce estimaciones sesgadas y conclusiones equivocadas por muy sofisticada que sea su implementación. Este capítulo no presenta métodos nuevos: organiza los ya vistos en un *mapa de decisión* que conecta las características del problema (estimando, diseño, dimensión, heterogeneidad, instrumentos) con el método apropiado, y declara con franqueza qué parte de la decisión el mapa no puede tomar.

18.2 Problema causal, estimando e identificación

18.2.1 Dimensiones del problema causal

Todo problema causal aplicado puede caracterizarse en seis dimensiones que determinan la identificabilidad del efecto y el método apropiado:

1. **Dimensión de los controles p frente al tamaño muestral n.** Si $p \ll n$ y las relaciones son aproximadamente lineales, OLS clásico basta. Si p es comparable a n o mayor, se requieren métodos de alta dimensión (doble selección, DML).
2. **Heterogeneidad del efecto.** Si el efecto se asume constante, el modelo lineal parcial es suficiente. Si hay heterogeneidad estructurada, se requieren el modelo interactivo, los meta-learners o los bosques causales.
3. **Endogeneidad del tratamiento.** Si se asume no confusión, aplican los métodos de selección sobre observables (*matching*, IPW, DML). Si hay endogeneidad por variables no observadas, se requieren instrumentos o diseños cuasi-experimentales (discontinuidad en la regresión, diferencias en diferencias).
4. **Estructura temporal.** Corte transversal, panel, serie temporal o adopción escalonada determinan la elección entre métodos.
5. **Disponibilidad de instrumentos.** Con un instrumento válido, IV o DML-PLIV. Sin él, hay que justificar la no confusión o usar métodos de sensibilidad.
6. **Objetivo de la estimación.** ATE, ATT, CATE, valor de una política o LATE son estimandos distintos y requieren métodos distintos.

18.2.2 Estimando e identificación

El estimando define qué cantidad poblacional se quiere aprender. Los más frecuentes son:

- **ATE** $= E[Y(1) - Y(0)]$: efecto promedio en toda la población. Identificable bajo no confusión y soporte común.
- **ATT** $= E[Y(1) - Y(0) \mid D = 1]$: efecto en los tratados. Solo requiere no confusión para el resultado sin tratamiento, $Y(0) \perp\!\!\!\perp D \mid X$.
- **CATE** $= E[Y(1) - Y(0) \mid X = x]$: efecto condicional en covariables. Requiere no confusión dentro de cada subgrupo.

- **LATE** $= E[Y(1) - Y(0) \mid \text{cumplidores}]$: efecto local en los cumplidores. Identificable con un instrumento relevante, con exclusión y monotonía.
- **Valor de una política** $= E[Y(\pi(X))]$: valor de una regla de asignación. Se estima con aprendizaje de políticas (Capítulo 21).

La identificación, esto es, expresar el estimando como función de la distribución observada, depende de supuestos propios de cada diseño. La Tabla 18.2 resume el supuesto clave de cada uno y qué tan creíble suele ser.

18.3 Teoría, supuestos y garantías

18.3.1 Mapa de decisión metodológica

La Tabla 18.1 organiza el mapa según diseño, dimensión y heterogeneidad, y empareja cada combinación con el método clásico y su contraparte de ML.

Diseño	Dimensión	Heterog.	Método clásico	Método ML
Corte transversal	$p \ll n$	No	OLS	No hace falta
Corte transversal	$p \sim n$	No	Doble selección	DML con modelo lineal parcial
Corte transversal	$p \ll n$	Sí	Subgrupos ad hoc	Meta-learners, bosque causal
Corte transversal	$p \sim n$	Sí	Sin equivalente simple	DML interactivo, bosque causal
IV	$p \ll n$	No	2SLS	No hace falta
IV	$p \sim n$	No	Doble selección con IV	DML-PLIV
Discontinuidad	No aplica	No	Polinomio local	Con ML solo para covariables
Diferencias en diferencias	No aplica	No	TWFE con un solo momento de adopción	Sin ML necesario
Panel con adopción escalonada	No aplica	No	Callaway y Sant'Anna, Sun y Abraham, DiD sintético (nunca TWFE)	Matrix completion
Panel con X_{it}	$p \sim n$	No	Efectos fijos con controles	DML de panel
Optimización de políticas	No aplica	Sí	Sin equivalente	Aprendizaje de políticas, uplift

Tabla 18.1: Mapa de decisión metodológica.

18.3.2 Identificación jerárquica de diseños

Los diseños no tienen la misma *fuerza de identificación*. La Tabla 18.2 los ordena por la credibilidad típica del supuesto clave que los sostiene. El orden es una regla general y no una ley: un instrumento con una exclusión dudosa puede ser menos creíble que un diseño de diferencias en diferencias con tendencias previas que se ven paralelas.

Diseño	**Credibilidad típica**	**Supuesto clave y su contrastabilidad**
Experimento aleatorizado	Alta	Aleatorización. Se verifica con el balance de covariables y el cumplimiento
Discontinuidad en la regresión	Alta	Continuidad de los resultados potenciales en el umbral. Se contrasta con densidad y covariables alrededor del corte
Variables instrumentales	Media a alta	Relevancia (se contrasta) y exclusión (no se contrasta)
Diferencias en diferencias	Media	Tendencias paralelas sin tratamiento. Se contrasta solo en los periodos previos
Control sintético	Media	Combinación convexa de unidades no tratadas que reproduzca el contrafactual
No confusión (selección sobre observables)	Media a baja	Ausencia de confusores no observados. No se contrasta; solo se analiza su sensibilidad

Tabla 18.2: Identificación jerárquica de diseños causales (credibilidad típica del supuesto clave).

Un diseño de mayor credibilidad requiere supuestos más creíbles y produce, por tanto, estimaciones más robustas. Al elegir, conviene priorizar el diseño de mayor credibilidad que sea factible con los datos disponibles.

18.3.3 Un procedimiento de decisión en el orden correcto

El mapa se usa en un orden que importa: primero el estimando y el diseño, después la dimensión y la heterogeneidad, y al final el estimador.

18.3.4 Criterios adicionales de selección

Más allá del mapa y la jerarquía, tres criterios refinan la elección.

Calidad de los controles. Si los controles son ruidosos o están mal medidos, los métodos de ML, que los usan de forma intensiva, pueden empeorar la estimación. En ese caso son preferibles los diseños que dependen menos de X (diferencias en diferencias, discontinuidad).

Tamaño muestral. La heterogeneidad se estima con mucho menos precisión que el efecto promedio. Con unos pocos cientos de observaciones, los métodos más parsimoniosos (OLS, *matching*, meta-learners simples) suelen ser preferibles a los bosques causales o a las redes

Algoritmo

Entrada: Pregunta causal, estimando deseado, descripción de cómo se asignó el tratamiento y de los datos disponibles.
Salida: Diseño de identificación, estimador y plan de validación.
Fijar el estimando (ATE, ATT, CATE, LATE, valor de una política) y la población a la que se aplicará.
if hubo aleatorización o una regla de asignación conocida con umbral **then** usar el diseño experimental o de discontinuidad.
else if hay un instrumento defendible (relevante y con exclusión argumentada) **then** usar IV o DML-PLIV y reportar el F y el intervalo de Anderson-Rubin.
else if hay variación temporal o entre unidades con unidades tratadas y no tratadas **then** usar diferencias en diferencias o control sintético, con adopción escalonada tratada con estimadores robustos.
else asumir no confusión y justificarla con el diagrama causal; elegir el estimador por p frente a n y por la heterogeneidad (tabla del mapa).
Preregistrar el diseño y el estimador antes de ver los resultados.
Plan de validación: placebos, sensibilidad a los supuestos clave, comparación con un diseño de menor credibilidad.
return Diseño, estimador, plan de validación y supuestos por declarar.

Algoritmo 13. Selección de diseño y método

profundas, cuya ventaja aparece con más datos. No hay un umbral universal, y la simulación con efecto conocido (Capítulo 5) es la forma de saber cuánto es «suficiente» en un caso concreto.

Costo computacional y de mantenimiento. Un método más complejo se paga también en operación: más tiempo de cómputo, más piezas que monitorear y más difícil de explicar. Esa carga debe compararse con la ganancia de credibilidad o de precisión.

Intuición

Caja de profundización: discontinuidad en la regresión y transportabilidad

Objetivo. Completar el mapa con dos temas adicionales.

Discontinuidad en la regresión. Cuando el tratamiento se asigna según un umbral c de una variable continua (por ejemplo, una beca para quienes obtienen más de 70 puntos), se compara a quienes quedaron justo arriba con quienes quedaron justo abajo. Es un experimento local alrededor del corte:

$$\tau_{\mathrm{RD}} = \lim_{x \to c^{+}} E[Y \mid X = x] - \lim_{x \to c^{-}} E[Y \mid X = x]. \tag{18.1}$$

Si el umbral no se cumple de manera perfecta (algunos de abajo reciben el tratamiento y algunos de arriba no), el diseño es *difuso* y se convierte en un diseño de variables instrumentales con el umbral como instrumento. El efecto es local en el corte y no se extrapola a otros puntos.

Transportabilidad. Si un modelo se entrena con una población (Santiago), ¿sirve para otra (Temuco)? Dos situaciones son distintas: un *cambio en la distribución de covariables*, con el mismo mecanismo causal, que se puede corregir reponderando; y un *cambio de mecanismo*, donde la relación entre X, D e Y es otra, que ninguna reponderación corrige. Los diagramas de selección ayudan a decidir cuál es el caso (Capítulo 26).

18.4 Casos resueltos

Cuatro casos recorren el procedimiento. En ninguno la decisión es automática: cada uno termina con la lista de supuestos que el analista debe declarar.

Caso 1: retorno a la educación con proximidad a la universidad como instrumento. Escolaridad sobre salario, n de unos pocos miles y pocos controles, con un instrumento candidato (vivir cerca de una universidad). Hay un instrumento relevante, el diseño es de corte transversal y no hay heterogeneidad que sea el objetivo: IV con 2SLS y controles pretratamiento, sin usar como control la experiencia potencial (que es función de la escolaridad, Capítulo 4). DML-PLIV solo si hubiera muchos controles o relaciones no lineales. Se declara la exclusión (la cercanía a una universidad no afecta el salario salvo por la escolaridad) y se reporta el F de primera etapa y la sensibilidad a esa exclusión.

Caso 2: política monetaria con adopción escalonada entre países. Datos mensuales de diez años, 30 covariables, política adoptada en momentos distintos por pocos países. Hay variación temporal y entre unidades, adopción escalonada y pocas unidades tratadas: estimadores robustos a la adopción escalonada o control sintético (Capítulo 17, Capítulo 28), nunca TWFE, con un *event study* como primer paso. La no confusión no se asume: se asume tendencias paralelas condicionales, que se contrasta en los periodos previos.

Caso 3: beca con tratamiento aleatorizado y heterogeneidad. Experimento con $n = 20 \sim 000$ y 50 covariables. La identificación está resuelta por el diseño. La decisión es sobre la estimación de la heterogeneidad: con muestra grande, un bosque causal o un DML interactivo (Capítulo 13), validado con curvas Qini y calibración (Capítulo 14), y luego aprendizaje de políticas si hay restricción presupuestaria (Capítulo 21).

Caso 4: reforma tributaria con datos observacionales. Panel de firmas, 100 covariables, $n = 800$, sin aleatorización ni instrumento. Se asume no confusión condicional, la más débil de las identificaciones. Con p del orden de n, se usa la doble selección o DML con modelo lineal parcial (Capítulo 16, Capítulo 11), y la conclusión se acompaña de un análisis de sensibilidad a confusores no observados y de un placebo.

18.4.1 Validación de la elección metodológica

Para cada caso, la elección debe validarse con:

- **Placebo del tratamiento:** asignar un tratamiento falso y verificar que el estimador no encuentra efecto.
- **Sensibilidad a supuestos:** variar el método dentro del mismo diseño (distintos K de *cross-fitting*, distintos *learners*) y verificar la estabilidad.
- **Comparación con diseños más débiles:** si es posible, estimar con un diseño de menor credibilidad y documentar la diferencia.

18.5 Implementación en Python

La función siguiente codifica un primer descarte con umbrales ilustrativos. Es una ayuda para ordenar la conversación y no reemplaza al análisis de identificación; los umbrales ($p > 0.5n$, $n < 1 \sim 000$) no tienen una justificación teórica y deben ajustarse al contexto.

```
def choose_method(n, p, has_iv, is_panel, has_heterogeneity,
treatment_staggered=False):
    """Devuelve el método recomendado según las características del problema.

    ADVERTENCIA: es una heurística de primer descarte, no un sustituto del
análisis
    de identificación. Presupone que la pregunta causal, el estimando y el
grafo ya
    están definidos. Los umbrales son ilustrativos.
    """
    if is_panel and treatment_staggered:
        # Estimadores robustos a la adopción escalonada; nunca TWFE (pesos
negativos).
        return ("Callaway-Sant'Anna / Sun-Abraham; DiD sintético "
                "o matrix completion si hay pocas unidades tratadas")
    if is_panel:
        return "DML-panel con transformación within" if p > 0.5 * n else
"Efectos fijos con controles"
    if has_iv:
        return "DML-PLIV" if p > 0.3 * n else "2SLS clásico"
    if has_heterogeneity:
        return "Meta-learners (T o X)" if n < 1000 else "Bosque causal"
    if p > 0.3 * n:
        return "DML con modelo lineal parcial"
    return "Doble selección con LASSO" if p > 50 else "OLS con controles (HC1)"


if __name__ == "__main__":
    # Pruebas de coherencia con los casos del texto.
    assert "DML-PLIV" in choose_method(2000, 800, True, False, False)
    assert "Callaway" in choose_method(200, 10, False, True, False,
treatment_staggered=True)
    assert choose_method(3000, 15, True, False, False) == "2SLS clásico"
    assert choose_method(500, 80, False, False, True) == "Meta-learners (T o
X)"
```

Listado 18.1: Función de decisión metodológica (heurística de primer descarte).

18.6 Errores comunes y límites

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Usar ML cuando los métodos clásicos bastan	Complejidad innecesaria, pérdida de interpretabilidad, más piezas que mantener	$p \ll n$ y linealidad razonable	OLS con errores robustos
Usar DML sin justificar la no confusión	Estimaciones sesgadas por una endogeneidad no resuelta	Posibles confusores no observados	IV, discontinuidad, diferencias en diferencias o control sintético; análisis de sensibilidad
Cambiar de método según los resultados (*specification mining*)	Sesgo de selección; inferencia inválida	Elección metodológica posterior a ver los datos	Preregistrar el diseño; elegir el método antes de estimar
Tomar la jerarquía de credibilidad como ley	Preferir un diseño de «alta» credibilidad con un supuesto indefendible en el caso concreto	Argumentar los supuestos del caso, no del tipo de diseño	Declarar la exclusión, la continuidad o las tendencias paralelas con evidencia del contexto

Tabla 18.3: Riesgos comunes en la elección metodológica.

Límites. El mapa es orientativo. Los casos límite (panel con adopción escalonada y heterogeneidad, IV con muchos instrumentos débiles, discontinuidad con covariables de alta dimensión) requieren un análisis experto que el mapa no reemplaza.

Hay además un límite de fondo que conviene explicitar, porque la existencia de una función de selección invita a olvidarlo. El mapa organiza la elección del **estimador** dando por resuelta la de la **identificación**, que es la parte difícil del problema. Las seis dimensiones de la Sección 18.2 son observables en los datos: n, p, si hay panel, si hay un instrumento candidato. Las condiciones que determinan la validez del resultado no lo son: si las covariables observadas cierran las rutas de puerta trasera, si el instrumento satisface la exclusión, si las tendencias habrían sido paralelas. Ningún argumento del mapa captura eso, y ninguna heurística puede. La jerarquía de la Tabla 18.2 ordena los diseños por la credibilidad típica de esos supuestos precisamente porque es lo que el mapa no puede decidir. Elegir DML en lugar de OLS mejora la flexibilidad de la estimación, pero un diseño de mayor credibilidad, cuando los datos lo permiten, mejora algo que ninguna cantidad de flexibilidad compensa.

18.7 Ejercicios propuestos

1. Recomiende un método y declare los supuestos que debe argumentar en cada uno de los cinco problemas: (a) efecto de un experimento aleatorizado sobre el rendimiento escolar ($n = 5 \sim 000$, $p = 10$); (b) efecto de una reforma tributaria sobre la inversión ($n = 800$, $p = 100$); (c) efecto de un programa social sobre la pobreza con adopción escalonada en

un panel; (d) efecto de un medicamento sobre la presión arterial con un instrumento; (e) efecto heterogéneo de becas sobre la deserción ($n = 20 \sim 000$, $p = 50$).

2. Justifique por qué DML no es adecuado cuando hay confusión no observada. ¿Qué alternativas existen y qué supuestos nuevos exigen?
3. Discuta en qué casos el bosque causal es preferible al R-learner y viceversa.
4. Construya un ejemplo en el que un instrumento con exclusión dudosa sea menos creíble que un diseño de diferencias en diferencias con tendencias previas paralelas, y explique qué evidencia cambiaría el orden.
5. Ejecute las pruebas de coherencia del listado 18.1 y agregue dos casos propios donde la heurística recomiende un método que usted no usaría, explicando por qué.

18.8 Lecturas complementarias

Athey y Imbens (2019) ofrece una revisión moderna de los métodos. Imbens y Rubin (2015) es la referencia canónica para los métodos clásicos. Chernozhukov et al. (2018a) es la referencia para DML. Athey (2017) aporta una perspectiva de política.

PARTE IV

Registro y operación local en producción

Esta parte lleva el estimador desplegado en la Parte II hasta un servicio documentado y operado con responsabilidad: *model cards* causales que declaran los supuestos de identificación y viajan con el modelo, y una compuerta de registro con pruebas estadísticas, no solo de software, antes de aceptar cualquier actualización.

CAPÍTULO 19

Model cards causales y registro local de artefactos

Cuadro de decisión del capítulo

Decisión:	Documentar supuestos de identificación en la *model card*, no solo métricas de desempeño
Alternativas:	*Model card* estándar (solo *accuracy*/desempeño) vs. *model card* causal extendida
Trade-off clave:	Fricción de documentar más campos vs. riesgo de uso indebido del modelo por otros equipos
Stack:	Python, `json`, `joblib`, repositorio local
Riesgo principal:	Que un consumidor del modelo lo use fuera de su población o supuestos de validez sin saberlo

Implementación en el monorepo del curso (2026)

Plantilla de *model card* causal del curso: `04_notebooks_produccion_streamlit/B2_hub_cicd/model_card/MODEL_CARD.md` (alineada al Apéndice G). Lab `L17`. Bundle local: directorio `artifacts/registered_model/`. La card debe declarar estimando (ATE), supuestos, población del monorepo (`ihdp_medium`) y límites (datos sintéticos de benchmark; no uso clínico).

19.1 El problema de diseño

El Capítulo 15 sirvió el estimador DML como un endpoint que cualquiera puede consultar. Pero «poder consultarlo» no es lo mismo que «poder usarlo correctamente». Una *model card*, la práctica ya estándar en la comunidad de ML de documentar un modelo junto con sus métricas, datos de entrenamiento y limitaciones (Mitchell et al. 2019), resuelve ese problema

para modelos predictivos. El problema de diseño de este capítulo es que la *model card* estándar no tiene ningún campo para lo que más importa en un modelo **causal**: bajo qué supuestos de identificación es válido, para qué población se estimó el efecto, y qué covariables se controlaron. Registrar un estimador causal sin una *model card* específica es, en la práctica, invitar a que se use fuera de su dominio de validez.

19.2 Opciones y trade-offs

Opciones y trade-offs

- ***Model card* estándar.** Documenta arquitectura, métricas de desempeño (*accuracy*, F1, RMSE) y, en el mejor de los casos, algunas consideraciones éticas generales. Para un modelo causal, es **insuficiente**: no hay campo para el DAG supuesto, ni para el conjunto de covariables de puerta trasera, ni para la población sobre la que el efecto es válido.
- ***Model card* causal extendida.** Añade explícitamente los campos que un modelo predictivo no necesita: estimando ($\tau(x)$, ATE, LATE), supuestos de identificación declarados, diseño (observacional/cuasi-experimental/experimental), población de entrenamiento y límites de validez externa. El costo es puramente de fricción, la de completar más campos antes de publicar; no hay costo técnico ni de infraestructura.

La decisión no es realmente una disyuntiva difícil, porque la *model card* extendida domina a la estándar para cualquier modelo causal, pero vale la pena presentarla como **trade-off**: completar los campos causales añade fricción mínima y evita usos fuera del dominio de validez.

19.3 Decisión de referencia para el curso

Todo modelo causal registrado siguiendo este capítulo usa la plantilla de **model card causal** del Apéndice G, con los siguientes campos obligatorios: estimando, diseño de identificación, supuestos declarados y clasificados (con referencia al DAG cuando exista uno), roles causales, población de entrenamiento (con las variables que la delimitan y la regla de soporte), y una sección explícita de «no usar este modelo para». La ficha existe en dos formas con el mismo contenido: un documento para personas y un archivo legible por máquina, que es el que consume el servicio del Capítulo 15.

Los supuestos de una ficha no son todos del mismo tipo, y tratarlos igual es el error más frecuente. Algunos se pueden mirar en los datos: el soporte común, el balance, la fuerza de un instrumento, la estabilidad del efecto. Para esos la ficha guarda un umbral calibrado y la última verificación, y el monitoreo del Capítulo 30 los vuelve a mirar. Otros no se pueden verificar con ningún dato: la no confusión condicional, la exclusión de un instrumento, las tendencias paralelas posteriores al tratamiento. Para esos la ficha no puede guardar una verificación, que no existe. Guarda cuánto tendría que fallar el supuesto para cambiar la decisión, hasta

cuándo vale ese cálculo y qué eventos obligan a revisarlo (Capítulo 33). Una ficha que escribe «verificado» junto a un supuesto no observable afirma algo que nadie comprobó.

19.4 El contrato de la ficha

Como el servicio del Capítulo 15 lee la ficha para decidir cuándo abstenerse, la ficha deja de ser documentación y pasa a ser una interfaz. Se rige por su propio contrato.

Contrato C-05 · Ficha causal del modelo

Entrada	Los roles causales (Capítulo 4), los datos de entrenamiento, el estimando, el diseño de identificación, los supuestos declarados con su clase, las métricas y los resultados de validación.
Salida	Un documento para personas y un archivo legible por máquina con el mismo contenido, que valida contra el esquema versionado del Apéndice G. El archivo incluye la regla de soporte y la versión del modelo con la huella de los datos con que se entrenó. Cada supuesto observable lleva su umbral (con la tasa de falsas alarmas y la fecha de calibración) y su última verificación; cada supuesto no observable lleva su sensibilidad (método, umbral de la decisión, valor crítico, fecha de cálculo y fecha de revisión).
Invariantes	(1) La ficha viaja con el artefacto y no se actualiza por separado. (2) Cada reentrenamiento produce una ficha nueva con versión y huella de datos nuevas. (3) El soporte y la huella los calcula el proceso de registro a partir de los datos, no una persona. (4) El veredicto de cada supuesto observable lo calcula el proceso de registro con el valor y el umbral, y una ficha con un observable que no pasó no se registra. (5) Un supuesto no observable nunca figura como verificado: lleva su sensibilidad, y esta se calcula de los datos y del estimador registrados, no la escribe una persona. (6) La ficha guarda la verificación vigente al registrar; las posteriores viven en el reporte del monitoreo, que cita la versión de la ficha.
Modos de fallo	Una ficha que no valida no se registra. Una ficha cuya huella no coincide con los datos de referencia bloquea el registro. Un supuesto no observable al que se le escribe a mano una verificación, o una sensibilidad que nadie recalculó tras cambiar los datos: el contrato lo detecta solo en lo que el esquema y la huella alcanzan, y por eso el Capítulo 33 agrega su propio contrato. Un modelo registrado sin ficha, o con una ficha de otra versión, es el fallo que el contrato existe para impedir.

Prueba de aceptación (a) La ficha valida contra el esquema. (b) La huella coincide con la del conjunto de datos de referencia versionado. (c) El servicio del Capítulo 15 carga la ficha y se abstiene fuera del soporte que ella declara. (d) Una ficha con un supuesto observable sin umbral o con un veredicto que no sale de su valor, y una con un supuesto no observable sin sensibilidad, se rechazan.

19.5 Implementación de referencia

El documento para personas sigue una plantilla en Markdown. Los valores numéricos del ejemplo son ilustrativos: no provienen de una corrida.

```
---
license: mit
tags: [causal-inference, dml, econml]
---

# Estimador DML de retorno a la educacion

## Estimando
ATE del efecto de anios de educacion (`educ`) sobre el logaritmo del salario
(`wage`).

## Diseno de identificacion
Observacional. Ver DAG en `docs/dag.png`.

## Supuestos declarados
### Observables
- Soporte comun: ESS/n >= 0.6 (falsas alarmas 5%, calibrado el 2026-01-10).
  Ultima verificacion 2026-01-15: 0.82 (paso).
### No observables
- No confusion condicional en: age, black, south, married.
  Sensibilidad: robustez R2 respecto del umbral de decision 0.05.
  Valor critico 0.13. Calculada el 2026-01-15; revisar antes del 2026-04-15.

## Poblacion de entrenamiento
Hombres, 24-34 anios, encuesta NLS 1976 (Card, 1995). n=3,003.
**No valido fuera de este rango etario ni fuera de EE.UU.**

## Metricas
ATE estimado: 0.071 (IC 95%: [0.058, 0.084])
Cross-fitting: K=5. Learner: GradientBoostingRegressor.

## No usar este modelo para
- Poblaciones fuera del rango de entrenamiento (ver @cap-generalizacion-
```

```
transportabilidad).
- Decisiones individuales sin considerar el intervalo de confianza del CATE.
- Cualquier uso que reinterprete el ATE como un efecto garantizado a nivel
individual.
```

Listado 19.1: Plantilla mínima de *model card* causal en Markdown (valores ilustrativos).

El archivo legible por máquina se construye con una función. Calcula de los datos lo que el servicio hace cumplir, el soporte y la huella, para que nadie lo escriba a mano:

```
import copy
import hashlib
import json
import operator
from pathlib import Path

OPERADORES = {"<": operator.lt, "<=": operator.le, ">": operator.gt, ">=":
operator.ge}


def con_veredicto(supuesto):
    """Un supuesto observable recibe su `paso` calculado con el valor y el
umbral:
    no lo escribe una persona. Un no observable no tiene veredicto."""
    sup = copy.deepcopy(supuesto)
    if sup["clase"] == "observable":
        u, v = sup["umbral"], sup["ultima_verificacion"]
        v["paso"] = bool(OPERADORES[u["operador"]](v["valor"], u["valor"]))
    return sup


def construir_model_card(schema, df, ruta_datos, *, estimando, diseno,
supuestos,
                         metricas, validacion, no_usar_para, version,
                         descripcion, fuente=None):
    """Ficha causal legible por maquina. `schema` es el CausalSchema del Cap.
4;
    se guarda como datos (roles), no como objeto serializado."""
    X = schema.X(df)
    huella = hashlib.sha256(Path(ruta_datos).read_bytes()).hexdigest()
    poblacion = {"descripcion": descripcion,
                 "soporte": {"regla": "rango_por_covariable",
                             "rangos": {c: [float(X[c].min()),
float(X[c].max())]
                                        for c in schema.covariates}}}
    if fuente:
        poblacion["fuente"] = fuente
    return {
```

```
        "schema_version": "causal-model-card-v2",
        "estimando": estimando,
        "diseno_identificacion": diseno,
        "supuestos": [con_veredicto(s) for s in supuestos],
        "roles": {"tratamiento": schema.treatment, "resultado": schema.outcome,
                  "covariables": list(schema.covariates),
                  "instrumentos": list(schema.instruments)},
        "poblacion": poblacion,
        "metricas": metricas,
        "validacion": validacion,
        "no_usar_para": no_usar_para,
        "version": {"modelo": version, "hash_datos_entrenamiento": "sha256:" +
huella},
    }


def guardar_model_card(card, ruta="model/model_card.json"):
    with open(ruta, "w", encoding="utf-8") as f:
        json.dump(card, f, ensure_ascii=False, indent=2)
```

Listado 19.2: Construcción de `model_card.json` (esquema `causal-model-card-v2`, Ap. G.4). El soporte, la huella y el veredicto de los supuestos observables salen de los datos.

Con la ficha escrita, el registro local copia el paquete completo. La ficha en JSON es parte del paquete, porque es lo que lee el servicio:

```
from pathlib import Path
import shutil

origen = Path("model")
destino = Path("artifacts/registered_model")
destino.mkdir(parents=True, exist_ok=True)

for nombre in ("dml_estimator.joblib", "model_card.json", "MODEL_CARD.md"):
    shutil.copy2(origen / nombre, destino / nombre)
```

Listado 19.3: Registro local del modelo y su *model card*.

19.6 Aplicación al sistema causal del curso

La sección «No usar este modelo para» de la ficha cita directamente el capítulo de generalización y transportabilidad (Capítulo 26, más adelante en este volumen), que formaliza precisamente cuándo un efecto estimado en una población es válido en otra. Documentar la población de entrenamiento en la *model card* no es un ejercicio de transparencia general: es la información mínima que otro analista necesitaría para aplicar, correctamente, el criterio de transportabilidad de ese capítulo antes de reutilizar el modelo, y es también la regla con la que el servicio decide cuándo abstenerse. La clasificación de los supuestos hace lo mismo con

el monitoreo: lo que la ficha declara observable lo vigila el Capítulo 30 con el umbral que la ficha trae, y lo que declara no observable lo cubre la revisión del Capítulo 33.

19.7 Señales de alerta y checklist operativo

- ☐ La *model card* reporta métricas de desempeño pero no menciona el diseño de identificación ni los supuestos.
- ☐ No existe una sección explícita de «no usar para», dejando implícito el dominio de validez.
- ☐ El paquete registrado no incluye los roles causales (Capítulo 4) junto al modelo, obligando a cualquier consumidor a adivinar qué covariables espera. Guardarlos como datos en la ficha evita depender de un objeto serializado que solo se carga donde existe la misma clase.
- ☐ La *model card* no se actualizó tras reentrenar el modelo con datos nuevos (riesgo ya anticipado en el Capítulo 2).
- ☐ El paquete incluye solo el documento para personas, sin la ficha legible por máquina validada contra el esquema (Apéndice G).
- ☐ El soporte o la huella de los datos de la ficha se escribieron a mano y no los calculó el proceso de registro.
- ☐ Un supuesto no observable figura como «verificado», o su sensibilidad se escribió a mano o no se recalculó tras reentrenar o cambiar de población.
- ☐ Todos los supuestos de la ficha están en una sola lista sin clase, de modo que nadie sabe cuáles vigila el monitoreo y cuáles solo revisa una persona.

19.8 Ejercicios y notas bibliográficas

19.8.1 Ejercicios conceptuales

1. Compare la *model card* causal de este capítulo con una ficha estándar de un modelo predictivo. Liste tres campos presentes en la causal y ausentes en la estándar, y explique por qué cada uno importa específicamente para un modelo causal.
2. (Arnold et al. 2019) propone una idea relacionada pero distinta a las *model cards*: las FactSheets como «declaración de conformidad del proveedor». Investigue brevemente la diferencia de enfoque y discuta si sería más o menos apropiada que una *model card* para un estimador causal registrado por un equipo interno (no un proveedor externo).
3. Un consumidor recibe una ficha cuyo soporte declara `age` entre 24 y 34 y consulta con `age = 41`. ¿Qué debe hacer el servicio? Escriba en una frase por qué esa regla es más segura si la calcula el proceso de registro que si la escribe quien entrena el modelo.
4. Clasifique los supuestos de un estimador DML de efectos de un programa de capacitación (no confusión condicional, soporte común, estabilidad del efecto en el tiempo, estabilidad del mecanismo de asignación) en observables y no observables, y diga para cada uno qué campo de la ficha lo registra.

19.8.2 Ejercicio de infraestructura

1. Complete la primera mitad del Notebook de producción B2: adapte la plantilla del listado 19.1 al modelo de su Notebook A2, construya su `model_card.json` con el listado 19.2, registre el paquete local con el listado 19.3 y verifique que ambas fichas se encuentran junto al artefacto serializado.

19.8.3 Notas bibliográficas

Mitchell et al. (2019) introduce el formato de *model card* que este capítulo extiende. Gebru et al. (2021) propone la pieza complementaria y, para un sistema causal, igual de necesaria: las **datasheets for datasets**, que documentan cómo se recolectaron los datos, con qué propósito, quién los financió y qué preprocesamiento sufrieron. La documentación de datasets mediante **datasheets** ((Gebru et al. 2021), Gebru et al. 2021) es análoga a las Model Cards para modelos causales (Apéndice G) y debe incluir información sobre motivación, composición, proceso de recolección, preprocesamiento, usos recomendados y consideraciones éticas. La conexión con este libro es directa y vale la pena hacerla explícita: la mitad de los campos que una datasheet exige (cómo se seleccionaron las unidades, si hubo criterios de elegibilidad, qué instancias faltan) son exactamente la **ficha de procedencia del tratamiento** del Capítulo 7, y son la información sin la cual un consumidor externo no puede evaluar si el supuesto de identificación declarado en la *model card* es siquiera plausible. Una *model card* causal sin su datasheet documenta el modelo pero no lo que lo hace válido. Arnold et al. (2019) propone un tercer formato, orientado a proveedores de servicios de IA, con más énfasis en cumplimiento normativo. La discusión de documentación de interfaces de inferencia en general se retoma de (Kästner et al. 2024), Capítulo 10; su versión legible por máquina es la operación de metadatos del servicio del Capítulo 15.

CAPÍTULO 20

20 CI/CD para modelos causales

Cuadro de decisión del capítulo

Decisión:	El pipeline de CI debe correr pruebas de sanidad estadística, no solo pruebas de código
Alternativas:	CI genérico (solo tests de software) vs. CI con pruebas estadísticas causales integradas
Trade-off clave:	Tiempo de ejecución del pipeline vs. riesgo de publicar automáticamente un modelo roto
Stack:	`pytest`, `jsonschema`, scripts de CI local; Docker es opcional
Riesgo principal:	Que un cambio de código pase todos los tests de software y aun así rompa la validez causal

Implementación en el monorepo del curso (2026)

Script de referencia: `scripts/audit_repo.sh` (pytest Serie A, labs, humo B1–B4). Lab `L18`. Autograders: `grade_b1.py`…`grade_b4.py`. Simulaciones de este capítulo: `herramientas/verificaciones/verif_cap20.py` (opciones `–se` y `–sin-controles`). CI genérico de software **no basta**: el pipeline local exige humo de efecto/API/política.

20.1 El problema de diseño

El Capítulo 15 construyó el servicio; el Capítulo 19 registró el artefacto y su documentación localmente. Ninguno de los dos automatizó lo que ocurre **después**: cuando alguien modifica el código (agrega una covariable, cambia el *learner* de *nuisance*, actualiza los datos de entrenamiento), ¿qué garantiza que la nueva versión no rompió algo antes de que se publique automáticamente? Un pipeline de CI/CD genérico, el que prueba por ejemplo que el servicio responde con el código de estado correcto, no detecta absolutamente nada sobre si el efecto estimado sigue siendo razonable. El problema de diseño de este capítulo es que un sistema causal necesita, además de las pruebas de software estándar, pruebas que sean sensibles a **lo**

que este libro entiende por «romperse»: que un placebo deje de dar cero, que el intervalo de confianza colapse o se dispare, que el soporte común desaparezca con los nuevos datos.

20.2 Opciones y trade-offs

Opciones y trade-offs

- **CI genérico.** Corre únicamente pruebas de software: ¿el código importa sin error?, ¿el servicio responde?, ¿el paquete se construye? Es rápido (segundos a minutos), pero no detecta ningún problema de validez estadística: un cambio que introduce un mal control (Capítulo 8) pasa este CI sin ninguna advertencia.
- **CI con pruebas estadísticas integradas.** Además de las pruebas de software, ejecuta la prueba placebo y el chequeo de balance ya usados en capítulos anteriores (Capítulo 7, Capítulo 14) como parte del pipeline automatizado, con umbrales que, si se violan, bloquean el registro local del artefacto. Es más lento (minutos, porque implica reentrenar o reestimar sobre datos de prueba) y requiere mantener un dataset de referencia fijo para que las pruebas sean reproducibles, pero es la única opción que previene que una regresión estadística llegue a producción sin supervisión humana.

20.3 Decisión de referencia para el curso

El pipeline de referencia de este capítulo corre en dos etapas: una etapa rápida de pruebas de software y una etapa de pruebas estadísticas (validación de la ficha, placebo repetido, estabilidad del efecto y balance, todas sobre un conjunto de referencia fijo), ambas ejecutadas automáticamente antes de registrar una actualización. Esta separación evita que cada cambio menor de código dispare un reentrenamiento costoso, sin sacrificar la garantía de que nada se registra sin pasar la prueba de sanidad estadística.

Frontera · 2026

En 2026 el ecosistema local de herramientas abiertas cubre bien cuatro tareas: registrar experimentos y versionar los artefactos del modelo, versionar los conjuntos de datos, validar el esquema y los rangos de los datos de entrada, y vigilar la deriva de las variables. Ninguna de esas herramientas sabe qué es un placebo, un chequeo de balance o un intervalo de confianza sobre un efecto: sus pruebas se detienen en la integridad de los datos y en la estabilidad de las métricas predictivas. El contrato de la sección siguiente describe por eso la etapa estadística y deja lo demás a lo que ofrezca el entorno. Si una herramienta nueva cubriera también esa etapa, el contrato seguiría siendo el mismo.

La implementación de este capítulo usa `pytest` y scripts locales por una razón puramente práctica: son herramientas abiertas y de baja fricción para un equipo sin infraestructura previa.

Conviene situarla dentro del ecosistema local: **MLflow** para registrar experimentos y versionar artefactos de modelo; **DVC** en modo local para versionar el dataset de referencia; **Great Expectations** o **Pandera** para validar el esquema y los rangos de los datos de entrada; y **Evidently** para el monitoreo de *drift* que el Capítulo 30 desarrolla. Lo que estas herramientas aportan es todo lo que no es la etapa estadística, y no conviene reimplementarlo.

Tres criterios de diseño de esa etapa merecen ser explícitos, porque determinan si el pipeline es útil o solo ruidoso. Primero, **el dataset de referencia debe estar congelado y versionado**: una prueba estadística sobre datos que cambian no distingue una regresión del código de un cambio en los datos. Segundo, **los umbrales deben fijarse antes y documentarse**, no ajustarse cuando la prueba falla: la tentación de relajar el umbral para desbloquear un *merge* es exactamente el fallo que el pipeline existe para prevenir. Tercero, **un fallo estadístico no debe tratarse como un fallo de software**: el bloqueo correcto no es «arreglar el código hasta que pase» sino «un humano decide si el cambio en el efecto es legítimo»; un cambio genuino en el mundo también rompe un umbral, y esa es información valiosa, no un error.

20.4 El contrato de la compuerta de registro

Lo que este capítulo fija no es un conjunto de herramientas sino una compuerta: el punto único por el que un candidato pasa a ser la versión registrada. Cualquier sistema de integración continua la implementa si cumple el contrato siguiente, que usa el formato del C-04 (Sección 15.4).

Contrato C-06 · Compuerta de registro

Operaciones	*verificar*: recibe un candidato y devuelve una decisión (*registra* o *bloquea*) con el informe de cada prueba. *registrar*: copia el artefacto del candidato al registro local, y solo acepta un candidato cuya decisión *registra* exista.
Entrada	El candidato (el estimador entrenado y su ficha causal, contrato C-05 del Capítulo 19). El conjunto de referencia, congelado y con su huella. Los umbrales de cada prueba, escritos y versionados antes de la corrida.
Salida	La decisión y un informe que, para cada prueba, dice qué midió, qué valor obtuvo, qué umbral tenía y si pasó. Un bloqueo estadístico queda marcado como pendiente de decisión humana.
Invariantes	(1) Nada llega al registro sin una decisión *registra* del mismo candidato. (2) La etapa estadística solo corre si la de software pasó. (3) El conjunto de referencia y los umbrales se fijan antes de la corrida; cambiarlos es un cambio propio, que se revisa aparte del candidato que lo motivó. (4) Con el mismo candidato, los mismos datos y las mismas semillas, la decisión es idéntica. (5) Cada prueba declara qué clase de fallo cubre y cuál no. (6)

	Un bloqueo estadístico lo levanta una persona, con la justificación escrita, y nunca se levanta editando la prueba.
Modos de fallo	Datos de referencia que cambian en silencio: la prueba deja de distinguir una regresión del código de un cambio en los datos. Un umbral relajado para destrabar un cambio: el pipeline pasa a verificar lo que el equipo quiere y no lo que necesita. Un placebo único: se rechaza de vez en cuando aunque todo esté bien y bloquea por mala suerte. Cobertura aparente: hay pruebas, pero ninguna mira el fallo que ocurrió. Una ficha inválida: las pruebas posteriores no tienen sentido, y la etapa se detiene.
Prueba de aceptación	Se inyectan fallos de causa conocida sobre un caso con verdad conocida (el caso canónico de más abajo) y se comprueba la decisión. (a) El candidato sano se registra, con una tasa de falsos bloqueos que no supera la calculada. (b) Quitar un control clave bloquea, y lo bloquea la prueba de estabilidad, no el placebo. (c) Un error estándar declarado a la mitad del real bloquea en casi todas las corridas. (d) Una ficha cuya huella no coincide con la de los datos de referencia bloquea sin llegar a la etapa estadística. (e) *registrar* sin decisión *registra* es imposible.

Cada decisión del contrato responde a un fallo concreto.

Hay un solo camino hacia el registro. La compuerta no recomienda: decide, y la operación de registro rechaza al candidato que no tenga su decisión. Un control que depende de que alguien lo recuerde falla justo el día de más prisa, que es cuando más hace falta.

El informe dice qué se midió, no solo si pasó. La persona que recibe un bloqueo tiene que decidir si el cambio de efecto es legítimo, y para eso necesita el valor, el umbral y la prueba. Un «falló» sin números invita a relajar el umbral hasta que pase.

Un bloqueo no apaga nada. La compuerta decide si un candidato llega a ser la versión vigente. Mientras una persona lo revisa, la versión vigente sigue respondiendo, que en el vocabulario del Capítulo 2 es la acción *continuar* (Sección 2.5).

20.4.1 Qué mira cada prueba

Cada prueba de la etapa estadística mira una clase de fallo, y ninguna las mira todas. Saber cuál ve cada una evita la falsa tranquilidad de un pipeline con muchas pruebas que no miran el fallo que ocurre.

Prueba	Detecta	No ve
Validación de la ficha	Una ficha incompleta o mal formada, un supuesto observable cuyo veredicto no sale de su valor y su umbral o que no lo supera, un supuesto no observable sin sensibilidad, datos distintos de los de referencia.	Que lo que la ficha afirma sea cierto.
Placebo repetido	Un intervalo que no cubre lo que declara cuando el efecto es nulo, por ejemplo por un error estándar subestimado.	Un control omitido: el tratamiento permutado no depende de nada.
Estabilidad del efecto	Un control omitido, un cambio de especificación o de datos que mueva el efecto respecto del registrado.	Un error estándar mal calculado si el efecto puntual no se mueve.
Balance y soporte	Que los datos nuevos no tengan el solape que exige la identificación (Capítulo 7).	Una confusión no observada.

El placebo permuta el tratamiento, así que este queda independiente de todas las covariables por construcción. Por eso no puede notar que falta un control: la omisión de una confusora solo sesga cuando el tratamiento depende de ella, y el tratamiento permutado no depende de nada. Lo que el placebo sí detecta es que el intervalo no tenga la cobertura que declara cuando el efecto es nulo. Para el control omitido hace falta otra prueba, que reestime el efecto real y lo compare con el valor registrado en la *model card*, con una tolerancia fijada antes de correrla. Y como un placebo aislado se rechaza una de cada veinte veces aunque todo esté bien, la prueba repite la permutación y tolera un número de rechazos que se calcula de antemano.

20.4.2 Los umbrales se calibran con la tasa medida

Si en cada permutación el placebo rechaza con probabilidad p_0 cuando el modelo está sano, y se repiten R permutaciones con una tolerancia de k rechazos, un modelo sano se bloquea con probabilidad $P(X > k)$, donde X sigue una binomial con parámetros R y p_0. El cálculo supone rechazos independientes, y las permutaciones comparten los mismos datos, de modo que es una aproximación. El valor de p_0 no es el nominal, y el caso canónico siguiente muestra por qué.

Caso canónico · Lo que el placebo no ve

Se simulan $n = 1\,500$ unidades con cuatro covariables: $X_1 \sim N(0,1)$ y tres binarias, $X_2 \sim \text{Bernoulli}(0.3)$, $X_3 \sim \text{Bernoulli}(0.4)$ y $X_4 \sim \text{Bernoulli}(0.6)$. El tratamiento es continuo, $D = 12 + X_1 + 0.8X_4 + \nu$ con $\nu \sim N(0, 1.5^2)$, y el resultado es $Y = 0.08D + 0.20X_1 + 0.15X_4 - 0.10X_2 + \varepsilon$ con $\varepsilon \sim N(0, 0.4^2)$. El efecto verdadero es 0,08. X_1 y X_4 confunden tratamiento y resultado, X_2 solo afecta al resultado y X_3 no afecta a nada.

Con los cuatro controles, el estimador recupera el efecto: entre 0,068 y 0,090 según la semilla de los datos (verdad 0,08), con un error estándar de alrededor de 0,007. El placebo, con 200 permutaciones del tratamiento y semilla fija, rechaza el 11 % de las veces y no el 5 % nominal. La causa se ve en las cifras: el estimador declara un error estándar medio de 0,0057 sobre las permutaciones, pero su estimación varía con una desviación estándar de 0,0068, de modo que el error declarado es un 16 % menor que el real.

Quitar controles no mueve el placebo. Sin la experiencia ni el estado civil (las dos confusoras), rechaza el 6,0 %; sin la experiencia, el 5,5 %; sin el estado civil, el 11 %. Ninguna cifra supera la del modelo completo. El efecto reestimado sí se mueve, y mucho. Medido en errores estándar del modelo completo, quitar las dos confusoras lo desplaza entre 8,9 y 9,8 errores estándar a lo largo de cinco semillas; quitar solo la experiencia, entre 8,4 y 9,0; quitar solo el estado civil, que confunde menos, entre 1,5 y 2,3. Una tolerancia de un error estándar detecta los tres casos, y una de tres errores estándar deja pasar el último.

La tabla traduce las tasas de rechazo en la probabilidad de que la compuerta bloquee. Las dos últimas filas simulan un error estándar declarado a dos tercios y a la mitad del real, con las mismas permutaciones.

Situación	Rechazo del placebo	Bloqueo con 10 permutaciones y tolerancia 2	Bloqueo con 20 permutaciones y tolerancia 5
Modelo sano, tasa nominal	5,0 %	1,2 %	0,03 %
Modelo sano, tasa medida	11,0 %	8,8 %	1,8 %
Error estándar a 2/3 del real	28,5 %	58 %	52 %
Error estándar a 1/2 del real	43,5 %	88 %	93 %

Dos conclusiones. La primera es que la tolerancia se calcula con la tasa medida del modelo sano y no con la nominal. Con 10 permutaciones y tolerancia 2, que sería correcta si la tasa fuera del 5 %, el modelo sano de esta simulación se bloquearía el 8,8 % de las veces; con 20 permutaciones y tolerancia 5 baja al 1,8 %. La segunda es que el placebo es una prueba tosca contra el error estándar subestimado. Detecta con alta probabilidad una subestimación a la mitad (93 %), pero solo la mitad de las veces una subestimación a dos tercios (52 %), y las menores las deja pasar. Para esas hace falta otra evidencia, como la cobertura sobre datos con verdad conocida que pide el contrato C-04.

La regla de partida es medir p_0 con 200 permutaciones o más sobre el conjunto de referencia, elegir R y k de modo que $P(X > k)$ no supere el 2 %, y guardar p_0, R y k junto a la huella de los datos. Cuando el conjunto de referencia cambia, hay que medir p_0 de nuevo. La prueba de estabilidad sigue la misma lógica con otra unidad: su tolerancia se expresa en errores estándar del intervalo registrado, porque eso distingue un cambio de especificación del ruido. Con el código, los datos y las semillas congelados, reestimar da el mismo efecto y el desplazamiento es cero, de modo que cualquier tolerancia positiva es un permiso explícito para cambiar algo. Conviene empezar con un error estándar y subirla solo si una diferencia mayor no cambiaría la decisión que el efecto alimenta.

20.5 Implementación de referencia

```
#!/usr/bin/env bash
# comandos locales de CI
set -euo pipefail

# Etapa rápida: software y servicio local
python -m compileall -q src tests
pytest tests/test_software.py -v
# opcional, solo si se empaqueta en contenedor:
docker build -t causal-service:local .

# Etapa estadística: no registrar artefactos si falla
python scripts/validar_schema.py
pytest tests/test_placebo.py -v --tb=short
pytest tests/test_efecto_estable.py -v --tb=short
pytest tests/test_balance.py -v --tb=short

# Registro local del bundle validado
mkdir -p artifacts/registered_model
cp model/dml_estimator.joblib model/model_card.json \
   MODEL_CARD.md artifacts/registered_model/
```

Listado 20.1: CI local con pruebas de software y estadísticas en etapas separadas.

La etapa estadística empieza validando la ficha, porque una ficha inválida invalida todo lo que viene después. El script comprueba las tres cosas que el Apéndice G declara verificables por máquina: que la ficha cumple el esquema, que el veredicto de cada supuesto observable sale de su valor y su umbral y que ninguno falló, y que la huella de los datos coincide con la del conjunto de referencia versionado:

```
# scripts/validar_schema.py
import hashlib, json, sys
from pathlib import Path
from jsonschema import Draft202012Validator, FormatChecker
```

```
def cargar(ruta):
    return json.loads(Path(ruta).read_text(encoding="utf-8"))

card = cargar("model/model_card.json")
esquema = cargar("schemas/causal-model-card-v2.schema.json")
datos_ref = Path("data/referencia_ci.parquet")

errores = []
# (i) esquema
for e in Draft202012Validator(esquema,
format_checker=FormatChecker()).iter_errors(card):
    ruta = "/".join(map(str, e.absolute_path)) or "(raiz)"
    errores.append(f"{ruta}: {e.message}")
# (ii) supuestos observables: el veredicto sale del valor y el umbral, y
ninguno fallo
OPS = {"<": lambda a, b: a < b, "<=": lambda a, b: a <= b,
       ">": lambda a, b: a > b, ">=": lambda a, b: a >= b}
for sup in card.get("supuestos", []):
    u, v = sup.get("umbral"), sup.get("ultima_verificacion")
    if sup.get("clase") != "observable" or not (u and v):
        continue                      # los no observables y los incompletos ya
los cubre el esquema
    if v["paso"] != OPS[u["operador"]](v["valor"], u["valor"]):
        errores.append(f"supuesto {sup['nombre']!r}: el veredicto no sale del
valor y el umbral")
    elif not v["paso"]:
        errores.append(f"supuesto {sup['nombre']!r} no supera su umbral")
# (iii) huella de los datos de referencia
huella = "sha256:" + hashlib.sha256(datos_ref.read_bytes()).hexdigest()
if card.get("version", {}).get("hash_datos_entrenamiento") != huella:
    errores.append("huella distinta de la de los datos de referencia")

if errores:
    sys.exit("model_card.json no valido:\n  " + "\n  ".join(errores))
print("model_card.json valido")
```

Listado 20.2: Validación de `model_card.json` en el CI local (Ap. G.4): esquema, supuestos observables y huella de los datos.

Las dos pruebas estadísticas leen los roles de la ficha, y no una lista de columnas escrita en el código, para que no puedan divergir de lo que el servicio usa. La del placebo repite la permutación y tolera un número de rechazos calculado con la tasa medida del modelo sano:

```
# tests/test_placebo.py
import copy, json
import joblib
import numpy as np
import pandas as pd
```

```
REPETICIONES = 20   # permutaciones del tratamiento
MAX_RECHAZOS = 5    # P(mas de 5 de 20) = 0.018 si p0 = 0.11

def test_placebo_no_significativo():
    with open("model/model_card.json", encoding="utf-8") as f:
        r = json.load(f)["roles"]
    modelo = joblib.load("model/dml_estimator.joblib")
    df = pd.read_parquet("data/referencia_ci.parquet")  # fija
    X, Y = df[r["covariables"]], df[r["resultado"]].to_numpy()
    D = df[r["tratamiento"]].to_numpy()
    rng = np.random.default_rng(0)
    rechazos = 0
    for _ in range(REPETICIONES):
        est = copy.deepcopy(modelo)          # sin estado compartido
        est.fit(Y, rng.permutation(D), X=X)  # rompe el vinculo con Y
        lb, ub = est.ate_interval(X=X, alpha=0.05)
        rechazos += not (lb <= 0 <= ub)
    assert rechazos <= MAX_RECHAZOS, (
        f"Placebo significativo en {rechazos} de {REPETICIONES} "
        "permutaciones. Revisar antes de registrar."
    )
```

Listado 20.3: Prueba estadística de humo: reestimar con el tratamiento permutado no debe dar un efecto significativo.

La de estabilidad reestima el efecto con los datos y el código del candidato y lo compara con el que la ficha registró, en unidades del error estándar que la ficha declara. Exige que el estimador tenga las semillas fijadas, porque de lo contrario el desplazamiento no sería cero ni siquiera sin cambios:

```
# tests/test_efecto_estable.py
import copy, json
import joblib
import pandas as pd

TOLERANCIA_EE = 1.0   # en errores estandar; fijar antes de correr

def test_efecto_estable():
    with open("model/model_card.json", encoding="utf-8") as f:
        ficha = json.load(f)
    r, m = ficha["roles"], ficha["metricas"]
    df = pd.read_parquet("data/referencia_ci.parquet")
    X = df[r["covariables"]]
    est = copy.deepcopy(joblib.load("model/dml_estimator.joblib"))
    est.fit(df[r["resultado"]].to_numpy(),
            df[r["tratamiento"]].to_numpy(), X=X)
```

```
    ee = (m["ic95"][1] - m["ic95"][0]) / (2 * 1.96)  # EE del IC
    desplazamiento = abs(float(est.ate(X=X)) - m["efecto"]) / ee
    assert desplazamiento <= TOLERANCIA_EE, (
        f"El efecto se aleja {desplazamiento:.1f} errores estandar "
        f"del registrado (tolerancia {TOLERANCIA_EE}). "
        "Decide una persona si el cambio es legitimo."
    )
```

Listado 20.4: Prueba de estabilidad: el efecto reestimado no se aleja del registrado más de la tolerancia, en errores estándar.

20.6 Aplicación al sistema causal del curso

El registro local del artefacto solo ocurre si la etapa estadística pasó. Es decir, el artefacto del Capítulo 19 queda condicionado a que el placebo, la estabilidad del efecto y el balance sigan siendo razonables, no solo a que el código compile. Esta es, en términos concretos, la implementación de la **confiabilidad** como requisito de sistema que el Capítulo 2 definió al inicio del libro: el sistema «sigue produciendo el comportamiento correcto» porque el pipeline se lo exige mecánicamente, no porque alguien se acuerde de verificarlo manualmente antes de cada registro.

La misma compuerta sirve al aprendizaje continuo. Un reentrenamiento programado produce un candidato como cualquier otro, y pasa por las mismas pruebas antes de sustituir a la versión vigente (Capítulo 31). Lo que cambia es quién propone el candidato, no quién decide si se registra.

20.7 Señales de alerta y checklist operativo

- ☐ El pipeline de CI/CD solo corre pruebas de software; ningún job verifica placebo, balance o cobertura de intervalos.
- ☐ El dataset de referencia usado en las pruebas estadísticas no está versionado, por lo que las pruebas pueden dar resultados distintos en ejecuciones distintas sin que nadie lo note.
- ☐ El registro del artefacto ocurre en el mismo paso que las pruebas de software, sin depender del resultado de las pruebas estadísticas.
- ☐ Nadie revisa manualmente los resultados de las pruebas estadísticas cuando fallan; el pipeline solo las corre pero no las reporta de forma visible al equipo.
- ☐ El pipeline tiene un placebo pero ninguna prueba que reestime el efecto, de modo que un control omitido pasaría sin que nada lo note.
- ☐ La tolerancia del placebo se tomó de la tasa nominal del 5 % y no de la tasa medida sobre el modelo sano, o el umbral se modificó en el mismo cambio que lo hizo fallar.

20.8 Ejercicios y notas bibliográficas

20.8.1 Ejercicios conceptuales

1. Explique por qué separar las pruebas de software (rápidas, en cada *push*) de las pruebas estadísticas (lentas, solo antes de publicar) es un mejor diseño que correr ambas en cada *commit*. ¿Qué se pierde con esta separación?
2. Proponga una tercera prueba estadística, además del placebo y el balance, que tenga sentido incluir en el pipeline de CI para un estimador DML-IV (Capítulo 17). Justifique qué supuesto específico protege.
3. La tasa de rechazo del placebo del modelo sano, medida con 200 permutaciones, es 0,11. Con 20 permutaciones por corrida, calcule la tolerancia mínima que mantiene los falsos bloqueos por debajo del 2 %. ¿Qué tolerancia hace falta si la tasa medida sube a 0,15 al cambiar el conjunto de referencia, y qué se pierde en la detección?
4. En el caso canónico, quitar la confusora más débil desplaza el efecto entre 1,5 y 2,3 errores estándar. Explique por qué una tolerancia de tres errores estándar no la detecta y qué se pierde al bajarla a uno. ¿De qué debería depender la elección?

20.8.2 Ejercicio de infraestructura (cierra el Notebook B2)

1. Complete el Notebook de producción B2: ejecute los comandos locales del listado 20.1 y las pruebas de los listados 20.3 y 20.4 adaptadas a su modelo. Verifique que quitar una covariable de control clave hace fallar la prueba de estabilidad y que el placebo, en cambio, sigue pasando. Mida la tasa de rechazo del placebo de su modelo sano con 200 permutaciones, fije con ella el número de permutaciones y la tolerancia, y registre los tres valores en el campo `validacion` de la ficha. Explique por qué, y documente el resultado.

20.8.3 Notas bibliográficas

La práctica general de CI/CD para sistemas de ML se documenta en (Huyen 2022) y (Kästner et al. 2024), ya citados en capítulos anteriores; Breck et al. (2017) (citado en el Capítulo 2) incluye explícitamente pruebas de «reproducibilidad del pipeline de entrenamiento» en su rúbrica, que este capítulo extiende con pruebas específicas de validez causal.

PARTE V

Heterogeneidad, políticas y targeting

Esta parte pasa de la estimación de efectos a la toma de decisiones: aprendizaje de políticas óptimas bajo restricciones de bienestar y presupuesto, y uplift modeling para targeting de intervenciones.

CAPÍTULO 21

Aprendizaje de políticas óptimas

Cuadro sinóptico del capítulo

Problema:	Aprender una regla de asignación óptima bajo restricciones presupuestarias y de equidad
Estimando:	Valor de la política $V(\pi)$, *welfare regret*
Identificación:	No confusión, SUTVA, soporte común
Método:	Árbol de política, estimación doblemente robusta del valor
Nuisance:	$\mu_d(x)$, $e_d(x)$, CATE $\tau(x)$
Garantía:	Regret $O_p\left(\sqrt{\mathrm{VC}(\Pi)/n}\right)$ sobre una clase Π de VC-dimensión finita (Kitagawa y Tetenov, 2018; extendido a *nuisance* estimados por ML en Athey y Wager, 2021)
Librerías:	`econml.policy`
Validación:	*Hold-out*, *cross-fitting*, valor doblemente robusto con intervalo

Nota técnica

Con la Parte IV completa, el estimador causal ya se puede publicar y operar en producción (Capítulo 19 y Capítulo 20). Este capítulo abre la Parte V y cambia la pregunta: hasta ahora el libro estimó **cuánto** efecto tiene un tratamiento; desde aquí, la pregunta es **a quién** asignarlo, reutilizando el CATE de los meta-learners y los bosques causales (Capítulo 12 y Capítulo 13) como insumo de una regla de decisión.

21.1 Motivación aplicada

Un ministerio debe decidir a qué hogares ofrecer un programa de capacitación laboral. El programa es costoso (1 000 dólares por hogar) y solo puede cubrir al 30 % de la población. El CATE estimado varía ampliamente: en algunos hogares el efecto sobre ingresos es de

2 500 dólares y en otros es cercano a cero. La pregunta de política es: *dada una restricción presupuestaria, ¿qué regla de asignación maximiza el bienestar agregado?*

Este es el problema de *policy learning*: encontrar una regla $\pi : \mathcal{X} \to \{0, 1\}$ que maximice el *valor de la política* $V(\pi) = E[Y(\pi(X))]$ sujeto a restricciones presupuestarias o de equidad. Kitagawa y Tetenov (2018) y Athey y Wager (2021) desarrollaron el marco formal, mostrando que bajo no confusión se puede aprender la política óptima con garantías de *welfare regret*.

Este capítulo desarrolla la teoría del policy learning, muestra con tres casos de resultado conocido cómo se comporta el valor de una política frente al presupuesto y cómo se evalúa con inferencia válida, y discute las extensiones a restricciones presupuestarias y de equidad.

21.2 Teoría, supuestos y garantías

21.2.1 Valor de una política y *welfare regret*

Con $\mu_d(x) = E[Y \mid X = x, D = d]$ y $\tau(x) = \mu_1(x) - \mu_0(x)$, el valor de una regla π es

$$V(\pi) = E[Y(\pi(X))] = E[\pi(X)\mu_1(X) + (1 - \pi(X))\mu_0(X)] = E[\mu_0(X) + \pi(X)\tau(X)] \tag{21.1}$$

Como $E[\mu_0(X)]$ no depende de π, comparar políticas equivale a comparar el *valor incremental* $\tilde{V}(\pi) = V(\pi) - V(0) = E[\pi(X)\tau(X)]$, el valor respecto de no tratar a nadie. La política óptima es

$$\pi^*(x) = \mathbf{1}\{\tau(x) > 0\}, \tag{21.2}$$

y el *welfare regret* mide cuánto pierde una regla $\hat{\pi}$ respecto de la óptima:

$$\text{Regret}(\hat{\pi}) = V(\pi^*) - V(\hat{\pi}) = E[(\pi^*(X) - \hat{\pi}(X))\tau(X)]. \tag{21.3}$$

21.2.2 Estimación del valor de la política

Bajo no confusión, $V(\pi)$ es identificable también a partir de datos observacionales. Con $e_d(x) = P(D = d \mid X = x)$, el estimador *doubly robust* es

$$\hat{V}(\pi) = \left(\frac{1}{n}\right) \sum_i \left[\hat{\mu}_{\pi(X_i)}(X_i) + \frac{\mathbf{1}\{D_i = \pi(X_i)\}}{\hat{e}_{\pi(X_i)}(X_i)} \big(Y_i - \hat{\mu}_{\pi(X_i)}(X_i)\big) \right]. \tag{21.4}$$

Restando el mismo estimador para $\pi = 0$ se obtiene la forma que usan los algoritmos de este capítulo, $\hat{\tilde{V}}(\pi) = (1/n)\sum_i \pi(X_i)\hat{\Gamma}_i$, donde $\hat{\Gamma}_i$ es el *score* doblemente robusto del CATE (el mismo Γ_i del DR-learner del Capítulo 12):

$$\hat{\Gamma}_i = \hat{\mu}_1(X_i) - \hat{\mu}_0(X_i) + D_i \frac{Y_i - \hat{\mu}_1(X_i)}{\hat{e}_1}(X_i) - (1 - D_i)\frac{Y_i - \hat{\mu}_0(X_i)}{\hat{e}_0}(X_i). \tag{21.5}$$

Conviene separar con cuidado dos resultados que se citan a menudo de forma intercambiable, porque responden preguntas distintas y sus supuestos no son los mismos. El primero es la inferencia sobre el valor de una política dada; el segundo, la garantía de regret de una política aprendida.

Proposición 21.1 ***(Inferencia sobre el valor de una política fija)***

Sea π una regla fija, o aprendida con una muestra independiente de la que se usa para evaluarla. Bajo no confusión, soporte común y *nuisance* estimados por *cross-fitting* a tasas que cumplen la condición de producto, la *efficient influence function* de $V(\pi)$ es

$$\psi_\pi(W) = \mu_{\pi(X)}(X) + \frac{\mathbf{1}\{D = \pi(X)\}}{e_{\pi(X)}(X)} \cdot \big(Y - \mu_{\pi(X)}(X)\big) - V(\pi), \tag{21.6}$$

caso particular de la forma canónica de la Nota técnica 10.2.4. Por tanto

$$\sqrt{n}\big(\hat{V}(\pi) - V(\pi)\big) \xrightarrow{d} \mathcal{N}(0, E[\psi_\pi^2]), \tag{21.7}$$

y para comparar dos políticas π_A, π_B sobre las mismas observaciones, la diferencia $\hat{V}(\pi_A) - \hat{V}(\pi_B)$ es asintóticamente normal con varianza $E\Big[\big(\psi_{\pi_A} - \psi_{\pi_B}\big)^2\Big]/n$, de modo que el estadístico

$$z = \frac{\hat{V}(\pi_A) - \hat{V}(\pi_B)}{\hat{\sigma}_{AB}/\sqrt{n}}, \quad \hat{\sigma}^2_{AB} = \mathrm{Var}_n\big(\hat{\psi}_{\pi_A} - \hat{\psi}_{\pi_B}\big), \tag{21.8}$$

se compara con una normal estándar, donde $\hat{\psi}_\pi$ es la función de influencia estimada de cada política sobre cada observación.

La condición de que π sea fija o independiente de la muestra de evaluación es esencial. Si $\hat{\pi}$ se aprendió con las mismas observaciones que se usan para estimar su valor, el estimador sufre la misma maldición del ganador que el árbol sin honestidad del Capítulo 13: la regla fue elegida justamente por rendir bien en esa muestra. Por eso la evaluación se hace en un *hold-out* y la comparación de dos reglas, con el estadístico anterior sobre el mismo *hold-out*; reportar *welfare* puntuales sin ese test no permite decir cuál de dos políticas es mejor.

21.2.3 Garantías de aprendizaje

El teorema de **regret óptimo** $O_p\big(n^{-1/2}\big)$ para clases de políticas con VC-dimensión finita se debe a Kitagawa y Tetenov (2018). Los métodos basados en GRF para policy learning (Athey y Wager 2021) implementan esta teoría mediante árboles de decisión honestos.

Teorema 21.2 ***(Kitagawa y Tetenov, 2018: maximización del bienestar empírico)***

Sea Π una clase de políticas con VC-dimensión finita $\mathrm{VC}(\Pi)$, y sea

$$\hat{\pi}_{\mathrm{EWM}} = \operatorname*{argmax}_{\pi \in \Pi} \hat{V}(\pi) \tag{21.9}$$

el maximizador del *welfare* empírico, con propensión conocida o estimada a tasa paramétrica. Bajo soporte común acotado ($e(x) \in [\underline{e}, 1 - \underline{e}]$) y resultados acotados, el *regret* respecto de la mejor política **dentro de la clase** satisface

$$E\Big[\max_{\pi \in \Pi} V(\pi) - V(\hat{\pi}_{\mathrm{EWM}})\Big] = O\Big(\sqrt{\mathrm{VC}(\Pi)/n}\Big), \tag{21.10}$$

y esta tasa es minimax-óptima sobre la clase.

Dos precisiones sobre este enunciado, ambas importantes en la práctica. Primera: el regret se mide contra $\max_{\pi\in\Pi} V(\pi)$, la mejor política **de la clase**, no contra la política óptima sin restricciones $\pi^*(x) = \mathbf{1}\{\tau(x) > 0\}$. La diferencia entre ambas, el **error de aproximación** de la clase, no desaparece con más datos y es el precio de exigir reglas interpretables. Segunda: la garantía no requiere estimar bien el CATE. La maximización empírica optimiza directamente el *welfare* y puede producir una política casi óptima aunque $\hat{\tau}$ sea un estimador mediocre, lo que explica por qué «el CATE tiene RMSE alto» y «la política es buena» no son afirmaciones contradictorias.

El resultado de Athey y Wager (2021) extiende este marco al caso que interesa a este libro: cuando $\hat{V}$ se construye con *nuisance* $(\hat{\mu}_d, \hat{e})$ estimados con *machine learning* en vez de conocidos.

Teorema 21.3 ***(Athey y Wager, 2021: policy learning con nuisance estimados)***

Si $\hat{\pi}$ maximiza el estimador doblemente robusto (21.4) sobre una clase Π de VC-dimensión finita, con *nuisance* estimados por *cross-fitting* a tasas que satisfacen la condición de producto $\sqrt{n}a_n^2 \to 0$, entonces el regret respecto de la mejor política de la clase conserva la tasa $O_p\left(\sqrt{\mathrm{VC}(\Pi)/n}\right)$: el error de estimación de los *nuisance* entra solo a segundo orden.

La estructura del argumento es la misma que la del Capítulo 10 (ortogonalidad más *cross-fitting* hacen que el error de los *nuisance* sea de segundo orden), aplicada ahora a un problema de optimización sobre una clase de funciones en lugar de a la estimación de un escalar. Ese es el aporte específico de Athey y Wager; la garantía de regret con clases de VC-dimensión finita es de Kitagawa y Tetenov.

21.2.4 Evaluación de políticas con datos históricos

Intuición

Caja de profundización: evaluación de políticas con datos históricos

Objetivo. Estimar cuánto valdría una política sin tener que implementarla.

El problema. Hay una política $\pi(x)$ que decide a quién tratar. Se quiere su valor esperado $V(\pi) = E[Y(\pi(X))]$, pero solo se observa Y bajo la política original, no bajo la nueva.

Tres formas de estimar $V(\pi)$ sin implementar la política:

- **IPS (*Inverse Propensity Scoring*):** cada observación cuenta solo si lo que recibió coincide con lo que la nueva política le habría asignado, y se pondera por $1/e_{D_i}(X_i)$, la inversa de la probabilidad de haber recibido eso.
- **SNIPS (*Self-Normalized IPS*):** igual que IPS pero normalizando los pesos para mayor estabilidad.
- **DR (*Doubly Robust*):** combina la predicción directa con IPS. Si el modelo de resultado o el propensity es correcto, el estimador es consistente.

Precaución. Si la nueva política trata a personas muy diferentes de las que fueron tratadas originalmente (poco solapamiento), los pesos explotan y los estimadores IPS y DR se vuelven inestables. Es una extrapolación.

21.2.5 Restricciones presupuestarias

Si la restricción es tratar a lo más a una fracción β de la población, la política óptima es

$$\pi^*_{\text{budget}}(x) = \mathbf{1}\{\tau(x) > c\}, \quad c = \max\big(q_{1-\beta}, 0\big), \tag{21.11}$$

donde $q_{1-\beta}$ es el cuantil $1-\beta$ de $\tau(X)$. Se trata a quienes están en el β superior de τ, pero nunca a quien tiene $\tau \le 0$: si menos de una fracción β de la población se beneficia, el presupuesto no se agota. El umbral c es el precio sombra del presupuesto: la regla trata a quien devuelve más que c por unidad tratada, el mismo costo sombra λ de la asignación por *net score* del Capítulo 22. Cuando el presupuesto no ata, $c = 0$ y se recupera π^*.

Caso canónico · Valor de la política frente al presupuesto

Cinco covariables normales estándar, $\tau(X) = 1 + 2X_0 + X_1$ (media 1, desviación típica $\sqrt{5} \approx 2.24$), resultado sin tratamiento X_2, ruido normal estándar y asignación aleatoria. Con orden perfecto, tratar a la fracción β de mayor τ rinde $V(\beta) = \beta\mu + \sigma\varphi(\Phi^{-1}(1-\beta))$, con $\mu = 1$, $\sigma = \sqrt{5}$, Φ la normal estándar y φ su densidad.

Política	30 %	50 %	100 %
Orden perfecto con piso (τ conocido)	1,077	1,392	1,480
Orden estimado con piso (T-learner, 3 000)	1,067	1,381	1,469
Al azar con la misma fracción	0,300	0,500	1,000

Tratar a todos rinde 1,000 (el efecto medio). Con el 30 % de presupuesto, el *targeting* rinde 3,6 veces lo que rinde tratar al azar la misma fracción, y con una señal fuerte y 3 000 unidades de entrenamiento el orden estimado casi coincide con el perfecto (1,067 frente a 1,077; desviación típica entre repeticiones de 0,008). La curva crece hasta $\beta^* = P(\tau > 0) = 0,67$ y se aplana en $E[\tau^+] = 1,48$, porque el piso en cero impide seguir tratando a quien perjudica. Dos lecturas se desprenden. Primera, la ventaja sobre «tratar a todos» depende del presupuesto: con una fracción menor que aproximadamente 0,27 el valor del *targeting* queda por debajo de 1,00, el de tratar a todos, referente que un presupuesto tan escaso no permite alcanzar; y el valor máximo, $E[\tau^+] = 1,48$, supera a tratar a todos porque trata solo a quien se beneficia. Segunda, con una señal débil o una muestra pequeña la brecha entre el orden estimado y el perfecto crece, y esa brecha es lo que el *regret* mide.

La figura 21.1 muestra las cuatro curvas del caso canónico.

Una advertencia sobre la forma de la curva. Que el *targeting* domine al tratamiento aleatorio en todo el rango de presupuesto no es un hallazgo empírico sino una consecuencia mecánica de que $\hat{\tau}$ ordene mejor que el azar; una curva así no valida nada por sí sola. Lo

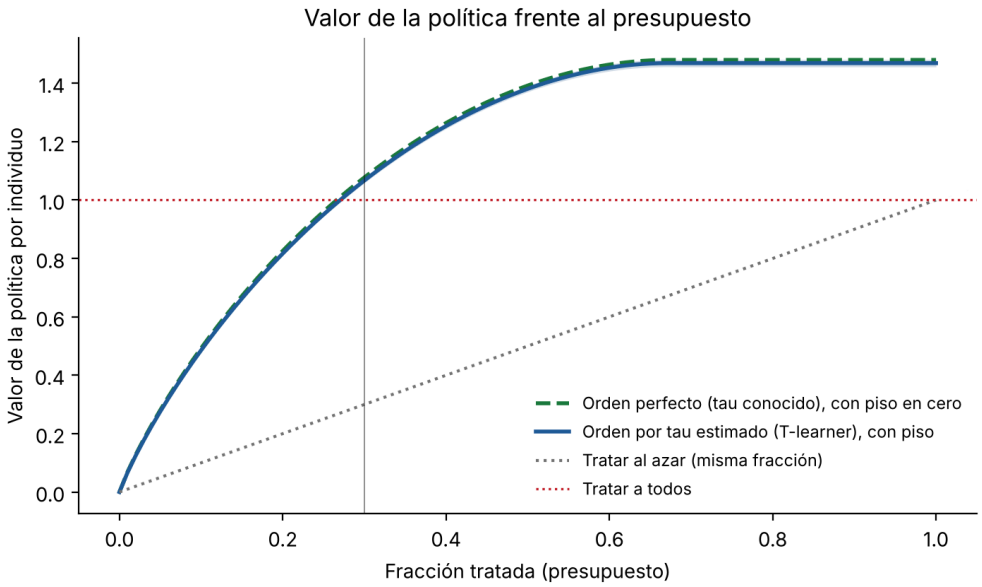


Figura 21.1: Valor de la política frente al presupuesto en el caso canónico. Verde discontinua: orden perfecto con piso en cero. Azul: orden por CATE estimado (T-learner), con banda de una desviación típica entre 20 repeticiones. Gris punteada: tratamiento al azar de la misma fracción. Roja punteada: tratar a todos. La línea vertical marca el presupuesto del 30 %. El script que genera la figura está en el material de verificación.

informativo es lo contrario: si la curva de *targeting* **no** se separa de la aleatoria, la conclusión correcta es que no hay heterogeneidad accionable, y la política óptima es tratar a todos o a nadie según el signo del ATE. Es un resultado perfectamente respetable que el *baseline* de efecto constante del Capítulo 14 está diseñado para detectar antes de invertir en un sistema de *targeting* que no aporta valor.

Caso canónico · Un piso en cero

Mismas covariables, pero con $\tau(X) = 2X_0 + X_1 - 1.5$, de modo que solo el 24,6 % de la población se beneficia, y un presupuesto del 30 %. Con 3 000 unidades, 50 repeticiones y el mismo CATE estimado para las dos reglas, tratar al 30 % superior a secas, aunque el 5 % de esos tengan efecto estimado negativo, rinde 0,309, mientras que tratar solo a quien tiene CATE estimado positivo (el 24,8 % de la población) rinde 0,319. El umbral $\max(q_{0.70}, 0)$ evita gastar presupuesto donde el efecto es negativo; ignorar ese piso cuesta *welfare* en cuanto el presupuesto supera a la fracción que se beneficia.

21.3 Algoritmo: árbol de política con presupuesto

Una política de la clase de árboles de profundidad acotada se aprende maximizando el valor incremental empírico, no ajustando un árbol de regresión a los CATE estimados: la regla de

Algoritmo

Entrada: Datos $\left(X_i, \hat{\Gamma}_i\right)_{i=1}^{n}$ con $\hat{\Gamma}_i$ de la (21.5) estimados por *cross-fitting*, presupuesto $\beta \in (0,1)$, profundidad máxima $d_{\max}$, tamaño mínimo de hoja $n_{\min}$, tolerancia δ.
Salida: Regla $\hat{\pi} : \mathcal{X} \to \{0,1\}$ que trata a lo sumo una fracción β y maximiza el valor incremental estimado.
Dada un precio $c \geq 0$, construir el árbol $\mathcal{T}_c$ de profundidad a lo sumo $d_{\max}$ y hojas de al menos $n_{\min}$ unidades que maximice $\sum_m \max\left(0, \sum_{i \in \mathcal{L}_m} \left(\hat{\Gamma}_i - c\right)\right)$, y fijar $\hat{\pi}_c(x) = \mathbf{1}\left\{\sum_{i \in \mathcal{L}_m} \left(\hat{\Gamma}_i - c\right) > 0\right\}$ para $x \in \mathcal{L}_m$.
if la fracción tratada por $\hat{\pi}_0$ es a lo sumo β **then return** $\hat{\pi}_0$ (el presupuesto no ata).

$c_{\min} \leftarrow 0$, $c_{\max} \leftarrow \max_i \hat{\Gamma}_i$ (con $c_{\max}$ nadie recibe tratamiento).
repeat hasta $c_{\max} - c_{\min} < \delta$:
  $c \leftarrow \frac{c_{\min} + c_{\max}}{2}$ y construir $\hat{\pi}_c$
  if la fracción tratada por $\hat{\pi}_c$ supera β **then** $c_{\min} \leftarrow c$
  else guardar $\hat{\pi}_c$ y $c_{\max} \leftarrow c$
Estimar $\hat{V}(\hat{\pi})$ y su intervalo con la proposición de la Sección 21.2.2 en una muestra *hold-out* distinta.
return la mejor regla factible guardada.

Algoritmo 14. Árbol de política con restricción presupuestaria

cada hoja es tratar si el promedio de los *scores* $\hat{\Gamma}_i$ de la hoja supera el precio c, y el árbol se elige para maximizar la suma de esas ganancias.

La bisección es válida porque la fracción tratada no crece con c. Como con las asignaciones por *net score*, el tratamiento cambia a saltos con el precio, de modo que la regla factible puede dejar sin usar una pequeña parte del presupuesto. Con una clase de árboles de profundidad 2 o 3 la búsqueda de la partición óptima es exhaustiva y exacta para unas decenas de covariables, y es lo que hace que el árbol de política sea una herramienta aplicable.

Caso canónico · Un intervalo centrado en lo que se estima

Con el DGP del primer caso, 3 000 unidades, un árbol de política de profundidad 3 aprendido en el 70 % de la muestra y evaluado en el 30 % restante, se construye el intervalo de la proposición de la Sección 21.2.2 con la estimación doblemente robusta como centro. En 200 repeticiones, contiene el *welfare* verdadero de la política el 99 % de las veces, algo por encima del 95 % nominal, con un sesgo medio de la estimación de 0,0002. El exceso se explica porque el valor «verdadero» se calcula como un promedio sobre la misma muestra de evaluación, con la que el estimador comparte buena parte de la variación. Un intervalo centrado en el valor verdadero, en cambio, cubriría el 100 % por construcción, y por eso mismo no informaría nada: la variabilidad se mide en torno de lo que se estima, no de lo que se quiere recuperar.

21.4 Implementación en Python

21.4.1 Policy learning con econml

Atención

Este listado es sintético, no aplicado. El código toma las covariables numéricas del dataset `gov_transfers` pero **simula** el tratamiento y el resultado a partir de un CATE conocido. Esa elección es deliberada y tiene una razón metodológica, no de conveniencia: el objetivo aquí es evaluar el *policy learning* comparando la política aprendida contra el *welfare* verdadero, y ese contraste solo es posible cuando $\tau(x)$ se conoce por construcción. Con datos reales no existe *ground truth* del CATE (Capítulo 14) y lo único que puede reportarse es un valor estimado, no un regret. Léase, pues, como una verificación de que el procedimiento recupera la política correcta cuando **sabemos** cuál es, y no como evidencia sobre el efecto real de las transferencias gubernamentales.

```
import numpy as np
import pandas as pd
from econml.dml import CausalForestDML
from econml.policy import PolicyTree, PolicyForest
from sklearn.ensemble import GradientBoostingRegressor,
GradientBoostingClassifier
from sklearn.model_selection import train_test_split

# --- DGP SINTETICO ------------------------------------------------
# Las covariables X son reales (gov_transfers); D, tau e Y se SIMULAN
# para disponer del CATE verdadero y poder medir el regret.
df = pd.read_csv("../data/datasets/real/public_causaldata/gov_transfers/
data.csv")
rng = np.random.default_rng(42)
n = len(df)
X = df.select_dtypes(include=[np.number]).dropna(axis=1).values[:n]
X = X[:, :10]  # limitar a 10 features
D = rng.binomial(1, 0.5, n)          # asignacion aleatoria SIMULADA
tau_true = 2 * X[:, 0] + X[:, 1]     # CATE verdadero SIMULADO
Y = X[:, 2] + D * tau_true + rng.standard_normal(n)
# ------------------------------------------------------------------

# Separar muestra hold-out
X_train, X_test, Y_train, Y_test, D_train, D_test, tau_train, tau_test =
train_test_split(
    X, Y, D, tau_true, test_size=0.3, random_state=42
)

# Paso 1: estimar CATE en train
```

```
cf = CausalForestDML(
    model_y=GradientBoostingRegressor(n_estimators=200, random_state=42),
    model_t=GradientBoostingClassifier(n_estimators=200, random_state=42),
    discrete_treatment=True,
    n_estimators=400,
    min_samples_leaf=20,
    cv=5,
    random_state=42
).fit(Y_train, D_train, X=X_train)

# Paso 2: aprender politica en train
policy = PolicyTree(max_depth=3, min_samples_leaf=50, random_state=42)
policy.fit(X_train, cf.effect(X_train))

# Paso 3: evaluar la politica en test (hold-out)
pi_test = policy.predict(X_test)

# Evaluacion con ground truth sintetico
welfare_test = tau_test[pi_test == 1].mean() * pi_test.mean()

print(f"Welfare en hold-out (tau verdadero simulado): {welfare_test:.4f}")
print(f"Fraccion tratada en hold-out: {pi_test.mean():.3f}")

# Paso 4: estimar el welfare incremental en hold-out, con IC via influence
function.
# welfare_test usa el tau verdadero del DGP: es el valor que se quiere
recuperar, y solo
# existe porque los datos son sinteticos. Con datos reales solo se dispone de
la estimacion
# doblemente robusta (v_hat), y el IC debe centrarse en ella, no en
welfare_test.
# cf.effect() da tau_hat, NO mu_1(X): hacen falta mu_1 y mu_0 por separado (T-
learner)
# para construir el score doblemente robusto. No se puede aproximar con tau_hat
solo.
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import GradientBoostingRegressor as GBR_mu

e_hat = LogisticRegression(max_iter=1000).fit(X_train,
D_train).predict_proba(X_test)[:, 1]
mu1_hat = GBR_mu(random_state=42).fit(X_train[D_train == 1], Y_train[D_train ==
1]).predict(X_test)
mu0_hat = GBR_mu(random_state=42).fit(X_train[D_train == 0], Y_train[D_train ==
0]).predict(X_test)
pi = pi_test.astype(int)

# Score IRM (forma canonica del Cap. 10, fila "ATE bajo IRM"), ponderado por
```

```
pi(X):
# es el integrando doblemente robusto de V_tilde(pi) = E[pi(X) tau(X)].
score_irm = ((mu1_hat - mu0_hat)
             + D_test * (Y_test - mu1_hat) / np.clip(e_hat, 0.01, 0.99)
             - (1 - D_test) * (Y_test - mu0_hat) / np.clip(1 - e_hat, 0.01,
0.99))
v_hat = np.mean(pi * score_irm)
psi_pi = pi * score_irm - v_hat
se_pi = psi_pi.std(ddof=1) / np.sqrt(len(Y_test))
print(f"Welfare DR en hold-out: {v_hat:.4f}  IC 95%: [{v_hat - 1.96 *
se_pi:.4f}, {v_hat + 1.96 * se_pi:.4f}]")
print(f"Welfare verdadero (solo por ser sintetico): {welfare_test:.4f}")
```

Listado 21.1: Policy learning con evaluación hold-out sobre un DGP sintético (covariables reales de `gov_transfers`, tratamiento y resultado simulados).

El intervalo se centra en la estimación doblemente robusta y no en el *welfare* calculado con el CATE verdadero. En una simulación de verificación con 200 repeticiones (semillas 0 a 199), el intervalo así construido contuvo el *welfare* verdadero el 99 % de las veces y la estimación quedó centrada (sesgo medio de 0,0002). El código está en `herramientas/verificaciones/verif_cap21.py`, que reemplaza `CausalForestDML` y `PolicyTree` por equivalentes de scikit-learn (un T-learner con `GradientBoostingRegressor` y un árbol de regresión sobre $\hat{\tau}$), porque EconML no está en el entorno de verificación. El listado entrena el `PolicyTree` con $\hat{\tau}$ como recompensa del tratamiento (una versión de plug-in); la versión doblemente robusta del algoritmo usa los $\hat{\Gamma}_i$ en lugar de $\hat{\tau}_i$. La figura y la tabla del caso canónico salen de `herramientas/figuras/fig_cap21_policy_value.py`.

21.4.2 Restricción presupuestaria

```
# Restriccion: tratar como maximo al 30 % con mayor CATE, y solo a quien se
beneficia.
# cf y el hold-out (X_test, tau_test) vienen del listado anterior.
cate = cf.effect(X_test)
umbral = max(np.quantile(cate, 0.70), 0.0)   # top 30 %, pero nunca con efecto
estimado <= 0
pi_budget = (cate > umbral).astype(int)
welfare_budget = np.mean(pi_budget * tau_test)   # tau verdadero: solo por ser
sintetico
print(f"Fraccion tratada: {pi_budget.mean():.3f} (tope 0.30)")
print(f"Welfare con restriccion presupuestaria (30%): {welfare_budget:.4f}")
print(f"Welfare de tratar a todos: {tau_test.mean():.4f}")
print("Welfare de no tratar a nadie: 0.0")
```

Listado 21.2: Policy learning con restricción presupuestaria.

21.5 Riesgos, límites y sensibilidad

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Evaluar en la muestra de aprendizaje	Valor optimista (maldición del ganador): la regla se eligió por rendir bien ahí	Comparar el valor dentro y fuera de muestra	Evaluar en un *hold-out* y con *cross-fitting*; intervalo centrado en la estimación (proposición de la Sección 21.2.2)
Comparar políticas sin test	Declarar mejor a una regla por una diferencia de ruido	Estadístico z sobre el mismo *hold-out*	Reportar el valor de cada regla con su intervalo y el del diferencial
Omitir el piso en cero	Se gasta presupuesto en quien tiene efecto negativo (0,309 frente a 0,319 en el caso canónico)	Fracción tratada frente a fracción con CATE estimado positivo	Umbral $c = \max(q_{1-\beta}, 0)$
Ignorar equidad	Exclusión sistemática de grupos minoritarios	Auditar la distribución demográfica de los tratados	Imponer restricciones de paridad demográfica o *equalized CATE* (Capítulo 24)
CATE mal calibrado	Política subóptima (umbral de tratamiento incorrecto)	Gráfico de calibración: $\hat{\tau}(x)$ frente a resultados observados	DR-learner o bosque causal con *cross-fitting*; recalibrar
Solape débil	Pesos $1/\hat{e}$ extremos en el score $\hat{\Gamma}$; árbol que sigue el ruido	Distribución de $\hat{e}$ y de los pesos	Recorte de $\hat{e}$, restringir la política al soporte común

Tabla 21.1: Riesgos comunes en policy learning.

Límites. Policy learning requiere no confusión. Si hay variables confusoras no observadas, la política aprendida puede estar sesgada. Además, las garantías de regret son asintóticas y relativas a la mejor política de la clase; con muestras pequeñas, la política aprendida puede estar lejos de la óptima, y con una clase demasiado simple el error de aproximación domina.

21.6 Ejercicios propuestos

21.6.1 Ejercicios teóricos

1. Muestre que $\hat{V}(\pi) - \hat{V}(0) = (1/n)\sum_i \pi(X_i)\hat{\Gamma}_i$ con $\hat{\Gamma}_i$ de la (21.5), a partir de la (21.4).
2. Con $\tau \sim \mathcal{N}(\mu, \sigma^2)$ y orden perfecto, deduzca la fórmula $V(\beta) = \beta\mu + \sigma\varphi(\Phi^{-1}(1-\beta))$ del caso canónico para β menor o igual que $P(\tau > 0)$. Calcule $V(0.3)$ con $\mu = 1$ y $\sigma = \sqrt{5}$, el β^* y el máximo $E[\tau^+]$, y compárelos con la tabla.
3. Con un presupuesto β mayor que $P(\tau > 0)$, ¿por qué la política óptima trata solo a $P(\tau > 0)$ de la población? Relacione el precio c del algoritmo con el costo sombra de la asignación por *net score* (Capítulo 22).

4. Explique por qué evaluar una política en la misma muestra con la que se aprendió sobreestima su valor, y por qué el intervalo de la proposición de la Sección 21.2.2 deja de ser válido en ese caso.
5. Dé un ejemplo de $\tau(x)$ para el cual la mejor política de la clase de árboles de profundidad 1 tenga un error de aproximación grande frente a π^*, y explique por qué más datos no lo reducen.
6. Discuta: ¿cómo modificaría el algoritmo para imponer *equalized CATE* entre dos grupos demográficos?

21.6.2 Ejercicios computacionales

1. Replique el listado 21.1 sobre `nsw_mixtape`. ¿Qué regla de política se aprende, y con qué intervalo de su valor?
2. Compare tres políticas: (a) tratar a todos, (b) tratar al azar al 30 %, (c) tratar al top 30 % por CATE estimado. ¿En cuánto mejora el *welfare*? Repita con el estadístico z de la proposición de la Sección 21.2.2.
3. Construya un DGP donde la política óptima trate solo a un subgrupo pequeño. Verifique que el policy learning lo identifica.

21.7 Lecturas complementarias

Kitagawa y Tetenov (2018) introducen la *Empirical Welfare Maximization* y la cota de regret sobre clases de VC-dimensión finita; Athey y Wager (2021) la extienden al caso con *nuisance* estimados por ML mediante el *score* doblemente robusto, que es la versión usada en este capítulo. Leer ambos en ese orden evita la confusión de atribución más común en la literatura aplicada. Zhang et al. (2012) es un precursor importante por la vía de reformular la elección de política como un problema de clasificación ponderada. Para policy learning bajo restricciones presupuestarias, de equidad o de forma de la regla, Kitagawa et al. (2021) tratan el caso general de clasificación restringida, y el Capítulo 24 retoma el *trade-off* entre *welfare* y equidad que de ahí se sigue. La conexión con la teoría de la decisión estadística, con policy learning como caso particular de reglas de tratamiento bajo identificación parcial, se desarrolla en el Capítulo 25.

CAPÍTULO 22

Uplift modeling y targeting económico

Cuadro sinóptico del capítulo

Problema:	Asignación óptima de tratamientos con costos diferenciales y presupuesto
Estimando:	CATE por tratamiento $\tau_k(x)$, valor de la política $V(\pi)$
Identificación:	No confusión condicional y soporte común (o asignación aleatorizada)
Método:	Uplift modeling, asignación por *net score*, curvas Qini
Nuisance:	$\hat{\mu}_k(x)$, $\hat{e}_k(x)$, costos c_k
Garantía:	Ranking evaluado fuera de muestra con intervalos por *bootstrap*; magnitud verificada con el *transformed outcome*
Librerías:	causalml, econml
Validación:	Curva Qini, AUUC, análisis de costo-efectividad

Nota técnica

El Capítulo 21 formalizó la política óptima como problema de decisión restringido; este capítulo cierra la Parte V con la práctica de **targeting** de marketing y programas sociales, y con las mismas curvas Qini ya usadas para validación en el Capítulo 14, ahora como criterio de evaluación de la política y no solo del estimador.

22.1 Motivación aplicada

Una empresa de telecomunicaciones quiere reducir la *churn* (baja de clientes). Dispone de tres acciones: (a) no hacer nada, (b) enviar un SMS con descuento, (c) llamar por teléfono con una oferta personalizada. El costo de cada acción es distinto: el SMS cuesta 0,5 dólares y

la llamada 8. El efecto sobre la retención varía por cliente. La pregunta de política es a qué clientes aplicar cada acción, sujeto a un presupuesto total de 100 000 dólares.

El *uplift modeling* es el análogo del policy learning en contextos de marketing. La métrica clave es el *uplift*: la diferencia en la probabilidad de conversión (o retención) entre recibir y no recibir el tratamiento. Los métodos se desarrollaron en la industria [(Radcliffe 2007); (Gutierrez y Gérardy 2017)] y se han integrado con la literatura académica de ML causal [(Athey y Wager 2021)].

Este capítulo presenta los métodos clásicos de uplift, la evaluación por curvas Qini y la extensión a múltiples tratamientos y restricciones presupuestarias, con dos casos de resultado conocido: uno sobre por qué el ranking se evalúa fuera de muestra y otro sobre cómo se asigna un presupuesto entre dos acciones de costos muy distintos.

22.2 Marco teórico formal

22.2.1 Uplift y CATE

El *uplift* es matemáticamente equivalente al CATE:

$$\text{uplift}(x) = E[Y(1) - Y(0) \mid X = x] = \tau(x). \tag{22.1}$$

La diferencia con el capítulo 12 es el foco aplicado: uplift modeling se pregunta por el *ranking* (qué clientes tienen mayor uplift) y por la *cost-effectiveness* (cuánto uplift se obtiene por dólar invertido), no solo por la estimación puntual del CATE.

Esa diferencia de foco tiene una consecuencia práctica que conviene fijar desde el principio, porque determina qué se puede y qué no se puede hacer con un modelo de uplift. Si la decisión es **a quién tratar con un presupuesto fijo**, basta con que el ranking sea correcto: la escala de $\hat{\tau}$ es irrelevante, y las métricas de ranking (Qini, AUUC) son el criterio adecuado. Si la decisión es **cuánto presupuesto asignar**, o **qué acción elegir entre varias con costos distintos**, el ranking no basta: hace falta que la **magnitud** de $\hat{\tau}$ esté bien calibrada, porque el punto de corte óptimo compara $\tau_k(x)$ contra un costo c_k medido en las mismas unidades. Un modelo puede tener un AUUC excelente y estar tan mal calibrado que la regla de asignación por *net score* de la Sección 22.3 gaste el doble de lo proyectado. Por eso este capítulo reporta siempre las dos cosas, ranking y calibración, y por eso el *transformed outcome* del Capítulo 14, que sí da magnitudes insesgadas, reaparece aquí como diagnóstico obligatorio.

22.2.2 Qini y AUUC: teoría, supuestos y garantías

La curva Qini y el AUUC (*Area Under Uplift Curve*) son las métricas estándar para evaluar modelos de uplift en ausencia de *ground truth* individual.

Definición. Sea $\mathcal{D}$ una muestra con n unidades, cada una con tratamiento $D_i \in \{0, 1\}$ y resultado observado Y_i. Se ordenan las unidades por $\hat{\tau}(x_i)$ descendente. Para cada punto de corte $p \in [0, 1]$, el uplift acumulado, en su versión ponderada por propensión, es

$$\text{uplift}(p) = \left(\frac{1}{n}\right) \sum_{i=1}^{\lfloor np \rfloor} \left(Y_i \frac{D_i}{\hat{e}}(x_i) - \frac{Y_i(1-D_i)}{1-\hat{e}(x_i)} \right), \tag{22.2}$$

donde $\hat{e}(x)$ es la propensión estimada (en un experimento es la fracción de tratados, constante). El AUUC integra esta curva sobre $p \in [0,1]$ y se normaliza respecto de una asignación aleatoria:

$$\text{AUUC} = \int_0^1 (\text{uplift}(p) - \text{uplift}_{\text{aleatorio}}(p))\, \mathrm{d}p. \tag{22.3}$$

Supuestos. La validez de la curva Qini y el AUUC requiere:

- **Inconfundibilidad:** $Y(1), Y(0) \perp\!\!\!\perp D \mid X$.
- **Soporte común:** $0 < e(x) < 1$ para todo x.
- **Propensity score correcto:** $\hat{e}(x)$ es una estimación consistente de $e(x) = P(D = 1 \mid X = x)$.

Bajo estos supuestos, la (22.2) estima de forma consistente el beneficio acumulado de tratar primero a las unidades que el modelo ordena arriba, $E[\tau(X)\mathbf{1}\{\text{rango}(X) \le p\}]$. La curva **evalúa** un ordenamiento; no lo produce, y un modelo con un ordenamiento sin información da una curva sobre la diagonal.

Lectura de la curva. La pendiente de la curva en la posición p es, por construcción, el uplift promedio de las unidades que ocupan esa posición: una curva que sube con fuerza al principio y se aplana o desciende al final indica que el modelo concentra el efecto en la cabeza del ranking y que tratar a todos rinde menos que tratar a los mejores. El AUUC es el análogo para uplift de la curva de Lorenz y el coeficiente de Gini, que Radcliffe (2007) introduce y Gutierrez y Gérardy (2017) sitúan en la literatura de inferencia causal. En la práctica, curvas más arriba indican mejor capacidad de ranking, y con intervalos de confianza por *bootstrap* sobre la muestra de evaluación es posible juzgar si las diferencias entre modelos superan el ruido.

Uplift ponderado por costo. Cuando los costos del tratamiento varían entre individuos, se pondera el uplift por el costo unitario:

$$\text{CW-uplift}(x) = \frac{\hat{\tau}(x)}{c(x)}, \tag{22.4}$$

donde $c(x)$ es el costo del tratamiento para el cliente x. Esta métrica permite priorizar las acciones con mayor retorno por dólar invertido. Con una sola acción y un presupuesto, tratar por orden descendente de $\hat{\tau}/c$ es la solución del problema de la mochila fraccionaria, y por eso es el criterio natural; la regla de *net score* de la sección siguiente lo contiene como caso particular.

Caso canónico · El mismo modelo, dos evaluaciones

Cinco mil clientes con ocho covariables uniformes en $[-1, 1]$, asignados al azar a control, SMS o llamada con probabilidades 0,4, 0,3 y 0,3. La retención basal es $0.45 + 0.08x_2$ y los uplifts verdaderos son débiles, $\tau_{\text{SMS}} = 0.06 - 0.05x_0 + 0.03x_1$ y $\tau_{\text{llamada}} = 0.12 + 0.09x_1 -$

$0.02x_3$, de modo que las acciones difieren en unos pocos puntos porcentuales entre clientes. Se estima cada uplift con un T-learner de *gradient boosting* (profundidad 3, 200 árboles) contra el brazo de control, y se calcula el área normalizada entre la curva Qini y la diagonal de dos maneras: dentro de muestra (modelo ajustado y evaluado sobre las 5 000 unidades) y en *hold-out* (modelo ajustado sobre el 60 % y evaluado sobre el 40 % restante):

Acción	**Qini dentro de muestra**	**Qini en *hold-out***
SMS	0,0755	−0,0063
Llamada	0,0759	−0,0068

Dentro de la muestra de ajuste, el Qini es claramente positivo para las dos acciones, y fuera de ella es ligeramente negativo: el modelo ordena ruido, y la evaluación en la muestra de ajuste no lo delata. Con una heterogeneidad débil y un modelo flexible, el ranking aprendido es un artefacto de la muestra, y por eso el ranking se evalúa siempre en datos que el modelo no vio. Con una heterogeneidad marcada (uplifts que varían en decenas de puntos porcentuales), un modelo más suave y evaluación en *hold-out*, el Qini es positivo para las dos acciones y la correlación entre el uplift estimado y el verdadero es de 0,67 para el SMS y de 0,85 para la llamada; esa es la configuración del caso siguiente.

22.2.3 Multi-treatment uplift

Cuando hay K tratamientos posibles, el problema se extiende a estimar $\tau_k(x) = E[Y(k) - Y(0) \mid X = x]$ para $k = 1, ..., K$. Sin restricción de presupuesto, la política óptima asigna a cada cliente la acción con mayor $v\tau_k(x) - c_k(x)$, donde v es el valor monetario del resultado (un cliente retenido) y c_k el costo del tratamiento k, y no trata si el máximo no es positivo. El valor v es lo que permite comparar una probabilidad con dólares; cuando no se conoce, el presupuesto es la única restricción y el costo sombra de la sección siguiente cumple su papel.

Intuición

Caja de profundización: *bootstrap* para la curva Qini y *embeddings* como covariables

***Bootstrap* para la curva Qini.** Una forma de comparar modelos de uplift con incertidumbre, con el modelo ya ajustado y sobre la muestra de evaluación:

1. Remuestrear la muestra de evaluación muchas veces (por ejemplo, 200).
2. Cada vez, recalcular la curva Qini y el AUUC de cada modelo.
3. Reportar el AUUC con su intervalo, y la diferencia entre modelos con el suyo.

Esto evita confiar en un solo número que puede ser ruidoso.

***Embeddings* como covariables.** Con texto, imágenes u otros datos no estructurados se pueden usar *embeddings* (representaciones numéricas) como covariables X para estimar

Algoritmo

Entrada: $\hat{\tau}_k(x_i)$ para cada acción $k = 1, ..., K$ y cada unidad $i = 1, ..., N$; costos c_k; presupuesto B; precio de equilibrio $\lambda_0 \geq 0$ ($1/v$ si se conoce el valor monetario v del resultado, 0 si el presupuesto es la única restricción); tolerancia δ.
Salida: Asignación $\pi(x) \in \{0, 1, ..., K\}$ que maximiza el uplift total sujeto a $\sum_{i=1}^{N} c_{\pi(x_i)} \leq B$.
Para cada λ, definir $\pi_\lambda(x) = \text{argmax}_k s_k(x)$ con $s_k(x) = \hat{\tau}_k(x) - \lambda \cdot c_k$ y $s_0(x) = 0$ (no tratar), y $G(\lambda) = \sum_{i=1}^{N} c_{\pi_\lambda(x_i)}$ su gasto.
if $G(\lambda_0) \leq B$ **then return** π_{λ_0} (el presupuesto no ata).

$\lambda_{\min} \leftarrow \lambda_0$, $\lambda_{\max} \leftarrow \max_{i,k} \hat{\tau}_k(x_i)/c_k$ (con $\lambda_{\max}$ nadie recibe tratamiento).
repeat hasta $\lambda_{\max} - \lambda_{\min} < \delta$:
  $\lambda \leftarrow \frac{\lambda_{\min} + \lambda_{\max}}{2}$
  if $G(\lambda) > B$ **then** $\lambda_{\min} \leftarrow \lambda$
  else guardar π_λ como mejor asignación factible y $\lambda_{\max} \leftarrow \lambda$
return la mejor asignación factible guardada.

Algoritmo 15. Asignación por net score con presupuesto

el CATE. Un *embedding* puede ser un proxy de variables sensibles como género o raza, de modo que su uso requiere la revisión de equidad que el Capítulo 23 desarrolla.

22.3 Algoritmo: asignación por net score con presupuesto

Resolver la asignación óptima de tratamientos con costos distintos y un presupuesto limitado requiere un enfoque de optimización. El método de *net score* introduce un costo sombra λ que equilibra el beneficio marginal del tratamiento con su costo.

El problema formal: hay K tratamientos con costos c_k y un presupuesto B. Se quiere asignar a cada persona la acción que maximice el uplift neto (beneficio menos costo sombra) sin exceder B.

El parámetro λ es el multiplicador de Lagrange (costo sombra) de la restricción presupuestaria. Cuando $\lambda = 0$, el algoritmo asigna según el uplift bruto; al aumentar λ, se penalizan los tratamientos costosos, favoreciendo acciones más baratas. La bisección es válida porque el gasto $G(\lambda)$ no crece con λ (a un precio mayor, ningún cliente pasa a una acción más cara), y converge al menor λ cuya asignación cabe en el presupuesto. Como el gasto cambia a saltos con λ (cada cliente pasa de una acción a otra de golpe), ese valor puede dejar sin usar una pequeña parte del presupuesto.

La solución de net score es equivalente a resolver

$$\pi^*(x) = \text{argmax}_k \{\tau_k(x) - \lambda^* c_k(x)\}, \tag{22.5}$$

donde λ^* es el costo sombra que agota el presupuesto B. Nótese que λ^* no es una penalización de regularización (como en LASSO), sino el precio implícito de relajar la restricción presupuestaria en una unidad. Con una sola acción, $\tau(x) - \lambda c \geq 0$ equivale a $\tau(x)/c \geq \lambda$, de modo

que el net score trata a los clientes cuyo retorno por dólar supera el costo sombra: reproduce el orden de la mochila fraccionaria. Con varias acciones, compara entre sí las acciones de cada cliente. Con dos acciones de costos $c_s < c_l$, la acción cara se prefiere a la barata cuando $\tau_l(x) - \tau_s(x) > \lambda(c_l - c_s)$, y a no tratar cuando $\tau_l(x) > \lambda c_l$: la acción cara solo se justifica donde su uplift adicional paga la diferencia de costo a precio λ.

Caso canónico · Un presupuesto entre dos acciones

Mismos clientes y brazos, con heterogeneidad marcada: retención basal $0.40 + 0.08x_2$, $\tau_{\text{SMS}} = 0.06 - 0.16x_0 + 0.08x_1$ y $\tau_{\text{llamada}} = 0.12 + 0.30x_1 - 0.10x_3$. El uplift de cada acción se estima contra el control con un T-learner suave (profundidad 2, 100 árboles) sobre el 60 % de la muestra y se evalúa en el *hold-out* de 2 000 clientes. Costos de 0,5 y 8 dólares: tratar a todos con SMS cuesta 1 000 y llamar a todos, 16 000. Con un presupuesto de 4 000, el uplift total que las tres estrategias logran, medido con los efectos verdaderos (que solo se conocen porque los datos son sintéticos), es:

Estrategia	Gasto	Tratados	Uplift estimado	Uplift verdadero
A: solo SMS, a los de mayor $\hat{\tau}_{\text{SMS}}$	687	69 % SMS	165,6	142,4
B: solo llamadas, a los de mayor $\hat{\tau}_{\text{llamada}}$	4 000	25 % llamada	162,0	164,0
C: *net score*	3 999	54 % SMS y 22 % llamada	278,3	255,8

La estrategia C supera a las otras dos y el multiplicador hace transparente por qué: con $\lambda^* \approx 0.022$, la llamada solo se asigna donde su uplift supera al del SMS en más de $7.5 \times 0.022 \approx 0.17$ (y supera a no tratar), y el SMS barato se usa en el resto. Las estrategias A y B fijan la acción de antemano y solo optimizan a quién alcanzar; C optimiza conjuntamente ambas decisiones, que es el problema real. A gasta apenas 687, porque mandar SMS a todos los clientes con uplift positivo estimado no agota el presupuesto, y B solo alcanza al 25 % con llamadas.

Hay una segunda lectura, menos cómoda. El uplift estimado de C (278,3) supera en 9 % al verdadero (255,8), y el de A (165,6) en 16 % al suyo (142,4). La asignación elige justo a los clientes donde el error de estimación es favorable, de modo que la cifra proyectada es optimista aunque el modelo esté bien calibrado en promedio. Para reportar el beneficio de la campaña no sirve la misma muestra con la que se asignó: hace falta un grupo de control retenido o un segundo *hold-out*.

La figura 22.1 resume el caso en dos paneles. El izquierdo ordena a los clientes del *hold-out* por uplift estimado y acumula su uplift verdadero. El derecho compara las tres estrategias a distintos presupuestos.

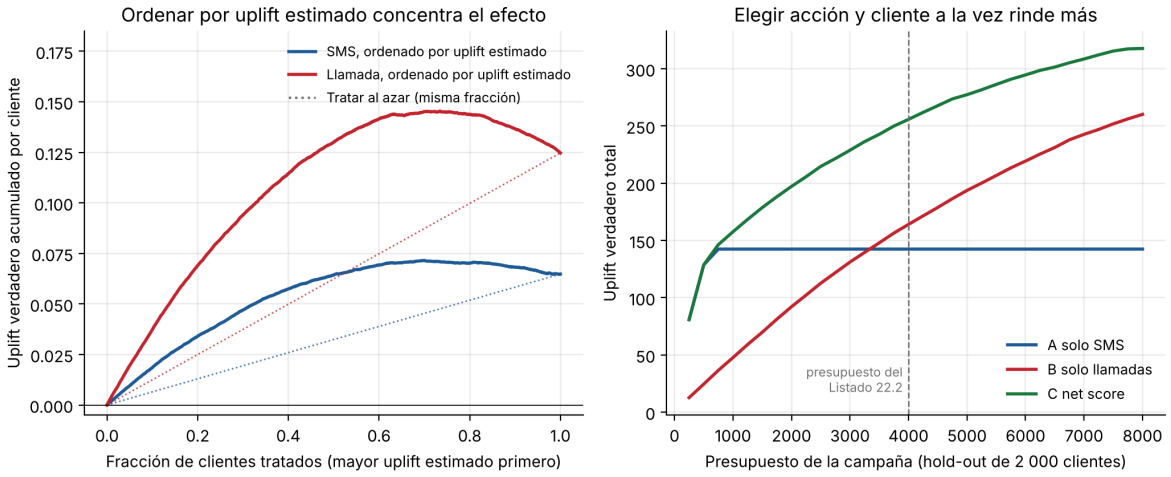


Figura 22.1: Izquierda: uplift verdadero acumulado al tratar primero a los clientes de mayor uplift estimado (línea continua) frente a tratar al azar (línea punteada), para SMS y llamada. Derecha: uplift verdadero total de las estrategias A, B y C según el presupuesto; la línea vertical marca el presupuesto del caso canónico (4 000). Datos sintéticos con semilla fija ($n = 5\,000$, *hold-out* de 2 000 clientes, T-learner con *gradient boosting*). El script que genera la figura está en el material de verificación.

Interpretación. En el panel izquierdo, tratar al 20 % de clientes con mayor uplift estimado captura el 53 % del uplift total verdadero en el caso del SMS y el 55 % en el de la llamada, más del doble de lo que lograría una selección al azar. Las curvas alcanzan su máximo cerca del 70 % de los clientes y luego descienden: entre el 28 % y el 29 % de los clientes tiene uplift verdadero negativo, de modo que tratar a todos rinde menos que tratar a los mejores. Esa caída es lo que justifica el *targeting*, y es invisible para quien solo mira el uplift promedio.

En el panel derecho, la estrategia C rinde al menos tanto como A y B en todo el rango de presupuestos. La estrategia A se estanca desde un presupuesto de 750, porque solo hay SMS útiles para una parte de los clientes y mandar más no suma uplift. La estrategia B parte muy por debajo, porque cada llamada consume 16 veces lo que cuesta un SMS, y supera a A recién desde un presupuesto de 3 500. C combina lo mejor de ambas: con presupuestos bajos reparte SMS, y a medida que el presupuesto crece incorpora llamadas donde su uplift adicional lo justifica.

Un principio sostiene el diseño del estimador y no puede dejar de enunciarse: no existe forma de derivar $\tau_{\text{llamada}}(x)$ a partir de $\tau_{\text{SMS}}(x)$ escalándolo por un factor. Cada acción tiene su propio efecto heterogéneo, con su propio patrón, y estimarlo requiere que los datos contengan variación en esa acción. Si el histórico solo tiene SMS, no hay uplift de llamada que estimar. Cada uplift se estima contra el brazo de control sobre su propia muestra y solo después se predice sobre toda la población: comparar directamente el brazo de SMS contra el de llamada estimaría $\tau_{\text{llamada}} - \tau_{\text{SMS}}$, una diferencia de efectos que responde otra pregunta («¿cuánto mejor es llamar que enviar un SMS?») y que no sirve para el problema de asignación, donde la alternativa relevante de cada acción es **no hacer nada**.

22.4 Aplicación con Python

22.4.1 Uplift modeling con causalml

La biblioteca `causalml` (Chen et al. 2020) proporciona implementaciones de meta-learners (S-, T-, X-, R- y DR-learner) y herramientas de validación como la curva Qini y el AUUC. El siguiente listado muestra un flujo completo de estimación y evaluación **con los dos tratamientos del caso** (SMS y llamada), porque el análisis de costo-efectividad requiere una estimación de uplift **por acción**, no una sola.

```
import numpy as np
import pandas as pd
from sklearn.model_selection import train_test_split
from xgboost import XGBRegressor
from causalml.inference.meta import BaseTRegressor
from causalml.metrics import plot_qini, qini_score

FEATURES = [f"x{i}" for i in range(8)]

def make_churn_data(n=5000, seed=42):
    """DGP sintetico de churn con TRES brazos: control, SMS, llamada.

    Los dos tratamientos tienen patrones de heterogeneidad distintos --
    ese es justamente el punto: no se derivan uno del otro.
    """
    rng = np.random.default_rng(seed)
    X = rng.uniform(-1, 1, (n, 8))
    # Asignacion a tres brazos (aleatoria: es una campana experimental)
    arm = rng.choice(["control", "sms", "call"], size=n, p=[0.4, 0.3, 0.3])
    tau_sms = 0.06 - 0.16 * X[:, 0] + 0.08 * X[:, 1]    # uplift del SMS (a
algunos les hace dano)
    tau_call = 0.12 + 0.30 * X[:, 1] - 0.10 * X[:, 3]   # uplift de la llamada
    base = 0.40 + 0.08 * X[:, 2]                         # retencion basal
    p = base + (arm == "sms") * tau_sms + (arm == "call") * tau_call  # queda
dentro de (0, 1)
    Y = (rng.uniform(size=n) < p).astype(int)
    df = pd.DataFrame(X, columns=FEATURES)
    df["y"], df["arm"] = Y, arm
    df["tau_sms_true"], df["tau_call_true"] = tau_sms, tau_call  # solo eval.
    return df

df = make_churn_data(5000)

# El uplift se estima en train y se evalua en test. Evaluar el ranking en la
misma
# muestra donde se ajusto el modelo premia el sobreajuste, no la capacidad de
ordenar.
```

```
train, test = train_test_split(df, test_size=0.4, random_state=0)
test = test.copy()

def uplift_por_accion(train, test, accion, features=FEATURES):
    """Estima tau_accion(x) contra el brazo de control, con datos de train.

    Se restringe la muestra a {control, accion}: comparar dos brazos
    activos entre si estimaria una diferencia de efectos, no un uplift.
    """
    sub = train[train["arm"].isin(["control", accion])]
    learner = BaseTRegressor(learner=XGBRegressor(max_depth=2,
n_estimators=100,
                                                  learning_rate=0.05))
    learner.fit(X=sub[features].values,
                treatment=(sub["arm"] == accion).astype(int).values,
                y=sub["y"].values)
    return learner.predict(test[features].values).ravel()  # sobre TODO el
hold-out

# Un estimador por accion -> dos columnas de uplift, ambas estimadas
test["uplift_sms"] = uplift_por_accion(train, test, "sms")
test["uplift_call"] = uplift_por_accion(train, test, "call")

# Evaluacion de ranking, por accion, sobre su propia submuestra del hold-out
for accion in ["sms", "call"]:
    sub = test[test["arm"].isin(["control", accion])].copy()
    sub["treatment"] = (sub["arm"] == accion).astype(int)
    col = f"uplift_{accion}"
    q = qini_score(sub[["y", "treatment", col]],
                   outcome_col="y", treatment_col="treatment")[col]
    print(f"{accion:>5}: Qini (hold-out) = {q:.4f}")

sub_sms = test[test["arm"].isin(["control", "sms"])].copy()
sub_sms["treatment"] = (sub_sms["arm"] == "sms").astype(int)
plot_qini(sub_sms[["y", "treatment", "uplift_sms"]],
          outcome_col="y", treatment_col="treatment")
```

Listado 22.1: Uplift modeling multi-tratamiento con `causalml`: un estimador por acción.

Las cifras de los casos canónicos salen de una réplica con *learners* equivalentes de scikit-learn (un T-learner propio con `GradientBoostingRegressor` y el área de la curva Qini calculada sobre datos aleatorizados), porque XGBoost y `causalml` no están en el entorno de verificación; con otros *learners* los números cambian, la conclusión no. La simulación está en `herramientas/verificaciones/verif_cap22.py`. En el caso del Qini dentro de muestra frente a *hold-out*, la configuración que lo exhibe (heterogeneidad débil, profundidad 3, 200 árboles) no es la del listado, que usa la heterogeneidad marcada y el modelo suave del segundo caso.

22.4.2 Costo-efectividad: tres estrategias

El listado 22.2 implementa la comparación de tres estrategias de targeting (SMS, llamada y mixta) con el algoritmo de net score, con $\lambda_0 = 0$.

> **Nota:** El siguiente ejemplo es **ilustrativo con datos simulados**. En un caso real, `uplift_sms` y `uplift_call` se estiman mediante un X-learner u otro meta-learner (Capítulo 12) entrenado en datos históricos con tratamientos observados.

```
# Costos unitarios y presupuesto de la campana, sobre el hold-out del listado
anterior
COSTOS = {"nada": 0.0, "sms": 0.5, "call": 8.0}
BUDGET = 4_000   # con n = 2 000: llamar a todos costaria 16 000; mandar SMS a
todos, 1 000

def uplift_total(df, asignacion, col_sms, col_call):
    """Uplift esperado y gasto de una asignacion accion-por-cliente."""
    u = np.where(asignacion == "sms", df[col_sms],
        np.where(asignacion == "call", df[col_call], 0.0))
    gasto = np.array([COSTOS[a] for a in asignacion]).sum()
    return u.sum(), gasto

d = test.reset_index(drop=True)
n = len(d)

def top_con_presupuesto(uplift, costo, budget):
    """A los de mayor uplift, mientras alcance el presupuesto y el uplift
estimado sea positivo."""
    k = min(int(budget / costo), int((uplift > 0).sum()))
    return uplift.argsort()[::-1][:k]

# --- Estrategia A: solo SMS, a los de mayor uplift_sms ---
asig_a = np.full(n, "nada", dtype=object)
asig_a[top_con_presupuesto(d["uplift_sms"].to_numpy(), COSTOS["sms"], BUDGET)]
= "sms"

# --- Estrategia B: solo llamadas, a los de mayor uplift_call ---
asig_b = np.full(n, "nada", dtype=object)
asig_b[top_con_presupuesto(d["uplift_call"].to_numpy(), COSTOS["call"],
BUDGET)] = "call"

# --- Estrategia C: net score con costo sombra (Algoritmo de la seccion
#     anterior). Bisecta lambda hasta agotar el presupuesto sin pasarse. ---
def asignar_net_score(df, budget, tol=1e-6, max_iter=80):
    """Devuelve la asignacion factible (gasto <= budget) con el menor costo
sombra hallado."""
```

```
    u_sms, u_call = df["uplift_sms"].to_numpy(), df["uplift_call"].to_numpy()
    lo = 0.0
    hi = max(u_sms.max() / COSTOS["sms"], u_call.max() / COSTOS["call"])  # con
lam = hi nadie recibe nada
    mejor = np.full(len(df), "nada", dtype=object)
    for _ in range(max_iter):
        lam = (lo + hi) / 2
        scores = np.column_stack([
            np.zeros(len(df)),                        # no hacer nada
            u_sms - lam * COSTOS["sms"],
            u_call - lam * COSTOS["call"],
        ])
        asig = np.array(["nada", "sms", "call"], dtype=object)
[scores.argmax(axis=1)]
        gasto = np.array([COSTOS[a] for a in asig]).sum()
        if gasto <= budget:
            mejor, hi = asig, lam    # factible: probar un costo sombra menor
        else:
            lo = lam                 # se pasa del presupuesto: subir el costo
sombra
        if hi - lo < tol:
            break
    return mejor

asig_c = asignar_net_score(d, BUDGET)

for nombre, asig in [("A (solo SMS)", asig_a), ("B (solo llamadas)", asig_b),
                     ("C (net score, mixto)", asig_c)]:
    u_est, gasto = uplift_total(d, asig, "uplift_sms", "uplift_call")
    u_ver, _ = uplift_total(d, asig, "tau_sms_true", "tau_call_true")  # solo
por ser sintetico
    print(f"Estrategia {nombre:22s} gasto={gasto:8.1f}  "
          f"uplift estimado={u_est:7.1f}  uplift verdadero={u_ver:7.1f}")
```

Listado 22.2: Análisis costo-efectividad: tres estrategias sobre el *hold-out* y las columnas de uplift estimadas en el listado 22.1.

Una advertencia sobre los datos de esta sección: la versión previa de los listados usaba un presupuesto de 100 000 dólares con 5 000 clientes, que nunca ata (llamar a todos cuesta 40 000), de modo que las estrategias A y B terminaban tratando a todos y el costo sombra se quedaba en cero. El presupuesto de 4 000 sobre el *hold-out* de 2 000 clientes es lo que hace que la restricción sea efectiva y que la comparación sea informativa.

22.5 Riesgos, límites y mitigación

El uso de uplift modeling para targeting con múltiples tratamientos y restricciones presupuestarias presenta riesgos metodológicos que deben diagnosticarse y mitigarse.

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Multiplicar el uplift de una acción para inferir el de otra	Comparación inválida entre acciones y política subóptima	Verificar que cada tratamiento tiene su propia estimación de $\hat{\tau}_k$ en los datos	Estimar $\tau_k(x)$ por separado para cada acción k, contra el control
Evaluar el ranking en la muestra de ajuste	Un ranking de ruido parece útil (caso canónico «El mismo modelo, dos evaluaciones»)	Comparar el Qini dentro y fuera de muestra	Evaluar siempre en datos retenidos; *bootstrap* sobre la muestra de evaluación
Optimizar solo el ranking sin validar la magnitud	Mala calibración: el gasto real no coincide con el proyectado	Comparar la calibración del CATE con el *transformed outcome*	Reportar ranking y calibración; usar el *transformed outcome* para magnitudes insesgadas
Proyección optimista del beneficio	El uplift proyectado de la política elegida supera al real (9 % en el caso canónico)	Comparar el uplift proyectado con el medido en un grupo retenido	Medir el beneficio en un control retenido o en un segundo *hold-out*, no en la muestra de asignación
Costos mal medidos o costos hundidos	Política errónea; se gasta en acciones con retorno negativo	Sensibilidad de la política a c_k variando ± 20 %	Costos reales (contables u operativos) e incertidumbre por *bootstrap*
Datos históricos no aleatorizados	El uplift confunde el efecto de la acción con la regla con que se asignó	Revisar cómo se asignó cada acción y el solape por brazo	Experimento de asignación aleatoria para entrenar; ponderación por propensión si no es posible

Tabla 22.1: Riesgos comunes en uplift modeling y targeting.

Además de los riesgos anteriores, es importante considerar la equidad: una estrategia que maximiza el uplift puede excluir sistemáticamente a grupos vulnerables. Se recomienda reportar la distribución demográfica de los tratados y evaluar si existen disparidades injustificadas en la asignación.

22.6 Ejercicios propuestos

22.6.1 Ejercicios teóricos

1. Muestre que, con una sola acción de costo $c > 0$, la regla $\tau(x) - \lambda c \geq 0$ equivale a $\tau(x)/c \geq \lambda$, y explique por qué ordenar por τ/c resuelve el problema de la mochila fraccionaria con un presupuesto.
2. Con dos acciones de costos 0,5 y 8, derive las dos condiciones del net score para asignar la llamada y compruebe el umbral de 7.5λ del caso canónico. Si $\lambda^* = 0.022$, ¿qué diferencia de uplift entre llamada y SMS hace falta?

3. Un modelo de uplift tiene un AUUC excelente. Si se multiplica $\hat{\tau}_{\text{llamada}}$ por 3, ¿cambia su Qini? ¿Cambia la asignación por net score para un presupuesto dado? Relacione el resultado con la distinción entre ranking y calibración de la Sección 22.2.1.
4. Explique por qué el uplift proyectado de la política elegida es optimista aunque el modelo sea insesgado en promedio. Dé un ejemplo de dos clientes con el mismo uplift verdadero y errores de estimación distintos, y explique por qué un segundo *hold-out* corrige el problema.
5. Con dos acciones, la de mayor efecto promedio puede no ser la que conviene a un cliente concreto. Dé las condiciones, en términos del net score, bajo las que a un cliente le conviene la acción de menor efecto promedio.
6. Discuta: ¿en qué casos el uplift modeling es preferible al policy learning formal?

22.6.2 Ejercicios computacionales

1. Replique el listado 22.1 sobre `thornton_hiv` (un solo tratamiento). ¿Cuál es el Qini score?
2. Sobre el DGP del listado 22.1, compare el uplift promedio de cada acción ($\overline{\tau}_{\text{SMS}}$ frente a $\overline{\tau}_{\text{llamada}}$) con el ranking que produce cada una. Verifique que la acción con mayor efecto promedio **no** es necesariamente la que conviene asignar a cada cliente.
3. Verifique la calibración de ambos estimadores de uplift contra los valores verdaderos (`tau_sms_true`, `tau_call_true` del DGP). Luego multiplique artificialmente `uplift_call` por 3 y vuelva a correr el listado 22.2. ¿Cambia el Qini de esa acción? ¿Cambia la asignación óptima y el gasto?
4. Modifique el listado 22.2 para imponer la restricción de tratar al menos al 20 % de cada grupo demográfico. ¿Cómo cambia el uplift total?

22.7 Lecturas complementarias

Radcliffe (2007) introduce la curva Qini en el contexto de marketing directo, que es donde nace toda esta literatura. Rzepakowski y Jaroszewicz (2012) desarrollan los árboles de uplift con criterios de división específicos (basados en divergencias entre las distribuciones de respuesta de tratados y controles) y son la referencia canónica del caso multi-tratamiento tratado en la Sección 22.2.3. Gutierrez y Gérardy (2017) revisan la literatura y conectan el vocabulario de uplift de la industria con el de inferencia causal académica; es una lectura recomendada para quien llegue desde cualquiera de los dos lados. Chen et al. (2020) documentan `causalml`, la librería de Uber usada en este capítulo. Para policy learning con restricciones presupuestarias tratado formalmente, (Athey y Wager 2021) y el Capítulo 21.

PARTE VI

Explicación, equidad y decisión estructural

Esta parte formaliza la equidad algorítmica como un problema de descomposición causal por rutas, que distingue la discriminación directa de la mediación legítima, la complementa con las herramientas más usadas de interpretabilidad y auditoría, generaliza el problema de decisión más allá de la asignación binaria de tratamiento, y cierra con la teoría formal de transportabilidad: cuándo un efecto estimado en un dominio es válido en otro.

CAPÍTULO 23

Explicación causal y equidad algorítmica

Cuadro sinóptico del capítulo

Problema:	Descomponer el efecto de un atributo protegido en rutas directas e indirectas
Estimando:	Efecto total, directo controlado (CDE), directo e indirecto naturales (NDE, NIE) y efectos específicos por ruta
Identificación:	Grafo causal con rutas etiquetadas como legítimas o no, e ignorabilidad secuencial
Método:	Fórmulas de mediación de Pearl; equidad contrafactual; discriminación por proxy y no resuelta
Garantía:	Descomposición exacta del efecto total en directo más indirecto, bajo el grafo y las ignorabilidades supuestas
Librerías:	dowhy (estimación de mediación)
Validación:	Sensibilidad al grafo de rutas propuesto y a confusores mediador-resultado

23.1 Problema causal, estimando e identificación

El Capítulo 24, que sigue a este capítulo, trata la interpretabilidad en el sentido más difundido en *machine learning*: explicaciones locales que atribuyen una predicción a sus variables de entrada por su contribución estadística. Ese tipo de explicación es **asociativa**: describe cómo covarían las variables con la salida del modelo, no si esa covariación refleja un mecanismo causal legítimo o discriminatorio. Este capítulo se ubica en la tradición de la equidad causal y pregunta algo distinto y más difícil: si un algoritmo de decisión (contratación, crédito, libertad condicional) produce resultados distintos según un atributo protegido (género, raza, origen),

¿ese efecto pasa por una ruta legítima o por una discriminatoria? Responderlo exige descomponer el efecto total en sus componentes causales por ruta, y no solo medirlo.

23.2 Teoría, supuestos y garantías

23.2.1 Efectos directos, indirectos y espurios

Sea A un atributo protegido (por ejemplo, género), M un mediador que A afecta (por ejemplo, la elección de ocupación) e Y el resultado (por ejemplo, el salario). Con resultados potenciales $Y(a, m)$ y $M(a)$, se definen cuatro efectos.

Definición 23.1 ***(Descomposición directo e indirecto)***

- **Efecto total:** $\mathrm{TE} = E[Y(1, M(1)) - Y(0, M(0))]$.
- **Efecto directo controlado:** $\mathrm{CDE}(m) = E[Y(1, m) - Y(0, m)]$, el efecto de A sobre Y cuando el mediador se fija en m.
- **Efecto directo natural:** $\mathrm{NDE} = E[Y(1, M(0)) - Y(0, M(0))]$, el efecto de A cuando el mediador se mantiene en el valor que tendría sin cambiar A.
- **Efecto indirecto natural:** $\mathrm{NIE} = E[Y(1, M(1)) - Y(1, M(0))]$, la parte que pasa por el cambio que A induce en M.

Con estas definiciones $\mathrm{TE} = \mathrm{NDE} + \mathrm{NIE}$.

La pregunta de equidad no es si el efecto total de A sobre Y es distinto de cero. Eso puede ser enteramente legítimo si el efecto pasa por una ruta que la organización considera aceptable, por ejemplo si hombres y mujeres eligen, en promedio, ocupaciones distintas por preferencia genuina y esas ocupaciones pagan distinto. La pregunta es qué parte del efecto viaja por rutas que no se aceptan. El efecto directo, la parte de A sobre Y que no pasa por ningún mediador, es el indicio causal del **trato diferencial directo**, la noción más estricta de discriminación. Las rutas indirectas por mediadores que la organización no acepta como legítimos también cuentan, y cuáles son es una decisión normativa.

La descomposición solo es válida bajo supuestos que el grafo declara.

Proposición 23.2 ***(Identificación de la descomposición)***

Sean X las covariables previas a A. Si (i) $Y(a, m) \perp\!\!\!\perp A \mid X$ (sin confusión de A con el resultado) y (ii) $Y(a, m) \perp\!\!\!\perp M \mid A, X$ (sin confusión del mediador con el resultado), entonces

$$\mathrm{CDE}(m) = E_X[E[Y \mid A = 1, M = m, X] - E[Y \mid A = 0, M = m, X]]. \tag{23.1}$$

Si además (iii) $Y(a, m) \perp\!\!\!\perp M(a') \mid X$ para $a \neq a'$ (independencia entre mundos) y $M(a) \perp\!\!\!\perp A \mid X$, entonces

$$\begin{aligned} \mathrm{NDE} &= \sum_{x,m} (E[Y \mid 1, m, x] - E[Y \mid 0, m, x]) P(m \mid 0, x) P(x), \\ \mathrm{NIE} &= \sum_{x,m} E[Y \mid 1, m, x] (P(m \mid 1, x) - P(m \mid 0, x)) P(x). \end{aligned} \tag{23.2}$$

En un modelo lineal sin interacción $A \times M$, con $M = \gamma A + ...$ e $Y = \delta A + \beta M + ...$, el efecto directo es δ y el indirecto es $\beta\gamma$.

La condición (ii) es la que más se incumple en la práctica: cualquier causa común de M e Y que no se observe, como el entorno familiar que influye en la ocupación y en el salario, invalida el efecto directo estimado. La condición (iii) no se puede contrastar ni siquiera con un experimento sobre A y M, porque involucra resultados de mundos distintos; por eso los efectos naturales exigen más fe en el modelo que el efecto directo controlado.

23.2.2 Equidad contrafactual

Kusner et al. (2017) formaliza una noción de equidad en el Nivel 3 de la jerarquía causal de Pearl (Capítulo 3). Sea U el vector de variables latentes de un modelo estructural. Una decisión $\hat{Y}$ es **contrafactualmente justa** si, para todo x, a y a',

$$P\Big(\hat{Y}_{A\leftarrow a}(U) = y \mid X = x, A = a\Big) = P\Big(\hat{Y}_{A\leftarrow a'}(U) = y \mid X = x, A = a\Big), \tag{23.3}$$

es decir, si la decisión de un individuo no cambiaría en el mundo donde su atributo protegido fuera distinto, manteniendo fijo lo que no depende causalmente de A. Es una noción más exigente que la paridad demográfica o la igualdad de tasas de error, ambas puramente asociativas (Nivel 1), porque exige razonar sobre el mundo contrafactual de cada individuo y no solo sobre promedios poblacionales. Calcularla requiere un modelo estructural con el que inferir U a partir de lo observado, y por tanto supuestos que el análisis asociativo no necesita.

Kilbertus et al. (2017) desarrollan la contraparte de Nivel 2 con dos criterios operativos. Una decisión **no discrimina por proxy** si no cambia cuando se interviene sobre los **proxies**, las variables que se declaran sustitutos del atributo protegido (el código postal como proxy de raza, el patrón de compras como proxy de género): $P\big(\hat{Y} \mid \mathrm{do}(P = p)\big)$ no depende de p. Una decisión **no discrimina de forma no resuelta** si no existe una ruta dirigida de A a $\hat{Y}$ que no esté bloqueada por una **variable resolutora**, una variable cuya influencia sobre la decisión la organización acepta como no discriminatoria. Los dos criterios exigen declaraciones normativas previas (qué es proxy, qué es resolutora); lo técnico, y verificable, es comprobar en el grafo si se cumplen y neutralizar los proxies, algo que se puede hacer sin observar A.

La consecuencia para el diseño de un sistema en producción es directa. Ante un algoritmo que discrimina hay dos remedios de naturaleza distinta: uno **técnico**, que identifica los proxies en el grafo y los neutraliza, y uno **normativo**, que declara qué rutas se aceptan y que ningún método puede automatizar. Confundir ambos es el error característico de las auditorías que se limitan a quitar las variables sensibles del modelo: eliminan A y dejan intactos todos sus proxies, sin tocar ninguna de las dos fuentes reales del problema.

23.3 Procedimiento: auditoría causal de equidad

El paso de etiquetado es el único que no tiene forma estadística: una ruta aceptada o rechazada es un juicio legal, ético y organizacional. El procedimiento lo hace explícito **antes** de estimar, en vez de dejarlo implícito en la elección de los controles.

Algoritmo

Entrada: Decisión o resultado Y, atributo protegido A, datos con covariables, grafo causal propuesto.
Salida: Descomposición del efecto, lista de rutas aceptadas y rechazadas, y acciones correctivas.
Declarar el atributo protegido, la decisión y la población afectada.
Dibujar el grafo y **etiquetar cada ruta de A a Y** como aceptada (resolutora), proxy o no clasificada, con las partes interesadas.
Verificar las ignorabilidades de la proposición de la Sección 23.2.1 para el efecto que se quiere estimar y declarar las que no se cumplen.
Estimar el efecto total, el directo (CDE y, si (iii) es creíble, NDE) y el indirecto por cada mediador.
Analizar la sensibilidad a un confusor mediador-resultado y a mediadores omitidos.
Neutralizar los proxies en el modelo de decisión y recalcular la brecha.
return Descomposición, rutas declaradas, sensibilidad y acciones; todo documentado en la ficha del modelo (Capítulo 19).

Algoritmo 16. Auditoría causal de equidad

23.4 Casos canónicos y validación

Las cifras de los tres casos provienen de simulaciones con muestras de 200 000 observaciones, promediadas sobre 20 repeticiones en los dos primeros. El script es `herramientas/verificaciones/verif_cap23.py`.

Caso canónico · Mediación lineal: efecto directo e indirecto

A binaria con probabilidad $1/2$, $M = 0.5A + \varepsilon_M$ e $Y = 0.15A + 0.6M + \varepsilon_Y$, sin confusión. El efecto total verdadero es $0.15 + 0.6 \times 0.5 = 0.45$, el directo es 0,15 y el indirecto es $0.6 \times 0.5 = 0.30$. Estimados: efecto total 0,449 (diferencia de medias), efecto directo controlado 0,150 (coeficiente de A en la regresión de Y sobre A y M) y efecto indirecto 0,299 (la diferencia). La descomposición recupera lo que se sembró. Si M es una ocupación aceptada, dos tercios del efecto total son legítimos y un tercio (0,15) es discriminación directa.

Caso canónico · Un confusor mediador-resultado deforma el efecto directo

Mismo proceso, pero con una variable U no observada que afecta a M y a Y: $M = 0.5A + 0.8U + \varepsilon_M$, $Y = 0.15A + 0.6M + 0.8U + \varepsilon_Y$. El efecto total sigue siendo 0,45 y el directo verdadero 0,15. La regresión de Y sobre A y M da un efecto directo de **−0,045**: no solo está lejos del valor verdadero sino que tiene el signo opuesto, de modo que un auditor concluiría que el algoritmo favorece al grupo protegido cuando en realidad lo perjudica. Es la violación de la condición (ii) de la proposición de la Sección 23.2.1, y el error de signo es la razón por la que el análisis de sensibilidad a un confusor mediador-resultado no es opcional.

Caso canónico · Quitar el atributo no quita la brecha

El mérito S es independiente del atributo A. Un proxy $P = A + \varepsilon_P$ (por ejemplo, el código postal) y una etiqueta histórica $Y = S + 0.5P + \varepsilon$ que arrastra el proxy. Un modelo de decisión ajustado con A, S y P produce una brecha de 0,505 entre los grupos. Ajustado **sin A** (con S y P) la brecha es 0,504: eliminar la variable sensible no cambia nada, porque el proxy hace el mismo trabajo (coeficientes de S y P de 0,996 y 0,501). Neutralizar el proxy en la decisión, evaluando el modelo con P fijo en su media, reduce la brecha a 0,001.

El caso salarial de género es el ejemplo clásico de la literatura: el efecto total observado se descompone en una parte explicada por ocupación, experiencia y sector (efecto indirecto, cuya legitimidad es en sí misma objeto de debate normativo y no solo estadístico) y un residuo no explicado por esas variables (una aproximación al efecto directo). La descomposición de Oaxaca y Blinder, de la economía laboral, es un antecesor estadístico de la misma idea; el lenguaje de rutas añade la posibilidad de declarar, antes de estimar, qué mediadores se consideran legítimos.

23.5 Implementación en Python

```
import numpy as np

rng = np.random.default_rng(3)
n = 20_000

# A: atributo protegido (0/1). M: mediador legítimo (ocupación). Y: resultado
(salario).
# Efecto directo deliberado (discriminación) = 0.15; efecto indirecto = 0.6 *
0.5 = 0.30.
A = rng.binomial(1, 0.5, size=n)
M = 0.5 * A + rng.normal(size=n)
Y = 0.15 * A + 0.6 * M + rng.normal(size=n)

efecto_total = Y[A == 1].mean() - Y[A == 0].mean()

# CDE: en un modelo lineal sin interacción A x M coincide con el coeficiente de
A en Y ~ A + M.
# Se ESTIMA con los datos; no se usa el 0.15 del generador.
Z = np.column_stack([np.ones(n), A, M])
cde = np.linalg.lstsq(Z, Y, rcond=None)[0][1]

print(f"Efecto total A->Y:         {efecto_total:.3f}")
print(f"Efecto directo controlado: {cde:.3f}  (debería acercarse a 0.15)")
print(f"Efecto indirecto (vía M):  {efecto_total - cde:.3f}")
```

```
assert abs(cde - 0.15) < 0.05 and abs((efecto_total - cde) - 0.30) < 0.06   #
coherencia
```

Listado 23.1: Descomposición de efectos con un modelo estructural lineal simulado.

En un caso real, `dowhy` implementa estimadores de mediación que no requieren conocer el modelo estructural verdadero, siempre que el grafo de rutas, incluyendo cuáles se declaran legítimas, esté especificado.

23.6 Riesgos, límites y sensibilidad

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Declarar legítimo un mediador afectado históricamente por A	Se blanquea discriminación pasada (por ejemplo, acceso restringido a una ocupación por género)	Análisis histórico de cómo A determinó M	Revisar con las partes interesadas antes de aceptar el mediador
Tratar la legitimidad de una ruta como una cuestión estadística	Un juicio normativo se presenta como resultado técnico	Quién etiquetó las rutas y con qué criterio	Etiquetar antes de estimar y documentar la decisión
Confusor mediador-resultado no observado	El efecto directo estimado puede errar incluso en el signo (caso 2)	Análisis de sensibilidad al grado de confusión	Reportar un rango de efecto directo; no concluir con un valor puntual
Mediador omitido	Se infla o se deforma el efecto directo	Contrastar el grafo con datos adicionales	Ampliar el grafo; sensibilidad al grafo
Quitar solo la variable sensible	La brecha persiste por los proxies (caso 3)	Brecha de decisión con y sin A	Neutralizar los proxies identificados en el grafo

Tabla 23.1: Riesgos en el análisis causal de equidad.

Límites. Igual que en el Capítulo 8, toda la descomposición depende de que el grafo propuesto sea correcto. La equidad contrafactual exige además un modelo estructural completo, algo que pocos sistemas reales tienen. Y ningún análisis causal reemplaza la decisión normativa de qué se considera discriminación.

23.7 Ejercicios y notas bibliográficas

23.7.1 Ejercicios teóricos

1. Para el caso de la brecha salarial de género, proponga dos mediadores: uno que consideraría legítimo y uno que consideraría cuestionable aceptar como legítimo aun si estadísticamente media parte del efecto. Justifique la distinción normativa.

2. Explique por qué la equidad contrafactual de (Kusner et al. 2017) es una noción de Nivel 3 y no de Nivel 1, y por qué eso la hace más difícil de verificar que la paridad demográfica.
3. Para el modelo del segundo caso canónico, calcule el límite del coeficiente de A en la regresión de Y sobre A y M en función de los pesos de U, y verifique que vale $-0{,}045$. Sugerencia: aplique el teorema de Frisch-Waugh-Lovell.
4. Muestre que, en el caso de un modelo lineal sin interacción, $\text{NDE} = \text{CDE}(m)$ para todo m y $\text{NIE} = \beta\gamma$.
5. Explique por qué eliminar un proxy del conjunto de variables y neutralizarlo (evaluar el modelo con el proxy fijo) son operaciones distintas, y en qué situación darían el mismo resultado.

23.7.2 Ejercicio computacional

1. Modifique el listado 23.1 para que el efecto directo verdadero sea 0 y verifique numéricamente que el CDE estimado converge a 0 mientras el efecto indirecto permanece distinto de cero. Luego añada un confusor U entre M e Y y observe cómo cambia el CDE estimado.

23.7.3 Notas bibliográficas

Las fórmulas de mediación causal y la descomposición en efecto directo, indirecto y espurio se desarrollan en (Pearl 2009) y se sistematizan para la equidad algorítmica en (Bareinboim 2025). Kusner et al. (2017) introduce la equidad contrafactual como criterio formal de Nivel 3, y Kilbertus et al. (2017) la contraparte de Nivel 2 con la distinción entre proxy e influencia no resuelta que estructura la Sección 23.2.2. Plečko y Bareinboim (2024) sistematizan el análisis causal de equidad (efectos directos, indirectos y espurios) en una monografía de referencia. Los trabajos de Nabi y Shpitser y de Zhang y Bareinboim sobre efectos específicos por ruta separan la discriminación directa de la indirecta con mayor generalidad. El Capítulo 24 complementa este tratamiento causal con las definiciones observacionales estándar de la literatura de *fair machine learning* (paridad demográfica, *equalized odds*, calibración) y con el resultado de imposibilidad que muestra que no pueden satisfacerse a la vez. La integración de equidad y causalidad es un área activa de investigación.

CAPÍTULO 24

Ética, interpretabilidad y comunicación de resultados

Cuadro sinóptico del capítulo

Problema:	Equidad, interpretabilidad y comunicación en ML causal aplicado a políticas públicas
Estimando:	CATE por grupo demográfico, policy value, importancia de variables
Identificación:	No confusión, modelo causal del atributo protegido, SUTVA
Método:	Las tres familias canónicas (independencia, separación y suficiencia) y su incompatibilidad; equidad en el efecto; atribución de Shapley sobre un sustituto del CATE; policy trees
Nuisance:	$\mu_d(x), e(x)$, modelo de outcome
Garantía:	Identificación bajo supuestos; cobertura de IC bajo normalidad asintótica
Librerías:	`econml`, `shap`, `scikit-learn`
Validación:	Auditoría causal, placebos, counterfactual fairness

Nota técnica

El Capítulo 23 formalizó la equidad como una pregunta de descomposición causal por rutas. Este capítulo la complementa con la caja de herramientas más usada en la práctica, la atribución de importancia y las métricas de auditoría estándar, y con una advertencia central: esas herramientas explican el **modelo**, no necesariamente el **mecanismo causal** subyacente, una distinción que retoma directamente la del Capítulo 1 entre predicción y causa.

24.1 Motivación aplicada

Un ministerio usa un modelo de ML causal para decidir qué hogares reciben un subsidio. El modelo se entrenó sobre datos históricos que reflejan desigualdades preexistentes: los hogares encabezados por mujeres, las minorías étnicas y las zonas rurales tienen históricamente menor acceso a programas sociales. El modelo, al optimizar predicción sobre estos datos, puede perpetuar o amplificar esas desigualdades, un fenómeno conocido como *algorithmic bias*.

Este capítulo aborda tres dimensiones éticas del ML causal aplicado a políticas públicas: (i) sesgo algorítmico y equidad, (ii) interpretabilidad de modelos causales complejos y (iii) comunicación de incertidumbre a tomadores de decisión. Argumentamos que la calidad técnica de un modelo causal no se mide solo en su precisión estadística, sino en sus consecuencias sociales y en la transparencia con que se comunica.

24.2 Teoría, supuestos y garantías

24.2.1 Equidad causal

La literatura de *fair machine learning* ha convergido en **tres familias canónicas** de criterios observacionales, que Barocas et al. (2019) organizan según qué independencia estadística exigen entre la decisión $\pi(X)$, el atributo protegido G y el resultado relevante Y^*:

Definición 24.1 ***(Independencia (demographic parity))***

Una regla de asignación π satisface *demographic parity* (o paridad estadística) respecto a un atributo protegido G si $\pi(X) \perp\!\!\!\perp G$: la tasa de asignación es la misma en todos los grupos.

Definición 24.2 ***(Separación (equalized odds))***

π satisface *equalized odds* (Hardt et al. 2016) si $\pi(X) \perp\!\!\!\perp G \,|\, Y^*$: las tasas de verdaderos positivos y de falsos positivos coinciden entre grupos. La versión relajada que exige la igualdad solo sobre $Y^* = 1$ se conoce como *equality of opportunity*.

Definición 24.3 ***(Suficiencia (calibración por grupo))***

π (o el score que la genera) satisface *calibración por grupo* si $Y^* \perp\!\!\!\perp G \,|\, \pi(X)$: condicional a la puntuación asignada, la tasa base del resultado es la misma en todos los grupos.

Teorema 24.4 ***(Incompatibilidad de los criterios)***

Salvo en dos casos degenerados (predicción perfecta, o tasas base idénticas entre grupos, es decir, $P(Y^* = 1 \mid G = g)$ constante en g) **no existe** ninguna regla de decisión que satisfaga simultáneamente separación y suficiencia. Las tres familias son, en general, mutuamente incompatibles de a pares.

El resultado se debe a Chouldechova (2017) y, con otra formulación, a Kleinberg et al. (2017); Barocas et al. (2019) lo organizan en las tres familias. Es la pieza que más se omite al presentar el tema y la que más importa para un sistema en producción: **no hay una definición de**

equidad que se pueda «activar» en el pipeline. Elegir un criterio es descartar los otros, y esa elección es normativa (depende de qué error se considera más grave en el contexto concreto) y no se puede delegar en el equipo técnico. El resultado se hizo célebre a raíz del debate sobre COMPAS, donde una parte sostenía que el algoritmo era injusto (falsos positivos desiguales, criterio de separación) y otra que era justo (calibrado por grupo, criterio de suficiencia): ambas tenían razón bajo su criterio, y el teorema explica por qué la discusión no podía resolverse con más datos.

Caso canónico · Separación sin suficiencia

Dos grupos con tasas base 0,50 y 0,20. Un clasificador binario tiene en ambos grupos la misma tasa de verdaderos positivos (0,80) y la misma tasa de falsos positivos (0,10): satisface separación. Su valor predictivo positivo, la proporción de verdaderos positivos entre quienes reciben la etiqueta positiva, es

$$\mathrm{VPP}_1 = \frac{0.80 \times 0.50}{0.80 \times 0.50 + 0.10 \times 0.50} = 0.89, \quad \mathrm{VPP}_2 = \frac{0.80 \times 0.20}{0.80 \times 0.20 + 0.10 \times 0.80} = 0.67 \tag{24.1}$$

Una etiqueta positiva significa cosas distintas según el grupo: 89 de cada 100 positivos del primer grupo lo son de verdad, frente a 67 de cada 100 en el segundo. El clasificador no satisface suficiencia, y la única forma de igualar el valor predictivo sería aceptar tasas de error distintas entre grupos. Ningún ajuste de umbral resuelve esto porque las tasas base difieren.

Una advertencia adicional sobre el punto de partida de toda esta familia: Dwork et al. (2012) ya señalaron que la paridad demográfica es un criterio débil y manipulable (se puede satisfacer tratando bien a los miembros cualificados de un grupo y arbitrariamente a los del otro) y propusieron en su lugar la **equidad individual**: individuos similares respecto a una métrica de tarea deben recibir decisiones similares. Su límite práctico, reconocido por los propios autores, es que la métrica de similitud es exactamente lo difícil de especificar, y en ella se esconde el mismo juicio normativo que se pretendía evitar.

24.2.2 Del criterio observacional al criterio causal

Las tres familias anteriores son criterios de $\mathcal{L}_1$: se definen sobre la distribución conjunta observada, sin referencia a mecanismos. Un sistema **causal** admite además un criterio propio, que este libro usa como complemento y no como sustituto:

Definición 24.5 ***(Equidad en el efecto (equalized CATE))***

Una política satisface **equidad en el efecto** respecto a G si la distribución del CATE estimado $\hat{\tau}(X)$, y por tanto el beneficio esperado del tratamiento, es comparable entre grupos definidos por G.

Conviene ser explícitos sobre el estatus de esta definición: **no** pertenece al canon de la literatura de *fair ML* y no debe presentarse como si lo hiciera. Es una noción específica de sistemas de asignación causal, y responde a una pregunta que los tres criterios canónicos no formulan:

no «¿a quién se le asigna el tratamiento?» sino «¿quién se beneficia de él?». La distinción importa porque las dos preguntas pueden dar respuestas opuestas: una política puede satisfacer paridad demográfica en la asignación y, sin embargo, concentrar todo el beneficio real en un solo grupo, si el efecto es heterogéneo. Y tiene un límite serio que debe declararse: si el CATE es genuinamente menor en un grupo por razones estructurales (como en el caso de los hogares rurales de la Sección 24.4.1), **imponer** equidad en el efecto no es posible ni deseable; lo que la métrica aporta es hacer visible esa desigualdad estructural, no corregirla por decreto.

Kitagawa et al. (2021) formalizan el trade-off resultante: maximizar $V(\pi)$ sujeto a restricciones de equidad, de cualquiera de las familias anteriores, define un problema de **clasificación restringida** cuyas garantías de regret difieren de las del Capítulo 21 sin restricciones. El resultado operativo es que el costo en *welfare* de imponer equidad es cuantificable y debe reportarse: no como argumento contra la restricción, sino como el precio explícito de una decisión distributiva que alguien debe tomar a sabiendas.

24.2.3 Interpretabilidad

Los modelos de ML causal (bosques causales, modelos profundos) son cajas negras. Tres estrategias de interpretabilidad:

- **Atribución de Shapley.** Asigna a cada variable una contribución a la predicción, basada en los valores de Shapley de la teoría de juegos, que Lundberg y Lee (2017) llevaron a la explicación de modelos de aprendizaje.
- **Gráficos de dependencia parcial.** Muestran el efecto marginal de una variable sobre $\hat{\tau}$, promediando sobre las demás.
- **Policy trees.** Una vez aprendido un CATE, se aprende un árbol de decisión poco profundo sobre $\hat{\tau}$ para producir una regla interpretable.

¿Qué objeto se está explicando? Antes de aplicar cualquiera de las tres, hay que responder una pregunta que se salta con frecuencia y que invalida buena parte de las auditorías de interpretabilidad de modelos causales. Un estimador causal contiene **varios** modelos, y explicar el equivocado produce conclusiones sistemáticamente engañosas:

Modelo interno	Qué predice	Qué significa su atribución
$\hat{\mu}_Y$ (*outcome*)	$E[Y \mid X]$	Qué variables predicen el **resultado**. No dice nada sobre el efecto del tratamiento. Es el error más común.
$\hat{e}$ (*propensity*)	$E[D \mid X]$	Qué variables predicen **quién fue tratado**. Útil como diagnóstico de selección, no de efecto.
$\hat{\tau}$ (CATE)	$E[Y(1) - Y(0) \mid X]$	Qué variables explican la **heterogeneidad del efecto**. Es lo que casi siempre se quiere y casi nunca se calcula.

Aplicar la atribución a $\hat{\mu}_Y$ y presentarla como «las variables que más influyen en el efecto» es un error de categoría, no una aproximación tolerable: la edad puede ser el predictor dominante del salario y ser completamente irrelevante para la heterogeneidad del retorno a la educación. Para explicar el CATE hay que explicar el CATE. Como los estimadores de CATE suelen no exponer un modelo sobre el que la atribución pueda operar directamente, la vía practicable es ajustar un **modelo sustituto** (*surrogate*) sobre las predicciones $\hat{\tau}(X)$ y explicar ese, con la salvedad, que hay que reportar, de que se está explicando la aproximación y no el estimador.

Caso canónico · Dos rankings de importancia

Cinco covariables $x_0, ..., x_4$ independientes y uniformes en $[-1, 1]$, y un atributo protegido A binario e independiente, con $P(A = 1) = 0.3$. El resultado sin tratamiento depende solo de x_1, $Y(0) = 3x_1 + \varepsilon$, y el efecto es $\tau = 2 + 3x_0 - 1.5A$. Las varianzas se calculan exactamente: $\mathrm{Var}(3x_1) = \frac{9}{3} = 3.00$ para el resultado sin tratamiento y, para el efecto, $\mathrm{Var}(3x_0) = 3.00$ y $\mathrm{Var}(1.5A) = 1.5^2 \times 0.3 \times 0.7 = 0.47$, de modo que x_0 explica el 86 % de la heterogeneidad del efecto y A el 14 %. La variable x_1 no aporta nada.

Un ranking de importancia calculado sobre el modelo del resultado pone a x_1 en primer lugar. Un ranking calculado sobre el sustituto del CATE la deja en último y pone a x_0 y a A arriba. Reportar el primero bajo el título «qué determina el efecto del programa» dice algo falso sobre el mecanismo, y el segundo deja ver que el atributo protegido es fuente de heterogeneidad, que es lo que una auditoría de equidad necesita ver.

Dos cautelas más, sobre las que conviene ser explícito en cualquier informe. Primera: el sustituto explica $\hat{\tau}$, no τ; si el estimador de CATE está sesgado, la atribución explicará fielmente un artefacto. Segunda, y más de fondo: incluso una atribución correcta sobre el CATE es **asociativa dentro del modelo**, no causal sobre el mundo. Que x_0 explique la heterogeneidad no significa que intervenir sobre x_0 cambie el efecto del tratamiento; responder eso exige el aparato de rutas del Capítulo 23, no una atribución de importancia.

Un detalle del diseño del análisis importa tanto como el método: el atributo protegido tiene que entrar entre las covariables del estimador. Si afecta a la probabilidad de recibir el tratamiento y al efecto, como en el caso canónico, dejarlo fuera deja confusión sin controlar (el resultado con tratamiento depende de A y la asignación también) y, además, impide ver cualquier brecha entre grupos. Un análisis de equidad por grupo que no incluye al grupo entre las covariables no puede detectar la desigualdad que busca.

24.2.4 Comunicación de incertidumbre

El error más común al comunicar resultados causales a no técnicos es reportar solo el estimado puntual sin intervalo. La regla operacional: *todo número reportado debe acompañarse de una medida de incertidumbre.*

- Reportar intervalos al 95 % en formato «[lb, ub]».
- Para el CATE, reportar la distribución (histograma, mapa) y no solo el promedio.

Algoritmo

Entrada: Covariables X (con el atributo protegido A entre ellas), estimaciones $\hat{\tau}(x_i)$ del estimador de CATE y umbral de fidelidad ρ (por ejemplo 0,8).
Salida: Ranking de importancia para la heterogeneidad del efecto, con su fidelidad, o el aviso de que no es fiable.
Ajustar un modelo sustituto g sobre los pares $(x_i, \hat{\tau}(x_i))$.
Medir la fidelidad R^2 de g respecto de $\hat{\tau}$ por validación cruzada.
Si $R^2 < \rho$, avisar que el sustituto no reproduce el CATE y detenerse.
Calcular la atribución de Shapley de g para cada observación y promediar su valor absoluto por variable.
Normalizar las importancias y reportarlas junto con R^2, aclarando que se explica $\hat{\tau}$ y no τ.
return ranking e importancias normalizadas

Algoritmo 17. Atribución de importancia sobre un sustituto del CATE

Algoritmo

Entrada: Datos (Y, D, X, A), procedimiento completo de estimación del CATE y número de réplicas B.
Salida: Efecto medio por grupo con su intervalo, y un intervalo para la brecha entre grupos.
Para cada grupo g, estimar el efecto medio y su intervalo con el método del propio estimador, que propaga el error de estimación de los *nuisance*.
Para $b = 1, ..., B$: remuestrear las unidades con reemplazo, re-estimar el procedimiento completo y calcular la brecha $\hat{\delta}_b$ entre grupos.
Tomar los percentiles 2,5 y 97,5 de $\hat{\delta}_1, ..., \hat{\delta}_B$ como intervalo de la brecha.
return intervalos por grupo e intervalo de la brecha

Algoritmo 18. Brecha de efecto entre dos grupos con incertidumbre

- Distinguir afirmaciones predictivas («el modelo predice») de afirmaciones causales («el efecto causal estimado es»).

Una tabla de resultados mínima para quien decide tiene cuatro columnas: grupo, tamaño, efecto medio estimado e intervalo al 95 %. El intervalo se calcula con el método del propio estimador o con un bootstrap del procedimiento completo (Algoritmo 18), nunca con la dispersión de las estimaciones individuales, que mide la heterogeneidad dentro del grupo y no la incertidumbre de estimación.

24.3 Algoritmos e implementación

Los dos procedimientos del capítulo, la atribución sobre un sustituto del efecto y la comparación de grupos con incertidumbre, caben en pseudocódigo.

24.3.1 Atribución sobre un sustituto del efecto

24.3.2 Brecha entre grupos con incertidumbre

La diferencia con la versión ingenua no es un tecnicismo. Aplicar un t-test a los $\hat{\tau}_i$ trata las **predicciones** del modelo como si fueran observaciones independientes: ignora por completo que cada $\hat{\tau}_i$ arrastra el error de estimación de los *nuisance* y del bosque, y produce p-valores que pueden ser órdenes de magnitud demasiado pequeños. En una auditoría de equidad, ese

error tiene una consecuencia concreta y grave: declarar una brecha de efecto entre grupos como estadísticamente significativa cuando la evidencia no lo respalda, o, peor, sostener sobre esa base una decisión de asignación diferenciada por grupo protegido.

24.3.3 Interpretabilidad con SHAP

```
import shap
import numpy as np
import pandas as pd
from econml.dml import CausalForestDML
from sklearn.ensemble import GradientBoostingRegressor,
GradientBoostingClassifier

# Dataset simulado
rng = np.random.default_rng(42)
n = 5000
X = rng.uniform(-1, 1, (n, 5))
A = rng.binomial(1, 0.3, n)  # 30% es minoria
tau = 2 + 3*X[:, 0] - 1.5 * A
e = 0.4 + 0.2 * np.tanh(X[:, 0]) - 0.1 * A
D = (rng.uniform(size=n) < e).astype(int)
Y = 3 * X[:, 1] + D * tau + rng.standard_normal(n) * 0.5

# A entra como covariable: afecta al tratamiento y al efecto, asi que dejarla
# fuera confunde la estimacion y impide ver la brecha entre grupos.
XA = np.column_stack([X, A])
cf = CausalForestDML(model_y=GradientBoostingRegressor(random_state=42),
                     model_t=GradientBoostingClassifier(random_state=42),
                     discrete_treatment=True, random_state=42, cv=5).fit(Y, D,
X=XA)
cate_hat = cf.effect(XA)

nombres = [f"x{i}" for i in range(5)] + ["A"]

# --- (a) INCORRECTO: SHAP sobre el modelo de outcome -----------------
# Explica que variables predicen Y, NO que variables explican el efecto.
# Se incluye solo para contrastar; no reportar esto como "drivers del CATE".
# cf.model_y es la plantilla SIN ajustar; los modelos ajustados por
# fold de cross-fitting estan en cf.models_y[iteracion][fold].
expl_y = shap.TreeExplainer(cf.models_y[0][0])
shap_y = expl_y.shap_values(XA[:200])

# --- (b) CORRECTO: SHAP sobre un sustituto del CATE ------------------
# Se ajusta un modelo interpretable-por-SHAP a las predicciones tau(x)
# y se explica ESE. El R^2 del sustituto mide cuanta de la estructura
# del CATE se conserva: si es bajo, la explicacion no es fiable.
from sklearn.ensemble import RandomForestRegressor
```

```
from sklearn.model_selection import cross_val_score

surrogate = RandomForestRegressor(n_estimators=300, min_samples_leaf=20,
                                  random_state=42)
r2 = cross_val_score(surrogate, XA, cate_hat, cv=5, scoring="r2").mean()
surrogate.fit(XA, cate_hat)
print(f"Fidelidad del sustituto al CATE (R2 CV): {r2:.3f}")
if r2 < 0.8:
    print("ADVERTENCIA: el sustituto no reproduce bien el CATE; "
          "la atribucion SHAP sobre el es poco informativa.")

expl_tau = shap.TreeExplainer(surrogate)
shap_tau = expl_tau.shap_values(XA[:200])
shap.summary_plot(shap_tau, XA[:200], feature_names=nombres,
                  show=False)  # <- ESTE es el grafico a reportar

# Contraste explicito de los dos rankings de importancia
imp_y = np.abs(shap_y).mean(axis=0)
imp_tau = np.abs(shap_tau).mean(axis=0)
comparacion = pd.DataFrame({
    "feature": nombres,
    "importancia_para_Y": imp_y / imp_y.sum(),
    "importancia_para_CATE": imp_tau / imp_tau.sum(),
})
print(comparacion.sort_values("importancia_para_CATE", ascending=False))
# En este DGP tau = 2 + 3*x0 - 1.5*A y mu0 = 3*x1: el ranking para Y
# destaca x1, el ranking para el CATE destaca x0. Son distintos, y
# reportar el primero como si fuera el segundo es un error de categoria.
```

Listado 24.1: SHAP para Causal Forest.

El contraste final del listado no es decorativo: en este DGP, construido de modo que μ_0 dependa de x_1 y τ de x_0 y de A, los dos rankings de importancia señalan variables **distintas**. En la réplica de verificación (con sustitutos de `shap` y `econml`, porque no están instalados en el entorno de pruebas), x_1 concentró el 57 % de la importancia para Y y apenas el 1 % para el CATE, mientras que x_0 concentró el 72 % de la importancia para el CATE y A el 26 %. Esos porcentajes dependen del estimador y del sustituto, y con las librerías reales pueden variar; lo que no varía es el contraste, que ya se sigue de la construcción del caso canónico. En la misma réplica, sin A entre las covariables, el efecto medio estimado fue de 1,68 para la mayoría y de 1,61 para la minoría, frente a los efectos verdaderos de 2,00 y 0,52; con A incluida, los estimados fueron 2,00 y 0,53.

24.3.4 Tabla de resultados para policymakers

```
def format_results_for_policymakers(est, X, A=None, group_labels=None):
    """Genera tabla resumen con IC, distinguiendo grupos.
```

```
    NOTA: el IC de cada grupo se calcula con `est.ate_interval(X=X[A==g])`,
    que propaga el error de estimacion de los nuisance via la influence
    function del estimador (ver el capitulo de ortogonalidad). Un enfoque
    ingenuo -- usar la desviacion estandar de los CATE ESTIMADOS puntuales,
    como si fueran observaciones i.i.d. -- cuantifica la dispersion del
    efecto DENTRO del grupo, no la incertidumbre de estimacion, y produce
    intervalos demasiado estrechos (ver el listado de analisis de equidad).
    """
    rows = []
    if A is None:
        A = np.zeros(len(X), dtype=int)
    groups = np.unique(A)
    for g in groups:
        mask = A == g
        n_g = int(mask.sum())
        mean_g = est.ate(X=X[mask])
        lb, ub = est.ate_interval(X=X[mask], alpha=0.05)
        label = group_labels[g] if group_labels else f"Grupo {g}"
        rows.append({"Grupo": label, "n": n_g,
                     "CATE medio": f"{mean_g:.2f}",
                     "IC 95%": f"[{lb:.2f}, {ub:.2f}]"})
    return pd.DataFrame(rows)

df_comm = format_results_for_policymakers(cf, XA, A, {0: "Mayoria", 1:
"Minoria"})
print(df_comm.to_markdown(index=False))
```

Listado 24.2: Tabla de resultados para comunicación a tomadores de decisión.

24.3.5 Análisis de equidad

```
import scipy.stats as st

# --- Efecto promedio por grupo, con IC del ESTIMADOR ------------------
# Se usa ate_interval sobre el subconjunto de cada grupo: propaga la
# incertidumbre de estimacion via influence function, a diferencia de
# aplicar t-tests sobre los CATE puntuales (que trata predicciones como
# si fueran observaciones y produce IC demasiado estrechos).
for a in [0, 1]:
    mask = A == a
    ate_a = cf.ate(X=XA[mask])
    lb_a, ub_a = cf.ate_interval(X=XA[mask], alpha=0.05)
    print(f"Grupo A={a} (n={mask.sum()}): efecto medio = {ate_a:.3f} "
          f"(IC 95%: [{lb_a:.3f}, {ub_a:.3f}])")

# --- Contraste de la brecha entre grupos ------------------------------
```

```
# La brecha es un funcional del modelo; su incertidumbre se obtiene por
# bootstrap sobre el pipeline completo (re-estimando el bosque), no por
# un t-test sobre los cate_hat, que ignora el error de estimacion.
def brecha_bootstrap(Y, D, XA, A, B=200, seed=0):
    rng = np.random.default_rng(seed)
    n, brechas = len(Y), []
    for _ in range(B):
        idx = rng.integers(0, n, n)
        m = CausalForestDML(
            model_y=GradientBoostingRegressor(random_state=42),
            model_t=GradientBoostingClassifier(random_state=42),
            discrete_treatment=True, random_state=42, cv=3
        ).fit(Y[idx], D[idx], X=XA[idx])
        brechas.append(m.ate(X=XA[idx][A[idx] == 0]) - m.ate(X=XA[idx][A[idx]
== 1]))
    return np.percentile(brechas, [2.5, 97.5])

# lo, hi = brecha_bootstrap(Y, D, XA, A)   # costoso: B re-ajustes del bosque
# print(f"Brecha de efecto entre grupos, IC 95% bootstrap: [{lo:.3f},
{hi:.3f}]")
```

Listado 24.3: Análisis de equidad en policy learning.

24.4 Caso empírico y validación

24.4.1 Auditoría de equidad en focalización de transferencias

Suponga que, en un programa de transferencias hipotético (el libro no incluye sus datos y no hay cifras que reproducir), un bosque causal estima para los hogares rurales un CATE claramente menor que para los urbanos. Eso reflejaría no un sesgo del modelo, sino una desigualdad estructural: las transferencias tendrían menor efecto en hogares rurales por falta de acceso a mercados. La recomendación de política no es excluir hogares rurales (eso amplificaría la desigualdad), sino complementar las transferencias con inversión en infraestructura rural.

La auditoría incluye los siguientes pasos:

1. Estimar el CATE por grupo demográfico, con el atributo protegido entre las covariables.
2. Comparar el efecto medio por grupo con el intervalo del propio estimador o con el *bootstrap* del pipeline (Algoritmo 18); usar Kolmogorov-Smirnov solo como descriptivo de la distribución de $\hat{\tau}$.
3. Evaluar la sensibilidad de las diferencias a la inclusión de confusores adicionales.
4. Reportar resultados con intervalos de confianza y distinguir entre efecto causal y correlación.

Intuición

Caja de profundización: Equidad causal y explicaciones contrafactuales

Objetivo. Entender cómo la causalidad ayuda a evaluar si un modelo es justo.

¿Qué es equidad? No hay una definición única. Tres enfoques:

- **Demographic parity:** la tasa de tratamiento es igual entre grupos (ej: misma proporción de hombres y mujeres reciben el beneficio).
- **Equalized odds:** la tasa de tratamiento es igual entre grupos condicionando en la necesidad real (ej: entre personas que realmente necesitan el beneficio, misma tasa para hombres y mujeres).
- **Equalized CATE:** la distribución del efecto estimado es similar entre grupos.

Equidad contrafactual. Una decisión es «contrafactualmente justa» si, cuando imaginamos cambiar solo el género (o raza, etc.) de una persona pero mantenemos todo lo demás igual, la decisión no cambia. Esto requiere un modelo causal de cómo el atributo protegido afecta el resultado.

Explicaciones contrafactuales. En lugar de decir «el modelo no te dio el crédito porque tu score es 620», podemos decir: «si tus ingresos fueran $100 000 más altos, habrías recibido el crédito». Esto es más accionable y comprensible.

Documentación responsable. Todo proyecto de ML causal debería incluir:

- **Model card:** una ficha con el propósito, población, limitaciones y riesgos del modelo.
- **Auditoría de equidad:** comparar el CATE promedio entre grupos definidos por atributos protegidos.

24.5 Riesgos, límites y sensibilidad

24.5.1 Tabla de riesgos

La tabla 24.1 resume los riesgos principales al usar ML causal en contextos de política pública, junto con sus consecuencias, diagnósticos y estrategias de mitigación.

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Atribución sobre el modelo equivocado	Reportar los predictores de Y como si fueran los determinantes del efecto: conclusión falsa sobre el mecanismo	Verificar sobre qué objeto se calculó la atribución (Sección 24.2.3): ¿$\hat{\mu}_Y$, $\hat{e}$ o $\hat{\tau}$?	Explicar un sustituto ajustado sobre $\hat{\tau}(X)$ y reportar su fidelidad (R^2 CV); contrastar ambos rankings como en el caso canónico de los dos rankings y en el algoritmo 17
Atribución leída como causal	Sobreinterpretación: creer que intervenir sobre la variable cambia el efecto	Nota explícita de que la atribución es asociativa dentro del modelo, incluso cuando se calcula sobre el CATE	Para preguntas de mecanismo, usar descomposición por rutas (Capítulo 23); validar el CATE con placebos y refutación
IC sobre CATE por grupo con t--test	Intervalos demasiado estrechos; brechas de equidad declaradas significativas sin evidencia	Comprobar si el IC usa la desviación de los $\hat{\tau}_i$ o la *influence function* del estimador	Usar el intervalo del propio estimador por subgrupo o un bootstrap del pipeline completo (algoritmo 18)
Atributo protegido fuera de las covariables	Confusión sin controlar y brechas entre grupos invisibles	Comprobar que el atributo protegido entra al estimador cuando afecta a la asignación o al efecto	Incluirlo como covariable y analizar el efecto por grupo
Fairness sin causalidad	Métrica engañosa al no considerar la estructura causal del sesgo	Auditoría causal comparando CATE entre grupos	Counterfactual fairness con modelo causal explícito
Comunicación sin IC	Decisión errónea basada en falsa confianza	Tabla con IC al 95% para todo estimado reportado	Incertidumbre cuantificada y comunicada explícitamente

Riesgo	Consecuencia	Diagnóstico	Mitigación
Optimizar welfare sin restricciones de equidad	Política que excluye sistemáticamente a minorías	Reportar equidad junto con welfare agregado	Restricciones de equidad en la optimización
No distinguir afirmaciones causales de predictivas	Confundir quién necesita el programa con quién se beneficiaría más	Verificar si el estimando es $E[Y(1) - Y(0) \mid X]$ o $E[Y \mid X, D]$	Usar lenguaje explícito: «efecto causal estimado» frente a «predicción»

Tabla 24.1: Riesgos en ética, interpretabilidad y comunicación de ML causal

24.5.2 Cuándo no usar este método

La equidad causal es un campo activo de investigación. Las definiciones existentes no solo «pueden» entrar en conflicto: el teorema de incompatibilidad de la Sección 24.2.1 garantiza que, fuera de casos degenerados, **no pueden satisfacerse a la vez**. No hay por tanto una solución técnica única, y presentar una auditoría de equidad como si la hubiera es en sí mismo un error de método. Lo que este capítulo sostiene es más modesto y más defendible: hacer explícito qué criterio se adoptó, por qué, y cuánto *welfare* cuesta.

Una limitación adicional del enfoque de este capítulo merece declararse. Todos los criterios discutidos evalúan la **decisión** o el **efecto**, dando por buenos los datos sobre los que se estimaron. Si el sesgo está en la medición misma (si Y se registra de forma sistemáticamente distinta entre grupos, o si la población de entrenamiento excluye a un grupo por el diseño del muestreo, como en el Capítulo 7) ninguna restricción de equidad sobre la política corrige el problema, y la auditoría producirá métricas satisfactorias sobre un sistema injusto. La comunicación a no técnicos requiere, además, traducir conceptos estadísticos (IC, CATE, regret) a lenguaje sustantivo sin perder rigor, tema que cierra el libro en el Capítulo 32.

24.6 Ejercicios propuestos

24.6.1 Ejercicios teóricos

1. Dos grupos tienen tasas base 0,50 y 0,20. Un clasificador binario tiene, en ambos, tasa de verdaderos positivos 0,90 y tasa de falsos positivos 0,20. Calcule el valor predictivo positivo en cada grupo. ¿Qué criterio de equidad se satisface y cuál no? ¿Qué tendría que cambiar para igualar el valor predictivo?
2. Construya una política de tratamiento que satisfaga *equalized CATE* entre dos grupos. ¿En cuánto se reduce el welfare respecto a la política óptima sin restricciones?
3. Explique por qué un análisis de equidad por grupo que no incluye al atributo protegido entre las covariables no puede detectar una brecha de efecto, y bajo qué condiciones, además, sesga el efecto medio estimado.

4. Escriba un *policy brief* (1 página) comunicando los resultados de un análisis causal a un ministro no técnico. Incluya IC, recomendación de política y limitaciones.

24.6.2 Ejercicios computacionales

1. Replique el listado 24.3 sobre `gov_transfers` o `nsw_mixtape`. ¿Hay diferencias de CATE entre grupos demográficos?
2. Use SHAP para interpretar un Causal Forest entrenado sobre `nhefs`. ¿Qué variables son más importantes para la heterogeneidad del efecto de dejar de fumar?

24.7 Lecturas complementarias

Barocas et al. (2019) es el tratamiento de referencia de la equidad algorítmica y la fuente de la organización en tres familias (independencia, separación, suficiencia) adoptada en la Sección 24.2.1. El teorema de incompatibilidad se demuestra en Chouldechova (2017), para el caso del valor predictivo y las tasas de error, y en Kleinberg et al. (2017), para puntuaciones de riesgo. Dwork et al. (2012) es el trabajo fundacional del campo y de la noción de equidad individual; Hardt et al. (2016) introduce *equalized odds* y *equality of opportunity*, junto con un procedimiento de post-procesamiento para imponerlas. Para la vía causal, descomposición por rutas y equidad contrafactual, véase el Capítulo 23 y sus referencias. Kitagawa et al. (2021) formalizan el policy learning bajo restricciones y permiten cuantificar el costo en *welfare* de cada criterio.

Sobre interpretabilidad, Lundberg y Lee (2017) es la referencia de la atribución de Shapley aplicada a modelos, y Lipton (2018) la lectura crítica indispensable antes de usarla: muestra que «interpretabilidad» designa objetivos distintos y a veces incompatibles (confianza, causalidad, transferibilidad, comunicabilidad), y que una técnica de atribución no satisface automáticamente ninguno de ellos, el argumento que la Sección 24.2.3 aplica al caso específico de explicar un estimador causal. Para comunicación de incertidumbre a audiencias no técnicas, (Spiegelhalter 2019).

CAPÍTULO 25

Decisiones estructurales bajo incertidumbre

Cuadro sinóptico del capítulo

Problema:	Elegir entre acciones, no solo estimar el efecto de una acción dada
Estimando:	Utilidad esperada bajo cada acción candidata, $E[U(Y(\text{do}(d)))]$, y el valor de reducir la incertidumbre antes de decidir
Identificación:	Efecto identificado y con soporte en los datos para cada acción candidata, más una función de utilidad declarada
Método:	Maximización de utilidad esperada, con criterios de peor caso y de arrepentimiento cuando la incertidumbre importa
Garantía:	Si cada efecto está identificado y bien estimado, la acción elegida es la óptima mientras la mejor se separe de la segunda; cerca de un empate la elección es inestable
Librerías:	numpy; `scipy.optimize` y los módulos de política de econml para espacios de acciones grandes
Validación:	Comparación con el *status quo*, mapa de regiones de decisión según los parámetros normativos y valor de la información

25.1 Problema causal, estimando e identificación

El Capítulo 21 resolvió una versión de este problema: dado un CATE estimado, a quién asignar un tratamiento binario bajo una restricción de presupuesto. Este capítulo generaliza la pregunta en dos direcciones, que Bareinboim agrupa bajo el nombre de **decisiones estructurales**. Primero, la acción no tiene por qué ser binaria ni consistir en tratar o no tratar a cada unidad: puede ser elegir entre varios programas alternativos, fijar un parámetro continuo o intervenir sobre más de una variable a la vez. Segundo, la decisión exige una **función de**

utilidad explícita y no solo un efecto estimado, porque comparar acciones distintas obliga a decir cuánto vale cada resultado posible y no solo cuál es más probable.

Tres ideas organizan el capítulo. La utilidad es en parte una decisión normativa y debe escribirse. La incertidumbre sobre los efectos entra en la decisión por vías precisas, y ninguna de ellas es la de ensanchar un intervalo y esperar que cambie la recomendación. Y la acción de recolectar información pertenece al conjunto de acciones factibles, aunque casi nunca se la incluya.

25.2 Teoría, supuestos y garantías

25.2.1 La decisión como maximización de utilidad esperada

Definición 25.1 ***(Decisión óptima)***

Dado un conjunto de acciones factibles $\mathcal{D}$ y una función de utilidad $U : \mathcal{Y} \to \mathbb{R}$ que asigna un valor a cada resultado posible, la **acción óptima** es

$$d^* = \underset{d \in \mathcal{D}}{\operatorname{argmax}}\, E[U(Y(\mathrm{do}(d)))] \tag{25.1}$$

donde $E[U(Y(\mathrm{do}(d)))]$ se calcula con la distribución interventiva de Nivel 2 de la PCH (Capítulo 3) inducida por cada acción candidata d.

La diferencia con la estimación de los capítulos anteriores es sutil pero importante. Estimar $\tau(x)$ responde cuál es el efecto; resolver d^* responde qué debería hacerse, y esa segunda pregunta siempre exige una función de utilidad, aunque nadie la haya escrito. Cuando el Capítulo 21 maximizaba el valor de la política sujeto a un presupuesto, ya usaba una utilidad particular, lineal en el resultado y con una restricción de costo. Este capítulo hace explícito que elegir esa utilidad es una decisión de modelado con consecuencias.

Hay un resultado elemental que conviene tener presente antes de hablar de incertidumbre. Sea $U(d, \tau) = v\tau_d - c_d$ la utilidad de la acción d, con v el valor de una unidad de efecto, c_d el costo de la acción y $\tau = (\tau_d)_{d \in \mathcal{D}}$ el vector de efectos, que quien decide no conoce. La distribución con que se describe esa ignorancia es la del analista (una distribución posterior, o la aproximación normal centrada en la estimación y con su error estándar); es una elección de modelado y no un dato.

Proposición 25.2 ***(Utilidad lineal e incertidumbre)***

Si τ tiene media $|\tau|$ bajo esa distribución, entonces $E[U(d, \tau)] = v|\tau|_d - c_d$ para toda acción d. La acción de máxima utilidad esperada depende solo de las medias $|\tau|_d$, y no cambia si la incertidumbre alrededor de ellas se ensancha, se estrecha o se reparte de otra manera.

Demostración. Es la linealidad de la esperanza: $E[v\tau_d - c_d] = vE[\tau_d] - c_d$. □

La proposición es casi trivial y sus consecuencias no lo son. Con utilidad lineal, un intervalo de confianza ancho no modifica la acción que recomienda la utilidad esperada; informa, pero no decide. Los intervalos de utilidad que se añaden a las tablas de decisión sirven para otra

cosa: para saber si conviene fiarse de la recomendación. La incertidumbre cambia la decisión por tres vías, que las secciones siguientes desarrollan: cuando la utilidad no es lineal (aversión al riesgo), cuando el criterio no es la esperanza (peor caso, arrepentimiento) y cuando puede comprarse información antes de decidir.

25.2.2 Criterios de decisión cuando el efecto no está identificado con precisión

Maximizar la utilidad esperada con la estimación puntual es el criterio por defecto, pero no el único defendible, y adoptarlo sin decirlo esconde un supuesto fuerte: que la incertidumbre cabe en una media y que el estimador puntual puede tratarse como el valor verdadero. La teoría estadística de la decisión ofrece un vocabulario preciso para las alternativas. Manski (2004) lo llevó al problema de elegir una regla de tratamiento con datos de un experimento, usando el criterio de arrepentimiento minimax, y el mismo criterio se aplica cuando el efecto está solo **parcialmente identificado**, es decir, cuando datos y supuestos acotan τ dentro de un conjunto en vez de fijarlo.

Tres criterios cubren el espectro de posturas razonables:

Criterio	Qué maximiza	Cuándo es defendible
Utilidad esperada	$E[U(Y(\text{do}(d)))]$ bajo la distribución de incertidumbre elegida	Efecto bien identificado y estimado con precisión; decisión repetida muchas veces, de modo que los promedios se realizan
Maximin (Wald)	El peor resultado posible dentro del conjunto de escenarios: $\max_d \min_{\tau \in \mathcal{T}} U(d, \tau)$	Decisiones irreversibles o con consecuencias graves en el peor escenario; aversión fuerte a la ambigüedad
Minimax regret (Savage)	La menor pérdida máxima respecto de la mejor acción en cada escenario: $\min_d \max_{\tau \in \mathcal{T}} [\max_{d'} U(d', \tau) - U(d, \tau)]$	Cuando el maximin resulta paralizante por concentrarse en escenarios extremos poco plausibles

Los dos criterios de la derecha dependen de un conjunto de escenarios $\mathcal{T}$ que alguien debe declarar. En este capítulo se usa el intervalo de confianza de 95 % de cada efecto como sustituto práctico de ese conjunto. Es una simplificación: un intervalo de confianza resume el error de muestreo, mientras que un conjunto identificado genuino resume lo que los datos y los supuestos no pueden distinguir, y no se estrecha al crecer la muestra. Quien tenga cotas de identificación parcial debe usarlas en su lugar.

La diferencia entre los criterios no es académica. Con un efecto cuyo intervalo cruza el cero, la utilidad esperada puede recomendar intervenir porque el punto estimado es positivo, mientras el maximin recomienda no hacerlo porque el peor caso es dañino. El minimax regret

puede recomendar una tercera cosa. Reportar cuál criterio se aplicó es tan importante como reportar el efecto estimado, porque la recomendación depende de ambos.

25.2.3 El valor de la información

Una acción que el marco de utilidad esperada suele dejar fuera del conjunto $\mathcal{D}$, y que casi siempre debería estar dentro, es **no decidir todavía y obtener más datos**. Su valor se calcula con las mismas piezas.

Definición 25.3 ***(Valor esperado de la información perfecta)***

$$\mathrm{EVPI} = E_{\tau}\Big[\max_{d\in\mathcal{D}} U(d,\tau)\Big] - \max_{d\in\mathcal{D}} E_{\tau}[U(d,\tau)] \tag{25.2}$$

Es lo que se ganaría en promedio si el verdadero τ se conociera antes de elegir.

Proposición 25.4 ***(Cota del valor de un estudio)***

Se cumple $\mathrm{EVPI} \geq 0$, con igualdad si y solo si existe una acción que es óptima con probabilidad uno. Además, para cualquier estudio con resultado S, su valor esperado $\mathrm{EVSI} = E_S[\max_d E[U(d,\tau) \mid S]] - \max_d E[U(d,\tau)]$ cumple $0 \leq \mathrm{EVSI} \leq \mathrm{EVPI}$.

Demostración (esquema). El máximo de esperanzas no supera a la esperanza del máximo, y coinciden solo si la misma acción alcanza el máximo casi seguramente. Para el EVSI, $\max_d E[U \mid S] \leq E[\max_d U \mid S]$ para cada resultado S; tomando esperanza sobre S se obtiene $\mathrm{EVSI} \leq \mathrm{EVPI}$, y $0 \leq \mathrm{EVSI}$ porque $E_S[\max_d E[U \mid S]] \geq \max_d E_S[E[U \mid S]] = \max_d E[U]$. □

El EVPI es un techo y no una tarifa: ningún estudio real resuelve toda la incertidumbre, de modo que su valor es el EVSI, siempre menor. Sirve igual para decidir. Si el EVPI es pequeño frente al costo de un estudio, lo razonable es decidir con lo que se tiene; si es grande, el experimento compite legítimamente con las acciones sustantivas, y omitirlo del conjunto de acciones sesga la decisión hacia intervenir con la información actual. La idea viene de la teoría de la decisión bayesiana de Raiffa y Schlaifer, y encaja con el Capítulo 31, donde los bandits tratan la exploración como parte de la decisión.

25.2.4 Identificación y soporte de cada acción

Todo lo anterior supone que el efecto de cada acción candidata está identificado, y es el supuesto que más se olvida cuando el conjunto de acciones crece. Cuando la acción involucra más de una variable de intervención (por ejemplo, el monto de una transferencia y el requisito de asistencia a capacitaciones), $\mathcal{D}$ pasa de un binario a un espacio multidimensional, y las combinaciones que ningún hogar recibió no tienen efecto identificado por los datos: tienen una extrapolación del modelo, cuya utilidad estimada hereda toda la fragilidad de extrapolar (Capítulo 26). El análogo del soporte común del Capítulo 5 debe comprobarse acción por acción, y las acciones sin soporte deben marcarse como tales en la recomendación en vez de mezclarse con las identificadas. Las intervenciones suaves, que modifican un mecanismo en lugar de fijar un valor, tienen sus propias condiciones de identificación, tratadas en el mismo capítulo.

Algoritmo

Entrada: Conjunto de acciones factibles, estimaciones de efecto con su incertidumbre, costos, función de utilidad con sus parámetros normativos.
Salida: Acción recomendada, regiones de decisión y valor de la información.
Declarar $\mathcal{D}$, incluyendo el *status quo* y la acción «obtener más información».
Escribir la función de utilidad y marcar qué parámetros son normativos y quién los fija.
Comprobar para cada acción que su efecto está identificado y tiene soporte en los datos; marcar las que son extrapolación.
Calcular la utilidad esperada de cada acción y la acción óptima.
Calcular el peor caso y el arrepentimiento máximo de cada acción sobre el conjunto de escenarios declarado.
Recorrer los parámetros normativos y trazar las regiones donde cada criterio recomienda cada acción.
Calcular el valor esperado de la información perfecta y compararlo con el costo de un estudio.
return Recomendación, criterio aplicado, regiones de decisión y valor de la información; todo registrado en la ficha del modelo (Capítulo 19).

Algoritmo 19. Decisión entre acciones con incertidumbre

La incertidumbre entra, además, por dos vías que conviene no confundir. La **estadística** es el error de estimación de cada efecto, la misma que cuantifican los intervalos de los capítulos anteriores. La **estructural** es la duda sobre si el SCM supuesto es siquiera el correcto: ningún intervalo la captura, y solo un análisis de sensibilidad al grafo, como el del Capítulo 8, la aborda parcialmente.

25.3 Procedimiento: decidir entre acciones con incertidumbre

El error más común es entregar solo el resultado del cuarto paso, la acción óptima, sin decir a qué distancia está del umbral donde cambiaría. Una recomendación que se invierte con un cambio pequeño de un parámetro normativo es una recomendación frágil, y el mapa de regiones es la forma de verlo.

25.4 Casos canónicos y validación

Los tres casos usan las mismas tres políticas candidatas de un programa social. Cada una tiene un efecto estimado (media y error estándar, en puntos del resultado) y un costo por beneficiario:

Política	Efecto	Error estándar	Costo
Sin intervención	0	0	0
Transferencia simple	0,12	0,03	500
Transferencia más capacitación	0,19	0,05	900

La utilidad es $U = v\tau_d - c_d$, con v el valor monetario de un punto de efecto, un parámetro normativo que ningún dato determina. Las cifras son deterministas salvo el valor de la

información, que se calcula por Monte Carlo con semilla fija. El script es `herramientas/verificaciones/verif_cap25.py`. El peor caso usa el extremo inferior del intervalo de 95 % de cada efecto, y el arrepentimiento se evalúa sobre los 27 escenarios que combinan el extremo inferior, el centro y el extremo superior de los tres intervalos.

Caso canónico · Las regiones de decisión dependen de un parámetro normativo

La utilidad esperada recomienda no intervenir si v es menor que 4 167 (el costo de 500 dividido por el efecto de 0,12), la transferencia simple entre 4 167 y 5 714 y la capacitación por encima de 5 714 (el costo adicional de 400 dividido por el efecto adicional de 0,07). Los otros dos criterios cortan en lugares distintos:

v	Utilidad esperada	Maximin	Minimax regret
3 000	ninguna	ninguna	ninguna
5 000	simple	ninguna	ninguna
7 000	capacitación	ninguna	capacitación
10 000	capacitación	simple	capacitación
15 000	capacitación	capacitación	capacitación

Con $v = 5000$ la transferencia simple gana por 100 contra 50, pero el intervalo de 95 % de su utilidad va de -194 a 394 y el de la capacitación de -440 a 540: se solapan casi por completo y el peor caso de ambas es negativo, de modo que el maximin recomienda no intervenir. El arrepentimiento máximo es 540 para no intervenir, 734 para la simple y 834 para la capacitación, y el minimax regret coincide con el maximin. Tres criterios, tres respuestas posibles con el mismo efecto estimado.

Caso canónico · Ensanchar el error estándar no mueve la utilidad esperada

Se duplica el error estándar de la capacitación, de 0,05 a 0,10, con el mismo efecto estimado. La utilidad esperada no cambia para ningún valor de v, como anticipa la proposición de la Sección 25.2.1. El maximin sí cambia: con 0,10 el efecto en el peor caso de la capacitación es $0.19 - 1.96 \times 0.10 = -0.006$, su utilidad de peor caso es negativa para todo v y deja de ser recomendada. Por encima de 12 990 el maximin elegía la capacitación con 0,05; con 0,10 se queda en la transferencia simple. El minimax regret no cambia en el rango probado (de 3 000 a 30 000): el umbral sigue en unos 6 470, porque el ancho adicional entra con el mismo coeficiente en el arrepentimiento de no intervenir (el escenario donde la capacitación resulta alta) y en el de la capacitación (el escenario donde resulta baja), y se cancela en la comparación entre ambos.

Caso canónico · Cuánto vale saber más

Se describe la incertidumbre de cada efecto con una normal centrada en su estimación y con su error estándar, independientes entre políticas. Con $v = 5000$, la utilidad de la transferencia simple es $N(100, 150^2)$ y la de la capacitación $N(50, 250^2)$. El valor esperado de la información perfecta entre las tres acciones es 100 por beneficiario: la mejor acción vale hoy 100 y, sabiendo los efectos verdaderos antes de elegir, valdría en promedio 200. Por cada acción por separado frente a no intervenir, el valor de la información es 22,7 para la simple y 76,7 para la capacitación. Depende del parámetro normativo: con $v = 3000$ vale 3, porque no intervenir es robusto, y entre 100 y 135 para v entre 5 000 y 15 000. Si el programa alcanzara a 10 000 hogares, el techo del valor de un estudio con $v = 5000$ sería de 1 000 000 en las mismas unidades.

Las políticas son estilizadas. En un programa real, los efectos vendrían de un estimador de la Parte II con su inferencia (Capítulo 11), y los costos incluirían los administrativos y los legales de cada diseño. La lección no cambia: la acción óptima depende de un parámetro normativo, de un criterio declarado y de cuánta incertidumbre vale la pena reducir antes de comprometerse.

25.5 Implementación en Python

```
import itertools
import numpy as np

# Tres politicas candidatas: efecto estimado (media, error estandar) y costo
por beneficiario
politicas = {
    "sin_intervencion": {"efecto": 0.0, "se": 0.0, "costo": 0},
    "transferencia_simple": {"efecto": 0.12, "se": 0.03, "costo": 500},
    "transferencia_mas_capacitacion": {"efecto": 0.19, "se": 0.05, "costo":
900},
}
V = 5000   # valor monetario de un punto de efecto: parametro normativo, no un
dato
Z = 1.96   # los intervalos de 95 % hacen de conjunto de escenarios


def utilidad(efecto, costo, v=V):
    return v * efecto - costo


def evaluar(v=V):
    """Utilidad esperada, utilidad de peor caso y arrepentimiento maximo de
cada politica."""
    nombres = list(politicas)
```

```
    eu = {k: utilidad(p["efecto"], p["costo"], v) for k, p in
politicas.items()}
    peor = {k: utilidad(p["efecto"] - Z * p["se"], p["costo"], v) for k, p in
politicas.items()}
    niveles = [[p["efecto"] - Z * p["se"], p["efecto"], p["efecto"] + Z *
p["se"]]
               for p in politicas.values()]
    arrep = dict.fromkeys(nombres, 0.0)
    for esc in itertools.product(*niveles):          # 27 escenarios
        u = {k: utilidad(e, politicas[k]["costo"], v) for k, e in zip(nombres,
esc)}
        mejor = max(u.values())
        for k in nombres:
            arrep[k] = max(arrep[k], mejor - u[k])
    return eu, peor, arrep


def recomienda(v=V):
    eu, peor, arrep = evaluar(v)
    return max(eu, key=eu.get), max(peor, key=peor.get), min(arrep,
key=arrep.get)


def valor_informacion_perfecta(v=V, n=400_000, semilla=0):
    """EVPI con efectos normales independientes: E[max_d U] - max_d E[U]."""
    rng = np.random.default_rng(semilla)
    U = np.column_stack([utilidad(p["efecto"] + p["se"] *
rng.standard_normal(n), p["costo"], v)
                         for p in politicas.values()])
    return U.max(axis=1).mean() - U.mean(axis=0).max()


for v in (3000, 5000, 7000, 10000):
    eu, peor, arrep = evaluar(v)
    print(f"v={v:>6}  recomienda (EU, maximin, minimax regret): {recomienda(v)}
EVPI={valor_informacion_perfecta(v):6.1f}")

# Coherencia simple con las cifras del texto
assert abs(500 / 0.12 - 4166.7) < 0.1 and abs(400 / 0.07 - 5714.3) < 0.1
assert recomienda(5000) == ("transferencia_simple", "sin_intervencion",
"sin_intervencion")
assert recomienda(10000) == ("transferencia_mas_capacitacion",
"transferencia_simple", "transferencia_mas_capacitacion")
assert 95 < valor_informacion_perfecta(5000) < 105
```

Listado 25.1: Criterios de decisión y valor de la información para tres políticas candidatas.

Con pocas acciones basta recorrerlas todas. Si el espacio de acciones es continuo o combinatorio (montos, umbrales, combinaciones de requisitos), la maximización de $E[U]$ se hace con optimización numérica (`scipy.optimize`) o, para reglas por unidad, con los módulos de política de `econml`, y el peor caso y el arrepentimiento se aproximan sobre una muestra de escenarios. El listado usa tres acciones para que cada cifra pueda comprobarse a mano.

25.6 Riesgos, límites y sensibilidad

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Función de utilidad implícita	Decisión con valores que nadie aprobó	¿Está escrita U y quién fijó sus parámetros?	Escribir U y asignar un responsable
Sensibilidad al parámetro normativo	Mismo efecto estimado, acciones distintas (caso 1)	Distancia de v al umbral más cercano	Reportar el mapa de regiones
Leer el error estándar como si moviera la utilidad esperada	Un intervalo ancho no cambia la recomendación (caso 2)	¿La utilidad es lineal en el efecto?	Usar peor caso, aversión al riesgo o valor de la información
Intervalo de confianza como conjunto identificado	Peor caso y arrepentimiento ignoran lo que los datos no distinguen	Separar error de muestreo y cotas de identificación	Usar cotas de identificación parcial o sensibilidad
Omitir «obtener más información»	Se interviene cuando un estudio valdría más (caso 3)	EVPI frente al costo del estudio	Incluir el estudio como acción
Acción sin soporte en los datos	Una extrapolación se presenta como estimación	Positividad acción por acción	Marcar como extrapolada o experimentar

Tabla 25.1: Riesgos en la decisión entre acciones bajo incertidumbre.

Límites. El minimax regret depende del conjunto de escenarios que se declare, y un conjunto distinto puede dar otra acción. Los valores de información de este capítulo suponen efectos independientes y normales; con dependencia entre ellos, o con colas pesadas, cambian. Y ninguna de estas cuentas sustituye la discusión normativa de qué resultado vale cuánto y para quién, que es la parte que la tecnología no puede decidir.

25.7 Ejercicios y notas bibliográficas

25.7.1 Ejercicios teóricos

1. Explique por qué el problema de policy learning del Capítulo 21 (a quién tratar bajo presupuesto) es un caso particular del problema de decisión estructural de este capítulo, identificando cuál es $\mathcal{D}$ y cuál es U en ese caso.

2. Para el programa de la Sección 25.4, proponga una función de utilidad alternativa que dé peso explícito a la equidad distributiva (por ejemplo, que penalice que el efecto se concentre en un subgrupo). ¿Cambiaría la acción óptima?
3. Sea $w \sim N(\mu, \sigma^2)$ el beneficio neto de una acción y $u(w) = -e^{-aw}$ una utilidad con aversión al riesgo. Muestre que la utilidad esperada equivale a la de recibir con certeza $\mu - a\sigma^2/2$. Con $v = 7000$, encuentre el valor de a por encima del cual la transferencia simple supera a la capacitación y el valor por encima del cual conviene no intervenir. Sugerencia: la desviación estándar de la utilidad es v por el error estándar del efecto; el primer valor es $a \approx 0.0023$.
4. Deduzca que, para una sola acción con utilidad $N(m, s^2)$ y $m > 0$ frente a no intervenir, el valor de la información perfecta es $s[\varphi(m/s) - (m/s)\Phi(-m/s)]$, con φ y Φ la densidad y la función de distribución normal estándar. Verifique que vale 22,7 para la transferencia simple con $v = 5000$.
5. Explique por qué, con utilidad lineal, no tiene sentido comparar dos estimaciones de igual media y distinto error estándar mediante la utilidad esperada, y qué criterio o qué dato adicional haría que la diferencia importara.

25.7.2 Ejercicios computacionales

1. Modifique el listado 25.1 con al menos dos valores distintos de `V` (uno bajo, uno alto) y reporte si la acción óptima cambia según cada criterio. Discuta qué implica para la robustez de la recomendación.
2. Repita el cálculo con el error estándar de la capacitación en 0,05 y en 0,10, para valores de v entre 3 000 y 30 000. ¿Qué criterios cambian su recomendación al ampliar el error estándar? ¿Por qué la utilidad esperada nunca cambia y por qué, en este ejemplo, tampoco lo hace el minimax regret?
3. Añada al listado una cuarta acción, «piloto aleatorizado», con un costo fijo y que reduzca a la mitad el error estándar de ambos efectos si se elige, y compruebe si compite con las acciones sustantivas para algún valor de v.

25.7.3 Notas bibliográficas

Este capítulo sigue la formalización de decisiones estructurales de (Bareinboim 2025). El marco de la teoría de la decisión bajo incertidumbre, con funciones de pérdida, admisibilidad y utilidad esperada, está en (Berger 1985). Manski (2004) es la lectura clave de la Sección 25.2.2: formula la elección de una regla de tratamiento como un problema de decisión con datos de un experimento, desarrolla el criterio de arrepentimiento minimax para ese contexto y deriva sus implicaciones para la asignación de tratamientos según las covariables. Es también el antecedente directo de la *Empirical Welfare Maximization* del Capítulo 21. Los criterios de peor caso y de arrepentimiento se deben a Wald y a Savage, y el valor de la información a Raiffa y Schlaifer. Los usos más aplicados de este marco en la práctica de targeting son el Capítulo 21 y el Capítulo 22.

CAPÍTULO 26

Generalización y transportabilidad entre dominios

Cuadro sinóptico del capítulo

Problema:	Determinar si un efecto estimado en un dominio es válido en otro
Estimando:	El efecto en el dominio destino, $P^*(y \mid \text{do}(x))$
Identificación:	Diagrama de selección: qué mecanismos difieren entre dominio fuente y destino, y qué variables se miden en el destino
Método:	Teoría de transportabilidad (Pearl y Bareinboim); en el caso simple, reponderación por la distribución de las covariables del destino
Garantía:	Si el efecto es transportable, existe una fórmula que lo calcula combinando datos de ambos dominios; si no lo es, ningún ajuste con esos datos lo recupera
Librerías:	Sin implementación estándar madura; el listado usa numpy y pandas
Validación:	Muestra de resultados en el destino cuando sea posible; sensibilidad a diferencias de mecanismo no modeladas

26.1 Problema causal, estimando e identificación

La ficha del modelo causal (Capítulo 19) declara la población de entrenamiento y advierte que el modelo no debe usarse fuera de ella. Este capítulo formaliza qué significa «fuera de esa población» y bajo qué condiciones, ni nunca ni siempre, un efecto estimado en un dominio puede aplicarse legítimamente en otro. La noción informal de validez externa, tratada casi siempre de forma cualitativa en la econometría aplicada, tiene una versión formal y verificable en el marco de la PCH: la **transportabilidad**.

La pregunta importa en producción por una razón simple. Un sistema se entrena y se valida en un dominio y opera en otro, porque la población cambia, porque se abre un mercado nuevo

o porque el tiempo pasa. La teoría dice qué hace falta saber del dominio nuevo, y cuánto, para que el efecto estimado siga siendo una guía.

26.2 Teoría, supuestos y garantías

26.2.1 Diagramas de selección

Definición 26.1 ***(Diagrama de selección)***

Un **diagrama de selección** es un grafo causal aumentado con nodos especiales S, uno por cada mecanismo que se sospecha difiere entre el dominio fuente Π y el dominio destino Π^*, con una flecha $S_i \to V_i$ que indica que el mecanismo que genera V_i puede diferir entre dominios. Las variables sin nodo S entrante comparten el mismo mecanismo generador en ambos dominios.

Por ejemplo, si un efecto se estimó en una población urbana (Π) y se quiere aplicar a una rural (Π^*), y se sospecha que la distribución de ingresos difiere entre ambas pero el mecanismo por el cual el ingreso afecta al resultado es el mismo, el diagrama tiene un nodo S que apunta a la variable de ingreso (su **distribución** difiere) y ninguno que apunte a la ecuación estructural que relaciona ingreso con resultado (su **mecanismo** es el mismo). Dibujar ese diagrama obliga a declarar, variable por variable, qué se supone igual y qué se supone distinto, y es la parte del análisis que ninguna estimación sustituye.

26.2.2 Qué puede decirse del efecto en el destino

Definición 26.2 ***(Efecto transportable)***

Dado un diagrama de selección, el efecto $P^*(y \mid \mathrm{do}(x))$ en el dominio destino es **transportable** desde el dominio fuente si existe una fórmula que lo expresa en términos de (i) cantidades estimables con datos experimentales o cuasi-experimentales del dominio fuente Π y (ii) cantidades observacionales del dominio destino Π^*, típicamente la distribución de las variables a las que apunta algún nodo S.

El marco de los diagramas de selección y el término **transportabilidad** se introducen en Pearl y Bareinboim (2011). El resultado central de (Bareinboim y Pearl 2013) es un algoritmo **completo**, análogo al cálculo-do del Capítulo 8, que determina para cualquier diagrama de selección si el efecto es transportable y, si lo es, produce la fórmula de transporte explícita. La completitud tiene aquí el mismo valor operativo que allá: si el algoritmo responde que no, ninguna técnica de reponderación, adaptación de dominio o ajuste de covariables recupera el efecto en el destino con esos datos y ese diagrama.

El caso simple y frecuente es el que se usa en el resto del capítulo. Sea Z un conjunto de covariables medidas en ambos dominios y supóngase que los únicos nodos S del diagrama apuntan a variables de Z: cambia su distribución, no ningún mecanismo.

Proposición 26.3 ***(Fórmula de transporte con una covariable)***

Si el tratamiento es aleatorio en la fuente y los únicos nodos S entrantes lo hacen a variables de Z, de modo que $Y \perp\!\!\!\perp S \mid Z, \mathrm{do}(X)$ (Z es $\boldsymbol{S}$**-admisible**), entonces

$$P^*(y \mid \mathrm{do}(x)) = \sum_z P(y \mid \mathrm{do}(x), z)\, P^*(z), \tag{26.1}$$

y en particular $\mathrm{ATE}^* = \sum_z \mathrm{ATE}(z)\, P^*(z)$. La fórmula exige soporte: todo valor z con $P^*(z) > 0$ debe tener $P(z) > 0$, porque de lo contrario no hay efecto condicional en la fuente que reponderar.

Demostración (esquema). Como S solo apunta a Z, dado Z el mecanismo que genera Y bajo la intervención es el mismo en ambos dominios, de modo que $P^*(y \mid \mathrm{do}(x), z) = P(y \mid \mathrm{do}(x), z)$. La fórmula sigue de la ley de la probabilidad total bajo P^*. El efecto condicional se estima con el experimento de la fuente y $P^*(z)$ con datos del destino, sin resultados del destino. □

Es el resultado de Pearl y Bareinboim (2014) para el caso en que S apunta solo a una covariable. Los efectos que varían con z son los que dependen de la reponderación: si el efecto condicional es el mismo en todo estrato, el efecto transportado es el de la fuente y la reponderación no cambia nada.

La reponderación se puede escribir también con pesos. Si $R = 1$ indica el dominio destino y $R = 0$ la fuente, el peso de una unidad de la fuente con covariables x es

$$w(x) = \frac{P(R = 1 \mid x)}{P(R = 0 \mid x)} \cdot \frac{P(R = 0)}{P(R = 1)}, \tag{26.2}$$

que equivale a la razón de densidades $P^*(x)/P(x)$ y cumple $E_{\Pi}[w(X)] = 1$. Los odds de pertenencia sin la corrección por la proporción de cada muestra no suman uno y sesgan la reponderación.

Hay dos casos que la literatura nombra de forma distinta y que se confunden con facilidad. La **transportabilidad** pregunta si un efecto estimado en un dominio Π vale en un dominio Π^* **distinto**. La **generalización** pregunta algo más específico: si un efecto estimado sobre una **muestra seleccionada**, como los participantes de un ensayo o los clientes que aceptaron una oferta, vale para la población de la que se extrajo, cuando la selección no fue aleatoria. Es el caso en que el nodo S apunta a un indicador de selección muestral y no a un mecanismo del dominio destino, y el resultado que lo cubre es la recuperación del sesgo de selección de Bareinboim et al. (2014). La distinción importa en producción: el Capítulo 30 vigila la deriva entre dominios (transportabilidad), mientras que la ficha de procedencia del Capítulo 7 documenta el sesgo de selección del que depende la generalización. Son dos amenazas distintas, con diagnósticos distintos.

Correa y Bareinboim (2020) extienden el marco a **intervenciones suaves**: acciones que no fijan una variable a un valor constante sino que modifican su mecanismo, como cambiar la regla de asignación de un subsidio en vez de dárselo a todos. Es la forma que toma la mayoría de las decisiones de política reales y la que el Capítulo 25 formaliza como decisión estructural.

Algoritmo

Entrada: Efecto estimado en la fuente, descripción de la fuente y del destino, variables medidas en cada dominio.
Salida: Veredicto de transportabilidad, fórmula de transporte y estimación con su cobertura, o lista de lo que falta medir.
Declarar la pregunta (un efecto o una política) y los dos dominios.
Dibujar el diagrama de selección: para cada variable, decir si su mecanismo o su distribución puede diferir, y por qué.
Decidir si el efecto es transportable; en el caso simple, comprobar que los nodos S apuntan solo a covariables medidas en ambos dominios.
Si lo es, derivar la fórmula y comprobar el soporte: qué fracción del destino cae en valores observados en la fuente.
Estimar con reponderación por estratos o por pesos de dominio, y reportar la cobertura.
Si no lo es, decidir entre medir más variables en el destino, obtener resultados del destino o acotar con supuestos explícitos.
return Diagrama, fórmula, estimación, cobertura y sensibilidad a un mecanismo no anticipado, registrados en la ficha del modelo (Capítulo 19).

Algoritmo 20. Evaluación de la transportabilidad

Su resultado, también completo, es el que corresponde invocar cuando la pregunta no es si este efecto vale allá sino si esta **política** vale allá.

26.2.3 Por qué esto no es lo mismo que reestimar con más datos

Conviene distinguir la transportabilidad de dos prácticas más simples. No es lo mismo que **agrupar los datos de ambos dominios y reestimar**: si los mecanismos efectivamente difieren, agrupar sin más introduce sesgo, no lo elimina. Tampoco es lo mismo que **reentrenar el modelo con datos del dominio destino**, la opción por defecto en un sistema puramente predictivo (Capítulo 2): reentrenar requiere datos etiquetados del destino, que con frecuencia no existen. Es la situación en la que la teoría de transportabilidad aporta algo que el *machine learning* estándar no ofrece, porque permite, bajo el diagrama correcto, extrapolar sin resultados del destino.

26.3 Procedimiento: evaluar la transportabilidad de un efecto

El paso del diagrama es el único sin forma estadística, y es el que decide el resto. Dos analistas con los mismos datos y diagramas distintos llegan a veredictos distintos, y los datos no bastan para zanjar cuál diagrama es el correcto.

26.4 Casos canónicos y validación

Los tres casos comparten un proceso con verdad conocida: $Y = 0.4D + b\,DX + 0.5X + \varepsilon$, con el tratamiento aleatorizado en la fuente, $X \sim N(0,1)$ en la fuente y $X \sim N(1, 1.5^2)$ en el destino. Con $b = 0.3$ el efecto verdadero es $0.4 + 0.3E[X]$: 0,4 en la fuente y 0,7 en el destino. Las cifras

provienen de simulaciones con muestras de 20 000 observaciones por dominio, promediadas sobre 30 repeticiones. El script es `herramientas/verificaciones/verif_cap26.py`.

Caso canónico · Reponderar por la covariable que difiere

La diferencia de medias ingenua en la fuente da 0,40 y subestima el efecto en el destino. Reponderar los efectos por estrato con la distribución de X en el destino da 0,59 con 5 estratos, 0,63 con 10, 0,65 con 20 y 0,67 con 50, contra una verdad de 0,70. Mejora con los estratos porque el efecto varía dentro de cada uno, y no llega a 0,70 porque los estratos extremos, abiertos, reciben una masa grande del destino, que es más disperso. Con pesos de un clasificador de dominio el promedio es 0,72, pero con una desviación entre repeticiones de 0,18, diez veces la de los estratos: con un destino más disperso que la fuente, los pesos tienen varianza infinita en teoría y enorme en la práctica.

Caso canónico · Soporte: lo que la fuente no vio

Se quita de la fuente su quintil más alto de X. Solo el 46 % del destino cae en estratos observados. Reponderar solo sobre esos estratos y renormalizar da 0,32, que coincide con el efecto verdadero de esa parte del destino (0,31). El efecto del destino completo es 0,70, y ningún método lo recupera desde esa fuente sin un supuesto adicional sobre cómo se comporta el efecto donde la fuente no tiene datos. Descartar esos estratos sin renormalizar subestimaría el efecto en la misma proporción, de modo que la cobertura se reporta y la fórmula se aplica solo a lo cubierto.

Caso canónico · Un mecanismo que cambió no se ve desde la fuente

En el destino el término de interacción es $b = 0.5$ en vez de 0,3, de modo que el efecto verdadero es $0.4 + 0.5 \times 1 = 0.9$. El estimador reponderado usa solo los resultados de la fuente y las covariables del destino, ninguno de los cuales cambió, y devuelve 0,67 (50 estratos). Un error de más de 0,2 que ninguna estadística calculada con esos datos puede delatar: es el caso de un nodo S que apunta a Y y que el diagrama no declaró. Solo una muestra de resultados del destino lo revela.

El estimador de retorno a la educación de Card (1995), usado en varios capítulos del curso, se estimó en una población de hombres jóvenes de Estados Unidos, con salarios de 1976. Aplicarlo a otro país o a otra década exige preguntarse explícitamente si el mecanismo por el cual la educación afecta al salario (productividad, señalización, redes) es razonablemente estable entre esos dominios o si solo difiere la distribución de las covariables. En el primer caso ninguna fórmula simple lo resuelve y el efecto no es transportable sin supuestos adicionales fuertes; en el segundo, una reponderación como la del caso 1 podría ser defendible.

26.5 Implementación en Python

```
import warnings
import numpy as np
import pandas as pd


def efecto_transportado(df_fuente, df_destino, estrato, tratamiento,
resultado):
    """Efecto por estrato en la fuente (tratamiento aleatorio) ponderado por la
    distribucion del estrato en el destino. Devuelve (efecto, cobertura): la
cobertura
    es la fraccion del destino que cae en estratos observados en la fuente."""
    por_estrato = (
        df_fuente.groupby(estrato)
        .apply(lambda g: g.loc[g[tratamiento] == 1, resultado].mean()
                         - g.loc[g[tratamiento] == 0, resultado].mean())
        .dropna()
    )
    peso = df_destino[estrato].value_counts(normalize=True)
    comunes = por_estrato.index.intersection(peso.index)
    cobertura = peso[comunes].sum()
    if cobertura < 1:
        warnings.warn(f"Solo el {cobertura:.1%} del destino cae en estratos
observados en la fuente.")
    return (por_estrato[comunes] * peso[comunes]).sum() / cobertura, cobertura


# Datos simulados: mismo mecanismo en ambos dominios, distinta distribucion de
X
rng = np.random.default_rng(0)
n = 20_000
fuente = pd.DataFrame({"X": rng.normal(0, 1, n), "D": rng.binomial(1, 0.5, n)})
fuente["Y"] = 0.4 * fuente.D + 0.3 * fuente.D * fuente.X + 0.5 * fuente.X +
rng.standard_normal(n)
destino = pd.DataFrame({"X": rng.normal(1, 1.5, n)})

# La covariable continua se discretiza con los mismos bordes en ambos dominios
bordes = [-np.inf, *fuente["X"].quantile(np.linspace(0, 1, 21)[1:-1]), np.inf]
for df in (fuente, destino):
    df["estrato"] = pd.cut(df["X"], bordes, labels=False)

efecto, cobertura = efecto_transportado(fuente, destino, "estrato", "D", "Y")
ingenuo = fuente.loc[fuente.D == 1, "Y"].mean() - fuente.loc[fuente.D == 0,
"Y"].mean()
print(f"ingenuo={ingenuo:.3f}  transportado={efecto:.3f}
cobertura={cobertura:.2f}  (verdad del destino: 0.70)")
```

```
assert abs(ingenuo - 0.4) < 0.1 and 0.58 < efecto < 0.75 and cobertura == 1.0
# coherencia
```

Listado 26.1: Efecto transportado por reponderación de estratos, con cobertura del destino.

El listado es el caso particular más simple y no el teorema general: es válido bajo un diagrama de selección donde S apunta solo a la covariable de estratificación. La función avisa y reporta la cobertura en lugar de descartar en silencio los estratos del destino que la fuente no observó. Para covariables continuas o de dimensión alta, la reponderación por estratos cede su lugar a los pesos de un clasificador de dominio, con la advertencia del caso 1 sobre su varianza.

26.6 Riesgos, límites y sensibilidad

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Asumir transportabilidad sin diagrama	Equivale a un diagrama vacío no argumentado	¿Hay un diagrama escrito y revisado?	Escribirlo y declarar lo que se supone igual
Leer «no hay evidencia de que difiera» como «no difiere»	La falta de análisis se toma por evidencia a favor	¿Qué se midió en el destino?	Medir las covariables clave y una muestra de resultados
Mecanismo cambiado y no declarado	Error grande sin señal en los datos disponibles (caso 3)	Comparar resultados del destino con los transportados	Muestra de resultados del destino; sensibilidad
Falta de soporte	Se extrapola donde la fuente no tiene datos (caso 2)	Cobertura del destino por estratos observados	Reportar solo lo cubierto; no renormalizar en silencio
Pesos con varianza enorme	Estimación inestable cuando el destino es más disperso (caso 1)	Distribución de los pesos y tamaño efectivo de muestra	Estratos, recorte con sesgo declarado o ampliar la fuente
Estratos demasiado gruesos	Sesgo por heterogeneidad dentro del estrato (caso 1)	Estimación con 5, 10, 20 y más estratos	Refinar los estratos o modelar el efecto condicional

Tabla 26.1: Riesgos al transportar un efecto entre dominios.

Límites. La fórmula de transporte es válida para las diferencias que declara el diagrama, y cualquier diferencia de mecanismo no anticipada la invalida. El algoritmo completo cubre casos donde el mecanismo mismo difiere y la fórmula combina cantidades experimentales de la fuente con observacionales del destino, y excede el alcance de este capítulo; la ausencia de una reponderación simple no equivale a la ausencia de transportabilidad.

26.7 Ejercicios y notas bibliográficas

26.7.1 Ejercicios teóricos

1. Para el ejemplo de la Sección 26.2.1 (población urbana y rural), dibuje el diagrama de selección descrito y explique qué habría que medir en el dominio rural para aplicar la fórmula de transporte.
2. Explique por qué reentrenar el modelo con datos del dominio destino no es una opción disponible en muchos de los casos de uso reales que motivan la teoría de transportabilidad.
3. Muestre con el proceso de los casos canónicos que el efecto verdadero del destino es $0.4 + 0.3E^*[X]$, y que la fórmula de transporte da ese valor cuando los estratos son infinitesimalmente finos. ¿Qué ocurre con $b = 0$?
4. Demuestre que $E_\Pi[w(X)] = 1$ para los pesos de dominio de la Sección 26.2.2 y que $E_\Pi[w(X)^2]$ es infinita cuando el destino es normal con una varianza suficientemente mayor que la de la fuente. ¿A partir de qué cociente de varianzas ocurre, si las medias coinciden?

26.7.2 Ejercicio computacional

1. Con el proceso de los casos canónicos y el listado 26.1, compare el efecto transportado con el efecto verdadero del destino y con la diferencia de medias ingenua de la fuente, y repita con 5, 10, 20 y 50 estratos. ¿Por qué mejora el resultado al aumentar los estratos? Luego quite de la fuente el estrato más alto y observe la cobertura. Con $b = 0$, el efecto es constante: ¿qué aprende de la reponderación en ese caso?

26.7.3 Notas bibliográficas

Pearl y Bareinboim (2011) introducen los diagramas de selección, y Pearl y Bareinboim (2014) desarrollan la fórmula de transporte que justifica la reponderación de este capítulo. Bareinboim y Pearl (2013) establecen el algoritmo de decisión completo para transportabilidad, y Correa y Bareinboim (2020) lo extienden a intervenciones suaves, el caso relevante cuando lo que se quiere transportar es una política y no un efecto puntual. Bareinboim (2025) presenta los tres de forma integrada con el resto de la Jerarquía Causal de Pearl. La noción informal de validez externa en econometría aplicada, con la que conviene contrastar este tratamiento formal, se discute en (Imbens y Rubin 2015). Sobre la relación con el reentrenamiento en un sistema en producción, véanse el Capítulo 31 (cuándo actualizar) y el Capítulo 30 (cómo detectar que el dominio cambió).

PARTE VII

Métodos avanzados

Esta parte cubre métodos de mayor capacidad y de naturaleza distinta a los anteriores: arquitecturas de deep learning causal con balance de representación, y control sintético con matrix completion para el caso de una sola unidad tratada observada en el tiempo.

CAPÍTULO 27

Deep learning para inferencia causal

Cuadro sinóptico del capítulo

Problema:	Estimar CATE con no linealidades complejas usando redes neuronales
Estimando:	$\tau(x) = E[Y(1) - Y(0) \mid X = x]$
Identificación:	No confusión, soporte común, SUTVA
Método:	TARNet, CFRNet (IPM), DeepIV
Nuisance:	$\mu_1(x), \mu_0(x), \Phi(x)$
Garantía:	Cota de error bajo no confusión y representación balanceada; inferencia válida solo cuando la red actúa como *nuisance* dentro de un score ortogonal
Librerías:	PyTorch, econml
Validación:	Balance de representación, MMD, comparación con meta-learners

Nota técnica

Con la Parte VI completa, el curso ya cubrió estimación, decisión, equidad y generalización con los métodos «estándar» de ML causal, y esta Parte VII reúne dos familias de métodos más especializados. Este capítulo extiende los meta-learners y los bosques causales (Capítulo 12 y Capítulo 13) con arquitecturas de *deep learning* diseñadas específicamente para balancear representaciones entre grupos de tratamiento.

27.1 Motivación aplicada

Una plataforma de salud digital desea estimar el efecto de un programa de recordatorios personalizados sobre la adherencia a medicamentos. Cada usuario tiene cientos de características (historial médico, comportamiento en la app, demografía). El efecto del tratamiento es altamente no lineal: para algunos subgrupos el recordatorio es muy efectivo, para otros es nulo.

Los métodos basados en árboles (*causal forest*) pueden no capturar la estructura compleja; una red neuronal podría.

El *deep causal learning* aplica redes neuronales al problema de estimación causal. La innovación central, introducida por (Shalit et al. 2017) con TARNet y CFRNet, es aprender una *representación balanceada* $\Phi(X)$ tal que las distribuciones de $\Phi(X)$ para tratados y controles sean similares, permitiendo estimar $\mu_0(\Phi(X))$ y $\mu_1(\Phi(X))$ con la misma red.

Este capítulo desarrolla TARNet y CFRNet, presenta DeepIV (Hartford et al. 2017) para variables instrumentales y discute las extensiones modernas (CEVAE, contrastive balance). Su mensaje de fondo es doble: la representación balanceada no sustituye al supuesto de no confusión, y la inferencia válida con redes llega por el aparato ortogonal, no por la red.

27.2 Teoría, supuestos y garantías

27.2.1 TARNet: representación compartida

TARNet (*Treatment-Agnostic Representation Network*) tiene arquitectura:

1. **Capa de representación** $\Phi : R^p \to R^k$ que mapea covariables a un embedding.
2. **Cabezas de outcome** $h_0, h_1 : R^k \to R$ separadas para tratados y controles.

La predicción es $\hat{\mu}_d(x) = h_d(\Phi(x))$. El CATE estimado es $\hat{\tau}(x) = h_1(\Phi(x)) - h_0(\Phi(x))$.

La *loss* es el error cuadrático medio:

$$\mathcal{L}_{\text{TARNet}} = \left(\frac{1}{n}\right) \sum_i \left(Y_i - h_{D_i}(\Phi(X_i))\right)^2. \tag{27.1}$$

27.2.2 CFRNet: balance con una métrica integral de probabilidad

CFRNet (*Counterfactual Regression with IPM*) añade a TARNet una penalización de *Integral Probability Metric* (IPM) que fuerza el balance entre las distribuciones de $\Phi(X)$ para tratados y controles:

$$\mathcal{L}_{\text{CFRNet}} = \mathcal{L}_{\text{TARNet}} + \alpha \cdot \text{IPM}(\Phi(X \mid D = 0), \Phi(X \mid D = 1)). \tag{27.2}$$

Aquí α es el peso de la penalización IPM, no el nivel de significación.

La IPM puede ser la distancia de Wasserstein, la discrepancia máxima de medias (MMD) o una pérdida adversarial, como en las redes neuronales de adaptación de dominio.

Teorema 27.1 ***(Shalit, Johansson y Sontag, 2017)***

Bajo no confusión y soporte común, y para una representación Φ invertible y diferenciable, el error esperado en τ (el error de estimación del efecto heterogéneo) está acotado por una suma de tres términos: (i) los errores factuales de las dos cabezas de resultado, (ii) un múltiplo de la IPM entre las distribuciones de $\Phi(X)$ para tratados y controles y (iii) el ruido irreducible del resultado. La versión de muestra finita añade un término de complejidad de la clase de funciones.

Algoritmo

Entrada: Datos $(X_i, D_i, Y_i)_{i=1}^n$, red de representación Φ con cabezas h_0, h_1, épocas E, tasa de aprendizaje η, peso IPM $\alpha \geq 0$
Salida: Estimación del CATE $\hat{\tau}(x) = h_1(\Phi(x)) - h_0(\Phi(x))$
for `epoch` $= 1$ **to** `E` **do**

Calcular representación $\Phi_i = \Phi(X_i)$ para todo i
Predecir $\hat{Y}_i = h_{D_i}(\Phi_i)$
$\mathcal{L}_{\text{MSE}} \leftarrow \left(\frac{1}{n}\right) \sum_{i=1}^n \left(Y_i - \hat{Y}_i\right)^2$
if CFRNet **then**
IPM $\leftarrow$ MMD$(\{\Phi_i : D_i = 0\}, \{\Phi_i : D_i = 1\})$
$\mathcal{L} \leftarrow \mathcal{L}_{\text{MSE}} + \alpha \cdot \text{IPM}$
else
$\mathcal{L} \leftarrow \mathcal{L}_{\text{MSE}}$
end if
Actualizar parámetros con $\nabla \mathcal{L}$ vía Adam(η)

end for
return $\hat{\tau}(x) = h_1(\Phi(x)) - h_0(\Phi(x))$

Algoritmo 21. Entrenamiento TARNet/CFRNet

La cota explica por qué se penaliza la IPM, pero es una cota, no una igualdad: minimizarla no equivale a minimizar el error en τ, un punto que la Sección 27.7.1 desarrolla.

27.2.3 DeepIV

Para casos con variable instrumental, (Hartford et al. 2017) proponen DeepIV. El modelo es $Y = h(D, X) + \varepsilon$, con $E[\varepsilon \mid Z, X] = 0$ pero ε posiblemente correlacionado con D, de modo que la regresión directa de Y sobre D y X sesga la función estructural h. La estimación se hace en dos etapas con dos redes:

1. **Red de tratamiento** $g(z, x)$, que modela la densidad $p(D \mid Z, X)$ y se ajusta por máxima verosimilitud.
2. **Red estructural** $h(d, x)$, que estima la función causal y se ajusta minimizando el error cuadrático del resultado frente a la esperanza de $h(D, x)$ bajo la densidad estimada en la primera etapa.

Las dos etapas no se combinan en una sola pérdida: la segunda toma la primera como dada. La identificación descansa en las condiciones habituales de un instrumento (relevancia, exclusión e independencia) y en la forma aditiva del error.

27.3 Algoritmos de entrenamiento

El siguiente pseudocódigo describe el procedimiento de entrenamiento de TARNet y su extensión CFRNet. La diferencia clave es la penalización IPM que fuerza el balance de la representación latente $\Phi(X)$ entre grupos de tratamiento y control.

Algoritmo

Entrada: Datos $(Z_i, X_i, D_i, Y_i)_{i=1}^n$, familia de redes para la densidad $p_\theta(d \mid z, x)$ y para la función estructural $h_\varphi(d, x)$, número de simulaciones M
Salida: Función estructural estimada $h_\varphi(d, x)$
Etapa 1. Ajustar θ maximizando $\sum_i \log p_\theta(D_i \mid Z_i, X_i)$.
Etapa 2. Para cada i, simular $\tilde{D}_{i1}, \ldots, \tilde{D}_{iM}$ de $p_\theta(\cdot \mid Z_i, X_i)$.
Ajustar φ minimizando $\sum_i \left(Y_i - \left(\frac{1}{M}\right) \sum_{m=1}^{M} h_\varphi(\tilde{D}_{im}, X_i)\right)^2$.
return h_φ

Algoritmo 22. DeepIV en dos etapas

27.4 Implementación en Python

```
import torch
import torch.nn as nn
import torch.optim as optim
import numpy as np
from torch.utils.data import DataLoader, TensorDataset

class TARNet(nn.Module):
    def __init__(self, in_dim, rep_dim=64, hidden=128):
        super().__init__()
        # Representacion compartida
        self.rep = nn.Sequential(
            nn.Linear(in_dim, hidden), nn.ReLU(),
            nn.Linear(hidden, hidden), nn.ReLU(),
            nn.Linear(hidden, rep_dim),
        )
        # Cabezas separadas para D=0 y D=1
        self.h0 = nn.Sequential(
            nn.Linear(rep_dim, hidden), nn.ReLU(),
            nn.Linear(hidden, 1),
        )
        self.h1 = nn.Sequential(
            nn.Linear(rep_dim, hidden), nn.ReLU(),
            nn.Linear(hidden, 1),
        )
    def forward(self, X, D):
        Phi = self.rep(X)
        out = torch.where(D.unsqueeze(-1) == 1, self.h1(Phi), self.h0(Phi))
        return out.squeeze(-1)
    def predict_cate(self, X):
        Phi = self.rep(X)
        return (self.h1(Phi) - self.h0(Phi)).squeeze()

# DGP
def make_dgp(n=3000, seed=0):
```

```
    rng = np.random.default_rng(seed)
    X = rng.uniform(-1, 1, (n, 10))
    e = 1/(1 + np.exp(-1.0 - 0.5*X[:, 0]))
    D = (rng.uniform(size=n) < e).astype(np.float32)
    tau = 2 + 3*X[:, 0] - X[:, 1]**2
    mu0 = np.sin(X[:, 2]) + X[:, 3]
    Y = mu0 + D * tau + rng.standard_normal(n) * 0.5
    return X.astype(np.float32), D.astype(np.float32), Y.astype(np.float32),
tau

X, D, Y, tau_true = make_dgp(3000, seed=42)
X_t = torch.from_numpy(X); D_t = torch.from_numpy(D); Y_t = torch.from_numpy(Y)

# Entrenamiento
torch.manual_seed(42)
model = TARNet(in_dim=X.shape[1])
opt = optim.Adam(model.parameters(), lr=1e-3, weight_decay=1e-4)
for epoch in range(200):
    model.train()
    opt.zero_grad()
    pred = model(X_t, D_t)
    loss = ((pred - Y_t)**2).mean()
    loss.backward()
    opt.step()
    if epoch % 50 == 0:
        print(f"Epoch {epoch}: loss={loss.item():.4f}")

# Evaluacion
model.eval()
with torch.no_grad():
    cate_hat = model.predict_cate(X_t).numpy()
rmse = np.sqrt(np.mean((cate_hat - tau_true)**2))
print(f"RMSE en CATE: {rmse:.4f}")
```

Listado 27.1: Implementación de TARNet en PyTorch.

27.4.1 CFRNet con penalización MMD

```
def mmd_loss(Phi0, Phi1, sigma=1.0):
    """Maximum Mean Discrepancy entre representaciones de tratados y
controles."""
    def kernel(A, B):
        # RBF kernel
        diff = A.unsqueeze(1) - B.unsqueeze(0)
        return torch.exp(-diff.pow(2).sum(-1) / (2 * sigma**2))
    K00 = kernel(Phi0, Phi0); K11 = kernel(Phi1, Phi1); K01 = kernel(Phi0,
Phi1)
```

```
    return K00.mean() + K11.mean() - 2 * K01.mean()

class CFRNet(TARNet):
    def forward_loss(self, X, D, Y, alpha=1.0):
        Phi = self.rep(X)
        pred = torch.where(D.unsqueeze(-1) == 1, self.h1(Phi),
self.h0(Phi)).squeeze(-1)
        mse = ((pred - Y)**2).mean()
        Phi0 = Phi[D == 0]; Phi1 = Phi[D == 1]
        if len(Phi0) > 1 and len(Phi1) > 1:
            mmd = mmd_loss(Phi0, Phi1)
        else:
            mmd = torch.tensor(0.0)
        return mse + alpha * mmd

# Entrenamiento CFRNet
model_cfr = CFRNet(in_dim=X.shape[1])
opt = optim.Adam(model_cfr.parameters(), lr=1e-3, weight_decay=1e-4)
for epoch in range(200):
    model_cfr.train(); opt.zero_grad()
    loss = model_cfr.forward_loss(X_t, D_t, Y_t, alpha=1.0)
    loss.backward(); opt.step()
    if epoch % 50 == 0:
        print(f"Epoch {epoch}: loss={loss.item():.4f}")

model_cfr.eval()
with torch.no_grad():
    cate_cfr = model_cfr.predict_cate(X_t).numpy()
print(f"CFRNet RMSE: {np.sqrt(np.mean((cate_cfr - tau_true)**2)):.4f}")
```

Listado 27.2: CFRNet con penalización MMD.

27.5 Arquitectura de TARNet/CFRNet

La figura 27.1 muestra la arquitectura común de TARNet y CFRNet. Una red de representación compartida $\Phi(X)$ mapea las covariables a un embedding de menor dimensión; dos cabezas separadas h_0, h_1 estiman $\mu_0(\Phi(X))$ y $\mu_1(\Phi(X))$ respectivamente. El CATE se obtiene por diferencia: $\hat{\tau}(X) = h_1(\Phi(X)) - h_0(\Phi(X))$. CFRNet añade a TARNet una penalización IPM (Integral Probability Metric) que fuerza el balance entre las distribuciones de $\Phi(X)$ para tratados y controles, reduciendo el desbalance observado de covariables en el espacio de representación, bajo el supuesto previo de no confusión.

Cap. 13 — Arquitectura TARNet / CFRNet (Shalit, Johansson & Sontag, 2017)

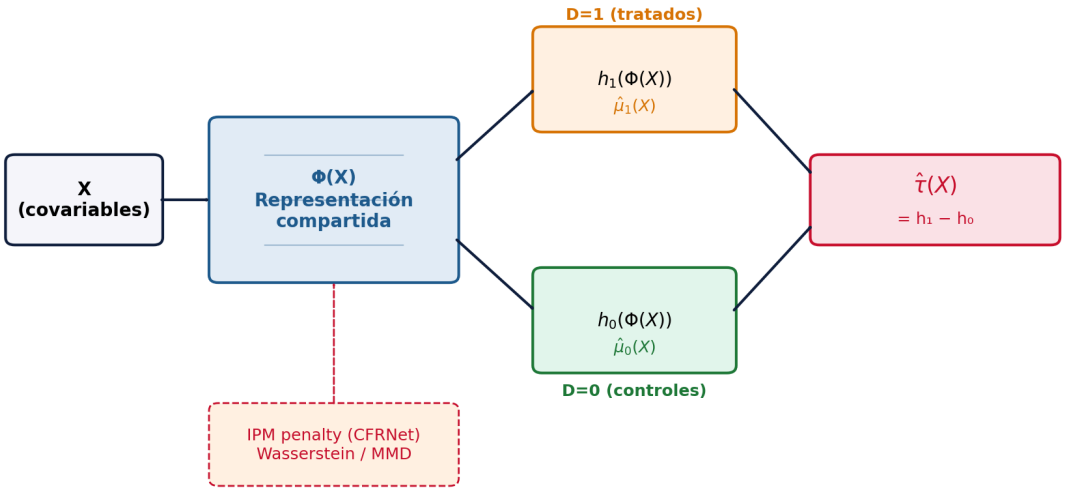


Figura 27.1: Arquitectura de TARNet / CFRNet (Shalit, Johansson & Sontag, 2017). La capa de representación compartida Φ es seguida por dos cabezas separadas h_0, h_1 para $D = 0$ y $D = 1$. CFRNet añade una penalización IPM (Wasserstein o MMD) que fuerza el balance entre las distribuciones de $\Phi(X)$ condicionales al tratamiento.

27.6 Caso empírico y validación

Caso canónico · Balance perfecto, información nula

Diez covariables independientes y uniformes en $[-1, 1]$. El tratamiento se asigna con probabilidad $\frac{1}{1+e^{-1-0.5x_0}}$, el resultado sin tratamiento es $\mu_0 = \sin(x_2) + x_3$ y el efecto es $\tau(x) = 2 + 3x_0 - x_1^2$, de modo que el efecto es heterogéneo y quienes reciben el tratamiento tienen x_0 más alto.

Una representación Φ constante logra balance perfecto, porque la distribución de $\Phi(X)$ es la misma para tratados y controles, y la IPM vale cero. Pero entonces las dos cabezas ven la misma entrada y la estimación del efecto es una constante, la diferencia de medias entre tratados y controles. Esa constante estima el efecto sobre los tratados, que es mayor que el efecto medio, y ningún valor constante puede acertar el efecto individual: el error cuadrático medio es al menos la varianza del propio efecto, $\mathrm{Var}(\tau) = \mathrm{Var}(3x_0) + \mathrm{Var}(x_1^2) = 3.00 + 0.09 = 3.09$, es decir, una desviación típica de 1,76 unidades en un efecto cuyo promedio ronda 1,67.

Un valor de α suficientemente grande empuja la representación hacia ese extremo. Un valor intermedio puede ayudar o perjudicar según el DGP, y por eso α se valida, no se fija.

La ventaja de los métodos profundos aparece, si aparece, cuando el DGP tiene no linealidades complejas o interacciones de alto orden y la muestra es grande; en DGPs simples o con muestras pequeñas los métodos basados en árboles son competitivos y más rápidos de entrenar. Cuál domina en un caso concreto es una pregunta empírica que depende del DGP y del tamaño muestral, y la literatura no encuentra una arquitectura que gane siempre (Curth y Schaar (2021)).

Intuición

Caja de profundización: Representaciones balanceadas y diagnóstico de balance

Objetivo. Entender por qué TARNet/CFRNet aprenden una representación intermedia y cómo verificar si está bien balanceada.

La idea. En lugar de estimar $\mu_1(X)$ y $\mu_0(X)$ directamente sobre las covariables originales, la red primero aprende una «representación» compacta $\Phi(X)$. Luego estima los outcomes a partir de esa representación.

¿Por qué balancear? Si la distribución de $\Phi(X)$ es similar entre tratados y controles, cualquier diferencia en outcomes se debe más probablemente al tratamiento y no a confusores observados. CFRNet agrega una penalización que fuerza este balance.

Cómo diagnosticar el balance. Una vez entrenada la red, podemos calcular:

- Diferencia de medias de $\Phi(X)$ entre tratados y controles (debe ser cercana a cero).
- MMD (Maximum Mean Discrepancy): distancia entre las dos distribuciones.
- Si el MMD es grande, la red no está balanceando bien y podemos aumentar el peso de la penalización.

Advertencia importante. El balance de $\Phi(X)$ NO garantiza identificación causal. Si hay confusores no observados que no están en X, ninguna red puede solucionarlo.

27.7 Límites y errores comunes

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Balance sin identificación	Falsa seguridad: balancear $\Phi(X)$ no crea el supuesto de no confusión	DAG y supuestos declarados; el balance es sobre covariables **observadas**	No confusión explícita y justificada; ningún ajuste arquitectónico la sustituye

Riesgo	Consecuencia	Diagnóstico	Mitigación
Overfitting profundo	Mala generalización	Train/test loss	Regularización, *early stopping*, validación
α (peso IPM) fijado sin validar	Representación sobre-balanceada y poco informativa; error en τ mayor que sin penalización (Curth y Schaar 2021)	Barrido de α incluyendo $\alpha = 0$ (TARNet) y comparación del error en τ sobre un DGP con *ground truth*	Tratar α como hiperparámetro a validar y reportar su valor; no asumir que CFRNet domina a TARNet
Reportar $\hat{\tau}(x)$ sin cuantificar incertidumbre	Decisiones individuales basadas en un punto sin intervalo	Verificar si el pipeline produce algún IC	Usar la red como *nuisance* dentro de DML (Sección 27.7.2), o *bootstrap* asumiendo su costo; para decisiones individuales, intervalos conformes (Sección 14.2.8)

Tabla 27.1: Riesgos comunes en deep causal learning

Los métodos profundos suelen requerir muestras grandes y un ajuste cuidadoso de hiperparámetros; con muestras pequeñas, los basados en árboles son preferibles. Dos límites merecen un tratamiento más detenido, porque la literatura reciente los ha precisado y en ambos casos la lectura ingenua del método es la equivocada.

27.7.1 ¿Balancear la representación ayuda realmente?

La penalización IPM de CFRNet se presenta habitualmente como una mejora inequívoca sobre TARNet, y la ecuación (27.2) lo sugiere: forzar $\Phi(X \mid D = 0)$ y $\Phi(X \mid D = 1)$ a parecerse debería reducir el término de discrepancia de la cota de Shalit et al. (2017). Curth y Schaar (2021) muestran que el argumento es más frágil de lo que parece, y por una razón instructiva: la cota que justifica la penalización es **laxa**, y minimizarla no equivale a minimizar el error en τ.

El mecanismo del problema es directo. El balance es una restricción sobre la representación compartida; hacerla más fuerte reduce la información sobre X que Φ conserva, y parte de esa información puede ser necesaria para estimar bien μ_0 y μ_1. Con α grande, la red aprende una representación tan balanceada como poco informativa; en el extremo, Φ constante logra balance perfecto y error máximo, como en el caso canónico de más arriba. Empíricamente, el

α óptimo depende del DGP y con frecuencia es cercano a cero; TARNet sin penalización es un competidor serio, no un *baseline* trivial.

La lección que Curth y van der Schaar extraen, y que este capítulo adopta, es que lo determinante no es la penalización IPM sino los **sesgos inductivos** de la arquitectura: cómo se comparte información entre las dos cabezas, si se modela τ directamente o por diferencia, si se usa el *propensity* como entrada. Operativamente: α debe tratarse como un hiperparámetro a validar, no como un interruptor que se activa porque «balancear es bueno», y su valor óptimo debe reportarse.

27.7.2 Redes como estimadores de *nuisance* e inferencia válida

Es cierto que TARNet y CFRNet, tal como se han presentado, no producen intervalos de confianza: se optimiza una pérdida predictiva y no hay ninguna garantía distribucional sobre $\hat{\tau}(x)$. Pero sería inexacto concluir que la inferencia con redes neuronales sea un problema sin tratamiento teórico. Dos líneas de trabajo lo abordan directamente y conviene conocerlas.

Farrell et al. (2021) establecen tasas de convergencia no asintóticas para redes profundas con activaciones ReLU y, sobre esa base, demuestran normalidad asintótica e inferencia válida para funcionales semiparamétricos, incluido el ATE, estimados con redes como *nuisance*. El resultado es exactamente la pieza que faltaba: muestra que las redes satisfacen la condición de tasa $\sqrt{n}a_n^2 \to 0$ del Capítulo 10 bajo condiciones explícitas sobre profundidad, anchura y suavidad de la función objetivo. La consecuencia práctica es que **usar una red como estimador de cada *nuisance* dentro de DML está respaldado por la teoría**, y es probablemente la forma más sensata de combinar *deep learning* e inferencia causal en producción hoy.

La segunda línea automatiza el paso de ortogonalización. Chernozhukov et al. (2022a) observan que el término de corrección de un score ortogonal es siempre un **representador de Riesz** del funcional de interés, y proponen aprenderlo directamente con una red (RieszNet) o un bosque (ForestRiesz), en lugar de derivarlo a mano para cada estimando. Esto convierte la construcción del score, que en los Capítulo 10 y Capítulo 11 se hizo analíticamente para el modelo lineal parcial y el modelo de regresión interactivo, en un problema de aprendizaje, y extiende DML a funcionales para los que nadie ha derivado la fórmula.

La conclusión operativa para este capítulo es una inversión de la práctica habitual: en vez de usar una red para estimar τ directamente y luego buscar cómo hacer inferencia sobre ella, conviene usar la red donde su capacidad de aproximación aporta, en los *nuisance* de alta dimensión, y dejar la inferencia al aparato ortogonal que ya la tiene resuelta. El *bootstrap* sobre TARNet/CFRNet sigue siendo una opción práctica para cuantificar incertidumbre, pero es costoso y sus garantías bajo regularización y optimización no convexa son mucho menos claras.

27.8 Ejercicios propuestos

27.8.1 Ejercicios teóricos

1. Muestre que si Φ es constante la IPM vale cero y la estimación del CATE es constante. Calcule el menor error cuadrático medio posible para un efecto $\tau(x) = 2 + 3x_0 - x_1^2$ con x_0, x_1 independientes y uniformes en $[-1, 1]$.
2. Explique por qué balancear $\Phi(X)$ no sustituye el supuesto de no confusión. Dé un ejemplo con un confusor no observado en el que el balance sobre X sea perfecto y el efecto siga sesgado.
3. Explique por qué conviene usar una red como estimador de los *nuisance* dentro de DML en lugar de estimar τ directamente con TARNet. ¿Qué garantía se gana y qué se pierde?
4. En DeepIV, ¿por qué la regresión directa de Y sobre D y X sesga h y qué papel cumple el instrumento en la segunda etapa?

27.8.2 Ejercicios computacionales

1. Replique el listado 27.1 variando la profundidad de la red (1, 2, 3 capas ocultas). ¿Cuándo aparece overfitting?
2. Implemente CFRNet con penalización Wasserstein en lugar de MMD (usar `geomloss` o `POT`).
3. Compare TARNet, CFRNet y Causal Forest sobre un DGP con no linealidades crecientes. ¿En qué punto el deep causal supera a los árboles?
4. Barra el peso de la penalización IPM en $\alpha \in \{0, 0.1, 1, 10, 100\}$ y grafique el error en τ contra el MMD de la representación. Verifique que el α que minimiza el MMD **no** es el que minimiza el error, y relacione el resultado con la Sección 27.7.1.
5. Use la red TARNet (sin las cabezas causales: solo la representación más una cabeza) como `model_y` y `model_t` dentro de `LinearDML`, y compare el ATE con IC obtenido así frente al ATE que produce TARNet directamente por promedio de $\hat{\tau}(x)$. ¿Cuál de los dos permite reportar un intervalo con respaldo teórico, y por qué (Sección 27.7.2)?
6. Implemente DeepIV sobre el dataset `iv_noncompliance` (sintético) y verifique que recupera la función estructural conocida.

27.9 Lecturas complementarias

Shalit et al. (2017) es la referencia fundacional de TARNet/CFRNet y de la cota de error con IPM. Hartford et al. (2017) introduce DeepIV. Louizos et al. (2017) propone CEVAE. Shi et al. (2019) extiende a DragonNet, que incorpora el *propensity* como cabeza adicional y aplica una corrección dirigida al estimando.

Tres lecturas son indispensables para no quedarse en el estado del arte de 2017. Curth y Schaar (2021) revisan críticamente la familia completa desde el ángulo de los sesgos inductivos

y son la fuente del análisis de la Sección 27.7.1 sobre los límites de la representación balanceada; su comparación empírica sistemática es también el mejor punto de partida para elegir arquitectura. Farrell et al. (2021) establecen las tasas y la teoría de inferencia que hacen de las redes profundas un *nuisance learner* legítimo dentro de DML. Chernozhukov et al. (2022a) proponen aprender el representador de Riesz, y con él el score ortogonal, en lugar de derivarlo analíticamente, extendiendo el aparato de la Parte II a funcionales arbitrarios.

CAPÍTULO 28

Control sintético y matrix completion

Cuadro sinóptico del capítulo

Problema:	Estimar el efecto causal en un panel con una o pocas unidades tratadas
Estimando:	El efecto sobre la unidad tratada en cada período posterior, τ_t, y su promedio
Identificación:	La trayectoria sin tratamiento de la unidad tratada se reproduce con las de las no tratadas: combinación convexa (control sintético) o rango bajo (matrix completion)
Método:	Control sintético; matrix completion con norma nuclear
Nuisance:	Pesos w_j (control sintético) o matriz L (matrix completion)
Garantía:	Control sintético: sesgo acotado con buen ajuste previo y muchos períodos previos. Matrix completion: error que decrece con las entradas observadas bajo rango bajo e incoherencia, con garantías formales para faltantes aleatorios
Librerías:	scipy.optimize y numpy
Validación:	Ajuste previo, placebos en espacio y en tiempo, curva del efecto frente a λ

Nota técnica

En este capítulo, SCM designa el método de control sintético (*synthetic control method*) y no el modelo causal estructural del Capítulo 3; la sigla coincide por accidente. Los capítulos anteriores de esta parte estiman efectos de unidades individuales; este cierra la Parte VII con el caso de una o pocas unidades tratadas que se observan a lo largo del tiempo.

28.1 Problema causal, estimando e identificación

Una economista del Banco Central debe estimar el efecto de una reforma tributaria aplicada en una región sobre la recaudación. No hay una región de control perfecta: todas tienen trayectorias distintas. El método de control sintético de Abadie y Gardeazabal (2003) construye un control ponderando regiones no tratadas, llamadas **donantes**, para reproducir la trayectoria previa de la región tratada. La diferencia entre lo que ocurrió después y lo que esa combinación predice es el efecto estimado.

El método clásico tiene límites conocidos: exige que la tratada se reproduzca bien con los donantes, maneja con dificultad varias unidades tratadas o adopción escalonada, y no produce errores estándar convencionales. Athey et al. (2021) proponen *matrix completion* como alternativa: tratan la matriz de resultados sin tratamiento como una matriz de rango bajo con ruido, en la que las celdas tratadas son entradas faltantes que se imputan. El capítulo desarrolla ambos métodos, los compara con casos de verdad conocida y explica cómo se hace inferencia cuando hay una sola unidad tratada.

28.2 Teoría, supuestos y garantías

28.2.1 Control sintético

Hay una unidad tratada ($i = 1$) y N donantes ($i = 2, ..., N + 1$) observados en $t = 1, ..., T$, con tratamiento en los períodos $t > T_0$ para la unidad 1. Con resultados potenciales $Y_{it}(0)$ y $Y_{it}(1)$, el estimando es $\tau_t = Y_{1t}(1) - Y_{1t}(0)$ para $t > T_0$. Lo que falta es $Y_{1t}(0)$ después de T_0. Se identifica bajo cuatro supuestos:

- **Sin anticipación:** antes de T_0 el tratamiento no afecta a la unidad tratada.
- **Sin interferencia:** los donantes no reciben efectos indirectos de la intervención.
- **Modelo de factores para el resultado sin tratamiento:** $Y_{it}(0) = \delta_t + \lambda_i^\top \mu_t + \varepsilon_{it}$, con factores comunes μ_t, cargas λ_i específicas de cada unidad y ruido transitorio ε_{it}.
- **Envolvente convexa:** existen pesos $w_j \geq 0$ con $\sum_j w_j = 1$ tales que $\sum_j w_j \lambda_j = \lambda_1$, es decir, la tratada está dentro de la envolvente convexa de los donantes en el espacio de las cargas.

El control sintético estima los pesos con los datos previos:

$$\hat{\boldsymbol{w}} = \operatorname*{argmin}_{\boldsymbol{w}} \sum_{t=1}^{T_0} \left(Y_{1t} - \sum_{j=2}^{N+1} w_j Y_{jt} \right)^2, \quad w_j \geq 0, \quad \sum_j w_j = 1, \tag{28.1}$$

y el efecto estimado es $\hat{\tau}_t = Y_{1t} - \sum_j \hat{w}_j Y_{jt}$ para $t > T_0$. Abadie et al. (2010) muestran que, si los pesos reproducen exactamente la trayectoria previa y las cargas, el sesgo del estimador está acotado por una cantidad que se anula cuando crece el número de períodos previos, bajo condiciones sobre los choques transitorios. Dos advertencias sobre el alcance: la cota formal exige ajuste previo exacto, y en la práctica el ajuste solo es aproximado, de modo que hay que

mirarlo; y la restricción convexa impide extrapolar, de modo que una unidad extrema no se reproduce con ningún vector de pesos.

28.2.2 Matrix completion

Athey et al. (2021) reinterpretan el problema como imputación. Sea $Y(0) \in \mathbb{R}^{N\times T}$ la matriz de resultados sin tratamiento, de la que solo se observan las celdas no tratadas. El modelo es

$$Y(0) = L + \varepsilon, \tag{28.2}$$

con L de rango bajo ($\operatorname{rank}(L) \le r \ll \min(N,T)$) y ruido ε cuya media, dado L y el patrón de tratamiento, es cero. Con $\mathcal{O}$ el conjunto de celdas observadas, el estimador con restricción explícita de rango,

$$\hat{L} = \underset{L:\ \operatorname{rank}(L)\le r}{\operatorname{argmin}} \sum_{(i,t)\in\mathcal{O}} (Y_{it} - L_{it})^2, \tag{28.3}$$

es no convexo y computacionalmente intratable en general. La solución estándar lo relaja sustituyendo el rango por la norma nuclear:

$$\hat{L} = \underset{L}{\operatorname{argmin}} \left\{ \sum_{(i,t)\in\mathcal{O}} (Y_{it} - L_{it})^2 + \lambda \|L\|_* \right\}, \quad \|L\|_* = \sum_i \sigma_i(L), \tag{28.4}$$

con $\sigma_i(L)$ los valores singulares. La justificación es la del LASSO en el Capítulo 6: así como la norma ℓ_1 es la envolvente convexa de la cantidad de coeficientes no nulos y por eso induce esparsidad, la norma nuclear es la envolvente convexa del rango sobre la bola espectral y por eso induce rango bajo. Recht et al. (2010) establecen condiciones, análogas a la propiedad de isometría restringida del caso esparso, bajo las cuales la relajación recupera la solución de rango mínimo. El paralelo sirve también para las advertencias: igual que el LASSO contrae los coeficientes que selecciona, la norma nuclear contrae los valores singulares que retiene, lo que sesga $\hat{L}$ hacia cero y por tanto el efecto estimado.

El efecto sobre la unidad tratada es $\hat{\tau} = (1/(T-T_0)) \sum_{t>T_0} \left(Y_{1t} - \hat{L}_{1t}\right)$.

La garantía de recuperación de L tiene la forma habitual: el error decrece con el número de entradas observadas y crece con el rango, bajo incoherencia, que impide que la información de L se concentre en pocas filas o columnas. Pero las garantías formales más simples suponen entradas faltantes **al azar**, y en un panel causal los faltantes son la asignación del tratamiento: bloques finales de períodos de las unidades tratadas. Ese patrón no es aleatorio, y es la razón de que la validez de matrix completion descanse en supuestos sobre L y sobre el patrón de tratamiento, no en un teorema general, y de que convenga validarlo con placebos en lugar de darlo por válido.

28.2.3 Elegir λ o r: el hiperparámetro que fija el contrafactual

La decisión más consecuente del método es el nivel de regularización, porque determina literalmente el contrafactual. Con λ muy alto el modelo es rígido y no reproduce la trayectoria previa; el sesgo aparece como un mal ajuste visible y contrae el contrafactual de las unidades

extremas. Con λ muy bajo el modelo tiene grados de libertad para ajustar el ruido previo y, al extrapolar al período posterior, parte del efecto estimado puede ser ese sobreajuste proyectado.

El procedimiento estándar es la **validación cruzada de bloque**: enmascarar artificialmente un bloque de celdas que sí se observan, imputarlas con cada valor candidato de λ y elegir el que minimiza el error de imputación fuera de muestra. La clave del diseño es que el patrón de enmascaramiento **imite la estructura del faltante real**: bloques de los últimos períodos previos y no celdas dispersas al azar, porque el problema real es de extrapolación temporal y no de imputación aleatoria. Validar con celdas dispersas produce un λ demasiado bajo.

Dos diagnósticos acompañan a la elección. Primero, la **curva del efecto estimado frente a λ**: una meseta indica robustez, una pendiente pronunciada indica que el resultado es función del hiperparámetro (la misma lectura que en el Capítulo 16). Segundo, el **ajuste previo** con el λ elegido: si el error de imputación previo es comparable a la magnitud del efecto estimado, no hay señal que distinguir del ruido, por bueno que sea el valor de validación cruzada.

28.2.4 Comparación entre ambos métodos

Dimensión	Control sintético	Matrix completion
Varias unidades tratadas	Un control por unidad	Natural: la misma matriz
Adopción escalonada	Un control por unidad y cohorte	Natural: faltantes en bloques distintos
Ajuste previo	Exigido y verificable	Implícito en la elección de λ
Inferencia	Placebos por permutación	Placebos o remuestreo; sin teoría estándar con una unidad tratada
Supuesto estructural	Tratada en la envolvente convexa de los donantes	Rango bajo, incoherencia y patrón de tratamiento no informativo

Tabla 28.1: Control sintético y matrix completion.

28.2.5 Inferencia con una sola unidad tratada

Con una sola unidad tratada no hay muestra sobre la que aplicar un teorema central del límite, de modo que el error estándar convencional no está definido. Abadie et al. (2015) formalizan la alternativa: un **test de permutación** que aplica el mismo procedimiento a cada donante como si hubiera sido el tratado, construye la distribución de efectos placebo y sitúa el de la unidad realmente tratada dentro de ella. Si cae en la cola extrema, se rechaza el efecto nulo. El p-valor es exacto bajo intercambiabilidad pero **discreto**: con J donantes, el mínimo alcanzable es $1/(J+1)$. Con 9 donantes no se puede obtener $p < 0.10$, por grande que sea el efecto, y ese límite hay que reportarlo.

Algoritmo

Entrada: Resultado previo de la tratada $\boldsymbol{Y}_{1,\text{ pre}} \in \mathbb{R}^{T_0}$; donantes previos $\boldsymbol{Y}_{0,\text{ pre}} \in \mathbb{R}^{T_0 \times N}$ y posteriores $\boldsymbol{Y}_{0,\text{ post}} \in \mathbb{R}^{(T-T_0)\times N}$; resultado posterior de la tratada $\boldsymbol{Y}_{1,\text{ post}}$.
Salida: Pesos $\hat{\boldsymbol{w}}$, contrafactual sintético y efecto estimado por período.
Resolver la optimización restringida:
$\hat{\boldsymbol{w}} = \operatorname{argmin}_{\boldsymbol{w}} \left\| \boldsymbol{Y}_{1,\text{ pre}} - \boldsymbol{Y}_{0,\text{ pre}} \boldsymbol{w} \right\|^2$
sujeto a $w_j \geq 0$ para todo j y $\sum_j w_j = 1$.
Calcular el contrafactual posterior:
$\hat{\boldsymbol{Y}}_{1,\text{ post}} = \boldsymbol{Y}_{0,\text{ post}} \hat{\boldsymbol{w}}$
Estimar el efecto por período:
$\hat{\tau}_t = Y_{1t} - \hat{Y}_{1,\text{ post},t}, \quad t = T_0 + 1, ..., T$
Verificar el ajuste previo y calcular los placebos de cada donante.
return $\hat{\boldsymbol{w}}, \hat{\boldsymbol{Y}}_{1,\text{ post}}, \hat{\boldsymbol{\tau}}$, ajuste previo y p-valor de permutación

Algoritmo 23. Control sintético clásico

Los placebos con mal ajuste previo producen efectos posteriores grandes por construcción y contaminan la distribución de referencia. La práctica estándar es usar el cociente entre el error cuadrático medio posterior y el previo (RMSPE) en lugar del efecto crudo, o descartar los donantes con ajuste previo mucho peor que el de la tratada. Las variantes más recientes relajan la restricción convexa: Doudchenko y Imbens (2016) muestran que control sintético, diferencias en diferencias y varios emparejamientos son casos de una misma familia de regresiones sobre las unidades de control, que difieren en las restricciones sobre los pesos; Ben-Michael et al. (2021) corrigen el sesgo del ajuste imperfecto con un modelo de resultado, la misma lógica de aumento doblemente robusto del Capítulo 11 trasladada al panel.

Intuición

Synthetic difference-in-differences y placebos en el tiempo. Arkhangelsky et al. (2021) combinan el control sintético con las diferencias en diferencias. Los pesos de unidad hacen que los controles reproduzcan la trayectoria previa de las tratadas, con un nivel libre; los pesos de tiempo hacen que los períodos previos más informativos reproduzcan el promedio posterior de los controles; y el efecto es una diferencia en diferencias ponderada con ambos pesos. Es más robusto que el control sintético cuando las tendencias paralelas no se cumplen del todo. En cuanto a los placebos, los **en espacio** reasignan el tratamiento a cada donante, y los **en el tiempo** aplican el método a un período previo donde no debería haber efecto; los primeros calibran la inferencia y los segundos detectan anticipación y mal ajuste.

Algoritmo

Entrada: Matriz de resultados Y, celdas observadas $\mathcal{O}$, rejilla de valores de λ, último período previo T_0.
Salida: λ elegido, matriz imputada $\hat{L}$ y efecto estimado.
Para cada λ de la rejilla:
enmascarar además los últimos períodos previos de algunas unidades de control;
imputar con umbralización suave de valores singulares (restar λ a cada valor singular, con piso en cero, y repetir hasta converger);
medir el error de imputación en el bloque enmascarado.
Elegir el λ de menor error promedio sobre varias elecciones de unidades enmascaradas.
Imputar con el λ elegido usando solo las celdas realmente observadas.
Estimar $\hat{\tau} = (T - T_0)^{-1} \sum_{t>T_0} \left(Y_{1t} - \hat{L}_{1t}\right)$ y repetir el procedimiento como placebo sobre unidades no tratadas.
return λ, $\hat{L}$, $\hat{\tau}$ y su comparación con los placebos

Algoritmo 24. Matrix completion con λ por validación cruzada de bloque

28.3 Procedimientos

28.4 Casos canónicos y validación

Los casos usan un panel de factores con verdad conocida: 20 unidades, 30 períodos, rango 2 y ruido normal de desviación 0,5. Una unidad recibe un efecto aditivo de 2,5 desde el período 16, y las demás no reciben efecto. Las cifras promedian 200 repeticiones. El script es `herramientas/verificaciones/verif_cap28.py` y la figura sale de `herramientas/figuras/fig_cap28_scm_mc.py`.

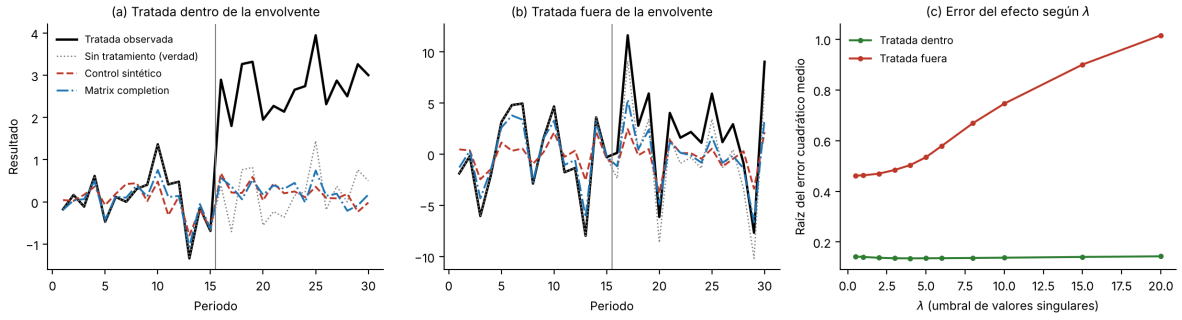


Figura 28.1: (a) y (b): trayectoria de la unidad tratada, control sintético y matrix completion en una realización, con la unidad tratada dentro y fuera de la envolvente convexa de los donantes; la línea vertical marca el inicio del tratamiento. (c): raíz del error cuadrático medio del efecto estimado por matrix completion frente a λ, en 200 repeticiones. Efecto verdadero 2,5.

Caso canónico · Dentro de la envolvente convexa, ambos métodos recuperan el efecto

La unidad tratada tiene cargas dentro de las de los donantes (panel (a) de la Figura 28.1). El control sintético estima el efecto con sesgo de +0,011 y raíz del error cuadrático medio (RMSE) de 0,152; matrix completion con λ elegido por validación cruzada, sesgo de +0,008 y RMSE de 0,138. El ajuste previo del control sintético tiene RMSPE de 0,36, por debajo del ruido de 0,5, un valor menor que el ruido porque con 19 donantes y 15 períodos previos los pesos ajustan parte del ruido.

Caso canónico · Fuera de la envolvente, el control sintético falla y lo delata el ajuste previo

Ahora la unidad tratada tiene cargas extremas, fuera de las de todos los donantes (panel (b)). El control sintético ya no puede reproducirla: el RMSPE previo sube a 2,52, cinco veces el ruido, y el RMSE del efecto sube a 0,757. Matrix completion, que extrapola con la estructura de rango bajo, tiene RMSE de 0,482. El sesgo medio sigue siendo pequeño (+0,073 y +0,032) porque el error cambia de signo según la realización de los factores: lo que se degrada es la dispersión, de modo que una sola estimación puede errar mucho en cualquier sentido. El diagnóstico es el ajuste previo, no el efecto.

Caso canónico · El hiperparámetro fija el contrafactual

Con la tratada dentro de la envolvente, el RMSE del efecto es plano frente a λ (entre 0,135 y 0,143 para λ de 0,5 a 20): una meseta. Con la tratada extrema el RMSE crece con λ: 0,46 con $\lambda = 0.5$, 0,54 con 5, 0,75 con 10 y 1,02 con 20, porque la regularización contrae hacia cero el contrafactual de la unidad extrema. La elección por validación cruzada de bloque (0,482) queda cerca del mejor valor de la rejilla. Reportar la curva distingue el caso robusto del caso en que el resultado depende del hiperparámetro.

Caso canónico · La inferencia por placebos tiene un piso discreto

Con 19 donantes el p-valor mínimo es 0,05. Bajo efecto nulo, el test rechaza al 5 % en el 6,0 % de las repeticiones (nominal 5 %); con el efecto de 2,5 rechaza en el 87 %. Con 9 donantes el mínimo es 0,10: no rechaza nunca al 5 %, bajo efecto nulo rechaza al 10 % en el 11,5 % de las repeticiones y con efecto rechaza en el 79,5 %. Con pocos donantes, un efecto grande no puede producir un p-valor pequeño, y reportar el piso evita que el lector lo suponga continuo.

Abadie et al. (2010) aplicaron el control sintético a la ley de control del tabaco de California (Proposición 99) sobre el consumo de cigarrillos, y Abadie y Gardeazabal (2003) al costo económico del conflicto en el País Vasco, los dos usos clásicos del método. Las cifras de esas

aplicaciones no se reproducen aquí; lo que se usa de ellas es el procedimiento de inferencia por placebos del tercer caso.

28.5 Implementación en Python

```
import numpy as np
from scipy.optimize import minimize


def pesos_scm(y_pre, X_pre):
    """Pesos no negativos que suman uno y minimizan ||y_pre - X_pre w||^2."""
    J = X_pre.shape[1]
    res = minimize(lambda w: np.sum((y_pre - X_pre @ w) ** 2), np.ones(J) / J,
method="SLSQP",
                   bounds=[(0, 1)] * J, constraints=[{"type": "eq", "fun":
lambda w: w.sum() - 1}])
    return res.x


def soft_impute(Y, observada, lam, n_iter=300, tol=1e-5):
    """Imputa las celdas no observadas con umbralizacion suave de valores
singulares."""
    M = np.where(observada, Y, 0.0)
    for _ in range(n_iter):
        U, s, Vt = np.linalg.svd(np.where(observada, Y, M),
full_matrices=False)
        M_nuevo = (U * np.maximum(s - lam, 0.0)) @ Vt
        if np.linalg.norm(M_nuevo - M) < tol * (np.linalg.norm(M) + 1e-12):
            return M_nuevo
        M = M_nuevo
    return M


# Panel con factores: 20 unidades, 30 periodos, unidad 0 tratada desde t = 15
con efecto 2.5
rng = np.random.default_rng(0)
N, T, T0, TAU = 20, 30, 15, 2.5
carga = rng.standard_normal((N, 2))
carga[0] = [0.2, -0.1]                       # la tratada queda dentro de la
envolvente de los donantes
Y = carga @ rng.standard_normal((2, T)) + 0.5 * rng.standard_normal((N, T))
Y[0, T0:] += TAU

# Control sintetico
w = pesos_scm(Y[0, :T0], Y[1:, :T0].T)
efecto_scm = (Y[0, T0:] - Y[1:, T0:].T @ w).mean()
rmspe_pre = np.sqrt(np.mean((Y[0, :T0] - Y[1:, :T0].T @ w) ** 2))      # ajuste
```

```
previo: hay que mirarlo

# Matrix completion: las celdas posteriores de la tratada son las faltantes
observada = np.ones((N, T), dtype=bool)
observada[0, T0:] = False
efecto_mc = (Y[0, T0:] - soft_impute(Y, observada, lam=5.0)[0, T0:]).mean()

print(f"SCM: {efecto_scm:.3f} (RMSPE previo {rmspe_pre:.2f})   MC:
{efecto_mc:.3f}   (verdad: {TAU})")
assert abs(efecto_scm - TAU) < 0.6 and abs(efecto_mc - TAU) < 0.6   #
coherencia
```

Listado 28.1: Control sintético y matrix completion sobre un panel de factores simulado.

```
def lambda_por_cv(Y, observada, rejilla, T0, bloque=5, n_val=5, rondas=3,
semilla=0):
    """Enmascara los ultimos `bloque` periodos previos de `n_val` unidades de
control (la
    tratada es la unidad 0) y elige el lambda con menor error de imputacion en
ese bloque."""
    rng = np.random.default_rng(semilla)
    cols = np.arange(T0 - bloque, T0)
    error = np.zeros(len(rejilla))
    for _ in range(rondas):
        filas = rng.choice(np.arange(1, Y.shape[0]), n_val, replace=False)
        m = observada.copy()
        m[np.ix_(filas, cols)] = False
        for k, lam in enumerate(rejilla):
            L = soft_impute(Y, m, lam)
            error[k] += np.mean((Y[np.ix_(filas, cols)] - L[np.ix_(filas,
cols)]) ** 2)
    return rejilla[int(np.argmin(error))]


lam = lambda_por_cv(Y, observada, [1.0, 2.0, 3.0, 5.0, 8.0, 12.0], T0)
efecto_cv = (Y[0, T0:] - soft_impute(Y, observada, lam)[0, T0:]).mean()
print(f"lambda elegido: {lam}   efecto MC: {efecto_cv:.3f}")
assert lam in [1.0, 2.0, 3.0, 5.0, 8.0, 12.0] and abs(efecto_cv - TAU) < 0.6
# coherencia
```

Listado 28.2: Elección de λ por validación cruzada de bloque.

El segundo listado usa los objetos definidos en el primero. Para varias unidades tratadas o adopción escalonada, la máscara marca como faltante el bloque posterior de cada unidad tratada y el resto del código no cambia.

28.6 Riesgos, límites y mitigación

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Mal ajuste previo	El contrafactual no reproduce la trayectoria y el efecto mide el error de ajuste (caso 2)	RMSPE previo frente al ruido y al efecto	Ampliar donantes, relajar pesos o usar matrix completion
Pocos donantes	Control débil y p-valor acotado por abajo en $1/(J+1)$ (caso 4)	Número de donantes con buen ajuste; concentración de los pesos	Ampliar el conjunto de donantes; reportar el p-valor mínimo alcanzable
Tratada fuera de la envolvente convexa	Ningún vector de pesos convexos la reproduce	Cargas o covariables de la tratada frente al rango de los donantes	Relajar los pesos o aumentar con un modelo de resultado
λ mal elegido	Contrafactual contraído o sobreajustado (caso 3)	Curva del efecto frente a λ; validación cruzada de bloque	Elegir por bloque, reportar la curva y los placebos
Donantes afectados o anticipación	Se viola la ausencia de interferencia o de anticipación; el efecto se subestima	Cercanía entre tratada y donantes; placebo en el tiempo	Excluir donantes expuestos; dejar uno fuera; acotar T_0

Tabla 28.2: Riesgos en control sintético y matrix completion.

Límites. Los dos métodos suponen que no hay interferencia entre unidades y que el mecanismo que genera los resultados sin tratamiento es estable antes y después de la intervención. Ninguno puede distinguir el efecto de la intervención de un choque simultáneo que solo afecta a la tratada, y los placebos solo detectan los choques que también afectan a los donantes.

28.7 Ejercicios y notas bibliográficas

28.7.1 Ejercicios teóricos

1. Explique por qué, en el segundo caso canónico, el sesgo medio es pequeño pero el error de cada estimación es grande, y qué señal observable avisa del problema.
2. Muestre que, bajo intercambiabilidad y el efecto nulo, $P(p \le k/(J+1)) \le k/(J+1)$ para el p-valor de permutación, y que el mínimo alcanzable es $1/(J+1)$.
3. Demuestre que la solución de $\min_L (1/2)\|M-L\|_F^2 + \lambda\|L\|_*$ es $L = U\max(\Sigma - \lambda I, 0)V^\top$ si $M = U\Sigma V^\top$ es la descomposición en valores singulares, y explique por qué eso implica que el estimador contrae hacia cero.
4. Explique por qué validar con celdas enmascaradas dispersas al azar produce un λ más bajo que validar con un bloque de períodos finales.

28.7.2 Ejercicios computacionales

1. Con el listado 28.1, coloque la unidad tratada fuera de la envolvente convexa (por ejemplo, cargas $(3, 3)$) y compare el RMSPE previo y el efecto estimado de ambos métodos con el caso de la unidad central.
2. Replique el control sintético sobre el panel `texas` de la colección de datos públicos (la expansión de la capacidad carcelaria de Texas en 1993 y el encarcelamiento de hombres negros, con los demás estados como donantes). Reporte el efecto posterior y el p-valor de placebos con su mínimo alcanzable.
3. Modifique el listado 28.1 para incluir efectos fijos de unidad y de tiempo en matrix completion. ¿Mejora la imputación?
4. Aplique matrix completion a un panel con adopción escalonada de la colección, como `abortion`, y compare con el control sintético sobre una cohorte.

28.7.3 Notas bibliográficas

Abadie y Gardeazabal (2003) y Abadie et al. (2010) son las referencias del control sintético clásico; Abadie et al. (2015) desarrolla la inferencia por permutación de placebos y las correcciones por ajuste previo que la hacen utilizable. Doudchenko y Imbens (2016) sitúan el control sintético, las diferencias en diferencias y el emparejamiento dentro de una familia común de estimadores de pesos, y son la mejor lectura para entender qué se supone al elegir cada uno. Ben-Michael et al. (2021) proponen el control sintético aumentado para el ajuste previo imperfecto. Athey et al. (2021) introduce matrix completion en el contexto causal y su relación con los estimadores anteriores, y Recht et al. (2010) establece la teoría de la relajación por norma nuclear. Arkhangelsky et al. (2021) propone la diferencia en diferencias sintética como híbrido. Sobre la conexión con la literatura de diferencias en diferencias con adopción escalonada, los mismos problemas vistos desde el otro extremo del espectro de unidades tratadas, véase el Capítulo 17 y sus referencias.

PARTE VIII

Estructura, monitoreo y frontera

Esta parte cierra el libro relajando el supuesto de que el grafo causal es conocido, con algoritmos de descubrimiento de estructura, y extendiendo el sistema desplegado en la Parte IV con lo que un servicio en producción necesita con el tiempo: monitoreo de la validez de sus propios supuestos causales, un patrón responsable de actualización continua, un panorama de la frontera del RL causal, un capítulo sobre cómo comunicar todo esto a las personas que dependen de él, y uno final sobre los supuestos que ningún monitoreo puede ver.

CAPÍTULO 29

Descubrimiento causal y grafos

Cuadro sinóptico del capítulo

Problema:	Inferir la estructura causal (grafo) a partir de datos observacionales
Estimando:	DAG $G = (V, E)$, «CPDAG», matriz de adyacencia $\boldsymbol{W}$
Identificación:	Causal sufficiency, faithfulness, aciclicidad, Markov property
Método:	Basados en restricciones (PC, FCI); basados en score (GES); optimización continua (NOTEARS)
Nuisance:	Tests de independencia, matriz de pesos
Garantía:	Consistencia del esqueleto bajo faithfulness (PC); solución global bajo aciclicidad (NOTEARS)
Librerías:	`dowhy`, `causal-learn`, `networkx`
Validación:	SHD, precisión, recall, estabilidad por subsampling

Nota técnica

Todo el curso, hasta aquí, asumió que el grafo causal, o al menos el conjunto de puerta trasera, estaba dado por conocimiento de dominio. Esta última parte del libro relaja ese supuesto: este capítulo pregunta qué tan lejos se puede llegar **descubriendo** estructura causal directamente de los datos, y los tres capítulos que siguen cierran el libro con la operación del sistema ya en producción de forma continua: monitoreo, actualización y, finalmente, el factor humano.

29.1 Motivación aplicada

Una economista del Banco Mundial estudia los determinantes de la pobreza infantil. Tiene 30 variables (ingreso familiar, educación parental, acceso a salud, nutrición, entorno barrial, etc.) y quiere saber no solo qué variables están correlacionadas con pobreza, sino cuáles son *causas*

y cuáles son *consecuencias*. Esta es la pregunta del *causal discovery*: inferir la estructura causal (grafo) a partir de datos observacionales.

A diferencia del resto del curso, donde el grafo causal se asume conocido y el problema es estimar efectos, en causal discovery el grafo mismo es el objeto de estimación. Pearl (2009) formalizó el marco de DAGs (Directed Acyclic Graphs). Spirtes et al. (2000) introdujo el algoritmo PC basado en tests de independencia condicional. Zheng et al. (2018) propuso NOTEARS, que reformula el descubrimiento causal como optimización continua.

Este capítulo presenta los fundamentos de DAGs, el algoritmo PC y NOTEARS, con implementaciones en `dowhy` y `causal-learn`. Discute los límites para aplicaciones económicas: el supuesto de *causal sufficiency* (no hay confusores no observados) es fuerte y raramente plausible.

29.2 Marco teórico formal

29.2.1 DAGs y el criterio de puerta trasera

Un *DAG* es un grafo dirigido acíclico $G = (V, E)$ donde los nodos son variables y las aristas $X_i \to X_j$ indican causalidad directa. La distribución conjunta factoriza según el DAG:

$$p(X_1, \ldots, X_p) = \prod_i p(X_i \mid \text{parents}(X_i)). \tag{29.1}$$

El criterio de puerta trasera, que dice qué conjuntos de variables permiten identificar un efecto a partir de un DAG dado, se desarrolló en el Capítulo 8. Este capítulo trata el problema inverso: no leer el grafo para decidir qué controlar, sino estimar el grafo mismo.

29.2.2 Algoritmo PC

El algoritmo PC (Spirtes y Glymour, 1991) construye un DAG en tres pasos:

1. **Esqueleto:** empezar con el grafo completo no dirigido. Para cada par (X_i, X_j), testar independencia condicional dado subconjuntos de vecinos. Eliminar la arista si se encuentra independencia.
2. **Orientación de colisionadores:** para cada tripleta $X_i - X_k - X_j$ con X_i y X_j no adyacentes, orientar como $X_i \to X_k \leftarrow X_j$ si X_k no pertenece al conjunto separador que hizo independientes a X_i y X_j.
3. **Reglas de orientación:** aplicar las reglas de Meek para orientar las aristas restantes, evitando ciclos y nuevos colisionadores.

El output es una *CPDAG* (Completed Partially Directed Acyclic Graph), que representa la clase de equivalencia de Markov: DAGs que no pueden distinguirse observacionalmente. Este es el límite duro del descubrimiento a partir de datos observacionales, y es una instancia del mismo principio que el Teorema de la Jerarquía Causal del Capítulo 3, visto desde el ángulo de la estructura: si dos grafos inducen las mismas independencias condicionales, ningún algoritmo que solo mire $P(v)$ puede separarlos.

Kalisch y Bühlmann (2007) establecen las propiedades estadísticas del algoritmo en alta dimensión: bajo *faithfulness*, suficiencia causal, normalidad multivariante y esparsidad del grafo verdadero, la CPDAG estimada por PC es consistente incluso cuando p crece exponencialmente con n. Su análisis aporta además el resultado que más importa en la práctica: el costo computacional crece de forma exponencial con el grado máximo del grafo y solo de forma polinomial con p, lo que hace viable el algoritmo en grafos dispersos y lo vuelve inviable en grafos densos.

Una tercera familia: métodos de score. Junto a los métodos basados en restricciones (PC, FCI) y a los de optimización continua (NOTEARS), existe una tercera familia que busca el grafo que maximiza un criterio de ajuste penalizado, típicamente BIC, sobre el espacio de DAGs. Su representante canónico es GES (*Greedy Equivalence Search*), y Chickering (2002) demuestra un resultado notable: pese a ser una búsqueda voraz sobre un espacio combinatorio enorme, GES es **consistente**, es decir, converge a la clase de equivalencia correcta con probabilidad tendiente a uno. La diferencia práctica con PC es de robustez: PC toma decisiones discretas e irreversibles (eliminar una arista tras un test), de modo que un error temprano se propaga a todo el resto del procedimiento; GES optimiza un criterio global y no arrastra ese tipo de error en cascada. En muestras pequeñas, donde los tests de independencia tienen poca potencia, la diferencia puede ser material.

Advertencia: los métodos de las tres familias son **sensibles a la elección de hiperparámetros** (por ejemplo, el nivel de significancia α en PC o la penalización en GES). (Machlanski et al. 2024) (Machlanski et al. 2024, AISTATS) muestran que pequeños cambios en hiperparámetros pueden producir grafos radicalmente diferentes.

Recomendación: usar análisis de sensibilidad y validación de expertos de dominio.

29.2.3 Pseudocódigo: PC skeleton

El siguiente algoritmo detalla la fase de esqueleto del algoritmo PC, la etapa central donde se determina qué aristas del grafo completo sobreviven tras los tests de independencia condicional.

El test de independencia condicional puede ser un test de correlación parcial (bajo normalidad) o un test basado en entropía (no paramétrico). La elección de α controla la densidad del grafo estimado: α pequeños producen grafos más dispersos. Los sets separadores $\text{sep}(X_i, X_j)$ se preservan para la etapa posterior de orientación de colisionadores.

El algoritmo se detiene cuando ningún nodo tiene más de l vecinos, no cuando un nivel l no elimina ninguna arista. La segunda regla parece razonable y es un error frecuente. Conviene además fijar las adyacencias al comenzar cada nivel (la variante «estable» de PC), para que el resultado no dependa del orden en que se listan las variables.

Algoritmo

Entrada: Datos $\boldsymbol{X} \in R^{n \times p}$, nivel de significación α, orden máximo m
Salida: Esqueleto no dirigido $G = (V, E)$
Inicializar G como grafo completo no dirigido con p nodos
$l \leftarrow 0$
while $l \leq m$ y existe una arista (X_i, X_j) en G con $|\text{adj}(G, X_i) \setminus \{X_j\}| \geq l$ **do**
  for cada arista (X_i, X_j) en G con $|\text{adj}(G, X_i) \setminus \{X_j\}| \geq l$ **do**
    for cada subconjunto $S \subseteq \text{adj}(G, X_i) \setminus \{X_j\}$ con $|S| = l$ **do**
      if test de independencia $X_i \perp\!\!\!\perp X_j \mid S$ no se rechaza a nivel α **then**
        Eliminar arista (X_i, X_j) de G
        Registrar S como *set separador* $\text{sep}(X_i, X_j)$
        break
      end if
    end for
  end for
  $l \leftarrow l + 1$
end while
return G con sets separadores $\text{sep}(\cdot, \cdot)$

Algoritmo 25. PC skeleton: esqueleto del grafo causal

Caso canónico · Un nivel sin eliminaciones no es el final

Cuatro variables con aristas $A \to B$, $A \to X$, $A \to Y$, $B \to X$ y $B \to Y$. Las variables X e Y no son adyacentes, pero solo quedan independientes condicionando en el par $\{A, B\}$: condicionando solo en A sigue abierto el camino por B, y al revés. Con un oráculo de independencia, los niveles $l = 0$ y $l = 1$ no eliminan ninguna arista. Parar en el primer nivel sin eliminaciones deja el grafo completo, con la arista espuria $X - Y$; la regla correcta continúa hasta $l = 2$, separa X de Y con $\{A, B\}$ y recupera el esqueleto exacto.

Con 5 000 unidades y un test de correlación parcial, una simulación reproduce las dos conductas: la regla incorrecta deja la arista espuria y la correcta recupera el esqueleto.

29.2.4 NOTEARS

Zheng et al. (2018) reformulan el descubrimiento causal como optimización continua. La aciclicidad se impone con la restricción:

$$h(\boldsymbol{W}) = \text{tr}(e^{\boldsymbol{W} \circ \boldsymbol{W}}) - p = 0, \tag{29.2}$$

donde $\boldsymbol{W}$ es la matriz de pesos (adyacencia) y $\circ$ es el producto de Hadamard. El problema es:

$$\min_{\boldsymbol{W}} \|X - X\boldsymbol{W}\|_F^2 + \lambda \|\boldsymbol{W}\|_1 \quad \text{sujeto a} \quad h(\boldsymbol{W}) = 0. \tag{29.3}$$

La ventaja: se resuelve con métodos de optimización continua (Lagrangiano aumentado), evitando la búsqueda combinatoria de PC.

Caso canónico · Escala y orientación: la varsortability

Un modelo lineal con cadena $X_0 \to X_1 \to X_2 \leftarrow X_3$, pesos 2,0, 1,5 y 1,0, ruido normal estándar y una variable X_4 aislada. Las varianzas teóricas crecen a lo largo de las cadenas causales: 1 para X_0, 5 para X_1 y 13,25 para X_2. Esa regularidad de escala es una pista sobre el orden causal que un método de optimización continua puede explotar sin que haya detectado ninguna estructura.

En la simulación de este capítulo (1 000 unidades), NOTEARS lineal recupera exactamente las tres aristas sobre los datos en su escala original. Sobre los mismos datos estandarizados, donde desaparece la pista, invierte la orientación de las tres y agrega una arista espuria. El resultado es el fenómeno de *varsortability* documentado por Reisach et al. (2021), y la consecuencia práctica es reportar siempre las dos corridas, con y sin estandarización.

29.2.5 Límites: causal sufficiency

Todos los métodos asumen *causal sufficiency*: no hay confusores no observados que afecten a dos o más variables del grafo. En aplicaciones económicas este supuesto es fuerte.

29.3 Implementación en Python

29.3.1 Construcción de DAGs con dowhy

```
import pandas as pd
from dowhy import CausalModel

# DAG del retorno a la educacion. Los nombres de nodo son los de las columnas
# del dataset; U es un confusor que NO esta en los datos. `fameduc` es una
# caracteristica familiar observada y anterior a la educacion. No se usa la
# experiencia potencial (edad - educ - 6) porque es funcion del tratamiento.
graph = """
graph [
  directed 1
  node [ id "nearc4" label "nearc4" ]
  node [ id "educ" label "educ" ]
  node [ id "lwage" label "lwage" ]
  node [ id "fameduc" label "fameduc" ]
  node [ id "U" label "U" ]
  edge [ source "nearc4" target "educ" ]
  edge [ source "educ" target "lwage" ]
  edge [ source "fameduc" target "educ" ]
  edge [ source "fameduc" target "lwage" ]
  edge [ source "U" target "educ" ]
```

```
  edge [ source "U" target "lwage" ]
]
"""

df = pd.read_csv("../data/datasets/real/public_causaldata/close_college/
data.csv")
model = CausalModel(
    data=df,
    treatment="educ",
    outcome="lwage",
    graph=graph.replace("\n", " "),
)
# Con U sin observar no hay conjunto de ajuste valido: el estimando que queda
# es el del instrumento nearc4, y hay que pedirlo explicitamente.
identified_estimand = model.identify_effect(proceed_when_unidentifiable=True)
print(identified_estimand)
```

Listado 29.1: Identificación con DAGs en dowhy.

Dos detalles del listado importan. Los nombres de nodo del grafo deben coincidir con los de las columnas del dataset, porque `CausalModel` busca el tratamiento y el resultado por nombre, y el grafo debe declararse dirigido. Y el confusor U no tiene columna: es la forma de decir que existe y que no se puede condicionar sobre él. Con ese grafo, ningún conjunto de variables observadas bloquea el camino educ $\leftarrow U \rightarrow$ lwage, así que el criterio de la puerta trasera no identifica el efecto. Lo que sí hace el grafo es declarar que `nearc4` es un instrumento: no tiene flechas desde U ni hacia el resultado, salvo a través de `educ`, y en el grafo sin la flecha educ $\rightarrow$ lwage queda d-separado de `lwage`. Ese es el estimando por variable instrumental que debe devolver `identify_effect`. Además, el DAG no incluye la experiencia potencial como causa de la educación: con la definición habitual (edad menos educación menos seis) es función del tratamiento, y tratarla como covariable previa, como se advirtió en el Capítulo 4, invalida el grafo.

29.3.2 PC con causal-learn y NOTEARS con la implementación de referencia

La librería `causal-learn` (implementación Python del Tetrad original) provee implementaciones eficientes de PC, FCI, GES y LiNGAM, pero no de NOTEARS. Para NOTEARS usamos la implementación de referencia de Zheng et al. (2018), distribuida como paquete `notears` en su repositorio público (`pip install git+https://github.com/xunzheng/notears`).

```
import numpy as np
import pandas as pd
from causallearn.search.ConstraintBased.PC import pc
from notears.linear import notears_linear  # implementación de referencia
(Zheng et al.)
```

```
# --- Datos sintéticos ---
rng = np.random.default_rng(42)
n, d = 1000, 5
# Estructura: X0 -> X1 -> X2, X3 -> X2, X4 aislada
W_true = np.zeros((d, d))
W_true[0, 1] = 2.0; W_true[1, 2] = 1.5; W_true[3, 2] = 1.0
E = rng.standard_normal((n, d))
I = np.eye(d)
X = E @ np.linalg.inv(I - W_true)
df = pd.DataFrame(X, columns=[f"X{i}" for i in range(d)])

# --- PC ---
pc_graph = pc(df.values, alpha=0.05, indep_test="fisherz", show_progress=False)
print(pc_graph.G)  # CPDAG estimada (aristas --- sin orientar, --> orientadas)

# --- NOTEARS ---
W_est = notears_linear(df.values, lambda1=0.05, loss_type="l2")
print("W estimado (NOTEARS):\n", np.round(W_est, 2))

# --- Sensibilidad a la escala: misma corrida sobre datos estandarizados ---
Z = (df - df.mean()) / df.std()
W_std = notears_linear(Z.values, lambda1=0.05, loss_type="l2")
print("W estimado (NOTEARS, estandarizado):\n", np.round(W_std, 2))
```

Listado 29.2: PC con causal-learn y NOTEARS con la implementación de referencia.

La función `pc` de `causal-learn` implementa el algoritmo completo con los tres pasos (esqueleto, colisionadores, reglas de Meek). El argumento `indep_test` permite elegir entre tests paramétricos (`fisherz`) y no paramétricos (`kci`, `chisq`). NOTEARS, en cambio, es sensible a la escala de las variables, como muestra el caso canónico de la varsortability. La verificación se hizo con una reimplementación fiel de `notears_linear` (`herramientas/verificaciones/notears_ref.py`) y con la semilla del listado; en la escala original las varianzas muestrales fueron 1,0 para X_0, 5,3 para X_1 y 13,7 para X_2. La simulación de la regla de parada de PC está en `herramientas/verificaciones/verif_cap29.py`. La figura del caso de estudio se genera con `herramientas/figuras/fig_cap29_dag.py`, que estima los pesos con la misma reimplementación.

29.4 Caso empírico y validación

29.4.1 Evaluación de grafos estimados

Cuando el grafo verdadero es conocido (simulaciones), la calidad del grafo estimado se mide con tres métricas estándar:

- **SHD (Structural Hamming Distance):** número de inserciones, eliminaciones y reorientaciones de aristas que hacen falta para convertir el grafo estimado en el verdadero. Es una métrica global que penaliza errores de omisión, de comisión y de dirección.

- **Precisión:** proporción de aristas orientadas del grafo estimado que existen, con esa dirección, en el grafo verdadero. Mide qué tan confiable es cada arista que el algoritmo reporta.
- **Recall:** proporción de aristas verdaderas que el algoritmo logra recuperar, con su dirección. Mide qué tan completo es el descubrimiento.

Un ejemplo exacto fija las convenciones. En la cadena del caso canónico anterior ($X_0 \to X_1 \to X_2 \leftarrow X_3$, con X_4 aislada), un PC ideal, con un oráculo de independencia, devuelve la CPDAG $X_0 - X_1$, $X_1 \to X_2$, $X_3 \to X_2$: la arista $X_0 - X_1$ queda sin orientar porque ambas direcciones son equivalentes de Markov. Contra el DAG verdadero su SHD es 1 (una reorientación pendiente), su precisión es 1,00 (las dos aristas orientadas son correctas) y su recall es 0,67 (dos de las tres aristas verdaderas recuperadas con su dirección). NOTEARS lineal sobre los datos en su escala original recupera las tres aristas orientadas y tiene SHD 0, precisión 1,00 y recall 1,00. El resultado de NOTEARS no es una ventaja del método: es el efecto de la escala, como muestra el caso canónico de la varsortability.

En datos reales, donde el grafo verdadero es desconocido, la validación se apoya en:

- **Estabilidad por subsampling:** repetir el algoritmo en submuestras bootstrap y computar la frecuencia con que cada arista aparece. Aristas con baja frecuencia (menos del 50 %) son sospechosas de espurias.
- **Análisis de sensibilidad:** variar α (en PC) o λ (en NOTEARS) y observar cómo cambia la estructura. Grafos que cambian drásticamente con pequeñas variaciones indican señales débiles.
- **Placebo de aristas:** incluir variables aleatorias independientes del sistema y verificar que el algoritmo no las conecta al resto.

29.4.2 Caso de estudio: DAGs y descubrimiento causal

La figura 29.1 muestra dos elementos complementarios. El panel izquierdo presenta un DAG explícito, supuesto por el analista, para el problema del retorno a la educación (Card, 1995), donde U representa un confusor no observado (habilidad) que afecta tanto a la educación como al salario. El panel derecho muestra el grafo estimado por NOTEARS sobre datos sintéticos con estructura conocida (la cadena del caso canónico anterior, con una variable aislada).

Interpretación. El DAG del panel izquierdo formaliza la estructura causal supuesta: la proximidad a una universidad afecta la educación pero no directamente el salario (exclusión); el confusor no observado U (habilidad) afecta a ambos, generando el sesgo de variable omitida que justifica el uso de variables instrumentales. El panel derecho muestra que NOTEARS recupera la estructura sobre datos sintéticos de escala favorable. Con datos económicos reales, aplicar un método de descubrimiento requiere cuidado: el supuesto de causal sufficiency raramente se satisface y el grafo estimado debe interpretarse como una guía exploratoria, no como evidencia definitiva.

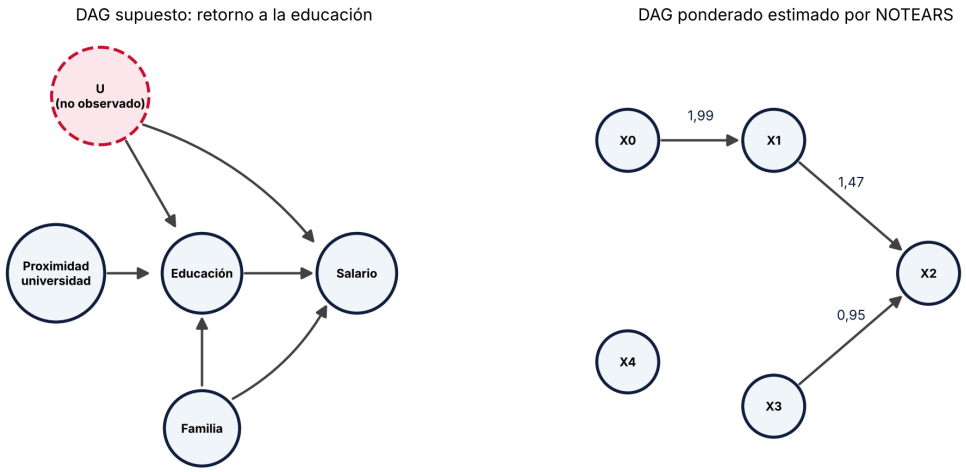


Figura 29.1: Izquierda: DAG supuesto para el retorno a la educación (Card, 1995); U denota un confusor no observado. Derecha: DAG ponderado estimado por NOTEARS sobre datos sintéticos con estructura conocida ($X_0 \to X_1$, $X_1 \to X_2$, $X_3 \to X_2$, y X_4 aislada); las etiquetas en las aristas son los pesos estimados.

Intuición

Caja de profundización: d-separation y cómo evaluar un grafo estimado

Objetivo. Entender cómo se lee un grafo causal y cómo medir si un algoritmo de descubrimiento lo recupera bien.

d-separation: una forma de leer el grafo. Decimos que un conjunto Z «bloquea» un camino entre X e Y si:

- El camino tiene una **secuencia** ($X \to Z \to Y$ o $X \leftarrow Z \leftarrow Y$): Z debe estar en el conjunto.
- El camino tiene un **fork** ($X \leftarrow Z \to Y$): Z debe estar en el conjunto.
- El camino tiene un **collider** ($X \to Z \leftarrow Y$): Z NO debe estar en el conjunto (ni ninguno de sus descendientes).

Si todos los caminos entre X e Y están bloqueados, $X \perp\!\!\!\perp Y \mid Z$.

Evaluación de grafos estimados. Cuando simulamos datos con un grafo verdadero, podemos comparar:

- **SHD (Structural Hamming Distance):** cuántas aristas (presentes, ausentes o mal orientadas) difieren entre el grafo verdadero y el estimado.
- **Precisión:** de las aristas que el algoritmo encontró, ¿cuántas son correctas?
- **Recall:** de las aristas verdaderas, ¿cuántas encontró el algoritmo?

Métodos de descubrimiento.

- **PC:** usa tests de independencia condicional. Bueno si hay suficientes datos.
- **FCI:** permite variables latentes (no observadas).
- **GES:** busca el grafo que maximiza un criterio de ajuste penalizado.

- **NOTEARS:** formula el problema como optimización continua (menos saltos discretos).

29.5 Riesgos, límites y sensibilidad

29.5.1 Tabla de riesgos

Riesgos, límites y mitigación

Riesgo	Consecuencia	Diagnóstico	Mitigación
Causal sufficiency falsa	Grafo sesgado: se omiten aristas o se introducen aristas espurias por la presencia de confusores no observados que afectan a múltiples variables	Comparar resultados con FCI (no asume sufficiency); análisis de sensibilidad ante la posible presencia de *latent confounders*	Usar FCI en lugar de PC cuando haya sospecha de variables latentes; reportar siempre el supuesto y discutir su plausibilidad en el contexto aplicado
Faithfulness débil	Independencias condicionales engañosas: una arista verdadera se elimina porque el test de independencia no la detecta (cancelación de caminos opuestos)	Realizar tests de independencia con múltiples umbrales ($\alpha = 0.01, 0.05, 0.10$) y verificar si la estructura es estable	Usar tests no paramétricos (KCI) cuando las relaciones sean no lineales; aumentar n si es posible; aplicar bootstrap de aristas para evaluar estabilidad
Sobreajuste estructural	Aristas espurias: el algoritmo detecta dependencias que son ruido muestral, especialmente con p grande relativo a n	Subsampling: repetir el algoritmo en B submuestras bootstrap y retener solo aristas con frecuencia mayor que 70 %	Regularización: aumentar α en PC (grafos más dispersos) o λ en NOTEARS; usar BIC como criterio de selección de modelo; validar con hold-out

Riesgo	Consecuencia	Diagnóstico	Mitigación
Escala y orden de las variables	El método de optimización continua explota la regularidad de escala (varsortability) y orienta mal las aristas	Repetir la corrida con y sin estandarización y comparar las orientaciones	Reportar solo las aristas cuya dirección sobrevive a ambas escalas; no confiar en la orientación como evidencia causal

Tabla 29.1: Riesgos en descubrimiento causal y grafos

29.5.2 Límites del descubrimiento causal

Causal discovery en economía es difícil por la presencia ubicua de confusores no observados. Los métodos son útiles como *exploración* de estructura, no como reemplazo del razonamiento económico sustantivo. Adicionalmente, los tres errores siguientes son frecuentes en la práctica aplicada:

1. **Interpretar la CPDAG como DAG.** PC produce una clase de equivalencia; algunas aristas no se pueden orientar observacionalmente. Presentar el grafo como si todas las aristas estuvieran dirigidas induce una falsa certeza sobre la direccionalidad causal.
2. **Aplicar NOTEARS sin normalizar variables.** NOTEARS es sensible a escala; conviene estimar la matriz de pesos con y sin estandarización (media cero, varianza uno) y reportar ambas. Este punto es más grave de lo que sugiere su formulación como consejo de preprocesamiento: en un modelo lineal-gaussiano, reescalar las variables cambia el grafo que el criterio de NOTEARS considera óptimo, de modo que el «descubrimiento» puede estar reflejando las unidades de medida y no la estructura causal.
3. **Usar un solo umbral de significación.** La elección de α en PC (o λ en NOTEARS) tiene un efecto grande sobre la densidad del grafo. Reportar siempre un análisis de sensibilidad con múltiples valores.

Sobre el tercer punto, con más peso del que suele dársele. Machlanski et al. (2024) evalúan sistemáticamente la sensibilidad de los algoritmos de descubrimiento a sus hiperparámetros y encuentran que el efecto de esa elección es **comparable o mayor** que las diferencias entre algoritmos: el ranking de métodos publicado en un *benchmark* puede invertirse ajustando los hiperparámetros de forma distinta pero igualmente razonable. La implicación metodológica es incómoda y conviene asumirla: buena parte de las comparaciones «algoritmo A supera a algoritmo B» en esta literatura no es replicable fuera de la configuración exacta del estudio original.

Para la práctica de este curso se siguen dos reglas. Primera, **ningún grafo descubierto se reporta como un objeto único**: se reporta la familia de grafos obtenida al variar α (o λ) en un rango declarado, y las aristas se clasifican por su estabilidad a través de esa familia y de submuestras bootstrap. Segunda, **el output del descubrimiento no alimenta**

directamente la estimación: una arista descubierta es una hipótesis para discutir con conocimiento de dominio, no un supuesto de identificación validado. Dejar que un algoritmo de descubrimiento fije el conjunto de puerta trasera que luego usará el DML es trasladar al algoritmo exactamente la responsabilidad que el Capítulo 3 demostró que no puede tener.

29.6 Ejercicios propuestos

29.6.1 Ejercicios teóricos

1. Construya un DAG para el efecto de dejar de fumar sobre el peso, justificando cada arista. Identifique un conjunto de control mediante el criterio de puerta trasera del Capítulo 8.
2. Dado el DAG $X \to Z \leftarrow Y$, ¿qué CPDAG devuelve un PC con oráculo? ¿Y para $X \to Z \to Y$? Explique por qué en el segundo caso ninguna arista puede orientarse.
3. Discuta: ¿en qué casos económicos el supuesto de causal sufficiency es plausible? Dé tres ejemplos donde no lo es.
4. Muestre, con el DAG del caso canónico de la regla de parada, que parar en el primer nivel sin eliminaciones es incorrecto. ¿Qué par de variables queda mal conectado y con qué conjunto separador se elimina?

29.6.2 Ejercicios computacionales

1. Aplique NOTEARS a un dataset sintético con 5 variables y estructura conocida, con y sin estandarización. ¿Recupera la estructura en cada caso?
2. Use `dowhy` para identificar el efecto de `educ` sobre `lwage` bajo tres DAGs distintos. ¿Cómo cambia el set de control recomendado?
3. Construya el DAG del ejercicio teórico 1 con `networkx` y compruebe el conjunto de control con la prueba de d-separación.

29.7 Lecturas complementarias

Pearl (2009) es la referencia canónica para DAGs, d-separación y clases de equivalencia. Spirtes et al. (2000) introduce el algoritmo PC y el marco de descubrimiento basado en restricciones; Kalisch y Bühlmann (2007) establece su consistencia en alta dimensión y es la referencia a citar cuando se aplica PC con p grande. Chickering (2002) demuestra la consistencia de GES y es la entrada a la familia de métodos basados en score, complementaria a las otras dos. Zheng et al. (2018) reformulan el problema como optimización continua con la restricción de aciclicidad diferenciable (NOTEARS).

Sobre los límites prácticos del campo, Machlanski et al. (2024) documentan la sensibilidad a hiperparámetros discutida en la Sección 29.5 y son lectura obligada antes de tomar cualquier *benchmark* de descubrimiento al pie de la letra; Reisach et al. (2021) documentan el efecto de la

escala en los métodos de optimización continua. Sharma y Kiciman (2020) documenta `dowhy`. Para la implementación en Python, `causal-learn` (https://github.com/py-why/causal-learn) es la librería de referencia, con implementaciones de PC, FCI, GES y otros algoritmos de descubrimiento causal.

CAPÍTULO 30

Monitoreo de supuestos causales en producción

Cuadro de decisión del capítulo

Decisión:	Monitorear la validez de los supuestos causales, no solo la distribución de entradas y salidas
Alternativas:	Monitoreo genérico de ML (drift de *inputs*/*outputs*) vs. monitoreo causal-aware (drift de identificación)
Trade-off clave:	Costo de cómputo del monitoreo adicional vs. riesgo de servir estimaciones inválidas sin saberlo
Stack:	`scipy.stats`, Streamlit local para el dashboard
Riesgo principal:	Que el servicio siga respondiendo con normalidad mientras el efecto que reporta ya no es válido

Implementación en el monorepo del curso (2026)

Dashboard de referencia: `04_notebooks_produccion_streamlit/B4_monitoring_dashboard/` (Streamlit local; KS de covariables, tasa de tratamiento, proxy de estabilidad). Labs `L25` y `L27` (reentrenar vs alertar). Humo: `grade_b4.py`. El monitoreo del curso es **docente y simulado** sobre el benchmark; en un sistema real se conecta al tráfico local del endpoint B1. Verificación de las cifras: `herramientas/verificaciones/verif_cap30.py` y `verif_listados_cap30.py`.

30.1 El problema de diseño

El monitoreo estándar de sistemas de ML en producción, el que describe (Kästner et al. 2024) en su discusión de *data distribution shifts*, vigila si la distribución de las variables de entrada o de las predicciones se aleja de la observada en entrenamiento. Ese monitoreo es

necesario pero **no suficiente** para un sistema causal: el servicio del Capítulo 15 puede seguir respondiendo con total normalidad (mismo formato, mismo rango de valores, ninguna alerta de *drift* estándar) mientras el efecto que reporta dejó de ser válido, porque cambió algo que ningún monitoreo de *drift* genérico observa: la fuerza de un instrumento, el soporte común entre tratados y controles, o la estabilidad del efecto estimado en ventanas recientes de datos. El problema de diseño de este capítulo es definir qué métricas, específicas de validez causal y no solo de distribución de datos, deben monitorearse continuamente.

30.2 Opciones y trade-offs

Opciones y trade-offs

- **Monitoreo genérico.** Vigila solo la distribución univariada de las covariables de entrada (tests de Kolmogorov-Smirnov o similares) y, si acaso, la distribución de las predicciones. Es barato de implementar y es lo que ofrecen la mayoría de las herramientas de MLOps por defecto. No detecta, por construcción, ningún problema de identificación: un cambio en la relación entre covariables y tratamiento, que rompe el supuesto de no confusión sin alterar la distribución marginal de ninguna variable por separado, pasa completamente inadvertido.
- **Monitoreo causal-aware.** Extiende el monitoreo genérico con métricas específicas: reejecutar el chequeo de balance del Capítulo 7 sobre los datos recientes, verificar que el soporte común no se haya erosionado y, cuando aplica, verificar que la fuerza del instrumento (el F-estadístico de la primera etapa, Capítulo 17) no haya caído por debajo de los umbrales convencionales. Es más costoso de mantener y requiere mantener disponible el pipeline de estimación completo, no solo el servicio de predicción, para poder recalcular estas métricas periódicamente.

30.3 Decisión de referencia para el curso

El sistema de referencia del curso monitorea cuatro métricas causales específicas, además del monitoreo genérico de *inputs*: **(i)** *drift* de covariables por variable; **(ii)** *drift* de la relación **entre** covariables y tratamiento, que es la que sostiene el supuesto de identificación; **(iii)** fuerza de la relación tratamiento-instrumento en la ventana reciente, cuando el diseño la usa; **(iv)** estabilidad del efecto **reestimado** en ventanas móviles, contrastada mediante un test formal y no por inspección de si un número cae dentro de un intervalo.

Cuatro precisiones sobre el diseño de estas métricas, porque la versión ingenua de cada una falla de forma característica.

Sobre (i): el test KS no es suficiente y su p-valor engaña. Con ventanas grandes, el test de Kolmogorov–Smirnov rechaza ante diferencias irrelevantes; con ventanas pequeñas, no detecta diferencias materiales. Es el mismo problema que el t-test tenía en el chequeo de balance del Capítulo 7, y admite la misma solución: reportar un **tamaño de efecto** junto al p-valor.

Las dos medidas convencionales son la **ASMD** (diferencia media estandarizada absoluta, la SMD ya usada en aquel capítulo, aplicada ahora entre entrenamiento y ventana reciente) y el **PSI** (*Population Stability Index*), $\text{PSI} = \sum_b (p_b - q_b)\log(p_b/q_b)$ sobre una discretización en *bins*, cuyos umbrales convencionales en la industria son $\text{PSI} < 0.1$ (estable), 0.1–0.25 (revisar) y > 0.25 (deriva material).

El PSI tiene además un defecto de implementación frecuente. Si el histograma de la ventana se calcula con los bordes de entrenamiento, los valores que caen fuera de ese rango se descartan, y esos son justo los de una cola nueva. En una simulación donde el 20 % de los valores recientes cae en una cola que el entrenamiento no tenía, esa versión reporta un PSI de 0,05 (estable) y la que abre el primer y el último *bin* al infinito reporta 0,22 (revisar).

Sobre (ii): el *drift* que rompe la identificación puede no mover ninguna marginal. Esta es la métrica que distingue el monitoreo causal del genérico, y suele omitirse. La no confusión no depende de la distribución marginal de cada covariable sino de la **relación** entre covariables y asignación al tratamiento. Si el criterio con que se asigna el tratamiento cambia (un nuevo equipo comercial prioriza distinto, se modifica una regla de elegibilidad), la distribución de cada X_j puede permanecer idéntica y aun así el supuesto de identificación haber dejado de sostenerse. La forma económica de vigilarlo es preguntar si el *propensity score* aprendido en la referencia sigue ordenando bien la asignación en la ventana reciente: se ajusta $\hat{e}(X)$ con los datos de referencia, se calcula su AUC sobre la ventana nueva y se compara con su AUC de validación cruzada en la referencia. Una caída indica que lo que el modelo sabía sobre cómo se asigna el tratamiento dejó de valer.

La versión tentadora, reajustar el *propensity* en cada ventana y comparar las AUC, falla justo en el caso que importa. Si pasa a mandar otra covariable con una fuerza parecida a la de la anterior, el AUC reajustado apenas se mueve, porque la regla nueva es tan predecible como la vieja. En una simulación donde la regla pasa de depender de una covariable a depender de otra (ventanas de 400 observaciones, 100 réplicas), el criterio reajustado detectó el cambio en 2 % de las ventanas; puntuar el modelo de referencia lo detectó en todas y no dio falsas alarmas en las ventanas sin cambio.

Sobre (iii): el F debe ser el del instrumento, no el del modelo. La fuerza del instrumento se mide con el F de la primera etapa para el instrumento excluido. El F global de la regresión mide el ajuste conjunto de todos los regresores, y se infla cuando las covariables predicen bien el tratamiento aunque el instrumento no aporte nada. El umbral convencional $F > 10$ proviene de Stock y Yogo (2005) y está derivado para un solo instrumento y una primera etapa lineal. Aplicarlo fuera de ese caso exige justificación adicional.

Sobre (iv): comparar un punto contra un intervalo no es un test. Verificar si el efecto reciente cae dentro del IC original ignora por completo la incertidumbre del efecto reciente, y por tanto ni controla el error de tipo I ni tiene potencia interpretable. El contraste correcto es entre dos estimaciones, cada una con su error estándar: bajo independencia de las dos ventanas,

$$z = \left(\hat{\theta}_{\text{rec}} - \hat{\theta}_{\text{orig}}\right) \Big/ \sqrt{\text{SE}_{\text{rec}}^2 + \text{SE}_{\text{orig}}^2} \tag{30.1}$$

es aproximadamente normal estándar bajo la hipótesis nula de efecto estable. Esto exige **reestimar** el efecto en la ventana reciente, no solo predecir con el modelo antiguo, que por construcción devuelve el efecto antiguo. Es la razón por la que el monitoreo causal requiere mantener disponible el pipeline de estimación completo y no solo el servicio de inferencia.

Sobre los umbrales: se calibran, no se heredan. Un umbral fijo mezcla dos cosas. La distribución de un estadístico cuando nada cambió depende del tamaño de la ventana y de cuántas covariables se vigilan, así que el mismo número resulta demasiado sensible en un sistema y demasiado romo en otro. El procedimiento es tomar ventanas del propio periodo de referencia (sin cambio por construcción), calcular el estadístico en cada una y fijar el umbral en el cuantil que corresponde a la tasa de falsas alarmas que el equipo está dispuesto a tolerar. Los umbrales convencionales de este capítulo (PSI de 0,1 y 0,25, ASMD de 0,25, $F > 10$) son puntos de partida para ese ejercicio, no sustitutos de él.

Caso canónico · Ventana nula del test KS

Una referencia de 2000 observaciones y seis covariables independientes, todas normales estándar. Se extraen 1000 ventanas sin ningún cambio, de tamaño n, y en cada una se registra el mayor KS entre las seis covariables.

n	Falsa alarma con umbral fijo 0,12	Umbral calibrado (percentil 95)
100	57 %	0,17
300	menos de 1 %	0,10
1000	0 %	0,07

El umbral fijo dispara en más de la mitad de las ventanas pequeñas aunque no haya cambiado nada, y es demasiado romo en las grandes. Con ventanas de 300 observaciones y un desplazamiento de 0,3 desviaciones estándar en una sola covariable, el umbral calibrado detecta el 76 % de las ventanas y el fijo, el 53 %. Las cifras provienen de una simulación con semillas fijas y se reproducen con la verificación del Cap. 30 del material complementario.

30.4 El contrato del monitoreo causal

El libro no fija una herramienta de monitoreo: fija un contrato. Cualquier sistema, sea un tablero, una tarea programada o una alerta por correo, lo cumple si pasa su prueba de aceptación. Este contrato cierra el ciclo con los anteriores: lee la ficha del modelo (C-05), reestima con el mismo pipeline que pasó la compuerta de registro (C-06) y devuelve una de las cinco acciones del Sección 2.5.

Contrato C-07 · Monitoreo causal

Operaciones	*evaluar*: recibe una ventana reciente de datos y devuelve el reporte de las cuatro señales y la acción que corresponde. *calibrar*: toma ventanas del periodo de referencia, sin cambio por construcción, y fija los umbrales para una tasa de falsas alarmas declarada.
Entrada	La referencia (los datos de entrenamiento, con su huella). Los roles causales y el efecto con su error estándar, tal como los registra la ficha del modelo (Capítulo 19), junto con los supuestos que la ficha declara observables y sus umbrales. Una función que reestima el efecto con el pipeline completo. Los umbrales vigentes, con la tasa de falsas alarmas y la fecha con que se calibraron.
Salida	Para cada señal, su valor, su umbral y su estado, nunca un semáforo sin número. Una sola acción, la de la primera pregunta que falla según el orden de la Tabla 30.1.
Invariantes	(1) La referencia es fija: toda comparación usa la misma, de modo que las alertas son comparables en el tiempo. (2) Todo umbral lleva su tasa de falsas alarmas y su fecha de calibración. (3) El mecanismo de asignación se puntúa con el modelo de la referencia y no se reajusta en la ventana. (4) El efecto se reestima, no se predice con el modelo antiguo, y el contraste propaga los dos errores estándar. (5) Con la misma ventana, la misma referencia y los mismos umbrales, el reporte es idéntico. (6) Una ventana demasiado pequeña para calibrar, o con valores faltantes en las columnas vigiladas, se reporta como «sin evidencia» y nunca como «todo en orden».
Modos de fallo	Un umbral heredado de otro sistema: alarmas constantes o silencio. Reajustar el *propensity* en cada ventana: el cambio de regla pasa inadvertido. Comparar el efecto reciente contra el intervalo antiguo en vez de contrastar dos estimaciones. Un PSI con los bordes de entrenamiento cerrados: la cola nueva se descarta. Vigilar solo el efecto, y reaccionar siempre tarde, o solo las marginales, y alertar sin consecuencia. Un contraste con $\alpha = 0.05$ evaluado cada día: da, en teoría, una falsa alarma cada veinte días en ventanas independientes.
Prueba de aceptación	Sobre un generador con verdad conocida (el caso canónico de más abajo) se comprueba que cada cambio inyectado enciende la señal que le corresponde y no las demás. (a) Sin cambio, la tasa de ventanas con alguna señal encendida no supera la tasa

declarada en la calibración. (b) Un desplazamiento marginal enciende la (i). (c) Un cambio de regla de asignación, sin mover ninguna marginal, enciende la (ii) y no la (i). (d) Un instrumento sin fuerza enciende la (iii). (e) Un cambio del efecto enciende la (iv).

El contrato reutiliza lo que ya existe en capítulos anteriores. La señal (i) es el chequeo de balance del Capítulo 7 con los mismos estadísticos de tamaño de efecto, aplicado ahora a entrenamiento contra ventana reciente y no a tratados contra controles. La (ii) reutiliza el *propensity score* que el Capítulo 11 ya estima como *nuisance*. La (iii) es el diagnóstico de instrumentos débiles del Capítulo 17. La (iv) necesita el pipeline de estimación completo y no solo el modelo servido en el Capítulo 15.

Caso canónico · Un generador con cuatro cambios posibles

Se simulan unidades con tres covariables normales estándar X_1, X_2, X_3 y un instrumento $Z \sim N(0,1)$. El tratamiento es binario, $D \sim \text{Bernoulli}(\sigma(X_1 + 0.8Z))$, y el resultado es $Y = \tau D + X_1 + 0.5X_3 + \varepsilon$ con $\tau = 0.5$ y $\varepsilon \sim N(0,1)$. La referencia tiene 3 000 unidades y cada ventana reciente, 400. Se inyecta un cambio por vez: un desplazamiento de X_3 en una desviación estándar; un cambio de regla, con la asignación dependiendo de X_2 en lugar de X_1; un instrumento sin efecto sobre el tratamiento; y un efecto que baja de 0,5 a 0,1.

La tabla da el porcentaje de 100 ventanas recientes en que se enciende cada señal.

Cambio inyectado	**(i)**	**(ii)**	**(iii)**	**(iv)**
Ninguno	0 %	0 %	0 %	2 %
Desplazamiento de X_3 en una DE	100 %	0 %	0 %	2 %
Regla de asignación (X_1 pasa a X_2)	0 %	100 %	0 %	1 %
Instrumento sin efecto	0 %	0 %	99 %	2 %
Efecto de 0,5 a 0,1	0 %	0 %	0 %	95 %

Cada cambio enciende la señal que le corresponde y casi ninguna otra. La tercera fila es el caso que justifica la señal (ii): la regla de asignación cambió, ninguna distribución marginal se movió, y solo el modelo de referencia puntuado sobre la ventana lo ve. La cuarta es la pérdida de fuerza del instrumento, que detecta la (iii) en el 99 % de las ventanas, y la última es el cambio de efecto, que solo detecta la (iv), en el 95 %. Sin cambio alguno, la única señal que se enciende es la (iv), en el 2 % de las ventanas, por debajo del 5 % nominal. Estas tasas son por ventana. En una serie de ventanas sucesivas las falsas alarmas se acumulan: en las series de deriva de la Sección 30.6, el 42 % de las series de diez ventanas tuvo al menos una falsa alarma de la (iv).

Una observación sobre el orden de las alertas, que es lo que hace útil el reporte en vez de solo ruidoso. Las cuatro métricas no son intercambiables ni igual de graves. El *drift* marginal (i) es una señal **temprana** y con frecuencia benigna: la población cambia y el modelo puede seguir siendo válido. El *drift* del mecanismo de asignación (ii) ataca directamente el supuesto de identificación y es el más serio aunque el efecto estimado todavía no se haya movido. La caída de fuerza del instrumento (iii) invalida la inferencia aunque el efecto puntual parezca estable. Y el cambio en el efecto (iv) es la señal **tardía**, la que llega cuando el problema ya está afectando a las decisiones. Un sistema que solo monitorea (iv) reacciona siempre tarde; uno que solo monitorea (i) genera alertas constantes sin consecuencia. El valor del reporte está en leer las cuatro juntas.

30.5 Implementación de referencia

El listado implementa las cuatro señales como funciones independientes y un reporte que las combina. Lee los roles y el efecto de la ficha del modelo, de modo que no depende de ningún objeto serializado del notebook.

```
import numpy as np
import pandas as pd
from scipy import stats
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import roc_auc_score
from sklearn.model_selection import cross_val_predict

# --- (i) Drift marginal de covariables: tamano de efecto + p-valor ----
def drift_covariables(df_train, df_rec, covariables, psi_bins=10):
    """PSI y ASMD por covariable. El p-valor KS se reporta pero NO se usa
    como criterio: con ventanas grandes rechaza ante diferencias
    irrelevantes (mismo problema que el t-test en el chequeo de balance)."""
    filas = []
    for c in covariables:
        a, b = df_train[c].dropna(), df_rec[c].dropna()
        s_pool = np.sqrt((a.var(ddof=1) + b.var(ddof=1)) / 2)
        asmd = abs(a.mean() - b.mean()) / s_pool if s_pool > 0 else 0.0
        # PSI sobre bins definidos por los cuantiles de ENTRENAMIENTO. Los
        # extremos se abren a +-inf: con los bordes de entrenamiento,
        # np.histogram descartaria los valores nuevos fuera de rango, que son
        # justo la cola que el monitoreo tiene que ver.
        bordes = np.unique(np.quantile(a, np.linspace(0, 1, psi_bins + 1)))
        bordes[0], bordes[-1] = -np.inf, np.inf
        p = np.histogram(a, bins=bordes)[0] / len(a)
        q = np.histogram(b, bins=bordes)[0] / len(b)
        eps = 1e-6
        p, q = np.clip(p, eps, None), np.clip(q, eps, None)
        psi = float(((p - q) * np.log(p / q)).sum())
        filas.append({
```

```
            "covariable": c, "asmd": asmd, "psi": psi,
            "p_ks": stats.ks_2samp(a, b).pvalue,
            # Umbrales convencionales; declararlos, no descubrirlos
            "alerta": (psi > 0.25) or (asmd > 0.25),
        })
    return pd.DataFrame(filas).sort_values("psi", ascending=False)

# --- (ii) Drift de la relacion X -> D (lo que rompe la identificacion) -
def drift_mecanismo_asignacion(df_train, df_rec, covariables, tratamiento,
                               tolerancia=0.10):
    """Lo que el modelo aprendio sobre COMO se asigna el tratamiento, sigue
    valiendo en la ventana reciente? Se ajusta el propensity en la referencia
    y se PUNTUA en la ventana. Reajustarlo en cada ventana no sirve: si cambia
    QUE covariable manda pero no cuanto, el AUC reajustado casi no se mueve.
    La tolerancia es un punto de partida: calibrela con ventanas sin cambio."""
    modelo = LogisticRegression(max_iter=1000)
    p_cv = cross_val_predict(modelo, df_train[covariables],
df_train[tratamiento],
                             cv=5, method="predict_proba")[:, 1]
    auc_train = roc_auc_score(df_train[tratamiento], p_cv)
    modelo.fit(df_train[covariables], df_train[tratamiento])
    p_rec = modelo.predict_proba(df_rec[covariables])[:, 1]
    auc_rec = roc_auc_score(df_rec[tratamiento], p_rec)
    return {"auc_entrenamiento": auc_train, "auc_reciente": auc_rec,
            "delta_auc": auc_rec - auc_train,
            "alerta": (auc_train - auc_rec) > tolerancia}

# --- (iii) Fuerza del instrumento ------------------------------------
def fuerza_instrumento(df_rec, instrumento, tratamiento, covariables,
umbral_f=10):
    """F de la PRIMERA ETAPA sobre el instrumento excluido, no el F global del
    modelo: ese mide el ajuste conjunto de TODOS los regresores e infla el
    diagnostico cuando las covariables predicen bien el tratamiento.
    Umbral convencional F > 10 (Stock y Yogo, 2005); por debajo, alerta."""
    y = df_rec[tratamiento].to_numpy(float)
    W = np.c_[np.ones(len(y)), df_rec[covariables].to_numpy(float)]
    Z = np.c_[W, df_rec[instrumento].to_numpy(float)]

    def rss(X):
        beta = np.linalg.lstsq(X, y, rcond=None)[0]
        return float(((y - X @ beta) ** 2).sum())

    rss_r, rss_u = rss(W), rss(Z)            # sin y con el instrumento
    f_stat = (rss_r - rss_u) / (rss_u / (len(y) - Z.shape[1]))
    return {"f_primera_etapa": f_stat, "alerta_debil": f_stat < umbral_f}

# --- (iv) Estabilidad del efecto: contraste formal entre ventanas ------
```

```
def estabilidad_efecto(reestimar, df_rec, theta_orig, se_orig, alpha=0.05):
    """Reestima el efecto en la ventana reciente y contrasta H0: los dos
    efectos son iguales, propagando AMBOS errores estandar.

    `reestimar(df) -> (theta, se)` corre el pipeline de estimacion completo.
    No basta con predecir con el modelo antiguo: eso devuelve, por
    construccion, el efecto antiguo."""
    theta_rec, se_rec = reestimar(df_rec)
    se_combinado = np.sqrt(se_orig**2 + se_rec**2)
    z = (theta_rec - theta_orig) / se_combinado
    p_valor = 2 * (1 - stats.norm.cdf(abs(z)))
    return {"theta_original": theta_orig, "theta_reciente": theta_rec,
            "se_reciente": se_rec, "z": z, "p_valor": p_valor,
            "alerta": p_valor < alpha}

def reporte_monitoreo(df_train, df_rec, roles, reestimar, theta_orig, se_orig):
    """`roles` es la seccion "roles" de model_card.json (tratamiento,
covariables,
    instrumentos); theta_orig y se_orig salen de metricas.efecto y
metricas.ic95."""
    cov, trat = roles["covariables"], roles["tratamiento"]
    drift = drift_covariables(df_train, df_rec, cov)
    reporte = {
        "drift_covariables": drift,
        "drift_mecanismo_asignacion": drift_mecanismo_asignacion(
            df_train, df_rec, cov, trat),
        "estabilidad_efecto": estabilidad_efecto(
            reestimar, df_rec, theta_orig, se_orig),
    }
    if roles.get("instrumentos"):
        reporte["fuerza_instrumento"] = fuerza_instrumento(
            df_rec, roles["instrumentos"][0], trat, cov)
    reporte["requiere_atencion"] = bool(
        drift["alerta"].any()
        or reporte["drift_mecanismo_asignacion"]["alerta"]
        or reporte["estabilidad_efecto"]["alerta"]
        or reporte.get("fuerza_instrumento", {}).get("alerta_debil", False)
    )
    return reporte
```

Listado 30.1: Las cuatro métricas de monitoreo causal sobre una ventana reciente de datos.

En el listado, `drift_covariables` implementa la señal (i), `drift_mecanismo_asignacion` la (ii), `fuerza_instrumento` la (iii) y `estabilidad_efecto` la (iv). La función de reestimación que recibe `estabilidad_efecto` corre el pipeline del Capítulo 11 sobre la ventana y devuelve el efecto y su error estándar.

30.6 Aplicación al sistema causal del curso

La aplicación del contrato muestra el **orden temporal** en que se encienden las alertas ante una deriva gradual. En una simulación con diez ventanas sucesivas de 400 observaciones, en las que la media de una covariable sube 0,2 desviaciones estándar por ventana, la señal (i) se enciende en la segunda ventana (mediana de 40 series), tanto si la covariable modula el efecto como si no. Lo que distingue un caso del otro es la (iv). Si la covariable no modula el efecto, la (iv) no pasa de su tasa de falsas alarmas: se enciende en el 4,8 % de las ventanas. Si lo modula (el efecto es $0.5 + 0.5X_2$ y la covariable que deriva es X_2), se enciende en el 82 % de las ventanas, por primera vez en la ventana 2,5 (mediana), y ninguna de las 40 series quedó sin alerta. El *drift* de covariables es, con frecuencia, la señal temprana de que el efecto reportado empezará a ser poco confiable, pero por sí solo no dice si importa; monitorear solo el efecto final deja al sistema sin saber qué cambió. Leer las dos juntas es lo que convierte la alerta en información.

El caso complementario es el cambio de regla de asignación del tratamiento, que no mueve ninguna distribución marginal de covariables. Ahí la señal (i) no reporta nada, correctamente, porque nada marginal cambió, y solo la (ii) lo detecta (Sección 30.4). Es la demostración práctica de por qué un monitoreo de MLOps genérico, por completo que sea en su propio terreno, no basta para un sistema causal: el supuesto que se está violando no es una propiedad de los datos de entrada, sino de la relación entre ellos y la decisión que generó el tratamiento.

El Notebook de producción B4 despliega la función `reporte_monitoreo` del listado 30.1 como un tablero local de Streamlit sobre un escenario simulado de *drift* gradual.

30.7 De la señal a la acción

Un reporte con cuatro semáforos deja sin responder lo importante: qué hacer. El sistema de referencia usa cinco acciones (continuar, alertar, abstenerse, revisar la identificación y reentrenar) y hace las preguntas en orden de gravedad: la primera que falla decide.

Pregunta	Si falla	Acción
1) ¿Hay soporte suficiente de tratados y controles?	Sin soporte no hay estimador que juzgar; responder sería extrapolar	**Abstenerse** de responder para esas unidades
2) ¿Sigue vigente la identificación?	Cambió el mecanismo de asignación o se debilitó el instrumento, aunque el efecto todavía se vea estable	**Revisar la identificación** (decide una persona)
3) ¿Pasa la estadística y es comparable la población?	El pipeline falla o la población cambió; el efecto puede seguir siendo válido, pero para otra población	**Alertar**

Pregunta	Si falla	Acción
4) ¿Cambió el efecto?	Con lo anterior en orden, un cambio de efecto sí justifica actualizar el modelo	**Reentrenar**, con el champion-challenger del Capítulo 31
Todo en orden		**Continuar**

Tabla 30.1: Orden de las preguntas de monitoreo y la acción que dispara cada una.

El orden se defiende por lo que cada fallo deja sin sentido. Sin soporte, las demás señales no significan nada. Si la identificación ya no se sostiene, el efecto estimado está mal aunque la población sea la misma y aunque el número parezca estable; una población distinta, en cambio, puede dar un efecto perfectamente válido para otra, y solo requiere que alguien decida a cuál sirve. Un cambio de efecto que llega junto con un pipeline roto o una población nueva no es buena razón para reemplazar el modelo sin mirar. Otro orden puede sostenerse (por ejemplo, la estadística antes que la identificación, porque un pipeline roto no merece la discusión), pero no tener ninguno es indefendible: el sistema acaba reentrenando cada vez que algo se mueve, que es la forma más frecuente de borrar la base sobre la que se estimó el efecto.

Las cuatro señales vigilan supuestos observables. El que más pesa, que no haya confusión que las covariables medidas no recojan, no tiene señal: el sistema puede estar quieto en las cuatro y sesgado por una causa que nadie midió. Eso no se arregla con un quinto semáforo. Se arregla con otra cosa, que es declarar cuánto margen tiene la decisión frente a ese supuesto y cuándo se vuelve a mirar (Capítulo 33).

30.8 Señales de alerta y checklist operativo

- ☐ El sistema solo monitorea la disponibilidad del servicio (¿responde?), no la validez estadística de lo que responde.
- ☐ El chequeo de balance del entrenamiento nunca se vuelve a ejecutar sobre datos de producción.
- ☐ No existe una ventana de referencia fija para comparar la estabilidad del efecto; cada comparación usa un punto de referencia distinto, haciendo las alertas no comparables en el tiempo.
- ☐ Las alertas de monitoreo se generan pero nadie las revisa: no hay un proceso definido de qué hacer cuando el reporte pide atención (retomado en el Capítulo 31).
- ☐ Los umbrales se heredaron de otro sistema o de una guía, sin medir cuántas alarmas dan en ventanas sin cambio.
- ☐ Todos los semáforos están en verde y nadie ha dicho qué pasa con los supuestos que ningún semáforo vigila (Capítulo 33).

30.9 Ejercicios y notas bibliográficas

30.9.1 Ejercicios conceptuales

1. Explique por qué el monitoreo genérico de *drift* de predicciones (vigilar solo la distribución de $\hat{Y}$) puede no detectar un problema de validez causal aunque la distribución de $\hat{Y}$ se mantenga estable.
2. Para el sistema del Notebook A2 (DML sobre retornos a la educación), proponga un escenario concreto de cambio en los datos que dispare la alerta de fuerza del instrumento sin disparar ninguna alerta de *drift* de covariables.
3. Construya un escenario simulado en el que la regla de asignación del tratamiento cambie (por ejemplo, que pase a depender de una covariable que antes no usaba) **manteniendo idénticas todas las distribuciones marginales de covariables**. Verifique que la señal (i) no reporta nada y que la (ii) sí. Explique qué supuesto de identificación se ha violado.
4. Compare, sobre una ventana con *drift* leve, el veredicto del test formal de estabilidad del efecto con el del criterio ingenuo («¿el efecto reciente cae dentro del IC original?»). Muestre un caso en que ambos difieran y argumente cuál de los dos debe gobernar la alerta.
5. La señal (iv) con $\alpha = 0.05$ tiene una tasa nominal de falsas alarmas del 5 % por ventana sin cambio. Si el sistema evalúa una ventana nueva cada día, ¿cada cuántos días esperaría una falsa alarma? Proponga una regla (por ejemplo, exigir la alerta en dos ventanas consecutivas) y calcule cómo cambian la tasa de falsas alarmas y la demora en detectar un cambio real, suponiendo ventanas independientes.

30.9.2 Ejercicio de infraestructura (Lab, arranca Notebook B4)

1. Implemente el listado 30.1 sobre su modelo del Notebook A2/B1, simulando una ventana de datos recientes con *drift* deliberado en al menos una covariable. Verifique que el reporte detecta el *drift* introducido.

30.9.3 Notas bibliográficas

Kästner et al. (2024) y Huyen (2022) (Capítulo 8, «Data Distribution Shifts and Monitoring») desarrollan el monitoreo de *drift* genérico que este capítulo extiende, incluida la taxonomía de *covariate shift*, *label shift* y *concept drift* que conviene tener presente al interpretar el reporte. El umbral convencional de $F > 10$ para descartar instrumentos débiles proviene de Stock y Yogo (2005), introducido en el Capítulo 17; recuérdese que está derivado para el caso de un instrumento y una primera etapa lineal, y que aplicarlo fuera de ese caso exige justificación adicional. Los criterios de balance sobre los que se apoya la señal (i) (ASMD y su umbral) son los de Rubin (2001), ya usados en el Capítulo 7; el PSI, en cambio, no tiene una referencia académica canónica, pues es una convención de la industria del riesgo crediticio, y sus umbrales

deben tratarse como reglas prácticas calibradas al dominio, no como criterios con respaldo teórico.

CAPÍTULO 31

Aprendizaje continuo y panorama de *Reinforcement Learning* causal

Cuadro sinóptico del capítulo

Problema:	Cuándo y cómo actualizar un sistema causal; cómo la PCH se extiende a decisiones secuenciales
Primera mitad:	Aprendizaje continuo (decisión de ingeniería, Plantilla B)
Segunda mitad:	RL causal (panorama conceptual, Plantilla A, sin implementación completa)
Patrones:	*Shadow deployment*, *champion-challenger*; bandits causales como caso introductorio de RL causal
Alcance:	La segunda mitad es deliberadamente un panorama: RL causal es un programa de investigación activo, no una receta cerrada

Este capítulo tiene dos mitades de naturaleza distinta. La primera es una decisión de ingeniería: cuándo reentrenar un sistema causal y cómo hacerlo sin ponerlo en riesgo. La segunda es un panorama de una frontera de investigación activa: qué cambia cuando la decisión deja de ser única y pasa a ser una secuencia en la que cada acción modifica los datos que se verán después, el problema que estudia el *Reinforcement Learning* (RL).

31.1 Aprendizaje continuo para sistemas causales

31.1.1 El problema de diseño

El Capítulo 30 dejó una pregunta abierta. Cuando la primera pregunta que falla es la del efecto y las tres anteriores están en orden, la acción que corresponde es reentrenar (Sección 2.5). Falta decir cómo se hace. Huyen (2022) (Capítulo 9, «Continual Learning and Test in Production») describe el espectro de respuestas posibles, desde no hacer nada hasta reentrenar de forma automática con cada lote de datos nuevo.

En un sistema causal reentrenar tiene una dificultad que el ML predictivo no conoce. Un modelo predictivo nuevo se admite si puntúa mejor que el vigente sobre las etiquetas que van llegando. Del efecto causal no llega ninguna etiqueta: de cada unidad solo se observa el resultado del tratamiento que recibió (Sección 1.3), así que ningún modelo nuevo puede ganar una comparación contra la verdad. Solo puede cumplir condiciones. Además, reentrenar con datos nuevos puede cambiar sin ruido la población para la que el efecto es válido, no solo su varianza, como adelantó el Capítulo 2. Un reentrenamiento que mejora el ajuste y cambia la población es peor, no mejor, para quien sigue sirviendo a la población anterior.

31.1.2 Opciones y trade-offs

Opciones y trade-offs

- **Reentrenamiento automático.** El estimador se reajusta con los datos más recientes, sea en un calendario fijo o cada vez que el monitoreo lo pide, y sustituye al vigente sin intervención humana. Minimiza el trabajo operativo, pero en un sistema causal el nuevo estimador puede reflejar otra población u otro mecanismo sin que nadie lo audite antes de publicarlo. Es el riesgo que el Capítulo 20 buscaba prevenir con pruebas automáticas, y que esas pruebas por sí solas no bastan para descartar: un cambio de población pasa el placebo, como muestra el caso canónico más abajo.
- ***Champion-challenger* con regla de promoción.** El modelo reentrenado (el *challenger*) se evalúa en paralelo al que está en producción (el *champion*) y solo lo reemplaza si cumple una regla explícita, que compara las poblaciones y no solo las métricas. Es más lento y exige mantener los dos modelos corriendo, pero es la opción que permite que una persona intercepte un cambio de población antes de que llegue a producción.

31.1.3 Decisión de referencia para el curso

El libro adopta el patrón *champion-challenger*: ninguna actualización reemplaza al servicio vigente de forma automática. El *challenger* se entrena con datos recientes, pasa por la compuerta de registro del Capítulo 20 y, además, se compara su población con la del *champion* con el chequeo de balance del Capítulo 7. La decisión es una regla de promoción con dos entradas y, como salida, una de las cinco acciones del Sección 2.5.

Compuerta de registro	Población comparable	Acción	Qué ocurre
Pasa	Sí	Reentrenar	Se promueve el *challenger*. La ficha registra la fecha, el motivo y el resultado de la comparación.
Cualquiera	No	Revisar identificación	No se promueve. Una persona decide si la población que el servicio atiende cambió de verdad (y entonces cambia la ficha) o si los datos nuevos no la representan.
No pasa	Sí	Alertar	No se promueve. Sigue el *champion* y una persona recibe la prueba que falló.

Cuando las dos entradas fallan prevalece la acción más restrictiva, como en el resto del libro. Promover y reemplazar significan aquí un solo acto: que la versión nueva pase a ser la vigente.

Tres aclaraciones sobre la regla. Primera, el motivo del reentrenamiento no sale de la comparación. Se reentrena porque el monitoreo dijo que el efecto cambió con todo lo demás en orden, o porque hay datos nuevos suficientes para estrechar el intervalo (con el doble de datos y todo lo demás igual, el intervalo se acorta en un factor $1/\sqrt{2} \approx 0.71$). Segunda, la diferencia entre la estimación del *challenger* y la del *champion* no es una condición de la regla: si el motivo fue un cambio de efecto, se espera que sea grande. Se registra en la ficha junto con los dos intervalos (Sección G.1). Tercera, mientras la regla se evalúa, el *champion* sigue respondiendo; si el Capítulo 30 ordena abstenerse, esa orden prevalece sobre cualquier reentrenamiento en curso.

Qué hace el despliegue en sombra aquí. Antes de promover, el *challenger* puede correr en sombra (*shadow deployment*): recibe las mismas consultas que el *champion* y responde, pero su respuesta no llega a nadie. En un modelo predictivo la sombra mide error cuando llegan las etiquetas. Aquí no llegan, de modo que solo mide dos cosas: cuánto se separan las estimaciones de las dos versiones sobre las mismas consultas, y si el *challenger* se abstiene donde el *champion* responde, o al revés. La segunda es una pista barata de que el soporte cambió, porque la abstención depende de la población de soporte que declara la ficha (Sección 15.4).

Qué datos se comparan. La comparación pone frente a frente los datos con que se entrenó el *champion* y los datos nuevos que el *challenger* incorpora, no el conjunto completo con que se reentrena. Si el *challenger* se entrena con los datos viejos más los nuevos, la mezcla diluye la diferencia y el efecto que reporta corresponde a una población intermedia que nadie atiende.

Caso canónico · Un cambio de población que la compuerta no ve

Tres covariables normales estándar X_1, X_2, X_3. El tratamiento es $D \sim \text{Bernoulli}(\sigma(X_1))$ y el resultado, $Y = (0.5 + 0.5X_2)D + X_1 + 0.5X_3 + \varepsilon$ con $\varepsilon \sim N(0,1)$. El efecto depende de X_2, de modo que el efecto promedio es $0.5 + 0.5E[X_2]$. El *champion* se entrena con

3 000 unidades con $X_2 \sim N(0,1)$. Los datos nuevos son otras 3 000 unidades con $X_2 \sim N(0.4,1)$: la población se corrió 0,4 desviaciones en la covariable que modula el efecto. El estimador es un DML de modelo parcialmente lineal, con validación cruzada y *gradient boosting*.

Modelo	**Entrenado con**	**Efecto verdadero**	**Efecto estimado**
Champion	Sus datos	0,50	0,51
Challenger A	Solo los datos nuevos	0,70	0,71
Challenger B	Datos viejos y nuevos	0,60	0,61

La prueba de placebo rechaza con frecuencias parecidas en las dos poblaciones (6,5 % y 3 % con 200 permutaciones en cada una, una diferencia dentro del error de muestreo), porque al permutar el tratamiento el efecto es nulo en cualquiera de ellas. La de estabilidad compara el efecto reestimado con el que registra la ficha del propio candidato. La compuerta de registro, que se apoya en estas dos pruebas, no distingue a un *challenger* de otro. La comparación de poblaciones sí: contra los datos nuevos, la diferencia estandarizada de X_2 (0,40) supera el umbral de 0,25 en las 100 repeticiones; contra la mezcla (0,20), en ninguna. Comparar contra los datos nuevos es lo que evita promover al *challenger* B, cuyo 0,61 no es el efecto de ninguna de las dos poblaciones.

El umbral se calibra con la ventana nula. La comparación usa una diferencia estandarizada y no el p-valor de un test, por la misma razón que da el Capítulo 30 para el *drift*: con muestras grandes un test rechaza diferencias irrelevantes. En una simulación con 20 000 unidades por grupo y un corrimiento de 0,05 desviaciones en una covariable, el test de Kolmogorov–Smirnov al 5 % marcó el cambio en el 98,5 % de las repeticiones y la diferencia estandarizada con umbral 0,25 no lo marcó nunca. Con un corrimiento material de 0,3 desviaciones y 3 000 unidades por grupo, los dos lo detectan (100 % y 98 %).

El umbral de 0,25 es un valor de partida, y cuánto vale depende del tamaño de las muestras. La tabla muestra, para dos muestras de la misma población, la distribución del mayor desbalance estandarizado entre las cuatro covariables.

Caso canónico · Ventana nula del balance de poblaciones

Dos muestras de n unidades cada una, de la misma población, con cuatro covariables: una normal estándar y tres binarias con proporciones 0,3, 0,4 y 0,6. En 1 000 pares se registra el mayor desbalance estandarizado entre las cuatro.

n	Mediana	Percentil 98	Pares por encima de 0,25
100	0,20	0,40	27 %
300	0,12	0,22	0,6 %
1 000	0,06	0,13	0 %
3 000	0,04	0,07	0 %

Con 100 unidades por grupo, dos muestras de la misma población superan 0,25 en más de una de cada cuatro comparaciones. Desde 1 000 unidades el ruido queda muy por debajo del umbral y este pasa a medir materialidad.

La regla es que el umbral sea el mayor de dos números: el que fija la materialidad (qué desbalance importaría para el efecto, con 0,25 como valor de partida) y el percentil 98 de la ventana nula con los tamaños reales, que deja una tasa de falsas alarmas de 2 % por comparación. Con 100 unidades por grupo da 0,40, y esa cifra dice algo más que el umbral: la comparación apenas tiene potencia. Con 300 unidades por grupo y un corrimiento de 0,3 desviaciones detecta el 72 % de los casos y con 3 000 unidades, el 98 %.

Lo que esta comparación no ve. Solo compara covariables observadas. Un cambio en el mecanismo de asignación, o en una variable que no se mide, no la activa. Para eso están las señales (ii) y (iv) del Capítulo 30, aplicadas a los datos nuevos antes de entrenar.

31.2 Implementación de referencia

El listado implementa la regla de la tabla. Lee las covariables de los roles de la ficha del modelo (Capítulo 19), de modo que no depende de ningún objeto serializado, y devuelve la acción junto con la evidencia para que quede en el historial de la ficha.

```
import numpy as np

def asmd(a, b):
    """Diferencia media estandarizada absoluta entre dos muestras."""
    sd = np.sqrt((np.var(a, ddof=1) + np.var(b, ddof=1)) / 2)
    return abs(np.mean(a) - np.mean(b)) / sd if sd > 0 else 0.0

def evaluar_challenger(df_champion, df_nuevos, roles, pasa_compuerta,
umbral=0.25):
    """df_champion: datos con que se entreno el champion.
    df_nuevos: los datos que el challenger usa y el champion no vio.
```

```
    pasa_compuerta: resultado de la compuerta de registro del challenger (Cap.
20).
    umbral: valor de partida; se calibra con ventanas nulas (Cap. 30)."""
    desbalance = {c: asmd(df_champion[c], df_nuevos[c]) for c in
roles["covariables"]}
    peor = max(desbalance, key=desbalance.get)
    comparable = bool(desbalance[peor] < umbral)
    if not comparable:
        accion = "revisar_identificacion"   # otra poblacion: decide una
persona
    elif not pasa_compuerta:
        accion = "alertar"                  # sigue el champion; se muestra la
prueba que fallo
    else:
        accion = "reentrenar"               # se promueve el challenger
    return {"accion": accion, "promover": accion == "reentrenar",
            "poblacion_comparable": comparable, "pasa_compuerta":
bool(pasa_compuerta),
            "mayor_desbalance": (peor, round(float(desbalance[peor]), 3))}
```

Listado 31.1: Regla de promoción: compara la población del *champion* con los datos nuevos y devuelve una de las cinco acciones.

Las cifras de esta sección salen de simulaciones con semilla declarada que ejecutan este mismo listado, con un DML de *gradient boosting* en lugar de EconML. Están en `herramientas/verificaciones/verif_listados_cap31.py`.

31.2.1 Señales de alerta

- ☐ Los reentrenamientos se publican en un calendario, con la única condición de que pasen las pruebas de software.
- ☐ La única comparación entre versiones es una métrica de ajuste; ninguna compara la población de entrenamiento de la versión nueva con la de la vigente.
- ☐ El *challenger* se entrena con datos viejos y nuevos y la comparación se hace contra el conjunto completo, de modo que un corrimiento moderado se diluye.
- ☐ El umbral de la comparación de poblaciones se heredó de otro sistema o de la convención, sin medir el desbalance entre muestras de la misma población con los tamaños reales.
- ☐ Un *challenger* que no pasó la regla se promovió «por esta vez», o el umbral se cambió en el mismo cambio que lo hizo fallar.
- ☐ La ficha no registra el motivo del reentrenamiento ni el resultado de la comparación.

31.3 Panorama de *Reinforcement Learning* causal

31.3.1 De decisiones únicas a decisiones secuenciales

Todo el curso, hasta este punto, trató la decisión como una elección única: estimar un efecto, elegir una política, desplegarla. El RL estudia el caso en que un agente toma una **secuencia** de decisiones, cada una de las cuales afecta el estado futuro del entorno y, por tanto, las decisiones siguientes. Un sistema de recomendación que decide qué mostrar en cada visita, sabiendo que la decisión de hoy cambia los datos que se observarán mañana, es un ejemplo. El RL clásico optimiza esa secuencia suponiendo, casi siempre de forma implícita, que el entorno reacciona a las acciones del agente sin confusión oculta entre sus decisiones y las recompensas.

Bareinboim (2025) trata este problema en los capítulos que dedica a las tareas del RL causal y a la toma de decisiones. Cuando se aprende de datos observacionales, por ejemplo de las demostraciones de un agente anterior cuyas decisiones respondían a información que el agente nuevo no observa, ignorar la confusión puede llevar a una política sesgada.

31.3.2 Bandits causales: el caso introductorio más simple

El caso más simple, y un puente natural desde el *policy learning* del Capítulo 21, son los **bandits con confusores no observados** (Bareinboim et al. 2015). Es el problema clásico de bandidos de varios brazos con una complicación: una variable U que el agente no ve afecta tanto a la recompensa de cada brazo como a la inclinación natural del propio agente, el brazo que elegiría si nadie interviniera sobre su decisión. Los algoritmos habituales maximizan la recompensa esperada bajo intervención, $E[Y \mid \mathrm{do}(X = a)]$, y los autores muestran que esa meta no es la correcta cuando hay confusión.

Su ejemplo es un casino en el que la inclinación a jugar una máquina depende de si el jugador bebió y de si la máquina parpadea, y esas mismas variables afectan la recompensa. En la construcción del artículo, ambos brazos pagan 0,3 bajo intervención y 0,15 de forma observacional (condicionando en el brazo jugado), de modo que ninguna de las dos distribuciones por separado distingue un brazo del otro. Lo que sí informa es una pregunta contrafactual: dado que mi inclinación era jugar x, ¿cuánto ganaría si jugara a en su lugar? Comparar la recompensa de obedecer la inclinación con la de llevarle la contraria es el criterio que proponen, y lo implementan en una variante de *Thompson Sampling* que toma los datos observacionales como valores iniciales.

En sus simulaciones esta variante acumula menos arrepentimiento que *Thompson Sampling* estándar y que otra que usa la inclinación como contexto. El resultado es empírico: el artículo no ofrece un teorema de optimalidad ni cotas de arrepentimiento. La lección para el resto del libro es doble. La distribución intervencional no siempre es el objetivo correcto de quien decide, porque con confusión hacen falta tanto lo intervencional como lo observacional. Y la brecha entre ambos no es solo un problema que evitar: delata la existencia de un confusor y puede aprovecharse. La conexión con el Capítulo 8 es directa, porque decidir qué información

de contexto es segura de condicionar y cuál introduce sesgo de puerta trasera es una decisión de identificación. La conclusión es más constructiva que en el resto del libro.

Zhang y Bareinboim (2019) llevan el problema a los **regímenes de tratamiento dinámicos**: secuencias de decisiones en que cada acción cambia el estado sobre el que se toma la siguiente, como un tratamiento médico prolongado o una intervención social por etapas. Es el escenario que más se parece a las decisiones de política pública, y también donde la confusión es más difícil de manejar, porque una variable puede ser a la vez confusor de una decisión posterior y mediador de una anterior. Ningún ajuste por covariables resuelve esa situación, que exige el aparato de las fórmulas g de Robins, fuera del alcance de este libro. Los autores derivan cotas informativas sobre la dinámica del sistema a partir de datos observacionales confundidos y proponen un algoritmo de RL que las aprovecha; según su resumen, con arrepentimiento casi óptimo en línea.

31.3.3 Por qué el libro se detiene aquí

Frontera · 2026

RL causal es, en 2026, un programa de investigación activo más que un conjunto de recetas maduras y adoptadas en producción, a diferencia de DML o los meta-learners de la Parte II, que ya cuentan con implementaciones estándar. El libro se detiene en el panorama conceptual: entender **por qué** la confusión importa en RL y **cómo** se conecta con lo aprendido sobre identificación causal, sin pretender una cobertura de implementación que la madurez actual del campo no respalda. Lo que se puede dar por estable es que el RL con datos observacionales hereda todos los problemas de identificación de los capítulos anteriores. Lo que probablemente se mueva son los algoritmos concretos y sus garantías.

31.4 Ejercicios y notas bibliográficas

31.4.1 Ejercicios conceptuales

1. Explique por qué superar la compuerta de registro del Capítulo 20 (placebo y estabilidad del efecto) no basta para promover un modelo reentrenado, y qué comparación adicional pide la regla de promoción de este capítulo. Apóyese en el caso canónico del *challenger* B.
2. Los datos nuevos tienen un corrimiento de 0,4 desviaciones en una covariable. Si el *challenger* se entrena con la misma cantidad de datos viejos que de nuevos, ¿qué diferencia estandarizada verá la comparación contra el conjunto completo, aproximadamente, y cuál contra los datos nuevos solos? Explique qué pasa con la decisión si el umbral es 0,25.
3. En el casino de la Sección 31.3.2 ambos brazos pagan 0,3 bajo intervención. Explique por qué, aun así, un jugador cuya inclinación es el brazo 1 puede preferir el brazo 0, y qué cantidad contrafactual tendría que estimar para saberlo.

31.4.2 Ejercicio de infraestructura

1. Aplique el listado 31.1 a dos versiones de su modelo del Notebook A2, entrenadas con dos submuestras deliberadamente distintas del conjunto de datos para simular un cambio de población. Verifique que devuelve `revisar_identificacion` y que, con dos submuestras de la misma población, devuelve `reentrenar`. Luego mida, con 200 pares de submuestras de la misma población, la distribución del mayor desbalance, fije el umbral con la regla de la sección y registre el valor en la ficha.

31.4.3 Notas bibliográficas

Huyen (2022), Capítulo 9, desarrolla en profundidad los patrones de aprendizaje continuo y de pruebas en producción, incluido el despliegue en sombra, en su versión genérica para ML. Bareinboim (2025) es la referencia central del panorama de RL causal de este capítulo. Bareinboim et al. (2015) formaliza el caso introductorio de los bandits con confusores no observados y propone un criterio de decisión basado en la inclinación del agente, con evidencia de simulación. Zhang y Bareinboim (2019) lo extiende a regímenes de tratamiento dinámicos con cotas derivadas de datos observacionales. La conexión de este capítulo con el Capítulo 26 merece señalarse: la pregunta de si se puede promover este *challenger* se parece a la de si el efecto estimado con datos recientes transporta a la población que el servicio atiende, y la comparación de poblaciones de la regla es su versión operativa mínima. Es mínima porque solo ve covariables observadas y supone que lo que cambió son ellas y no el mecanismo.

CAPÍTULO 32

El lado humano de los sistemas causales

Cuadro de decisión del capítulo

Decisión:	Comunicar resultados causales con sus supuestos e incertidumbre explícitos, incluso a audiencias no técnicas
Alternativas:	Comunicación simplificada (solo el número o la historia) vs. comunicación con supuestos e incertidumbre explícitos
Trade-off clave:	Claridad y persuasión inmediata vs. honestidad sobre los límites del hallazgo
Riesgo principal:	Que un resultado válido **bajo supuestos** se comunique y se use como si fuera una verdad incondicional

32.1 El problema de diseño

Cada capítulo de este libro terminó con una advertencia sobre límites y supuestos: la sección de riesgos en los capítulos de teoría, la de señales de alerta en los de ingeniería. Ese cuidado se pierde con facilidad en el último paso del ciclo de vida de un sistema causal, que casi nunca es técnico: comunicar el resultado a quien debe tomar una decisión con él. Huyen (2022) dedica su último capítulo a la dimensión humana del ML, la que la formación técnica rara vez cubre: la experiencia de quien usa el sistema, la organización de los equipos y la responsabilidad. Para un sistema causal el riesgo de desconexión es mayor, porque la diferencia entre «X predice Y» y «X causa Y», el problema con el que abrió este libro en el Capítulo 1, es exactamente el matiz que se pierde primero en una comunicación simplificada.

32.2 Opciones y trade-offs

Opciones y trade-offs

- **Comunicación simplificada.** «El programa aumenta el empleo en 12 puntos.» Es clara, memorable y persuasiva, y con frecuencia es la única versión que sobrevive varias capas de resumen entre el equipo de datos y quien decide. Su costo es que omite exactamente lo que este libro pasó 31 capítulos formalizando: bajo qué supuestos, para qué población, con qué incertidumbre.
- **Comunicación con supuestos e incertidumbre explícitos.** «El programa aumenta la probabilidad de conseguir empleo en 12 puntos porcentuales (IC 95 %: 8 a 16), estimado sobre las personas que efectivamente participaron, bajo el supuesto de que no hay factores no observados que determinen a la vez la participación y el empleo.» Es honesta y auditable, pero es más difícil de retener y, sin cuidado en la forma, puede sonar a que el equipo técnico no está seguro de nada. El riesgo real es que el matiz se lea como debilidad del hallazgo en lugar de rigor.

La resolución de este trade-off no es elegir un extremo sino **estructurar** la comunicación en capas: un titular memorable, respaldado de inmediato por los supuestos y la incertidumbre en un lugar visible y accesible, no enterrado en un apéndice que nadie lee.

La forma de comunicar la incertidumbre tampoco es neutral, y la literatura de comunicación de riesgo ha establecido regularidades que conviene aprovechar en lugar de redescubrir. Spiegelhalter (2019) documenta dos que aplican directamente aquí. Primera, las **frecuencias naturales** se comprenden mejor que las probabilidades o los porcentajes: «de cada 100 personas que participan en el programa, entre 8 y 16 más consiguen empleo que si no hubieran participado» se retiene y se razona mejor que «el efecto es de 12 puntos porcentuales (IC 95 %: 8 a 16)», aunque digan lo mismo. Segunda, los **riesgos relativos** suelen inflar la percepción del efecto: «duplica la probabilidad» es correcto y engañoso si la probabilidad basal es de 0,1 %, de modo que conviene reportar siempre el cambio absoluto junto al relativo. A estas dos se suma una tercera, propia de los resultados causales: la comunicación debe explicitar **sobre qué población** aplica el número, porque la audiencia asumirá por defecto que aplica a la suya.

Hay además una asimetría que conviene tener presente al decidir cuánto matizar. Sobreestimar la certeza de un resultado causal produce decisiones que fallan en silencio: el programa se implementa, no funciona, y rara vez se atribuye el fracaso al análisis. Subestimarla produce, en el peor caso, que la decisión se posponga o se tome sin el análisis. Los dos errores tienen costos, pero solo el primero se disfraza de éxito, y esa es una razón práctica, no solo ética, para inclinarse por la comunicación con supuestos explícitos.

32.3 Decisión de referencia para el curso

El proyecto final del curso exige que todo resultado se comunique con una estructura de tres capas: **(i)** el hallazgo en una oración, en lenguaje no técnico; **(ii)** los supuestos de identificación y la población de validez, en un párrafo; **(iii)** el detalle técnico completo, para quien necesite auditarlo. Es, en esencia, la misma estructura de la *model card* causal del Capítulo 19 aplicada a la comunicación con personas y no solo a la documentación de un artefacto, y puede derivarse de ella: el hallazgo sale del efecto con su intervalo, la capa (ii) de la población de soporte y los supuestos, y la advertencia de lo que el resultado no implica, de la lista de usos que la ficha prohíbe.

Cómo se muestra la incertidumbre. Un intervalo dibujado dice más que un punto con una cifra al lado, y dice más aún si la audiencia puede leerlo. Galesic y Garcia-Retamero (2011) construyeron una escala para medir la alfabetización gráfica y concluyen que no todos se benefician de las visualizaciones estándar, así que conviene acompañar el gráfico con la cifra dicha en palabras. Cuatro prácticas resumen lo anterior: mostrar el intervalo y no solo la estimación puntual; informar cotas cuando la identificación es parcial, o el nivel de confusión no observada que revertiría la conclusión (Sección 14.2.5); explicar los supuestos de identificación en lenguaje no técnico; y dar el contexto sobre la magnitud práctica del efecto, porque que un efecto sea estadísticamente distinguible de cero no dice si es grande.

Qué se comunica cuando el sistema se abstiene o alerta. Las cinco acciones del Sección 2.5 también se comunican. Cuando el sistema se abstiene, lo que llega a la persona es «sin respuesta» con su motivo (por ejemplo, la consulta cae fuera de la población donde se estimó el efecto), nunca un cero, ni el último valor, ni un promedio. Cuando alerta, la alerta lleva la señal, su valor y su umbral, no un semáforo. Cuando se promueve una versión nueva, el titular y la ficha dicen desde cuándo vale la estimación y qué cambió. Y un resultado bien comunicado hace un mes puede estar viejo hoy: la capa (ii) indica hasta cuándo se verificaron los supuestos que el monitoreo puede observar (Capítulo 30).

32.4 La plantilla de comunicación

La plantilla no depende de ninguna herramienta: es texto para una persona.

```
## Hallazgo
[Una oracion, en lenguaje no tecnico, sin jerga estadistica.]

## Lo que esto significa (y lo que no)
- Poblacion para la que es valido: [...]
- Principal supuesto detras del resultado: [...]
- Ultima verificacion de los supuestos observables: [fecha]
- Incertidumbre: [IC 95%, en unidades que la audiencia entienda]
- Este resultado NO implica: [ej.: "no implica que el efecto sea
  el mismo para poblaciones fuera del rango estudiado"]

## Detalle tecnico
[Enlace al documento tecnico y a la ficha del modelo completos]
```

Listado 32.1: Plantilla de tres capas para comunicar un resultado causal.

32.5 Aplicación al sistema causal del curso: cierre

Este capítulo cierra el recorrido donde lo abrió el Capítulo 1: con la distinción entre una pregunta asociativa y una pregunta causal. En el trayecto, el libro desarrolló dos hilos en paralelo. El primero, de identificación y estimación (modelos causales estructurales, criterio de puerta trasera, ortogonalidad de Neyman, DML, *meta-learners*, bosques causales, diseños de panel e instrumentales, descubrimiento de estructura), responde **qué tan bien** se puede responder una pregunta causal con los datos disponibles. El segundo, de ingeniería de sistemas siguiendo a (Huyen 2022) y (Kästner et al. 2024) (anatomía de un sistema, datos de entrenamiento, *features* sin fuga, despliegue, *model cards*, CI/CD, monitoreo, aprendizaje continuo), responde **cómo** llevar esa respuesta, de forma responsable y verificable, hasta quien la necesita. Ninguno de los dos hilos es completo sin el otro: un estimador impecable que nadie puede auditar en producción es tan poco útil como un servicio impecablemente desplegado que estima la pregunta equivocada. Este capítulo y su plantilla de comunicación son el punto donde ambos hilos le entregan, por fin, algo a una persona que tiene que decidir. Queda una pregunta que ninguno de los dos hilos resuelve por sí solo, y que el Capítulo 33 retoma para terminar: qué hace un sistema con los supuestos que ningún dato puede verificar.

32.6 Señales de alerta y checklist operativo

- ☐ El resumen ejecutivo de un resultado causal no menciona ningún supuesto ni intervalo de incertidumbre.
- ☐ Nadie fuera del equipo técnico sabe cuál es la población para la que el efecto estimado es válido.
- ☐ La comunicación usa lenguaje causal («X causa Y») para un resultado que, honestamente, solo respalda una afirmación asociativa o condicional.
- ☐ No existe una versión accesible (capas 1 y 2 de la plantilla) del resultado; solo existe el documento técnico completo.

- ☐ Cuando el sistema se abstiene, la interfaz muestra un número de todos modos, o no dice por qué no responde.
- ☐ El resultado comunicado no dice hasta cuándo se verificaron sus supuestos observables.

32.7 Ejercicios y notas bibliográficas

32.7.1 Ejercicios conceptuales

1. Tome el resultado del Notebook A2 de su proyecto (o cualquier estimación de este curso) y redáctelo usando la plantilla de tres capas del listado 32.1.
2. Describa una situación, real o hipotética, en la que una comunicación simplificada de un resultado causal llevó, o podría llevar, a una decisión que el resultado técnico no respaldaba realmente.
3. Un sistema se abstiene en el 12 % de las consultas porque caen fuera de la población de soporte. El equipo de producto propone mostrar en esos casos el efecto promedio de la población de entrenamiento «para no dejar la pantalla vacía». Explique qué se pierde con esa decisión y redacte, con la plantilla, el mensaje que sí debería verse.

32.7.2 Ejercicio de cierre (proyecto final)

1. Complete la plantilla de comunicación de tres capas para el sistema desplegado de su proyecto final, y agréguela como parte de la entrega junto con la **model card** del Capítulo 19.

32.7.3 Notas bibliográficas

Huyen (2022), Capítulo 11 («The Human Side of Machine Learning»), es la referencia central de este capítulo. Sobre comunicación de incertidumbre estadística a audiencias no técnicas, Spiegelhalter (2019) es la referencia práctica más útil (frecuencias naturales, riesgos absolutos frente a relativos, representación visual de la incertidumbre) y la fuente de las dos primeras regularidades de la Sección 32.2. Galesic y Garcia-Retamero (2011) ofrece la escala de alfabetización gráfica. Lipton (2018) complementa la discusión desde el otro lado: qué se le está pidiendo realmente a un modelo cuando se pide que sea «interpretable» o «explicable», y por qué esas demandas encubren objetivos distintos (confianza, causalidad, transferibilidad) que conviene separar antes de intentar satisfacerlos. Sobre las buenas prácticas de reporte de resultados causales en particular, véase (Imbens y Rubin 2015).

CAPÍTULO 33

Supuestos no observables en operación

Cuadro de decisión del capítulo

Decisión:	Registrar, para cada supuesto que ningún dato verifica, cuánto tendría que fallar para cambiar la decisión, y revisarlo por plazo y por eventos
Alternativas:	Dejarlo como una frase de fe en la ficha vs. registrar su sensibilidad respecto de la decisión, una escala de referencia, un control negativo cuando exista y un plazo de revisión
Trade-off clave:	Un cálculo al registrar y una revisión periódica vs. una decisión que descansa en un supuesto que nadie vuelve a mirar
Stack:	Python y numpy (mínimos cuadrados), esquema JSON de la ficha
Riesgo principal:	Leer un valor de robustez alto como prueba de que el supuesto vale

Implementación en el monorepo del curso (2026)

El capítulo no tiene laboratorio propio: es lectura de cierre de la Parte VIII y se ejercita en el proyecto final, en el apartado de sensibilidad (Apéndice E). Verificación de las cifras: `herramientas/verificaciones/verif_cap33.py`.

33.1 El problema de diseño

El monitoreo del Capítulo 30 vigila cuatro cosas, y las cuatro se pueden mirar en los datos: cuánto cambiaron las covariables, si el mecanismo de asignación sigue ordenando como antes, si el instrumento conserva su fuerza y si el efecto reestimado se movió. Todo lo que ese capítulo

detecta es observable. El supuesto que más pesa en un estimador observacional no lo es. Que no haya una causa común del tratamiento y del resultado que las covariables medidas no recojan, la no confusión condicional, no deja rastro en ningún conjunto de datos, ni en el de entrenamiento ni en el que llegue mañana. El sistema puede estar quieto en las cuatro señales y estar sesgado, y el sesgo puede crecer sin mover ninguna de ellas.

El problema de diseño es qué puede hacer un sistema con un supuesto que no puede verificar. No puede verificarlo, y fingir lo contrario es el peor camino. Puede hacer cuatro cosas más modestas, y las cuatro caben en una ficha: decir cuánto tendría que fallar el supuesto para que la decisión cambie, buscar el rastro indirecto que su falla dejaría en algún otro resultado, declarar hasta cuándo vale lo que dijo y qué hechos obligan a revisarlo, y dejar escrito quién decide cuando eso ocurre. El capítulo trata esas cuatro cosas para la no confusión condicional, el supuesto que el libro ha seguido de punta a punta. Los otros supuestos no observables, la exclusión de un instrumento y las tendencias paralelas posteriores al tratamiento, usan el mismo registro, con su propio método de sensibilidad; este capítulo no los desarrolla.

Supuesto	**Clase**	**Qué hace el sistema**
Soporte común	Observable	Lo vigila con un umbral calibrado (Capítulo 30, Capítulo 7)
Estabilidad del mecanismo de asignación	Observable	Lo vigila con el modelo de la referencia (señal (ii))
Fuerza del instrumento	Observable	Lo vigila con el F de la primera etapa (señal (iii))
Estabilidad del efecto	Observable	Lo vigila con un contraste de dos estimaciones (señal (iv))
No confusión condicional	No observable	Registra su sensibilidad y su escala, vigila un control negativo y fija una revisión (este capítulo)
Exclusión del instrumento, tendencias paralelas posteriores	No observable	Mismo registro, con su propio método de sensibilidad (fuera del alcance de los listados de este libro)

Tabla 33.1: Clase de cada supuesto y lo que el sistema hace con él.

33.2 Opciones y trade-offs

Opciones y trade-offs

- **El supuesto como frase de fe.** La ficha dice «se asume no confusión condicional en estas covariables» y nada más. Cuesta una línea. Su defecto es que no cambia ninguna decisión: nadie sabe si el supuesto aguanta un confusor pequeño o uno enorme, y la frase sigue idéntica el día que el mundo cambia.

- **Sensibilidad registrada.** La ficha guarda un valor crítico respecto de la decisión, la escala con que se lo compara, un control negativo si existe y una fecha de revisión. Cuesta un cálculo al registrar y una revisión periódica. Lo que entrega es un margen declarado, que otra persona puede discutir y que el sistema puede recalcular.
- **Rediseñar para identificar.** Un experimento, un instrumento defendible o un diseño cuasi-experimental convierten el supuesto en otro, a veces más débil, a veces observable en parte. Es la respuesta de fondo y también la más cara. No la decide el sistema: es lo que se escala cuando el margen resulta estrecho y lo que está en juego es grande.

33.3 Decisión de referencia para el curso

El sistema de referencia registra, para cada supuesto no observable de la ficha, cuatro cosas: el método de sensibilidad, el valor crítico respecto de la **decisión** y no solo de cero, la escala de referencia con que se interpreta, y la fecha de cálculo con su plazo de revisión. Cuando existe un resultado que sirva de control negativo, lo vigila como una señal más del monitoreo. La revisión se dispara por plazo y por eventos, y la hace siempre una persona. Cinco precisiones, porque la versión ingenua de cada pieza falla de una forma característica.

Sobre el valor crítico: respecto de la decisión, no de cero. La pregunta de la literatura de sensibilidad es cuánta confusión haría falta para anular el efecto, y el Capítulo 14 la desarrolla con el *E-value* y con el R^2 parcial. Una decisión rara vez se juega en cero. Se trata cuando el efecto supera un costo, y lo que importa es cuánta confusión lleva el efecto hasta el costo. Sea $\hat{\tau}$ el efecto estimado, $\hat{\text{se}}$ su error estándar, «gl» los grados de libertad y c el umbral de la decisión. Se define $f_c = |\hat{\tau} - c| \,/(\hat{\text{se}}\sqrt{\text{gl}})$ y el **valor crítico de la decisión**

$$\text{VC}_c = \frac{1}{2}\left(\sqrt{f_c^4 + 4f_c^2} - f_c^2\right). \tag{33.1}$$

Es la fracción de la varianza residual del tratamiento y del resultado que un confusor tendría que explicar, en ambos a la vez y en la dirección adversa, para llevar el efecto hasta c. Con $c = 0$ es el valor de robustez habitual. La fórmula es la de Cinelli y Hazlett (2020) en un modelo lineal, aplicada a un umbral que no es cero.

Nota técnica

Cota del sesgo por omisión. En una regresión lineal de Y sobre D y X, si se omite un confusor U, el sesgo del coeficiente de D cumple

$$|\text{sesgo}| = \hat{\text{se}}\sqrt{\text{gl}}\sqrt{\frac{r^2_{Y\cdot U \mid X,D}\, r^2_{D\cdot U \mid X}}{1 - r^2_{D\cdot U \mid X}}}, \tag{33.2}$$

donde $r^2_{Y\cdot U \mid X,D}$ y $r^2_{D\cdot U \mid X}$ son los R^2 parciales de U con Y y con D. Es una identidad algebraica: si se conocieran las dos cantidades, el sesgo se conocería. No se conocen, y

por eso se las reemplaza por una escala de referencia. Para estimadores con aprendizaje automático, Chernozhukov et al. (2022b) extienden la idea con otras cantidades; la ficha registra qué método se usó.

Sobre la escala: un número sin escala no se puede juzgar, y la escala es una opinión. Un valor crítico de 0,13 no dice nada hasta que se lo compara con algo. La comparación habitual usa las covariables observadas: el R^2 parcial de la más fuerte con el tratamiento y con el resultado. Con esa escala se calcula el rango de efectos que daría un confusor tan fuerte como esa covariable, y la decisión se declara **frágil** si el umbral cae dentro del rango. La escala es una afirmación sobre el mundo, «ningún confusor oculto es más fuerte que esta covariable», y puede ser falsa. La ficha tiene que decir cuál usó, para que quien la lea pueda discutirla (caso 2).

Sobre el valor de robustez: un valor alto no prueba la ausencia de confusión. La confusión que infla el efecto estimado también infla su robustez aparente, porque el valor crítico crece con el tamaño del efecto estimado. En el caso 1 el valor de robustez pasa de 0,18 sin confusor a 0,53 con el más fuerte. Un colega que cite un valor alto como prueba de que no hay confusión está leyendo al revés una cantidad que no distingue un mundo con confusor de uno sin él. Un valor crítico bajo dice que la decisión es frágil. Uno alto no dice que sea sólida.

Caso canónico · La cota exacta y el valor de robustez

Se simulan $n = 2\,000$ unidades con dos covariables observadas X_1, X_2 y un confusor U no observado, todos normales estándar. El tratamiento es $D = 0.6X_1 + 0.3X_2 + \delta U + \varepsilon_D$ y el resultado es $Y = \tau D + 0.5X_1 + 0.5X_2 + \gamma U + \varepsilon_Y$, con $\tau = 0.2$. Se estima el efecto sin U (el estimador disponible) y con U (el que solo existe en la simulación). Cuatro intensidades: sin confusor, débil, medio y fuerte.

Confusor	R^2 con D	R^2 con Y	Efecto sin U	Sesgo real	Valor de robustez	VC, $c = 0.3$
Ninguno	0,00	0,00	0,192	0,000	0,18	0,105
Débil	0,04	0,08	0,252	0,059	0,22	0,048
Medio	0,21	0,23	0,434	0,241	0,36	0,127
Fuerte	0,46	0,37	0,689	0,496	0,53	0,350

La cota de la nota técnica, calculada con los R^2 verdaderos de U, coincide con el sesgo real hasta el error numérico (diferencias de 10^{-15}). Pero esos R^2 solo se conocen en la simulación. Lo que sí se calcula con los datos que existen en la práctica son las dos últimas columnas, que dependen solo del efecto estimado, su error estándar y los grados de libertad. El valor de robustez crece con el sesgo: la confusión más fuerte da el valor más alto.

Caso canónico · El margen de la decisión y su escala

Mismo proceso, con un costo de actuar $c = 0.3$. El efecto verdadero (0.2) está por debajo del costo, de modo que la decisión correcta es no tratar. Se repite el ejercicio en 500 muestras por escenario. Para cada una se calcula el rango de efectos con un confusor tan fuerte como X_1 (la mejor covariable observada) y se marca la decisión como frágil si c cae dentro del rango.

Confusor	Efecto medio sin U	Se trataría	VC medio	Rango con la escala de X_1	Decisión frágil
Ninguno	0,200	0 %	0,095	−0,04 a 0,44	100 %
Débil	0,258	4 %	0,041	0,04 a 0,48	100 %
Medio	0,441	100 %	0,129	0,30 a 0,59	58 %
Fuerte	0,699	100 %	0,347	0,64 a 0,76	0 %

Con el confusor medio el sistema trata en todas las muestras, y es un error. El margen declarado avisa en el 58 % de ellas. Con el confusor fuerte trata en todas, es un error, y el margen dice que la decisión es robusta: ningún confusor tan fuerte como X_1 la movería. Pero el confusor real tiene un R^2 parcial de 0,37 con el resultado y X_1 tiene 0,02. La escala era optimista. Y sin confusor alguno, el margen marca la decisión como frágil en el 100 % de las muestras: es una declaración sobre el margen, no un detector. Las cifras provienen de una simulación con semillas fijas.

Sobre el control negativo: ve solo lo que comparte. Si hay un resultado N que el tratamiento no puede causar, pero que comparte con Y una causa no observada, el efecto estimado de D sobre N debería ser cero. Si no lo es, hay confusión por una causa que N comparte con D. El control negativo es lo único de este capítulo que detecta en vez de acotar, y por eso se lo vigila en el tiempo como una señal más. Funciona solo cuando comparte el confusor: un control que no lo comparte da siempre una respuesta tranquilizadora, y es justo la que no sirve (caso 3). Tampoco cuantifica el sesgo de Y, solo dice que hay un problema.

Caso canónico · Un control negativo ve lo que comparte

Mismo proceso. El control negativo es $N = \zeta U + \varepsilon_N$, que el tratamiento no causa. Se estima el efecto de D sobre N, con las mismas covariables, y se rechaza la nulidad al 5 %. Se compara un control que comparte el confusor ($\zeta = 1$) con uno que no ($\zeta = 0$), en 500 muestras por escenario.

Confusor	Control que comparte U	Control que no lo comparte
Ninguno	5,6 %	4,6 %

Confusor	Control que comparte U	Control que no lo comparte
Débil	100 %	4,2 %
Medio	100 %	3,6 %
Fuerte	100 %	4,2 %

El control que comparte el confusor lo detecta en todas las muestras, incluso con el confusor débil. El que no lo comparte queda en la tasa nominal en todos los escenarios, también cuando el confusor es fuerte. Sin confusor, los dos rechazan alrededor del 5 %, que es la tasa de falsas alarmas.

Sobre el plazo: la sensibilidad caduca. El valor crítico es una propiedad de unos datos, un estimador y una población. Si cualquiera de los tres cambia, el número ya no describe lo que el sistema sirve. El registro lleva por eso una fecha de revisión, y la revisión se adelanta cuando ocurre alguno de estos hechos: cambió el mecanismo de asignación del tratamiento (la señal (ii) del Capítulo 30), entró o salió una covariable, el sistema empezó a servir una población distinta (Capítulo 26) o el control negativo se encendió. El plazo lo fija el equipo según cuánto cambia su mundo. La regla que sí es fija es que la revisión la hace una persona, que el resultado es renovar el cálculo, aceptar el margen con una nota o retirar el modelo, y que ningún proceso automático declara que un supuesto no observable «sigue valiendo».

33.4 El contrato de la sensibilidad

El contrato completa a la ficha (C-05) y al monitoreo (C-07). La ficha dice dónde se guarda la sensibilidad, el monitoreo aporta los eventos que obligan a revisarla y este contrato fija cómo se calcula y cuándo se revisa.

Contrato C-08 · Sensibilidad de los supuestos no observables

Operaciones	*calcular*: recibe el efecto estimado, su error estándar, los grados de libertad, el umbral de la decisión y la escala de referencia, y devuelve el registro de sensibilidad. *revisar*: recibe la ficha, la fecha y los eventos del monitoreo, y devuelve los motivos por los que una persona debe revisar cada supuesto no observable, o una lista vacía.
Entrada	El efecto con su error estándar y grados de libertad, tal como los registra la ficha (Capítulo 19). El umbral de la decisión: el costo o el efecto mínimo que justifica actuar. La escala de referencia: los R^2 parciales de la covariable observada más fuerte. Si existe, el efecto estimado sobre un control negativo. Los eventos del monitoreo (Capítulo 30) y la fecha.

Salida	Por cada supuesto no observable, el registro de sensibilidad: método, umbral de la decisión, valor crítico, rango de efectos con la escala de referencia, si la decisión es frágil, fecha de cálculo y fecha de revisión. Y la lista de motivos de revisión. Nunca un veredicto de «verificado».
Invariantes	(1) La sensibilidad se calcula con los datos y el estimador registrados, no se escribe a mano. (2) Se calcula respecto del umbral de la decisión, no solo respecto de cero. (3) El registro dice qué escala de referencia usó, y la ficha la declara como un supuesto. (4) Un valor crítico alto nunca se informa como evidencia de que el supuesto vale. (5) Todo evento de la lista de disparadores y todo plazo vencido produce un motivo de revisión, y la revisión la hace una persona. (6) Con los mismos datos, el mismo estimador y la misma fecha, el resultado es idéntico.
Modos de fallo	Un control negativo que no comparte el confusor: su silencio se lee como tranquilidad. Una escala de referencia optimista: la decisión se declara robusta frente a un confusor mucho más débil que el real (caso 2). Una sensibilidad calculada con unos datos y citada tras reentrenar con otros. Varios confusores moderados que juntos igualan a uno fuerte: la cota de un solo confusor no los ve.
Prueba de aceptación	Sobre el generador de los casos canónicos, con confusor de intensidad conocida. (a) Con los R^2 parciales verdaderos, la cota coincide con el sesgo real hasta el error numérico. (b) El valor crítico coincide con su forma cerrada y es idéntico para dos corridas iguales. (c) Un control negativo que comparte el confusor lo detecta en casi todas las muestras, y uno que no lo comparte no supera la tasa nominal. (d) Un plazo vencido, un cambio de regla de asignación y una covariable nueva producen cada uno su motivo; sin eventos y con plazo vigente, la lista está vacía.

33.5 Implementación de referencia

El cálculo es de mínimos cuadrados y cabe en numpy. El listado define las piezas del contrato y las prueba sobre el generador del caso medio: calcula el registro de sensibilidad con la escala de la mejor covariable observada, ejecuta el control negativo y decide qué eventos obligan a revisar.

```
import numpy as np
```

```
def mco(y, regresores):
    """Mínimos cuadrados con constante: coeficientes, errores estándar y grados
de libertad."""
    Z = np.column_stack([np.ones(len(y)), regresores])
    b = np.linalg.lstsq(Z, y, rcond=None)[0]
    e = y - Z @ b
    gl = len(y) - Z.shape[1]
    se = np.sqrt(np.diag(e @ e / gl * np.linalg.inv(Z.T @ Z)))
    return b, se, gl


def r2_parcial(y, regresores, j):
    """R2 parcial del regresor j (sin contar la constante), a partir de su
estadístico t."""
    b, se, gl = mco(y, regresores)
    t = b[j + 1] / se[j + 1]
    return t ** 2 / (t ** 2 + gl)


def valor_critico(efecto, se, gl, umbral=0.0):
    """Fuerza (R2 parcial con D y con Y, iguales) que lleva el efecto hasta
`umbral`."""
    f = abs(efecto - umbral) / (se * np.sqrt(gl))
    return 0.5 * (np.sqrt(f ** 4 + 4 * f ** 2) - f ** 2)


def cota_sesgo(se, gl, r2_y, r2_d):
    """|sesgo| por omitir un confusor con R2 parcial r2_y con Y y r2_d con
D."""
    return se * np.sqrt(gl) * np.sqrt(r2_y * r2_d / (1 - r2_d))


def registrar_sensibilidad(efecto, se, gl, umbral_decision, escala, fecha,
plazo):
    """Registro del contrato C-08 para un supuesto no observable.
    `escala` = (r2_d, r2_y) de la covariable observada más fuerte; fecha y
plazo son ISO."""
    r2_d, r2_y = escala
    cota = cota_sesgo(se, gl, r2_y, r2_d)
    return {"metodo": "robustez_r2",
            "parametro": "valor de robustez respecto del umbral de decision",
            "umbral_decision": umbral_decision,
            "valor_critico": round(float(valor_critico(efecto, se, gl,
umbral_decision)), 3),
            "escala": {"r2_d": round(float(r2_d), 3), "r2_y":
```

```
round(float(r2_y), 3),
                       "rango_efecto": [round(float(efecto - cota), 3),
round(float(efecto + cota), 3)]},
            "decision_fragil": bool(efecto - cota <= umbral_decision <= efecto
+ cota),
            "fecha": fecha, "revisar_antes_de": plazo}


def control_negativo(nc, d, X):
    """Efecto de D sobre un resultado que D no causa: distinto de cero indica
confusión compartida."""
    b, se, gl = mco(nc, np.column_stack([d, X]))
    return b[1], se[1], bool(abs(b[1] / se[1]) > 1.96)


DISPARADORES = {"cambio_regla_asignacion", "covariable_nueva",
"poblacion_nueva",
                "control_negativo_encendido"}


def motivos_revision(registro, hoy, eventos):
    """Motivos por los que una persona debe revisar el supuesto (lista vacía si
ninguno).
    Las fechas ISO se comparan como texto."""
    motivos = sorted(set(eventos) & DISPARADORES)
    if hoy > registro["revisar_antes_de"]:
        motivos.append("plazo_vencido")
    return motivos


# Generador del caso medio: confusor U no observado, control negativo N que
comparte U.
rng = np.random.default_rng(3)
n = 2000
X = rng.standard_normal((n, 2))
U = rng.standard_normal(n)
D = 0.6 * X[:, 0] + 0.3 * X[:, 1] + 0.5 * U + rng.standard_normal(n)
Y = 0.2 * D + 0.5 * X[:, 0] + 0.5 * X[:, 1] + 0.6 * U + rng.standard_normal(n)
N = 1.0 * U + rng.standard_normal(n)

b, se, gl = mco(Y, np.column_stack([D, X]))
escala = (r2_parcial(D, X, 0), r2_parcial(Y, np.column_stack([D, X]), 1))   #
X1 con D y con Y
reg = registrar_sensibilidad(b[1], se[1], gl, 0.3, escala, "2026-01-15",
"2026-04-15")
print(reg)
```

```
# La cota con los R2 verdaderos de U coincide con el sesgo real (identidad
algebraica).
b_largo = mco(Y, np.column_stack([D, X, U]))[0]
r2_d_u, r2_y_u = r2_parcial(D, np.column_stack([X, U]), 2), r2_parcial(Y,
np.column_stack([D, X, U]), 3)
assert abs(abs(b[1] - b_largo[1]) - cota_sesgo(se[1], gl, r2_y_u, r2_d_u)) <
1e-9
assert 0 < reg["valor_critico"] < 1 and reg["escala"]["rango_efecto"][0] < b[1]
< reg["escala"]["rango_efecto"][1]
assert control_negativo(N, D, X)[2]                       # el control que
comparte U se enciende
assert not control_negativo(rng.standard_normal(n), D, X)[2]   # un resultado
sin relación con U no se enciende
assert motivos_revision(reg, "2026-02-01", []) == []
assert motivos_revision(reg, "2026-05-01", ["covariable_nueva"]) ==
["covariable_nueva", "plazo_vencido"]
```

Listado 33.1: Sensibilidad de un supuesto no observable: valor crítico de la decisión, escala de referencia, control negativo y motivos de revisión.

La ficha guarda `reg` como el campo `sensibilidad` del supuesto de no confusión (Apéndice G), y el CI local lo exige con el esquema (Capítulo 20). La operación de revisión la llama el monitoreo cada vez que emite un evento y cada vez que corre el plazo.

33.6 Aplicación al sistema causal del curso

En el sistema de referencia, la ficha del estimador DML de retornos a la educación declara dos supuestos de clases distintas. El soporte común es observable: la ficha trae su umbral, calibrado con la tasa de falsas alarmas que el equipo tolera, y el monitoreo lo vuelve a medir en cada ventana. La no confusión condicional es no observable, y la ficha trae su sensibilidad: el valor crítico respecto del costo de actuar, el rango de efectos con la escala de la mejor covariable observada, y una fecha de revisión. Cuando el monitoreo detecta que cambió la regla con que se asigna el tratamiento, la señal (ii) enciende el evento, y este contrato lo convierte en una revisión con nombre y responsable. Quien revisa recalcula, y la ficha nueva lleva la sensibilidad nueva.

Lo que el libro enseña a ese sistema es una distinción y una disciplina. La distinción separa lo que se puede vigilar de lo que no. La disciplina consiste en que lo segundo no se declare verificado, se acote con un margen que otra persona pueda discutir y se vuelva a mirar cuando el mundo cambie. Un sistema así no sabe más sobre lo que no puede ver. Sabe cuánto de lo que afirma depende de ello, y lo dice.

33.7 Señales de alerta y checklist operativo

- ☐ Un supuesto no observable figura en la ficha como «verificado», o con una evidencia que no es un cálculo reproducible.

- ☐ El valor de robustez se reporta sin el umbral de la decisión y sin la escala con que se interpreta.
- ☐ Un valor de robustez alto se cita como prueba de que no hay confusión.
- ☐ La escala de referencia no está declarada, o se declara sin decir qué covariable la define.
- ☐ El control negativo elegido no comparte ninguna causa con el resultado, y su silencio se presenta como confirmación.
- ☐ La sensibilidad no se recalculó tras reentrenar con datos nuevos, cambiar de población o cambiar de especificación.
- ☐ Nadie tiene a su cargo la revisión disparada por un evento, o la revisión termina siempre en «sigue valiendo» sin dejar nota.

33.8 Ejercicios y notas bibliográficas

33.8.1 Ejercicios conceptuales

1. Con costo $c = 0.3$, efecto estimado 0.44, error estándar 0.023 y 1 995 grados de libertad, calcule el valor crítico de la decisión. Explique qué dice sobre la decisión y qué no dice.
2. Un equipo declara que «ningún confusor oculto es más fuerte que la mejor covariable observada», y con eso declara robusta la decisión. Dé dos razones por las que la declaración puede ser falsa y diga qué debe registrar la ficha para que otra persona pueda discutirla.
3. Para el estimador de retornos a la educación, proponga un resultado que sirva como control negativo (que la educación no pueda causar y que comparta una causa con el salario) y otro que no sirva. Explique por qué en cada caso.
4. Un colega cita un valor de robustez de 0,52 como prueba de que no hay confusión. Redacte en tres frases la respuesta, usando el caso 1.
5. Defina tres eventos que obliguen a revisar la sensibilidad del sistema de su organización, quién revisa y cuáles son los tres resultados posibles de la revisión.

33.8.2 Ejercicios computacionales

1. Con las funciones del listado 33.1, reproduzca la tabla del caso 1 para las cuatro intensidades y verifique que la cota coincide con el sesgo real en cada una.
2. Repita el caso 2 con costos $c = 0.1$ y $c = 0.5$. ¿Cómo cambia la fracción de decisiones frágiles y por qué?
3. Construya un control negativo que comparta solo una parte pequeña del confusor ($\zeta = 0.1$) y estime su potencia para $n = 500$ y $n = 2\,000$.

33.8.3 Notas bibliográficas

Cinelli y Hazlett (2020) son la fuente de la cota y del valor de robustez en escala R^2, y el Capítulo 14 presenta el protocolo completo con el *E-value* de VanderWeele y Ding (2017).

La versión para estimadores con aprendizaje automático, con otras cantidades en lugar de los R^2 parciales, es de Chernozhukov et al. (2022b). Los controles negativos vienen de la epidemiología: Lipsitch et al. (2010) explican qué debe cumplir un control para detectar confusión y por qué su silencio no es una prueba. Para las tendencias paralelas, el análogo de este capítulo es el análisis de sensibilidad de Rambachan y Roth (2023), que acota cuánto puede desviarse la tendencia posterior de la observada antes del tratamiento. La idea de tratar la decisión, y no el efecto, como el objeto de la sensibilidad se apoya en el marco de decisión bajo incertidumbre del Capítulo 25.

APÉNDICE A

Notación, convenciones y fundamentos matemáticos

A.1 Notación general

A lo largo de esta monografía se emplean las siguientes convenciones notacionales, salvo que se indique explícitamente lo contrario.

Símbolo	Significado
R	Conjunto de los números reales
N	Conjunto de los números naturales
$\mathbf{1}\{\cdot\}$	Función indicadora
$P(\cdot)$	Medida de probabilidad
$E[\cdot]$	Esperanza matemática
$\mathrm{Var}(\cdot)$	Varianza
$\mathrm{Cov}(\cdot,\cdot)$	Covarianza
$\mathbb{P}_n$	Medida empírica $\left(\frac{1}{n}\right)\sum_{i=1}^{n}\delta_{W_i}$
$\mathbb{G}_n$	Proceso empírico $\sqrt{n}(\mathbb{P}_n - P)$
$O_p(\cdot)$, $o_p(\cdot)$	Órdenes en probabilidad
$O(\cdot)$, $o(\cdot)$	Órdenes deterministas
$\xrightarrow{p}$	Convergencia en probabilidad
$\xrightarrow{d}$	Convergencia en distribución
$\xrightarrow{L^2}$	Convergencia en media cuadrática
$\xrightarrow{\text{a.s.}}$	Convergencia casi segura
$\perp\!\!\!\perp$	Independencia
$\mid$	Condicionamiento
$\lVert x \rVert_p$	Norma p de un vector ($\lVert x \rVert_2$ euclídea)
$\lVert M \rVert_F$	Norma de Frobenius de una matriz

Símbolo	Significado
$\|M\|_*$	Norma nuclear de una matriz
∇	Gradiente
∂	Derivada parcial o derivada de Fréchet
$\mathbf{1}_n$	Vector de unos de longitud n
I_n	Matriz identidad de $n \times n$
$a_n \lesssim b_n$	$a_n \leq C b_n$ para alguna constante $C > 0$
$a_n \asymp b_n$	$a_n \lesssim b_n$ y $b_n \lesssim a_n$

Tabla A.1: Símbolos y convenciones notacionales.

Para variables aleatorias se usan mayúsculas (X, Y, D) y para realizaciones concretas minúsculas (x, y, d). Los vectores y matrices se denotan en negrita ($\boldsymbol{X}$, $\boldsymbol{\beta}$). La norma $L^2(P)$ de una función f se escribe $\|f\|_{P,2} = \sqrt{\int f^2 \, \mathrm{d}P}$.

A.2 Modos de convergencia

Definición 1.1 ***(Convergencia en probabilidad)***

$X_n \xrightarrow{p} X$ si para todo $\varepsilon > 0$, $P(\|X_n - X\| > \varepsilon) \to 0$.

Definición 1.2 ***(Convergencia en distribución)***

$X_n \xrightarrow{d} X$ si $F_{X_n}(x) \to F_X(x)$ en todos los puntos de continuidad de F_X.

Definición 1.3 ***(Convergencia en L^2)***

$X_n \xrightarrow{L^2} X$ si $E\left[(X_n - X)^2\right] \to 0$.

La cadena de implicaciones es: $L^2 \Rightarrow p \Rightarrow d$. Las tasas de convergencia se expresan con la notación O_p y o_p.

A.3 Teoremas límite fundamentales

Teorema 1.4 ***(Ley débil de los grandes números)***

Si $X_1, \ldots, X_n$ son *i.i.d.* con $E\|X_i\| < \infty$, entonces $\overline{X}_n \xrightarrow{p} E[X]$.

Teorema 1.5 ***(Teorema central del límite)***

Si $X_1, \ldots, X_n$ son *i.i.d.* con $\mathrm{Var}(X_i) = \sigma^2 < \infty$, entonces $\sqrt{n}\left(\overline{X}_n - \mu\right) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$.

Teorema 1.6 ***(Slutsky)***

Si $X_n \xrightarrow{d} X$ e $Y_n \xrightarrow{p} c$, entonces:

- $X_n + Y_n \xrightarrow{d} X + c$,
- $X_n Y_n \xrightarrow{d} cX$,
- $\frac{X_n}{Y_n} \xrightarrow{d} \frac{X}{c}$ si $c \neq 0$.

A.4 Teoría asintótica semiparamétrica

A.4.1 Espacios tangentes

Sea $\mathcal{P}$ una familia de distribuciones parametrizada por (θ, η), donde $\theta \in R^d$ es el parámetro de interés y η es un parámetro *nuisance* infinito-dimensional. El *espacio tangente* en $\mathcal{P}_0$ es el *closure* del espacio generado por los *scores* de un submodelo paramétrico que pasa por $\mathcal{P}_0$.

Definición 1.7 ***(Pathwise derivative)***

Para un submodelo $t \to P_t$ con $P_0 = P$, el score *pathwise* es $s = \frac{\mathrm{d}}{\mathrm{d}t} \log p_t \mid_{t=0}$. El *efficient influence function* (EIF) es la proyección del score de θ sobre el espacio tangente.

A.4.2 Estimación semiparamétrica eficiente

Teorema 1.8 ***(Cota de Cramér-Rao semiparamétrica)***

La varianza asintótica mínima de un estimador regular de θ es $\tilde{I}_\theta^{-1}$, donde $\tilde{I}_\theta$ es la *información eficiente*: la varianza del EIF.

Teorema 1.9 ***(Bickel, Klaassen, Ritov & Wellner, 1993)***

Bajo regularidad, un estimador $\hat{\theta}$ es *asintóticamente eficiente* si y solo si su *influence function* iguala el EIF.

A.5 Ortogonalidad de Neyman

La ortogonalidad de Neyman (capítulo 10) es una propiedad del *score* que lo hace insensible en primer orden a errores de estimación de los *nuisance parameters*. Formalmente:

Definición 1.10 ***(Score Neyman-ortogonal)***

Un score $\psi(W, \theta, \eta)$ es Neyman-ortogonal en (θ_0, η_0) si para toda perturbación $\eta - \eta_0$ en una vecindad:

$$\partial_\eta E[\psi(W, \theta_0, \eta)] \mid_{\eta=\eta_0} [\eta - \eta_0] = 0. \tag{A.1}$$

Esta propiedad es la base del teorema central de DML del capítulo 10.

A.6 Cross-fitting y sample splitting

El *cross-fitting* preserva la independencia entre el estimador de *nuisance* y el score evaluado en la muestra principal. La idea es dividir la muestra en K *folds*; para cada *fold*, estimar $\hat{\eta}$ en los $K-1$ *folds* restantes y evaluar el score en el *fold* k. Esto evita el *overfitting bias* sin desperdiciar datos.

A.7 Honesty en árboles causales

La *honesty* (capítulo 13) es el análogo para árboles del *cross-fitting*: la muestra usada para decidir las divisiones del árbol es distinta de la usada para estimar el CATE dentro de cada hoja. Sin *honesty*, el árbol selecciona divisiones que maximizan la diferencia observada entre tratados y controles, introduciendo sesgo.

A.8 Norma nuclear y matrix completion

La *norma nuclear* de una matriz L es $\|L\|_* = \sum_i \sigma_i(L)$, donde σ_i son los valores singulares. Es la envolvente convexa del *rank*, lo que permite formular el problema de *matrix completion* (capítulo 28) como optimización convexa.

Teorema 1.11 ***(Recht, Fazel & Parrilo, 2010)***

Bajo *incoherence* y muestreo aleatorio suficientemente denso, la minimización de norma nuclear recupera exactamente la matriz de bajo rango subyacente.

A.9 Modelos causales estructurales

Un modelo causal estructural describe cada variable como función de sus causas directas más ruido:

$$X_j = f_j\big(\mathrm{PA}_j, U_j\big) \tag{A.2}$$

donde PA_j son los padres causales de X_j y U_j son factores no observados independientes.

Tres niveles de preguntas causales:

1. Asociación: $P(Y \mid X)$ — «¿Qué dice la data?»
2. Intervención: $P(Y \mid \mathrm{do}(X = x))$ — «¿Qué pasa si intervengo?»
3. Contrafactual: $P(Y_x \mid X = x', Y = y')$ — «¿Qué habría pasado si…?»

Para pasar del nivel 1 al 2 se necesitan supuestos de identificación (no confusión, exclusión, etc.). El ML predictivo opera en nivel 1; la evaluación de políticas requiere nivel 2.

A.10 Influence functions

La *influence function* (IF) de un estimador $\hat{\theta}$ nos dice cómo cambia $\hat{\theta}$ si modificamos una observación:

$$\hat{\theta} - \theta_0 \approx \left(\frac{1}{n}\right) \sum_{i=1}^{n} \psi(W_i, \theta_0, \eta_0) \tag{A.3}$$

Ejemplos:

- **ATE bajo IRM:** $\psi_i = \mu_1(X_i) - \mu_0(X_i) + \frac{D_i(Y_i - \mu_1(X_i))}{e(X_i)} - \frac{(1-D_i)(Y_i - \mu_0(X_i))}{1-e(X_i)} - \theta$
- **PLR (Robinson):** $\psi_i = v_i(u_i - \theta v_i)$, con $v_i = D_i - e(X_i)$, $u_i = Y_i - l(X_i)$

Ambas IF alcanzan la cota semiparamétrica de sus funcionales: el Teorema de eficiencia del DML-IRM (Sección 11.2.2) para IRM, y (Chernozhukov et al. 2018b) para PLR.

La varianza asintótica es $\mathcal{V} = E[\psi_i^2]$. La ortogonalidad garantiza que errores en η no contaminan θ en primer orden.

A.11 Regresión Discontinua (RDD)

Cuando el tratamiento se asigna según un umbral c en una variable continua X:

$$\tau_{\text{RD}} = \lim_{x \to c^+} E[Y \mid X = x] - \lim_{x \to c^-} E[Y \mid X = x] \tag{A.4}$$

Si el cumplimiento es imperfecto (*fuzzy RDD*):

$$\tau_{\text{FRD}} = \frac{\lim_{x \to c^+} E[Y \mid X = x] - \lim_{x \to c^-} E[Y \mid X = x]}{\lim_{x \to c^+} E[D \mid X = x] - \lim_{x \to c^-} E[D \mid X = x]} \tag{A.5}$$

El RDD difuso puede interpretarse como IV local donde el umbral es el instrumento.

A.12 Transportabilidad

Un efecto causal estimado en población A ¿puede aplicarse a población B? La respuesta depende de:

- **Covariate shift:** la distribución de X cambia entre A y B. Si el efecto es condicional en X y X captura toda la heterogeneidad, puede ser transportable.
- **Target shift:** la relación $Y_x \mid X$ cambia entre poblaciones. Se requieren diagramas de selección para decidir.

Un diagrama de selección incluye un nodo S que indica si una observación pertenece a la población fuente o destino. Si $Y \perp\!\!\!\perp S \mid X$, el efecto es directamente transportable y se recompone con la distribución de destino: $\text{ATE}^* = \sum_x \text{ATE}(x) P^*(x)$.

Equivalencia de notación con el Capítulo 26: allí la fuente es Π y el destino Π^* (aquí A y B). Además, el capítulo usa nodos $S_i \to V_i$ que marcan *qué mecanismos* pueden diferir entre dominios; el indicador binario de membresía usado aquí es el caso particular en que solo se distingue fuente de destino.

APÉNDICE B

Guía de librerías y entorno reproducible

Este apéndice reúne las herramientas concretas con las que se implementan los métodos del libro. Es material de implementación: las versiones y las interfaces cambian, y el texto de los capítulos no depende de él.

B.1 Entorno reproducible

Para garantizar la reproducibilidad de los experimentos y facilitar la instalación de todas las dependencias necesarias, se recomienda el uso de entornos virtuales gestionados con `conda` o `venv`. A continuación se describe la configuración base utilizada en los ejemplos de este apéndice.

La gestión de dependencias puede realizarse mediante un archivo `requirements.txt` o un archivo `environment.yml` de Conda. Ambas opciones permiten fijar versiones específicas de cada librería, asegurando que los resultados sean replicables en diferentes sistemas.

B.2 econml (Microsoft Research)

Propósito. Implementación de métodos de ML causal desarrollada por Microsoft Research. Es una de las librerías más completas para estimación de CATE.

Módulos principales.

- `econml.dml`: Double Machine Learning (`LinearDML`, `CausalForestDML`, `SparseLinearDML`).
- `econml.metalearners`: S/T/X-learners (`SLearner`, `TLearner`, `XLearner`).
- `econml.policy`: Policy trees y forests (`PolicyTree`, `PolicyForest`).
- `econml.iv`: Variables instrumentales (`DeepIV`, `OrthoIV`).
- `econml.orf`: Orthogonal Random Forests.
- `econml.score`: Validation scores (`RScorer`); fundamento y protocolo de uso en el Capítulo 14.

Ejemplo canónico.

```
import numpy as np
from econml.dml import LinearDML
from sklearn.ensemble import GradientBoostingClassifier,
GradientBoostingRegressor

# Datos sintéticos con efecto verdadero 1,0 y confusión observada en X[:, 0]
rng = np.random.default_rng(0)
n = 2000
X = rng.normal(size=(n, 3))
D = rng.binomial(1, 1 / (1 + np.exp(-X[:, 0])))
Y = 1.0 * D + X[:, 0] + rng.normal(size=n)

est = LinearDML(model_y=GradientBoostingRegressor(),
                model_t=GradientBoostingClassifier(),
                discrete_treatment=True, cv=5)
est.fit(Y, D, X=X)
ate = est.ate(X=X); cate = est.effect(X)
```

Listado B.1: Ejemplo canónico de uso de `econml` (`LinearDML`).

B.3 DoubleML

Propósito. Implementación del marco DML de Chernozhukov et al. (2018) con foco en inferencia rigurosa.

Módulos principales.

- `DoubleMLPLR`: Partial Linear Model.
- `DoubleMLIRM`: Interactive Regression Model.
- `DoubleMLPLIV`: Partial Linear IV Model.
- `DoubleMLIIVM`: Interactive IV Model.

Diferencia con econml. `DoubleML` está más orientado a inferencia (IC, tests); `econml` está más orientado a estimación de CATE. Complementarios.

B.4 causalml (Uber)

Propósito. Librería de Uber para *uplift modeling* y *meta-learners*. Fuerte en aplicaciones de marketing.

Módulos principales.

- `causalml.inference.meta`: S/T/X/R-learners con varias *base learners* (XGBoost, MLP).
- `causalml.metrics`: Qini, AUUC, *uplift curves*.
- `causalml.optimize`: Optimización de políticas bajo restricciones presupuestarias.
- `causalml.propensity`: Estimación de *propensity score* con varios modelos.

En versiones recientes, usar `BaseSRegressor`, `BaseTRegressor`, `BaseXRegressor` o `BaseRRegressor` con un *learner* base (por ejemplo, `XGBRegressor`).

B.5 dowhy (PyWhy)

Propósito. Framework de inferencia causal que integra identificación (con DAGs), estimación (con varios métodos), y refutación (*placebo tests*, sensibilidad).

Pipeline.

1. **Modelado:** definir tratamiento, *outcome*, y DAG con `CausalModel`.
2. **Identificación:** `model.identify_effect()` aplica el criterio de puerta trasera.
3. **Estimación:** `model.estimate_effect()` con el método elegido (*matching*, estratificación o ponderación por *propensity score*, regresión lineal, o estimadores de `econml` como DML).
4. **Refutación:** `model.refute_estimate()` con *placebos* y sensibilidad.

B.6 PyTorch

Propósito. Framework de *deep learning*. Usado en este curso para implementaciones *from-scratch* de TARNet, CFRNet, DeepIV.

Patrones comunes en ML causal.

```
import torch.nn as nn

class RepresentationNet(nn.Module):
    def __init__(self, in_dim, rep_dim):
        super().__init__()
        self.net = nn.Sequential(
            nn.Linear(in_dim, 128), nn.ReLU(),
            nn.Linear(128, 64), nn.ReLU(),
            nn.Linear(64, rep_dim),
        )
    def forward(self, X):
        return self.net(X)
```

Listado B.2: Red de representación para TARNet/CFRNet en PyTorch.

B.7 scikit-learn

Propósito. Base para todos los *learners* de ML. `RandomForestRegressor`, `GradientBoostingRegressor`, `LassoCV`, `LogisticRegressionCV` son los componentes básicos de DML.

B.8 networkx

Propósito. Manipulación de grafos. Útil para visualizar DAGs y construir estructuras causales antes de pasar a `dowhy`.

B.9 statsmodels

Propósito. Estimación econométrica clásica (OLS, 2SLS, IV) y tests estadísticos. Útil para *benchmarks* y comparaciones con métodos de ML.

B.10 Tabla comparativa

Librería	Versión	Foco	Fortaleza	Limitación
`econml`	0.17.0	CATE	Más completo	Curva de aprendizaje alta
`DoubleML`	0.11.4	Inferencia	IC rigurosos	Foco en ATE/ATT/LATE; menos orientado a CATE heterogéneo que `econml`
`causalml`	0.17.0	Uplift	Métricas de marketing	Enfoque específico en uplift
`dowhy`	0.14	Pipeline	Identificación + refutación	Estimación delegada
`PyTorch`	2.14.1	Deep causal	Flexibilidad total	Requiere experiencia
`scikit-learn`	1.9.1	Base	Estándar	No causal específico
`networkx`	3.7	Grafos	DAGs y visualización	No estima efectos
`statsmodels`	0.15.0	Econometría clásica	OLS, 2SLS, IV y tests	No incluye ML

Tabla B.1: Comparación de librerías y versiones vigentes (PyPI, 5 de octubre de 2026).

La columna *Versión* de la Tabla B.1 indica la última versión estable publicada en PyPI a fecha 5 de octubre de 2026 para los paquetes `econml`, `doubleml`, `causalml`, `dowhy`, `torch`, `scikit-learn`, `networkx` y `statsmodels`. Para reproducir resultados, fije estas versiones (u otras explícitas) en `requirements.txt` o `environment.yml` (Sección B.1).

B.11 Instalación recomendada

```
pip install econml doubleml causalml dowhy torch scikit-learn networkx
statsmodels shap jsonschema
```

Listado B.3: Instalación del stack base de librerías de ML causal.

B.11.1 Librerías complementarias

Librería	Foco	Fortaleza	Limitación
`causal-learn`	Causal discovery	PC, FCI, GES implementados	Curva de aprendizaje alta
`cdt`	Discovery toolbox	Muchos algoritmos en un lugar	Mantenimiento variable
`pgmpy`	Modelos gráficos	Grafos de probabilidad	No siempre causal
`geomloss`	Distancias Wasserstein/MMD	Útil para CFRNet	Requiere GPU opcional
`POT`	Transporte óptimo	Flexible y bien documentado	Costo computacional alto
`linearmodels` / `pyfixest`	IV, panel y DiD	Econometría clásica rápida	No incluye ML

Tabla B.2: Librerías complementarias.

Instalación opcional:

```
pip install causal-learn cdt pgmpy geomloss POT linearmodels pyfixest
```

Listado B.4: Instalación de librerías complementarias.

APÉNDICE C

Datos, DGP y benchmarks

Los capítulos usan dos familias de datos, y cada una responde una pregunta distinta. Los **conjuntos reales** permiten contrastar un método con resultados publicados y con diseños que otros han estudiado, pero la verdad del efecto casi nunca se conoce. Los **procesos generadores sintéticos** (DGP, por *data generating process*) se construyen con un efecto verdadero conocido, y por eso permiten medir sesgo, cobertura y potencia de un estimador. Un método se acepta cuando funciona en ambos: en los sintéticos, porque acierta; en los reales, porque su respuesta es plausible y sus diagnósticos no la desmienten.

C.1 Conjuntos reales

Conjunto	Diseño	Estimando	Caps.	Qué permite contrastar
Programa NSW de capacitación (Lalonde, 1986) `nsw_mixtape`	Experimento y comparación observacional	ATE, CATE	5, 10–13, 21, 24	Un resultado experimental conocido (cerca de 1 800 USD) frente a estimadores observacionales
Educación y salario, cercanía a una universidad (Card, 1995) `close_college`	IV	LATE	5, 10, 11, 13, 16, 17, 29	Un instrumento binario con primera etapa de tamaño moderado
Muestra de comparación de la CPS `cps_mixtape`	Observacional	ATE	11, 13, 14, 16	Grupo de comparación grande, con diferencias de base marcadas
Dejar de fumar y aumento de peso, NHEFS `nhefs`	Observacional	ATE, CATE	6, 11, 16, 24	Selección entre muchas covariables

Conjunto	Diseño	Estimando	Caps.	Qué permite contrastar
Transferencias públicas `gov_transfers`	Observacional	ATE, CATE	12, 21, 24	Covariables reales para procesos con efecto simulado
Expansión carcelaria de Texas en 1993 `texas`	Control sintético	ATT	28	Un panel con una sola unidad tratada y muchas candidatas a donante
Legalización del aborto `abortion`	Adopción escalonada	ATT	28	Un panel con varias cohortes de adopción
Doctrina del castillo (Cheng y Hoekstra, 2013) `castle`	DiD escalonado	ATT	complementario	Efectos por cohorte y tendencias previas
Pruebas de VIH con incentivos (Thornton, 2008) `thornton_hiv`	Experimento	ATE, CATE	14, 22	Efectos de un incentivo asignado al azar y su heterogeneidad
Elecciones reñidas de la Cámara de Representantes (Lee, Moretti y Butler, 2004) `close_elections_lmb`	RDD	LATE	complementario	Continuidad en el umbral y sensibilidad al ancho de banda
Donación de órganos `organ_donations`	DiD	ATT	complementario	Tendencias paralelas en un cambio de regla
Hipotecas `mortgages`	Observacional	ATE	complementario	Ejercicios adicionales de ajuste por observables

Tabla C.1: Conjuntos de datos reales de referencia y capítulos donde se usan.

Los capítulos señalados son aquellos donde el conjunto aparece en un ejemplo o en un ejercicio. Los marcados como complementarios no se usan en el texto y sirven para ejercicios adicionales.

C.2 Procesos generadores sintéticos

Cada proceso sintético aísla una dificultad: se genera con un efecto verdadero conocido y con el defecto que se quiere estudiar, y no con todos a la vez. Esa disciplina permite saber qué rompió a un estimador cuando falla.

Proceso	Diseño	Estimando	Caps.	Dificultad que aísla
Panel con efecto fijo dinámico `panel_fe_dynamic`	Panel	ATE	complementario	Efecto individual conocido y heterogéneo
DiD con tendencias paralelas `did_parallel_ok`	DiD	ATT	complementario	Caso base donde el supuesto se cumple
DiD con tendencias no paralelas `did_parallel_violation`	DiD	ATT	complementario	Sesgo cuando el supuesto falla
DiD escalonado con sesgo de TWFE `staggered_twfe_bias`	DiD escalonado	ATT	complementario	Pesos negativos del estimador de dos vías
IV con cumplimiento heterogéneo `iv_noncompliance`	IV	LATE	27	Efecto solo para quienes cumplen
IV con exclusión violada `iv_invalid_exclusion`	IV	LATE	complementario	Sesgo cuando el instrumento afecta el resultado por otra vía
Emparejamiento con confusor oculto `matching_hidden_conf`	Emparejamiento	ATE	complementario	Sesgo que el emparejamiento no corrige
Mediación con sesgo postratamiento `mediation_post_treatment`	Mediación	Efecto directo	complementario	Sesgo por condicionar en un mediador
Experimento con desgaste `rct_attrition`	Experimento	ATE	complementario	Pérdida de unidades que depende del tratamiento
RDD nítido con elección de ancho de banda `rdd_sharp_bandwidth`	RDD	LATE	complementario	Compromiso entre sesgo y varianza
RDD difuso con manipulación `rdd_fuzzy_manipulation`	RDD	LATE	complementario	Acumulación de unidades en el umbral
Control sintético con placebos `scm_placebo`	Control sintético	ATT	complementario	Inferencia por permutación

Tabla C.2: Procesos generadores sintéticos con efecto verdadero conocido.

C.3 Recomendaciones de uso por capítulo

- **Caps. 5 y 6 (predicción y causalidad, regularización):** el programa NSW y la cercanía a la universidad para motivar la diferencia entre predecir y estimar; dejar de fumar para la selección con muchas covariables; un proceso sintético para ilustrar el sesgo.
- **Caps. 10 y 11 (ortogonalidad y DML):** el programa NSW como aplicación y un proceso sintético con efecto conocido para verificar la cobertura del intervalo.
- **Caps. 12 y 13 (meta-learners y bosques causales):** un proceso sintético con efecto heterogéneo conocido, y el programa NSW como aplicación.
- **Cap. 14 (validación):** un proceso sintético con verdad conocida, y las pruebas de VIH para ejercicios con placebos.
- **Cap. 16 (selección en alta dimensión):** dejar de fumar y la cercanía a la universidad.
- **Cap. 17 (panel):** un panel sintético con efectos fijos.
- **Caps. 21 y 22 (políticas y uplift):** las transferencias públicas y las pruebas de VIH.
- **Cap. 27 (aprendizaje profundo causal):** un proceso sintético con estructura conocida.
- **Cap. 28 (control sintético y matrix completion):** el panel de Texas y los procesos con factores latentes.
- **Cap. 29 (descubrimiento de grafos):** un proceso sintético con estructura causal conocida.

C.4 Datos complementarios sugeridos

Conjunto sugerido	Diseño causal	Uso en el libro	Fuente
Progresa/Oportunidades	RDD	Cap. 18 (mapa de decisión)	Evaluación de impacto
Panel de salario mínimo	DiD	Cap. 17 (panel)	Literatura de salario mínimo
Bono de reempleo	Experimento	Caps. 5 y 11	Literatura de seguro de desempleo
Brecha salarial en la CPS	Doble lasso	Caps. 6 y 16	Datos de la CPS
Convergencia del crecimiento	Selección y DML	Cap. 16	Literatura de crecimiento
Proceso tipo IHDP	Referencia de CATE	Cap. 27	Literatura de aprendizaje profundo causal
Texto e *embeddings* de producto	CATE con texto	Caps. 22 a 27	Procesamiento de lenguaje

Tabla C.3: Datos complementarios sugeridos.

Algunos de estos conjuntos pueden no estar disponibles. En ese caso se recomienda un proceso sintético que emule las mismas características: un confusor de la fuerza que importa, un efecto verdadero conocido y el defecto que se quiere estudiar.

C.5 Verdad conocida e integridad

Un proceso sintético se entrega en dos partes: los datos que ve quien estima, sin la verdad, y los valores verdaderos (los efectos individuales τ_i, el parámetro θ, los efectos directos e indirectos) que conserva quien evalúa. Esa separación permite medir la precisión de una estimación sin revelar la respuesta de antemano.

Todo conjunto, real o sintético, se acompaña de una suma de verificación SHA-256 por archivo, calculada al publicarlo. La suma garantiza que la evaluación se hace sobre la versión exacta del conjunto prevista, y que un archivo modificado o dañado se detecta antes de usarlo y no después de reportar un resultado.

C.6 Estructura de archivos

Cada conjunto real tiene:

- `data.csv`: datos en formato *tidy*.
- `source_metadata.json`: fuente, licencia, año y diccionario de variables.
- `checksums.sha256.json`: integridad verificable.

Cada conjunto sintético tiene:

- `student.csv`: datos visibles para quien estima, sin la verdad.
- `truth_instructor_only.csv`: la verdad (τ_i, θ, etc.), para quien evalúa.
- `checksums.sha256.json`.

Para verificar la integridad de un conjunto descargado:

```
import hashlib, json, pathlib

carpeta = pathlib.Path("ruta/del/conjunto")
# se supone que el archivo asigna a cada nombre de archivo su suma SHA-256
esperadas = json.loads((carpeta / "checksums.sha256.json").read_text())
for nombre, suma in esperadas.items():
    real = hashlib.sha256((carpeta / nombre).read_bytes()).hexdigest()
    print(nombre, "OK" if real == suma else "DISTINTO")
```

Listado C.1: Verificación de integridad de un conjunto con sumas SHA-256.

Si todos los archivos coinciden, la salida muestra `OK` para cada uno. Un resultado `DISTINTO` indica que el archivo fue modificado o está dañado, y se recomienda descargarlo de nuevo del repositorio oficial.

APÉNDICE D

Glosario de estimandos, supuestos y métodos

D.1 Estimandos

ATE (Average Treatment Effect)	$\theta = E[Y(1) - Y(0)]$. Efecto promedio del tratamiento en la población.
ATT (Average Treatment Effect on the Treated)	$\theta_{\text{ATT}} = E[Y(1) - Y(0) \mid D = 1]$. Efecto promedio en los tratados.
CATE (Conditional Average Treatment Effect)	$\tau(x) = E[Y(1) - Y(0) \mid X = x]$. Efecto promedio condicional en $X = x$. Estimando central del curso.
LATE (Local Average Treatment Effect)	Efecto del tratamiento en los *compliers*: individuos cuyo tratamiento es afectado por el instrumento.
ETT (Effect of Treatment on the Treated)	$E[Y(1) - Y(0) \mid D = 1]$.
Policy value	$V(\pi) = E[Y(\pi(X))]$. Bienestar esperado bajo la regla de asignación π.
Uplift	En marketing, sinónimo de CATE. Diferencia en probabilidad de conversión entre tratados y controles condicional en covariables.
Regret (welfare regret)	$\text{Regret}(\hat{\pi}) = V(\pi^*) - V(\hat{\pi})$. Pérdida de bienestar por usar $\hat{\pi}$ en lugar de π^*.

D.2 Supuestos

No confusión (*unconfoundedness*)	$Y(0), Y(1) \perp\!\!\!\perp D \mid X$. Supuesto de que no hay confusores no observados condicional en X.
Overlap / soporte común	Supuesto de que $\eta < P(D = 1 \mid X = x) < 1 - \eta$ para algún $\eta > 0$ y todo x. Garantiza que hay información tanto de tratados como de controles en cada región del espacio de covariables.
$\underline{e}$	Cota inferior de soporte común: $\underline{e} < P(D = 1 \mid X = x) < 1 - \underline{e}$ para todo x.
SUTVA (Stable Unit Treatment Value Assumption)	Supuesto de no interferencia entre unidades y de versiones únicas del tratamiento.
Causal sufficiency	Supuesto de que no hay confusores no observados que afecten a dos o más variables del grafo causal. Requerido por algoritmos de *causal discovery*.
Sparsity	Supuesto de que el vector verdadero de coeficientes tiene pocas componentes no nulas. Requerido por LASSO y PDS.
Restricted eigenvalue (RE)	Condición sobre la matriz de diseño que garantiza la **tasa** de convergencia ℓ_2 del LASSO. Relativamente débil. No basta para recuperar el soporte.
Irrepresentabilidad	Condición sobre la correlación entre variables activas e inactivas, necesaria y esencialmente suficiente para que el LASSO recupere el **conjunto** de variables verdaderamente no nulas. Mucho más fuerte que RE y no verificable en la práctica (Capítulo 6).
Faithfulness	Supuesto de que toda independencia condicional presente en la distribución corresponde a una d-separación en el grafo. Requerido por los algoritmos de descubrimiento basados en restricciones.
Transportabilidad	Validez de un efecto estimado en un dominio Π cuando se aplica a un dominio distinto Π^*. Se decide sobre un **diagrama de selección** (Capítulo 26).
Generalización (validez externa)	Caso particular de transportabilidad en que el problema es la **selección muestral**: si el efecto estimado sobre la muestra observada vale para la población de la que se extrajo.
Equidad contrafactual	Una decisión es justa si no cambia al modificar solo el atributo protegido, manteniendo lo que no depende causalmente de él.

D.3 Métodos

DML (Double/Debiased Machine Learning)	Marco de estimación causal que combina ortogonalidad de Neyman con *cross-fitting* para permitir inferencia válida cuando los *nuisance* se estiman con ML.
Cross-fitting	Partición de la muestra en K *folds*; para cada *fold* k, el *learner nuisance* se entrena en los $K-1$ *folds* restantes y predice en el *fold* k. Evita *overfitting bias* sin desperdiciar datos.
Sample splitting	División de la muestra en dos partes: una para estimar *nuisance*, otra para estimar el parámetro causal. Caso especial de *cross-fitting* con $K = 2$.
Post-Double-Selection (PDS)	Procedimiento de Belloni, Chernozhukov & Hansen (2014) para selección de confusores en alta dimensión sin sesgo post--selección.
R-learner	Meta-learner que optimiza el *score* ortogonal de Robinson. Alcanza tasas cuasi-oracle para CATE; la eficiencia $\sqrt{n}$ aplica a funcionales como el ATE o clases paramétricas de $\tau(x)$.
DR-learner	Meta-learner *doubly robust* que regresa sobre X el pseudo--*outcome* Γ_i (score IRM antes de promediar). Su error depende de los *nuisance* a través del **producto** de sus errores, no de su suma (Capítulo 12).
Score de Robinson	$\psi = (D - m(X))\{Y - l(X) - \theta(D - m(X))\}$, con $l_0(X) = E[Y\|X]$ y $m_0(X) = E[D\|X]$. Base del PLR de DML y de la *loss* del R-learner.
Cálculo-do	Conjunto de tres reglas de reescritura que transforman expresiones con do() en expresiones observacionales. **Completo**: si sus reglas no identifican el efecto, ningún método lo hace con ese grafo (Capítulo 8).
Puerta trasera (*back-door*)	Criterio gráfico para elegir un conjunto de ajuste Z válido. Corolario del cálculo-do.
Puerta delantera (*front-door*)	Criterio de identificación vía un mediador que capta todo el efecto, aplicable cuando existe confusión no observada y ningún ajuste por covariables funciona.
EWM (Empirical Welfare Maximization)	Elección de la política que maximiza el *welfare* empírico sobre una clase Π de VC-dimensión finita. Regret $O\big(\sqrt{\mathrm{VC}(\Pi)/n}\big)$ (Kitagawa & Tetenov, 2018).
Net score	$s_k(x) = \tau_k(x) - \lambda c_k(x)$, con λ el costo sombra de la restricción presupuestaria. Base de la asignación multi-tratamiento (Capítulo 22).
RA-learner	*Regression Adjustment* learner: $\hat{\tau}(x) = \hat{\mu}_1(x) - \hat{\mu}_0(x)$.

Honestidad (*honesty*, en árboles causales)	Restricción por la cual la partición del árbol se decide usando una submuestra distinta de la que se usa para estimar el efecto dentro de cada hoja. Garantiza validez asintótica de los IC.
IPW (Inverse Probability Weighting)	Estimador que usa el inverso del *propensity score* para ponderar unidades y reconstruir el contrafactual.
IPM (Integral Probability Metric)	Métrica de distancia entre distribuciones. Usada en CFRNet para forzar balance entre representaciones de tratados y controles.
MMD (Maximum Mean Discrepancy)	Distancia entre distribuciones usada en CFRNet.
Propensity score	$e(x) = P(D = 1 \mid X = x)$. Probabilidad de recibir tratamiento condicional en covariables.
IPS (Inverse Propensity Scoring)	Ponderación por la inversa del *propensity score*.
SNIPS (Self-Normalized IPS)	Versión normalizada de IPS.
$e_0(x)$	Propensity score: $e_0(x) = E[D \mid X = x]$. En el modelo PLR se denota también como $m_0(x)$.
$\mu_d(x)$	*Outcome* condicional: $\mu_d(x) = E[Y \mid X = x, D = d]$. Equivalente a $\mu(d, x)$.
$\omega_i(x)$	Pesos locales inducidos por un bosque causal / *Generalized Random Forest*. El estimador del CATE se obtiene resolviendo $\sum_i \omega_i(x) \cdot \psi_i\big(\hat{\theta}(x)\big) = 0$.
$Y_i^\star$ (***Transformed outcome***)	$Y_i^\star = Y_i \cdot \frac{D_i - e_0(X_i)}{e_0(X_i)(1-e_0(X_i))}$. Su esperanza condicional es $E[Y^\star \mid X] = \tau(X)$.
$\mathcal{C}$	Conjunto de ajuste que satisface el criterio de puerta trasera de Pearl.
ζ	Error del instrumento en el modelo PLIV: $Z = r_0(X) + \zeta$.
SCM (Structural Causal Model)	Modelo que describe cada variable como función de sus causas directas más ruido exógeno.
NCM (Neural Causal Model)	Red neuronal que parametriza un SCM.
DAG (Directed Acyclic Graph)	Grafo dirigido acíclico que representa relaciones causales directas entre variables.
PCH (Pearl Causal Hierarchy)	Jerarquía de tres niveles: asociación, intervención, contrafactual.
$\mathbf{do}(X = x)$	Operador de intervención: representa la acción de fijar X en el valor x, rompiendo sus causas.

Contrafactual	Resultado potencial bajo una intervención que no ocurrió: «¿Qué habría pasado si…?».
FCI (Fast Causal Inference)	Algoritmo de descubrimiento causal que permite variables latentes.
GES (Greedy Equivalence Search)	Algoritmo de descubrimiento basado en *score*.
Synthetic DiD	Combinación de control sintético y diferencias-en-diferencias.
RDD (Regression Discontinuity Design)	Diseño causal basado en un umbral.
Fuzzy RDD	RDD con cumplimiento imperfecto del umbral; se estima como IV local.
Off-policy evaluation	Estimación del valor de una política usando datos generados por otra política.
Nuclear norm	$\|L\|_* = \sum_i \sigma_i(L)$. Envolvente convexa del *rank*. Usada en *matrix completion*.

D.4 Garantías

Ortogonalidad de Neyman (*Neyman orthogonality*)	Propiedad de un *score* cuya derivada de Gateaux respecto a los parámetros *nuisance* es cero en el valor verdadero. Permite que errores de estimación de *nuisance* solo afecten la inferencia causal en segundo orden.
EIF (Efficient Influence Function)	Proyección del *score* del parámetro de interés sobre el espacio tangente. Determina el límite semiparamétrico de Cramér-Rao.
Doblemente robusto (*doubly robust*)	Propiedad de un estimador que es consistente si al menos uno de dos modelos (*outcome regression* o *propensity score*) es consistente. No requiere ambos.
$\mathcal{V}$	Varianza asintótica de estimadores como DML o PDS: $\sqrt{n} \cdot \left(\hat{\theta} - \theta_0\right) \xrightarrow{d} \mathcal{N}(0, \mathcal{V})$.

D.5 Diagnósticos

Curva Qini	*Qini curve*. Curva de validación de *ranking* causal: *uplift* acumulado en función de la fracción de muestra ordenada por CATE estimado. Mide la calidad del *ranking*, no la calibración absoluta de $\hat{\tau}$.

AUUC (Area Under Uplift Curve)	Área bajo la curva *uplift*. Métrica de **ranking**, no de calibración: es invariante a reescalar $\hat{\tau}$. Solo comparable entre modelos evaluados sobre la misma muestra.
Coeficiente Qini	AUUC normalizada restando el *baseline* aleatorio y dividiendo por el modelo perfecto. Comparable entre datasets.
E-value	$\mathrm{E} = \mathrm{RR} + \sqrt{\mathrm{RR}(\mathrm{RR}-1)}$. Fuerza mínima de asociación que un confusor no observado debería tener con tratamiento y resultado para explicar el efecto observado. Cota necesaria, no suficiente (Capítulo 14).
SMD / ASMD	Diferencia media estandarizada (absoluta). Tamaño de efecto invariante a n para medir desbalance. Criterio de Rubin: $\lvert\mathrm{SMD}\rvert < 0.25$ y razón de varianzas en $[0.5, 2]$.
PSI (Population Stability Index)	$\sum_b (p_b - q_b)\log(p_b/q_b)$ sobre *bins*. Convención de industria para *drift*: < 0.1 estable, > 0.25 deriva material. Sin respaldo teórico canónico.
Descomposición de Goodman-Bacon	Descomposición del estimador TWFE en comparaciones 2×2 ponderadas; revela las comparaciones «prohibidas» contra unidades ya tratadas y los pesos negativos (Capítulo 17).
Equidad en el efecto (*equalized CATE*)	Métrica de equidad **específica de sistemas causales**: la distribución del CATE estimado es similar entre grupos. No pertenece al canon de *fair ML* (Capítulo 24).
SHD (Structural Hamming Distance)	Número de aristas que difieren entre dos grafos.
CPDAG	Grafo parcialmente dirigido que representa una clase de equivalencia de Markov: el máximo que puede identificarse de la estructura con datos observacionales.

APÉNDICE E

Plantilla de proyecto final y rúbrica

Nota técnica

Este apéndice es material de uso educativo: se conserva en la edición de curso y no forma parte de la edición comercial del libro (en modo comercial se omite, reservando su letra para no invalidar las referencias internas). Un lector que estudie por su cuenta puede usar igualmente la estructura del informe y los criterios de la rúbrica como plantilla de un trabajo individual.

E.1 Estructura del informe

El proyecto final debe seguir la siguiente estructura (10–15 páginas + apéndices):

1. **Resumen ejecutivo** (1 página). Pregunta económica, método principal, resultado central, recomendación de política.
2. **Introducción** (1–2 páginas). Motivación económica, contexto, pregunta causal precisa, contribución.
3. **Marco de identificación** (2 páginas). Supuestos de identificación, justificación económica, DAG si aplica, estimando objetivo.
4. **Datos** (1–2 páginas). Descripción del dataset, *dataset card*, estadísticas descriptivas, balance observacional.
5. **Método** (2–3 páginas). Justificación metodológica usando el mapa del capítulo 18, especificación del estimador, selección de hiperparámetros.
6. **Resultados** (2–3 páginas). Estimación del ATE/CATE con IC, análisis de heterogeneidad, mapas de CATE si aplica.
7. **Validación** (1–2 páginas). *Placebos*, comparación con *benchmarks* clásicos, sensibilidad a hiperparámetros.
8. **Discusión** (1 página). Limitaciones, robustez, implicancias de política, consideraciones éticas.
9. **Conclusión** (0.5 página). Síntesis de hallazgos y recomendación final.
10. **Apéndices.** Código reproducible, gráficos adicionales, análisis de sensibilidad extendido.

E.2 Capa causal de la pregunta

El estudiante debe indicar:

- ¿La pregunta es de asociación, intervención o contrafactual?
- Estimando objetivo: ATE, ATT, CATE, LATE o *policy value*.
- Nivel en la jerarquía de Pearl (PCH) al que pertenece la pregunta.

E.3 DAG o supuesto estructural

Incluir:

- Grafo causal del problema.
- Variables observadas y no observadas.
- Criterio de identificación utilizado (*back-door*, *front-door*, instrumento, etc.).
- Justificación económica de cada arista incluida en el grafo.

E.4 Identificación

El estudiante debe detallar:

- Estimando objetivo formalmente definido.
- Supuestos de identificación y su justificación económica.
- Expresión del estimando en términos de la distribución observada.
- Si aplica, derivación del *score* ortogonal o función de influencia.
- Discusión de identificación parcial o sensible si los supuestos son débiles.

E.5 Estimación

Incluir:

- Elección del método justificada con el mapa de decisión del curso.
- Especificación de *learners nuisance* y criterios de selección de hiperparámetros.
- Estrategia de *cross-fitting* (número de *folds*).
- Construcción de intervalos de confianza.
- Código reproducible con semillas fijadas.

E.6 Validación y refutación

Incluir al menos dos de las siguientes pruebas:

- *Placebo treatment* (el ATE debe ser cero).
- *Random common cause* (el ATE no debe cambiar).
- *Subset validation* (resultado estable en submuestras).

Además, se recomienda:

- Comparación con estimadores clásicos (OLS, IPW, *matching*).

- Validación fuera de muestra de las predicciones *nuisance*.
- Pruebas de sensibilidad a la definición de tratamiento.

E.7 Análisis de sensibilidad

Incluir:

- Sensibilidad a hiperparámetros de los *learners*.
- Sensibilidad a *trimming* de *propensities* extremos.
- Protocolo de tres niveles del Sección 14.2.5: E-value obligatorio; R^2 de Imbens / Cinelli–Hazlett si el estimador es tipo PLR; *bounds* de Manski si el *outcome* está acotado.

E.8 Transportabilidad

Incluir:

- Población de entrenamiento y población objetivo.
- Riesgos de desplegar el modelo fuera de la población de entrenamiento.
- Supuestos bajo los cuales el efecto se transporta (p. ej., RCT frente a población objetivo).

E.9 Ética y comunicación

Incluir:

- Auditoría de equidad: CATE promedio por grupo protegido.
- Explicación contrafactual de al menos una decisión.
- *Model card* o ficha del modelo con limitaciones.
- Tabla para tomadores de decisión con intervalos de confianza.

E.10 Criterios de evaluación

Dimensión	Criterio	Peso
Pregunta económica	Clara, relevante, bien delimitada	10%
Identificación	Supuestos justificados económicamente, DAG si aplica	15%
Método	Justificado con mapa de decisión, hiperparámetros documentados	20%
Reproducibilidad	Código corre limpio, semillas fijadas, versiones declaradas	15%
Validación	*Placebos*, sensibilidad, comparación con *benchmarks*	15%
Heterogeneidad	CATE estimado con IC, subgrupos identificados	10%

Dimensión	Criterio	Peso
Comunicación	Tablas claras, IC reportados, distinción predicción/causalidad	10%
Ética	Equidad discutida, sesgo algorítmico abordado si aplica	5%

Tabla E.1: Rúbrica de evaluación del proyecto final.

E.11 Entregables

1. **Informe PDF** (10–15 páginas) siguiendo la estructura anterior.
2. **Notebook Jupyter** reproducible con código completo, comentarios y conclusiones.
3. **Datos** (o *script* de descarga si el dataset es externo).
4. **Defensa oral** (15 min + 5 min preguntas).

E.12 Ejemplos de problemas aplicados

- Efecto de un programa de capacitación sobre empleabilidad, con heterogeneidad por sector.
- Efecto de una reforma tributaria sobre inversión empresarial, con *staggered adoption*.
- Efecto de becas sobre deserción universitaria, con CATE por características socioeconómicas.
- Efecto de recordatorios sobre adherencia médica, con múltiples tratamientos.
- Efecto de una política monetaria sobre inflación, con variable instrumental.
- Optimización de *targeting* de transferencias gubernamentales bajo restricciones de equidad.

E.13 Plazos sugeridos

- **Semana 10:** propuesta de problema y dataset (1 página).
- **Semana 12:** entrega intermedia: identificación + EDA + método tentativo.
- **Semana 14:** entrega del borrador completo para revisión por pares.
- **Semana 16:** entrega final + defensa oral.

APÉNDICE F

Checklists por método

F.1 Checklist DML

- ☐ Supuesto de no confusión justificado.
- ☐ Soporte común verificado.
- ☐ *Nuisance* evaluado fuera de muestra.
- ☐ *Cross-fitting* correcto.
- ☐ *Influence function* calculada.
- ☐ Intervalos de confianza reportados.
- ☐ *Placebos* realizados.
- ☐ Sensibilidad a *learners* reportada.

F.2 Checklist meta-learners

- ☐ S-learner no confunde el efecto con las covariables (incluir interacciones).
- ☐ T-learner no sufre por desbalance extremo entre grupos.
- ☐ X-learner utilizado cuando hay desbalance entre tratados y controles.
- ☐ R-learner implementado con *cross-fitting* y *score* ortogonal.
- ☐ Modelos *nuisance* evaluados fuera de muestra.
- ☐ Meta-learner elegido según los supuestos del problema.
- ☐ Intervalos de confianza construidos por *bootstrap* o *influence function*.

F.3 Checklist causal forest

- ☐ *Honesty* garantizada en la construcción de los árboles.
- ☐ Número de árboles suficiente para estabilidad del CATE.
- ☐ Criterio de *splitting* basado en heterogeneidad de efectos.
- ☐ *Propensity scores* estimados y calibrados.
- ☐ Supuesto de *overlap* verificado.
- ☐ BLP/BEST/CLAN ejecutados con `econml.validate.DRtester` β_2 reportado con p-valor.

☐ Inferencia válida para ATE y CATE.

F.4 Checklist PDS

☐ Supuesto de *sparsity* plausible en el contexto aplicado.
☐ Doble selección correctamente implementada (*outcome* y tratamiento).
☐ Parámetro λ seleccionado por validación cruzada.
☐ Inferencia post-selección válida (errores estándar no distorsionados).
☐ Número de regresores menor que el tamaño muestral.
☐ Errores estándar robustos a heterocedasticidad reportados.

F.5 Checklist panel/DMLIV

☐ Efectos fijos absorbentes de *shocks* comunes no observados.
☐ Errores estándar clusterizados a nivel de unidad *panel*.
☐ Instrumento válido (exogeneidad y exclusión justificadas).
☐ Instrumento relevante (F-statistic > 10 en primera etapa).
☐ *Cross-fitting* correcto para DMLIV.
☐ Test de sobreidentificación reportado si aplica.
☐ Inferencia robusta a instrumentos débiles si el F es bajo.

F.6 Checklist policy learning

☐ Criterio de bienestar (*policy value*) formalmente definido.
☐ Restricción de presupuesto especificada.
☐ Restricciones de equidad consideradas en la optimización.
☐ Política aprendida interpretable y comunicable.
☐ *Welfare regret* acotado.
☐ Política evaluada fuera de muestra.
☐ IC del *policy value* vía *influence function* (Sección 21.2.2); test de diferencia al comparar dos políticas.

F.7 Checklist uplift

☐ Curva Qini reportada y visualizada.
☐ Costos de intervención explícitamente definidos.
☐ *Ranking* de unidades estable en submuestras.
☐ Tratamiento y control balanceados en cada *fold*.
☐ AUUC reportado como métrica de *ranking*.
☐ Comparación con asignación aleatoria como *baseline*.

F.8 Checklist SCM/matrix completion

- ☐ Tendencia pre-tratamiento paralela verificada visualmente.
- ☐ *Pool* de *donors* adecuado y justificado.
- ☐ Rango de la matriz seleccionado por validación cruzada.
- ☐ *Placebo tests* en unidades *donors* reportados.
- ☐ Ajuste pre-tratamiento evaluado (RMSE).
- ☐ Sensibilidad a la composición del *donor pool* analizada.

F.9 Checklist causal discovery

- ☐ Supuestos del DAG explícitamente declarados.
- ☐ Supuesto de *faithfulness* razonable en el contexto.
- ☐ Estabilidad del grafo evaluada con submuestras.
- ☐ Confianza en aristas estimada por *bootstrap*.
- ☐ SHD reportado comparado con grafo *benchmark*.
- ☐ Orientación de aristas validada con conocimiento experto.
- ☐ Se reporta la CPDAG / clase de equivalencia, no un DAG único.
- ☐ Si no se sostiene la suficiencia causal, se usa FCI (PAG) en lugar de PC.
- ☐ Se reporta la familia de grafos obtenida al variar α (PC) o λ (NOTEARS).
- ☐ Ninguna arista descubierta fija por sí sola el conjunto de ajuste del DML.
- ☐ Con métodos de optimización continua, se comparan las estimaciones con y sin estandarización de variables.

APÉNDICE G

Plantilla de *model card* causal

Este apéndice desarrolla en detalle la plantilla de *model card* causal introducida en el Capítulo 19, con la explicación de cada campo y un ejemplo completo. Se usa para todo modelo causal registrado en el repositorio local a lo largo del curso, incluido el proyecto final.

G.1 Campos obligatorios y su propósito

Campo	Qué debe responder
Estimando	¿Qué cantidad exacta se estima? (ATE, CATE(x), LATE, política óptima). No basta con nombrar la variable de resultado.
Diseño de identificación	¿Experimental, cuasi-experimental (panel, IV, RDD) u observacional puro? Determina qué tan defendible es el resultado sin supuestos adicionales.
Supuestos declarados	Lista explícita, con la clase de cada supuesto. Los **observables** (soporte común, balance, fuerza del instrumento, estabilidad del efecto) llevan un umbral calibrado y su última verificación. Los **no observables** (no confusión condicional, exclusión del instrumento, tendencias paralelas posteriores al tratamiento) llevan su sensibilidad y su plazo de revisión (Capítulo 33), y ninguno se declara «verificado». Referencia al DAG cuando exista uno (Capítulo 8).
Población de entrenamiento	Las variables que delimitan la población (edad, geografía, período temporal, criterio de elegibilidad), que son la información mínima para aplicar el criterio de transportabilidad del Capítulo 26 antes de reusar el modelo, y la regla de soporte que el servicio hace cumplir (en la versión de referencia, el rango de cada covariable observado al entrenar, calculado de los datos y no escrito a mano).

Campo	Qué debe responder
Roles causales	¿Qué columna es el tratamiento, cuál el resultado, cuáles las covariables y los instrumentos? Es el `CausalSchema` (Capítulo 4) guardado como datos.
Métricas	Efecto puntual, intervalo de confianza, tamaño de muestra, especificación del estimador (*learner*, número de *folds*); declarar si se reporta intervalo poblacional, individual (conforme), o ambos
Resultados de validación	Resultado de la prueba placebo (Capítulo 14) y del chequeo de balance (Capítulo 7) más recientes.
No usar este modelo para	Lista explícita de usos indebidos previsibles: poblaciones fuera de rango, decisiones individuales sin considerar el intervalo, reinterpretación del ATE como efecto garantizado.
Historial de versiones	Fecha de cada reentrenamiento, resultado del proceso *champion-challenger* (Capítulo 31) que lo promovió.

G.2 Plantilla completa

```
---
license: mit
tags: [causal-inference, <metodo-usado>]
---

# <Nombre del modelo>

## Estimando
<Que cantidad causal exacta estima este modelo.>

## Diseno de identificacion
<Experimental / cuasi-experimental / observacional. Justificacion breve.>

## Supuestos declarados
### Observables (con umbral y ultima verificacion)
- Soporte comun: <metrica> <operador> <umbral>. Ultima verificacion
  <fecha>: <valor> (<paso / no paso>).
- <Balance, fuerza del instrumento, estabilidad del efecto, segun el diseno>
### No observables (con sensibilidad y plazo de revision)
- No confusion condicional en: <lista de covariables>.
  Sensibilidad: <metodo>. Valor critico de la decision: <valor>.
  Escala de referencia: <covariable observada, rango del efecto>.
  Calculada el <fecha>; revisar antes del <fecha>.
- <Otros supuestos del diseno: exclusion del instrumento,
  tendencias paralelas posteriores al tratamiento>
```

```
- DAG (si existe): <enlace o referencia>

## Poblacion de entrenamiento
<Variables que delimitan la poblacion. Rango temporal. Fuente de datos.>
**No valido fuera de esta poblacion sin verificar transportabilidad.**

## Metricas
- Efecto estimado: <valor> (IC 95%: [<inf>, <sup>])
- n = <tamano de muestra>
- Especificacion: <learner, K-folds, etc.>

## Resultados de validacion
- Prueba placebo: <paso / no paso, fecha>
- Chequeo de balance: <resultado, fecha>

## No usar este modelo para
- <Uso indebido 1>
- <Uso indebido 2>

## Historial de versiones
| Version | Fecha | Cambio | Promovido por |
|---------|-------|--------|----------------|
| 1.0     | <fecha> | Version inicial | n/a |
```

Listado G.1: Plantilla completa de *model card* causal, para copiar y guardar junto al artefacto local.

G.3 Checklist antes de registrar

- ☐ Todos los campos obligatorios de la Sección G.1 están completos, ninguno dice «N/A» sin justificación.
- ☐ La sección «No usar este modelo para» incluye al menos un uso indebido específico del dominio del modelo, no solo genérico.
- ☐ El `CausalSchema` (Capítulo 4) del modelo se registró junto con el artefacto serializado.
- ☐ La *model card* se actualizó en el mismo registro local que cualquier reentrenamiento (ninguna versión del modelo circula con una *model card* desactualizada).

G.4 Esquema legible por máquinas

La *model card* Markdown es para personas. Para máquinas existe el mismo contrato en forma de una ficha JSON que viaja junto al artefacto y que la operación *metadatos* del servicio devuelve tal cual (Sección 15.4). Para que sea verificable en el CI local del Capítulo 20 se fija un esquema JSON versionado. Sus campos son los de la tabla de la Sección G.1, con dos diferencias deliberadas: el historial de versiones completo vive en el Markdown y el JSON lleva solo la versión vigente, y se añaden los roles causales para que el servicio no dependa de ningún

objeto serializado. Esta es la versión 2 del esquema; la anterior solo pedía el nombre de cada supuesto.

```
{
  "$schema": "https://json-schema.org/draft/2020-12/schema",
  "title": "causal-model-card-v2",
  "type": "object",
  "required": ["schema_version", "estimando", "diseno_identificacion",
"supuestos",
               "roles", "poblacion", "metricas", "validacion", "no_usar_para",
"version"],
  "properties": {
    "schema_version": {"const": "causal-model-card-v2"},
    "estimando": {
      "type": "object", "required": ["tipo", "formula"],
      "properties": {"tipo": {"enum": ["ATE", "ATT", "CATE", "LATE",
"policy_value"]},
                     "formula": {"type": "string"}}},
    "diseno_identificacion": {
      "type": "object", "required": ["tipo", "metodo"],
      "properties": {"tipo": {"enum": ["RCT", "cuasi", "observacional"]},
                     "metodo": {"type": "string"}}},
    "supuestos": {
      "type": "array", "minItems": 1,
      "items": {
        "type": "object", "required": ["nombre", "clase"],
        "properties": {
          "nombre": {"type": "string"},
          "clase": {"enum": ["observable", "no_observable"]},
          "covariables": {"type": "array", "items": {"type": "string"}},
          "umbral": {
            "type": "object", "required": ["metrica", "operador", "valor",
"calibracion"],
            "properties": {
              "metrica": {"type": "string"},
              "operador": {"enum": ["<", "<=", ">", ">="]},
              "valor": {"type": "number"},
              "calibracion": {
                "type": "object", "required": ["tasa_falsas_alarmas", "fecha"],
                "properties": {"tasa_falsas_alarmas": {"type": "number",
"exclusiveMinimum": 0, "maximum": 1},
                               "fecha": {"type": "string", "format":
"date"}}}}},
          "ultima_verificacion": {
            "type": "object", "required": ["fecha", "valor", "paso"],
            "properties": {"fecha": {"type": "string", "format": "date"},
                           "valor": {"type": "number"},
                           "paso": {"type": "boolean"}}},
```

```
          "sensibilidad": {
            "type": "object",
            "required": ["metodo", "parametro", "umbral_decision",
"valor_critico", "fecha",
                         "revisar_antes_de"],
            "properties": {"metodo": {"type": "string"},
                           "parametro": {"type": "string"},
                           "umbral_decision": {"type": "number"},
                           "valor_critico": {"type": "number"},
                           "escala": {"type": "object"},
                           "decision_fragil": {"type": "boolean"},
                           "fecha": {"type": "string", "format": "date"},
                           "revisar_antes_de": {"type": "string", "format":
"date"}}}},
        "allOf": [
          {"if": {"properties": {"clase": {"const": "observable"}}},
           "then": {"required": ["umbral", "ultima_verificacion"]}},
          {"if": {"properties": {"clase": {"const": "no_observable"}}},
           "then": {"required": ["sensibilidad"]}}]}},
    "roles": {
      "type": "object", "required": ["tratamiento", "resultado",
"covariables"],
      "properties": {"tratamiento": {"type": "string"},
                     "resultado": {"type": "string"},
                     "covariables": {"type": "array", "minItems": 1, "items":
{"type": "string"}},
                     "instrumentos": {"type": "array", "items": {"type":
"string"}}}},
    "poblacion": {
      "type": "object", "required": ["descripcion", "soporte"],
      "properties": {
        "descripcion": {"type": "string"},
        "fuente": {"type": "string"},
        "soporte": {
          "type": "object", "required": ["regla", "rangos"],
          "properties": {
            "regla": {"enum": ["rango_por_covariable"]},
            "rangos": {"type": "object",
                       "additionalProperties": {"type": "array", "items":
{"type": "number"},
                                                "minItems": 2, "maxItems":
2}}}}}},
    "metricas": {
      "type": "object", "required": ["efecto", "ic95", "n"],
      "properties": {"efecto": {"type": "number"},
                     "ic95": {"type": "array", "items": {"type": "number"},
"minItems": 2, "maxItems": 2},
```

```
                    "n": {"type": "integer", "minimum": 1},
                    "spec": {"type": "object"}}},
    "validacion": {"type": "object"},
    "no_usar_para": {"type": "array", "minItems": 1, "items": {"type":
"string"}},
    "version": {
      "type": "object", "required": ["modelo", "hash_datos_entrenamiento"],
      "properties": {"modelo": {"type": "string"},
                     "hash_datos_entrenamiento": {"type": "string", "pattern":
"^sha256:[0-9a-f]{64}$"}}}
  }
}
```

Listado G.2: Esquema JSON versionado de la *model card* causal (`causal-model-card-v2`).

El esquema distingue dos clases de supuestos, y esa distinción es lo que cambió. Un supuesto **observable** trae su umbral (con la tasa de falsas alarmas y la fecha con que se calibró) y su última verificación antes del registro. Un supuesto **no observable** trae su sensibilidad: el método, el umbral de la decisión, el valor crítico, la fecha de cálculo y la fecha antes de la cual debe revisarse. Los no observables no tienen campo de verificación, porque ningún dato los verifica y un campo así invitaría a llenarlo. La ficha guarda solo la verificación vigente al registrar. Las posteriores viven en el reporte del monitoreo (Capítulo 30), que cita la versión de la ficha.

Y una ficha que lo cumple. Los valores numéricos son ilustrativos: no provienen de una corrida.

```
{
  "schema_version": "causal-model-card-v2",
  "estimando": {"tipo": "ATE", "formula": "E[Y(1) - Y(0)]"},
  "diseno_identificacion": {"tipo": "observacional", "metodo": "DML con cross-
fitting"},
  "supuestos": [
    {"nombre": "soporte_comun", "clase": "observable",
     "umbral": {"metrica": "ess_sobre_n", "operador": ">=", "valor": 0.6,
                "calibracion": {"tasa_falsas_alarmas": 0.05, "fecha":
"2026-01-10"}},
     "ultima_verificacion": {"fecha": "2026-01-15", "valor": 0.82, "paso":
true}},
    {"nombre": "no_confusion", "clase": "no_observable",
     "covariables": ["age", "black", "south", "married"],
     "sensibilidad": {"metodo": "robustez_r2",
                      "parametro": "valor de robustez respecto del umbral de
decision",
                      "umbral_decision": 0.05, "valor_critico": 0.13,
                      "escala": {"r2_d": 0.22, "r2_y": 0.07, "rango_efecto":
[0.045, 0.097]},
```

```
                    "decision_fragil": true,
                    "fecha": "2026-01-15", "revisar_antes_de": "2026-04-15"}}
  ],
  "roles": {"tratamiento": "educ", "resultado": "lwage",
            "covariables": ["age", "black", "south", "married"],
"instrumentos": []},
  "poblacion": {
    "descripcion": "Hombres de 24 a 34 anos, EE. UU., 1976",
    "fuente": "Card (1995)",
    "soporte": {"regla": "rango_por_covariable",
                "rangos": {"age": [24, 34], "black": [0, 1], "south": [0, 1],
"married": [0, 1]}}
  },
  "metricas": {"efecto": 0.071, "ic95": [0.058, 0.084], "n": 3003,
               "spec": {"learner": "GBM", "K": 5, "dml_variant": "DML2"}},
  "validacion": {"placebo": {"paso": true, "fecha": "2026-01-15"}},
  "no_usar_para": ["Poblaciones fuera del rango de entrenamiento",
                   "Decisiones individuales sin considerar el intervalo"],
  "version": {"modelo": "1.2",
              "hash_datos_entrenamiento":
"sha256:9f86d081884c7d659a2feaa0c55ad015a3bf4f1b2b0b822cd15d6c15b0f00a08"}
}
```

Listado G.3: Ejemplo de ficha JSON válida contra el esquema anterior (valores ilustrativos).

El CI de referencia valida tres cosas: (i) que la ficha cumple el esquema sintáctico; (ii) que el veredicto `paso` de cada supuesto observable coincide con su valor y su umbral, y que ninguno falló; y (iii) que la huella de los datos coincida con la del conjunto de referencia versionado (Capítulo 20). Las dos últimas no las expresa un esquema, por lo que las comprueba código del CI. El campo `dml_variant` exige nombrar DML1 o DML2 (Nota técnica 10.2.4), lo que cierra el círculo entre la teoría y lo que el artefacto declara.

APÉNDICE H

Checklist de arquitectura de despliegue

Este apéndice sintetiza, en formato de decisión rápida, las opciones de arquitectura discutidas a lo largo de la segunda mitad del libro (Capítulos 2, 15, 19, 20, 30 y 31), para usarse como referencia al diseñar el componente de producción de un sistema causal nuevo.

H.1 Elegir el patrón de *serving*

Si...	**Entonces considere...**
Las unidades a evaluar no se conocen de antemano y llegan una a la vez	Servicio REST síncrono (Capítulo 15)
La población completa a evaluar es fija y conocida con anticipación	*Batch* precomputado
Todos los consumidores comparten el mismo entorno de Python y necesitan latencia mínima	Biblioteca embebida
Se necesita servir a consumidores externos al equipo, en cualquier lenguaje	Servicio REST local con documentación de model card (Capítulo 19)

H.2 Checklist de la función de inferencia

- ☐ La función de inferencia es pura (sin estado mutable, sin efectos secundarios).
- ☐ El cálculo de *features* usa exactamente el mismo código en entrenamiento y en producción.
- ☐ La función usa el `CausalSchema` (Capítulo 4) para validar las covariables de entrada, no nombres de columna hardcodeados.
- ☐ La respuesta incluye intervalo de confianza y población de entrenamiento, no solo el efecto puntual (Capítulo 2).

H.3 Checklist de CI/CD

- ☐ El pipeline corre pruebas de software en cada *push* y pruebas estadísticas (placebo, balance) antes de publicar (Capítulo 20).
- ☐ Existe un dataset de referencia fijo y versionado para las pruebas estadísticas.
- ☐ El registro local del bundle está condicionado al resultado de ambos tipos de prueba, no solo de las de software.
- ☐ Ningún reentrenamiento se promueve a producción sin pasar por el proceso *champion--challenger* (Capítulo 31).

H.4 Checklist de monitoreo en producción

- ☐ Se monitorea el *drift* de covariables individuales, no solo de las predicciones agregadas (Capítulo 30).
- ☐ Cuando el diseño usa un instrumento, se monitorea su fuerza en ventanas recientes.
- ☐ Se monitorea la estabilidad del efecto reestimado en ventanas móviles mediante un test formal contra la estimación de referencia, no por inclusión en el intervalo de confianza original (Capítulo 30).
- ☐ Se monitorea la relación covariables→tratamiento (mecanismo de asignación), no solo las marginales.
- ☐ Existe un proceso definido y documentado de qué hacer cuando el monitoreo dispara una alerta, no solo la alerta misma.

H.5 Checklist de comunicación

- ☐ Todo resultado comunicado fuera del equipo técnico sigue la plantilla de tres capas del Capítulo 32.
- ☐ La población de validez del resultado es explícita en la primera o segunda capa de la comunicación, no solo en el detalle técnico.
- ☐ El lenguaje usado («causa» vs. «está asociado con») es consistente con el nivel de identificación efectivamente alcanzado.

APÉNDICE I

Contratos numerados del libro

Este libro describe cada pieza de ingeniería como un contrato numerado y no como un programa. Un contrato dice qué hace la pieza, qué debe cumplirse siempre y cómo se comprueba, sin decir con qué herramienta se construye. Esa separación es deliberada: las ideas del libro duran más que las librerías, y el material complementario que implementa los contratos puede cambiar sin que cambie el libro. Este apéndice reúne en un solo lugar los ocho contratos, cómo se relacionan, qué prueba de aceptación tiene cada uno y cómo declara un equipo cuáles cumple.

I.1 Cómo se lee un contrato

Todos los contratos usan la misma caja, con los mismos seis campos.

- **Operaciones.** Lo que la pieza ofrece a quien la usa. Un contrato que describe un documento, como la ficha del modelo (C-05), no tiene operaciones y empieza por lo que recibe.
- **Entrada y salida.** Lo que recibe y lo que devuelve, con el nivel de detalle que necesita quien implementa, no el que necesita quien programa.
- **Invariantes.** Lo que debe cumplirse siempre, para cualquier entrada. Cada invariante se puede comprobar: si no hay forma de probarlo, no es un invariante sino un deseo.
- **Modos de fallo.** Cómo falla la pieza y qué hace entonces. Incluye los fallos que el contrato existe para impedir y los que el contrato reconoce no poder ver.
- **Prueba de aceptación.** El procedimiento que decide si una implementación cumple el contrato, sobre datos con verdad conocida cuando el contrato habla de efectos.

La diferencia entre invariante y prueba importa. El invariante dice qué es verdad. La prueba es la evidencia de que lo es en una implementación concreta, y puede cubrir solo una parte de los invariantes. Por eso la declaración de conformidad de más abajo pide decir qué invariantes quedaron sin cubrir.

I.2 Los ocho contratos de un vistazo

Id	Contrato	Cap.	Qué garantiza	Depende de
C-01	Esquema de roles causales	4	Cada columna tiene un solo rol declarado, y el esquema viaja con los datos.	Ninguno
C-02	Comparación de poblaciones	7	Dos poblaciones se comparan con una medida de tamaño de efecto y un umbral calibrado, no con un p-valor.	C-01
C-03	Auditoría de *features*	9	Ninguna covariable entra sin un rol declarado ni sin verificarse como anterior al tratamiento.	C-01
C-04	Servicio de estimación	15	Cada consulta recibe un efecto con su intervalo, o una abstención sin ningún número.	C-01, C-05
C-05	Ficha causal del modelo	19	El modelo viaja con sus supuestos clasificados (los observables con su umbral, los no observables con su sensibilidad), su población de soporte y la huella de sus datos.	C-01, C-03 y los resultados de C-02
C-06	Compuerta de registro	20	Ningún candidato llega al registro sin una decisión de la compuerta.	C-05
C-07	Monitoreo causal	30	Cada cambio del mundo enciende la señal que le corresponde, y el reporte termina en una sola acción.	C-01, C-02, C-05
C-08	Sensibilidad de los supuestos no observables	33	Ningún supuesto que ningún dato verifica figura como verificado: lleva su margen frente a la decisión y su fecha de revisión.	C-05, C-07

El Capítulo 31 no define un contrato propio. Su regla de promoción usa la comparación de poblaciones (C-02) y la compuerta de registro (C-06), y devuelve una de las cinco acciones del Capítulo 2.

I.3 Una prueba de aceptación por contrato

Cada contrato se comprueba con un caso de verdad conocida, un proceso generador estilizado cuyo efecto se conoce y cuya descripción cabe en un párrafo. La tabla resume qué caso usa cada uno y qué debe ocurrir.

Id	Caso con verdad conocida	Qué debe ocurrir
C-01	Dos análisis sobre la misma tabla, con una experiencia potencial calculada con el tratamiento (Capítulo 4).	Cada fallo estructural se rechaza con un mensaje que nombra la columna, y el esquema escrito y vuelto a leer es igual. La covariable posterior al tratamiento pasa, y la prueba deja a la vista que el contrato no la detecta.
C-02	Cuarenta covariables y dos mecanismos de asignación (Capítulo 7).	Con la moneda justa, los rechazos crudos rondan el 5 % de las covariables y los de Holm casi no aparecen. Con asignación que depende de una covariable, solo se activa la bandera de esa covariable.
C-03	Cuatro tipos de *feature* y una verdad conocida (Capítulo 9).	La auditoría deja la especificación base con el confusor y la ampliada con el confusor y la de rol desconocido, y las seis estimaciones de la tabla del caso se reproducen.
C-04	Datos con efecto conocido (Capítulo 15).	La cobertura del intervalo no baja del piso calibrado, una consulta fuera de la población recibe una abstención sin número y dos llamadas idénticas devuelven lo mismo.
C-05	Una ficha de ejemplo y los datos de referencia con su huella (Apéndice G).	La ficha valida contra el esquema versionado, la huella coincide con la de los datos de referencia y el servicio se abstiene fuera del soporte que la ficha declara. Una ficha con un observable sin umbral o con un veredicto que no sale de su valor, y una con un no observable sin sensibilidad, se rechazan.
C-06	Fallos de causa conocida inyectados en un candidato (Capítulo 20).	El candidato sano se registra. Quitar un control clave, subestimar el error estándar o cambiar la huella de los datos bloquea, y lo bloquea la prueba que corresponde. Registrar sin una decisión es imposible.
C-07	Un generador con cuatro cambios posibles (Capítulo 30).	Cada cambio inyectado enciende la señal que le corresponde y no las demás, y sin cambio la tasa de alarmas no supera la declarada en la calibración.
C-08	Un generador con un confusor oculto de intensidad conocida y un control negativo (Capítulo 33).	La cota coincide con el sesgo real, el valor crítico coincide con su forma cerrada, el control que comparte el confusor se enciende y el que no lo comparte no supera la tasa nominal, y cada disparador produce su motivo de revisión.

I.4 Declaración de conformidad

Una implementación del material complementario declara qué contratos cumple con una tabla como la siguiente, que se publica junto con el código.

Contrato	Versión	Implementación	Prueba de aceptación ejecutada	Invariantes sin cubrir
C-01	1	Nombre y versión de la pieza que lo cumple	Fecha y resultado de la prueba	Lista, o ninguno

Cuatro reglas hacen que la tabla sirva para algo.

1. Se declara un contrato solo si su prueba de aceptación se ejecutó y pasó. Un contrato sin prueba ejecutada no se declara como cumplido, se declara como pendiente.
2. Los invariantes que la prueba no cubre se listan. Es información que el lector necesita para saber hasta dónde puede confiar en la pieza.
3. Una implementación puede cumplir un contrato sin parecerse a la descripción del libro: un servicio web, una biblioteca o una tarea programada que llena una tabla cumplen igual el C-04 si pasan su prueba.
4. La declaración nombra la versión del conjunto de contratos contra la que se probó. Este libro describe la versión 1.

I.5 Cuándo cambia un contrato

Un contrato cambia cuando una edición del libro debilita o endurece un invariante, agrega un modo de fallo que antes no se reconocía o cambia lo que la pieza recibe o devuelve. Cualquiera de esos cambios exige una nueva versión del conjunto de contratos, porque una implementación que pasaba la prueba anterior puede dejar de pasar la nueva. Una aclaración de redacción que no cambia el comportamiento no la exige. La edición declara su versión de contratos en esta sección y el material complementario declara la suya en su tabla de conformidad, de modo que quien lee ambos sabe si coinciden.

I.6 Un orden razonable para adoptarlos

Un equipo que empieza de cero no necesita los ocho a la vez. El orden que sigue es una propuesta y se apoya en las dependencias de la tabla inicial.

1. C-01, porque todos los demás consumen el esquema de roles y es la pieza más barata.
2. C-03, porque la lista de covariables que produce es lo que el esquema y la ficha registran, y porque un error aquí contamina todo lo posterior.
3. C-05 y C-04, juntos, porque un servicio sin ficha responde con un artefacto que nadie puede describir, y una ficha sin servicio no cambia ninguna decisión.
4. C-06, cuando haya más de una versión del modelo y alguien deba decidir cuál sirve.

5. C-02 y C-07, cuando el sistema ya esté en producción y haya que saber si el mundo cambió. El C-02 también se usa antes, al auditar los datos de entrenamiento, y ahí no espera a la producción.
6. C-08, junto con el C-07, cuando el sistema ya sirva decisiones y la ficha declare supuestos no observables, que es casi siempre.

I.7 Checklist de conformidad

- ☐ Cada contrato que el equipo dice cumplir tiene su prueba de aceptación ejecutada, con fecha y resultado.
- ☐ La declaración lista los invariantes que la prueba no cubre.
- ☐ La versión del conjunto de contratos de la declaración coincide con la de la edición del libro que se usa.
- ☐ Los casos de verdad conocida de las pruebas están versionados junto al código, con su semilla.
- ☐ Un cambio en una pieza vuelve a ejecutar la prueba de los contratos que declara, no solo la de los tests de la propia pieza.
- ☐ Ningún contrato se declara cumplido porque la pieza «hace lo que dice el libro» sin que nadie haya corrido la prueba.

APÉNDICE J

Guía para instructores y equipos de curso

Este apéndice reúne el material de coordinación docente y **no se imprime en la edición comercial del libro**. Quien imparte el curso, o coordina un equipo que lo adopta como capacitación interna, encuentra aquí el mapa entre sesiones, capítulos, laboratorios y entregas, el nivel de madurez declarado del material y la organización práctica del trabajo del estudiante. El contenido metodológico del libro no depende de este apéndice: un lector que estudie por su cuenta puede ignorarlo por completo.

J.1 Mapa sesión → capítulo → lab → entrega (resumen)

La tabla completa está en el sílabo. Resumen del hilo de producto:

Sesiones	Caps. monografía	Lab	Entrega	Valor de negocio
S1–S3	1–3	L01–L03	ninguna	Asociación vs efecto; PCH
S4–S6	4, 6–7	L04–L06	**A1**	¿Es estimable el programa?
S7–S11	8–11, 14	L07–L11	**A2**	ATE con IC; sin leakage
S12–S14	12–13, 15	L12–L14	**B1** + A3	API del efecto; CATE
S15–S16	repaso	L15	**A3** · parcial	Sistema causal integrado
S17–S18	19–20	L17–L18	**B2**	Model card local + CI local
S19–S24	21–26	L19–L24	**A4** · **B3**	Policy + dashboard local
S25–S28	29–32	L25–L28	**B4**	Monitoreo y comunicación
S29–S32	Ap. E/G/H	P1–P4	**Proyecto**	Tu caso en producción local

El Cap. 33 no tiene sesión ni laboratorio propio. Se asigna como lectura de cierre antes del proyecto final (S29), y su ejercicio se resuelve dentro del apartado de sensibilidad del proyecto.

El cierre del curso corresponde al proyecto final del Apéndice E, que evalúa el sistema completo (identificación, estimación, despliegue, documentación y monitoreo) y no una métrica de predicción aislada.

J.2 Nivel de madurez del material (NMM)

Los materiales de este curso (monografía, Series A/B, laboratorios y diapositivas) se declaran en **NMM 6: validado en entorno controlado**. Esto significa: los notebooks corren de punta a punta sobre los datasets de `data_benchmark_causal/`, los autograders (`grade_a1.py`… `grade_b4.py`) pasan de forma reproducible, la suite `scripts/audit_repo.sh` verifica la integridad cruzada del monorepo, y el contenido teórico fue auditado contra sus fuentes primarias, con correcciones registradas en `CHANGELOG_MEJORA.md`. Lo que aún falta para **NMM 7, validado con usuarios reales**: una cohorte completa de estudiantes que ejercite el material de punta a punta, cuyo **feedback** (encuestas de cierre, incidencias en labs, brechas entre lo que el material asume y lo que hace falta en el aula) retroalimente la próxima edición.

J.3 Práctica del curso: laboratorios, series de notebooks y proyecto

El trabajo práctico se organiza en el monorepo del curso (no en un repositorio externo opcional):

- **Labs L01–L28** (`05_labs_sesion/`): práctica formativa por sesión (30–50 min).
- **Serie A** (`03_notebooks_caso_estudio/`): A1 identificación (Jobs) · A2 DML · A3 CATE · A4 policy.
- **Serie B** (`04_notebooks_produccion_streamlit/`): B1 FastAPI · B2 model card/CI local · B3 dashboard local · B4 dashboard de drift.
- **Datos** (`data_benchmark_causal/…/datasets/`): CSV + `metadata.json` (benchmark documentado; ver callouts «monorepo» en los capítulos de ingeniería).
- **Proyecto** (`06_proyecto_final/`): sistema causal local con comparación **predictivo vs causal**.

La **Serie A** aplica la teoría a un caso con pregunta de identificación. La **Serie B** toma el artefacto de A y lo despliega localmente con FastAPI, Docker y Streamlit. El sílabo (`01_silabo/silabo.pdf`) fija la correspondencia exacta sesión ↔ Cap. N del PDF ↔ lab ↔ entrega.

Los callouts de implementación (**«Implementación en el monorepo del curso»**) aparecen en los capítulos de ingeniería (4, 9, 15, 19, 20 y 30) y conectan cada decisión de diseño con el archivo concreto del monorepo que la implementa. En la edición comercial del libro esos callouts se sustituyen por una nota genérica que remite al repositorio complementario.

J.4 Nota sobre las dos ediciones

Esta guía y el Apéndice E existen únicamente en la edición de curso. La edición comercial conserva los capítulos 1 a 33 y los apéndices técnicos (A a D y F a I), y omite el aparato docente: el mapa sesión ↔ capítulo ↔ lab, el nivel de madurez del material, la plantilla de proyecto con su rúbrica y esta misma guía. La edición de principios conserva además las mismas capas de teoría, pseudocódigo y casos canónicos, pero omite la capa de implementación y el Apéndice B. El contenido técnico de las capas comunes (teoría, algoritmos, casos canónicos, tablas de riesgos y ejercicios no computacionales) es idéntico en las tres ediciones; solo cambia el envoltorio editorial y, en la de principios, la ausencia de la capa de implementación.

Bibliografía

Abadie, Alberto, Alexis Diamond, y Jens Hainmueller. 2010. «Synthetic Control Methods for Comparative Case Studies: Estimating the Effect of California's Tobacco Control Program». *Journal of the American Statistical Association* 105 (490): 493-505.

Abadie, Alberto, Alexis Diamond, y Jens Hainmueller. 2015. «Comparative Politics and the Synthetic Control Method». *American Journal of Political Science* 59 (2): 495-510.

Abadie, Alberto, y Javier Gardeazabal. 2003. «The Economic Costs of Conflict: A Case Study of the Basque Country». *American Economic Review* 93 (1): 113-32.

Andrews, Isaiah, James H. Stock, y Liyang Sun. 2019. «Robust Methods in Nonparametric Conditional Moment Testing: The Case of Instrumental Variables». *Econometrica* 87 (4): 1153-81.

Angrist, Joshua D., y Alan B. Krueger. 1991. «Does Compulsory School Attendance Affect Schooling and Earnings?». *Quarterly Journal of Economics* 106 (4): 979-1014.

Arkhangelsky, Dmitry, Susan Athey, David A. Hirshberg, Guido W. Imbens, y Stefan Wager. 2021. «Synthetic Difference in Differences». *American Economic Review* 111 (12): 4088-118.

Arnold, Matthew, Rachel K. E. Bellamy, Michael Hind, et al. 2019. «FactSheets: Increasing Trust in AI Services through Supplier's Declarations of Conformity». *IBM Journal of Research and Development* 63 (4/5).

Aronow, Peter M., y Benjamin T. Miller. 2017. *Foundations of Agnostic Statistics*. Cambridge University Press.

Athey, Susan. 2017. «Beyond Prediction: Using Big Data for Policy Problems». *Science* 355 (6324): 483-85.

Athey, Susan, Mohsen Bayati, Nikolay Doudchenko, Guido Imbens, y Khashayar Khosravi. 2021. «Matrix Completion Methods for Causal Panel Data Models». *Journal of the American Statistical Association* 116 (536): 1716-30.

Athey, Susan, Julie Tibshirani, y Stefan Wager. 2019. «Generalized Random Forests». *Annals of Statistics* 47 (2): 1148-78.

Athey, Susan, y Guido Imbens. 2016. «Recursive Partitioning for Heterogeneous Causal Effects». *Proceedings of the National Academy of Sciences* 113 (27): 7353-60.

Athey, Susan, y Guido W. Imbens. 2019. «Machine Learning Methods That Economists Should Know About». *Annual Review of Economics* 11 : 685-725.

Athey, Susan, y Stefan Wager. 2019. «Estimating Treatment Effects with Causal Forests: An Application». *Observational Studies*,.

Athey, Susan, y Stefan Wager. 2021. «Policy Learning With Observational Data». *Econometrica* 89 (1): 133-61.

Bach, Philipp, Victor Chernozhukov, Malte S. Kurz, y Martin Spindler. 2022. «DoubleML– An Object-Oriented Implementation of Double Machine Learning in Python». *Journal of Machine Learning Research* 23 (53): 1-6.

Bareinboim, Elias. 2025. *Causal Artificial Intelligence: A Roadmap for Building Causally Intelligent Systems*. Columbia CausalAI Lab.

Bareinboim, Elias, Juan D. Correa, Duligur Ibeling, y Thomas Icard. 2022. «On Pearl's Hierarchy and the Foundations of Causal Inference». En *Probabilistic and Causal Inference: The Works of Judea Pearl*, editado por Geffner, Hector, Dechter, Rina, Halpern, y Joseph Y. ACM Books.

Bareinboim, Elias, Andrew Forney, y Judea Pearl. 2015. «Bandits with Unobserved Confounders: A Causal Approach». *Advances in Neural Information Processing Systems 28 (NeurIPS)*,.

Bareinboim, Elias, Jin Tian, y Judea Pearl. 2014. «Recovering from Selection Bias in Causal and Statistical Inference». *Proceedings of the 28th AAAI Conference on Artificial Intelligence*,.

Bareinboim, Elias, y Judea Pearl. 2013. «A General Algorithm for Deciding Transportability of Experimental Results». *Journal of Causal Inference* 1 (1): 107-34.

Barocas, Solon, Moritz Hardt, y Arvind Narayanan. 2019. *Fairness and Machine Learning*. Fairmlbook.org.

Battocchi, Keith, Eleanor Dillon, Maggie Hei, et al. 2019. «EconML: A Python Package for ML-Based Heterogeneous Treatment Effects Estimation». *GitHub repository, Microsoft Research*,.

Belloni, Alexandre, Daniel Chen, Victor Chernozhukov, y Christian Hansen. 2012. «Sparse Models and Methods for Optimal Instruments With an Application to Eminent Domain». *Econometrica* 80 (6): 2369-429.

Belloni, Alexandre, Victor Chernozhukov, y Christian Hansen. 2014. «Inference on Treatment Effects After Selection Among High-Dimensional Controls». *Review of Economic Studies* 81 (2): 608-50.

Ben-Michael, Eli, Avi Feller, y Jesse Rothstein. 2021. «The Augmented Synthetic Control Method». *Journal of the American Statistical Association* 116 (536): 1789-803.

Berger, James O. 1985. *Statistical Decision Theory and Bayesian Analysis*. 2.ª ed. Springer.

Bickel, Peter J., Chris A. J. Klaassen, Ya'acov Ritov, y Jon A. Wellner. 1993. *Efficient and Adaptive Estimation for Semiparametric Models*. Johns Hopkins University Press.

Bickel, Peter J., Ya'acov Ritov, y Alexandre B. Tsybakov. 2009. «Simultaneous Analysis of Lasso and Dantzig Selector». *Annals of Statistics* 37 (4): 1705-32.

Borusyak, Kirill, Xavier Jaravel, y Jann Spiess. 2024. «Revisiting Event-Study Designs: Robust and Efficient Estimation». *Review of Economic Studies* 91 (6): 3253-85.

Breck, Eric, Shanqing Cai, Eric Nielsen, Michael Salib, y D. Sculley. 2017. «The ML Test Score: A Rubric for ML Production Readiness and Technical Debt Reduction». *IEEE International Conference on Big Data*,.

Callaway, Brantly, y Pedro H. C. Sant'Anna. 2021. «Difference-in-Differences with Multiple Time Periods». *Journal of Econometrics* 225 (2): 200-230.

Card, David. 1995. «Using Geographic Variation in College Proximity to Estimate the Return to Schooling». *Aspects of Labour Economics*, 201-22.

Chaisemartin, Clément de, y Xavier D'Haultfœuille. 2020. «Two-Way Fixed Effects Estimators with Heterogeneous Treatment Effects». *American Economic Review* 110 (9): 2964-96.

Chen, Huigang, Totte Harinen, Jeong-Yoon Lee, Mike Yung, y Zhenyu Zhao. 2020. «CausalML: Python Package for Causal Machine Learning». *arXiv preprint arXiv:2002.11631*,.

Chernozhukov, Victor, Denis Chetverikov, Mert Demirer, et al. 2018b. «Double/Debiased Machine Learning for Treatment and Structural Parameters». *The Econometrics Journal* 21 (1): C1-68.

Chernozhukov, Victor, Denis Chetverikov, Mert Demirer, Esther Duflo, Christian Hansen, y Whitney Newey. 2018a. «Applied Causal Inference Inspired by Machine Learning». *Working paper, MIT*,.

Chernozhukov, Victor, Carlos Cinelli, Whitney Newey, Amit Sharma, y Vasilis Syrgkanis. 2022b. «Long Story Short: Omitted Variable Bias in Causal Machine Learning». *NBER Working Paper 30302*,.

Chernozhukov, Victor, Mert Demir, Christian Hansen, y Nathan Kallus. 2020. «Generic Machine Learning Inference on Heterogeneous Treatment Effects in Randomized Experiments». *arXiv preprint arXiv:1712.04802*,.

Chernozhukov, Victor, Matt Goldman, y Matt Taddy. 2016. «Locally Robust Semiparametric Estimation». *arXiv preprint arXiv:1608.00033*,.

Chernozhukov, Victor, Whitney Newey, Víctor Quintas-Martínez, y Vasilis Syrgkanis. 2022a. «RieszNet and ForestRiesz: Automatic Debiased Machine Learning with Neural Nets and Random Forests». *Proceedings of the 39th International Conference on Machine Learning (ICML)*,.

Chickering, David Maxwell. 2002. «Optimal Structure Identification with Greedy Search». *Journal of Machine Learning Research* 3 : 507-54.

Chouldechova, Alexandra. 2017. «Fair Prediction with Disparate Impact: A Study of Bias in Recidivism Prediction Instruments». *Big Data* 5 (2): 153-63.

Cinelli, Carlos, y Chad Hazlett. 2020. «Making Sense of Sensitivity: Extending Omitted Variable Bias». *Journal of the Royal Statistical Society: Series B* 82 (1): 39-67.

Correa, Juan D., y Elias Bareinboim. 2020. «General Transportability of Soft Interventions: Completeness Results». *Advances in Neural Information Processing Systems 33 (NeurIPS)*,.

Crump, Richard K., V. Joseph Hotz, Guido W. Imbens, y Oscar A. Mitnik. 2009. «Dealing with Small Sample Sizes Complicating Causal Effect Estimation». *Biometrika* 96 (2): 257-79.

Curth, Alicia, y Mihaela van der Schaar. 2021. «On Inductive Biases for Heterogeneous Treatment Effect Estimation». *Advances in Neural Information Processing Systems 34 (NeurIPS)*,.

Dehejia, Rajeev H., y Sadek Wahba. 1999. «Causal Effects in Nonexperimental Studies: Reevaluating the Evaluation of Training Programs». *Journal of the American Statistical Association* 94 : 1053-62.

Doudchenko, Nikolay, y Guido W. Imbens. 2016. «Balancing, Regression, Difference-in-Differences and Synthetic Control Methods: A Synthesis». *NBER Working Paper 22791*,.

Dwork, Cynthia, Moritz Hardt, Toniann Pitassi, Omer Reingold, y Richard Zemel. 2012. «Fairness Through Awareness». *Proceedings of the 3rd Innovations in Theoretical Computer Science Conference (ITCS)*, 214-26.

Elwert, Felix, y Christopher Winship. 2014. «Endogenous Selection Bias: The Problem of Conditioning on a Collider Variable». *Annual Review of Sociology* 40 : 31-53.

Farrell, Max H., Tengyuan Liang, y Sanjog Misra. 2021. «Deep Neural Networks for Estimation and Inference». *Econometrica* 89 (1): 181-213.

Foster, Dylan J., y Vasilis Syrgkanis. 2019. «Orthogonal Statistical Learning». *arXiv preprint arXiv:1901.09036*,.

Freyaldenhoven, Simon, Christian Hansen, y Jesse M. Shapiro. 2019. «Pre-Event Trends in the Panel Event-Study Design». *American Economic Review* 109 : 3307-38.

Galesic, Mirta, y Rocio Garcia-Retamero. 2011. «Graph Literacy: A Cross-Cultural Comparison». *Medical Decision Making* 31 (3): 444-57.

Gebru, Timnit, Jamie Morgenstern, Briana Vecchione, et al. 2021. «Datasheets for Datasets». *Communications of the ACM* 64 (12): 86-92.

Geer, Sara van de, Peter Bühlmann, Ya'acov Ritov, y Ruben Dezeure. 2014. «On Asymptotically Optimal Confidence Regions and Tests for High-Dimensional Models». *Annals of Statistics* 42 (3): 1166-202.

Goodman-Bacon, Andrew. 2021. «Difference-in-Differences with Variation in Treatment Timing». *Journal of Econometrics* 225 (2): 254-77.

Gutierrez, Pierre, y Jean-Yves Gérardy. 2017. «Causal Inference and Uplift Modelling: A Review of the Literature». *CEUR Workshop Proceedings* 1846.

Hardt, Moritz, Eric Price, y Nathan Srebro. 2016. «Equality of Opportunity in Supervised Learning». *Advances in Neural Information Processing Systems 29 (NeurIPS)*,.

Hartford, Jason, Greg Lewis, Kevin Leyton-Brown, y Matt Taddy. 2017. «Deep IV: A Flexible Approach for Counterfactual Prediction». *Proceedings of the 34th International Conference on Machine Learning (ICML)*,.

Hastie, Trevor, Robert Tibshirani, y Martin Wainwright. 2015. *Statistical Learning with Sparsity: The Lasso and Generalizations*. CRC Press.

Hernán, Miguel A., y James M. Robins. 2020. *Causal Inference: What If*. Boca Raton: Chapman & Hall/CRC.

Hoerl, Arthur E., y Robert W. Kennard. 1970. «Ridge Regression: Biased Estimation for Nonorthogonal Problems». *Technometrics* 12 : 55-67.

Holland, Paul W. 1986. «Statistics and Causal Inference». *Journal of the American Statistical Association* 81 (396): 945-60.

Huang, Yimin, y Marco Valtorta. 2006. «Pearl's Calculus of Intervention Is Complete». *Proceedings of the 22nd Conference on Uncertainty in Artificial Intelligence (UAI)*,.

Huyen, Chip. 2022. *Designing Machine Learning Systems: An Iterative Process for Production-Ready Applications*. O'Reilly Media.

Imbens, Guido W. 2003. «Sensitivity to Exogeneity Assumptions in Program Evaluation». *Unpublished manuscript, Harvard University*,.

Imbens, Guido W., y Donald B. Rubin. 2015. *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press.

Kalisch, Markus, y Peter Bühlmann. 2007. «Estimating High-Dimensional Directed Acyclic Graphs with the PC-Algorithm». *Journal of Machine Learning Research* 8 : 613-36.

Kästner, Christian, Eunsuk Kang, y Michael Hilton. 2024. «Machine Learning in Production: From Models to Products». https://mlip-cmu.github.io/book/.

Kennedy, Edward H. 2023. «Towards Optimal Doubly Robust Estimation of Heterogeneous Causal Effects». *Electronic Journal of Statistics* 17 (2): 3008-49.

Kilbertus, Niki, Mateo Rojas-Carulla, Giambattista Parascandolo, Moritz Hardt, Dominik Janzing, y Bernhard Schölkopf. 2017. «Avoiding Discrimination through Causal Reasoning». *Advances in Neural Information Processing Systems 30 (NeurIPS)*,.

Kish, Leslie. 1965. *Survey Sampling*. Wiley.

Kitagawa, Toru, Shosei Sakaguchi, y Aleksey Tetenov. 2021. «Constrained Classification and Policy Learning». *arXiv preprint arXiv:2106.12886 (cemmap working paper CWP26/21)*,.

Kitagawa, Toru, y Aleksey Tetenov. 2018. «Who Should Be Treated? Empirical Welfare Maximization Methods for Treatment Choice». *Econometrica* 86 (2): 591-616.

Kleinberg, Jon, Jens Ludwig, Sendhil Mullainathan, y Ziad Obermeyer. 2015. «Prediction Policy Problems». *American Economic Review* 105 (5): 491-95.

Kleinberg, Jon, Sendhil Mullainathan, y Manish Raghavan. 2017. «Inherent Trade-Offs in the Fair Determination of Risk Scores». *8th Innovations in Theoretical Computer Science Conference (ITCS 2017)*,.

Künzel, Sören R., Jasjeet S. Sekhon, Peter J. Bickel, y Bin Yu. 2019. «Metalearners for Estimating Heterogeneous Treatment Effects Using Machine Learning». *Proceedings of the National Academy of Sciences* 116 (10): 4156-65.

Kusner, Matt J., Joshua Loftus, Chris Russell, y Ricardo Silva. 2017. «Counterfactual Fairness». *Advances in Neural Information Processing Systems 30 (NeurIPS)*,.

LaLonde, Robert J. 1986. «Evaluating the Econometric Evaluations of Training Programs with Experimental Data». *American Economic Review* 76 : 604-20.

Lee, Jason D., Dennis L. Sun, Yuekai Sun, y Jonathan E. Taylor. 2016. «Exact Post-Selection Inference, with Application to the Lasso». *Annals of Statistics* 44 (3): 907-27.

Leeb, Hannes, y Benedikt M. Pötscher. 2006. «Can One Estimate the Conditional Distribution of Post-Model-Selection Estimators?». *Econometric Theory* 24 (6): 1915-33.

Lei, Jing, Max G'Sell, Alessandro Rinaldo, Ryan J. Tibshirani, y Larry Wasserman. 2018. «Distribution-Free Predictive Inference Using Regression». *Journal of the American Statistical Association* 113 (523): 1094-111.

Lei, Jing, y Emmanuel J. Candès. 2021. «Conformal Inference of Counterfactuals and Individual Treatment Effects». *Annals of Statistics* 49 (6): 3346-69.

Lipsitch, Marc, Eric Tchetgen Tchetgen, y Ted Cohen. 2010. «Negative Controls: A Tool for Detecting Confounding and Bias in Observational Studies». *Epidemiology* 21 (3): 383-88.

Lipton, Zachary C. 2018. «The Mythos of Model Interpretability». *Communications of the ACM* 61 (10): 36-43.

Louizos, Christos, Uri Shalit, Joris M. Mooij, David Sontag, Richard Zemel, y Max Welling. 2017. «Causal Effect Inference with Deep Latent-Variable Models». *Advances in Neural Information Processing Systems 30 (NeurIPS)*,.

Lundberg, Scott M., y Su-In Lee. 2017. «A Unified Approach to Interpreting Model Predictions». *NeurIPS*,.

Machlanski, Damian, Spyridon Samothrakis, y Paul Clarke. 2024. «Robustness of Algorithms for Causal Structure Learning to Hyperparameter Choice». *arXiv preprint arXiv:2310.18212*,.

Manski, Charles F. 1990. «Nonparametric Bounds on Treatment Effects». *American Economic Review* 80 (2): 386-90.

Manski, Charles F. 2004. «Statistical Treatment Rules for Heterogeneous Populations». *Econometrica* 72 (4): 1221-46.

Mitchell, Margaret, Simone Wu, Andrew Zaldivar, et al. 2019. «Model Cards for Model Reporting». *Proceedings of the Conference on Fairness, Accountability, and Transparency (FAT*)*, 220-29.

Mullainathan, Sendhil, y Jann Spiess. 2017. «Machine Learning: An Applied Econometric Approach». *Journal of Economic Perspectives* 31 (2): 87-106.

Newey, Whitney K. 1994. «The Asymptotic Variance of Semiparametric Estimators». *Econometrica* 62 (6): 1349-82.

Neyman, Jerzy. 1923. «On the Application of Probability Theory to Agricultural Experiments». *Annals of Agricultural Sciences* 5 : 1-51.

Neyman, Jerzy. 1959. «Optimal Asymptotic Tests of Composite Statistical Hypotheses». *Probability and Statistics*, 213-34.

Nie, Xinkun, y Stefan Wager. 2021. «Quasi-Oracle Estimation of Heterogeneous Treatment Effects». *Biometrika* 108 (2): 299-319.

Oprescu, Miruna, Vasilis Syrgkanis, y Zhiwei Wu. 2023. «EconML Documentation». *Microsoft Research*,.

Paleyes, Andrei, Raoul-Gabriel Urma, y Neil D. Lawrence. 2022. «Challenges in Deploying Machine Learning: A Survey of Case Studies». *ACM Computing Surveys* 55 (6): 1-29.

Pearl, Judea. 2009. *Causality: Models, Reasoning and Inference*. 2.ª ed. Cambridge University Press.

Pearl, Judea. 2010. «On a Class of Bias-Amplifying Variables That Endanger Effect Estimates». *Proceedings of the 26th Conference on Uncertainty in Artificial Intelligence (UAI)*, 417-24.

Pearl, Judea, y Elias Bareinboim. 2011. «Transportability of Causal and Statistical Relations: A Formal Approach». *Proceedings of the 25th AAAI Conference on Artificial Intelligence*, 247-54.

Pearl, Judea, y Elias Bareinboim. 2014. «External Validity: From Do-Calculus to Transportability Across Populations». *Statistical Science* 29 (4): 579-95.

Pearl, Judea, y Dana Mackenzie. 2018. *The Book of Why. The New Science of Cause and Effect*. Basic Books.

Perdomo, Juan, Tijana Zrnic, Celestine Mendler-Dünner, y Moritz Hardt. 2020. «Performative Prediction». *Proceedings of the 37th International Conference on Machine Learning (ICML), PMLR 119*, 7599-609.

Plečko, Drago, y Elias Bareinboim. 2024. «Causal Fairness Analysis: A Causal Toolkit for Fair Machine Learning». *Foundations and Trends in Machine Learning* 17 (3): 304-589. https://doi.org/10.1561/2200000106.

Pötscher, Benedikt M., y Hannes Leeb. 2009. «On the Distribution of Penalized Estimators». *Statistics and Decisions* 27 : 1-30.

Radcliffe, Nicholas J. 2007. «Using Control Groups to Target on Predicted Lift: Building and Assessing Uplift Models». *Direct Marketing Analytics Journal*,.

Rambachan, Ashesh, y Jonathan Roth. 2023. «A More Credible Approach to Parallel Trends». *The Review of Economic Studies* 90 (5): 2555-91.

Recht, Benjamin, Maryam Fazel, y Pablo A. Parrilo. 2010. «Guaranteed Minimum-Rank Solutions of Linear Matrix Equations via Nuclear Norm Minimization». *SIAM Review* 52 (3): 471-501.

Reisach, Alexander G., Christof Seiler, y Sebastian Weichwald. 2021. «Beware of the Simulated DAG! Causal Discovery Benchmarks May Be Easy to Game». *Advances in Neural Information Processing Systems 34 (NeurIPS)*, 27772-84.

Robins, James M., Andrea Rotnitzky, y Lue Ping Zhao. 1994. «Estimation of Regression Coefficients When Some Regressors Are Not Always Observed». *Journal of the American Statistical Association* 89 : 846-66.

Robins, James M., y Andrea Rotnitzky. 1995. «Semiparametric Efficiency in Double Robustness Regression». *Journal of the American Statistical Association* 90 : 122-29.

Robinson, Peter M. 1988. «Root-N-Consistent Semiparametric Regression». *Econometrica* 56 (4): 931-54.

Romano, Yaniv, Evan Patterson, y Emmanuel J. Candès. 2019. «Conformalized Quantile Regression». *Advances in Neural Information Processing Systems 32 (NeurIPS)*,.

Rosenbaum, Paul R., y Donald B. Rubin. 1983. «The Central Role of the Propensity Score in Observational Studies for Causal Effects». *Biometrika* 70 (1): 41-55.

Rubin, Donald B. 1974. «Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies». *Journal of Educational Psychology* 66 (5): 688-701.

Rubin, Donald B. 1976. «Inference and Missing Data». *Biometrika* 63 (3): 581-92.

Rubin, Donald B. 2001. «Using Propensity Scores to Help Design Observational Studies: Application to the Tobacco Litigation». *Health Services and Outcomes Research Methodology* 2 : 169-88.

Rzepakowski, Piotr, y Szymon Jaroszewicz. 2012. «Decision Trees for Uplift Modeling with Single and Multiple Treatments». *Knowledge and Information Systems* 32 (2): 303-27.

Schuler, Alejandro, Ken Jung, Robert Tibshirani, Trevor Hastie, y Nigam Subramanian. 2018. «A Comparison of Methods for Model Selection When Estimating Individual Treatment Effects». *arXiv preprint arXiv:1804.05146*,.

Sculley, D., Gary Holt, Daniel Golovin, et al. 2015. «Hidden Technical Debt in Machine Learning Systems». *Advances in Neural Information Processing Systems 28 (NeurIPS)*,.

Shalit, Uri, Fredrik D. Johansson, y David Sontag. 2017. «Estimating Individual Treatment Effect: Generalization Bounds and Algorithms». *Proceedings of the 34th International Conference on Machine Learning (ICML)*,.

Sharma, Amit, y Emre Kiciman. 2020. «DoWhy: An End-to-End Library for Causal Inference». *GitHub repository, Microsoft Research*,.

Shi, Claudia, David Blei, y Victor Veitch. 2019. «Adapting Neural Networks for the Estimation of Treatment Effects». *NeurIPS*,.

Shpitser, Ilya, y Judea Pearl. 2006. «Identification of Joint Interventional Distributions in Recursive Semi-Markovian Causal Models». *Proceedings of the 21st National Conference on Artificial Intelligence (AAAI)*, 1219-26.

Simpson, Edward H. 1951. «The Interpretation of Interaction in Contingency Tables». *Journal of the Royal Statistical Society, Series B* 13 (2): 238-41.

Spiegelhalter, David. 2019. *The Art of Statistics: Learning from Data*. Pelican Books.

Spirtes, Peter, Clark Glymour, y Richard Scheines. 2000. *Causation, Prediction, and Search*. MIT Press.

Stock, James H., Jonathan H. Wright, y Motohiro Yogo. 2002. «A Survey of Weak Instruments and Weak Identification in Generalized Method of Moments». *Journal of the American Statistical Association* 97 (460): 518-29.

Stock, James H., y Motohiro Yogo. 2005. «Testing for Weak Instruments in Linear IV Regression». En *Identification and Inference for Econometric Models: Essays in Honor of Thomas Rothenberg*, editado por Andrews, Donald W. K., Stock, y James H. Cambridge University Press.

Sun, Liyang, y Sarah Abraham. 2021. «Estimating Dynamic Treatment Effects in Event Studies with Heterogeneous Treatment Effects». *Journal of Econometrics* 225 (2): 175-99.

Thornton, Rebecca L. 2008. «The Demand for, and Impact of, Learning HIV Status». *American Economic Review* 98 (5): 1829-63.

Tibshirani, Robert. 1996. «Regression Shrinkage and Selection via the Lasso». *Journal of the Royal Statistical Society: Series B* 58 (1): 267-88.

Tibshirani, Ryan J., Rina Foygel Barber, Emmanuel J. Candès, y Aaditya Ramdas. 2019. «Conformal Prediction Under Covariate Shift». *arXiv preprint arXiv:1904.06019*,.

VanderWeele, Tyler J., y Peng Ding. 2017. «Sensitivity Analysis in Observational Research: Introducing the E-Value». *Annals of Internal Medicine* 167 (4): 268-74.

Wager, Stefan, y Susan Athey. 2018. «Estimation and Inference of Heterogeneous Treatment Effects using Random Forests». *Journal of the American Statistical Association* 113 (523): 1228-42.

Yadlowsky, Steve, Scott Fleming, Nigam Shah, Emma Brunskill, y Stefan Wager. 2021. «Evaluating Treatment Prioritization Rules via Rank-Weighted Average Treatment Effects». *arXiv preprint arXiv:2111.00066*,.

Yule, G. Udny. 1903. «Notes on the Theory of Association of Attributes in Statistics». *Biometrika* 2 (2): 121-34.

Zhang, Baqun, Anastasios A. Tsiatis, Marie Davidian, Min Zhang, y Eric B. Laber. 2012. «Estimating Optimal Treatment Regimes from a Classification Perspective». *Stat* 1 (1): 103-14.

Zhang, Cun-Hui, y Stephanie S. Zhang. 2014. «Confidence Intervals for Low Dimensional Parameters in High Dimensional Linear Models». *Journal of the Royal Statistical Society: Series B* 76 (1): 217-42.

Zhang, Junzhe, y Elias Bareinboim. 2019. «Near-Optimal Reinforcement Learning in Dynamic Treatment Regimes». *Advances in Neural Information Processing Systems 32 (NeurIPS)*,.

Zhao, Peng, y Bin Yu. 2006. «On Model Selection Consistency of Lasso». *Journal of Machine Learning Research* 7 : 2541-63.

Zheng, Xun, Bryon Aragam, Pradeep Ravikumar, y Eric P. Xing. 2018. «DAGs with NO TEARS: Continuous Optimization for Structure Learning». *Advances in Neural Information Processing Systems 31 (NeurIPS)*,.

Zou, Hui, y Trevor Hastie. 2005. «Regularization and Variable Selection via the Elastic Net». *Journal of the Royal Statistical Society: Series B* 67 (2): 301-20.